

Claude Certified Architect — תעודת Foundations

מדריך לימוד (מבוסס על מדריך המבחן הרשמי)

הקדמה

(trade-off) מאשרת שמומחה מסוגל לקבל החלטות מאוזנות Claude Certified Architect — Foundations תעודת Claude. בעת מימוש פתרונות אמיתיים מבוססי (trade-off) Claude Code-המבחן בוחן ידע יסודי ב Claude Agent SDK-ב, Claude Code-המבחן בוחן ידע יסודי ב Claude. הטכנולוגיות המרכזיות לבניית אפליקציות פרודקשן עם — Model Context Protocol (MCP) וב Claude API-ב Claude.

לתמיכת לקוחות, תכנון (agentic) שאלות המבחן מבוססות על תרחישי תעשייה ריאליסטיים: בניית מערכות סוכן יצירת כלי פרודוקטיביות למפתחים, וחילוץ נתונים, Claude Code ב-CD/CI פייפליין מחקר רב-סוכני, אינטגרציה של מובנים ממסמכים לא-מובנים.

הפרופיל המבוקש

Claude. שמתכנן ומשגר אפליקציות פרודקשן עם (solution architect) המועמד האידיאלי הוא ארכיטקט פתרונות: רצויה לפחות חצי שנת ניסיון מעשי ב:

- Claude Agent SDK — hooks, אורקסטרציה רב-סוכנית, הענקת משימות לתת-סוכנים, אינטגרציית כלים — מחזור חיים
- Claude Code — CLAUDE.md, MCP, Agent Skills, שרתי, מצב תכנון (planning mode)
- Model Context Protocol (MCP) — backend-כלים ומשאבים לאינטגרציה אל ה
- הנדסת פרומפט — JSON schemas, few-shot, דוגמאות, תבניות לחילוץ נתונים
- עבודה עם מסמכים ארוכים, העברת הקשר רב-סוכני — (context window) חלון הקשר
- אוטומטי, יצירת בדיקות code review — CI/CD פייפליין
- human-in-the-loop, הסלמה ואמינות — טיפול בשגיאות

פורמט המבחן

פרמטר	ערך
סוג שאלה	בחירה מרובה (1 נכון מתוך 4)
ניקוד	סולם 100–1000, ציון עובר 720
עונש על ניחוש	אין (תענו על כל שאלה!)
תרחישים	מתוך 8 אפשריים (בחירה אקראית) 4

תוכן המבחן: 5 דומיינים

משקל	דומיין
27%	ארכיטקטורת סוכנים ואורקסטרציה
18%	MCP עיצוב כלים ואינטגרציית
20%	זרימות עבודה Claude Code הגדרות
20%	הנדסת פרומפט ופלט מובנה
15%	ניהול הקשר ואמינות

תרחישי המבחן

תרחיש 1: סוכן תמיכת לקוחות

הסוכן משתמש Claude Agent SDK-אתם בונים סוכן שמטפל בהחזרות, מחלוקות חיוב ובעיות חשבון תוך שימוש ב היעד הוא +80%. (`get_customer`, `lookup_order`, `process_refund`, `escalate_to_human`) MCP בכלי פתרון במגע ראשון עם הסלמה מתאימה.

Claude Code תרחיש 2: יצירת קוד עם

תיעוד. צריך לשלב פקודות, refactoring, debugging, להאצת פיתוח: יצירת קוד Claude Code-אתם משתמשים ב ולהבין מתי להשתמש במצב תכנון, CLAUDE.md מותאמות אישית והגדרות slash.

תרחיש 3: מערכת מחקר רב-סוכנית

סוכן מתאם מאציל משימות לתת-סוכנים מתמחים: מחקר אינטרנטי, ניתוח מסמכים, סינתזה, ויצירת דוחות. המערכת חייבת להפיק דוחות מלאים עם ציטוטים.

תרחיש 4: כלי פרודוקטיביות למפתחים

ולאוטומט משימות שגרתיות. נעשה שימוש boilerplate לא-מוכר, לייצר codebase הסוכן עוזר למהנדסים לחקור MCP ובשרתי (Read, Write, Bash, Grep, Glob) בכלים מובנים.

5 תרחיש: Claude Code ל-Continuous Integration

הפרומפטים חייבים. PR אוטומטי, יצירת בדיקות ופידבק על code review ל-CI/CD בפייפליין Claude Code שילוב false positives להיות מתוכננים למזער.

תרחיש 6: חילוץ נתונים מובנים

ושומרת על דיוק גבוה. עליה לטפל JSON schema המערכת מחלצת מידע ממסמכים לא-מובנים, מאמתת פלט מול נכון במקרי קצה.

שיחתי AI תרחיש 7: דפוסי ארכיטקטורת

אתם מתכננים מערכות שיחה רב-תורניות שמכסות ניהול חלון הקשר, התמדה של הוראות בין תורים, אסטרטגיות זיכרון, עיצוב כלים לביצוע בטוח, וטיפול בקלט משתמש דו-משמעי או סותר.

סוכניים (תוכן חסר — עזרו לנו להשלים!) AI תרחיש 8: כלי

תרחיש זה דווח על ידי נבחנים אך טרם כוסה במדריך. אם נתקלתם בשאלות מהתרחיש הזה במבחן האמיתי, שתפו [ב-GitHub Issues](#) כדי שנוסיף כיסוי מלא. התרומה שלכם תעזור לכל מי שמתכונן למבחן

תיעוד רשמי

משאב	כתובת
Claude API — Messages	https://platform.claude.com/docs/en/api/messages
Claude API — Tool Use	https://platform.claude.com/docs/en/build-with-claude/tool-use
Claude API — Message Batches	https://platform.claude.com/docs/en/build-with-claude/message-batches
Claude Agent SDK — Overview	https://platform.claude.com/docs/en/agent-sdk/overview
Claude Agent SDK — Hooks	https://platform.claude.com/docs/en/agent-sdk/hooks
Claude Agent SDK — Subagents	https://platform.claude.com/docs/en/agent-sdk/subagents
Claude Agent SDK — Sessions	https://platform.claude.com/docs/en/agent-sdk/sessions
Model Context Protocol (MCP)	https://modelcontextprotocol.io/
MCP — Tools	https://modelcontextprotocol.io/docs/concepts/tools
MCP — Resources	https://modelcontextprotocol.io/docs/concepts/resources
MCP — Servers	https://modelcontextprotocol.io/docs/concepts/servers
Claude Code — Documentation	https://code.claude.com/docs/en/overview
Claude Code — CLAUDE.md and Memory	https://code.claude.com/docs/en/memory
Claude Code — Skills (incl. slash commands)	https://code.claude.com/docs/en/skills
Claude Code — Hooks	https://code.claude.com/docs/en/hooks
Claude Code — Sub-agents	https://code.claude.com/docs/en/sub-agents
Claude Code — MCP Integration	https://code.claude.com/docs/en/mcp
Claude Code — GitHub Actions CI/CD	https://code.claude.com/docs/en/github-actions

Claude Code — GitLab CI/CD	https://code.claude.com/docs/en/gitlab-ci-cd
Claude Code — Headless (non-interactive mode)	https://code.claude.com/docs/en/headless
Prompt Engineering Guide	https://platform.claude.com/docs/en/build-with-claude/prompt-engineering/overview
Extended Thinking	https://platform.claude.com/docs/en/build-with-claude/extended-thinking
Anthropic Cookbook (code examples)	https://github.com/anthropics/anthropic-cookbook

יסודות תיאורטיים: חלק

חלק זה מכסה את כל התיאוריה שצריך לעבור בהצלחה את המבחן. החומר מאורגן לפי טכנולוגיות ומושגים ולא לפי דומינים — כך בונים הבנה עמוקה יותר של כל נושא.

יסודות אינטראקציה עם המודל — Claude API: פרק 1

תיעוד: [Messages API](#) | [Prompt Engineering](#)

API מבנה בקשת 1.1

כוללת Claude Messages API פועל על פי מודל בקשה-תגובה. כל בקשה ל Claude API-

```
{
  "model": "claude-sonnet-4-6",
  "max_tokens": 1024,
  "system": "You are a helpful assistant.",
  "messages": [
    { "role": "user", "content": "Hi!" },
    { "role": "assistant", "content": "Hello!" },
    { "role": "user", "content": "How are you?" }
  ],
  "tools": [...],
  "tool_choice": { "type": "auto" }
}
```

שדות מפתח:

- `model` — בחירת מודל (`claude-opus-4-6` , `claude-sonnet-4-6` , `claude-haiku-4-5`)
- `max_tokens` — מספר טוקנים מקסימלי בתגובה
- `system` — system prompt (מגדיר התנהגות המודל)

- `messages` — היסטוריית שיחה (חובה לשלוח את ההיסטוריה המלאה כדי לשמור על קוהרנטיות)
- `tools` — הגדרות הכלים הזמינים
- `tool_choice` — אסטרטגיית בחירת כלי

1.2 תפקידי הודעות (Message Roles)

משתמש בשלושה תפקידים `messages` -מערך ה:

- `user` — הודעות משתמש
- `assistant` — תגובות המודל (כלולות בשליחת היסטוריה)
- `tool` — התפקיד אינו מוגדר במפורש; זה מופיע כ) תוצאות קריאה לכלי — `tool_result` content block

בין בקשות — כל state חייבים לשלוח את כל היסטוריית השיחה. המודל לא שומר API חשוב במיוחד: בכל בקשת קריאה עצמאית.

1.3 בתגובה `stop_reason` השדה

שמציין מדוע המודל הפסיק לייצר `stop_reason` כוללת Claude API תגובת

ערך	תיאור	פעולה
"end_turn"	המודל סיים את תגובתו	הציגו תוצאה למשתמש
"tool_use"	המודל רוצה לקרוא לכלי	הריצו את הכלי והחזירו תוצאה
"max_tokens"	הגעתם לגבול טוקנים	התגובה קטומה; ייתכן שצריך להגדיל גבול
"stop_sequence"	stop sequence-נתקלתם ב	טפלו לפי לוגיקת האפליקציה

הם החשובים ביותר — הם שולטים בלולאת הסוכן "end_turn" ו- "tool_use" במערכות סוכן

1.4 System Prompt

הוא הוראה מיוחדת שמגדירה הקשר וכללי התנהגות. הוא system prompt-ה:

- `system` מועבר בנפרד בשדה `messages`; לא חלק ממערך ה
- בעדיפות גבוהה יותר מהודעות משתמש
- נטען פעם אחת וחל לאורך כל השיחה
- משמש להגדרת תפקיד, מגבלות ופורמט פלט

יכול ליצור אסוציאציות לא-רצויות לכלים. למשל, הוראה כמו "תאמת תמיד system prompt חשוב למבחן: ניסוח של גם כשזה לא נחוץ, `get_customer` -את הלקוח" עלולה לגרום למודל להשתמש יותר מדי ב

1.5 חלון הקשר (Context Window)

חלון ההקשר הוא הכמות הכוללת של טקסט (בטוקנים) שהמודל יכול לעבד בבת אחת. הוא כולל

- system prompt

- היסטוריית ההודעות המלאה
- הגדרות כלים
- תוצאות כלים

בעיות מפתח של חלון ההקשר

1. מודלים מעבדים מידע באמינות בהתחלה ובסוף של קלט ארוך, אבל עלולים לפספס **lost-in-the-middle אפקט**. פרטים באמצע. מיתון: מקמו מידע קריטי קרוב לתחילה או לסוף.
2. **הצטברות תוצאות כלי**: כל קריאה לכלי מוסיפה פלט להקשר. אם כלי מחזיר +40 שדות אבל רק 5 רלוונטיים — רוב ההקשר מבוזז.
3. **סיכום פרוגרסיבי**: בעת דחיסת היסטוריה, ערכים מספריים, אחוזים ותאריכים אובדים לעיתים והופכים מעורפלים ("בערך", "בקירוב", "כמה").

2 Tools - tool_use: פרק 2

תיעוד: Tool Use

2.1 מה זה tool_use

לקרוא לפונקציות חיצוניות. המודל לא מריץ קוד בעצמו — הוא מייצר Claude-הוא מנגנון שמאפשר ל tool_use בקשת קריאה מובנית; הקוד שלכם מריץ אותה ומחזיר את התוצאה.

2.2 הגדרת כלי

JSON schema כל כלי מוגדר באמצעות:

```
{
  "name": "get_customer",
  "description": "Finds a customer by email or ID. Returns the customer profile, including name, email, order history, and account status. Use this tool BEFORE lookup_order to verify the customer's identity. Accepts an email (format: user@domain.com) or a numeric customer_id.",
  "input_schema": {
    "type": "object",
    "properties": {
      "email": {"type": "string", "description": "Customer email"},
      "customer_id": {"type": "integer", "description": "Numeric customer ID"}
    },
    "required": []
  }
}
```

היבטים קריטיים של תיאור הכלי:

- בוחר כלים על בסיס התיאור שלהם. תיאורים מינימליים ("מאחזר LLM. התיאור הוא מנגנון הבחירה העיקרי. מידע לקוח") מובילים לטעויות כשכלים חופפים.
- כללו בתיאור:
 - מה הכלי עושה ומחזיר
 - פורמטי קלט וערכים לדוגמה
 - מקרי קצה ומגבלות
 - מתי להשתמש בכלי הזה לעומת חלופות דומות
- יש תיאורים `analyze_document` ו-`analyze_content` -הימנעו מתיאורים זהים או חופפים בין כלים. אם ל. כמעט זהים — המודל יבלבל ביניהם.
- עם MCP על פני כלי (Read, Grep) סוכנים עשויים להעדיף כלים מובנים: **MCP כלים מובנים מול כלי**. הדגישו יתרונות קונקרטיים, נתונים ייחודיים או הקשר: MCP פונקציונליות דומה. כדי למנוע — חזקו את תיאורי כלי שכלים מובנים לא יכולים לספק.

2.3 הפרמטר `tool_choice`

שולט באופן שבו המודל בוחר כלים `tool_choice`:

מתי להשתמש	התנהגות	ערך
ברירת מחדל לרוב המקרים	המודל מחליט אם לקרוא לכלי או לענות בטקסט	<code>{"type": "auto"}</code>
כשצריך פלט מובנה מובטח	המודל חייב לקרוא לאיזשהו כלי	<code>{"type": "any"}</code>
כשצריך לכפות צעד ראשון / סדר הפעלה	המודל חייב לקרוא לכלי ספציפי	<code>{"type": "tool", "name": "extract_metadata"}</code>

תרחישים חשובים:

- מספר כלי חילוץ → המודל בוחר את המתאים ביותר אבל אתם עדיין מקבלים פלט + `tool_choice: "any"` מובנה
- (לפני העשרה `extract_metadata` למשל) בחירה כפויה → כשחייבים להבטיח פעולה ראשונה מסוימת

2.4 לפלט מובנה JSON Schemas

הוא Claude-הוא הדרך **האמינה ביותר** לקבל פלט מובנה מ JSON schemas עם `tool_use` -שימוש ב

- תקין מבחינה תחבירית (אין סוגריים חסרים, פסיקים מיותרים) JSON מבטיח
- (נוכחים `required` שדות) אוכף את המבנה הנדרש
- לא** מבטיח נכונות סמנטית (ערכים עדיין יכולים להיות שגויים)

עיצוב סכמה — עקרונות מפתח

```
{
  "type": "object",
  "properties": {
    "category": {
      "type": "string",
      "enum": ["bug", "feature", "docs", "unclear", "other"]
    },
    "category_detail": {
      "type": ["string", "null"],
      "description": "Details if category = 'other' or 'unclear'"
    },
    "severity": {
      "type": "string",
      "enum": ["critical", "high", "medium", "low"]
    },
    "confidence": {
      "type": "number",
      "minimum": 0,
      "maximum": 1
    },
    "optional_field": {
      "type": ["string", "null"],
      "description": "Null if the information was not found in the source"
    }
  },
  "required": ["category", "severity"]
}
```

כללי עיצוב סכמה

- Required מול optional:** דוחפים את המודל required רק אם המידע תמיד זמין. שדות required-סמנו שדות כ: **Required**. לבדוד ערכים כשהמידע חסר.
- nullable שדות:** למידע שעלול להיות חסר. המודל יכול להחזיר `"type": ["string", "null"]` -השתמשו ב: `null` במקום להזות `null`.
- Enums עם "other":** שדה פירוט כדי לא לאבד נתונים מחוץ לקטגוריות שהגדרתם + `"other"` הוסיפו: `"other"` עם `Enum` מראש.
- Enum "unclear":** כן הוא טוב יותר `"unclear"` — למקרים שבהם המודל לא יכול לבחור קטגוריה בביטחון: `"unclear"` Enum. מקטגוריה שגויה.

שגיאות תחביריות מול סמנטיות 2.5

סוג שגיאה	דוגמה	מיתון
תחבירית	לא תקין, סוג שדה שגוי JSON	(מבטל) JSON schema עם <code>tool_use</code>
סמנטית	סכומים לא מסתכמים, ערך בשדה לא נכון, הדיה	retry-with-feedback, self-correction, בדיקות אימות

בניית מערכות סוכן — Claude Agent SDK: פרק 3

תיעוד: [Agent SDK](#) | [Hooks](#) | [Subagents](#) | [Sessions](#)

3.1 מהי לולאת סוכן (Agentic Loop)

לולאת הסוכן היא הדפוס הליבתי לביצוע משימות אוטונומיות. המודל לא רק עונה — הוא מבצע רצף פעולות:

- עם כלים Claude-שלחו בקשה ל.
- קבלו תגובה.
- בדקו `stop_reason`:
 - `"tool_use"` -> צרפו תוצאה להיסטוריה, חזרו לצעד 1
 - `"end_turn"` -> המשימה הושלמה, הציגו תוצאה למשתמש
- חזרו עד להשלמה.

מחליט באיזה כלי לקרוא בא הלאה על בסיס הקשר ותוצאות קודמות. שונה Claude **model-driven**: זוהי גישה מעצי החלטה מקודדים-קשיחים שבהם הרצף קבוע מראש.

אנטי-פטרנים (להימנע):

- "Task completed" כדי לזהות סיום assistant-ניתוח טקסט של ה.
- כתנאי עצירה ראשי (`max_iterations=5`) שימוש בגבול איטרציות שרירותי.
- ייצר תוכן טקסטואלי כאות סיום assistant-בדיקה אם ה.

. `stop_reason == "end_turn"` **גישה נכונה**: הסימן האמין היחיד לסיום הוא

3.2 הגדרת AgentDefinition

Claude Agent SDK-הוא אובייקט הגדרת הסוכן ב `AgentDefinition`:


```
agent = AgentDefinition(
    name="customer_support",
    description="Handles customer requests for returns and order issues",
    system_prompt="You are a customer support agent...",
    allowed_tools=["get_customer", "lookup_order", "process_refund",
"escalate_to_human"],
    # For a coordinator:
    # allowed_tools=["Task", "get_customer", ...]
)
```

פרמטרים מרכזיים:

- `name` / `description` — זיהוי ותיאור הסוכן
- `system_prompt` — system prompt עם הוראות
- `allowed_tools` — רשימת הכלים המותרים (עקרון הרשאה מינימלית)

3.3 Hub-and-Spoke: מתאם ותת-סוכנים

hub-and-spoke: ארכיטקטורה רב-סוכנית בדרך כלל בנויה כטופולוגיית



המתאם אחראי על:

- פירוק המשימה לתת-משימות
- החלטה אילו תת-סוכנים נדרשים (בחירה דינמית)
- האצלת עבודה לתת-סוכנים
- צבירה ואימות תוצאות
- retries-טיפול בשגיאות ו
- העברת תוצאות למשתמש

עקרון קריטי: לתת-סוכנים יש הקשר מבודד.

- תת-סוכנים אינם יורשים אוטומטית את היסטוריית השיחה של המתאם
- כל ההקשר הנדרש חייב להיות מועבר במפורש בפרומפט של תת-הסוכן
- תת-סוכנים לא חולקים זיכרון בין קריאות
- כל התקשורת זורמת דרך המתאם (לצורך תצפיתיות ובקרת שגיאות)

3.4 ליצירת תת-סוכנים Task הכלי

Task: תת-סוכנים נוצרים דרך הכלי

```
# The coordinator's allowedTools must include "Task"
coordinator_agent = AgentDefinition(
    allowed_tools=["Task", "get_customer"]
)
```

העברת הקשר מפורשת היא חובה:

```
# Bad: the subagent has no context
Task: "Analyze the document"

# Good: full context in the prompt
Task: "Analyze the following document.
Document: [full document text]
Prior search results: [web search results]
Output format requirements: [schema]"
```

ים בתגובה אחת — תת-הסוכנים רצים במקביל- Task הפעלה מקבילית: מתאם יכול לקרוא למספר

```
# One coordinator response contains:
Task 1: "Search for articles about X"
Task 2: "Analyze document Y"
Task 3: "Search for articles about Z"
# All three run concurrently
```

3.5 Hooks ב-Agent SDK

מאפשרים ירוט וטרנספורמציה בנקודות ספציפיות במחזור החיים של הסוכן Hooks.

מיירט תוצאת כלי לפני שהיא מועברת למודל **PostToolUse**:

```
# Example: normalize date formats from different MCP tools
@hook("PostToolUse")
def normalize_dates(tool_result):
    # Convert Unix timestamp -> ISO 8601
    # Convert "Mar 5, 2025" -> "2025-03-05"
    return normalized_result
```

ליירוט קריאות יוצאות חוסם פעולות שמפרות מדיניות **Hook**:

```
# Example: block refunds above $500
@hook("PreToolUse")
def enforce_refund_limit(tool_call):
    if tool_call.name == "process_refund" and tool_call.args.amount > 500:
        return redirect_to_escalation(tool_call)
```

מול הוראות בפרומפט **hooks**: הבדל מרכזי

תכונה	Hooks	הוראות בפרומפט
הבטחה	דטרמיניסטית (100%)	הסתברותית (<90%, לא 100%)
מתי להשתמש	compliance, כללי עסק קריטיים, פעולות פיננסיות	העדפות כלליות, המלצות, פורמט
דוגמה	חסום החזרים < 500\$	"נסה לפתור לפני הסלמה"

לא בפרומפטים, **hooks-כלל**: כששגיאה יוצרת תוצאות פיננסיות, משפטיות או בטיחותיות — השתמשו ב

פרק 4: Model Context Protocol (MCP)

4.1 מה זה MCP

Model Context Protocol (MCP) הוא פרוטוקול פתוח לחיבור מערכות חיצוניות ל Claude. MCP סוגי שלושה מגדיר: משאבים עיקריים:

1. **Tools** — (הרצת פקודות, API קריאות, CRUD) פונקציות שהסוכן יכול לקרוא להן כדי לבצע פעולות
2. **Resources** — (קטלוגי תוכן, DB תיעוד, סכמות) נתונים שהסוכן יכול לקרוא להקשר
3. **Prompts** — תבניות פרומפט מוגדרות מראש למשימות נפוצות

4.2 שרתי MCP

MCP כשמתחברים לשרת tools/resources ומספק MCP הוא תהליך שמממש את פרוטוקול MCP שרת:

- כל הכלים מתגלים אוטומטית
- כלים מכל השרתים המחוברים זמינים בו-זמנית
- תיאורי הכלים קובעים איך המודל ישתמש בהם

4.3 הגדרת שרתי MCP

לשימוש צוותי — (`.mcp.json`) הגדרת פרויקט:

```
{
  "mcpServers": {
    "github": {
      "command": "npx",
      "args": ["-y", "@modelcontextprotocol/server-github"],
      "env": {
        "GITHUB_TOKEN": "${GITHUB_TOKEN}"
      }
    },
    "jira": {
      "command": "npx",
      "args": ["-y", "mcp-server-jira"],
      "env": {
        "JIRA_TOKEN": "${JIRA_TOKEN}"
      }
    }
  }
}
```

נקודות מפתח:

- VCS-נשמר בשורש הפרויקט ומנוהל ב `.mcp.json`
- משמשים לסודות — הטוקנים עצמם לא מוקמטים (`${GITHUB_TOKEN}`) משתני סביבה
- זמין לכל תורמי הפרויקט

לשרתים אישיים/ניסיוניים — (`~/.claude.json`) הגדרת משתמש:

- של המשתמש home directory-נשמר ב

- VCS לא משותף דרך
- מתאים לניסיונות אישיים ובדיקות

בחירת שרתים:

- קהילתיים קיימים MCP העדיפו שרתי — (Jira, GitHub, Slack) לאינטגרציות סטנדרטיות
- בנו שרתים משלכם רק לזרימות עבודה ייחודיות וצוותיות

4.4 הדגל MCP ב-`isError`

בתגובה. זה מסמן לסוכן שהקריאה נכשלה `isError: true` -נתקל בשגיאה, הוא משתמש ב MCP כשכלי

שגיאה מובנית (טוב):

```
{
  "isError": true,
  "content": {
    "errorCategory": "transient",
    "isRetryable": true,
    "message": "The service is temporarily unavailable. Timeout while calling the orders API.",
    "attempted_query": "order_id=12345",
    "partial_results": null
  }
}
```

שגיאה גנרית (אנטי-פטרן):

```
{
  "isError": true,
  "content": "Operation failed"
}
```

שגיאה גנרית לא נותנת לסוכן שום מידע להחלטה — האם לנסות שוב, לשנות שאילתה או להסלים?

4.5 MCP Resources

הם נתונים שסוכן יכול לבקש כדי לקבל הקשר בלי לבצע פעולות Resources:

- קטלוגי תוכן (למשל רשימת כל משימות הפרויקט, ניווט היררכי)
- סכמות מסד נתונים (הבנת מבנה הנתונים)
- (מדריכים פנימיים, API references) תיעוד
- issue/task סיכומי

מספק "מפה" Resource. הסוכן לא צריך קריאות כלי חקרניות כדי להבין אילו נתונים קיימים **Resources יתרון**. מיידית.

הגדרות וזרימות עבודה — Claude Code: פרק 5

תיעוד: [Claude Code](#) | [Memory / CLAUDE.md](#) | [Skills](#) | [MCP](#) | [Hooks](#) | [Sub-agents](#) | [GitHub Actions](#) | [Headless](#)

5.1 CLAUDE.md ההיררכיה של

יש היררכיה תלת-שכבתית. Claude Code הוא קובץ/קבצי ההוראות ל CLAUDE.md:

1. רמת משתמש: `~/.claude/CLAUDE.md`
 - חל רק על המשתמש הזה
 - VCS לא משותף דרך
 - העדפות אישיות וסגנון עבודה
2. בשורש CLAUDE.md או `.claude/CLAUDE.md`: רמת פרויקט
 - חל על כל תורמי הפרויקט
 - VCS מנוהל דרך
 - סטנדרטי קוד, סטנדרטי בדיקה, החלטות ארכיטקטוניות
3. בתת-תיקיות CLAUDE.md: רמת תיקייה
 - חל בעת עבודה עם קבצים בתיקייה
 - codebase-מוסכמות ספציפיות לחלק זה של ה

(רמת משתמש) `~/.claude/CLAUDE.md` - **טעות נפוצה:** חבר צוות חדש לא מקבל הוראות פרויקט כי הן הושמו ב `.claude/CLAUDE.md` (רמת פרויקט) - במקום ב

5.2 (יבוא קבצים) @path תחביר

מה שהופך את ההגדרה למודולרית, @path יכול להתייחס לקבצים חיצוניים באמצעות CLAUDE.md:

```
# Project CLAUDE.md
```

```
Coding standards are described in @./standards/coding-style.md
Test requirements are in @./standards/testing-requirements.md
Project overview is in @README.md and dependencies are in @package.json
```

כללי @path:

- השתמשו ב-@ מיד לפני נתיב הקובץ (בלי רווח)
- נתמכים נתיבים יחסיים ומוחלטים
- נתיבים יחסיים נפתרים יחסית לקובץ שמכיל את היבוא
- עומק קינון מקסימלי של יבוא הוא 5

זה מונע כפילויות ומאפשר לכל חבילה לכלול רק סטנדרטי רלוונטיים.

5.3 התיקיה `.claude/rules/`

מונוליטי, לארגון כללים לפי נושא CLAUDE.md היא חלופה ל `.claude/rules/`.

```
.claude/rules/
testing.md          -- testing conventions
api-conventions.md  -- API conventions
deployment.md       -- deployment rules
react-patterns.md   -- React patterns
```

לטעינה מותנית `paths` עם `YAML frontmatter`: תכונה מרכזית:

```
---
paths: ["src/api/**/*.js"]
---
```

For API files, use `async/await` with explicit error handling.
Each endpoint must return a standard response wrapper.

```
---
paths: ["**/*.test.tsx", "**/*.test.ts"]
---
```

Tests must use `describe/it` blocks.
Use data factories instead of hardcoding.
Do not mock the database—use a test database.

איך זה עובד:

- עורך קובץ שמתאים לתבנית Claude Code כלל נטען רק כש `paths`
- זה חוסך הקשר וטוקנים — כללים לא-רלוונטיים לא נטענים
- מאפשרות להחיל מוסכמות לפי סוג קובץ ללא תלות במיקום (אידיאלי לבדיקות פזורות) `glob` תבניות

ברמת תיקייה `CLAUDE.md` לעומת `paths` עם `.claude/rules/` -מתי להשתמש ב:

- `(tests, migrations)` כשמוסכמות חלות על קבצים פזורים בהרבה תיקיות — עם `paths` `.claude/rules/`
- ברמת תיקייה — כשמוסכמות קשורות לתיקיה ספציפית ולא נחוצות במקום אחר `CLAUDE.md`

5.4 Custom Slash Commands ו-Skills

(`.claude/commands/`) פקודות מותאמות אישית, Claude Code, הערה: בגרסה הנוכחית של מדריך המבחן `/name` שני הפורמטים יוצרים פקודות (`.claude/skills/`) `skills` מאוחדות עם הפורמט הזה עדיין נתמך — `.claude/commands/` -מתייחס ל

: `/name` הן תבניות פרומפט הניתנות לשימוש חוזר שמופעלות דרך `Slash commands`

(`legacy`, נתמך, `.claude/commands/`) פורמט:

```
.claude/commands/  
review.md          -- /review -- standard code review  
test-gen.md        -- /test-gen -- test generation
```

פורמט `.claude/skills/` (נוכחי):

```
.claude/skills/  
review/SKILL.md    -- /review -- with frontmatter configuration  
test-gen/SKILL.md
```

פקודות פרויקט (`.claude/commands/` או `.claude/skills/`):

- של הריפו clone וזמינות לכולם בעת VCS-נשמרות ב
- מבטיחות זרימות עבודה עקביות בכל הצוות

פקודות משתמש (`~/.claude/commands/` או `~/.claude/skills/`):

- VCS פקודות אישיות שלא משותפות דרך
- לזרימות עבודה אינדיבידואליות

5.5 Skills — `.claude/skills/`

Skills של frontmatter הן פקודות מתקדמות שמוגדרות דרך SKILL.md:

```
---  
context: fork  
allowed-tools: ["Read", "Grep", "Glob"]  
argument-hint: "Path to the directory to analyze"  
---  
  
Analyze the code structure in the specified directory.  
Output a report on dependencies and architectural patterns.
```

Frontmatter פרמטרי:

פרמטר	תיאור
<code>context: fork</code>	לא מזהם את הסשן הראשי verbose בתת-סוכן מבודד. פלט skill-מריץ את ה
<code>allowed-tools</code>	(לא יכול למחוק קבצים אם לא הותר skill-אבטחה — למשל ה) מגביל אילו כלים זמינים
<code>argument-hint</code>	רמז שמבקש ארגומנט בעת הפעלה ללא פרמטרים

CLAUDE.md לעומת skill מתי:

- Skill** — (ניתוח, יצירה, review) למשימה ספציפית on-demand הפעלה —
- CLAUDE.md** — סטנדרטי ומוסכמות כלליים שטעונים תמיד

Skills אישיים (`~/.claude/skills/`):

- צרו ואריאנטים אישיים בשמות שונים כדי לא להשפיע על חברי הצוות

לעומת ביצוע ישיר (Planning Mode) מצב תכנון 5.6

מצב תכנון:

- המודל רק חוקר ומתכנן; לא מבצע שינויים
- codebase כדי לחקור את ה Read, Grep, Glob-משתמש ב
- מייצר תוכנית מימוש שהמשתמש מאשר
- חקירה בטוחה בלי תופעות לוואי

מתי להשתמש במצב תכנון:

- שינויים גדולים (עשרות קבצים)
- (?איך להגדיר גבולות: microservices) מספר גישות סבירות
- (?איזה מבנה? framework איזה) החלטות ארכיטקטוניות
- לא מוכר (חייבים להבין לפני שמשנים) codebase
- מיגרציות ספרייה שמשפיעות על +45 קבצים

מתי להשתמש בביצוע ישיר:

- ברור stack trace תיקון בקובץ יחיד עם
- בודדת validation הוספת בדיקת
- שינויים מובנים היטב ולא דו-משמעיים

גישה משולבת:

- מצב תכנון לחקירה ועיצוב
- המשתמש מאשר את התוכנית
- ביצוע ישיר ליישום התוכנית המאושרת

codebase-תת-סוכן מתמחה לחקירת ה Explore subagent:

- מההקשר הראשי verbose מבודד פלט
- מחזיר רק סיכום
- מונע אזילת חלון הקשר במשימות רב-שלביות

5.7 הפקודה /compact

היא פקודה מובנית לדחיסת הקשר /compact:

- מסכמת היסטוריה קודמת כדי לפנות חלון הקשר
- verbose משמשת בסשני חקירה ארוכים שבהם ההקשר מתמלא בפלט כלי
- סיכון: ערכים מספריים מדויקים, תאריכים ופרטים ספציפיים עלולים ללכת לאיבוד בסיכום

5.8 הפקודה /memory

היא פקודה מובנית לניהול זיכרון בין סשנים /memory:

- לעריכה, מאפשרת לשמור הערות, העדפות והקשר CLAUDE.md פותחת את הקובץ
- מידע נמשך בין סשנים ונטען אוטומטית בהפעלה

- שימושית לשמירת מוסכמות פרויקט, העדפות משתמש, פקודות בשימוש תכוף, והקשר עבודה נוכחי
- חלופה להסבר חוזר של אותן הוראות בכל ששן

5.9 Claude Code CLI ל-CI/CD

הדגל `-p` (או `--print`):

```
claude -p "Analyze this pull request for security issues"
```

- יוצא, stdout-מצב לא-אינטראקטיבי: מעבד את הפרומפט, מדפיס ל
- לא מחכה לקלט משתמש
- CI/CD בפייפליין Claude הדרך הנכונה היחידה להריץ

ל-CI-פלט מובנה

```
claude -p "Review this PR" --output-format json --json-schema  
'{"type":"object",...}'
```

- `--output-format json` — JSON-פלט ב
- `--json-schema` — אימות פלט מול סכמה
- אוטומטית PR-על ה inline ניתן לפרסר את התוצאה כדי לפרסם הערות

שייצר קוד הוא לרוב פחות אפקטיבי בסקירתו (המודל שומר את הקשר Claude **בידוד הקשר של ששן**: אותו ששן review-עצמאי ל instance-השיקול שלו ופחות סביר שיאתגר את ההחלטות של עצמו). השתמשו ב

הקודמות בהקשר והנחו review-אחרי קומיטים חדשים, כללו את תוצאות ה re-review **מניעת הערות כפולות**: בעת לדווח רק על בעיות חדשות או לא-פתורות Claude את


5.10 `fork_session` וניהול ששנים

ממשיך ששן בעל שם `--resume <session-name>`:

```
claude --resume investigation-auth-bug
```

- ממשיך שיחה קודמת עם הקשר שמור
- שימושי לחקירות ארוכות שמתפרסות על מספר ששנים
- סיכון: אם קבצים השתנו מאז הסשן הקודם, תוצאות הכלים עלולות להיות מיושנות

יוצר סניף עצמאי מהקשר משותף `fork_session`:



- יורשים הקשר עד נקודת ההסתעפות forks-שני ה
- אחרי כן הם מתפצלים עצמאית
- שימושי להשוואת גישות או בדיקת אסטרטגיות

מתי להתחיל סשן חדש במקום להמשיך:

- תוצאות הכלים מיושנות (קבצים השתנו)
- עבר הרבה זמן וההקשר ירד באיכותו
- עדיף להתחיל מחדש עם "הנה סיכום קצר של מה שמצאנו: ..." במקום להמשיך עם נתוני כלי ישנים

פרק 6: הנדסת פרומפט — טכניקות מתקדמות

תיעוד: [Prompt Engineering](#) | [Anthropic Cookbook](#)

6.1 Few-shot Prompting

הוא הכללה של 2-4 דוגמאות קלט/פלט בפרומפט כדי להדגים את ההתנהגות הצפויה Few-shot prompting.

אפקטיבי יותר מתיאורים טקסטואליים few-shot למה:

- הוראה מעורפלת כמו "תהיה מדויק יותר" יכולה להתפרש בהרבה דרכים
- דוגמה מראה באופן חד-משמעי את הפורמט הצפוי ולוגיקת ההחלטה
- המודל מכליל את הדפוס למקרים חדשים (הוא לא רק חוזר על הדוגמאות)

ומתי להשתמש בהן few-shot סוגי דוגמאות:

1. **דוגמאות לתרחישים דו-משמעיים:**

```
Request: "My order is broken"
Action: Call get_customer -> lookup_order -> check status.
Rationale: "broken" may mean a damaged item; you need order details.
```

```
Request: "Get me a manager"
Action: Immediately call escalate_to_human.
Rationale: The customer explicitly requests a human. Do not attempt to solve autonomously.
```

2. **דוגמאות לפורמט פלט:**

Finding example:

```
{
  "location": "src/auth/login.ts:42",
  "issue": "SQL injection in the username parameter",
  "severity": "critical",
  "suggested_fix": "Use a parameterized query"
}
```

3. דוגמאות להפרדת קוד מקובל מקוד בעייתי:

```
// Acceptable (do not flag):
const items = data.filter(x => x.active);

// Problem (flag):
const items = data.filter(x => x.active == true); // Use strict equality ===
```

4. דוגמאות לחילוף מפורמטי מסמכים שונים:

Document with inline citations:

"As shown in the study (Smith, 2023), the rate is 42%."

-> {"value": "42%", "source": "Smith, 2023", "type": "inline_citation"}

Document with bibliography references:

"The rate is 42%. [1]"

-> {"value": "42%", "source": "reference_1", "type": "bibliography"}

5. דוגמאות למדידות לא-פורמליות:

Text: "about two handfuls of rice"

-> {"amount": "~100g", "original_text": "two handfuls", "precision": "approximate"}

Text: "a pinch of salt"

-> {"amount": "~1g", "original_text": "a pinch", "precision": "approximate"}

אפקטיבי במיוחד לחילוף יחידות מדידה לא-פורמליות ולא-סטנדרטיות, שמגוונות מדי לכללים בלבד Few-shot.

מחמירים לפלט מובנה, הוסיפו כללי JSON schemas-כללי נורמליזציה פורמט בפרומפט: בעת שימוש ב נורמליזציה בפרומפט:

Normalization:

- Dates: always ISO 8601 (YYYY-MM-DD); "yesterday" -> compute an absolute date
- Currency: numeric amount + currency code; "five bucks" -> {"amount": 5, "currency": "USD"}
- Percentages: decimal fraction; "half" -> 0.5

תקין תחבירית אבל הערכים לא עקביים JSON-זה מונע שגיאות סמנטיות שבהן ה

קריטריונים מפורשים לעומת הוראות מעורפלות 6.2

רע (מעורפל):

Check code comments for accuracy.
Be conservative—report only high-confidence findings.

טוב (קריטריונים מפורשים):

Flag a comment as problematic ONLY if:

1. The comment describes behavior that CONTRADICTS the actual code behavior
2. The comment references a non-existent function or variable
3. A TODO/FIXME comment refers to a bug that has already been fixed in code

Do NOT flag:

- Comments that are merely stylistically outdated
- Comments with minor wording inaccuracies
- Missing comments (that is a separate category)

הגדירו קריטריוני חומרה עם דוגמאות:

CRITICAL: Runtime failure for users
Example: NullPointerException while processing a payment

HIGH: Security vulnerability
Example: SQL injection, XSS, missing authorization checks

MEDIUM: Logic bug without immediate impact
Example: Wrong sorting, off-by-one error

LOW: Code quality
Example: Duplication, suboptimal algorithm for small data

6.3 Prompt Chaining

מפרק משימה מורכבת לרצף שלבים ממוקדים

Step 1: Analyze auth.ts (local issues only)
-> Output: list of issues in auth.ts

Step 2: Analyze database.ts (local issues only)
-> Output: list of issues in database.ts

Step 3: Integration pass (cross-file dependencies)
-> Output: issues at module boundaries

למה זה חשוב:

- מונע דילול תשומת לב — כשהמודל מקבל יותר מדי קבצים בבת אחת, הוא עלול לפספס באגים בחלקם ולתת הערות שטחיות על אחרים
- מבטיח איכות ניתוח עקבית לכל קובץ
- מאפשר ניתוח נפרד של אינטראקציות בין-קבצים

dynamic decomposition לעומת prompt chaining מתי

- **Prompt chaining** — משימות צפויות וחזרתיות (code review, קבצים, מיגרציות)
- **Dynamic decomposition** — חקירות פתוחות שבהן תת-המשימות מתבהרות רק במהלך הביצוע

6.4 "Interview"-דפוס ה

שואל שאלות הבהרה Claude, לפני יישום פתרון:

Claude: "Before implementing caching for the API, a few questions:
 1. Which cache invalidation strategy do you prefer—TTL or event-based?
 2. Is stale data acceptable when the cache is unavailable?
 3. Should caching be per-user or global?
 4. What is the expected data volume to cache?"

מתי זה שימושי:

- (מערכות משפטיות, fintech, healthcare) דומיין לא מוכר
- (מצבי כשל, cache אסטרטגיות) משימות עם השלכות לא-מובנות
- מספר גישות סבירות שבחירת הטובה תלויה בהקשר

6.5 Validation I-Retry-with-Feedback

כשנתונים מחולצים נכשלים באימות:

Step 1: Extract data from the document
 Step 2: Validate (Pydantic, JSON Schema, business rules)
 Step 3: If there's an error—retry with context:
 - The original document
 - The previous (incorrect) extraction
 - The specific error: "Field 'total' = 150, but sum(line_items) = 145. Re-check values."

יהיה אפקטיבי retry מתי:

- שגיאות פורמט (תאריך בפורמט שגוי)
- שגיאות מבניות (שדה ממוקם במקום הלא נכון)
- אי-עקביות אריתמטיות (המודל יכול לבדוק מחדש)

לא יעזור retry מתי:

- המידע לא קיים במסמך המקור
- ההקשר הנדרש חיצוני (הנתונים במסמך אחר שלא סופק)

לאימות נתונים מבוסס-סכמה. למבחן, הנקודות החשובות Python היא ספריית Pydantic: **ככלי אימות Pydantic**

- Claude מ-JSON נבדקות בקוד אחרי קבלת enum מגבלות, requiredness, **אימות מבני:** סוגים
- **אימות סמנטי:** validators עסקית (לוגיקה אכופים מותאמים לסך הכל) start_date < end_date)
- עם הקשר השגיאה Claude-בנו הודעת שגיאה וקראו שוב ל Pydantic, עם כשל אימות: **validate-retry לולאות**

- **JSON Schema יצירת:** מספקים מקור אמת, `tool_use` ל-JSON Schema יכולים לייצר Pydantic מודלים של `JSON Schema` יחיד

6.6 Self-correction

דפוס לזיהוי סתירות פנימיות:

```
{
  "stated_total": "$150.00",
  "calculated_total": "$145.00",
  "conflict_detected": true,
  "line_items": [
    {"name": "Widget A", "price": 75.00},
    {"name": "Widget B", "price": 70.00}
  ]
}
```

מאפשר לטפל באי-`conflict_detected`, המודל מחלץ גם את הערך המוצהר וגם ערך מחושב — אם הם שונים התאמה.

7 Message Batches API: פרק 7

Message Batches תיעוד:

7.1 סקירה

של בקשות לעיבוד אסינכרוני batch מאפשר לכם להגיש Message Batches API-

תכונה	ערך
חיסכון	לעומת קריאות סינכרוניות 50%
חלון עיבוד	(לאיחור SLA אין הבטחת) עד 24 שעות
Multi-turn tool calling	לא נתמך (בקשה אחת = תגובה אחת)
קישור	לקישור בין בקשה לתגובה <code>custom_id</code> שדה

7.2 Synchronous API לעומת Batch API מתי

משימה	API	למה
merge לפני PR בדיקת	Synchronous	המפתח מחכה; 24 שעות לא מקובל

לילה tech-debt דוח	Batch	התוצאה נדרשת לבוקר; חיסכון של 50%
ביקורת אבטחה שבועית	Batch	לא דחוף; חיסכון של 50%
אינטראקטיבי Code review	Synchronous	נדרשת תגובה מיידי
עיבוד 10,000 מסמכים	Batch	עיבוד מסיבי; החיסכון משמעותי

שימוש ב custom_id-7.3

```
{
  "custom_id": "doc-invoice-2024-001",
  "params": {
    "model": "claude-sonnet-4-6",
    "max_tokens": 1024,
    "messages": [{"role": "user", "content": "Extract data from: ..."}]
  }
}
```

מאפשר לכם custom_id:

- לקשר את התוצאה למסמך המקורי
- בכשל, להגיש מחדש רק את המסמכים שנכשלו
- להימנע מעיבוד חוזר של מסמכים שהצליחו

Batches-טיפול בכשלים ב 7.4

1. של 100 מסמכים batch הגישו
2. מצליחים; 5 נכשלים (חרגו מגבול ההקשר) 95
3. custom_id זהו כשלים לפי
4. chunks-למשל פצלו מסמכים ארוכים ל) שנו אסטרטגיה
5. הגישו מחדש רק את 5 המסמכים שנכשלו

SLA תכנון 7.5

יכול לקחת עד 24 שעות API Batch-אם צריך תוצאה תוך 30 שעות ו

- חלון הגשה: 30 - 24 = 6 שעות
- deadline-חייבים להיות מוגשים לא יאוחר מ-24 שעות לפני ה Batches
- להגשות תכופות, פצלו לחלונות של 4 שעות

פרק 8: אסטרטגיות פירוק משימות

8.1 Fixed Pipelines (Prompt Chaining)

כל שלב מוגדר מראש:

```
Document -> Metadata extraction -> Data extraction -> Validation -> Enrichment -> Final output
```

מתי להשתמש:

- מבנה המשימה צפוי (ביקורות תמיד עוקבות אחר אותה תבנית)
- כל השלבים ידועים מראש
- צריך יציבות ושחזוריות

8.2 Dynamic Adaptive Decomposition

תת-משימות נוצרות על בסיס תוצאות ביניים:

- "Add tests for a legacy codebase"
- > First: map the structure (Glob, Grep)
- > Found: 3 modules with no tests, 2 with partial coverage
- > Prioritize: start with the payments module (high risk)
- > During work: discovered a dependency on an external API
- > Adapt: add a mock for the external API before writing tests

מתי להשתמש:

- משימות חקרניות פתוחות
- כשהיקף מלא לא ידוע מראש
- כשכל שלב תלוי בתוצאות הקודם

8.3 Multi-pass Code Review

עם +10 קבצים PRs:

```
Pass 1 (per-file): Analyze auth.ts -> list local issues
Pass 1 (per-file): Analyze database.ts -> list local issues
Pass 1 (per-file): Analyze routes.ts -> list local issues
...
Pass 2 (integration): Analyze relationships between files
-> Cross-file issues: inconsistent types, circular dependencies
```

יחיד מעל 14 קבצים גרוע pass למה:

- דילול תשומת לב: ניתוח עמוק לחלק מהקבצים, שטחי לאחרים
- הערות לא-עקביות: דפוס מסומן בקובץ אחד ומאושר באחר

- באגים מפוספסים: שגיאות ברורות נדלגות עקב עומס קוגניטיבי

Human-in-the-Loop-פרק 9: הסלמה ו

מתי להסלים לאדם 9.1

טריגרים להסלמה (כללים ברורים)

מצב	פעולה
"הלקוח מבקש מפורשות "תביא לי מנהל	הסלימו מיד; אל תנסו לפתור
המדיניות לא מכסה את הבקשה	הסלימו (למשל התאמת מחיר למתחרה כשהמדיניות שותקת)
הסוכן לא מצליח להתקדם	הסלימו אחרי מספר ניסיונות סביר
פעולה פיננסית מעל סף	(לא בפרומפט, hook רצוי דרך) הסלימו
מספר תוצאות בחיפוש לקוח	בקשו מזהים נוספים; אל תנחשו

מה לא טריגר אמין

שיטה לא-אמינה	למה נכשלת
sentiment ניתוח	מצב רוח של לקוח לא בקורלציה עם מורכבות התיק
ביטחון עצמי של המודל (1–10)	המודל יכול לטעות בביטחון; קליברציה גרועה
מסווג אוטומטי	שאינ training data עלול לדרוש; over-engineering

דפוסי הסלמה 9.2

הסלמה מיידיית

```
Customer: "I want to speak to a manager"
Agent: [immediately calls escalate_to_human]
NOT: "I can help with your issue, let me..."
```

הסלמה אחרי ניסיון פתרון

```
Customer: "My refrigerator broke two days after purchase"
Agent: [checks the order, offers a warranty replacement]
If the customer is not satisfied -> escalate
```

הסלמה ניואנסית (acknowledge → resolve → escalate on reiteration):

Customer: "This is outrageous, I'm very unhappy with the quality!"
Agent: [acknowledges frustration] "I understand your frustration."
[offers resolution] "I can offer a replacement or a refund."
Customer: "No, I want to talk to someone!"
Agent: [customer insists again -> immediate escalation]

עיקרון מפתח: הכירו ברגש קודם, אז הציעו פתרון קונקרטי, והסלימו רק אם הלקוח חוזר על הבקשה לבן אדם. אל תסלימו על ביטוי ראשון של חוסר שביעות רצון (זה לא זהה לבקשת מנהל).

הסלמה על פער במדיניות:

Customer: "Competitor X has this item 30% cheaper—give me a discount"
Policy: covers price adjustments only on your own site
Agent: [escalates – policy does not cover competitor price matching]

9.3 מובנים Handoff פרוטוקולי

בהסלמה, הסוכן צריך להעביר סיכום מובנה לאדם:

```
{
  "customer_id": "CUST-12345",
  "customer_name": "Ivan Petrov",
  "issue_summary": "Refund request for a damaged item",
  "order_id": "ORD-67890",
  "root_cause": "Item arrived damaged; photos attached",
  "actions_taken": [
    "Verified customer via get_customer",
    "Confirmed order via lookup_order",
    "Offered a standard replacement – customer insists on a refund"
  ],
  "refund_amount": "$89.99",
  "recommended_action": "Approve a full refund",
  "escalation_reason": "Customer requested to speak with a manager"
}
```

האופרטור האנושי לא רואה את כל תמלול השיחה — הוא רואה רק את הסיכום הזה. לכן הוא חייב להיות שלם ומכיל בתוך עצמו.

9.4 Confidence Calibration ופיקוח אנושי

למערכות חילוף נתונים:

1. **ציוני ביטחון ברמת שדה:** המודל מוציא ציון ביטחון לכל שדה מחולץ.
2. **קליברציה:** השתמשו בסטים מתויגים לכיוון ספים
3. **ניתוב:**
 - ביטחון גבוה + דיוק יציב -> עיבוד אוטומטי
 - ביטחון נמוך או מקורות עמומים -> סקירה אנושית

Stratified random sampling:

- שוטף של מדגם audit גם לחילוצים בביטחון גבוה, בצעו
- דיוק מצרפי של 97% יכול להסתיר 40% שגיאות לסוג מסמך מסוים
- נתחו דיוק לפי סוג מסמך ולפי שדה, לא רק כללי

פרק 10: טיפול בשגיאות במערכות רב-סוכניות

10.1 קטגוריות שגיאה

קטגוריה	דוגמאות	Retryable	פעולת סוכן
Transient	כשל רשת, 503, Timeout	כן	Retry עם exponential backoff
Validation	פורמט קלט לא תקין, שדה חובה חסר	לא (תקנו קלט)	שנו בקשה ונסו שוב
Business	הפרת מדיניות, חציית סף	לא	הסבירו למשתמש; הציעו חלופה
Permission	גישה נדחתה	לא	הסלימו

10.2 אנטי-פטרנים בטיפול שגיאות

אנטי-פטרן	בעיה	גישה נכונה
"search unavailable" סטטוס גנרי	המתאם לא יכול להחליט איך להתאושש	תוצאות, query, החזירו סוג שגיאה חלקיות, חלופות
השתקה שקטה (תוצאה ריקה = הצלחה)	המתאם חושב שלא היו תוצאות, אבל זה היה כשל	"הבדילו" "אין תוצאות" מ"כשל בחיפוש"
ביטול כל הזרימה על כשל אחד	אתם מאבדים את כל התוצאות החלקיות	המשיכו עם תוצאות חלקיות; סמנו פערים
אינסופיים בתוך תת- Retries סוכן	ובזבוז משאבים latency	אז הפצה, (2-1 retries) החלמה מקומית למתאם

שגיאת תת-סוכן מובנית 10.3

```
{
  "status": "partial_failure",
  "failure_type": "timeout",
  "attempted_query": "AI impact on music industry 2024",
  "partial_results": [
    {"title": "AI Music Generation Report", "url": "...", "relevance": 0.8}
  ],
  "alternative_approaches": [
    "Try a narrower query: 'AI music composition tools'",
    "Use an alternative data source"
  ],
  "coverage_impact": "Not covered: AI impact on music production"
}
```

זה מספק למתאם את המידע הדרוש כדי להחליט:

- שונה עם query עם Retry?
- להשתמש בתוצאות חלקיות?
- להאציל לתת-סוכן אחר?
- להמשיך בלי הסקציה הזו ולסמן את הפער?

הערות כיסוי בסינתזה הסופית 10.4

```
## Report: AI Impact on Creative Industries

### Visual Art (FULL COVERAGE)
[research results]

### Music (PARTIAL COVERAGE – search agent timeout)
[partial results]
⚠ Note: coverage for this section is limited due to a timeout in the search agent.

### Literature (FULL COVERAGE)
[research results]
```

פרק 11: ניהול הקשר במערכות פרודקשן

11.1 חילוץ עובדות לבלוק נפרד

במקום להסתמך על היסטוריית שיחה (שיוצרת באיכות בעת סיכום), חלצו עובדות מפתח לבלוק מובנה:

```
=== CASE FACTS (updated whenever a new fact appears) ===
Customer ID: CUST-12345
Order ID: ORD-67890
Order Date: 2025-01-15
Order Amount: $89.99
Issue: Damaged item on delivery
Customer Request: Full refund
Status: Pending manager approval
===
```

כללו את הבלוק הזה בכל פרומפט, ללא קשר לאיך ההיסטוריה מסוכמת.

קיצוץ תוצאות כלי 11.2

מחזיר +40 שדות אבל אתם צריכים רק 5 למשימה הנוכחית `lookup_order` אם

```
# PostToolUse hook: keep only relevant fields
@hook("PostToolUse", tool="lookup_order")
def trim_order_fields(result):
    return {
        "order_id": result["order_id"],
        "status": result["status"],
        "total": result["total"],
        "items": result["items"],
        "return_eligible": result["return_eligible"]
    }
```

זה חוסך הקשר ומפחית רעש.

קלט מודע-מיקום 11.3

lost-in-the-middle מקמו מידע קריטי תוך התחשבות באפקט

```
[KEY FINDINGS – at the top]
Found 3 critical vulnerabilities...

[DETAILED RESULTS – middle]
=== File auth.ts ===
...
=== File database.ts ===
...

[ACTION ITEMS – at the end]
Priority: fix auth.ts vulnerabilities before merge.
```

Scratchpad קבצי 11.4

scratchpad בחקירות ארוכות, הסוכן יכול לכתוב ממצאים מרכזיים לקובץ

```
# investigation-scratchpad.md
## Key findings
- PaymentProcessor in src/payments/processor.ts inherits from BaseProcessor
- refund() is called from 3 places: OrderController, AdminPanel, CronJob
- External PaymentGateway API has a rate limit of 100 req/min
- Migration #47 added refund_reason (NOT NULL) – 2024-12-01
```

מחדש discovery במקום להריץ scratchpad-כשההקשר יורד באיכותו (או בסשן חדש), הסוכן יכול להתייעץ ב

האצלה לתת-סוכנים כדי להגן על ההקשר 11.5

```
Main agent: "Investigate dependencies of the payments module"
-> Subagent (Explore): reads 15 files, traces imports
-> Returns: "Payments depends on AuthService, OrderModel, and the external
PaymentGateway API"

Main agent: keeps one line in context instead of 15 files
```

שכבת הקשר נפרדת: במערכות רב-סוכניות, כל תת-סוכן פועל בתוך תקציב הקשר מוגבל — הוא מקבל רק את גלובלי, ומקצה state המידע הנדרש למשימתו. המתאם פועל כשכבת הקשר נפרדת: הוא מצרף פלטי תת-סוכן, שומר שבו סוכן אחד צורך את החלון במידע לא רלוונטי לאחרים, "context leakage" הקשר. זה מונע

תקציבי הקשר מוגבלים לתת-סוכנים:

- שלחו הקשר מינימלי: משימה ספציפית + נתונים נדרשים
- של נתונים גולמיים dumps הנחו את תת-הסוכן להחזיר תוצאות מובנות, לא
- כדי להגביל את ערכת הכלים של תת-הסוכן — פחות כלים פירושו פחות הסחות `allowedTools`-השתמשו ב דעת ועלות הקשר נמוכה יותר

מובנה (להתאוששות מקריסה) State שמירת 11.6

שלו למיקום ידוע state-כל סוכן מייצא את ה

```
// agent-state/web-search-agent.json
{
  "status": "completed",
  "queries_executed": ["AI music 2024", "AI music composition"],
  "results_count": 12,
  "key_findings": [...],
  "coverage": ["music composition", "music production"],
  "gaps": ["music distribution", "music licensing"]
}
```

```
// agent-state/manifest.json
{
  "web-search": "completed",
  "doc-analysis": "in_progress",
  "synthesis": "not_started"
}
```

בהמשך manifest המתאם טוען.

(מקור הציטוט) Provenance פרק 12: שימור

12.1 Attribution בעיית אובדן

בעת סיכום תוצאות ממקורות מרובים, הקישור "טענה" → מקור יכול ללכת לאיבוד:

Bad: "The AI music market is estimated at \$3.2B." (No source, no year.)

Good:

```
{
  "claim": "The AI music market is estimated at $3.2B.",
  "source_url": "https://example.com/report",
  "source_name": "Global AI Music Report 2024",
  "publication_date": "2024-06-15",
  "confidence": 0.9
}
```

12.2 טיפול בנתונים סותרים

כששני מקורות מספקים ערכים שונים


```
{
  "claim": "Share of AI-generated music on streaming platforms",
  "values": [
    {
      "value": "12%",
      "source": "Spotify Annual Report 2024",
      "date": "2024-03",
      "methodology": "Automated classification"
    },
    {
      "value": "8%",
      "source": "Music Industry Association Survey",
      "date": "2024-07",
      "methodology": "Survey of 500 labels"
    }
  ],
  "conflict_detected": true,
  "possible_explanation": "Difference in methodology and time period"
}
```

ותנו למתאם להחליט attribution אל תבחרו ערך אחד שרירותית. שמרו את שניהם עם

12.3 כללו תאריכים לפרשנות נכונה

בלי תאריכים, הבדלים זמניים יכולים להתפרש בטעות כסתירות:

Bad: "Source A says 10%, source B says 15%. Contradiction."

Good: "Source A (2023) says 10%, source B (2024) says 15%. Likely +5% growth over a year."

12.4 רינדור לפי סוג תוכן

אל תכפו הכל לפורמט אחד:

- נתונים פיננסיים -> טבלאות
- חדשות וניתוח -> פרוזה
- ממצאים טכניים -> רשימות מובנות
- סדרות זמן -> סדר כרונולוגי

Claude Code פרק 13: כלים מובנים של

13.1 הפניית בחירת כלי

משימה	כלי	דוגמה
-------	-----	-------

מציאת קבצים לפי שם/תבנית	Glob	<code>**/*.test.tsx</code> , <code>src/components/**/*.ts</code>
חיפוש בתוך קבצים	Grep	שם פונקציה, הודעת שגיאה, import
קריאת קובץ במלואו	Read	טעינת קובץ לניתוח
כתיבת קובץ חדש	Write	יצירת קובץ מאפס
עריכת קובץ קיים מדויקת	Edit	ספציפי דרך התאמת טקסט ייחודית snippet החלפת
shell הרצת פקודת	Bash	git, npm, בדיקות, build, הרצת

13.2 אסטרטגיית חקירה הדרגתית

אל תקראו את כל הקבצים בבת אחת. בנו הבנה הדרגתית

1. Grep: find entry points (function definition, export)
 2. Read: read the found files
 3. Grep: find usages (import, calls)
 4. Read: read consumer files
 5. Repeat until you have a complete picture

13.3 Fallback: Read + Write במקום Edit

נכשל בגלל התאמת טקסט לא-ייחודית Edit-כש:

1. Read — טענו את תוכן הקובץ המלא
2. שנו את התוכן תוכניתית
3. Write — כתבו את הגרסה המעודכנת

הערות לפי דומיין מבחן: II חלק

דומיין 1: ארכיטקטורת סוכנים ואורקסטרציה (27%)

1.1 תכנון לולאות סוכן לביצוע משימות אוטונומיות

ידע מפתח:

- בדקו Claude מחזור חיים של לולאת סוכן: שלחו בקשת `stop_reason` (מול `"tool_use"` `"end_turn"`), הריצו כלים, החזירו תוצאות לאיטרציה הבאה
- תוצאות כלי מצורפות להיסטוריית השיחה כדי שהמודל יחליט על הפעולה הבאה
- לעומת עצי החלטה מקודדים-קשיחים (בוחר את הכלי הבא Claude) model-driven קבלת החלטות

מיומנויות מפתח:

- `stop_reason = "tool_use"` - ועצרו ב- `"end_turn"`
- בקרת זרימה: המשיכו את הלולאה כש צירוף תוצאות כלי להקשר בין איטרציות
- לסיום, שימוש בגבולות איטרציה שרירותיים כמנגנון עצירה ראשי `assistant` אנטי-פטרנים להימנע: ניתוח טקסט

אורקסטרציה של מערכות רב-סוכניות (מתאם-תת-סוכן) 1.2

ידע מפתח:

- המתאם מחזיק בכל התקשורת בין סוכנים, טיפול שגיאות וניתוב: `hub-and-spoke` ארכיטקטורת
- תת-סוכנים פועלים עם הקשר מבודד — הם לא יורשים אוטומטית את היסטוריית המתאם
- אחריות המתאם: פירוק משימה, האצלה, צבירת תוצאות, בחירה דינמית של תת-סוכנים
- סיכון של פירוק מצומצם מדי על ידי המתאם

מיומנויות מפתח:

- חלקו כיסוי מחקרי בין תת-סוכנים כדי למזער כפילות
- מימשו לולאות שיפור איטרטיביות (המתאם מעריך סינתזה ומנתב מחדש משימות)
- נתבו את כל התקשורת דרך המתאם לצורך תצפיתיות

הגדרת קריאות תת-סוכן, העברת הקשר ויצירה 1.3

ידע מפתח:

- `"Task"` של המתאם חייב לכלול `allowedTools`; יוצר תת-סוכנים `Task` הכלי
- הקשר תת-סוכן חייב להיכלל מפורשות בפרומפט; תת-סוכנים לא יורשים הקשר הורה
- מגבלות כלים, `system prompts`, תיאורים: `AgentDefinition` הגדרת
- לחקירת חלופות `fork_session` ניהול סשנים דרך

מיומנויות מפתח:

- כללו פלטים מלאים מסוכנים קודמים בפרומפט תת-הסוכן
- השתמשו בפורמטים מובנים להפרדת נתונים ממטא-דאטה בהעברת הקשר
- בתור מתאם יחיד `Task` צרו תת-סוכנים מקבילים דרך מספר קריאות
- כתבו פרומפטי מתאם במונחי מטרות וקריטריוני איכות במקום הוראות שלב-אחר-שלב

handoff-מימוש זרימות עבודה רב-שלביות עם אכיפה ו 1.4

ידע מפתח:

- לבין הנחיית פרומפט לסדר זרימת עבודה (`hooks`, `preconditions`) ההבדל בין אכיפה תוכנית
- כשצריך הבטחות דטרמיניסטיות (למשל אימות זהות לפני פעולות פיננסיות), פרומפטים לבדם לא מספיקים
- מובנים בהסלמה (זיהוי לקוח, סיבה, פעולה מומלצת) `handoff` פרוטוקולי

מיומנויות מפתח:

- למשל חסום) תוכנותיים שחוסמים קריאות במורד הזרימה עד שצעדים קודמים הושלמו Preconditions (מאומת ID מחזיר `get_customer` -עד ש `process_refund`)
- פרקו בקשות לקוח רב-היבטיות לפריטים נפרדים
- הפיקו סיכומים מובנים בהסלמה לאדם

ליירוט קריאות כלי ונורמליזציה Agent SDK ב Hooks 1.5

ידע מפתח:

- ליירוט תוצאות כלי לפני שהמודל צורך אותן (`PostToolUse` למשל) Hook דפוסי
- למשל חסום החזרים מעל סף) `compliance` שמייטרים קריאות יוצאות לאכיפת כללי Hooks
- הסתברותי `compliance` מספקים הבטחות דטרמיניסטיות לעומת הוראות פרומפט שמספקות Hooks

מיומנויות מפתח:

- (קודי סטטוס מספריים, ISO 8601, Unix timestamps) לנורמליזציית פורמטי נתונים `hooks` `PostToolUse`
- ליירוט שחוסמים פעולות שמפרות מדיניות עם ניתוב להסלמה Hooks
- מובטח `compliance` על פני פרומפטים כשכללי עסק דורשים `hooks` בחרו

אסטרטגיות פירוק משימות לזרימות מורכבות 1.6

ידע מפתח:

- לעומת פירוק אדפטיבי דינמי מבוסס תוצאות ביניים) `Fixed pipelines` (prompt chaining)
- Prompt chaining: (אינטגרציה `pass` נתחו כל קובץ בנפרד, ואז הריצו) צעדים סדרתיים
- תוכניות חקירה אדפטיביות שיוצרות תת-משימות לפי מה שהתגלה

מיומנויות מפתח:

- לסקירות צפויות רב-היבטיות; השתמשו בפירוק דינמי לחקירות פתוחות prompt chaining-השתמשו ב
- אינטגרציה נפרד לבין-קבצים `pass` גדולים לניתוח לפי קובץ ועוד `code reviews` פצלו
- פרקו משימות פתוחות: מפו מבנה קודם, אז בנו תוכנית מתועדפת

Session State, Resume I-Fork 1.7

ידע מפתח:

- להמשך ששנים בעלי שם `--resume <session-name>`
- ליצירת ענפי חקירה עצמאיים מהקשר משותף `fork_session`
- חשיבות יידוע הסוכן על שינויי קבצים בעת המשך ששנים
- סשן חדש עם סיכום מובנה יכול להיות אמין יותר מהמשך עם תוצאות מיושנות

מיומנויות מפתח:

- להמשך סשני חקירה בעלי שם `--resume` -השתמשו ב
- להשוואת גישות במקביל `fork_session` -השתמשו ב
- לעומת התחלת סשן חדש (תוצאות מיושנות) (הקשר עדיין רלוונטי) `resume` בחרו בין

MCP (18%) דומיין 2: עיצוב כלים ואינטגרציית

עיצוב ממשקי כלי עם תיאורים ברורים 2.1

ידע מפתח:

- משתמש בו לבחירת כלים; תיאורים מינימליים מובילים לבחירה לא-LLM-תיאורי כלי הם המנגנון העיקרי ש אמינה
- חשיבות הכללת פורמטי קלט, שאילתות לדוגמה, מקרי קצה וגבולות תחולה
- תיאורים דו-משמעיים או חופפים גורמים לניתוב שגוי
- יכול ליצור אסוציאציות לא-רצויות לכלים `system prompt` ניסוח

מיומנויות מפתח:

- כתבו תיאורים שמבדילים בבירור כל כלי מחלופות דומות
- (`analyze_content` -> `extract_web_results`) למשל) שנו שמות כלים כדי לבטל חפיפה פונקציונלית
- פצלו כלים כלליים למתמחים עם חוזי קלט/פלט ברורים

MCP מימוש תגובות שגיאה מובנות לכלי 2.2

ידע מפתח:

- MCP בתגובות כלי `isError` הדגל
- הפרות **business שגיאות**, (קלט שגוי) **validation שגיאות**, (timeouts) **transient** ההבדל בין **שגיאות** ושגיאות גישה/הרשאה, (מדיניות מונעות החלטות התאוששות נכונות ("Operation failed") שגיאות גנריות
- `retryable` ל-`non-retryable` ההבדל בין שגיאות

מיומנויות מפתח:

- והודעה, `isRetryable`, (`transient/validation/permission`) `errorCategory` החזירו מטא-דאטה מובנית כמו קריאה לאדם
- עם הסברים ברורים למשתמש `business-rule` להפרות `retryable: false` -השתמשו ב
- הפיצו רק שגיאות שהם לא יכולים לפתור; `transient` בצעו החלמה מקומית בתוך תת-סוכנים לכשלים
- מתוצאות ריקות תקפות (אין תוצאות) (`retry` החלטת) הבדילו כשלי גישה

2.3 הקצאת כלים בין סוכנים והגדרת tool_choice

ידע מפתח:

- יותר מדי כלים לסוכן (למשל 18 במקום 4-5) **מפחית** אמינות בחירת כלים
- סוכנים עם כלים מחוץ להתמחותם נוטים להשתמש בהם לרעה
- בין-תפקידים utilities גישת כלים מצומצמת: רק כלים רלוונטיים לתפקיד ועוד ערכה מוגבלת של
- `tool_choice`: `"auto"`, `"any"`, ובחירה כפויה, `{"type": "tool", "name": "..."} (`

מיומנויות מפתח:

- הגבילו את ערכת הכלים של כל תת-סוכן למה שרלוונטי לתפקידו
- `fetch_url` -> `load_document` (למשל) החליפו כלים כלליים בחלופות מוגבלות
- להבטחת קריאת כלי במקום תשובה טקסטואלית `tool_choice: "any"` -השתמשו ב
- כפו כלי ספציפי כדי להבטיח סדר ביצוע

2.4 וזרימות סוכן Claude Code ב-MCP שילוב שרתי

ידע מפתח:

- לניסיונות `( ~/.claude.json )` לצוותים לעומת משתמש `( .mcp.json )` פרויקט MCP: היקף שרת
- לניהול סודות `( ${GITHUB_TOKEN}` למשל) `.mcp.json` -החלפת משתני סביבה ב
- המחברים מתגלים בחיבור וזמינים בו-זמנית MCP כלים מכל שרתי
- להפחתת קריאות כלי חקרניות (DB סיכומי משימות, סכמות) "כ"קטלוגי תוכן MCP resources

מיומנויות מפתח:

- `env-var` של הפרויקט עם טוקנים מבוססי `.mcp.json` -משתתפים ב MCP הגדירו שרתי
- `~/.claude.json` -שמרו שרתים אישיים/ניסיוניים ב
- קהילתיים על פני שרתים מותאמים אישית לאינטגרציות סטנדרטיות MCP העדיפו שרתי

2.5 בחירה ויישום של כלים מובנים (Read, Write, Edit, Bash, Grep, Glob)

ידע מפתח:

- `Grep` (imports, שמות פונקציות, הודעות שגיאה) חיפוש בתוך תוכן קבצים
- `Glob` מציאת קבצים לפי תבניות שם/סיומת
- `Read/Write`: פעולות מלאות על קבצים; `Edit`: ייחודיות טקסט ייחודיות
- `Read + Write` ל-fallback, נכשל עקב התאמות לא-ייחודיות Edit אם

מיומנויות מפתח:

- לגילוי קבצים לפי תבניות Glob לחיפוש תוכן וב Grep -השתמשו ב
- flows לעקיבת Read אז, Grep entry points, בנו הבנה הדרגתית
- wrapper עקבו אחר שימוש בפונקציות דרך מודולי

וזרימות עבודה (20%) Claude Code דומיין 3: הגדרות

עם היררכיה, היקף וארגון מודולרי CLAUDE.md הגדרת 3.1

ידע מפתח:

- או `.claude/CLAUDE.md` (פרויקט), `~/claude/CLAUDE.md` (משתמש CLAUDE.md: היררכיית CLAUDE.md (בתת-תיקיות CLAUDE.md) ורמת תיקיה, (בשורש CLAUDE.md
- VCS הגדרות ברמת משתמש חלות רק על משתמש אחד ולא משותפות דרך
- למודולריות (`./standards/coding-style.md` למשל) להתייחסות לקבצים חיצוניים `@path` תחביר CLAUDE.md
- מונוליטי CLAUDE.md לקבצי כללים ממוקדי-נושא במקום `.claude/rules/` תיקיית

מיומנויות מפתח:

- אבחנו בעיות היררכיה (חבר צוות חדש מפספס הוראות כי הן ברמת משתמש במקום פרויקט)
- בכל חבילה standards להכללה סלקטיבית של (`./standards/testing.md` למשל) `@path` -השתמשו ב
- גדול לקבצי CLAUDE.md פצלו (`testing.md`, `api-conventions.md`, `deployment.md`) מרובים `.claude/rules/` גדול לקבצי CLAUDE.md

3.2 Custom Slash Commands ויצירה והגדרה של Skills

ידע מפתח:

- לעומת פקודות משתמש ב (VCS משותפות דרך) `.claude/commands/` -פקודות פרויקט ב `~/claude/commands/`
- Skills `.claude/skills/` של frontmatter עם `SKILL.md`: `context: fork`, `allowed-tools`, `argument-hint`
- בהקשר תת-סוכן מבודד כדי שלא יזהם את הסשן הראשי skill-מריץ את ה `context: fork`
- בשמות שונים `~/claude/skills/` -אישיים יכולים לחיות ב skills ואריאנטי

מיומנויות מפתח:

- כדי שכל הצוות יקבל אותן `.claude/commands/` -של פרויקט ב slash commands שמרו
- verbose עם פלט skills לבידוד `context: fork` -השתמשו ב
- יכול להשתמש בהם skill להגבלת אילו כלים `allowed-tools` -השתמשו ב
- כדי לדרבן מפתחים לפרמטרים נדרשים `argument-hint` -השתמשו ב

3.3 לטעינת מוסכמות מותנית Path Specific שימוש בכללי

ידע מפתח:

- glob להפעלת כללים על בסיס תבניות `paths` עם frontmatter YAML יכולים לכלול `.claude/rules/` קבצי

- נטענים רק בעריכת קבצים תואמים, חוסכים הקשר וטוקנים path-כללים מסומני
- ברמת תיקייה כשמוסכמות חלות על הרבה CLAUDE.md יכולים להיות עדיפים על glob-מבוססי path כללי (tests למשל) תיקיות

מיומנויות מפתח:

- לטעינה רק בעבודה על קבצים תואמים `paths: ["terraform/**/*.ts"]` עם `.claude/rules/` צרו קבצי
- להחלת מוסכמות לפי סוג קובץ ללא תלות במיקום (glob `(**/*.test.tsx)` השתמשו בתבניות
- codebase-ברמת תיקייה כשמוסכמות מתפרסות על ה CLAUDE.md על path-העדיפו כללים מסומני

מתי להשתמש במצב תכנון מול ביצוע ישיר 3.4

ידע מפתח:

- **מצב תכנון:** למשימות מורכבות עם שינויים גדולים, מספר גישות סבירות, והחלטות ארכיטקטוניות
- (בודד validation למשל הוספת) **ביצוע ישיר:** לשינויים פשוטים ומובנים היטב
- לפני ביצוע שינויים codebase-מצב תכנון מאפשר חקירה בטוחה של ה
- מילולי discovery מבודד פלט Explore subagent

מיומנויות מפתח:

- (מיגרציות שנוגעות ל-45+ קבצים, microservices) השתמשו במצב תכנון למשימות עם השלכות ארכיטקטוניות
- ברור וקובץ יחיד stack trace השתמשו בביצוע ישיר לתיקונים עם
- כדי למנוע אזילת חלון הקשר במשימות רב-שלביות Explore subagent-השתמשו ב
- שלבו גישות: תכנון לגילוי, אז ביצוע ליישום

שיפור איטרטיבי לשיפור פרוגרסיבי 3.5

ידע מפתח:

- דוגמאות קונקרטיות של קלט/פלט הן הדרך האפקטיבית ביותר לתקשר ציפיות
- על בסיס כשלים iterate **איטרציה מונחית-בדיקות:** כתבו בדיקות קודם, אז
- שואל שאלות כדי להעלות שיקולי עיצוב לא-מובנים Claude: "interview"דפוס ה
- מתי לספק את כל הבעיות בהודעה אחת (תלויות הדדית) לעומת ברצף (עצמאיות)

מיומנויות מפתח:

- ספקו 2–3 דוגמאות קונקרטיות של קלט/פלט להבהרת דרישות טרנספורמציה
- בנו ערכות בדיקה עם התנהגות צפויה, מקרי קצה ודרישות ביצועים לפני מימוש
- (מצבי כשל, cache invalidation) להעלאת היבטי עיצוב interview השתמשו בדפוס
- קונקרטיים עם קלטים לדוגמה ופלטים צפויים למקרי קצה test cases ספקו

3.6 CI/CD בפייפליין Claude Code שילוב

ידע מפתח:

- למצב לא-אינטראקטיבי בפייפליין אוטומטי (`--print`) (או `-p`) הדגל
- CI-לפלט מובנה ב `--json-schema` ו `--output-format json`
- CI-שמופעל מ Claude Code ל- (review סטנדרטי בדיקות, קריטריוני) מספק הקשר פרויקט CLAUDE.md
- עצמאי instance- **בידוד הקשר ששן**: אותו ששן שייצר קוד הוא פחות אפקטיבי בסקירתו מ

מיומנויות מפתח:

- כדי להימנע מתליה על קלט אינטראקטיבי `-p` עם CI ב- Claude Code הריצו
- (PR על inline למשל הערות) לתוצאות מובנות `--json-schema` + `--output-format json` -השתמשו ב
- קודמות בעת הרצה מחדש אחרי קומיטים חדשים (דווחו רק על בעיות חדשות/לא-מתוקנות) review כללו תוצאות
- לשיפור איכות יצירת בדיקות CLAUDE.md-זמינים ב fixtures-תעדו סטנדרטי בדיקות ו
- כללו קבצי בדיקה קיימים בהקשר בעת יצירת בדיקות חדשות כדי להימנע מכפילות ולשמור על עקביות סגנון

דומיין 4: הנדסת פרומפט ופלט מובנה (20%)

עיצוב פרומפטים עם קריטריונים מפורשים לשיפור דיוק 4.1

ידע מפתח:

- קריטריונים מפורשים אפקטיביים יותר מהוראות מעורפלות (למשל "סמן הערות רק כשהן סותרות את הקוד" מול "בדוק דיוק הערות")
- הנחיה גנרית כמו "תהיה שמרני יותר" עובדת פחות טוב מקריטריונים קטגוריאליים קונקרטיים
- גבוהים בקטגוריות מסוימות פוגעים באמון false-positive על אמון מפתחים: שיעורי false positives ההשפעה של בקטגוריות מדויקות

מיומנויות מפתח:

- מה לדווח (באגים, אבטחה) לעומת מה להתעלם (סגנון מינורי): review הגדירו קריטריוני
- גבוהים false-positive בטלו זמנית קטגוריות עם שיעורי
- הגדירו קריטריוני חומרה מפורשים עם דוגמאות קוד לכל רמה

לשיפור עקביות פלט Few-shot Prompting שימוש ב 4.2

ידע מפתח:

- הן השיטה האפקטיבית ביותר להפקת פלט עקבי בפורמט וניתן לפעולה few-shot דוגמאות
- יכול להדגים טיפול במקרים דו-משמעיים (בחירת כלי, פערים בכיסוי בדיקות) Few-shot
- עוזר למודל להכליל לדפוסים חדשים במקום רק לחזור על ברירות מחדל Few-shot
- יכול להפחית הזיות במשימות חילוץ Few-shot

מיומנויות מפתח:

- ספקו 2–4 דוגמאות ממוקדות לתרחישים דו-משמעיים עם הצדקה
- שמדימות את פורמט הפלט (מיקום, בעיה, חומרה, תיקון מוצע) few-shot כללו דוגמאות
- ספקו דוגמאות שמבדילות דפוסי קוד מקובלים מבעיות אמיתיות
- ספקו דוגמאות לחילוף נכון ממסמכים עם מבנים שונים

4.3 I-JSON Schemas ו tool_use אכיפת פלט מובנה עם

ידע מפתח:

- הוא הדרך האמינה ביותר להבטיח פלט תואם-סכמה ולבטל שגיאות תחביר JSON Schemas עם tool_use JSON
- הוא חייב לקרוא לכלי; בחירה כפויה "any" המודל יכול להחזיר טקסט; עם tool_choice: "auto" עם בוחרת כלי ספציפי
- מחמירים מבטלים שגיאות תחביר אך לא מונעים שגיאות סמנטיות (סכומים לא מסתכמים; JSON Schemas ערכים בשדות שגויים)
- ועוד שדה פירוט להרחבה "other" עם enums; optional לעומת required עיצוב סכמה: שדות

מיומנויות מפתח:

- ופרסרו נתונים מתוצאות JSON Schemas הגדירו כלי חילוף עם tool_use
- להבטחת פלט מובנה כשקיימות מספר סכמות tool_choice: "any" -השתמשו ב
- כפופ קריאה לכלי ספציפי: tool_choice: {"type": "tool", "name": "extract_metadata"}
- כשהמקור עשוי לא להכיל מידע, כדי להימנע מבדיית ערכים nullable/הפכו שדות לאופציונליים
- ועוד שדות פירוט לקטגוריזציה הניתנת להרחבה "other" ו- "unclear" כמו enum השתמשו בערכי

4.4 ולולאות פידבק לאיכות חילוף Validation, Retries מימוש

ידע מפתח:

- Retry-with-error-feedback: לכוון תיקונים retry-קונקרטיות בפרומפט ה validation כללו שגיאות
- Retries לא אפקטיביים כשהמידע פשוט נעדר מהמקור
- (detected_pattern) עיצוב לולאת פידבק: עקבו אחר הדפוס שהפעיל ממצא
- (tool_use) מטופלות על ידי שגיאות סמנטיות (סכומים לא מסתדרים) לעומת שגיאות תחביר

מיומנויות מפתח:

- ספציפיות validation עם המסמך המקורי, חילוף שגוי ושגיאות follow-up פרומפטי
- לא יהיה אפקטיבי (המידע הנדרש רק במסמך חיצוני) retry זהו מתי
- false positives בממצאים לניתוח detected_pattern כללו שדות
- לזיהוי אי-התאמות stated_total וגם calculated_total על ידי חילוף גם self-correction עצבו

Batch עיצוב אסטרטגיות יעילות לעיבוד 4.5

ידע מפתח:

- Message Batches API: latency על SLA חיסכון, חלון עיבוד עד 24 שעות, אין הבטחות 50%
- בדיקות לפני) ולא מתאים למשימות חוסמות (audits, דוחות לילה) מתאים למשימות לא-חוסמות batch עיבוד merge)
- בתוך בקשה יחידה multi-turn tool calling-לא תומך ב Batch API
- batches בתוך request/response מקשרים custom_id שדות

מיומנויות מפתח:

- לעומסי לילה/שבועיים Batch API-סינכרוני לבדיקות חוסמות; השתמשו ב API-השתמשו ב
- למשל חלונות של 4 שעות להבטחת 30 שעות עם עיבוד 24) SLA על בסיס צרכי batch הגשת cadence תכננו (שעות)
- (custom_id מזהים לפי) טפלו בכשלים על ידי הגשה מחדש רק של מסמכים שנכשלו
- על פרומפטים תוך שימוש במדגם לפני הרצת עיבוד בקנה מידה גדול iterate

review רב-instance רב עיצוב ארכיטקטורות 4.6

ידע מפתח:

- המודל שומר את הקשר השיקול שלו ופחות סביר שיאתגר את ההחלטות של עצמו: self-review מגבלות
- ביקורת עצמאיים (בלי הקשר היצירה) טובים יותר במציאת בעיות עדינות Instances
- Multi-pass review: אינטגרציה בין-קבצים כדי להימנע מדילול תשומת לב pass ניתוח מקומי לכל קובץ ועוד

מיומנויות מפתח:

- שני עצמאי לסקירת שינויים בלי הקשר היצירה Claude instance-השתמשו ב
- אינטגרציה לניתוח זרימת נתונים בין-קבצים passes לפי קובץ ועוד passes-פצלו ביקורות רב-קבציות ל
- אימות עם ביטחון עצמי לניתוב ביקורות באופן מכויל passes-השתמשו ב

דומיין 5: ניהול הקשר ואמינות (15%)

ניהול הקשר שיחה לשימור מידע קריטי 5.1

ידע מפתח:

- סיכוני סיכום פרוגרסיבי: ערכים מספריים, אחוזים ותאריכים מתעבים לסיכומים מעורפלים
- מודלים מעבדים אמינות התחלה וסוף של קלטים ארוכים, אבל עלולים לפספס lost-in-the-middle אפקט ממצאים מהאמצע
- פלטי כלי יכולים להצטבר בהקשר באופן לא-פרופורציוני לרלוונטיות (+40 שדות כש-5 נחוצים)
- עוקבות API חשיבות שליחת היסטוריית השיחה המלאה בבקשות

מיומנויות מפתח:

- קבוע מחוץ להיסטוריה המסוכמת "case facts" חלצו עובדות טרנזקציוניות לבלוק
- לשדות רלוונטיים verbose קצצו פלטי כלי
- מקמו ממצאי מפתח בתחילת נתונים מצורפים עם כותרות סקציה מפורשות
- דרשו שתת-סוכנים יכללו מטא-דאטה (תאריכים, מקורות) בפלטים מובנים

עיצוב דפוס הסלמה אפקטיביים ופתרון דו-משמעיות 5.2

ידע מפתח:

- טריגרי הסלמה מתאימים: בקשה מפורשת לאדם, פערים/חריגים במדיניות, חוסר יכולת להתקדם
- הסלמה מיידית (בקשה מפורשת) לעומת ניסיון פתרון (בתחום הסוכן)
- וביטחון עצמי של המודל הם פרוקסי לא-אמינים למורכבות תיק sentiment ניתוח
- מספר התאמות לקוח דורש בקשת מזהים נוספים, לא ניחוש היוריסטי

מיומנויות מפתח:

- few-shot ב-system prompt קריטריוני הסלמה מפורשים עם דוגמאות
- בצעו בקשות מפורשות לאדם מיד ללא חקירה נוספת
- הסלימו כשהמדיניות דו-משמעית או שותקת לבקשה ספציפית
- בקשו מזהים נוספים כשתוצאות כלי מכילות מספר התאמות

מימוש אסטרטגיות הפצת שגיאות במערכות רב-סוכניות 5.3

ידע מפתח:

- מאפשר התאוששות חכמה יותר של מתאם (תוצאות חלקיות, חלופות, query, סוג כשל) הקשר שגיאה מובנה
- מתוצאות ריקות תקפות (אין התאמות) (retry דורשים החלטת timeouts) הבדילו כשלי גישה
- מסתירים הקשר חשוב מהמתאם ("search unavailable") סטטוסי שגיאה גנריים
- השתקה שקטה או ביטול כל הזרימה על כשל אחד הם אנטי-פטרנים

מיומנויות מפתח:

- החזירו הקשר שגיאה מובנה: סוג כשל, מה נוסה, תוצאות חלקיות, חלופות אפשריות
- הבדילו כשלי גישה מתוצאות ריקות תקפות
- הפיצו רק שגיאות לא-ניתנות-להתאוששות עם תוצאות; transient בצעו החלמה מקומית בתת-סוכנים לכשלים חלקיות
- סמנו כיסוי בסניתזה: מה מבוסס היטב לעומת היכן נשאר פערים

גדולים Codebases ניהול הקשר יעיל בחקירת 5.4

ידע מפתח:

- ירידה באיכות הקשר בסשנים ארוכים: המודל מתחיל להפיק תשובות לא-יציבות ומתייחס ל"דפוסים אופייניים" במקום למחלקות ספציפיות

- משמרים ממצאי מפתח מעבר לגבולות הקשר Scratchpad קבצי
- מילולי discovery האצלה לתת-סוכנים מבודדת פלט
- מובנה מאפשרת התאוששות מקריסה state שמירת

מיומנויות מפתח:

- צרו תת-סוכנים לשאלות ספציפיות תוך שמירה על תיאום ברמה גבוהה בסוכן הראשי
- לאחסון ממצאי מפתח והפניה אליהם בהמשך scratchpad השתמשו בקבצי
- סכמו ממצאי מפתח לפני יצירת תת-סוכני שלב הבא
- להפחתת שימוש בהקשר בחקירות ארוכות `/compact` -השתמשו ב

עיצוב זרימות עם פיקוח אנושי וקליברציית ביטחון 5.5

ידע מפתח:

- מדדים מצרפיים (למשל 97% דיוק כללי) יכולים להסוות ביצועים גרועים בסוגי מסמכים או שדות ספציפיים
- מודד שיעורי שגיאה בחילוצים בביטחון גבוה Stratified random sampling
- קליברציית ביטחון ברמת שדה תוך שימוש בסטים מתויגים
- אמתו דיוק לפי סוג מסמך ומגזר שדה לפני אוטומציה

מיומנויות מפתח:

- לזיהוי דפוסי שגיאה חדשים stratified random sampling מימשו
- נתחו דיוק לפי סוג מסמך ושדה לאימות ביצועים יציבים
- תוך שימוש בנתונים מתויגים review הוציאו ציוני ביטחון ברמת שדה וכיילו ספי
- נתבו חילוצים בביטחון נמוך או ממקורות עמומים לסקירה אנושית

טיפול באי-ודאות בסינתזה רב-מקורית Provenance שימור 5.6

ידע מפתח:

- "אובד בסיכום ללא שימור מיפוי "טענה → מקור Attribution
- מיפויים מובנים חייבים להישמר בעת צבירה
- במקום בחירה שרירותית של ערך אחד attribution טפלו בסטטיסטיקות סותרות על ידי הערה על קונפליקטים עם
- כללו תאריכי פרסום/איסוף כדי להימנע מקריאה שגויה של הבדלים זמניים כסתירות

מיומנויות מפתח:

- (שם מסמך, ציטוטים, URL) "דרשו שתת-סוכנים יוציאו מיפוי "טענה → מקור
 - בנו דוחות שמפרידים ממצאים יציבים מאלה הנמצאים במחלוקת
 - שמרו ערכים סותרים עם הערות והעבירו אותם למתאם להתאמה
 - כללו תאריכי פרסום לפרשנות זמנית נכונה
 - הנדרו תוכן לפי סוג: נתונים פיננסיים כטבלאות, חדשות כפרוזה, ממצאים טכניים כרשימות מובנות
-

דוגמאות שאלות מבחן עם הסברים

1 שאלה (תרחיש: Customer Support Agent)

רק עם שם lookup_order וקורא ל get_customer מצב: הנתונים מראים שב-12% מהמקרים הסוכן מדלג על הלקוח, מה שמוביל להחזרים שגויים.

איזה שינוי הכי אפקטיבי

- A) מ-ID עד שמתקבל lookup_order I- process_refund תוכנתי שחוסם precondition הוסיפו A) [נכון] get_customer
- B) system prompt שפרו את ה B)
- C) few-shot הוסיפו דוגמאות C)
- D) מימשו מסווג ניתוב D)

כשלוגיקה עסקית קריטית דורשת רצף כלים מסוים, תוכנה מספקת הבטחות דטרמיניסטיות שגישות: A למה מטפל בזמינות, לא בסדר כלים D. לא יכולות B, C) מבוססות-פרומפט

2 שאלה (תרחיש: Customer Support Agent)

לשאלות הקשורות בהזמנה. תיאורי הכלים lookup_order -במקום ל get_customer -מצב: הסוכן קורא ל מינימליים ודומים.

מה הצעד הראשון

- A) few-shot דוגמאות A)
- B) הרחיבו את תיאור כל כלי עם פורמטי קלט, דוגמאות וגבולות [נכון] B)
- C) הוסיפו שכבת ניתוב C)
- D) מזגו את הכלים D)

תיאורי כלים הם מנגנון הבחירה העיקרי של המודל. זה התיקון בעלות הנמוכה ביותר עם ההשפעה הגבוהה: B למה דורש יותר מאמץ מהמוצדק D. over-engineering זה C. מוסיף טוקנים בלי לטפל בשורש הבעיה A. ביותר

3 שאלה (תרחיש: Customer Support Agent)

מצב: הסוכן פותר רק 55% מהבעיות במטרת 80%. הוא מסלים מקרים פשוטים ומנסה לטפל באופן אוטונומי בחריגי מדיניות מורכבים.

איך משפרים את הקליברציה

- A) few-shot הוסיפו קריטריוני הסלמה מפורשים עם דוגמאות A) [נכון]
- B) ביטחון עצמי (1–10) עם הסלמה אוטומטית B)
- C) מסווג נפרד שאומן על נתונים היסטוריים C)
- D) sentiment ניתוח D)

זה C. לא אמין (המודל יכול לטעות בביטחון) B. מטפל ישירות בשורש הבעיה — גבולות החלטה לא-ברורים A: למה פותר בעיה אחרת (מצב רוח != מורכבות) D. over-engineering.

4 שאלה (תרחיש: Code Generation with Claude Code)

של הריפו clone סטנדרטי שזמינה לכל הצוות בעת code review ל-`/review` מצב: אתם צריכים פקודה מותאמת.

איפה ליצור את קובץ הפקודה?

- A) `.claude/commands/` הפרויקט [נכון] ב-repo
- B) `~/ .claude/commands/`
- C) `CLAUDE.md` בשורש
- D) `.claude/config.json`

B. זמינות אוטומטית לכולם version-controlled הן `.claude/commands/` -פקודות פרויקט הנשמרות ב: A: למה לא קיים D. להוראות, לא להגדרות פקודה C. לפקודות אישיות.

5 שאלה (תרחיש: Code Generation with Claude Code)

(עשרות קבצים, החלטות גבולות שירות) microservices-מצב: צריך לבצע ארגון מחדש של מונולית ל

באיזה גישה להשתמש?

- A) הבינו תלויות, עצבו גישה [נכון], codebase-מצב תכנון: חקרו את ה
- B) ביצוע ישיר הדרגתי
- C) ביצוע ישיר עם הוראות מפורטות מראש
- D) ביצוע ישיר ומעבר לתכנון כשנהיה קשה

מסכן בעבודה חוזרת B. מצב תכנון מתוכנן לשינויים גדולים, מספר גישות אפשריות והחלטות ארכיטקטוניות A: למה ריאקטיבי D. מניח שאתם כבר יודעים את המבנה C. יקרה.

6 שאלה (תרחיש: Code Generation with Claude Code)

בדיקות ממוקמות יחד עם הקוד. (React, API, database) יש מוסכמות שונות באזורים שונים codebase-מצב: ל אתם רוצים שמוסכמות יוחלו אוטומטית.

באיזה גישה להשתמש?

- A) קבצי `.claude/rules/` עם YAML frontmatter glob ותבניות [נכון]
- B) בשורש `CLAUDE.md` שמו הכל ב
- C) Skills ב- `.claude/skills/`
- D) בכל תיקייה `CLAUDE.md`

מאפשר החלת מוסכמות אוטומטית על (`**/*.test.tsx` למשל) glob עם תבניות `.claude/rules/` A: למה לא D. ידני/לפי דרישה C. מסתמך על הסקת המודל B. codebase-בסיס נתיבי קבצים — אידיאלי לבדיקות פזורות ב

7 (תרחיש: Multi-agent Research System) שאלה

על תעשיות יצירה", אבל הדוחות מכסים רק אמנות חזותית. המתאם פירק את AI מצב: המערכת חוקרת "השפעת "בצילום AI", "בעיצוב גרפי AI", "באמנות דיגיטלית AI": הנושא ל

מה הסיבה

- A) סוכן הסינתזה לא מזהה פערים
- B) המתאם פירק את המשימה בצורה מדי [נכון]
- C) סוכן חיפוש האינטרנט לא מחפש מספיק יסודית
- D) סוכן ניתוח המסמכים מסנן מקורות לא-חזותיים

הלוגים מראים שהמתאם פירק את "תעשיות יצירה" רק לתת-נושאים חזותיים, מפספס לגמרי מוזיקה, B: למה ספרות וקולנוע. תת-הסוכנים ביצעו נכון — הבעיה היא במה שהוקצה להם

שאלות נוספות

הקובץ המקורי כולל למעלה מ-70 שאלות. המבנה והעקרונות זהים — מקרי שימוש מתרחשי המבחן, ארבע לעיל. II-I אפשרויות, והסבר למה התשובה הנכונה היא הנכונה. כל אלה מבוססים על העקרונות שכוסו בחלקים [practical_test_en.html](#) לתרגול מלא, ראו את

מומלץ להתאמן בשאלות באנגלית כיוון שכך תקבלו את ניסוח השאלות הזהה למבחן האמיתי

תרגילים מעשיים

תרגיל 1: סוכן רב-כלים עם לוגיקת הסלמה

מטרה: לתכנן לולאת סוכן עם אינטגרציית כלים, טיפול שגיאות מובנה והסלמה

שלבים:

- עם תיאורים מפורטים (כללו שני כלים דומים לבחינת בחירת כלי) MCP הגדירו 3-4 כלי
- מימשו לולאת סוכן הבודקת ("tool_use" / "end_turn") stop_reason
- תיאור, errorCategory, isRetryable: הוסיפו תגובות שגיאה מובנות
- ליירוט שחוסם פעולות מעל סף ומנתב להסלמה hook מימשו
- בדקו עם בקשות רב-היבטיות

(הקשר ואמינות) 5, (MCP-כלים I) דומיינים: 1 (ארכיטקטורת סוכן), 2

לפיתוח צוותי Claude Code תרגיל 2: הגדרת

MCP ספציפיים ושרתי path פקודות מותאמות אישית, כללי, CLAUDE.md **מטרה:** להגדיר

שלבים:

1. universal ברמת פרויקט עם סטנדרטי CLAUDE.md צרו
 2. (paths: ["src/api/**/*"] , paths: ["**/*.test.*"]) לאזורי קוד שונים YAML frontmatter עם .claude/rules/ צרו קבצי
 3. פרויקט תחת skill צרו .claude/skills/ עם context: fork I- allowed-tools
 4. override + עם משתני סביבה .mcp.json -ב MCP הגדירו שרת ~/.claude.json אישי
 5. בדקו מצב תכנון לעומת ביצוע ישיר במשימות בעלות מורכבות שונה
- 3 (דומיינים: 2 (MCP-כלים ו), 2 (Claude Code הגדרות), 3

לחילוץ נתונים מובנים Pipeline: תרגיל 3

batch עיבוד, validation/retry, לולאות tool_use, JSON schemas, **מטרה:**

שלבים:

1. (JSON schema הגדירו כלי חילוץ עם nullable שדות, "other" עם enums, required/optional שדות)
 2. ספציפית validation עם המסמך, חילוץ שגוי ושגיאת retry, בשגיאה: validation: בנו לולאת
 3. למסמכים עם מבנים שונים few-shot הוסיפו דוגמאות
 4. מסמכים, טיפול בכשלים דרך Message Batches API: 100 דרך batch השתמשו בעיבוד custom_id
 5. ניתוב לאדם: ציוני ביטחון ברמת שדה, ניתוח לפי סוג מסמך
- 4 (הנדסת פרומפט), 5 (הקשר ואמינות) **דומיינים:**

מחקרי רב-סוכני pipeline של debugging-תרגיל 4: עיצוב ו

מטרה: אורקסטרציית תת-סוכנים, העברת הקשר, הפצת שגיאות, סינתזה עם מעקב מקורות

שלבים:

1. (הקשר מועבר מפורשות בפרומפטים, "Task" כולל allowedTools) מתאם עם +2 תת-סוכנים
 2. בתגובה אחת Task הריצו תת-סוכנים במקביל דרך מספר קריאות
 3. מקור, תאריך פרסום URL, דרשו פלט תת-סוכן מובנה: טענה, ציטוט
 4. של תת-סוכן: החזירו הקשר שגיאה מובנה למתאם והמשיכו עם תוצאות חלקיות timeout דמו
 5. הפרידו ממצאים מאומתים ממוכרזים; attribution בדקו עם נתונים סותרים: שמרו את שני הערכים עם
- 2 (הקשר ואמינות), 5 (MCP-כלים ו), 1 (ארכיטקטורת סוכן), 2 **דומיינים:**

נספח: טכנולוגיות ומושגים

טכנולוגיה	היבטי מפתח
Claude Agent SDK	AgentDefinition, agent loops, stop_reason , hooks (PostToolUse), יצירת תת-סוכנים דרך Task, allowedTools
Model Context Protocol (MCP)	משתני סביבה , mcp.json , תיאורי כלים , isError , MCP, tools, resources שרתי
Claude Code	CLAUDE.md, glob עם תבניות , .claude/rules/ , .claude/commands/ , .claude/skills/ עם SKILL.md, מצב תכנון, /compact , --resume , fork_session
Claude Code CLI	-p / --print למצב לא-אינטראקטיבי , --output-format json , --json-schema
Claude API	tool_use עם JSON schemas, tool_choice ("auto"/"any"/"forced"), stop_reason , max_tokens , system prompts
Message Batches API	multi-turn tool calling אין , custom_id , חיסכון, חלון של עד 24 שעות 50%
JSON Schema	Required לעומת optional, nullable שדות, enum סוגי, "other" + מצב strict פירוט,
Pydantic	validation/retry אימות סכמה, שגיאות סמנטיות, לולאות
כלים מובנים	Read, Write, Edit, Bash, Grep, Glob — מטרה וקריטריוני בחירה
Few-shot prompting	דוגמאות ממוקדות למצבים דו-משמעיים, הכללה לדפוסים חדשים
Prompt chaining	ממוקדים passes-פירוק סדרתי ל
חלון הקשר	scratchpad קבצי, "lost in the middle", תקציבי טוקנים, סיכום פרוגרסיבי
ניהול ששנים	Resume, fork_session , ששנים בעלי שם, בידוד הקשר,
קליברציית ביטחון	stratified sampling, ניקוד ברמת שדה, קליברציה על סטים מתווגים

נושאים מחוץ להיקף

- הנושאים הסמוכים הבאים לא יהיו במבחן
- או אימון מודלים מותאמים Claude של מודלי Fine-tuning
 - חיוב או ניהול חשבון Claude API, אימות
 - tool/schema מעבר למה שדרוש להגדרת) ספציפיים frameworks מימוש מפורט בשפות תכנות או
 - (תשתית, רשת) MCP פריסה או אירוח של שרתי container orchestration
 - תהליך אימון או משקלי מודל Claude, ארכיטקטורה פנימית של
 - או מתודולוגיות אימון בטיחות RLHF, Constitutional AI
 - vector database או embedding פרטי מימוש של מודלי

- Computer use (אוטומציית דפדפן, אינטראקציה דסקטופ)
- Vision (יכולות ניתוח תמונה)
- Streaming API או server-sent events
- Rate limiting, או חישובי עלות, מפורטים API מכסות,
- OAuth, סבב API keys, פרטי פרטוקול אימות,
- הגדרות ספציפיות לספק ענן (AWS, GCP, Azure)
- בנצ'מרקים של ביצועים או מדדי השוואת מודלים
- (מעבר לידיעה שזה קיים) prompt caching פרטי מימוש של
- tokenization אלגוריתמי ספירת טוקנים או פרטי

המלצות הכנה

1. מימשו לולאת סוכן מלאה עם קריאה לכלים, טיפול שגיאות וניהול ששנים. — **Claude Agent SDK בנו סוכן עם**. תתאמנו בתת-סוכנים והעברת הקשר מפורשת
2. ספציפיים path כללי, CLAUDE.md **לפרויקט אמיתי** — השתמשו בהיררכיית **Claude Code הגדירו**. MCP ושילוב שרת, `allowed-tools` I- `context: fork` עם `skills`, `claude/rules/` -ב
3. retry, כתבו תיאורים שמבדילים כלים דומים, החזירו שגיאות מובנות עם קטגוריות ודגלי — **MCP תכננו ובדקו כלי**. ובדקו מול בקשות משתמש דו-משמעיות
4. שדות, validation/retry, לולאות, JSON schemas עם `tool_use` -**לחילוך נתונים** — השתמשו ב **pipeline בנו**. optional/nullable, Message Batches API דרך batch ועיבוד
5. מפורשים, review לתרחישים דו-משמעיים, קריטריוני few-shot **תתאמנו בהנדסת פרומפט** — הוסיפו דוגמאות גדולים code reviews ל-code multi-pass וארכיטקטורות
6. discovery והאצילו, scratchpad **למדו דפוסי ניהול הקשר** — חלצו עובדות מפלטים מילוליים, השתמשו בקבצי. לתת-סוכנים כדי לטפל בגבולות הקשר
7. מתי להסלים (פערי מדיניות, בקשה מפורשת של משתמש, חוסר יכולת — **human-in-the-loop-הבינו הסלמה ו**. להתקדם) וזרימות ניתוב מבוסס-ביטחון
8. **קחו מבחן תרגול** לפני האמיתי. הוא משתמש באותם תרחישים ופורמט.

מותר להישראל, `guide_en.MD` **על התרגום**: המדריך הזה הוא תרגום עברי של המדריך האנגלי  נשמרו באנגלית לפי המוסכמה הישראלית. ('וכו, `tool_use`, MCP, CLAUDE.md) טכני. מונחים טכניים API נשמרו באנגלית כיוון שהם תחביר enum דוגמאות קוד, סכמות וערכי

[GitHub Issues](#) תרומות לשיפור התרגום מתקבלות בברכה דרך