

Claude Certified Architect — Foundations Certification

مطالعہ گائیڈ (سرکاری امتحانی گائیڈ کی بنیاد پر)

تعارف

سرٹیفیکیشن اس بات کی تصدیق کرتی ہے کہ ایک ماہر حقیقی Claude Certified Architect — Foundations Claude Code، Claude Agent SDK، Claude API، اور Model Context Protocol (MCP) — یعنی بنیادی علم کا جائزہ لیتا ہے — کے ساتھ پروڈکشن ایپلیکیشنز بنائی جاتی ہیں۔ Claude و بنیادی ٹیکنالوجیز جن سے

agentic systems امتحانی سوالات حقیقت پسندانہ صنعتی منظرناموں پر مبنی ہوتے ہیں: کسٹمر سپورٹ کے لیے، multi-agent research pipelines، ڈیزائن کرنا، Claude Code کو CI/CD میں ضم کرنا، developer productivity، structured data بنانا، اور غیر ساختہ دستاویزات سے tools نکالنا۔

هدف امیدوار

کرتا ہے آپ ship کے ساتھ پروڈکشن ایپلیکیشنز ڈیزائن اور Claude کے جو solution architect مثالی امیدوار ایک کے پاس کم از کم 6 ماہ کا عملی تجربہ ہونا چاہیے:

- Claude Agent SDK** — multi-agent orchestration، subagents کو delegate کرنا، tool integration، lifecycle hooks
- Claude Code** — CLAUDE.md، MCP servers، Agent Skills، planning mode
- Model Context Protocol (MCP)** — backend integration کے لیے tools اور resources
- Prompt engineering** — JSON schemas، few-shot examples، data extraction templates
- Context windows** — لمبی دستاویزات کے ساتھ کام، multi-agent context passing
- CI/CD pipelines** — automated code review، test generation
- Escalation and reliability** — error handling، human-in-the-loop

امتحانی فارمیٹ

پیرامیٹر	قدر
سوال کی قسم	Multiple choice (میں سے 1 درست 4)
اسکورنگ	100–1000 scale، passing score 720
Guessing penalty	نہیں (سوال کا جواب دیں!)
Scenarios	8 4 (randomly selected) میں سے

امتحانى مواد: 5 ڈومينز

وزن	ڈومین
27%	1. Agent architecture and orchestration
18%	2. Tool design and MCP integration
20%	3. Claude Code configuration and workflows
20%	4. Prompt engineering and structured output
15%	5. Context management and reliability

امتحان منظر نام

Scenario 1: Customer Support Agent

account اور، returns، billing disputes استعمال کرتے ہوئے Claude Agent SDK بناتے ہیں جو آپ ایک agent MCP tools (`get_customer`، `lookup_order`، `process_refund`، `escalate_to_human`) سنبھالتا ہے۔ مناسب first-contact resolution +80% استعمال کرتا ہے۔ 80 دفعہ ساتھ۔

Scenario 2: Claude Code Code Generation

code generation, refactoring, debugging, documentation اور custom slash commands کے ساتھ، آپ کو اسے development میں استعمال کرتے ہوئے Claude Code کے ساتھ integrate کرنا اور planning mode کرنا، اور سمجھنا کے integrate

Scenario 3: Multi-Agent Research System

تیار کرنا، جاننا، reports کو مکمل citations سسٹم کو report generation اور synthesis tasks کو specialized subagents اور coordinator agent سونپنا: web research, document analysis,

Scenario 4: Developer Productivity Tools

□ agent engineers کو unfamiliar codebases explore کرنے، boilerplate code اور routine tasks automate □□□ میں مدد دیتا □□ Built-in tools (Read, Write, Bash, Grep, Glob) اور MCP servers استعمال □□□ کد □□□ جاز□□□ ہیں □□

Scenario 5: Claude Code for Continuous Integration

Claude Code کو CI/CD pipeline میں ضم کریں تاکہ automated code reviews، test generation، pull request feedback اور Prompts حاصل کیے جاسکیں تاکہ false positives کم سے کم ہوں۔

Scenario 6: Structured Data Extraction

کرتا ہے، validate کے ذریعے JSON schemas کو output، سسٹم غیر ساختہ دستاویزات سے معلومات نکالتا ہے اور کو درست طور پر سنبھالنا چاہیے۔ edge cases پر برقرار رکھتا ہے اسے high accuracy اور

Scenario 7: Conversational AI Architecture Patterns

multi-turn conversational systems میں جن میں context window management، turns متعدد، memory strategies، tool design کے لیے execution محفوظ، کا برقرار رکھنا instructions میں اور مہم یا متضاد، user inputs کو سنبھالنا شامل ہے۔

Scenario 8: Agentic AI Tools (ہماری مدد کریں — مواد موجود نہیں)

میں شامل نہیں ہے۔ guide نہ دی لیکن ابھی تک اس candidates کی اطلاع امتحان دینے والے scenario اس کریں share میں GitHub Issues کے سوالات دیکھیں، تو انہیں scenario کے اصل امتحان میں اس شامل کر سکیں۔ آپ کا تعاون۔ اس شخص کی مدد کرے گا جو امتحان کی تیاری کر coverage تاکہ مہم مکمل رہے۔

سرکاری دستاویزات

وسیلہ	URL
Claude API — Messages	https://platform.claude.com/docs/en/api/messages
Claude API — Tool Use	https://platform.claude.com/docs/en/build-with-claude/tool-use
Claude API — Message Batches	https://platform.claude.com/docs/en/build-with-claude/message-batches
Claude Agent SDK — Overview	https://platform.claude.com/docs/en/agent-sdk/overview
Claude Agent SDK — Hooks	https://platform.claude.com/docs/en/agent-sdk/hooks
Claude Agent SDK — Subagents	https://platform.claude.com/docs/en/agent-sdk/subagents
Claude Agent SDK — Sessions	https://platform.claude.com/docs/en/agent-sdk/sessions
Model Context Protocol (MCP)	https://modelcontextprotocol.io/
MCP — Tools	https://modelcontextprotocol.io/docs/concepts/tools
MCP — Resources	https://modelcontextprotocol.io/docs/concepts/resources
MCP — Servers	https://modelcontextprotocol.io/docs/concepts/servers
Claude Code — Documentation	https://code.claude.com/docs/en/overview
Claude Code — CLAUDE.md and Memory	https://code.claude.com/docs/en/memory
Claude Code — Skills (incl. slash commands)	https://code.claude.com/docs/en/skills

Claude Code — Hooks	https://code.claude.com/docs/en/hooks
Claude Code — Sub-agents	https://code.claude.com/docs/en/sub-agents
Claude Code — MCP Integration	https://code.claude.com/docs/en/mcp
Claude Code — GitHub Actions CI/CD	https://code.claude.com/docs/en/github-actions
Claude Code — GitLab CI/CD	https://code.claude.com/docs/en/gitlab-ci-cd
Claude Code — Headless (non-interactive mode)	https://code.claude.com/docs/en/headless
Prompt Engineering Guide	https://platform.claude.com/docs/en/build-with-claude/prompt-engineering/overview
Extended Thinking	https://platform.claude.com/docs/en/build-with-claude/extended-thinking
Anthropic Cookbook (code examples)	https://github.com/anthropics/anthropic-cookbook

نظریاتی بنیادیں: حصہ ۱

یہ حصہ تمام نظریاتی احاطہ کرتا ہے جس کی آپ کو امتحان میں کامیابی کے لیے ضرورت ہے۔ مواد کو کے مطابق — اس سے آپ کے domains کے مطابق ترتیب دیا گیا ہے، نہ کہ امتحانی concepts ٹیکنالوجیز اور موضوع کی زیادہ گہری سمجھ پیدا کر سکتے ہیں۔

کی بنیادیں Claude API — Model Interaction: باب 1

دستاویزات: [Messages API](#) | [Prompt Engineering](#)

1.1 API Request Structure

Claude API کی request کی ر Claude Messages API کی پیروی کرتا ہے request-response model ایک شامل ہوتا ہے:

```
{
  "model": "claude-sonnet-4-6",
  "max_tokens": 1024,
  "system": "You are a helpful assistant.",
  "messages": [
    {"role": "user", "content": "Hi!"},
    {"role": "assistant", "content": "Hello!"},
    {"role": "user", "content": "How are you?"}
  ],
  "tools": [...],
  "tool_choice": {"type": "auto"}
}
```

م فیلڈر:

- `model` — model selection (`claude-opus-4-6` , `claude-sonnet-4-6` , `claude-haiku-4-5`)
- `max_tokens` — response کی تعداد tokens میں زیادہ سے زیادہ
- `system` — system prompt (model کی تعریف کرتا ہے)
- `messages` — conversation history (تاریخچه گفتگو) (آپ کو مکمل گفتگو)
- `tools` — tools کی definitions دستیاب
- `tool_choice` — tool selection strategy

1.2 Message Roles

`messages` array میں roles استعمال کرتا ہے:

- `user` — user messages
- `assistant` — model responses (history میں شامل کیا جاتا ہے)
- `tool` — tool call results (role واضح طور پر `tool_result` میں کیا جاتا ہے؛ `set` میں ظاہر ہوتا ہے)

Model requests بھیجی جائے گی۔ `conversation history` میں آپ کو مکمل API request انتہائی اہم: ہر آزاد ہوتا ہے call محفوظ نہیں رکھتا — ہر state درمیان

1.3 Response میں `stop_reason` Field

کیوں روکی generation model شامل ہوتا ہے، جو بتاتا ہے کہ `stop_reason` میں Claude API response

Value	Description	Action
"end_turn"	Model نے response مکمل کر لیا	کو دکھائیں user نتیجہ
"tool_use"	Model tool call کرنا چاہتا ہے	Tool execute result دیں اور
"max_tokens"	Token limit ختم ہو گئی	Response truncated ممکن ہے؛ limit بڑھانی پڑے گی
"stop_sequence"	Stop sequence مل گئی	کریں handle کہ مطابق application logic اپنی

کو کنٹرول کرتے agent loop سب سے اہم ہیں — یہی "end_turn" اور "tool_use" میں Agentic systems ہیں۔

1.4 System Prompt

System prompt متعین کرتا ہے behavioral rules اور context جو instruction ایک خاص

- messages array الگ ہوتا؛ یہ system field کا حصہ نہیں ہوتا؛ بلکہ الگ array
- user messages پر فوقیت رکھتا ہے
- میں لاگو رہتا ہے conversation ہوتا ہے اور پوری load ایک بار
- کی تعریف کے لیے استعمال ہوتا ہے output format اور role, constraints,

پیدا کر سکتی ہے مثال کے طور پر tool associations غیر ارادی wording کی system prompt: امتحان کے لیے اہم کو ضرورت سے زیادہ get_customer کو model کی تصدیق کریں "جیسی ہدایت customer پر،" ہمیشہ استعمال کرنے پر مجبور کر سکتی ہے، حتیٰ کے جب یہ ضروری نہ ہو

1.5 Context Window

Context window text (tokens) جسے اس میں process ایک وقت میں model کی کل مقدار ہے جسے شامل ہے:

- System prompt
- message history مکمل
- Tool definitions
- Tool results

مسائل context-window:

1. **Lost-in-the-middle effect:** models input سے اعتماد سے زیادہ موجود معلومات پر اختتام پر موجود معلومات کو زیادہ input سے اعتماد سے زیادہ models process کر سکتے ہیں۔ حل: اہم معلومات شروع یا آخر کے قریب miss کرتے ہیں، مگر درمیان کی تفصیلات process رکھیں
2. **Tool results** واپس کر کے 40+ fields tool شامل کرتا ہے اگر output میں tool call context کا جمع ہونا: ہر Tool results کا بڑا حصہ ضائع ہو جاتا ہے context مگر صرف 5 اہم ہوں، تو
3. **Progressive summarization:** history compress کرتے وقت numeric values, percentages, اور dates اکثر گم ہو کر غیر واضح ہو جاتے ہیں ("تقریباً"، "کچھ"، "چند")

2 Tools اور tool_use: باب

Tool Use: دستاویزات

2.1 tool_use کیا

برا Model کی اجازت دیتا external functions call Claude جو mechanism ایک tool_use result کرتا اور execute اس code بناتا؛ آپ کا structured tool call request میں چلاتا — و code راست واپس کرتا

2.2 Tool Definition

کیا جاتا define کے ذریعہ JSON schema ایک tool

```
{
  "name": "get_customer",
  "description": "Finds a customer by email or ID. Returns the customer profile, including name, email, order history, and account status. Use this tool BEFORE lookup_order to verify the customer's identity. Accepts an email (format: user@domain.com) or a numeric customer_id.",
  "input_schema": {
    "type": "object",
    "properties": {
      "email": {"type": "string", "description": "Customer email"},
      "customer_id": {"type": "integer", "description": "Numeric customer ID"}
    },
    "required": []
  }
}
```

کے انتہائی اہم ہلو Tool description

- Description tool selection** کی بنیاد پر descriptions کو ان کی LLM tools mechanism کا انتخاب کرتا Minimal descriptions ("Customer information retrieve کرتا) اُن مواقع پر غلطیوں کا (کرتا) overlap کے دو tools باعث بنتی ہیں جب کرتے ہوں
- Description میں شامل کریں:**
 - Tool کیا کرتا اور کیا واپس کرتا
 - Input formats اور example values
 - Edge cases اور constraints
 - مقابلہ میں کب استعمال و tool similar alternatives
- کی analyze_document اور analyze_content سے بچیں اگر overlapping descriptions ایک جیسے یا انہیں خلط ملط کر دے گا model تقریباً ایک جیسی ہوں، تو descriptions
- Built-in tools** MCP tools: agents similar functionality والے built-in tools (Read, Grep) کو MCP tools — مضبوط بنائیں MCP tool descriptions پر ترجیح دے سکتے ہیں اس سے بچنے کے لیے concrete advantages, unique data, یا context میں کر سکتے ہیں built-in tools نمایاں کریں جو یا و

2.3 tool_choice Parameter

کیسے منتخب کرتا model tools کے کنٹرول کرتا tool_choice

Value	Behavior	کب استعمال کریں
<code>{ "type": "auto" }</code>	Model کرنا tool call خود ط کرتا یا کرنا text یا میں جواب دینا	default زیاد تر حالات میں
<code>{ "type": "any" }</code>	Model کرنا tool call کو لازماً کوئی	guaranteed جب آپ کو structured output چاہیں
<code>{ "type": "tool", "name": "extract_metadata" }</code>	Model کرنا tool call کو لازماً ایک مخصوص tool کو	forced first step / execution order جب آپ کو چاہیں

ا: م منظر نامہ:

- `tool_choice: "any"` + multiple extraction tools → model منتخب کرتا ہے، مگر پھر بھی tool بہترین model ملنا structured output
- Forced selection → enrichment (مثلاً) کی ضمانت چاہیں action جب آپ کو کسی خاص پم (`extract_metadata`)

2.4 Structured Output JSON Schemas

حاصل کرنے کا سب سے قابلِ structured output Claude استعمال کرنا `tool_use` کے ساتھ JSON schemas

اعتماد طریقہ کے:


- Syntax (trailing commas، غائب ہیں، braces) کی ضمانت دیتا ہے JSON کے اعتبار سے درست (وٹ)
- (موجود وٹ ہیں required fields) نافذ کرتا ہے structure مطلوب
- Semantic correctness (values) کی ضمانت نہیں دیتا

Schema design — بنیادی اصول:

Error type	Example	Mitigation
Syntax	Invalid JSON, غلط field type	JSON schema کے ساتھ tool_use (ختم کر دیتا) (□□)
Semantic	Totals match نہیں کرتے, value غلط field میں, hallucination	Validation checks, feedback کے ساتھ retry, self-correction

3.3 Hub-and-Spoke: Coordinator اور Subagents

Multi-agent architecture عموماً hub-and-spoke topology میں بنائی جاتی ہے:



Coordinator کی ذمہ داریاں:

- Task کو subtasks میں تقسیم کرنا
- (dynamic selection) درکار subagents میں سے کون سا طے کرنا
- کو سونپنا subagents کام
- کرنا validate نتائج جمع اور
- Errors اور retries handle کرنا
- تک پہنچانا user نتائج

الگ ہوتا context subagents کا: اصول

- Subagents conversation history کی coordinator خود بخود inherit نہیں کرتے
- میں واضح طور پر دینا ہوتا context subagent prompt تمام ضروری
- Subagents memory share کے درمیان calls نہیں کرتے
- (observability اور error control کے ذریعے گزرتی coordinator communication تمام)

3.4 Subagents کے لیے Task Tool بنانا

Subagents Task tool کے ذریعے spawn میں جاتے ہیں:

```
# Coordinator میں allowedTools کے "Task" ہونا چاہیے
coordinator_agent = AgentDefinition(
    allowed_tools=["Task", "get_customer"]
)
```

Explicit context passing لازمی ہے:

```
# Bad: subagent کے پاس context نہیں ہے
Task: "Analyze the document"

# Good: context prompt مکمل
Task: "Analyze the following document.
Document: [full document text]
Prior search results: [web search results]
Output format requirements: [schema]"
```

Parallel spawning: coordinator ایک response میں متعدد Task s call کر سکتا ہے — subagents parallel چلتے ہیں:

```
# Coordinator کے ایک response میں شامل ہے
Task 1: "Search for articles about X"
Task 2: "Analyze document Y"
Task 3: "Search for articles about Z"
# تینوں ایک ساتھ چلتے ہیں
```

3.5 Agent SDK میں Hooks

Hooks agent lifecycle میں transformation اور interception پر points کے مخصوص

PostToolUse tool result کو model سے intercept تک پہنچانے سے پہلے model کو PostToolUse tool result کو

```
# کریں formats normalize سے تاریخ کے MCP tools مثال: مختلف
@hook("PostToolUse")
def normalize_dates(tool_result):
    # Unix timestamp -> ISO 8601
    # "Mar 5, 2025" -> "2025-03-05"
    return normalized_result
```

Outgoing-call interception hook policy والے block کو actions کی خلاف ورزی کرنے والے

```
# کریں refunds block مثال: 500$ سے اوپر
@hook("PreToolUse")
def enforce_refund_limit(tool_call):
    if tool_call.name == "process_refund" and tool_call.args.amount > 500:
        return redirect_to_escalation(tool_call)
```

Hooks اور prompt instructions میں فرق

Attribute	Hooks	Prompt instructions
Guarantee	Deterministic (100%)	Probabilistic (>90%, 100% نہیں)
کب استعمال کریں	Critical business rules, financial operations, compliance	General preferences, recommendations, formatting
مثال	Refunds > \$500 block کریں	"Try to solve before escalating"

استعمال کریں hooks، انہیں prompts — کے مالی، قانونی، یا حفاظتی نتائج کے failure قاعدے: جب

4 باب: Model Context Protocol (MCP)

MCP | Tools | Resources | Servers: دستاویزات

4.1 MCP کیا ہے

MCP (Model Context Protocol) Claude کو external systems سے جوڑتا ہے جو open protocol ایک ہے۔ MCP resource types define تین بنیادی کرتا ہے:

1. **Tools** — functions (agent actions) کے لیے (CRUD operations, API calls, command execution)
2. **Resources** — context کے لیے (documentation, database schemas, content catalogs)
3. **Prompts** — predefined prompt templates کے لیے tasks عام

4.2 MCP Servers

MCP server ایک process جو MCP protocol implement کرتا ہے اور tools/resources جب فراہم کرنا چاہے۔ آپ MCP server سے connect کر سکتے ہیں:

- وہ خود بخود tools تمام
- ایک ساتھ دستیاب ہوتے ہیں tools کے connected servers تمام
- انہیں کیسے استعمال کرے گا model طے کرتی ہے۔ Tool descriptions کے

4.3 MCP Servers کو Configure کرنا

Project configuration (`.mcp.json`) — team usage کے لیے:

```
{
  "mcpServers": {
    "github": {
      "command": "npx",
      "args": ["-y", "@modelcontextprotocol/server-github"],
      "env": {
        "GITHUB_TOKEN": "${GITHUB_TOKEN}"
      }
    },
    "jira": {
      "command": "npx",
      "args": ["-y", "mcp-server-jira"],
      "env": {
        "JIRA_TOKEN": "${JIRA_TOKEN}"
      }
    }
  }
}
```

ملاحظات:

- میں ہوتا ہے version control میں محفوظ ہوتا ہے اور `.mcp.json` project root
- Environment variables (`${GITHUB_TOKEN}`) secrets ہیں استعمال ہوتے ہیں۔ tokens خود commit نہیں کیے جاتے۔

- Database schemas (data structure سمجھنے کے لیے)
- Documentation (API references, internal guides)
- Issue/task summaries

Resource کا فائدہ: agent کے لیے exploratory tool calls میں پڑتی کے سمجھنے کے لیے agent کا فائدہ: Resource کا فائدہ: map فوری Resource کیا ہے

5 اور Claude Code — Configuration Workflows

دستاویزات: [Claude Code](#) | [Memory / CLAUDE.md](#) | [Skills](#) | [MCP](#) | [Hooks](#) | [Sub-agents](#) | [GitHub Actions](#) | [Headless](#)

5.1 CLAUDE.md Hierarchy

hierarchy استعمال کرتا ہے اس کی تین سطحی Claude Code میں جو instruction file(s) و CLAUDE.md ہے:

1. User-level: ~/.claude/CLAUDE.md
 - پر لاگو user صرف اسی
 - نمونہ ہوتا ہے share کہ ذریعہ VCS
 - working style اور preferences ذاتی
2. Project-level: .claude/CLAUDE.md یا root CLAUDE.md
 - پر لاگو project contributors تمام
 - ہوتا ہے manage کہ ذریعہ VCS
 - Coding standards, testing standards, architectural decisions
3. Directory-level: subdirectories میں CLAUDE.md
 - کہ ساتھ کام ہو تو لاگو ہوتا ہے files کی directory جب اسی
 - conventions کہ اُس حصہ کہ مخصوص codebase

~/.claude/CLAUDE.md میں ملتی کیونکہ و project instructions کو team member عام غلطی: ایک نئے میں رکھی گئی تھیں (user-level) ~/.claude/CLAUDE.md (project-level) کے بجائے

5.2 @path Syntax (File Imports)

جو جاتی configuration modular کر سکتا ہے، جس سے refer کے ذریعہ @path کو files بیرونی CLAUDE.md ہے:

Coding standards @./standards/coding-style.md میں بیان کیے گئے ہیں
 Test requirements @./standards/testing-requirements.md میں ہیں
 Project overview @README.md اور dependencies @package.json میں ہیں

- (نہیں space کوئی) آئی file path کے فوراً بعد @
- Relative اور absolute paths دونوں supported ہیں
- Relative paths کے مطابق file اس resolve میں
- Maximum import nesting depth 5

شامل ہوتی ہیں، standards میں صرف متعلقہ package کم ہوتی ہیں اور duplication اس سے

کرنے کے organize کے حساب سے topic کو rules کا متبادل ہے، جو monolithic CLAUDE.md .claude/rules/

لیہ استعمال ہوتا ہے:

```
.claude/rules/  
  testing.md          -- testing conventions  
  api-conventions.md  -- API conventions  
  deployment.md        -- deployment rules  
  react-patterns.md    -- React patterns
```

```
---
paths: ["src/api/**/*.json"]
---
```

استعمال کریں۔ explicit error handling کے ساتھ async/await کے لیے API files
وایس کے endpoint standard response wrapper

```
---
paths: ["**/*.test.tsx", "**/*.test.ts"]
---
```

استعمال ہونہ چاہئیں۔ describe/it blocks میں Tests
 ہمیں، hardcoding استعمال کریں Data factories
 استعمال کریں۔ Database mock - test database نہ کریں Database mock

ر. کسب کام کرتا

- کرتا match سہ pattern paths کر جو file edit ایسا Claude Code ہوتا ہے جب load صرف اس وقت Rule ہو
- نہیں ہیں rules load ہوتے ہیں — غیر متعلقہ tokens اور context اس سہ
- Glob patterns کرنے دینے ہیں، چاہے conventions apply کے لحاظ سہ file type آپ کو میں codebase files (tests، migrations) پر (کے لیے بہت مفید tests) کے ہیں بھی ہوں

کے استعمال کریں directory-level CLAUDE.md بمقابلہ .claude/rules/ والے paths

- .claude/rules/ with paths — جب conventions کئی directories میں بکھری files (tests، migrations) پر لاگو ہوں
- Directory-level CLAUDE.md — جب conventions کسی خاص directory میں اور کے ہیں خاص ضروری نہ ہوں

5.4 Custom Slash Commands اور Skills

skills کو (.claude/commands/) custom commands میں Claude Code version نوٹ: موجود بناؤ commands /name formats کر دیا گیا ہے دونوں unify کے ساتھ (.claude/skills/) supported اب بھی format کا ذکر کرتی ہے — و .claude/commands/ ہیں امتحانی گائیڈ

Slash commands reusable prompt templates ہیں جو /name کے ذریعے invoke کے ہیں:

.claude/commands/ format (legacy, supported):

```
.claude/commands/
review.md      -- /review -- standard code review
test-gen.md    -- /test-gen -- test generation
```

.claude/skills/ format (current):

```
.claude/skills/
review/SKILL.md -- /review -- frontmatter configuration کہ ساتھ
test-gen/SKILL.md
```

Project commands (.claude/commands/ یا .claude/skills/):

- کرنے والے سب کے لیے دستیاب ہوتے ہیں repo clone میں محفوظ ہوتے ہیں اور VCS
- یقینی بناتے ہیں consistent workflows ٹیم میں

User commands (~/.claude/commands/ یا ~/.claude/skills/):

- نہیں ہیں ہوتے share کے ذریعے VCS جو commands ذاتی
- کے لیے workflows انفرادی

5.5 Skills — .claude/skills/

Skills advanced commands ہیں جو SKILL.md frontmatter کے ذریعے configure کے ہیں:

```
---
context: fork
allowed-tools: ["Read", "Grep", "Glob"]
argument-hint: "Path to the directory to analyze"
---
```

کا تجزیہ کریں۔ code structure میں directory دی گئی
report پر ایک architectural patterns اور Dependencies

Frontmatter parameters:

Parameter	Description
<code>context:</code> <code>fork</code>	Verbose output main session کو pollute نہیں کرتا isolated subagent میں چلاتا
<code>allowed-</code> <code>tools</code>	نہیں کر skill files delete مثلاً — security) دستیاب ہوں گے tools یں محدود کرتا ہے کون سے (سکا گی اگر اجازت نہ ہو
<code>argument-</code> <code>hint</code>	مانگنے کا اشارہ argument ہو تو invoke کے بغیر skill parameters جب

Skill `CLAUDE.md` کے استعمال کریں:

- Skill — task مخصوص on-demand invocation (review, analysis, generation) کے لیے
- `CLAUDE.md` — general standards اور conventions ہمیشہ لوڈ ہونے والے

Personal skills (`~/claude/skills/`):

- متاثر نہ ہوں teammates مختلف ناموں سے بنائیں تاکہ personal variants اپنی

5.6 Planning Mode `Direct Execution` کے مقابلے

Planning mode:

- Model نہیں کرتا changes کرتا ہے؛ plan اور investigate صرف
- Codebase explore کے لیے Read, Grep, Glob استعمال کرتا ہے
- کرتا ہے user approve تیار کرتا ہے جس implementation plan ایک
- safe exploration کے side effects بغیر

Planning mode کے استعمال کریں:

- changes (files درجنوں) بڑے
- Multiple plausible approaches (microservices: boundaries کیسے define ہوں؟)
- Architectural decisions (کیا framework کون سا؟ structure؟)
- Unfamiliar codebase (change کی ضرورت ہے سمجھنا)
- Library migrations 45+ files کو متاثر کریں

Direct execution کے استعمال کریں:

- Single-file fixes ساتھ stack trace واضح
- شامل کرنا validation check ایک
- changes اچھی طرح سمجھ گئی، غیر مبہم

Combined approach:

1. Investigation اور design کے لیے planning mode
2. User plan approve کر
3. Approved plan implement کے لیے direct execution

Explore subagent — codebase explore کے لیے specialized subagent:

- Verbose output کو main context سے isolate کرنا
- واپس کرنا summary صرف
- روکنا Multi-phase tasks میں context-window exhaustion

5.7 /compact Command

/compact context compress کے لیے built-in command:

- میں جگہ خالی کرنا context window کو summarize کر کے history چھپی
- Long investigation sessions میں verbose tool output سے context بھر جائے
- Risk: exact numeric values, dates, اور specific details summarization میں گم ہو سکتے ہیں

5.8 /memory Command

/memory sessions memory manage کے لیے built-in command:

- محفوظ کیے جا سکیں context اور notes, preferences, کے لیے کھولنا، تاکہ CLAUDE.md file editing
- Information sessions اور load پر خود بخود startup کے پار برقرار رہتی ہیں
- Project conventions, user preferences, frequently used commands, اور current work context محفوظ کر کے لیے مفید
- دوبارہ سمجھانے کا متبادل instructions میں وہی session رہے

5.9 Claude Code CLI for CI/CD

-p (یا --print) flag:

```
claude -p "Analyze this pull request for security issues"
```

- Non-interactive mode: prompt process کرنا، اور print پر stdout، exit کرنا،
- User input کا انتظار نہیں کرتا
- CI/CD pipelines میں Claude کا واحد درست طریقہ

CI کے لیے structured output:

```
claude -p "Review this PR" --output-format json --json-schema
'{"type":"object",...}'
```

- `--output-format json` — output کو JSON میں دیتا ہے
- `--json-schema` — output کو schema کے مطابق validate کرتا ہے
- Result کو automatically inline PR comments میں لے کر دے دیتا ہے

Session context isolation: Claude session میں جس code generate کیا گیا ہے، اکثر review میں کمی ہوتی ہے، چونکہ review کے وقت، پچھلے review کے context (model reasoning context) کو بھی لے لیا جاتا ہے۔ اس کا امکان کم ہوتا ہے کہ challenge ساتھ رکھتا ہے اور اپنی فیصلوں کو (model reasoning context) کو لے لیا جاتا ہے۔ اس کا استعمال کریں independent instance کے لیے Review کو

Duplicate comments review results context کے وقت، پچھلے review کے بعد دوبارہ commits سے بچاؤ: review کے بعد دوبارہ review کے context کی ہدایت دیں unresolved issues report کو صرف نئے یا Claude میں شامل کریں اور

5.10 Session Management اور `fork_session`

`--resume <session-name>` named session کو resume کرتا ہے:

```
claude --resume investigation-auth-bug
```

- saved context کے ساتھ پچھلی conversation کے
- Long investigations sessions مفید ہیں ان کے لیے جو متعدد sessions پر پھیلی ہوئی ہیں
- Risk: tool results stale بدل چکی ہیں تو files کے بعد session اگر پچھلی

`fork_session` shared context سے independent branch بناتا ہے:

```
Codebase investigation
|
fork_session
/      \
Approach A:  Approach B:
Redux       Context API
```

- کرتا ہے کہ context inherit تک forks branch point دونوں
- کرتا ہے کہ diverge اس کے بعد وہ آزادانہ طور پر
- Approaches compare یا strategies test کرنے کے لیے مفید ہے

Resume نئی session کے بجائے نئے

- Tool results stale (files) کے بدل چکی ہیں
- ہو گیا کہ context degrade کافی وقت گزر چکا ہو اور
- کرنے کے بجائے یہ بہتر ہے کہ "م" جو پایا اس کا مختصر خلاصہ ہے: resume کے ساتھ tool data پرانے کیا جائے restart "... سے"

باب 6: Prompt Engineering — Advanced Techniques

دستاویزات: [Prompt Engineering](#) | [Anthropic Cookbook](#)

6.1 Few-shot Prompting

Few-shot prompting میں input/output prompt 2–4 دکھانے کے لیے expected behavior کے طریقے جس میں شامل کیے جاتے ہیں examples

Few-shot text descriptions زیادہ مؤثر کیوں

- "وہ کو کئی طریقوں سے سمجھا جا سکتا ہے" precise کیسے زیادہ instruction مہم
- Example دکھانا decision logic اور expected format غیر مہم طور پر
- Model pattern (صرف examples) کرنا generalize پر cases کو نئے

Few-shot examples کی اقسام اور استعمال

1. Ambiguous scenarios کے لیے examples:

```
Request: "My order is broken"
Action: Call get_customer -> lookup_order -> check status.
Rationale: "broken" damaged item آپ کو ہو سکتا ہے؛ order details میں درکار
```



```
Request: "Get me a manager"
Action: کریں escalate_to_human call فوراً
Rationale: مانگ رہا ہے خود حل کرنے کی کوشش نہ کریں human واضح طور پر
```

2. Output formatting کے لیے examples:

```
Finding example:
{
  "location": "src/auth/login.ts:42",
  "issue": "SQL injection in the username parameter",
  "severity": "critical",
  "suggested_fix": "Use a parameterized query"
}
```

3. Acceptable کے لیے problematic code کے لیے examples:

```
// Acceptable (flag کریں):
const items = data.filter(x => x.active);

// Problem (flag کریں):
const items = data.filter(x => x.active == true); // Use strict equality ===
```

4. Different document formats سے extraction کے لیے examples:

Document with inline citations:

"As shown in the study (Smith, 2023), the rate is 42%."

-> {"value": "42%", "source": "Smith, 2023", "type": "inline_citation"}

Document with bibliography references:

"The rate is 42%. [1]"

-> {"value": "42%", "source": "reference_1", "type": "bibliography"}

5. Informal measurements کے لیے examples:

Text: "about two handfuls of rice"

-> {"amount": "~100g", "original_text": "two handfuls", "precision": "approximate"}

Text: "a pinch of salt"

-> {"amount": "~1g", "original_text": "a pinch", "precision": "approximate"}

Few-shot purely rule-based instructions میں مؤثر اور non-standard measurement units جو informal خاص طور پر Few-shot based instructions کے لیے بہت متنوع ہوتی ہیں

Prompts استعمال strict JSON schemas کے لیے structured output جب format normalization rules میں Prompts شامل کریں normalization rules میں prompt کریں:

Normalization:

- Dates: ہمیشہ ISO 8601 (YYYY-MM-DD); "yesterday" -> absolute date compute کریں
- Currency: numeric amount + currency code; "five bucks" -> {"amount": 5, "currency": "USD"}
- Percentages: decimal fraction; "half" -> 0.5

وہ values inconsistent درست ہو مگر JSON syntactically کم ہوتے ہیں جہاں semantic errors اس سے

6.2 Explicit Criteria بمقابلہ Vague Instructions

Bad (vague):

Code comments کی accuracy چیک کریں

Conservative high-confidence findings report کریں - صرف

Good (explicit criteria):

Comment کو problematic میں اس صورت میں flag کریں جب:

1. Comment کا actual code behavior سے CONTRADICT ہو
2. Comment کا حوالہ دہ variable یا function کسی غیر موجود
3. TODO/FIXME comment ایسے bug جو کسی fix میں پہلے ہی code کی طرف اشارہ کرے جو

Flag نہ کریں:

- کہ لحاظ سے پرانہ style جو صرف comments ایسے
- wording inaccuracies معمولی
- Missing comments (الگ category یہ الگ)

Severity criteria examples کے ساتھ define کریں:

CRITICAL: User کہ لیے runtime failure

Example: Payment process وقت NullPointerException

HIGH: Security vulnerability

Example: SQL injection, XSS, missing authorization checks

MEDIUM: Logic bug کہ بغیر فوری impact

Example: Wrong sorting, off-by-one error

LOW: Code quality

Example: Duplication, کہ لیے data suboptimal algorithm

6.3 Prompt Chaining

Prompt chaining میں توڑنا sequence کی focused steps کو ایک complex task

Step 1: auth.ts analyze کریں (صرف local issues)

-> Output: auth.ts میں issues کی list

Step 2: database.ts analyze کریں (صرف local issues)

-> Output: database.ts میں issues کی list

Step 3: Integration pass (cross-file dependencies)

-> Output: module boundaries پر issues

یہ کیوں اہم:

- **Attention dilution** — جب files دیکھتا تو کچھ files ایک ساتھ ہوت سی model سد بچاتا — جب bugs miss files دیکھتا
- سد سکتا سد shallow commentary کر سکتا اور باقی پر
- یقینی بناتا سد consistent analysis quality کہ لیے file
- Cross-file interactions الگ analysis کہ لیے

Prompt chaining کب استعمال کریں dynamic decomposition بمقابلہ:

- **Prompt chaining** — predictable, repeatable tasks (code review, file migrations)
- **Dynamic decomposition** — open-ended investigations ان subtasks execution وت واضح وت

6.4 “Interview” Pattern

Solution implement Claude clarifying questions پوچھتا:

Claude: "API کہ لیے caching implement چند سوالات

1. پسند کرتہ ہیں؟ cache invalidation strategy میں سد کون سی event-based یا TTL آپ

2. قابل قبول سد؟ stale data ہو تو کیا cache unavailable اگر

3. Caching per-user یا global؟ مونی چاہیہ

4. Cache کہ لیے expected data volume کہ لیے

یہ کب مفید:

- Unfamiliar domain (fintech, healthcare, legal systems)
- Implications and tasks (cache strategies, failure modes)
- Viable approaches on context جہاں بہترین انتخاب

6.5 Validation اور Retry-with-Feedback

جب extracted data validation fail کرے:

```
Step 1: Document سے data extract کریں
Step 2: Validate کریں (Pydantic, JSON Schema, business rules)
Step 3: retry کریں کہ ساتھ context ہو – error اگر:
- Original document
- Previous (incorrect) extraction
- Specific error: "Field 'total' = 150, but sum(line_items) = 145. Re-check values."
```

Retry مؤثر ہوگا:

- Format errors (date غلط format میں)
- Structural errors (field جگہ غلط)
- Arithmetic inconsistencies (model دوبارہ check کر سکتا ہے)

Retry گا مدد نہیں کرے:

- Information source document ہی نہیں
- Required context external (data کسی اور document میں کیا گیا)

Pydantic validation tool: Pydantic Python library جو schema-based data validation کے لیے استعمال ہوتی ہے امتحان کے لیے اس کے نکات یہ ہیں:

- **Structural validation:** types, requiredness, enum constraints JSON کے بعد code میں جانچا جاتا ہے
 - **Semantic validation:** custom validators business logic enforce کرتے ہیں (sum of items equals total! start_date < end_date)
 - **Validate-retry loops:** Pydantic validation failure پر error message بنا کر Claude کو error context میں prompt ساتھ دوبارہ کریں
 - **JSON Schema generation:** Pydantic models سے JSON Schema generate کر سکتے ہیں `tool_use` کے لیے
- فراہم کرتا ہے single source of truth میں، جو ایک

6.6 Self-correction

Internal contradictions detect کرنے کا pattern:


```
{
  "stated_total": "$150.00",
  "calculated_total": "$145.00",
  "conflict_detected": true,
  "line_items": [
    {"name": "Widget A", "price": 75.00},
    {"name": "Widget B", "price": 70.00}
  ]
}
```

آپ `conflict_detected` دونوں نکالتا ہے — اگر وہ مختلف ہوں تو Model stated value اور computed value کو discrepancy handle کرنے دیتا ہے

7 Message Batches API: باب 7

دستاویزات: [Message Batches](#)

7.1 Overview

کرنے دیتا ہے batches submit کے requests کے لیے asynchronous processing کو Message Batches API

Attribute	Value
Savings	50% کے مقابلے میں 50 synchronous calls
Processing window	24 hours (latency SLA guarantee) زیادہ سے زیادہ
Multi-turn tool calling	Supported نہیں (یک request = ایک response)
Correlation	request اور response کے لیے <code>custom_id</code> field کو جوڑنے کے لیے

7.2 Batch API کے مقابلے Synchronous API میں استعمال کریں

Task	API	Why
Pre-merge PR check	Synchronous	Developer 24 hours انتظار کر رہا ہے؛ قابل قبول نہیں
Overnight tech-debt report	Batch	savings % صبح تک چاہیے؛ Result 50
Weekly security audit	Batch	savings % فوری نہیں؛ 50
Interactive code review	Synchronous	درکار کے response فوری
10,000 documents process کرنا	Batch	Bulk processing؛ savings میں

7.3 custom_id کا استعمال

```
{
  "custom_id": "doc-invoice-2024-001",
  "params": {
    "model": "claude-sonnet-4-6",
    "max_tokens": 1024,
    "messages": [{"role": "user", "content": "Extract data from: ..."}]
  }
}
```

custom_id آپ کو یہ کرنے دیتا ہے:

- Result کو original document link سے
- Failure submit دوبارہ کی صورت میں صرف
- Successful documents process کو دوبارہ

7.4 Batch کو Failures میں Handle کرنا

1. 100 documents کا batch submit کریں
2. 95 succeed 5 fail (context limit exceeded) ہوں
3. Failures کو custom_id سے identify کریں
4. Strategy (میں تقسیم کریں chunks کو long documents مثلاً) بدلیں
5. 5 failed documents submit کو دوبارہ صرف اُن

7.5 SLA Planning

تک لگ سکتے ہیں 24 hours کو Batch API چاہے اور result میں hours اگر آپ کو 30

- Submission window: 30 - 24 = 6 hours
- Batches کو deadline 24 hours سے کم از کم
- Frequent submissions 4 hour windows میں تقسیم کریں

8: Task Decomposition Strategies

8.1 Fixed Pipelines (Prompt Chaining)

ہوتا ہے defined step سے:

Document -> Metadata extraction -> Data extraction -> Validation -> Enrichment -> Final output

کب استعمال کریں:

- Task structure predictable (reviews ایک template follow کریں)
- پلاٹ سڈ معلوم ہوں steps تمام
- چا پیڈ reproducibility اور stability آپ کو

8.2 Dynamic Adaptive Decomposition

Subtasks intermediate results پر بنیاد کی generate ہیں:

1. "Legacy codebase کے لیے tests add کریں"
2. -> structure map (Glob, Grep) کریں
3. -> 3 modules بغیر tests، partial coverage کے ساتھ
4. -> Prioritize: payments module شروع کریں (high risk)
5. -> دریافت ہوئی dependency پر external API: کام کے دوران
6. -> Adapt: tests کے لیے external API لکھنے سے پہلے mock add کریں

کب استعمال کریں:

- Open-ended investigative tasks
- شروع میں معلوم نہ ہو scope جب مکمل
- پر منحصر ہو results کے step پچھلے step جب ر

8.3 Multi-pass Code Review

10+ files والی pull requests کے لیے:

```
Pass 1 (per-file): auth.ts analyze کریں -> local issues کی list
Pass 1 (per-file): database.ts analyze کریں -> local issues کی list
Pass 1 (per-file): routes.ts analyze کریں -> local issues کی list
...
Pass 2 (integration): files درمیان کے relationships analyze کریں
-> Cross-file issues: inconsistent types, circular dependencies
```

14 files کی pass پر ایک کی خراب:

- Attention dilution: shallow کچھ کی، deep analysis کی files کچھ
- Inconsistent comments: approve دوسری میں، pattern flag میں ایک file
- Missed bugs: cognitive overload واضح سڈ errors کی وجہ سے

9 Escalation اور Human-in-the-Loop: باب 9

9.1 Escalate کی طرف Human کب

Escalation triggers (rules واضح):

Situation	Action
-----------	--------

Customer "get me a manager" واضح طور پر کہتا ہے	کریں؛ حل کرنے کی کوشش نہ کریں escalate فوراً
Policy request کو cover نہ کرتی ہو	Escalate policy جب competitor price matching مثلاً کریں (ہو)
Agent پیش رفت نہ کر سکے	کریں escalate کے بعد attempts مناسب تعداد میں
Threshold financial operation سے اوپر	Escalate کے ذریعے prompt enforce، کے ذریعے hook ترجیحاً کریں (نہیں)
Customer multiple matches تلاش کرتے وقت	مانگیں؛ انداز نہ لگائیں identifiers مزید

نہیں ہیں reliable trigger جو:

Unreliable method	Why it fails
Sentiment analysis	نہیں کرتا correlate سے Customer کا mood case complexity
Model self-rated confidence (1–10)	کمزور calibration غلط ہو سکتا ہے؛ Model confidently
Automatic classifier	موجود نہ ہو training data؛ ممکن Overengineering

9.2 Escalation Patterns

Immediate escalation:

Customer: "I want to speak to a manager"
 Agent: [کرتا escalate_to_human call فوراً]
 NOT: "I can help with your issue, let me..."

Resolve escalation: کی کوشش کے بعد

Customer: "My refrigerator broke two days after purchase"
 Agent: [کرتا warranty replacement offer، چیک کرتا]
 escalate -> مطمئن نہ ہو customer اگر

Nuanced escalation (acknowledge → resolve → reiteration پر escalate):

Customer: "This is outrageous, I'm very unhappy with the quality!"
 Agent: [frustration acknowledge] "سمجھتا ہوں frustration میں آپ کی"
 [resolution offer] "پیش کر سکتا ہوں refund یا replacement میں"
 Customer: "No, I want to talk to someone!"
 Agent: [customer insist دوبارہ -> immediate escalation]

کریں escalate دیں، اور صرف اسی وقت concrete solution کریں، پھر emotion acknowledge بنیادی اصول: پہلے
 manager (نہیں) کریں escalate کے پہلے اطلاع پر dissatisfaction کی خواہش دہرائیں customer human جب
 (مانگندہ کے برابر نہیں ہیں)

Policy gap کے لیے escalation:

Customer: "Competitor X has this item 30% cheaper—give me a discount"
Policy: کرتی ہے price adjustments cover پر site صرف اپنی
Agent: [escalate – policy competitor price matching کو cover نہیں کرتی]

9.3 Structured Handoff Protocols

Escalation کو دینی چاہیے structured summary human agent پر:

```
{
  "customer_id": "CUST-12345",
  "customer_name": "Ivan Petrov",
  "issue_summary": "Refund request for a damaged item",
  "order_id": "ORD-67890",
  "root_cause": "Item arrived damaged; photos attached",
  "actions_taken": [
    "Verified customer via get_customer",
    "Confirmed order via lookup_order",
    "Offered a standard replacement – customer insists on a refund"
  ],
  "refund_amount": "$89.99",
  "recommended_action": "Approve a full refund",
  "escalation_reason": "Customer requested to speak with a manager"
}
```

دیکھتا ہے summary تک رسائی نہیں ہوتی — صرف یہ full conversation transcript کو Human operator کو دینی چاہیے self-contained اس لیے یہ مکمل اور

9.4 Confidence Calibration اور Human Oversight

Data extraction systems کے لیے:

1. **Field-level confidence scores:** model کے لیے extracted field کا confidence score نکالتا ہے
2. **Calibration:** labeled validation sets کے thresholds tune کریں استعمال کر کے
3. **Routing:**
 - High confidence + stable accuracy -> automated processing
 - Low confidence یا ambiguous sources -> human review

Stratified random sampling:

- High-confidence extractions کا sample audit بھی باقاعدگی سے کریں
- Aggregate 97% accuracy کا document type 40% errors کا چھپا سکتی ہے
- Accuracy کا analyze کے حساب سے field اور document type، میں overall کو صرف

Multi-agent Systems میں Error Handling: باب 10

10.1 Error Categories

Category	Examples	Retryable	Agent action
Transient	Timeout, 503, network failure	Yes	Exponential backoff ساتھ retry کریں
Validation	Invalid input format, missing required field	No (input fix کریں)	Request modify اور retry کریں
Business	Policy violation, threshold exceeded	No	پیش alternative کو سمجھائیں؛ User کریں
Permission	Access denied	No	Escalate کریں

10.2 Error-handling Anti-patterns

Anti-pattern	Problem	Correct approach
Generic status “search unavailable”	Coordinator decide نہیں کر سکتا کہ recover کیسے کرنا ہے	Error type, query, partial results, alternatives واپس کریں
Silent suppression (empty result = success)	Coordinator match سمجھتا ہے کہ failure ملا، حالانکہ	“no results” اور “search failure” میں فرق کریں
Workflow پر پورا failure ایک abort کرنا	ضائع ہو جاتا ہے partial results تمام	Partial results ساتھ جاری رکھیں؛ gaps annotate کریں
Subagent میں infinite retries	Latency اور resources کا ضیاع	Local recovery (1–2 retries)، پھر coordinator تک propagate

10.3 Structured Subagent Error

```
{
  "status": "partial_failure",
  "failure_type": "timeout",
  "attempted_query": "AI impact on music industry 2024",
  "partial_results": [
    {"title": "AI Music Generation Report", "url": "...", "relevance": 0.8}
  ],
  "alternative_approaches": [
    "Try a narrower query: 'AI music composition tools'",
    "Use an alternative data source"
  ],
  "coverage_impact": "Not covered: AI impact on music production"
}
```

کو فیصلہ کرنا کہ آیا ضروری معلومات دیتا ہے coordinator

- Modified query ساتھ retry کریں؟
- Partial results استعمال کریں؟
- subagent کو delegate کسی اور کریں؟
- gap annotate کریں؟ بغیر جاری رکھیں اور section اس

10.4 Final Synthesis میں Coverage Annotations

Report: AI Impact on Creative Industries

Visual Art (FULL COVERAGE)

[research results]

Music (PARTIAL COVERAGE – search agent timeout)

[partial results]

⚠️ Note: coverage search agent timeout سے محدود ہے اس کی section

Literature (FULL COVERAGE)

[research results]

Context میں Production Systems: باب 11

Management

11.1 Facts کو Extract میں Separate Block

Conversations history کو (جو summarize کے دوران summarize ہو جاتی ہے) key facts کو extract میں structured block میں:

```
=== CASE FACTS (fact جب بھی نیا) update آئے ===
Customer ID: CUST-12345
Order ID: ORD-67890
Order Date: 2025-01-15
Order Amount: $89.99
Issue: Damaged item on delivery
Customer Request: Full refund
Status: Pending manager approval
===
```

کیونکہ summarized history میں شامل کریں، prompt میں block یں

11.2 Tool Results کو Trimming کرنا

اگر `lookup_order` 40+ fields مگر current task میں 5 درکار ہیں واپس کرتا ہے

```
# PostToolUse hook: relevant fields رکھیں
@hook("PostToolUse", tool="lookup_order")
def trim_order_fields(result):
    return {
        "order_id": result["order_id"],
        "status": result["status"],
        "total": result["total"],
        "items": result["items"],
        "return_eligible": result["return_eligible"]
    }
```

کم ہوتی ہے noise بچتا ہے اور context اس سے

11.3 Position-aware Input

Lost-in-the-middle effect کو critical information میں رکھتے ہیں

3 critical vulnerabilities ... ملین

```
=== File auth.ts ===
```

■ ■ ■

```
=== File database.ts ===
```

• • •

Priority: merge `auth.ts` vulnerabilities fix کریں.

Long investigations میں agent key findings scratchpad file □□ لکھ سکتا

```
# investigation-scratchpad.md
## Key findings
- PaymentProcessor in src/payments/processor.ts inherits from BaseProcessor
- refund() تین places سے call ہوتی ہے: OrderController, AdminPanel, CronJob
- External PaymentGateway API limit: 100 req/min
- Migration #47 نے refund_reason (NOT NULL) add کیا - 01-12-2024
```

scratchpad دوبار چلائے گا بچائے agent discovery (میں session یا نئی) و جائے context degrade جب consult کر سکتا ہے

```
Main agent: "payments module کی dependencies investigate کریں"
  -> Subagent (Explore): 15 files read کرتا, imports trace کرتا
  -> Returns: "Payments depends on AuthService, OrderModel, and the external
PaymentGateway API"
```

Main agent: context 15 میں ایک files کے بجائے line رکھتا ہے

Separate context layer: Multi-agent systems میں کام کرتا ہے — context budget محدود subagent میں — صرف اپنے task اس کے لیے ضروری information کو ملتی ہے۔ Coordinator ایک separate context layer طور پر context allocate کرتا ہے، اور global state store، کرتا ہے subagent outputs aggregate کرتا ہے۔ وہ اس کے agent window میں نہ دیتا ہے، جہاں ایک “context leakage” ہے۔ اس کے دوسروں کے لیے غیر متعلق ہے۔

Subagents $\square_{\downarrow}$ $\square_{\leq}$ constrained context budgets:

- Minimal context **بہجیں**: specific task + ضروری data
- Subagent کو raw data dumps **بجائے** structured results کی **ہدایت** دیں
- `allowedTools` **subagent** کو toolset کو **کم** — کم distractions کا مطلب کم tools کریں — **context cost**

11.6 Structured State Persistence (crash recovery لی کی)

کرتا ہے export پر location ایک معلوم state اپنی agent ر:

```
// agent-state/web-search-agent.json
{
  "status": "completed",
  "queries_executed": ["AI music 2024", "AI music composition"],
  "results_count": 12,
  "key_findings": [...],
  "coverage": ["music composition", "music production"],
  "gaps": ["music distribution", "music licensing"]
}
```

Coordinator resume پر ایک manifest load کرتا ہے:

```
// agent-state/manifest.json
{
  "web-search": "completed",
  "doc-analysis": "in_progress",
  "synthesis": "not_started"
}
```

12 کو محفوظ رکھنا Provenance: باب 12

12.1 Attribution Loss Problem

گم ہو سکتا ہے link "claim → source" کی جاتی ہیں، تو results summarize سے sources جب متعدد

Bad: "The AI music market is estimated at \$3.2B." (No source, no year.)

Good:

```
{
  "claim": "The AI music market is estimated at $3.2B.",
  "source_url": "https://example.com/report",
  "source_name": "Global AI Music Report 2024",
  "publication_date": "2024-06-15",
  "confidence": 0.9
}
```

12.2 Conflicting Data کو Handle کرنا

دیں values مختلف sources جب دو

```
{
  "claim": "Share of AI-generated music on streaming platforms",
  "values": [
    {
      "value": "12%",
      "source": "Spotify Annual Report 2024",
      "date": "2024-03",
      "methodology": "Automated classification"
    },
    {
      "value": "8%",
      "source": "Music Industry Association Survey",
      "date": "2024-07",
      "methodology": "Survey of 500 labels"
    }
  ],
  "conflict_detected": true,
  "possible_explanation": "Methodology اور time period فرق کا"
}
```

کو coordinator کے ساتھ محفوظ رکھیں اور attribution کو اندھا دھند منتخب نہ کریں۔ دونوں کو value کسی ایک فیصلہ کرنے دیں۔

12.3 Correct Interpretation کے لیے Dates شامل کریں

سمجھ لیا جا سکتا ہے contradiction کو temporal differences کے بغیر Dates:

Bad: "Source A says 10%, source B says 15%. Contradiction."

Good: "Source A (2023) says 10%, source B (2024) says 15%. Likely 5+ سال میں 1% growth."

12.4 Content Type کے مطابق Render کریں

میں نہ ٹھونسیں format کے چیز کو ایک کی:

- Financial data -> tables
- News اور analysis -> prose
- Technical findings -> structured lists
- Time series -> chronological ordering

باب 13: Claude Code کے Built-in Tools

13.1 Tool Selection Reference

Task	Tool	Example
تلاش کرنا files کے نام/pattern	Glob	<code>**/*.test.tsx</code> , <code>src/components/**/*.ts</code>
File contents کے اندر search کرنا	Grep	Function name, error message, import
File مکمل پڑھنا	Read	Analysis کے لیے file load کرنا
بنانا file نیا	Write	Scratch کے file create کرنا
precise edit میں file موجود	Edit	Unique text match کے ذریعے specific snippet replace کرنا
Shell command چلانا	Bash	git, npm, tests, build

13.2 Incremental Investigation Strategy

نہ پڑھیں کے سمجھ بوجھ کو رفتہ رفتہ بنائیں files ایک ساتھ تمام:

1. Grep: entry points تلاش کریں (function definition, export)
2. Read: پڑھیں files ملنے والی
3. Grep: usages تلاش کریں (import, calls)
4. Read: consumer files پڑھیں
5. کریں repeat نہ مل جائے picture جب تک مکمل

13.3 Fallback: Edit کے بجائے Read + Write

و جائے fail کی وجہ سے Edit non-unique text match جب:

1. Read — لوڈ کریں file content مکمل
2. Content کو programmatically modify کریں
3. Write — لکھ دیں updated version

امتحانی ڈومین نوٹس: II حصہ

Orchestration اور Agent Architecture: ڈومین 1 (27%)

1.1 Autonomous Task Execution اور Agentic Loops Design کرنا

Key knowledge:

- Agent loop lifecycle: Claude request بھیجیں، `stop_reason` ("tool_use" بمقابلہ "end_turn") چیک واپس کریں results کے لیے iteration کریں، اگلی tools execute کریں
- Tool results conversation history میں append تاکہ آپس میں model اگلا action کر سکے
- Model-driven decision making (Claude tool اگلا چنتا) بمقابلہ hard-coded decision trees

Key skills:

- Flow control: جب `stop_reason = "tool_use"` تو loop جاری رکھیں اور `"end_turn"` پر رک جائیں
- Iterations درمیان context کو tool results میں append کرنا
- Anti-patterns سے بچنا: completion کے لیے assistant text parse کرنا، primary stopping mechanism کے استعمال پر arbitrary iteration limits

1.2 Multi-agent Systems (Coordinator–Subagent) Orchestrate کرنا

Key knowledge:

- Hub-and-spoke architecture: coordinator تمام inter-agent communication، error handling، اور routing کا مالک ہوتا ہے
- Subagents isolated context میں کام کرتے ہیں — وہ خود بخود coordinator کی history inherit نہیں کرتے
- Coordinator responsibilities: task decomposition، delegation، result aggregation، dynamic selection of subagents
- Coordinator کی overly narrow decomposition کا خطرہ

Key skills:

- Research coverage کم ہو duplication کے درمیان تقسیم کریں تاکہ subagents کو
- Iterative refinement loops implement کریں (coordinator synthesis evaluate اور tasks re-route کریں)
- Observability کے ذریعے route کے coordinator communication کے لیے تمام

کریا

Key knowledge:

- Task tool subagents spawn: □□ کرتا coordinator □□ allowedTools میں "Task" □□ شامل □□ونا □□ا
- Subagent context prompt میں explicitly □□ا □□ا؛ □□ا □□ا subagents parent context inherit □□ا کرتا □□ا
- AgentDefinition configuration: descriptions, system prompts, tool constraints
- Alternatives explore □□ا □□ا □□ا fork_session □□ا ذریعہ □□ا session management

Key skills:

- Previous agents کا full outputs subagent prompt میں شامل کریں
- Context pass کو metadata اور data کے الگ الگ structured formats میں کرنا وقت سے بچاتا ہے
- Coordinator turn میں متعدد tasks کے parallel subagents spawn کریں
- Coordinator prompts goals اور quality criteria کے طور پر، step-by-step instructions کے طور پر

Workflows Implement کرنا

Key knowledge:

- Workflow ordering اور **prompt guidance** (hooks, preconditions) کے **programmatic enforcement** کے لیے درمیان فرق
- **identity verification** (مثلاً مالی operations پر)، **prompts** کے **deterministic guarantees** کے درکار ہوں کافی نہیں ہوتے
- **structured handoff protocols** (customer ID, reason, recommended action) کے دوران **Escalation**

Key skills:

- مکمل نہ ہوں steps کریں جب تک پوائنٹ block کو downstream calls جو programmatic preconditions ایسا (کریں block `process_refund` واپس کرنے تک ID verified کے `get_customer` مثلاً)
- Multi-aspect customer requests الگ الگ items تقسیم کریں
- Human کو escalate کرتے وقت structured summaries produce کریں

1.5 Tool Calls Intercept اور Agent SDK Hooks

Key knowledge:

- Hook patterns (مثلاً `PostToolUse`) tool results کو model consume کرنا۔ پھر اسے intercept کرنا۔
- Hooks outgoing calls intercept کرنا۔ compliance rules enforce کرنا۔ (مثلاً threshold اوپر refunds block کرنا)
- Hooks **deterministic guarantees** دیتی ہیں، جبکہ **probabilistic compliance** prompt instructions دیتی ہیں۔

Key skills:

- `PostToolUse` hooks سے data formats normalize کریں (Unix timestamps, ISO 8601, numeric status codes)
- Policy-violating actions block کرنے کے لیے interception hooks اور escalation استعمال کریں اور redirect کریں
- منتخب کریں hooks کے بجائے prompts چاہیے۔ تو تو guaranteed compliance کو business rules جب

1.6 Complex Workflows کے لیے Task Decomposition Strategies

Key knowledge:

- **Fixed pipelines** (prompt chaining) کے مقابلے میں **dynamic adaptive decomposition** کی بنیاد پر intermediate results
- Prompt chaining: sequential steps (پھر integration pass، analyze کو الگ الگ file)
- Adaptive investigation plans جو discovered information کی بنیاد پر subtasks generate کرتے ہیں

Key skills:

- Predictable multi-aspect reviews کے لیے prompt chaining؛ open-ended investigations کے لیے dynamic decomposition
- Large code reviews کو per-file analysis + separate cross-file integration pass میں تقسیم کریں
- Open-ended tasks کو degrade ہونے سے پہلے prioritized plan کریں، پھر structure map کریں: پھر

1.7 Session State, Resuming, اور Forking

Key knowledge:

- Named sessions continue کرنے کے لیے `--resume <session-name>`
- Shared context سے independent investigation branches بنانے کے لیے `fork_session`
- Resume کی اہمیت agent کو file changes کرتے وقت
- Structured summary کے ساتھ session، stale results کے ساتھ resuming زیادہ reliable سے زیادہ

Key skills:

- Named investigation sessions continue کرنے کے لیے `--resume` استعمال کریں
- Approaches parallel compare کرنے کے لیے `fork_session` استعمال کریں
- Resuming (context ابھی current ہے) اور نئی session شروع کرنے (results stale ہیں) درمیان انتخاب کریں

5.10 fork_session اور Session Management

`--resume <session-name>` named session کو resume کرتا ہے:

```
claude --resume investigation-auth-bug
```

- جاری رکھتا conversation کے ساتھ پچھلی saved context
- پر پھیلی ہوں ان کے لیے مفید sessions جو متعدد Long investigations
- Risk: tool results stale بدل چکی ہوں تو files کے بعد session اگر پچھلی

fork_session shared context سے independent branch بنانا:

```
Codebase investigation
|
fork_session
/      \
Approach A:  Approach B:
Redux       Context API
```

- کرتے ہیں context inherit تک forks branch point دونوں
- کرتے ہیں diverge اس کے بعد وہ آزادانہ طور پر
- کرنے کے لیے مفید strategies test کرنے یا Approaches compare

Resume نئی session کے بجائے نئی:

- Tool results stale ہوں (files بدل چکی ہوں)
- وہ گیا context degrade کافی وقت گزر چکا ہو اور
- کرنے کے بجائے یہ بہتر ہے کہ "م نہ جو پایا اس کا مختصر خلاصہ یہ ہے": resume کے ساتھ tool data پرانے کیا جائے restart "... سے"

2 Tool Design اور MCP Integration (18%) ڈومین

2.1 Clear Descriptions کے ساتھ Tool Interfaces Design کرنا

Key knowledge:

- Tool descriptions minimal descriptions کرنا؛ LLM tools select میں جن سے mechanism و بنیادی unreliable selection دیتی
- Input formats, example queries, edge cases, اور applicability boundaries کی اہمیت شامل کرنے
- Ambiguous یا overlapping descriptions misrouting کا سبب بنتی ہیں
- System prompt wording tools کے associations کے ساتھ غیر ارادی بنا سکتی ہیں

Key skills:

- کریں distinguish سے واضح طور پر similar alternatives کو tool لکھیں جو descriptions ایسی
- Functional overlap کے لیے (مثلاً `analyze_content` -> `extract_web_results`) کریں tools rename ختم کرنے کے لیے
- واضح ہوں input/output contracts میں تقسیم کریں جن کے specialized tools کو general-purpose tools

2.2 MCP Tools کے لیے Structured Error Responses Implement کرنا

Key knowledge:

- MCP tool responses میں `isError` flag
- Transient errors** (timeouts), **validation errors** (bad input), **business errors** (policy violations), اور **access/permission errors** کے درمیان فرق
- Generic errors ("Operation failed") میں recovery decisions روک دینے کے لیے
- Retryable اور non-retryable errors میں فرق

Key skills:

- `errorCategory` (transient/validation/permission), `isRetryable` جیسی human-readable message اور `retryable: false` کے ساتھ user-facing explanations کے لیے واضح structured metadata واپس کریں
- Business-rule violations کے لیے واضح `retryable: false` استعمال کریں
- Transient failures کے لیے subagents میں local recovery کے لیے صرف وہ errors propagate کریں جو خود حل نہ کر سکیں
- Access failures (retry decision) اور valid empty results (no matches) میں فرق کریں

2.3 Agents میں Tools Allocation اور `tool_choice` Configure کرنا

Key knowledge:

- کم کرتی tool selection reliability (مثلاً 18 کے بجائے 4-5) tools کے زیادہ
- Specialization کے لیے agents رکھنے والے tools سے باہر
- Scoped tool access: role-relevant tools + cross-role utilities محدود
- `tool_choice: "auto"`, `"any"` اور forced tool selection (`{"type": "tool", "name": "..."}`)

Key skills:

- تک محدود رکھیں relevant tools صرف subagent کا toolset
- General tools کو constrained alternatives سے بدلیں (مثلاً `fetch_url` -> `load_document`)
- `tool_choice: "any"` کے بجائے text answer کے لیے استعمال کریں تاکہ
- Specific tool force کے لیے execution order assured کریں تاکہ

2.4 MCP Servers اور Claude Code میں Agent Workflows کو Integrate کرنا

Key knowledge:

- MCP server scope: user کے لیے experiments کے مقابلے میں project (`.mcp.json`) کے لیے (`~/claude.json`)
- Secrets management کے لیے `.mcp.json` میں environment variable substitution (مثلاً `${GITHUB_TOKEN}`)

- available ہوتے ہیں اور ایک ساتھ discover پر tools connection کے connected MCP servers کے
- MCP resources بطور "content catalogs" (task summaries, database schemas) exploratory tool calls کم کرتے ہیں

Key skills:

- Shared MCP servers کو project میں `.mcp.json` env-var-based tokens ساتھ configure کے
- Personal/experimental servers کو `~/claude.json` میں رکھیں
- Standard integrations کے لیے community MCP servers کو custom servers پر ترجیح دیں

2.5 Built-in Tools (Read, Write, Edit, Bash, Grep, Glob) منتخب اور کرنا Apply

Key knowledge:

- **Grep:** file contents کے اندر search (function names, error messages, imports)
- **Glob:** name/extension patterns کے تلاش کرنا files کے
- **Read/Write:** full-file operations؛ **Edit:** unique text matches کے ذریعے precise changes
- **Read + Write:** واپس جائیں جہاں تو fail کی وجہ سے Edit non-unique matches کے

Key skills:

- Content search کے لیے Grep اور pattern-based discovery کے لیے
- **Read** کے لیے flows trace پھر Grep کے لیے entry points: سمجھ بوجھ رفتہ رفتہ بنائیں
- Wrapper modules کے ذریعے function usage trace کریں

3 اور Claude Code Configuration: ڈومین Workflows (20%)

3.1 Hierarchy, Scope, اور Modular Organization کے ساتھ CLAUDE.md Configure کرنا

Key knowledge:

- CLAUDE.md hierarchy: user (`~/claude/CLAUDE.md`), project (`.claude/CLAUDE.md` یا root `CLAUDE.md`), اور directory-level (subdirectories میں CLAUDE.md)
- User-level settings کے لیے VCS کے ذریعے share کے لیے اور user صرف ایک
- External files refer کے لیے syntax (مثلاً `@./standards/coding-style.md` یا `@path`) کے لیے CLAUDE.md modular بننا
- Monolithic CLAUDE.md کے بجائے topic-focused rule files کے لیے `.claude/rules/` directory

Key skills:

- user- اس لیے نہ ہیں ملتیں کیونکہ instructions کو team member نہ کریں (Hierarchy issues diagnose level میں تھیں project-level میں نہ)
- package کے لیے standards selectively include میں CLAUDE.md کے لیے (مثلاً @path استعمال کریں) (@./standards/testing.md)
- CLAUE.md کے لیے کو متعدد files (testing.md, api-conventions.md, deployment.md) .claude/rules/ میں تقسیم کریں

3.2 Custom Slash Commands اور Skills بنانا اور Configure کرنا

Key knowledge:

- .claude/commands/ بمقابلہ (shared کے ذریعے VCS Project commands میں) .claude/commands/ میں user commands
- .claude/skills/ میں SKILL.md frontmatter: context: fork , allowed-tools , argument-hint
- context: fork skill کو isolated subagent context تاکہ main session pollute نہ ہو
- Personal skill variants ~/.claude/skills/ میں رکھ سکتے ہیں

Key skills:

- Project slash commands .claude/commands/ میں رکھیں تاکہ پوری team میں حاصل کر سکیں
- Verbose output کے لیے skills isolate کے لیے context: fork استعمال کریں
- Skill کے لیے allowed-tools محدود کرنے کے لیے tools کے لیے استعمال کرنا
- Required parameters کے لیے argument-hint مانگنے کے لیے استعمال کریں

3.3 Conditional Convention Loading کے لیے Path-specific Rules استعمال کرنا

Key knowledge:

- .claude/rules/ files میں YAML frontmatter paths کے مطابق glob patterns شامل ہو سکتا ہے تاکہ rules activate ہوں
- Path-scoped rules matching files edit کرتے وقت context اور tokens میں load کرتے وقت
- Glob-based path rules directory-level CLAUDE.md میں جب conventions سے بہتر ہو سکتے ہیں جب directories میں apply (مثلاً tests)

Key skills:

- paths: ["terraform/**/*"] کے ساتھ .claude/rules/ files صرف matching files بنائیں تاکہ load ہوں
- Glob patterns (**/* .test .tsx) کے لیے location استعمال کریں تاکہ conventions apply ہوں
- path-specific کے بجائے directory-level CLAUDE.md میں تو conventions codebase میں پھیلی ہوں تو کو ترجیح دیں

Key skills:

- Interactive input پر hang لے لے کے لیجئے کہ وہ CI میں Claude Code کو -p کے ساتھ چلائیں
- Structured results (مثلاً inline PR comments) کے لیے --output-format json + --json-schema استعمال کریں
- new/unfixed issues (صرف) شامل کریں review results کے وقت پچھلے run کے بعد دوبارہ commits نہ (کریں report)
- Test generation quality کے لیے CLAUSE.md میں testing standards اور available fixtures document کریں
- style نہ ہو اور duplication میں شامل کریں تاکہ context کو existing test files کے وقت tests generate نہ کرے consistent ہو

4 Prompt Engineering اور Structured Output (20%)

4.1 Accuracy کے ساتھ Explicit Criteria، تر کرنے کے لیے لی کرنا Design

Key knowledge:

- Explicit criteria vague instructions میں زیادہ مؤثر ہوتے ہیں (مثلاً "flag comments only when they contradict code" بمقابلہ "check comment accuracy")
- "be more conservative" generic guidance concrete categorical criteria کے مؤثر ہیں
- False positives developer trust پر اثر انداز ہوتے ہیں: کچھ categories میں high false-positive rates درست کم کر دیتی ہیں trust پر بھی categories

Key skills:

- Review criteria define کرنا (bugs, security) اور ignore کرنا (minor style) report کرنا
- High false-positive rates والی categories طور پر disable عارضی
- explicit severity criteria define کے ساتھ code examples کے لیے level کر

4.2 Output Consistency کے ساتھ Few-shot Prompting، تر کرنے کے لیے لی کرنا استعمال کرنا

Key knowledge:

- Few-shot examples consistently formatted, actionable output مؤثر ہے کہ سب کے method پیدا کرنے کا
- Few-shot cases (tool selection, test coverage gaps) کو دکھا سکتا ہے
- Few-shot model کو نہ generalize پر patterns کو نہ، صرف مدد دیتا ہے،
- Few-shot extraction tasks میں hallucinations کو کر سکتا ہے

Key skills:

- Ambiguous scenarios کے لیے rationale 4–2 کے ساتھ targeted examples دینے
- Output format (location, issue, severity, suggested fix) کے ساتھ examples دکھانے والے
- میں فرق دکھائیں real issues اور acceptable code patterns دینے جو examples ایسے
- دینے examples کے extraction سے درست documents والے structures مختلف

4.3 Structured Output کے ساتھ JSON Schemas اور tool_use کرنا Enforce

Key knowledge:

- tool_use with JSON Schemas schema-conformant output اور JSON syntax errors کی ضمانت دینے اور طریقہ کے reliable کرنے کا سب سے
- tool_choice: "any" واپس کر سکتا ہے؛ model text میں "any" منتخب کرتی ہے؛ forced selection specific tool؛
- Strict JSON Schemas syntax errors semantic errors ختم کرتی ہیں مگر (توٹے؛ totals) میں غلط fields values
- Schema design: required vs optional fields؛ enums کے ساتھ "other" + detail string extensibility کے لیے

Key skills:

- JSON Schemas کے ساتھ extraction tools define کریں اور tool_use results سے data parse کریں
- استعمال کریں tool_choice: "any" یقینی بنانے کے لیے structured output کے ساتھ تو schemas متعدد
- Specific tool call force کریں: tool_choice: {"type": "tool", "name": "extract_metadata"}
- Source میں information کی صورت میں values fabricate نہ ہونے کی صورت میں optional/nullable رکھیں
- Extensible categorization کے لیے "unclear" اور "other" enum values + detail fields جیسے کے لیے کریں

4.4 Extraction Quality کے لیے Validation, Retries, Feedback Loops Implement کرنا

Key knowledge:

- Retry-with-error-feedback: correction guide کے لیے concrete validation errors میں retry prompt کرنے کے لیے شامل کریں
- فوائد ہونے میں retries کے لیے information source سے تو واپس کرنا
- Feedback loop design: finding کو trigger کرنے والا pattern (detected_pattern) track کریں
- Semantic errors (totals reconcile کے لیے) syntax errors (جو tool_use سے address ہوتے ہیں)

Key skills:

- Original document, incorrect extraction, اور specific validation errors کے ساتھ follow-up prompts دینے
- تو اس کی شناخت کریں (میں سے واپس کرنا external document صرف required info کے لیے) واپس کرنا

- False positives analyze `detected_pattern` fields میں findings کرنے کے لیے
- Discrepancies detect `calculated_total` اور `stated_total` extract کرنے کے لیے self-correction design کریں

4.5 Efficient Batch Processing Strategies Design کرنا

Key knowledge:

- Message Batches API: 50% savings, 24-hour processing window, latency SLA guarantee
- Batch processing non-blocking tasks (overnight reports, audits) اور blocking tasks (pre-merge checks) کے لیے مناسب
- Batch API single request میں multi-turn tool calling support
- `custom_id` fields batch request/response correlate کرتی ہیں

Key skills:

- Blocking checks synchronous API اور overnight/weekly workloads کے لیے Batch API استعمال کریں
- SLA needs مطابق batch submission cadence plan کریں (24-hour guarantee مثلاً 30 processing 4-hour windows کے ساتھ)
- Failed documents (identified by `custom_id`) submit کر کے failures handle کریں
- Large-scale processing کے لیے sample prompts iterate کے ساتھ

4.6 Multi-instance اور Multi-pass Review Architectures Design کرنا

Key knowledge:

- Self-review limitations: model reasoning context کو فیصلوں اور اپنے challenge ساتھ رکھتا ہے اور امکان کم ہوتا ہے
- Independent review instances (generation context بغیر) subtle issues میں بہتر ہوتی ہیں
- Multi-pass review: per-file local analysis + cross-file integration pass attention dilution سے بچانا

Key skills:

- Changes review second independent Claude instance کے بغیر generation context کرنے کے لیے
- Multi-file reviews کو per-file passes + integration passes میں تقسیم کریں تاکہ cross-file dataflow analysis ہو سکے
- Self-rated confidence کے ساتھ verification passes کے reviews استعمال کر کے route طریقہ سے

5 Reliability اور Context Management ڈومین: 5 (15%)

5.1 Critical Information Conversation Context محفوظ رکھنا اور Critical Information Manage کرنا

Key knowledge:

- Progressive summarization کے خطرات: numeric values, percentages, اور dates vague summaries میں بدل جاتے ہیں
- Lost-in-the-middle effect: models long inputs کے شروع اور آخر کو زیادہ reliable سے process طریقہ سے کر سکتے ہیں findings miss ہیں، لیکن درمیان کے
- Tool outputs relevance میں context کے مقابلہ میں disproportionately جمع ہو سکتے ہیں (40+ fields جب 5 fields کے درکار ہوں)
- Subsequent API requests کی اہمیت full conversation history میں

Key skills:

- Transactional facts کو summarized history سے باہر ایک persistent “case facts” block میں نکالیں
- Verbose tool outputs کو relevant fields تک trim کریں
- Key findings کو aggregated data کے شروع میں explicit section headings رکھیں
- Subagents کے structured outputs میں metadata (dates, sources) شامل کروائیں

5.2 Effective Escalation Patterns Design اور Ambiguity Resolve کرنا

Key knowledge:

- Suitable escalation triggers: human کی explicit request, policy gaps/exceptions, اور پانا
- Immediate escalation (explicit request) کے اندر attempt-to-resolve (agent scope) کے مقابلہ میں
- Sentiment analysis اور model confidence self-ratings case complexity کے unreliable proxies ہیں
- Multiple customer matches کے heuristic guessing کے بجائے additional identifiers چاہئیں

Key skills:

- System prompt میں explicit escalation criteria few-shot examples کے ساتھ دیں
- Human کی explicit request کو بغیر اضافی investigation کے فوراً execute کریں
- Escalate ہو تو silent یا ambiguous کے لیے specific request کسی policy جب
- Tool results میں multiple matches کے additional identifiers مانگیں

5.3 Multi-agent Systems میں Error Propagation Strategies کرنے

Key knowledge:

- Structured error context (failure type, query, partial results, alternatives) coordinator کو smarter recovery دیتا ہے
- Access failures (timeouts retry decision میں) اور valid empty results (no matches) میں فرق کریں
- Generic error statuses (“search unavailable”) coordinator سے valuable context چھپا دیتا ہے
- Silent suppression یا failure پر پورا workflow abort کرنا anti-patterns میں

Key skills:

- Structured error context: failure type, کیا گیا attempt, partial results, possible alternatives واپس کریں
- Access failures کو valid empty results الگ کریں
- Transient failures subagents کے لیے صرف local recovery میں non-recoverable errors partial results کے ساتھ propagate کریں
- Synthesis میں coverage annotate کیا اچھی طرح supported اور کے ان gaps میں

5.4 Large Codebases Investigate کرتے وقت Context Efficiently Manage کرنا

Key knowledge:

- Long sessions میں context degradation: model unstable answers اور مخصوص classes دینے لگتا ہے
- Scratchpad files key findings کو context boundaries میں پار محفوظ رکھتے ہیں
- Subagents کو delegate سے verbose discovery output isolate ہو جاتی ہے
- Structured state persistence crash recovery ممکن بناتی ہے

Key skills:

- Specific questions subagents spawn کے لیے high-level coordination main agent میں رکھیں
- Key findings scratchpad files کے لیے refer محفوظ رکھتے ہیں اور بعد میں
- Key findings summarize کے لیے subagents spawn کے phase اگلا ہے
- Long investigations دوران context usage کے لیے کم کرنے /compact استعمال کریں

5.5 Human Oversight اور Confidence Calibration کے ساتھ Workflows Design کرنا

Key knowledge:

- Aggregate metrics (97% overall accuracy) specific document types یا fields پر کمزوری چھپا سکتا ہے
- Stratified random sampling high-confidence extractions میں error rates measure کرتا ہے

- Field-level confidence calibration labeled validation sets ذریعہ
- Automation سند document type اور field segment حساب سے accuracy validate کریں

Key skills:

- New error patterns detect کریں stratified random sampling implement کریں
- Stable performance validate کریں accuracy analyze کریں حساب شد اور document type
- Field-level confidence scores output کریں review thresholds calibrate کریں ذریعہ labeled data اور
- Low-confidence یا ambiguous-source extractions human review کریں route کی طرف

5.6 Multi-source Synthesis میں Provenance Preserve کرنا اور Uncertainty Handle کرنا

Key knowledge:

- محفوظ نہ رہیں mappings “claim → source” کہو جاتی ہیں اگر attribution کا دوران Summarization
- برقرار رہتی چاہئیں structured mappings کا دوران Aggregation
- conflict annotate کا ساتھ attribution منتخب کرنے کا بجائے value ایک arbitrarily کو conflicting statistics کریں handle کا
- publication/collection dates سمجھنے سے بچنے کا لیے contradiction کو Temporal differences شامل کریں

Key skills:

- Subagents کے “claim → source” mappings (URL، document name، quotes) output کروائیں
- Reports کو stable findings اور disputed ones میں الگ کریں
- Conflicting values کے annotations اور ساتھ محفوظ رکھیں
- Correct temporal interpretation کے لیے reconciliation کے لیے
- Correct temporal interpretation کے لیے publication dates شامل کریں
- Content type کے مطابق financial data tables، news prose، technical findings میں structured lists

Claude Certified Architect — Foundations Certification

مطالعہ □ گائیڈ (سرکاری امتحانی گائیڈ کی بنیاد پر)

تعارف

Claude Certified Architect — Foundations

Claude- based سرٹیفیکیشن اس بات کی تصدیق کرتی ہے کہ ایک ماہر Claude Code، Claude Agent SDK، Claude API، اور Model Context Protocol (MCP) کے بنیادی ٹیکنالوجیز جن کا وقت درست trade-off حل بنانا ہے امتحان کر سکتا ہے۔ یہ بنیادی علم کو جانچتا ہے — یعنی وہ بنیادی ٹیکنالوجیز جن کا وقت درست trade-off حل بنانا ہے امتحان کر سکتا ہے۔ یہ بنیادی علم کو جانچتا ہے — یعنی وہ بنیادی ٹیکنالوجیز جن کا وقت درست trade-off حل بنانا ہے

بنانا agentic systems امتحان کے سوالات حقیقی دنیا کے منظر ناموں پر مبنی ہوتے ہیں: کسٹمر سپورٹ کے لیے، multi-agent research pipelines، Claude Code کو CI/CD شامل کرنا، developer productivity، structured data بنانا، اور غیر ساختہ دستاویزات سے tools نکالنا

هدف امیدوار

کرتا آپ ship کے ساتھ پروڈکشن ایپلیکیشنز ڈیزائن اور Claude کے جو solution architect مثالی امیدوار ایک کے پاس کم از کم 6 ماہ کا عملی تجربہ ہونا چاہیے:

- Claude Agent SDK** — multi-agent orchestration، subagents کو delegate کرنا، tool integration، lifecycle hooks
- Claude Code** — CLAUDE.md، MCP servers، Agent Skills، planning mode
- Model Context Protocol (MCP)** — backend integration کے لیے tools اور resources
- Prompt engineering** — JSON schemas، few-shot examples، data extraction templates
- Context windows** — لمبی دستاویزات، multi-agent context passing
- CI/CD pipelines** — automated code review، test generation
- Escalation and reliability** — error handling، human-in-the-loop

امتحانی فارمیٹ

پیرامیٹر	قدر
سوال کی قسم	Multiple choice (میں سے 1 درست 4)
اسکورنگ	100–1000 scale، passing score 720
Guessing penalty	نہیں (سوال کا جواب دیں!)
Scenarios	8 4 (randomly selected) میں سے

امتحانی مواد: 5 ڈومینز

ڈومین	وزن
1. Agent architecture and orchestration	27%
2. Tool design and MCP integration	18%
3. Claude Code configuration and workflows	20%
4. Prompt engineering and structured output	20%
5. Context management and reliability	15%

امتحانى منظر نامہ

Scenario 1: Customer Support Agent

returns, billing disputes, اور account issues کے ساتھ Claude Agent SDK کے استعمال کرتے ہوئے agent MCP tools (get_customer, lookup_order, process_refund, escalate_to_human) کے ساتھ 80% first-contact resolution مناسب، 20% escalation کے ساتھ۔

Scenario 2: Claude Code ساتھ Code Generation

code generation, refactoring, debugging, documentation اور custom slash commands کے ساتھ CLAUDE.md configuration آپ کو development میں استعمال کرتے ہوئے Claude Code آپ کے workflow میں integrate کرنے کے لیے استعمال کو سمجھنا اور planning mode کرنا، اور

Scenario 3: Multi-Agent Research System

□□ ساتھ مکمل رپورٹس تیار کرنی چاہئیں □ citations □ سسٹم کو report generation اور synthesis, tasks کو specialized subagents اور coordinator agent سونپنا □□

Scenario 4: Developer Productivity Tools

agent engineers کو unfamiliar codebases explore کرنے، boilerplate code اور routine tasks بنانے، MCP servers اور Built-in tools (Read, Write, Bash, Grep, Glob) میں مدد دینا اور automate کو تیز کرنا

Scenario 5: Claude Code for Continuous Integration

Claude Code کو CI/CD pipeline میں ضم کریں تاکہ automated code reviews, test generation, pull request feedback اور false positives کم ہوں۔

Scenario 6: Structured Data Extraction

کرتا ہے، validate کے ذریعے JSON schemas کو output، سسٹم غیر ساختہ، دستاویزات سے معلومات نکالتا ہے درست طور پر سننے والے چائے، edge cases پر قرار رکھتا ہے اسے high accuracy اور

Scenario 7: Conversational AI Architecture Patterns

turns متعدد، context window management، ڈیزائن کرتے ہیں جن میں multi-turn conversational systems آپ اور مہم یا متضاد، tool design کو لے execution محفوظ، memory strategies، کا برقرار رکھنا instructions میں user inputs کو سنبھالنا شامل ہے

Scenario 8: Agentic AI Tools (ہماری مدد کریں —! مواد موجود نہیں)

میں شامل ہیں۔ یہ guide نہ دی ہے لیکن ابھی تک اس candidates کی اطلاع امتحان دینے والے scenario اس کریں share میں [GitHub Issues](#) کے سوالات دیکھیں، تو ان میں scenario اگر آپ نہ اصل امتحان میں اس شامل کر سکیں۔ آپ کا تعاون اس شخص کی مدد کرے گا جو امتحان کی تیاری کر coverage تاکہ ہم مکمل کر لیں۔

نظریاتی بنیادیں: حصہ 1

یہ حصہ و بنیادی نظریہ بیان کرتا ہے جس کی آپ کو امتحان میں کامیابی کے لیے ضرورت ہے۔ مواد کو topic کے مطابق — اس کے domains کے مطابق ترتیب دیا گیا ہے، نہ کہ امتحانی concepts اور technologies کی گہری سمجھ بھنی۔

کی بنیادیں Claude API — Model Interaction: باب 1

دستاویزات: [Messages API](#) | [Prompt Engineering](#)

1.1 API Request Structure

Claude API میں عموماً یہ Claude Messages API request پر کام کرتا ہے request-response model ایک request-response model میں شامل ہوتا ہے:

```
{
  "model": "claude-sonnet-4-6",
  "max_tokens": 1024,
  "system": "You are a helpful assistant.",
  "messages": [
    {"role": "user", "content": "Hi!"},
    {"role": "assistant", "content": "Hello!"},
    {"role": "user", "content": "How are you?"}
  ],
  "tools": [...],
  "tool_choice": {"type": "auto"}
}
```

م فیلڈز:

- `model` — model selection (`claude-opus-4-6`, `claude-sonnet-4-6`, `claude-haiku-4-5`)
- `max_tokens` — response میں زیادہ سے زیادہ tokens
- `system` — system prompt (model کی تعریف)
- `messages` — conversation history (full history کی ضرورت ہے)
- `tools` — available tools کی definitions
- `tool_choice` — tool selection strategy

1.2 Message Roles

roles میں تین array messages:

- `user` — user messages
- `assistant` — model responses (history میں شامل ہوتے ہیں)

- `tool` — tool call results (عملاً `tool_result` content block)

محفوظ state کے درمیان Model requests بھیجیں conversation history میں مکمل API request م بات: ر آزاد ہوتی call نہیں رکھتا؛ ر

1.3 stop_reason

نہ کیوں رکا model ہوتا جو بتاتا کہ `stop_reason` میں Claude API response

Value	Description	Action
"end_turn"	نہ جواب مکمل کر لیا Model	کو نتیجہ دکھائیں user
"tool_use"	چاہتا Model tool call	واپس دیں result چلائیں اور tool
"max_tokens"	ختم ہو گئی Token limit	بڑھا سکتے ہیں limit؛ response truncated
"stop_sequence"	مل گئی Stop sequence	کریں handle کے مطابق application logic

کرے loop control ہیں — یہی signals سب سے اہم "end_turn" اور "tool_use" میں Agentic systems ہیں

1.4 System Prompt

متعین کرتا context اور behavioral rules جو instruction ایک خاص System prompt

- `messages` array الگ ہوتا؛ `system` field کا حصہ نہیں ہوتا؛ الگ
- user messages پر فوقیت رکھتا
- ہو کر پوری گفتگو میں لاگو رہتا load ایک بار
- کی وضاحت کے لیے استعمال ہوتا output format اور role, constraints,

کو غیر ارادی طور پر متاثر کر سکتی مثال tool selection wording کی system prompt: امتحان کے لیے اہم ضرورت سے زیادہ `get_customer` کو model کی تصدیق کریں "جیسی ہدایت customer کے طور پر" ہمیشہ استعمال کرنے پر ل جا سکتی

1.5 Context Window

کر سکتا اس میں شامل process ایک وقت میں model جسے (tokens) و کل متن Context window

- System prompt
- message history مکمل
- Tool definitions
- Tool results

اہم مسائل:

1. **Lost-in-the-middle effect:** درمیان کی input لمبے، مؤثر ہوتی ہیں، آغاز اور اختتام کی معلومات زیادہ مؤثر ہوتی ہیں، حل: اہم معلومات شروع یا آخر میں رکھیں details miss

2. **Tool results** واپس tool 40+ fields شامل کرتی ہیں اگر output میں tool call context کا جمع ہونا: ہر Tool results ضائع ہوتا ہے context کو مگر صرف 5 امیون تو
3. **Progressive summarization:** history compress کرنے پر numeric values, percentages, اور dates اکثر vague ہوتی ہیں

2 tool_use اور Tools: باب 2

Tool Use: دستاویزات

2.1 tool_use کیا ہے

براہ راست Model کو external functions call کرنے کے لیے Claude جس کے ذریعے mechanism tool_use واپس کرتا ہے result کو execute اس کے لیے code بنانا ہے: آپ کا structured tool call نہیں چلاتا — وہ code درست ہے

2.2 Tool Definition

tool JSON schema کے ذریعے define کیا جاتا ہے:

```
{
  "name": "get_customer",
  "description": "Finds a customer by email or ID. Returns the customer profile, including name, email, order history, and account status. Use this tool BEFORE lookup_order to verify the customer's identity. Accepts an email (format: user@domain.com) or a numeric customer_id.",
  "input_schema": {
    "type": "object",
    "properties": {
      "email": {"type": "string", "description": "Customer email"},
      "customer_id": {"type": "integer", "description": "Numeric customer ID"}
    },
    "required": []
  }
}
```

Tool description نکات:

1. Description کا سبب بنتی selection غلط Minimal descriptions کا mechanism tool selection کی ہیں
2. Description کا edge cases، input format، کیا کرتا ہے، کیا واپس کرتا ہے tool میں شامل کریں، اور یہ کب استعمال ہو
3. Overlapping descriptions سے بچیں
4. Built-in tools اور MCP tools overlap کو MCP tool واضح بنائیں

2.3 tool_choice

Value	Behavior	کب استعمال کریں
<code>{ "type": "auto" }</code>	Model خود ط کرتا ہے	default عام
<code>{ "type": "any" }</code>	Model tool call کو لازماً کرے گی	structured output جب چاہے
<code>{ "type": "tool", "name": "extract_metadata" }</code>	Model tool call کو لازماً کرے گی	forced first step / order ہے

2.4 JSON Schemas for Structured Output

reliable لینے کا سب سے structured output Claude استعمال کرنا `tool_use` کے ساتھ JSON schemas کی semantic correctness نافذ کرتا ہے، مگر required structure کم کرتا ہے اور syntax errors طریقہ سے یقیناً ضمانت نہیں دیتا

اصول Design:

- رکھیں جو ہمیشہ ملنے چاہئیں required fields صرف وہ
- استعمال کریں nullable fields کے لیے missing data ممکن
- ضائع نہ ہو information شامل کریں تاکہ enum values جیسے "unclear" اور "other"

2.5 Syntax اور Semantic Errors

Error type	Example	Mitigation
Syntax	Invalid JSON, field type غلط	JSON schema کے ساتھ <code>tool_use</code>
Semantic	Totals match نہیں کرتے، value field غلط	Validation checks, feedback retry

بنانا Claude Agent SDK — Agentic Systems: باب 3

دستاویزات: [Agent SDK](#) | [Hooks](#) | [Subagents](#) | [Sessions](#)

3.1 Agentic Loop

چلانا sequence کی actions صرف جواب نہیں دیتا، بلکہ Claude میں Agentic loop

- Claude کو tools کے ساتھ request بھیجیں
- Response لیں
- چیک کریں `stop_reason`:
 - "tool_use" → tool چلائیں، result history پھر دوبارہ request میں ڈالیں

- "end_turn" → task کو دین user مکمل، نتیجہ task

مکمل ہونے تک دہرائیں۔ 4.

Text parsing یا arbitrary iteration دیکھیں کہ `stop_reason == "end_turn"` کہ لیں `signal: completion` درست قابلِ اعتماد نہیں کہ limit


3.2 AgentDefinition

```
agent = AgentDefinition(
    name="customer_support",
    description="Handles customer requests for returns and order issues",
    system_prompt="You are a customer support agent...",
    allowed_tools=["get_customer", "lookup_order", "process_refund",
"escalate_to_human"],
)
```

اصول اپنائیں کہ Least privilege کہ allowed_tools اور، system_prompt، description، name: کم چیزیں

3.3 Coordinator اور Subagents

استعمال کرتی کہ ہیں hub-and-spoke topology اکثر Multi-agent systems



Coordinator task کہ کو توڑتا کہ subagents، نتائج جوڑتا کہ، کام سونپتا کہ، منتخب کرتا کہ، errors handle کرتا جواب پہنچانا کہ کہ final تک user کہ، اور

نہیں کرتے کہ inherit خود بخود parent history الگ ہوتا کہ؛ وہ کہ context کا subagents: کم اصول

3.4 Task Tool

Subagents Task tool کہ spawn کہ ہیں Coordinator کہ allowed_tools میں "Task" ہونا کہ چاہیے کہ

context passing: صحیح

- Task: "Analyze the document" کافی نہیں
- Task: "Analyze this document. Full text: ... Output schema: ..." درست کہ

Coordinator ایک response میں multiple Task s کہ، لہذا کہ parallel subagents بھیج سکتا کہ، ممکن کہ ہیں

3.5 Hooks

Hooks lifecycle کہ points کہ work کہ ہیں کہ کرتے کہ

PostToolUse tool result کو model یں normalize کر سکتا ہے۔

```
@hook("PostToolUse")
def normalize_dates(tool_result):
    return normalized_result
```

PreToolUse policy violation block □□ کر سکتا

```
@hook("PreToolUse")
def enforce_refund_limit(tool_call):
    if tool_call.name == "process_refund" and tool_call.args.amount > 500:
        return redirect to escalation(tool call)
```

Critical business rules ہوتی ہیں۔ prompt instructions probabilistic ہوتے ہیں؛ hooks deterministic یاد رکھیں۔
 rules ہوتے ہیں، hooks کے لئے

باب 4: Model Context Protocol (MCP)

MCP | Tools | Resources | Servers: دستاویزات

4.1 MCP کا

resource سے جوڑتا ہے اس کے تین بنیادی Claude کو external systems سے جو open protocol ایک MCP types ہیں:

1. **Tools** — actions $\square_{\text{J}}$ $\square_{\text{S}}$ functions
2. **Resources** — context data (documentation, schemas, catalogs)
3. **Prompts** — predefined task templates

4.2 MCP Servers

و جات tools discover و ن Connect کرتا expose tools/resources جو MCP server ایک process میں اور ک مطابق استعمال و ت میں descriptions میں اور

4.3 Configuration

تیم کے لیے (.mcp.json) Project config

```
{
  "mcpServers": {
    "github": {
      "command": "npx",
      "args": ["-y", "@modelcontextprotocol/server-github"],
      "env": {"GITHUB_TOKEN": "${GITHUB_TOKEN}"}
    }
  }
}
```

User config سہ آتی ہے secrets environment variables میں ہوتی ہے؛ Project config version control (~/claude.json) personal/experimental servers کے لیے ہوتی ہے

4.4 isError

واپس کریں structured error کے بجائے Generic errors استعمال کریں `isError: true` میں MCP tool errors

```
{
  "isError": true,
  "content": {
    "errorCategory": "transient",
    "isRetryable": true,
    "message": "The service is temporarily unavailable."
  }
}
```

4.5 Resources

Resources کے پڑھ سکتا ہے action بغیر agent میں جو data و Resources: schemas, docs, content catalogs, summaries، exploratory tool calls میں کم کرتے ہیں

5 اور Claude Code — Configuration Workflows

دستاویزات: [Claude Code](#) | [Memory / CLAUDE.md](#) | [Skills](#) | [MCP](#) | [Hooks](#) | [Sub-agents](#) | [GitHub Actions](#) | [Headless](#)

5.1 CLAUDE.md Hierarchy

تین سطحوں پر ہو سکتا ہے CLAUDE.md

- **User-level:** `~/.claude/CLAUDE.md` — پر لاگو user صرف اسی
- **Project-level:** `.claude/CLAUDE.md` یا `root` `CLAUDE.md` — لی تیم پوری
- **Directory-level:** subdirectories میں `CLAUDE.md` — folder conventions مخصوص

5.2 @path Syntax

CLAUDE.md میں @path سے external files refer تاکہ جا سکتے ہیں تاکہ:

Coding standards `@./standards/coding-style.md` میں ہیں
Test rules `@./standards/testing-requirements.md` میں ہیں

5.3 .claude/rules/

`.claude/rules/` rules کو topic سے لحاظ سے organize کرنا اور `paths` کے ذریعے conditional loading کرتا ہے:

```
---
paths: ["src/api/**/*"]
---
```

استعمال کریں explicit error handling اور async/await کہ لیم API files

5.4 Commands اور Skills

`.claude/commands/` project commands کے لیے، جبکہ `~/.claude/commands/` personal commands کے لیے، ملتی ہیں۔ skills کے ساتھ `.claude/skills/` میں frontmatter کے لیے

5.5 Skills اور context: fork

`context: fork` skill کو isolated context میں چلاتا ہے `allowed-tools` اور tool access سے محدود کریں، `argument-hint` سے required input مانگیں

5.6 Planning Mode

Planning mode کے لیے، multiple approaches، architectural تبدیلیوں، unfamiliar codebases، Direct execution کے لیے، changes کے لیے، اور واضح

5.7 /compact اور /memory

`/compact` context compress کرتا ہے، اور `/memory` notes اور preferences میں مدد دیتا ہے

5.8 Claude Code CLI for CI/CD

کد: `-p` / `--print` non-interactive mode کو استعمال کرنا:

```
claude -p "Analyze this pull request for security issues"
```

Structured output کو `--output-format json` اور `--json-schema` استعمال کریں

باب 6: Prompt Engineering — Advanced Techniques

دستاویزات: [Prompt Engineering](#) | [Anthropic Cookbook](#)

6.1 Few-shot Prompting

Few-shot prompting 4–2 examples میں کر expected behavior کو دکھایا جاتا ہے۔ Vague instructions سے کم کرنا، example ambiguity زیادہ مؤثر ہے کیونکہ

6.2 Explicit Criteria

Vague instructions بجائے clear criteria دیں: کیا flag، اور ignore کرنا، severity کرنا، decide کیسے کرنی

6.3 Prompt Chaining

Complex task کو focused steps میں توڑیں: local analysis، integration pass، attention dilution کم کرنا

6.4 Interview Pattern

Claude کو clarifying questions، domain سے لگتا، خاص طور پر جب design ambiguity ہو، unfamiliar

6.5 Validation and Retry

Extraction fail کو original document، incorrect output، اور specific validation error کے ساتھ retry

6.6 Self-correction

کریں discrepancy handle تو conflict دونوں نکال؛ Model stated value اور calculated value

7: Message Batches API

Message Batches: دستاویزات

7.1 Overview

Message Batches API asynchronous processing 50: % savings، up to 24 hours window، اور multi-turn tool calling supported، custom_id requests اور responses link

7.2 کب استعمال کریں

Pre-merge checks اور interactive tasks، synchronous API، overnight reports اور bulk jobs، استعمال کریں Batch API

7.3 custom_id

custom_id result کو original document، جوڑ، failures identify، اور صرف failed items دوبار، submit میں مدد دیتا

8: Task Decomposition Strategies

8.1 Fixed Pipelines

Predictable tasks، fixed pipeline، Document → Extraction → Validation → Final output

8.2 Dynamic Decomposition

Open-ended tasks، subtasks intermediate results، کی بنیاد پر بنتے

8.3 Multi-pass Code Review

Large PRs، per-file analysis، cross-file integration pass، attention dilution، کم

9 Escalation اور Human-in-the-Loop: باب 9

9.1 Escalate کب کریں

Explicit user request, policy gaps, progress نہ ہونا, threshold سے اوپر financial action, یا ambiguous matching میں Sentiment analysis اور self-rated confidence unreliable ہیں۔ Escalate کی صورت میں

9.2 Escalation Patterns

human کو hand off نہ کرنا یا explicit insistence یا policy gap نہ کرنے کی کوشش کریں، پھر اگر resolve نہ ہو، مسئلہ حل کریں

9.3 Structured Handoff

human شامل کریں تاکہ recommended action اور، actions taken, issue summary, customer ID پر Escalation ملا۔ context کو مکمل operator

9.4 Confidence Calibration

Field-level confidence scores, calibration on labeled data, اور stratified sampling استعمال کریں

10 Error Handling میں Multi-agent Systems: باب 10

10.1 Error Categories

Transient errors retryable ہیں، validation errors input fix ہیں، مانگتی business errors policy-driven ہیں۔ کی جاتی ہیں۔ اور permission errors generally escalate ہیں، اور

10.2 Anti-patterns

Generic “search unavailable” response, silent suppression, workflow abort یا پورا کرنا نقصان دہ۔ Structured errors واپس کریں

10.3 Structured Subagent Error

Structured error میں failure type, attempted query, partial results, alternative approaches, اور coverage شامل کریں۔ impact

10.4 Final Synthesis میں Coverage

پارٹیاں، اور کچھ partially covered ہیں، کون سی sections fully covered میں واضح کریں کہ کون سی Report باقی ہیں۔ gaps

11 Context میں Production Systems: باب 11 Management

11.1 Facts Separate Block میں

Transactional facts کو persistent case facts block تاکہ summarization میں رکھیں تاکہ critical data کے باوجود زائد و اضافہ؛

11.2 Tool Results Trimming

PostToolUse hook رکھیں تاکہ relevant fields سے صرف

11.3 Position-aware Input

Important findings اور action items شروع میں اور lost-in-the-middle effect کو آخر میں رکھیں تاکہ

11.4 Scratchpad Files

Verbose findings scratchpad تاکہ long investigations میں لکھیں تاکہ محفوظ رہیں

11.5 Subagents کو Delegate کرنا

Exploration subagents میں صرف main context میں دیں اور

11.6 Structured State Persistence

ممکن ہے کہ crash recovery تاکہ export میں JSON file یا state manifest اپنی agent سے

12 Provenance رکھنا: باب 12 کو محفوظ رکھنا

12.1 Attribution Loss

Claim رکھیں تاکہ source URL، publication date، اور confidence کے ساتھ

12.2 Conflicting Data

کریں conflict flag ساتھ محفوظ رکھیں اور attribution دیں تو دونوں کو values مختلف sources اگر

12.3 Dates

دیکھیں publication dates سمجھنے کے لیے contradiction کو Temporal differences

12.4 Content Type کے مطابق Render

Financial data tables ، news prose ، میں ، technical findings structured lists اور time series ، میں دیکھائیں chronological order

13 Claude Code کے Built-in Tools : باب 13

13.1 Tool Selection Reference

Task	Tool	Example
تلاش کرنا file کے pattern	Glob	<code>**/*.test.tsx</code>
file contents میں search	Grep	function name, error message
پڑھنا file	Read	analysis کے لیے
بنانا file نیا	Write	scratch کے
precise edit	Edit	unique text match
shell command	Bash	git, npm, tests

13.2 Incremental Investigation

دیکھیں files consumer ، پھر usages ، پھر entry points ، پڑھیں ؛ کے files ایک ساتھ سب

13.3 Read + Write Fallback

کریں Write کریں ، پھر programmatically کریں ، تبدیلی Read کے تو Edit fail اگر

امتحانی ڈومین نوٹس : II حصہ

- C) Tool description agent شامل کریں جن میں few-shot examples اور instructions میں تفصیلی `dry_run=true` کو `call` سے `replace` کریں `preview_remove_member` impact details اور single-use confirmation token کو `preview` سے `bind`، درکار token کو `execute_remove_member` واپس کرتا ہے؛ `execute_remove_member` [درست] کرتا ہے

D) Token-binding approach سے `architecturally` `preview` ناممکن ہو جاتا ہے `execute tool` کو `literally` — `execute` `token` جو صرف `token` `generate` کر سکتا ہے `preview tool` `orchestration infrastructure` یا (A)، `timing heuristics` (C)، `LLM instructions` جو `approach` ہے واحد کرتی ہے `constraint enforce` `code level` پر `انحصار` کے بجائے (B)

سوال 62

`search_catalog` tool 12% fail وقت `Production monitoring` کا آپ کا `search_catalog` سے معلوم ہوتا ہے کہ آپ کا `search_catalog` `query syntax errors` % پر کامیاب ہوتا ہے، اور `retry 4` میں جو `network timeouts` %: 8 `return` یکساں طریقہ سے `error types` کامیاب نہیں ہوتا ہے فی الحال دونوں `retries` ہوتی ہیں

کریں گے؟ `modify` کیسے `error handling` کی tool آپ

- A) System prompt میں few-shot examples شامل کریں جو `network errors` میں فرق کیسے کریں `syntax errors`
- B) `uniformly exponential backoff retry logic` apply کریں `errors` پر تمام
- C) Tool `network timeouts` کے اندر `automatic retry with backoff` implement کریں؛ `syntax errors` کے ساتھ فوری واپس کریں [درست] `parameter validation details`
- D) `retryable` boolean flag اور `error type details` کو `errors` تمام

C) Tool level پر `transient errors` کے لیے `retries` handle کرنا صحیح `abstraction boundary` — `tool` کو `agent` کر سکتا ہے بغیر `deterministic retry logic` کے بارے میں یقینی علم اور `error type` `Uniform backoff` (B) `syntax errors` `prompt instructions` (A) follow کرے یا `interpret` (D) `flag` `انحصار` کے `و` پر وقت ضائع کرتا ہے جو کبھی کامیاب نہیں ہونے لگتا

سوال 63

بہت کم "اور `risk tolerance` نہ `user`، میں `turns` کی گفتگو کے کئی `Investment strategy` `returns maximize` پھر "میں اپنے" کرنا چاہتا ہے؟ `invest` کرنا چاہتا ہوں" اب وہ پوچھتا ہے: "مجھے کس چیز میں `returns maximize` پھر "میں اپنے"

سے `priority` کی اصل `recommendation user` سب سے بہتر طریقہ سے یقینی بنانا ہے کہ `approach` کونسا ہے؟

- A) پوچھیں کہ کونسی چیز زیادہ اہم ہے [درست] `user` تضاد کو سامنے لائیں اور
- B) `recommendations` کے لیے الگ الگ `scenarios` دونوں
- C) `preference` سب سے حال میں بیان کی گئی
- D) `balanced portfolio` تضاد کو حل کیے بغیر

مانگنا کی واحد clarification برا راست متضاد ہوں، تو تضاد سامنے لانا اور user preferences کی کیوں: جب A low risk کرنا اور Returns maximize کے اصل ارادہ سے ہم آہنگ ہو۔ user recommendation طریقہ کے بنیادی طور پر ناقابل مطابقت ادا ف میں جن کے لیے انسانی فیصلہ درکار کے tolerance

سوال 64

jazz کے "مجھے User کرتے ہیں playlist preferences refine میں conversation turns کئی Users: صورتحال "پسند ہیں؟ genres پوچھتا ہے "آپ کو کون سے Claude، بعد messages پسند ہے" کے دو

سب سے زیادہ ممکنہ وجہ کیا ہے؟

- A) Claude conversation memory کے لیے vector database connection درکار ہے
- B) Model کی context window exceed ہو گئی ہے
- C) Claude API کو session_id parameter درکار ہے
- D) شامل نہیں کر رہی ہے [درست] messages میں بچھا messages array application آپ کی

request کے stateless API call ہیں — server-side memory کے پاس Claude: کیوں D کا کوئی علم turns کے پاس بچھا Claude، شامل کیے بغیر conversation history میں مکمل messages array کا حصہ نہیں ہیں؛ دو architecture کے Claude (C) session_id اور (A) Vector databases ہیں ہوتا ناممکن (B) context window overflow کے لیے exchange کے messages

سوال 65

History تک پہنچ گئی ہے conversation 78,000 tokens، بعد cooking session صورتحال: 40 منٹ کے شامل ہیں آپ کو اسم معلومات discussion اور عمومی، allergies, recipe scaling, clarified cooking terms، کم کرنے ہیں tokens محفوظ رکھتے ہوئے

کے درمیان بہترین توازن رکھتا ہے؟ token reduction اور approach preservation کونسا

- A) خلاصہ کریں conversation history پوری
- B) رکھیں tokens صرف سب سے حالیہ 20,000
- C) خلاصہ کریں، اور discussion نکالیں، عمومی (allergies, quantities, preferences) structured data اسم رکھیں [درست] verbatim کو exchanges حالیہ
- D) کریں retrieve کے ذریعہ متعلقہ حصہ semantic search کریں اور conversation externally store مکمل

Allergies معلومات محفوظ رکھتی ہے valuable پر سب سے زیادہ cost سب سے کم Hybrid approach: کیوں C (summarization) ہوتا ہے میں compact structured block ایک critical facts جیسے recipe quantities اور exchanges ہوتی ہے، اور حالیہ discussion summarize عمومی، (سہ بچاتے ہوئے precision loss کے دوران conversational coherence کے لیے verbatim میں Options A اور B dietary information اسم B کے لیے ضرورت سے زیادہ پیچیدہ ہے cooking session ایک D ہیں؛

سوال 66

ka preferences اور topics پر assistant کے conversations میں reports کرتے ہیں کہ طویل Users: صورتحال رکھتی ہے message pairs صرف آخری 25 implementation حساب کھو دیتا ہے آپ کی موجود

کیا ہے؟ solution سب سے مؤثر

- A) Hybrid approach: messages پرانے حالیہ messages کا خلاصہ کرتے ہوئے حالیہ messages پرانے
- B) vector similarity search پر conversation history مکمل
- C) Window 50 message pairs تک بڑھائیں
- D) آگے جوڑیں running summary کا خلاصہ کریں اور dropped messages میں turn کر

A: Hybrid approach کیوں A محفوظ رکھتی ہے exact recent context کی مسئلہ کے دونوں پہلوؤں کو حل کرتی ہے Hybrid approach کیوں A برقرار compressed representation کی preferences جبکہ پہلو کی (کے لیے ام conversational coherence) miss کو context ام (B) Vector search صرف اسی مسئلہ کو ملتوی کرتا ہے (C) بڑھانا Window رکھتی ہے semantically سے current query کر سکتی ہے جو

سوال 67

بڑھ جاتی latency سے زیادہ ہوتے ہیں تو 50 turns conversations reports کرتے ہیں کہ جب Users: صورتحال بھی costs اور

بنیادی وجہ کیا ہے؟

- A) شامل ہوتی ہے conversation history کے ساتھ پوری API request کر
- B) Model gradually responses generate کرتا ہے
- C) History سے ملے ہوئے جاتے ہیں database operations کے ساتھ
- D) Model بناتا ہے internal user profile کی ضرورت والا processing زیادہ

A: Claude کی API پر مکمل طور پر stateless — request کو messages array میں پوری request بڑھتی ہے، conversation history شامل کرنی ہوتی ہے جسے جسے conversation history کے درمیان کوئی Model calls دونوں بڑھاتا ہے cost اور directly processing latency ل جاتی ہے، جو internal state رکھتا ہے (D غلط ہے)

سوال 68

تک بڑھ گئی ہے جب conversation history 85,000 tokens، بعد weekly sessions: صورتحال: تین مہینوں کے discussions پچھلی assistant کے بارے میں کیا نتیجہ اخذ کیا تھا؟، تو theme کے isolation پوچھتا ہے "م نہ user کرنے کے بجائے عام جوابات دیتا ہے reference

کیا ہے؟ approach سب سے مؤثر

- A) Rolling window truncation
- B) Key conclusions capture کے ہوئے progressive summarization
- C) Relevant exchanges retrieve کے لیے [درست] semantic embeddings کرنے کے لیے
- D) Discussion conclusions mark کے لیے structured XML tags کرنے کے لیے

scale کو discussion □□ جو تین مہینوں کی approach واحد semantic search پر conversation history کیوں C □□ Rolling window کر سکتی □□□ specific relevant exchanges surface پر demand کر سکتی □□ جبکہ truncation (A) history □□ Progressive summarization (B) discussions کا بیشتر حصہ ضائع کر دے گی □□ history (A) truncation ابstractions میں compress □□ کرتی □□ □□ users کھو دیتی □□ جن کا بار □□ میں specific conclusions ، کرتی □□ □□ compress میں abstractions بوجھ □□ ہیں □□

سوال 69

کرتا ہے، system prompt guidelines میں 10-15 Claude، دوران QA testing: صورتحال
 اندر 1000 token limits ابھی Conversation آجائی 1000 deviation میں responses لیکن بعد 1000

کیا ؟ solution بہترین

- A) Behavioral guidelines میں منتقل کریں □ user message کو پلا □
- B) 20 turns conversation شروع کریں □ بعد نئی □
- C) Conversation breakpoints پر guidelines reinforce □ user-role messages insert □ [درست]
- D) Non-compliant responses کو regenerate □ post-response validation □ کریں □

history کا براہ راست مقابلہ کرتا ہے Behavioral reminders کا periodic injection instruction drift کو regular intervals پر constraints re-establish کرتا ہے Guidelines کو user کو پر Accumulate message کو preventive Post-response validation (D) corrective میں منتقل کرنا authority ان کا (A) شامل کرتی ہے significant latency اور

سوال 70

□□ teaching methodology اور adaptation rules □□ جو AI tutor 2,800 token-system prompt میں **صورتحال:** آپ کو define 12 □□□ □□□ assistant proficiency levels □□□ کر دیتا □□، بعد 12 turns کرتا □□□

کیا fix سب سے مؤثر

- A) 5–4 turns میں inject کریں
- B) Verbose rules کو proficiency-level adaptation demonstrate کرنے والے few-shot examples سے replace کریں [درست]
- C) Critical rules کو system prompt میں رکھیں
- D) Responses evaluate کریں اور اگر difficulty level match نہ ہو تو regenerate کریں

B کیوں: Declarative rules 2,800 والا token system prompt drift کیونکہ vulnerable لی abstract rules
 reasoning س model میں turn ر
 clear کرنا لی match کو model ، کریں demonstrate proficiency-level adaptation correct کرنا جو replace
 behavioral patterns کئی — دیتا turns میں ، abstract instructions زیادہ reliably سوتا

سوال 71

clarifying کرنا، اور reasoning explain برقرار رکھنا، اپنی enthusiastic tone کو assistant **صورتحال**: آپ کے □
□ ہونی چاہئیں؟ define □ اس behavioral guidelines یوجہ □ □ ہیں □ □ questions

سوال 74

Assistant 4+ clarifying requests میں "جیس" venue book اکثر "پارٹی ک" لے Users: صورتحال
abandonment % پوچھتا ، جس سے 35 questions

کرتا ؟ improve کو بہترین طریقہ سے approach trade-off کونسا

- A) Hidden defaults کے ساتھ آگے بڑھیں
- B) میں پوچھیں compound message ایک clarifying questions تمام
- C) Assumptions explicitly بیان کریں اور [درست] corrections بڑھیں
- D) Structured intake form استعمال کریں

دیتا جبکہ غلط response کو فوری، مفید user بیان کرنا اور آگے بڑھنا Assumptions explicitly: کیوں C
کو نہیں بتاتا کیا user (A) Hidden defaults کرنے کی صلاحیت برقرار رکھتا correct کو assumptions
Structured کا تقاضا کرتی upfront effort سے user پھر بھی (B) Compound question list کیا گیا assume
form (D) کی بجائے زیادہ شامل کرتا friction کم

سوال 75

turns rules follow استعمال کرتا ابتدائی assistant contractor-persona system prompt صورتحال: آپ کا
Conversation length 2,500 tokens صرف دیتا assistant generic advice تک 7 turn کرتے ہیں، لیکن

سب سے زیادہ ممکنہ وجہ کیا ہے؟

- A) System prompts initial behavior establish کرتے ہیں صرف
- B) Turns accumulate کمزور ہوتی ہیں model کی attention کے ساتھ
- C) Accumulated assistant responses system prompt اثر کو dilute [درست] ہیں
- D) System prompt صرف ایک بار بھیجا جاتا ہے

System prompt جمع ہوتے ہیں assistant responses میں conversation history کیوں: جیس جیس C
behavioral constraints کو reflect والے text کا proportion ہوتے ہیں assistant-generated content بڑھتا ہے
بجائے اپنے پائلے system prompt instructions پر بھی token lengths چھوٹے Model کم ہوتا جاتا ہے relative
outputs کرتا compound کو drift، کرتا follow کو زیادہ patterns کے

سوال 76

کئی Assistant "میں مدد کر سکتے ہیں؟ report کرتے ہیں جیس" کیا آپ requests میں Users: صورتحال
abandonment % جس سے 40، (کیا ؟ deadline ؟ کیا مدد؟ report کون سی) کرتا respond سوالات پوچھ کر
ہوتا

کیا ؟ solution بہترین

- A) Reasonable assumptions کی پیشکش کریں [درست] adjustments بیان کریں، اور explicitly کریں، انہیں
- B) Respond کے ساتھ smaller model کرنے سے پائلے ambiguity classify کریں
- C) Assumptions predefined interpretations بیان کیے بغیر استعمال کریں
- D) Assistant تک محدود کریں clarifying question میں ایک turn کو

رکھتے ہیں اور in control کو user کو informed کے ساتھ آگے بڑھنا Reasonable stated assumptions: کیوں A کرتی ہے confuse کو users (C) Silent predefined interpretations کو مکمل طور پر ختم کرتا ہے back-and-forth کی back-and-forth turns بھی (D) One-question limit ہے، match ان کے ارادے سے response میں جب latency اور infrastructure مسئلہ حل کیے بغیر core UX (B) Smaller classification model ضرورت ہے شامل کرتا ہے complexity

عملی مشقیں

Exercise 1: Multi-tool Agent with Escalation Logic

Goal: tool integration, structured errors, اور escalation کے ساتھ agent loop بنائیں

Exercise 2: Configuring Claude Code for Team Development

Goal: CLAUDE.md, custom commands, path-specific rules, اور MCP servers configure کریں

Exercise 3: Structured Data Extraction Pipeline

Goal: JSON schema, validation/retry loops, اور Message Batches API کے ساتھ extraction pipeline بنائیں

Exercise 4: Designing and Debugging a Multi-agent Research Pipeline

Goal: subagent orchestration, explicit context passing, error propagation, اور source tracking implement کریں

Appendix: Technologies and Concepts

Technology	Key aspects
Claude Agent SDK	agent loops, <code>stop_reason</code> , hooks, <code>Task</code> , <code>allowedTools</code>
MCP	servers, tools, resources, <code>isError</code> , <code>.mcp.json</code>
Claude Code	CLAUDE.md, <code>.claude/rules/</code> , <code>.claude/commands/</code> , <code>.claude/skills/</code> , planning mode
Claude Code CLI	<code>-p</code> , <code>--output-format json</code> , <code>--json-schema</code>
Claude API	<code>tool_use</code> , <code>tool_choice</code> , <code>stop_reason</code> , <code>max_tokens</code>

Message Batches API	50% savings, 24-hour window, <code>custom_id</code>
JSON Schema	required/optional, nullable, enum values
Few-shot prompting	ambiguous scenarios ❌ ❌ examples
Prompt chaining	sequential decomposition
Context window	token budget, lost-in-the-middle
Confidence calibration	field-level scoring, stratified sampling

Out-of-Scope Topics

❌: موضوعات امتحان میں شامل نہیں ہیں

- Claude models کی fine-tuning
- Authentication, billing, یا account management
- implementation کی تفصیلی programming languages مخصوص
- hosting/infrastructure کی MCP servers
- Claude کی internal architecture یا model weights
- Constitutional AI, RLHF, یا safety training
- Embeddings یا vector databases کی implementation details
- Computer use / browser automation
- Vision / image analysis
- Streaming API یا SSE
- Rate limiting اور detailed API cost calculations
- OAuth اور API key rotation details
- Cloud-provider-specific configs
- Performance benchmarks
- Prompt caching implementation details
- Token counting algorithms

Preparation Recommendations

1. بنائیں agent کو ساتھ ایک Claude Agent SDK
2. کریں configure پر real project کو Claude Code
3. کریں test اور MCP tools design
4. بنائیں Data extraction pipeline
5. کریں Prompt engineering practice
6. سیکھیں Context management patterns

7. Escalation اور human-in-the-loop workflows سمجھیں

8. Practice exam حل کریں