

Claude Certified Architect — Foundations Certification

مطالعہ گائیڈ (سرکاری امتحانی گائیڈ کی بنیاد پر)

تعارف

سرٹیفیکیشن اس بات کی تصدیق کرتی ہے کہ ایک ماہر حقیقی Claude Certified Architect — Foundations Claude Code، Claude Agent SDK، Claude API، اور Model Context Protocol (MCP) — یعنی بنیادی علم کا جائزہ لیتا ہے — کے ساتھ پروڈکشن ایپلیکیشنز بنائی جاتی ہیں۔ Claude و بنیادی ٹیکنالوجیز جن سے

agentic systems امتحانی سوالات حقیقت پسندانہ صنعتی منظرناموں پر مبنی ہوتے ہیں: کسٹمر سپورٹ کے لیے، multi-agent research pipelines، ڈیزائن کرنا، Claude Code کو CI/CD میں ضم کرنا، developer productivity، structured data بنانا، اور غیر ساختہ دستاویزات سے tools نکالنا

هدف امیدوار

کرتا ہے آپ ship کے ساتھ پروڈکشن ایپلیکیشنز ڈیزائن اور Claude کے جو solution architect مثالی امیدوار ایک کے پاس کم از کم 6 ماہ کا عملی تجربہ ہونا چاہیے:

- Claude Agent SDK** — multi-agent orchestration، subagents کو delegate کرنا، tool integration، lifecycle hooks
- Claude Code** — CLAUDE.md، MCP servers، Agent Skills، planning mode
- Model Context Protocol (MCP)** — backend integration کے لیے tools اور resources
- Prompt engineering** — JSON schemas، few-shot examples، data extraction templates
- Context windows** — لمبی دستاویزات کے ساتھ کام، multi-agent context passing
- CI/CD pipelines** — automated code review، test generation
- Escalation and reliability** — error handling، human-in-the-loop

امتحانی فارمیٹ

پیرامیٹر	قدر
سوال کی قسم	Multiple choice (میں سے 1 درست 4)
اسکورنگ	100–1000 scale، passing score 720
Guessing penalty	نہیں (سوال کا جواب دیں!)
Scenarios	8 4 (randomly selected) میں سے

امتحانی مواد: 5 ڈومینز

ڈومین	وزن
1. Agent architecture and orchestration	27%
2. Tool design and MCP integration	18%
3. Claude Code configuration and workflows	20%
4. Prompt engineering and structured output	20%
5. Context management and reliability	15%

امتحانی منظر نامہ

Scenario 1: Customer Support Agent

returns, billing disputes, اور account issues استعمال کرتے ہوئے Claude Agent SDK بناتے ہیں جو آپ ایک agent MCP tools (`get_customer`, `lookup_order`, `process_refund`, `escalate_to_human`) سنبھالتا ہے۔ مناسب first-contact resolution +% استعمال کرنا 80 دفعہ (`escalate_to_human`) ساتھ ساتھ

Scenario 2: Claude Code ساتھ Code Generation

code generation, refactoring, تیز کرنے کے لیے استعمال کرتے ہیں development کو Claude Code آپ کے ساتھ CLAUDE.md configuration اور custom slash commands آپ کو اسدے debugging, documentation کے ساتھ integrate کب استعمال کرنا planning mode کرنا، اور یہ سمجھنا کے

Scenario 3: Multi-Agent Research System

tasks کو coordinator agent specialized subagents سونپتا: web research, document analysis, synthesis, تیار کرنے چاہئیں reports کے ساتھ مکمل citations سسٹم کو report generation اور

Scenario 4: Developer Productivity Tools

agent engineers کو unfamiliar codebases explore کرنے، boilerplate code اور routine tasks بنانے، MCP servers اور Built-in tools (Read, Write, Bash, Grep, Glob) میں مدد دیتا ہے۔ automate کیے جاتے ہیں

Scenario 5: Claude Code for Continuous Integration

pull اور automated code reviews, test generation, Claude Code کو CI/CD pipeline تاکہ کم سے کم false positives ڈیزائن ہونے چاہئیں کے Prompts حاصل ہو۔ request feedback

Scenario 6: Structured Data Extraction

کرتا ہے، validate کے ذریعے JSON schemas کو output، سسٹم غیر ساختہ دستاویزات سے معلومات نکالتا ہے اور high accuracy کے لیے edge cases پر سنبھالنا چاہیے۔ اس کا برقرار رکھنا اس کے لیے ضروری ہے۔

Scenario 7: Conversational AI Architecture Patterns

multi-turn conversational systems میں جن میں context window management، turns متعدد، memory strategies، tool design کے لیے execution محفوظ، کا برقرار رکھنا instructions میں اور مہم یا متضاد، user inputs کو سنبھالنا شامل ہے۔

Scenario 8: Agentic AI Tools (ہماری مدد کریں — مواد موجود نہیں)

میں شامل نہیں ہے۔ guide کے لیے ابھی تک اس candidates کی اطلاع امتحان دینے والے scenario اس میں share میں GitHub Issues کے سوالات دیکھیں، تو ان میں scenario کے اصل امتحان میں اس شامل کر سکیں۔ آپ کا تعاون اس شخص کی مدد کرے گا جو امتحان کی تیاری کے لیے coverage تاکہ مہم مکمل رہے۔

سرکاری دستاویزات

وسیلہ	URL
Claude API — Messages	https://platform.claude.com/docs/en/api/messages
Claude API — Tool Use	https://platform.claude.com/docs/en/build-with-claude/tool-use
Claude API — Message Batches	https://platform.claude.com/docs/en/build-with-claude/message-batches
Claude Agent SDK — Overview	https://platform.claude.com/docs/en/agent-sdk/overview
Claude Agent SDK — Hooks	https://platform.claude.com/docs/en/agent-sdk/hooks
Claude Agent SDK — Subagents	https://platform.claude.com/docs/en/agent-sdk/subagents
Claude Agent SDK — Sessions	https://platform.claude.com/docs/en/agent-sdk/sessions
Model Context Protocol (MCP)	https://modelcontextprotocol.io/
MCP — Tools	https://modelcontextprotocol.io/docs/concepts/tools
MCP — Resources	https://modelcontextprotocol.io/docs/concepts/resources
MCP — Servers	https://modelcontextprotocol.io/docs/concepts/servers
Claude Code — Documentation	https://code.claude.com/docs/en/overview
Claude Code — CLAUDE.md and Memory	https://code.claude.com/docs/en/memory
Claude Code — Skills (incl. slash commands)	https://code.claude.com/docs/en/skills

Claude Code — Hooks	https://code.claude.com/docs/en/hooks
Claude Code — Sub-agents	https://code.claude.com/docs/en/sub-agents
Claude Code — MCP Integration	https://code.claude.com/docs/en/mcp
Claude Code — GitHub Actions CI/CD	https://code.claude.com/docs/en/github-actions
Claude Code — GitLab CI/CD	https://code.claude.com/docs/en/gitlab-ci-cd
Claude Code — Headless (non-interactive mode)	https://code.claude.com/docs/en/headless
Prompt Engineering Guide	https://platform.claude.com/docs/en/build-with-claude/prompt-engineering/overview
Extended Thinking	https://platform.claude.com/docs/en/build-with-claude/extended-thinking
Anthropic Cookbook (code examples)	https://github.com/anthropics/anthropic-cookbook

نظریاتی بنیادیں: حصہ ۱

یہ حصہ تمام نظریاتی احاطہ کرتا ہے جس کی آپ کو امتحان میں کامیابی کے لیے ضرورت ہے۔ مواد کو کے مطابق — اس سے آپ کے domains کے مطابق ترتیب دیا گیا ہے، نہ کہ امتحانی concepts ٹیکنالوجیز اور موضوع کی زیادہ گہری سمجھ پیدا کر سکتے ہیں۔

کی بنیادیں Claude API — Model Interaction: باب 1

دستاویزات: [Messages API](#) | [Prompt Engineering](#)

1.1 API Request Structure

Claude API کی request کی ر Claude Messages API کی پیروی کرتا ہے request-response model ایک شامل ہوتا ہے:

```
{
  "model": "claude-sonnet-4-6",
  "max_tokens": 1024,
  "system": "You are a helpful assistant.",
  "messages": [
    {"role": "user", "content": "Hi!"},
    {"role": "assistant", "content": "Hello!"},
    {"role": "user", "content": "How are you?"}
  ],
  "tools": [...],
  "tool_choice": {"type": "auto"}
}
```

م فیلڈر:

- `model` — model selection (`claude-opus-4-6` , `claude-sonnet-4-6` , `claude-haiku-4-5`)
- `max_tokens` — response کی تعداد میں زیادہ سے زیادہ
- `system` — system prompt (model کی تعریف کرتا ہے)
- `messages` — conversation history (تاریخہ آپ کو مکمل) (بھیجی ہوئی history تسلسل برقرار رکھنے کے لیے آپ کو مکمل)
- `tools` — tools کی definitions دستیاب
- `tool_choice` — tool selection strategy

1.2 Message Roles

`messages` array میں roles استعمال کرتا ہے:

- `user` — user messages
- `assistant` — model responses (history میں شامل کیے جاتے ہیں)
- `tool` — tool call results (role واضح طور پر `tool_result` میں کیا جاتا ہے؛ `set` میں ظاہر ہوتا ہے)

Model requests بھیجی جائے گی۔ `conversation history` میں آپ کو مکمل API request انتہائی اہم: ہر آزاد ہوتا ہے call محفوظ نہیں رکھتا — ہر state درمیان

1.3 Response میں `stop_reason` Field

کیوں روکی generation model شامل ہوتا ہے، جو بتاتا ہے کہ `stop_reason` میں Claude API response

Value	Description	Action
"end_turn"	Model نے response مکمل کر لیا	user کو دکھائیں نتیجہ
"tool_use"	Model tool call کرنا چاہتا ہے	Tool execute کریں اور result دیں
"max_tokens"	Token limit ختم ہو گئی	Response truncated ہو سکتا ہے؛ limit بڑھانی پڑے گی
"stop_sequence"	Stop sequence مل گئی	کریں handle کہ مطابق application logic اپنی

کو کنٹرول کرتے agent loop سب سے اہم ہیں — یہی "end_turn" اور "tool_use" میں Agentic systems ہیں۔

1.4 System Prompt

System prompt متعین کرتا ہے behavioral rules اور context جو instruction ایک خاص

- messages array الگ ہوتا؛ یہ system field کا حصہ نہیں ہوتا؛ بلکہ الگ array
- user messages پر فوقیت رکھتا ہے
- میں لاگو رہتا ہے conversation ہوتا ہے اور پوری load ایک بار
- کی تعریف کے لیے استعمال ہوتا ہے output format اور role, constraints,

پیدا کر سکتی ہے مثال کے طور پر tool associations غیر ارادی wording کی system prompt: امتحان کے لیے اہم کو ضرورت سے زیادہ get_customer کو model کی تصدیق کریں "جیسی ہدایت customer پر،" ہمیشہ استعمال کرنے پر مجبور کر سکتی ہے، حتیٰ کے جب یہ ضروری نہ ہو

1.5 Context Window

Context window text (tokens) جسے اس میں process ایک وقت میں model کی کل مقدار ہے جسے شامل ہے:

- System prompt
- message history مکمل
- Tool definitions
- Tool results

مسائل context-window:

1. **Lost-in-the-middle effect:** models input سے اعتماد سے زیادہ موجود معلومات پر اختتام پر موجود معلومات کو زیادہ input سے اعتماد سے زیادہ models process کر سکتے ہیں۔ حل: اہم معلومات شروع یا آخر کے قریب miss کرتے ہیں، مگر درمیان کی تفصیلات process رکھیں
2. **Tool results** واپس کر کے tool 40+ fields شامل کرتا ہے اگر output میں tool call context کا جمع ہونا: ہر Tool results کا بڑا حصہ ضائع ہو جاتا ہے context مگر صرف 5 اہم ہوں، تو
3. **Progressive summarization:** history compress کرتے وقت numeric values, percentages, اور dates اکثر گم ہو کر غیر واضح ہو جاتے ہیں ("تقریباً"، "کچھ"، "چند")

2 Tools اور tool_use: باب

Tool Use: دستاویزات

2.1 tool_use کیا

برا Model کی اجازت دیتا external functions call Claude جو mechanism ایک tool_use result کرتا اور execute اس code بناتا؛ آپ کا structured tool call request میں چلاتا — و code راست واپس کرتا

2.2 Tool Definition

کیا جاتا define کے ذریعہ JSON schema ایک tool

```
{
  "name": "get_customer",
  "description": "Finds a customer by email or ID. Returns the customer profile, including name, email, order history, and account status. Use this tool BEFORE lookup_order to verify the customer's identity. Accepts an email (format: user@domain.com) or a numeric customer_id.",
  "input_schema": {
    "type": "object",
    "properties": {
      "email": {"type": "string", "description": "Customer email"},
      "customer_id": {"type": "integer", "description": "Numeric customer ID"}
    },
    "required": []
  }
}
```

کے انتہائی اہم ہلو Tool description:

- Description tool selection** کی بنیاد پر descriptions کو ان کی LLM tools mechanism کا بنیادی Minimal descriptions ("Customer information retrieve کرتا) اُن مواقع پر غلطیوں کا (کرتا) overlap کے دو tools باعث بنتی ہیں جب کرتے ہوں
- Description میں شامل کریں:**
 - Tool کیا کرتا اور کیا واپس کرتا
 - Input formats اور example values
 - Edge cases اور constraints
 - مقابلہ میں کب استعمال و tool similar alternatives
- کی analyze_document اور analyze_content سے بچیں اگر overlapping descriptions ایک جیسے یا انہیں خلط ملط کر دے گا model تقریباً ایک جیسی ہوں، تو descriptions
- Built-in tools** MCP tools: agents similar functionality والے built-in tools (Read, Grep) کو MCP tools — مضبوط بنائیں MCP tool descriptions پر ترجیح دے سکتے ہیں اس سے بچنے کے لیے concrete advantages, unique data, context یا و built-in tools میں کر سکتے ہیں جو

2.3 tool_choice Parameter

کیسے منتخب کرتا model tools کے کنٹرول کرتا tool_choice

Value	Behavior	کب استعمال کریں
<code>{ "type": "auto" }</code>	Model کرنا tool call خود ط کرتا یا کرنا text یا میں جواب دینا	default زیاد تر حالات میں
<code>{ "type": "any" }</code>	Model کرنا tool call کو لازماً کوئی	guaranteed جب آپ کو structured output چاہیں
<code>{ "type": "tool", "name": "extract_metadata" }</code>	Model کرنا tool call کو لازماً ایک مخصوص tool کو	forced first step / execution order جب آپ کو چاہیں

ا: م منظر نامہ:

- `tool_choice: "any"` + multiple extraction tools → model منتخب کرتا ہے، مگر پھر بھی tool بہترین model ملنا structured output
- Forced selection → enrichment (مثلاً) کی ضمانت چاہیں action جب آپ کو کسی خاص پم (`extract_metadata`)

2.4 Structured Output JSON Schemas

حاصل کرنے کا سب سے قابلِ structured output Claude استعمال کرنا `tool_use` کے ساتھ JSON schemas ی: اعتماد طریقہ

- Syntax (trailing commas، غائب ہیں، braces) کی ضمانت دیتا ہے JSON کے اعتبار سے درست (وٹ)
- (موجود وٹ ہیں required fields) نافذ کرتا ہے structure مطلوب
- Semantic correctness (values) کی ضمانت نہیں دیتا

Schema design — بنیادی اصول:


```
{
  "type": "object",
  "properties": {
    "category": {
      "type": "string",
      "enum": ["bug", "feature", "docs", "unclear", "other"]
    },
    "category_detail": {
      "type": ["string", "null"],
      "description": "Details if category = 'other' or 'unclear'"
    },
    "severity": {
      "type": "string",
      "enum": ["critical", "high", "medium", "low"]
    },
    "confidence": {
      "type": "number",
      "minimum": 0,
      "maximum": 1
    },
    "optional_field": {
      "type": ["string", "null"],
      "description": "Null if the information was not found in the source"
    }
  },
  "required": ["category", "severity"]
}
```

Schema design rules:


- Required vs optional:** بنائیں جن کی معلومات ہمیشہ دستیاب ہو۔ Required fields کو fields صرف اُن optional: Required fields model پر data کو values غائب ہونے پر مجبور کر سکتی ہیں۔
- Nullable fields:** استعمال کریں جو ممکنہ طور پر `"type": ["string", "null"]` ایسی معلومات کے لیے۔ بنائے value واپس کر سکتا ہے بجائے اس کے کہ وہ خود ساختہ `null` Model موجود نہ ہوں۔
- Enums with "other":** predefined categories کے لیے ہجاء کے لیے `"other"` شامل کریں۔ `"other"` + ایک detail string
- Enum "unclear":** کب بارے میں پُراعتما نہ ہو — ایماندار model category اُن صورتوں کے لیے جب `"unclear"` سے بہتر category غلط

2.5 Syntax vs Semantic Errors

Error type	Example	Mitigation
Syntax	Invalid JSON, field type غلط	JSON schema کے ساتھ <code>tool_use</code> (ختم کر دیتا) <code>tool_use</code>
Semantic	Totals match نہیں کرتے، value field غلط، hallucination	Validation checks, feedback کے ساتھ retry, self-correction

3.3 Hub-and-Spoke: Coordinator اور Subagents

Multi-agent architecture عموماً hub-and-spoke topology میں بنائی جاتی ہے:



Coordinator کی ذمہ داریاں:

- Task کو subtasks میں تقسیم کرنا
- (dynamic selection) درکار subagents میں سے طے کرنا کہ کون سا
- کو سونپنا subagents کام
- کرنا validate نتائج جمع اور
- Errors اور retries handle کرنا
- تک پہنچانا user نتائج

الگ ہوتا context subagents کا: اصول

- Subagents conversation history کی coordinator خود بخود inherit نہیں کرتے
- میں واضح طور پر دینا ہوتا context subagent prompt تمام ضروری
- Subagents memory share کرتے ہیں کہ درمیان
- (observability اور error control) کے ذریعے گزرتی coordinator communication تمام

3.4 Subagents کے لیے Task Tool بنانا

Subagents Task tool کے ذریعے spawn میں جاتے ہیں:

```
# Coordinator میں allowedTools کے "Task" ہونا چاہیے
coordinator_agent = AgentDefinition(
    allowed_tools=["Task", "get_customer"]
)
```

Explicit context passing لازمی ہے:

```
# Bad: subagent کے پاس context نہیں ہے
Task: "Analyze the document"

# Good: context prompt مکمل
Task: "Analyze the following document.
Document: [full document text]
Prior search results: [web search results]
Output format requirements: [schema]"
```

Parallel spawning: coordinator ایک response میں متعدد Task s call کر سکتا ہے — subagents parallel چلتے ہیں:

```
# Coordinator کے ایک response میں شامل ہے
Task 1: "Search for articles about X"
Task 2: "Analyze document Y"
Task 3: "Search for articles about Z"
# تینوں ایک ساتھ چلتے ہیں
```

3.5 Agent SDK میں Hooks

Hooks agent lifecycle میں transformation اور interception پر points کے مخصوص

PostToolUse tool result کو model سے intercept تک پہنچانے کے لیے:

```
# MCP tools کے تاریخ کو normalize formats سے تاریخ کو مختلف
@hook("PostToolUse")
def normalize_dates(tool_result):
    # Unix timestamp -> ISO 8601
    # "Mar 5, 2025" -> "2025-03-05"
    return normalized_result
```

Outgoing-call interception hook policy والے actions کو block کرنے کی خلاف ورزی کرنے والے:

```
# refunds block مثال: $500 سے اوپر
@hook("PreToolUse")
def enforce_refund_limit(tool_call):
    if tool_call.name == "process_refund" and tool_call.args.amount > 500:
        return redirect_to_escalation(tool_call)
```

Hooks اور prompt instructions میں فرق

Attribute	Hooks	Prompt instructions
Guarantee	Deterministic (100%)	Probabilistic (>90%, 100% نہیں)
کب استعمال کریں	Critical business rules, financial operations, compliance	General preferences, recommendations, formatting
مثال	Refunds > \$500 block کریں	"Try to solve before escalating"

استعمال کریں hooks، انہیں prompts — کے مالی، قانونی، یا حفاظتی نتائج کے failure قاعدے: جب

4: Model Context Protocol (MCP)

دستاویزات: [MCP](#) | [Tools](#) | [Resources](#) | [Servers](#)

4.1 MCP کیا ہے

MCP (Model Context Protocol) Claude کو external systems سے جوڑتا ہے جو open protocol ایک ہے۔ MCP سروس جوڑتا ہے جو external systems سے جوڑتا ہے جو open protocol ایک ہے۔ MCP سروس جوڑتا ہے جو external systems سے جوڑتا ہے جو open protocol ایک ہے۔

1. **Tools** — functions (agent actions) کے لیے (CRUD operations, API calls, command execution)
2. **Resources** — context کے لیے (documentation, database schemas, content catalogs)
3. **Prompts** — predefined prompt templates کے لیے tasks عام

4.2 MCP Servers

MCP server ایک process جو MCP protocol implement کرتا ہے اور tools/resources جب فراہم کرنا چاہے۔ MCP server آپ سے connect کرے گا:

- وہ خود بخود tools تمام
- ایک ساتھ دستیاب ہوتے ہیں tools کے connected servers تمام
- انہیں کیسے استعمال کرے گا model طے کرتی ہیں کے Tool descriptions

4.3 MCP Servers کو Configure کرنا

Project configuration (`.mcp.json`) — team usage کے لیے:

```
{
  "mcpServers": {
    "github": {
      "command": "npx",
      "args": ["-y", "@modelcontextprotocol/server-github"],
      "env": {
        "GITHUB_TOKEN": "${GITHUB_TOKEN}"
      }
    },
    "jira": {
      "command": "npx",
      "args": ["-y", "mcp-server-jira"],
      "env": {
        "JIRA_TOKEN": "${JIRA_TOKEN}"
      }
    }
  }
}
```

ملاحظات:

- میں ہوتا ہے version control میں محفوظ ہوتا ہے اور `.mcp.json` project root
- Environment variables (`${GITHUB_TOKEN}`) secrets میں استعمال ہوتے ہیں — tokens خود commit نہیں کیے جاتے

- Database schemas (data structure سمجھنے کے لیے)
- Documentation (API references, internal guides)
- Issue/task summaries

Resource کا فائدہ: agent کے لیے exploratory tool calls میں پڑتی کے سمجھنے کے لیے agent کا فائدہ: Resource کا فائدہ: map فوری Resource کیا ہے

5 اور Claude Code — Configuration Workflows

دستاویزات: [Claude Code](#) | [Memory / CLAUDE.md](#) | [Skills](#) | [MCP](#) | [Hooks](#) | [Sub-agents](#) | [GitHub Actions](#) | [Headless](#)

5.1 CLAUDE.md Hierarchy

hierarchy استعمال کرتا ہے اس کی تین سطحی Claude Code میں جو instruction file(s) و CLAUDE.md ہے:

1. User-level: ~/.claude/CLAUDE.md
 - پر لاگو user صرف اسی
 - نمونہ ہوتا ہے share کہ ذریعہ VCS
 - working style اور preferences ذاتی
2. Project-level: .claude/CLAUDE.md یا root CLAUDE.md
 - پر لاگو project contributors تمام
 - ہوتا ہے manage کہ ذریعہ VCS
 - Coding standards, testing standards, architectural decisions
3. Directory-level: subdirectories میں CLAUDE.md
 - کہ ساتھ کام ہو تو لاگو ہوتا ہے files کی directory جب اسی
 - conventions کہ اُس حصہ کہ مخصوص codebase

~/.claude/CLAUDE.md میں ملتی کیونکہ و project instructions کو team member عام غلطی: ایک نئے میں رکھی گئی تھیں (user-level) ~/.claude/CLAUDE.md (project-level) کے بجائے

5.2 @path Syntax (File Imports)

جو جاتی configuration modular کر سکتا ہے، جس سے refer کے ذریعہ @path کو files بیرونی CLAUDE.md ہے:

Coding standards @./standards/coding-style.md میں بیان کیے گئے ہیں
 Test requirements @./standards/testing-requirements.md میں ہیں
 Project overview @README.md اور dependencies @package.json میں ہیں

- (نہ) میں space کوئی) آئے file path کے فوراً بعد @
- Relative اور absolute دونوں paths supported ہیں
- Relative paths کے مطابق file اُس resolve کے میں جس میں import کے وٹے ہیں
- Maximum import nesting depth 5 ہے

شامل ہوتے ہیں، standards میں صرف متعلقہ package کم ہوتی ہے اور duplication اس سے

کرنے کے organize کے حساب سے topic کو rules کا متبادل ہے، جو monolithic CLAUDE.md .claude/rules/

لیہ استعمال ہوتا ہے:

```
.claude/rules/  
  testing.md          -- testing conventions  
  api-conventions.md  -- API conventions  
  deployment.md       -- deployment rules  
  react-patterns.md   -- React patterns
```

YAML frontmatter **کے ساتھ** `paths` conditional loading:

```
---
paths: ["src/api/**/*.json"]
---
```

استعمال کریں۔ explicit error handling کہ ساتھ async/await کہ لیے API files واپس کریں۔ endpoint standard response wrapper

```
---
paths: ["**/*.test.tsx", "**/*.test.ts"]
---
```

استعمال ہونہ چاہئیں۔ describe/it blocks میں Tests
 ہمیں، hardcoding استعمال کریں Data factories
 استعمال کریں، test database - نہ کریں Database mock

۱۰. کس کا کام کرتا ہے؟

- کرتا match سہ pattern paths کر جو file edit ایسا Claude Code ہوتا ہے جب load صرف اس وقت Rule ہو
- نہیں ہیں rules load ہوتے ہیں — غیر متعلقہ tokens اور context اس سہ
- Glob patterns کرنے دینے ہیں، چاہے conventions apply کے لحاظ سہ file type آپ کو میں codebase files (tests، migrations) پر (کے لیے بہت مفید tests) کے ہیں بھی ہوں

کے استعمال کریں directory-level CLAUDE.md بمقابلہ .claude/rules/ والے paths

- .claude/rules/ with paths — جب conventions کئی directories میں بکھری files (tests، migrations) پر لاگو ہوں
- Directory-level CLAUDE.md — جب conventions خاص کسی directory اور کے ہیں اور کے ہیں ضروری نہیں ہوں

5.4 Custom Slash Commands اور Skills

skills کو (.claude/commands/) custom commands میں Claude Code version نوٹ: موجود ہے
 بناتے commands /name formats کر دیا گیا ہے دونوں unify کے ساتھ (.claude/skills/) supported اب بھی format کا ذکر کرتی ہے — و (.claude/commands/) ہیں امتحانی گائیڈ

Slash commands reusable prompt templates ہیں جو /name کے ذریعے invoke کے ہیں:

.claude/commands/ format (legacy, supported):

```
.claude/commands/
review.md          -- /review -- standard code review
test-gen.md        -- /test-gen -- test generation
```

.claude/skills/ format (current):

```
.claude/skills/
review/SKILL.md    -- /review -- frontmatter configuration
test-gen/SKILL.md  کہ ساتھ
```

Project commands (.claude/commands/ یا .claude/skills/):

- کرنے والے سب کے لیے دستیاب ہوتے ہیں repo clone میں محفوظ ہوتے ہیں اور VCS
- یقینی بناتے ہیں consistent workflows ٹیم میں

User commands (~/.claude/commands/ یا ~/.claude/skills/):

- نہیں ہیں ہوتے share کے ذریعے VCS جو commands ذاتی
- کے لیے workflows انفرادی

5.5 Skills — .claude/skills/

Skills advanced commands ہیں جو SKILL.md frontmatter کے ذریعے configure کے ہیں:

```
---
context: fork
allowed-tools: ["Read", "Grep", "Glob"]
argument-hint: "Path to the directory to analyze"
---
```

کا تجزیہ کریں۔ code structure میں directory دی گئی
report پر ایک architectural patterns اور Dependencies

Frontmatter parameters:

Parameter	Description
<code>context:</code> <code>fork</code>	Verbose output main session کو pollute نہیں کرتا isolated subagent میں چلاتا
<code>allowed-</code> <code>tools</code>	نہیں کر skill files delete مثلاً — security) دستیاب ہوں گے tools یں محدود کرتا ہے کون سے (سکا گی اگر اجازت نہ ہو
<code>argument-</code> <code>hint</code>	مانگنے کا اشارہ argument ہو تو invoke کے بغیر skill parameters جب

Skill کے استعمال کریں CLAUDE.md بمقابلہ:

- Skill — task مخصوص on-demand invocation (review, analysis, generation) کے لیے
- CLAUDE.md — general standards اور conventions ہمیشہ لوڈ ہونے والے

Personal skills (~/ .claude/skills/):

- متاثر نہ ہوں teammates مختلف ناموں سے بنائیں تاکہ personal variants اپنی

5.6 Planning Mode Direct Execution بمقابلہ

Planning mode:

- Model نہیں کرتا changes کرتا ؛ plan اور investigate صرف
- Codebase explore کے لیے Read, Grep, Glob استعمال کرتا ہے
- کرتا ہے user approve تیار کرتا ہے جس implementation plan ایک
- safe exploration کے side effects بغیر

Planning mode کے استعمال کریں:

- changes (files درجنوں) بڑے
- Multiple plausible approaches (microservices: boundaries کیسے define ہوں؟)
- Architectural decisions (کیا framework کون سا؟ structure؟)
- Unfamiliar codebase (change کی ضرورت ہے سمجھنا)
- Library migrations 45+ files کو متاثر کریں

Direct execution کے استعمال کریں:

- Single-file fixes ساتھ stack trace واضح
- شامل کرنا validation check ایک
- changes اچھی طرح سمجھ گئی، غیر مبہم

Combined approach:

1. Investigation اور design کے لیے planning mode
2. User plan approve کر
3. Approved plan implement کے لیے direct execution

Explore subagent — codebase explore کے لیے specialized subagent:

- Verbose output کو main context سے isolate کرنا
- واپس کرنا summary صرف
- روکنا Multi-phase tasks میں context-window exhaustion

5.7 /compact Command

/compact context compress کے لیے built-in command:

- میں جگہ خالی کرنا context window کو summarize کر کے history چھپی
- Long investigation sessions میں verbose tool output سے context بھر جائے
- Risk: exact numeric values, dates, اور specific details summarization میں گم ہو سکتے ہیں

5.8 /memory Command

/memory sessions memory manage کے لیے built-in command:

- محفوظ کیے جا سکیں context اور notes, preferences, کے لیے کھولنا، تاکہ CLAUDE.md file editing
- Information sessions اور load پر خود بخود startup کے پار برقرار رہتی ہیں
- Project conventions, user preferences, frequently used commands, اور current work context محفوظ کر کے مفید
- دوبارہ سمجھانے کا متبادل instructions میں وہی session رہے

5.9 Claude Code CLI for CI/CD

-p (یا --print) flag:

```
claude -p "Analyze this pull request for security issues"
```

- Non-interactive mode: prompt process کرنا، اور print پر stdout، exit کرنا،
- User input کا انتظار نہیں کرتا
- CI/CD pipelines میں Claude کا واحد درست طریقہ

CI کے لیے structured output:

```
claude -p "Review this PR" --output-format json --json-schema
'{"type":"object",...}'
```

- `--output-format json` — output کو JSON میں دیتا ہے
- `--json-schema` — output کو schema مطابق validate کرتا ہے
- Result کو automatically inline PR comments میں parse کرنا

Session context isolation: Claude session میں code generate کرنا، اکثر review کیا جاتا ہے، اور اپنا reasoning context (model اپنی) سے الگ ہوتا ہے۔ چیلنج ساتھ رکھتا ہے اور اپنا فیصلوں کو (model اپنی) سے الگ ہوتا ہے۔ Review کے لیے independent instance استعمال کریں۔

Duplicate comments review results context میں وقت، پچھلے review کے بعد دوبارہ commits سے بچاؤ: unresolved issues report کی ہدایت دیں یا Claude میں شامل کریں اور

5.10 Session Management اور `fork_session`

`--resume <session-name>` named session کو resume کرتا ہے:

```
claude --resume investigation-auth-bug
```

- saved context سے جاری رکھتا ہے conversation کے ساتھ پچھلے context
- Long investigations میں مفید sessions جو متعدد پر پھیلی ہوئی ہیں ان کے لیے
- Risk: tool results stale بدل چکی ہیں تو files کے بعد session اگر پچھلے

`fork_session` shared context سے independent branch بناتا ہے:

```
Codebase investigation
|
fork_session
/      \
Approach A:  Approach B:
Redux       Context API
```

- کرتا ہے context inherit تک forks branch point دونوں
- کرتا ہے diverge اس کے بعد وہ آزادانہ طور پر
- Approaches compare کے لیے مفید strategies test کرنے یا

Resume نئی session کے بجائے نئی

- Tool results stale (files) میں بدل چکی ہیں
- ہو گیا context degrade کافی وقت گزر چکا ہو اور
- کرنے کے بجائے یہ بہتر ہے کہ "م" جو پایا اس کا مختصر خلاصہ ہے: resume کے ساتھ tool data پرانے کیا جائے restart "..."

باب 6: Prompt Engineering — Advanced Techniques

دستاویزات: [Prompt Engineering](#) | [Anthropic Cookbook](#)

6.1 Few-shot Prompting

Few-shot prompting میں input/output prompt 2–4 دکھانے کے لیے expected behavior کے طریقے جس میں شامل کیے جاتے ہیں examples

Few-shot text descriptions زیادہ مؤثر کیوں

- "وہ" کو کئی طریقوں سے سمجھا جا سکتا ہے precise جیسے "زیادہ" instruction میں
- Example decision logic اور expected format غیر میں طور پر
- Model pattern (صرف examples) کرنا generalize پر cases کو نئے

Few-shot examples کی اقسام اور استعمال

1. Ambiguous scenarios کے لیے examples:

```
Request: "My order is broken"
Action: Call get_customer -> lookup_order -> check status.
Rationale: "broken" damaged item آپ کو ہو سکتا ہے؛ order details میں درکار
```



```
Request: "Get me a manager"
Action: escalate_to_human call کریں فوراً
Rationale: Customer مانگ رہا ہے خود حل کرنے کی کوشش نہ کریں human واضح طور پر
```

2. Output formatting کے لیے examples:

```
Finding example:
{
  "location": "src/auth/login.ts:42",
  "issue": "SQL injection in the username parameter",
  "severity": "critical",
  "suggested_fix": "Use a parameterized query"
}
```

3. Acceptable problematic code کے لیے examples:

```
// Acceptable (flag نہ کریں):
const items = data.filter(x => x.active);

// Problem (flag کریں):
const items = data.filter(x => x.active == true); // Use strict equality ===
```

4. Different document formats سے extraction کے examples:

Document with inline citations:

"As shown in the study (Smith, 2023), the rate is 42%."

-> {"value": "42%", "source": "Smith, 2023", "type": "inline_citation"}

Document with bibliography references:

"The rate is 42%. [1]"

-> {"value": "42%", "source": "reference_1", "type": "bibliography"}

5. Informal measurements کے لیے examples:

Text: "about two handfuls of rice"

-> {"amount": "~100g", "original_text": "two handfuls", "precision": "approximate"}

Text: "a pinch of salt"

-> {"amount": "~1g", "original_text": "a pinch", "precision": "approximate"}

Few-shot purely rule-based instructions میں مؤثر اور non-standard measurement units جو informal خاص طور پر Few-shot based instructions کے لیے بہت متنوع ہوتی ہیں

Prompts استعمال strict JSON schemas کے لیے structured output جب format normalization rules میں شامل کریں normalization rules میں prompt کریں:

Normalization:

- Dates: ISO 8601 (YYYY-MM-DD); "yesterday" -> absolute date compute کریں ہمیشہ
- Currency: numeric amount + currency code; "five bucks" -> {"amount": 5, "currency": "USD"}
- Percentages: decimal fraction; "half" -> 0.5

values inconsistent اور درست ہو مگر JSON syntactically کم ہوتے ہیں جہاں semantic errors اس سے

6.2 Explicit Criteria بمقابلہ Vague Instructions

Bad (vague):

Code comments کی accuracy چیک کریں

Conservative high-confidence findings report کریں - صرف

Good (explicit criteria):

Comment کو problematic میں اُس صورت میں flag کریں جب:

1. Comment کا actual code behavior سے CONTRADICT ہو
2. Comment کا حوالہ دہ variable یا function کسی غیر موجود
3. TODO/FIXME comment ایسے bug جو کسی category میں

Flag نہ کریں:

- کہ لحاظ سے پرانہ style جو صرف comments ایسے
- wording inaccuracies معمولی
- Missing comments (category یہ الگ)

Severity criteria examples کے ساتھ define کریں:

CRITICAL: User کہ لیے runtime failure
Example: Payment process وقت NullPointerException

HIGH: Security vulnerability
Example: SQL injection, XSS, missing authorization checks

MEDIUM: Logic bug کہ بغیر فوری impact کہ
Example: Wrong sorting, off-by-one error

LOW: Code quality
Example: Duplication, کہ لیے data چھوٹہ suboptimal algorithm

6.3 Prompt Chaining

Prompt chaining میں توڑنا sequence کی focused steps کو ایک complex task

Step 1: auth.ts analyze کریں (صرف local issues)
-> Output: auth.ts میں issues کی list

Step 2: database.ts analyze کریں (صرف local issues)
-> Output: database.ts میں issues کی list

Step 3: Integration pass (cross-file dependencies)
-> Output: module boundaries پر issues

یہ کیوں اہم:

- **Attention dilution** — جب files دیکھتا تو کچھ files ایک ساتھ ہوت سی model سد بچاتا — جب shallow commentary کر سکتا اور باقی پر
- یقینی بناتا کہ consistent analysis quality کہ لیے file
- Cross-file interactions الگ analysis کہ لیے الگ

Prompt chaining کب استعمال کریں dynamic decomposition بمقابلہ:

- **Prompt chaining** — predictable, repeatable tasks (code review, file migrations)
- **Dynamic decomposition** — open-ended investigations ان subtasks execution وتہ واضح کہ دوران واضح کہ

6.4 “Interview” Pattern

Solution implement Claude clarifying questions پوچھتا کہ سد پلا:

Claude: "API کہ لیے caching implement چند سوالات
1. پسند کرتہ ہیں؟ cache invalidation strategy میں سد کون سی event-based یا TTL آپ
2. قابل قبول ہ؟ stale data ہو تو کیا cache unavailable اگر
3. Caching per-user یا global؟ مونی چاہیہ
4. Cache کہ لیے expected data volume کہ کرنے

یہ کب مفید:

- Unfamiliar domain (fintech, healthcare, legal systems)
- Implications and tasks (cache strategies, failure modes)
- Viable approaches context جہاں بہترین انتخاب پر منحصر ہے

6.5 Validation اور Retry-with-Feedback

جب extracted data validation fail کرے:

```
Step 1: Document سے data extract کریں
Step 2: Validate کریں (Pydantic, JSON Schema, business rules)
Step 3: retry کریں کہ ساتھ context ہو error اگر:
- Original document
- Previous (incorrect) extraction
- Specific error: "Field 'total' = 150, but sum(line_items) = 145. Re-check values."
```

Retry مؤثر ہوگا:

- Format errors (date غلط format میں)
- Structural errors (field جگہ غلط)
- Arithmetic inconsistencies (model دوبارہ check کر سکتا ہے)

Retry گا مدد نہیں کرے:

- Information source document ہی نہیں
- Required context external (data کسی اور document میں کیا گیا)

Pydantic validation tool: Pydantic Python library جو schema-based data validation کے لیے استعمال ہوتی ہے امتحان کے لیے اہم نکات یہ ہیں:

- **Structural validation:** types, requiredness, enum constraints JSON کے بعد code میں جانچا جاتا ہے
- **Semantic validation:** custom validators business logic enforce کرتے ہیں (sum of items equals total! start_date < end_date)
- **Validate-retry loops:** Pydantic validation failure پر error message بنا کر Claude کو error context میں prompt ساتھ دوبارہ کریں
- **JSON Schema generation:** Pydantic models سے JSON Schema generate کر سکتے ہیں `tool_use` فراہم کرتا ہے single source of truth میں، جو ایک

6.6 Self-correction

Internal contradictions detect کرنے کا pattern:


```
{
  "stated_total": "$150.00",
  "calculated_total": "$145.00",
  "conflict_detected": true,
  "line_items": [
    {"name": "Widget A", "price": 75.00},
    {"name": "Widget B", "price": 70.00}
  ]
}
```

آپ `conflict_detected` دونوں نکالتا ہے — اگر وہ مختلف ہوں تو Model stated value اور computed value کو discrepancy handle کرنے دیتا ہے

7 Message Batches API: باب 7

دستاویزات: [Message Batches](#)

7.1 Overview

کرنے دیتا ہے batches submit کے requests کے لیے asynchronous processing کو Message Batches API

Attribute	Value
Savings	50% کے مقابلے میں 50 synchronous calls
Processing window	24 hours (latency SLA guarantee) زیادہ سے زیادہ
Multi-turn tool calling	Supported نہیں (request = response ایک)
Correlation	request اور response کے لیے <code>custom_id</code> field کو جوڑنے کے لیے

7.2 Batch API کے مقابلے Synchronous API میں استعمال کریں

Task	API	Why
Pre-merge PR check	Synchronous	Developer 24 hours انتظار کر رہا ہے؛ قابل قبول نہیں
Overnight tech-debt report	Batch	savings % صبح تک چاہیے؛ Result 50
Weekly security audit	Batch	savings % فوری نہیں؛ 50
Interactive code review	Synchronous	درکار کے response فوری
10,000 documents process کرنا	Batch	Bulk processing؛ savings میں

7.3 custom_id کا استعمال

```
{
  "custom_id": "doc-invoice-2024-001",
  "params": {
    "model": "claude-sonnet-4-6",
    "max_tokens": 1024,
    "messages": [{"role": "user", "content": "Extract data from: ..."}]
  }
}
```

custom_id آپ کو یہ کرنے دیتا ہے:

- Result کو original document link سے
- Failure submit دوبارہ کی صورت میں صرف
- Successful documents process کو دوبارہ

7.4 Batch کو Failures میں Handle کرنا

1. 100 documents کا batch submit کریں
2. 95 succeed 5 fail (context limit exceeded) ہوں
3. Failures کو custom_id سے identify کریں
4. Strategy (میں تقسیم کریں chunks کو long documents مثلاً) بدلیں
5. 5 failed documents submit کو دوبارہ صرف اُن

7.5 SLA Planning

تک لگ سکتے ہیں 24 hours کو Batch API چاہے اور result میں hours اگر آپ کو 30

- Submission window: 30 - 24 = 6 hours
- Batches کو deadline 24 hours سے کم از کم
- Frequent submissions 4 hour windows میں تقسیم کریں

8: Task Decomposition Strategies

8.1 Fixed Pipelines (Prompt Chaining)

ہوتا ہے defined step سے:

Document -> Metadata extraction -> Data extraction -> Validation -> Enrichment -> Final output

کب استعمال کریں:

- Task structure predictable (reviews ایک template follow کریں)
- پلاٹ سڈ معلوم ہوں steps تمام
- چا پیڈ reproducibility اور stability آپ کو

8.2 Dynamic Adaptive Decomposition

Subtasks intermediate results پر بنیاد کی generate ہیں:

1. "Legacy codebase کے لیے tests add کریں"
2. -> Glob, Grep کریں structure map پہلے
3. -> 3 modules بغیر tests، partial coverage کے ساتھ
4. -> Prioritize: payments module شروع کریں (high risk)
5. -> دریافت ہوئی dependency پر external API: کام کے دوران
6. -> Adapt: tests پہلے mock add کریں کہ external API لکھنے سے پہلے

کب استعمال کریں:

- Open-ended investigative tasks
- شروع میں معلوم نہ ہو scope جب مکمل
- پر منحصر ہو results کے step پچھلے step جب ر

8.3 Multi-pass Code Review

10+ files والی pull requests کے لیے:

```
Pass 1 (per-file): auth.ts analyze کریں -> local issues کی list
Pass 1 (per-file): database.ts analyze کریں -> local issues کی list
Pass 1 (per-file): routes.ts analyze کریں -> local issues کی list
...
Pass 2 (integration): files درمیان کے relationships analyze کریں
-> Cross-file issues: inconsistent types, circular dependencies
```

14 files کے لیے pass پر ایک کی خراب:

- Attention dilution: shallow کچھ کی، deep analysis کی files کچھ
- Inconsistent comments: approve دوسری میں، pattern flag میں ایک file
- Missed bugs: cognitive overload واضح سڈ errors کی وجہ سے

9 Escalation اور Human-in-the-Loop: باب 9

9.1 Escalate کی طرف Human کب

Escalation triggers (rules واضح):

Situation	Action
-----------	--------

Customer "get me a manager" واضح طور پر کہتا ہے	کریں؛ حل کرنے کی کوشش نہ کریں escalate فوراً
Policy request کو cover نہ کرتی ہو	Escalate policy جب competitor price matching مثلاً کریں (ہو)
Agent پیش رفت نہ کر سکا	کریں escalate کے بعد attempts مناسب تعداد میں
Threshold financial operation سے اوپر	Escalate کے ذریعے prompt enforce، کے ذریعے hook ترجیحاً کریں (نہیں)
Customer multiple matches تلاش کرتے وقت	مانگیں؛ انداز نہ لگائیں identifiers مزید

نہیں ہیں reliable trigger جو:

Unreliable method	Why it fails
Sentiment analysis	نہیں کرتا correlate سے Customer کا mood case complexity
Model self-rated confidence (1–10)	کمزور calibration غلط ہو سکتا ہے؛ Model confidently
Automatic classifier	موجود نہ ہو training data؛ ممکن Overengineering

9.2 Escalation Patterns

Immediate escalation:

Customer: "I want to speak to a manager"
 Agent: [کرتا escalate_to_human call فوراً]
 NOT: "I can help with your issue, let me..."

Resolve escalation: کی کوشش کے بعد

Customer: "My refrigerator broke two days after purchase"
 Agent: [کرتا warranty replacement offer، چیک کرتا]
 escalate -> مطمئن نہ ہو customer اگر

Nuanced escalation (acknowledge → resolve → reiteration پر escalate):

Customer: "This is outrageous, I'm very unhappy with the quality!"
 Agent: [frustration acknowledge] "سمجھتا ہوں frustration میں آپ کی"
 [resolution offer] "پیش کر سکتا ہوں refund یا replacement میں"
 Customer: "No, I want to talk to someone!"
 Agent: [customer insist دوبارہ -> immediate escalation]

کریں escalate دیں، اور صرف اسی وقت concrete solution کریں، پھر emotion acknowledge بنیادی اصول: پہلا
 manager (نہیں) کریں escalate کے پہلا اظہار پر dissatisfaction کی خواہش دہرائیں customer human جب
 (مانگندہ کے برابر نہیں ہیں)

Policy gap کے لیے escalation:

Customer: "Competitor X has this item 30% cheaper—give me a discount"
Policy: کرتی ہے price adjustments cover پر site صرف اپنی
Agent: [escalate – policy competitor price matching کو cover نہیں کرتی]

9.3 Structured Handoff Protocols

Escalation کو دینی چاہیے structured summary human agent پر:

```
{
  "customer_id": "CUST-12345",
  "customer_name": "Ivan Petrov",
  "issue_summary": "Refund request for a damaged item",
  "order_id": "ORD-67890",
  "root_cause": "Item arrived damaged; photos attached",
  "actions_taken": [
    "Verified customer via get_customer",
    "Confirmed order via lookup_order",
    "Offered a standard replacement – customer insists on a refund"
  ],
  "refund_amount": "$89.99",
  "recommended_action": "Approve a full refund",
  "escalation_reason": "Customer requested to speak with a manager"
}
```

دیکھتا ہے summary تک رسائی نہیں ہوتی — صرف یہ full conversation transcript کو Human operator کو دینی چاہیے self-contained اس لیے یہ مکمل اور

9.4 Confidence Calibration اور Human Oversight

Data extraction systems کے لیے:

1. **Field-level confidence scores:** model کے لیے extracted field کا confidence score نکالتا ہے
2. **Calibration:** labeled validation sets کے thresholds tune کریں استعمال کر کے
3. **Routing:**
 - High confidence + stable accuracy -> automated processing
 - Low confidence یا ambiguous sources -> human review

Stratified random sampling:

- High-confidence extractions کا sample audit بھی باقاعدگی سے کریں
- Aggregate 97% accuracy کا document type 40% errors کا چھپا سکتی ہے
- Accuracy کا analyze کے حساب سے field اور document type، میں overall کو صرف

10 Error Handling میں Multi-agent Systems: باب 10

10.1 Error Categories

Category	Examples	Retryable	Agent action
Transient	Timeout, 503, network failure	Yes	retry کے ساتھ Exponential backoff
Validation	Invalid input format, missing required field	No (input fix کریں)	Request modify اور retry کریں
Business	Policy violation, threshold exceeded	No	پیش alternative کو سمجھائیں؛ User کریں
Permission	Access denied	No	Escalate کریں

10.2 Error-handling Anti-patterns

Anti-pattern	Problem	Correct approach
Generic status “search unavailable”	Coordinator decide نہیں کر سکتا کہ کیسے recover کرنا ہے	Error type, query, partial results, alternatives واپس کریں
Silent suppression (empty result = success)	Coordinator match سمجھتا ہے کہ کوئی failure ملا، حالانکہ	“no results” اور “search failure” میں فرق کریں
Workflow پر پورا failure ایک کرنا abort	ضائع ہو جاتا ہے partial results تمام	Partial results کے ساتھ جاری رکھیں؛ gaps annotate کریں
Subagent میں infinite retries	Latency اور resources کا ضیاع	Local recovery (1–2 retries)، پھر coordinator تک propagate

10.3 Structured Subagent Error

```
{
  "status": "partial_failure",
  "failure_type": "timeout",
  "attempted_query": "AI impact on music industry 2024",
  "partial_results": [
    {"title": "AI Music Generation Report", "url": "...", "relevance": 0.8}
  ],
  "alternative_approaches": [
    "Try a narrower query: 'AI music composition tools'",
    "Use an alternative data source"
  ],
  "coverage_impact": "Not covered: AI impact on music production"
}
```

کو فیصلہ کرنا کہ آیا ضروری معلومات دیتا ہے coordinator

- Modified query ساتھ retry کریں؟
- Partial results استعمال کریں؟
- subagent کو delegate کسی اور کریں؟
- gap annotate کریں؟ بغیر جاری رکھیں اور section اس

10.4 Final Synthesis میں Coverage Annotations

Report: AI Impact on Creative Industries

Visual Art (FULL COVERAGE)

[research results]

Music (PARTIAL COVERAGE – search agent timeout)

[partial results]

⚠️ Note: coverage search agent timeout سے محدود ہے اس کی section

Literature (FULL COVERAGE)

[research results]

Context میں Production Systems: باب 11

Management

کریں Extract میں Separate Block کو Facts 11.1

Conversations history کو (جو summarize کے دوران summarize ہو جاتی ہے) key facts کو extract میں structured block میں:

```
=== CASE FACTS (کیا جائے update آئے fact جب بھی نیا) ===
Customer ID: CUST-12345
Order ID: ORD-67890
Order Date: 2025-01-15
Order Amount: $89.99
Issue: Damaged item on delivery
Customer Request: Full refund
Status: Pending manager approval
===
```

کیوں نہ ہو summarize کتنی ہی history میں شامل کریں، چاہے prompt میں block نہ ہو

کریں Trimming کو Tool Results 11.2

اگر `lookup_order` 40+ fields مگر current task میں 5 درکار ہیں واپس کرتا ہے

```
# PostToolUse hook: صرف relevant fields رکھیں
@hook("PostToolUse", tool="lookup_order")
def trim_order_fields(result):
    return {
        "order_id": result["order_id"],
        "status": result["status"],
        "total": result["total"],
        "items": result["items"],
        "return_eligible": result["return_eligible"]
    }
```

کم ہوتی ہے noise بچتا ہے اور context اس سے

Position-aware Input 11.3

Lost-in-the-middle effect کو critical information کو ذہن میں رکھتے ہوئے

[KEY FINDINGS – اوپر]

3 critical vulnerabilities ملیں...

[DETAILED RESULTS – درمیان]

=== File auth.ts ===

...

=== File database.ts ===

...

[ACTION ITEMS – آخر میں]

Priority: merge auth.ts vulnerabilities fix کریں.

11.4 Scratchpad Files

Long investigations میں agent key findings scratchpad file میں لکھ سکتا ہے:

```
# investigation-scratchpad.md
## Key findings
- PaymentProcessor in src/payments/processor.ts inherits from BaseProcessor
- refund() تین places میں call ہوئی ہے: OrderController, AdminPanel, CronJob
- External PaymentGateway API limit: 100 req/min
- Migration #47 میں refund_reason (NOT NULL) add کیا گیا 01-12-2024
```

scratchpad دوبارہ چلانے کے بجائے agent discovery (میں session یا نئی) کو جائے context degrade جب consult کر سکتا ہے

11.5 Context Subagents کو Delegate کرنا

```
Main agent: "payments module کی dependencies investigate کریں"
-> Subagent (Explore): 15 files read کرتا ہے، imports trace کرتا ہے
-> Returns: "Payments depends on AuthService, OrderModel, and the external PaymentGateway API"
```

Main agent: context 15 میں files ایک بجائے line کہ رکھتا ہے

Separate context layer: Multi-agent systems میں subagent context budget — میں کام کرتا ہے — separate context layer ایک Coordinator ملتی ہے information کے لیے ضروری task اسے صرف اپنے کے طور پر۔ context allocate کرتا ہے، اور global state store، کرتا ہے subagent outputs aggregate، کرتا ہے "context leakage" اس سے بھر دیتا ہے جو information کو ایسی agent window نہیں ہوتا، جہاں ایک "context leakage" اس سے دوسروں کے لیے غیر متعلق ہو۔

Subagents کے constrained context budgets:

- Minimal context: specific task + ضروری data
- Subagent کو raw data dumps کے بجائے structured results کی ہدایت دینے کے لیے
- اور کم distractions کا مطلب کم tools کریں — کم limit کو toolset کے subagent سے allowedTools context cost

11.6 Structured State Persistence (crash recovery لی کی)

کرتا ہے export پر location ایک معلوم state اپنی agent ر:

```
// agent-state/web-search-agent.json
{
  "status": "completed",
  "queries_executed": ["AI music 2024", "AI music composition"],
  "results_count": 12,
  "key_findings": [...],
  "coverage": ["music composition", "music production"],
  "gaps": ["music distribution", "music licensing"]
}
```

کرتا ہے manifest load پر ایک Coordinator resume

```
// agent-state/manifest.json
{
  "web-search": "completed",
  "doc-analysis": "in_progress",
  "synthesis": "not_started"
}
```

12 کو محفوظ رکھنا Provenance: باب 12

12.1 Attribution Loss Problem

گم ہو سکتا ہے link "claim → source" کی جاتی ہیں، تو results summarize سے sources جب متعدد

Bad: "The AI music market is estimated at \$3.2B." (No source, no year.)

Good:

```
{
  "claim": "The AI music market is estimated at $3.2B.",
  "source_url": "https://example.com/report",
  "source_name": "Global AI Music Report 2024",
  "publication_date": "2024-06-15",
  "confidence": 0.9
}
```

12.2 Conflicting Data کو Handle کرنا

دیں values مختلف sources جب دو

```
{
  "claim": "Share of AI-generated music on streaming platforms",
  "values": [
    {
      "value": "12%",
      "source": "Spotify Annual Report 2024",
      "date": "2024-03",
      "methodology": "Automated classification"
    },
    {
      "value": "8%",
      "source": "Music Industry Association Survey",
      "date": "2024-07",
      "methodology": "Survey of 500 labels"
    }
  ],
  "conflict_detected": true,
  "possible_explanation": "Methodology اور time period فرق کا"
}
```

کو coordinator کے ساتھ محفوظ رکھیں اور attribution کو اندھا دھند منتخب نہ کریں۔ دونوں کو value کسی ایک فیصلہ کرنے دیں۔

12.3 Correct Interpretation کے لیے Dates شامل کریں

سمجھ لیا جا سکتا ہے contradiction کو temporal differences کے بغیر Dates:

Bad: "Source A says 10%, source B says 15%. Contradiction."

Good: "Source A (2023) says 10%, source B (2024) says 15%. Likely 5+ سال میں 1% growth."

12.4 Content Type کے مطابق Render کریں

میں نہ ٹھونسیں format کے چیز کو ایک کی:

- Financial data -> tables
- News اور analysis -> prose
- Technical findings -> structured lists
- Time series -> chronological ordering

باب 13: Claude Code کے Built-in Tools

13.1 Tool Selection Reference

Task	Tool	Example
تلاش کرنا files کے نام/pattern	Glob	<code>**/*.test.tsx</code> , <code>src/components/**/*.ts</code>
File contents کے اندر search کرنا	Grep	Function name, error message, import
File مکمل پڑھنا	Read	Analysis کے لیے file load کرنا
بنانا file نیا	Write	Scratch کے file create کرنا
precise edit میں file موجود	Edit	Unique text match کے ذریعے specific snippet replace کرنا
Shell command چلانا	Bash	git, npm, tests, build

13.2 Incremental Investigation Strategy

نہ: پڑھیں کے سمجھ بوجھ کو رفتہ رفتہ بنائیں files ایک ساتھ تمام

1. Grep: entry points تلاش کریں (function definition, export)
2. Read: پڑھیں files ملنے والی
3. Grep: usages تلاش کریں (import, calls)
4. Read: consumer files پڑھیں
5. کریں repeat نہ مل جائے picture جب تک مکمل

13.3 Fallback: Edit کے بجائے Read + Write

و: و جائے fail کی وجہ سے Edit non-unique text match جب

1. Read — لوڈ کریں file content مکمل
2. Content کو programmatically modify کریں
3. Write — لکھ دیں updated version

امتحانی ڈومین نوٹس: II حصہ

Orchestration اور Agent Architecture: ڈومین 1 (27%)

1.1 Autonomous Task Execution اور Agentic Loops Design کرنا

Key knowledge:

- Agent loop lifecycle: Claude request بھیجیں، `stop_reason` ("tool_use" بمقابلہ "end_turn") چیک واپس کریں results کے لیے iteration کریں، اگلی tools execute کریں
- Tool results conversation history میں append تاکہ آپس میں model اگلا action کر سکے
- Model-driven decision making (Claude tool اگلا چنتا) بمقابلہ hard-coded decision trees

Key skills:

- Flow control: جب `stop_reason = "tool_use"` تو loop جاری رکھیں اور `"end_turn"` پر رک جائیں
- Iterations کرنا append میں context کو tool results کے درمیان
- Anti-patterns سے بچنا: completion کے لیے assistant text parse کرنا، primary stopping mechanism کے استعمال کرنا arbitrary iteration limits پر

1.2 Multi-agent Systems (Coordinator–Subagent) Orchestrate کرنا

Key knowledge:

- Hub-and-spoke architecture: coordinator تمام inter-agent communication، error handling، اور routing کا مالک ہوتا ہے
- Subagents isolated context میں کام کرتے ہیں — وہ خود بخود coordinator کی history inherit نہیں کرتے
- Coordinator responsibilities: task decomposition، delegation، result aggregation، dynamic selection of subagents
- Coordinator کی overly narrow decomposition کا خطرہ

Key skills:

- Research coverage کم ہو duplication کے درمیان تقسیم کریں تاکہ subagents کو
- Iterative refinement loops implement کریں (coordinator synthesis evaluate اور tasks re-route کریں)
- Observability کے ذریعے route کے coordinator communication کے لیے تمام

1.3 Subagent Calls, Context Passing, اور Spawning Configure کرنا

Key knowledge:

- `Task` tool subagents spawn؛ `allowedTools` میں `"Task"` شامل ہونا چاہیے؛ `coordinator` کو `Task` tool subagents spawn؛
- Subagent context prompt میں `explicitly`؛ `Subagent context prompt` میں `explicitly`؛
- `AgentDefinition` configuration: descriptions, system prompts, tool constraints
- Alternatives explore `fork_session` `session management` کے ذریعے

Key skills:

- Previous agents کے full outputs subagent prompt میں شامل کریں
- Context pass کے وقت `structured formats` کے لیے `separate` `data` اور `metadata` کو
- `Task` calls کے ذریعے `parallel subagents` spawn کریں
- Coordinator prompts goals اور quality criteria کے طور پر لکھیں

1.4 Enforcement اور Handoff Patterns ساتھ Multi-step Workflows Implement کرنا

Key knowledge:

- Workflow ordering کے لیے `programmatic enforcement` (hooks, preconditions) اور `prompt guidance`
- `deterministic guarantees` کے لیے `identity verification` (مثلاً مالی operations کے لیے `identity verification`)، prompts
- `Escalation` کے لیے `structured handoff protocols` (customer ID, reason, recommended action)

Key skills:

- `programmatic preconditions` کے لیے `downstream calls` کو `block` کرنا
- `Multi-aspect customer requests` کے لیے `items` کو الگ
- `Human` کو `escalate` کے وقت `structured summaries` produce کریں

1.5 Tool Calls Intercept اور Data Normalize کرنے کے لیے Agent SDK Hooks

Key knowledge:

- Hook patterns (مثلاً `PostToolUse`) tool results کو model کے `consume` کے لیے
- Hooks outgoing calls intercept کے لیے `compliance rules` enforce کریں
- Hooks `deterministic guarantees` کے لیے `probabilistic compliance` کے لیے

Key skills:

- `PostToolUse` hooks سے data formats normalize کریں (Unix timestamps, ISO 8601, numeric status codes)
- Policy-violating actions block کرنے کے لیے interception hooks اور escalation استعمال کریں اور redirect کریں
- منتخب کریں hooks کے بجائے prompts چاہیے۔ تو تو guaranteed compliance کو business rules جب

1.6 Complex Workflows کے لیے Task Decomposition Strategies

Key knowledge:

- **Fixed pipelines** (prompt chaining) کے مقابلے میں **dynamic adaptive decomposition** کی بنیاد پر intermediate results
- Prompt chaining: sequential steps (پھر integration pass، analyze کو الگ الگ file)
- Adaptive investigation plans جو discovered information کی بنیاد پر subtasks generate کرتے ہیں

Key skills:

- Predictable multi-aspect reviews کے لیے prompt chaining؛ open-ended investigations کے لیے dynamic decomposition
- Large code reviews کو per-file analysis + separate cross-file integration pass میں تقسیم کریں
- Open-ended tasks کو degrade ہونے سے پہلے prioritized plan کریں، پھر structure map کریں: پھر

1.7 Session State, Resuming, اور Forking

Key knowledge:

- Named sessions continue کرنے کے لیے `--resume <session-name>`
- Shared context سے independent investigation branches بنانے کے لیے `fork_session`
- Resume کی اہمیت file changes کو agent کرتے وقت
- Structured summary کے ساتھ session، stale results کے ساتھ resuming زیادہ reliable سے زیادہ

Key skills:

- Named investigation sessions continue کرنے کے لیے `--resume` استعمال کریں
- Approaches parallel compare کرنے کے لیے `fork_session` استعمال کریں
- Resuming (context ابھی current ہے) اور نئی session شروع کرنے (results stale ہیں) درمیان انتخاب کریں

5.10 fork_session اور Session Management

`--resume <session-name>` named session کو resume کرتا ہے:

```
claude --resume investigation-auth-bug
```

- جاری رکھتا conversation کو ساتھ بچھلی saved context
- Long investigations sessions جو متعدد پر پھیلی ہوں ان کو لیں مفید
- Risk: tool results stale بدل چکی ہوں تو files کو بعد session اگر بچھلی

fork_session shared context سے independent branch بنانا:

```
Codebase investigation
|
fork_session
/      \
Approach A:  Approach B:
Redux       Context API
```

- کرتے ہیں context inherit تک forks branch point دونوں
- کرتے ہیں diverge اس کے بعد وہ آزادانہ طور پر
- کرنے کے لیے مفید strategies test کرنے یا Approaches compare

Resume نئی session کو بجائے نئی:

- Tool results stale ہوں (files بدل چکی ہوں)
- ہو گیا context degrade کافی وقت گزر چکا ہو اور
- کرنے کے بجائے یہ بہتر ہے کہ "م نہ جو پایا اس کا مختصر خلاصہ یہ ہے" resume کے ساتھ tool data پرانے کیا جائے restart "... سے"

2 Tool Design اور MCP Integration (18%)

2.1 Clear Descriptions کے ساتھ Tool Interfaces Design کرنا

Key knowledge:

- Tool descriptions minimal descriptions کرنا؛ LLM tools select میں جن سے mechanism و بنیادی unreliable selection دیتی
- Input formats, example queries, edge cases, اور applicability boundaries کی اہمیت
- Ambiguous یا overlapping descriptions misrouting کا سبب بنتی ہیں
- System prompt wording tools کے associations کے ساتھ غیر ارادی بنا سکتی ہیں

Key skills:

- کریں distinguish سے واضح طور پر similar alternatives کو tool لکھیں جو descriptions ایسی
- Functional overlap کے لیے (مثلاً `analyze_content` -> `extract_web_results`) کریں tools rename ختم کرنے کے لیے
- واضح ہوں input/output contracts میں تقسیم کریں جن کے specialized tools کو general-purpose tools

2.2 MCP Tools کے لیے Structured Error Responses Implement کرنا

Key knowledge:

- MCP tool responses میں `isError` flag
- Transient errors** (timeouts), **validation errors** (bad input), **business errors** (policy violations), اور **access/permission errors** کے درمیان فرق
- Generic errors ("Operation failed") میں recovery decisions روک دینے کے لیے
- Retryable اور non-retryable errors میں فرق

Key skills:

- `errorCategory` (transient/validation/permission), `isRetryable` جیسی human-readable message اور `retryable: false` کے ساتھ user-facing explanations کے لیے واضح structured metadata واپس کریں
- Business-rule violations کے لیے واضح `retryable: false` استعمال کریں
- Transient failures کے لیے subagents میں local recovery کے لیے errors propagate کریں؛ صرف وہی حل کر سکیں
- Access failures (retry decision) اور valid empty results (no matches) میں فرق کریں

2.3 Agents میں Tools Allocation اور `tool_choice` Configure کرنا

Key knowledge:

- کم کرتی tool selection reliability (مثلاً 18 کے بجائے 4-5) tools کے زیادہ
- Specialization کے لیے agents رکھنے والے tools سے باہر
- Scoped tool access: role-relevant tools + cross-role utilities محدود
- `tool_choice: "auto"`, `"any"` اور forced tool selection (`{"type": "tool", "name": "..."}`)

Key skills:

- تک محدود رکھیں relevant tools صرف subagent کا toolset
- General tools کو constrained alternatives کے لیے بدلیں (مثلاً `fetch_url` -> `load_document`)
- `tool_choice: "any"` کے بجائے text answer کے لیے استعمال کریں تاکہ
- Specific tool force کے لیے execution order assured کریں تاکہ

2.4 MCP Servers اور Claude Code میں Agent Workflows کو Integrate کرنا

Key knowledge:

- MCP server scope: user کے لیے experiments کے مقابلے میں project (`.mcp.json`) کے لیے (`~/claude.json`)
- Secrets management کے لیے `.mcp.json` میں environment variable substitution (مثلاً `${GITHUB_TOKEN}`)

- available ہوتے ہیں اور ایک ساتھ discover پر tools connection کے connected MCP servers کے
- MCP resources بطور "content catalogs" (task summaries, database schemas) exploratory tool calls کم کرتے ہیں

Key skills:

- Shared MCP servers کو project میں `.mcp.json` env-var-based tokens ساتھ configure کے
- Personal/experimental servers کو `~/claude.json` میں رکھیں
- Standard integrations کے لیے community MCP servers کو custom servers پر ترجیح دیں

2.5 Built-in Tools (Read, Write, Edit, Bash, Grep, Glob) منتخب اور کرنا Apply

Key knowledge:

- **Grep**: file contents کے اندر search (function names, error messages, imports)
- **Glob**: name/extension patterns کے تلاش کرنا files کے
- **Read/Write**: full-file operations؛ **Edit**: unique text matches کے ذریعے precise changes
- **Read + Write** پر واپس جائیں تو fail کی وجہ سے کے Edit non-unique matches کے

Key skills:

- Content search کے لیے Grep اور pattern-based discovery کے لیے
- **Read** کے لیے flows trace پھر Grep کے لیے entry points: سمجھ بوجھ رفتہ رفتہ بنائیں
- Wrapper modules کے ذریعے function usage trace کریں

3 اور Claude Code Configuration: ڈومین Workflows (20%)

3.1 Hierarchy, Scope, اور Modular Organization کے ساتھ CLAUDE.md Configure کرنا

Key knowledge:

- CLAUDE.md hierarchy: user (`~/claude/CLAUDE.md`), project (`.claude/CLAUDE.md` یا root `CLAUDE.md`), اور directory-level (subdirectories میں CLAUDE.md)
- User-level settings کے لیے اور user صرف ایک VCS کے لیے پر لاگو ہوتے ہیں اور
- External files refer کے لیے syntax (مثلاً `@./standards/coding-style.md`) `@path` کے لیے CLAUDE.md modular بننا
- Monolithic CLAUDE.md کے بجائے topic-focused rule files کے لیے `.claude/rules/` directory

Key skills:

- user-level اس لیے میں ملتیں کیونکہ وہ instructions کو team member (نہ) کریں Hierarchy issues diagnose (میں نہ) میں تھیں، project-level
- (مثلاً) @path کرنے کے لیے standards selectively include میں CLAUDE.md کے package کو استعمال کریں (@./standards/testing.md)
- files (testing.md, api-conventions.md, deployment.md) .claude/rules/ کو متعدد CLAUDE.md بڑے میں تقسیم کریں

3.2 Custom Slash Commands اور Skills بنانا اور Configure کرنا

Key knowledge:

- `~/.claude/commands/` بمقابلہ (VCS کے ذریعے shared) **Project commands** میں `~/.claude/commands/`
- `~/.claude/skills/` میں SKILL.md frontmatter: `context: fork`, `allowed-tools`, `argument-hint`
- `context: fork` skill کو isolated subagent context میں چلاتا ہے تاکہ main session pollute نہ ہو
- Personal skill variants `~/.claude/skills/` میں رکھے جاسکتے ہیں

Key skills:

- Project slash commands `.claude/commands/` پوری team میں رکھیں تاکہ پوری
- Verbose output `context: fork` استعمال کریں `skills isolate` والے `کے لیے`
- Skill `allowed-tools` محدود کرنے کے لیے `tools` کے استعمال کردہ
- Required parameters `argument-hint` مانگنے کے لیے

3.3 Conditional Convention Loading لیکھیں Path-specific Rules استعمال کرنا

Key knowledge:

- `.claude/rules/` files میں YAML frontmatter `paths` تاکہ `glob patterns` شامل ہو سکتا ہے۔ `rules activate` ہوں
- `Path-scoped rules` `matching files edit` وقت `load` کریں، `tokens` اور `context`، `بچت` ہیں
- `Glob-based path rules` `directory-level CLAUDE.md` میں جب `conventions` سے `بتر` ہو سکتے ہیں جب `tests` (مثلاً) `apply` میں `directories`

Key skills:

- `paths: ["terraform/**/*"]` `.claude/rules/` files پر load matching files تاکہ صرف `files` کے ساتھ `paths` کے مطابق فائلوں کو تلاش کیا جاسکے۔
- Glob patterns (`**/*.test.tsx`) تاکہ `location` استعمال کریں تاکہ `file type` کے لحاظ سے `file type` کے مطابق فائلوں کو تلاش کیا جاسکے۔
- `path-specific` کے بجائے `directory-level CLAUDE.md` بھر میں پھیلی ہوئی `conventions codebase` جب کو ترجیح دیں

Key skills:

- Interactive input پر hang لے لے کر لیجئے کہ CI میں Claude Code کو -p کے ساتھ چلائیں
- Structured results (مثلاً inline PR comments) کے لیے --output-format json + --json-schema استعمال کریں
- new/unfixed issues (صرف) شامل کریں review results کرتے وقت پچھلے run کے بعد دوبارہ commits نہ (کریں report)
- Test generation quality کے لیے CLAUSE.md میں testing standards اور available fixtures document کریں
- style نہ ہو اور duplication میں شامل کریں تاکہ context کو existing test files کے وقت tests generate نہ کرے consistent رہے

4 Prompt Engineering اور Structured Output (20%)

4.1 Accuracy کے ساتھ Explicit Criteria، تر کرنے کے لیے Design کرنا

Key knowledge:

- Explicit criteria vague instructions میں زیادہ مؤثر ہوتے ہیں (مثلاً "flag comments only when they contradict code" بمقابلہ "check comment accuracy")
- "be more conservative" generic guidance concrete categorical criteria کے مؤثر ہیں
- False positives developer trust پر اثر انداز ہوتے ہیں: کچھ categories میں high false-positive rates درست کم کر دیتی ہیں trust پر بھی categories

Key skills:

- Review criteria define کرنا (bugs, security) اور ignore کرنا (minor style) report کرنا
- High false-positive rates والی categories طور پر disable عارضی طور پر
- explicit severity criteria define کے ساتھ code examples کے لیے level پر

4.2 Output Consistency کے ساتھ Few-shot Prompting، تر کرنے کے لیے استعمال کرنا

Key knowledge:

- Few-shot examples consistently formatted, actionable output کا سب سے مؤثر method پیدا کرنے کا
- Few-shot cases (tool selection, test coverage gaps) کو دکھا سکتا ہے
- Few-shot model کو نہ generalize پر patterns کو نہ defaults میں مدد دیتا ہے، صرف
- Few-shot extraction tasks میں hallucinations کو کم کر سکتا ہے

Key skills:

- Ambiguous scenarios □ لی □ rationale 4–2 ساتھ □ targeted examples دیں
- Output format (location, issue, severity, suggested fix) □ وال □ examples دکھانے شامل کریں
- میں فرق دکھائیں real issues اور acceptable code patterns دیں جو examples ایسے □
- دیں □ examples □ extraction سہ □ درست documents وال □ structures مختلف

4.3 Structured Output ☐ ساتھ JSON Schemas اور tool_use

Key knowledge:

- `tool_use` with JSON Schemas schema-conformant output اور ختم JSON syntax errors کی ضمانت دینا
 - طریقہ □□ reliable □□ کا سبب سد
- `tool_choice: "auto"` میں model text □□ واپس کر سکتا □□؛ `"any"` لازماً □□ tool call میں اسد □□ کرنی □□
 - forced selection specific tool □□ منتخب کرتی □□
- Strict JSON Schemas syntax errors مگر semantic errors ختم کرتی □□ میں مگر (totals؛ □□ ملنا؛ □□)
 - fields غلط values
- Schema design: required vs optional fields؛ enums □□ ساتھ □□ "other" + detail string extensibility □□ □□

Key skills:

- JSON Schemas کے ساتھ tool_use results کو data parse کرنے اور extraction tools کو define کرنے کے لیے
- tool_choice: "any" یقینی بنانے کے لیے structured output کو ووں تو schemas متعدد استعمال کریں
- Specific tool call force کریں: tool_choice: {"type": "tool", "name": "extract_metadata"}
- Source information میں fields کو values fabricate نہ کرنے کی صورت میں optional/nullable رکھیں
- Extensible categorization کے لیے "unclear" اور "other" enum values + detail fields استعمال کریں

4.4 Extraction Quality ☐ لی ☐ ک Validation, Retries, اور Feedback Loops Implement کرنا

Key knowledge:

- Retry-with-error-feedback: correction guide `retry_prompt` میں concrete validation errors کا لیے شامل کریں
- `retries` میں فائدہ `tool_use` ہے۔ `retries` میں موجود `information source` اگر
- Feedback loop design: finding `trigger` والا `pattern` (`detected_pattern`) کریں
- Semantic errors (totals reconcile `tool_use`) جو `address` (جو `tool_use`) بمقابلہ `reconcile` (نہیں `tool_use`)

Key skills:

- Original document, incorrect extraction, اور specific validation errors کے ساتھ follow-up prompts دیں
- تو اس کی شناخت کریں (میں) اور external document (صرف required info) کے فوائد کے ساتھ retry جب

- False positives analyze `detected_pattern` fields میں findings کرنے کے لیے
- Discrepancies detect `calculated_total` اور `stated_total` extract کرنے کے لیے self-correction design کریں

4.5 Efficient Batch Processing Strategies Design کرنا

Key knowledge:

- Message Batches API: 50% savings, 24-hour processing window, latency SLA guarantee
- Batch processing non-blocking tasks (overnight reports, audits) اور blocking tasks (pre-merge checks) کے لیے مناسب
- Batch API single request میں multi-turn tool calling support
- `custom_id` fields batch request/response correlate کرتی ہیں

Key skills:

- Blocking checks synchronous API اور overnight/weekly workloads کے لیے Batch API استعمال کریں
- SLA needs مطابق batch submission cadence plan کریں (24-hour guarantee مثلاً 30 processing 4-hour windows کے ساتھ)
- Failed documents (identified by `custom_id`) submit کر کے failures handle کریں
- Large-scale processing کے لیے sample prompts iterate کے ساتھ

4.6 Multi-instance اور Multi-pass Review Architectures Design کرنا

Key knowledge:

- Self-review limitations: model reasoning context کو فیصلوں اور اپنے challenge ساتھ رکھتا ہے اور امکان کم ہوتا ہے
- Independent review instances (generation context بغیر) subtle issues میں بہتر ہوتی ہیں
- Multi-pass review: per-file local analysis + cross-file integration pass attention dilution سے بچانا

Key skills:

- Changes review second independent Claude instance کے بغیر generation context کرنے کے لیے
- Multi-file reviews کو per-file passes + integration passes میں تقسیم کریں تاکہ cross-file dataflow analysis ہو سکے
- Self-rated confidence کے ساتھ verification passes کے reviews استعمال کر کے route طریقہ سے

5 Context Management اور Reliability (15%) ڈومین 5

5.1 Critical Information Conversation Context محفوظ رکھنا اور Manage کرنا

Key knowledge:

- Progressive summarization کے خطرات: numeric values, percentages, اور dates vague summaries میں بدل جاتے ہیں
- Lost-in-the-middle effect: models long inputs کے شروع اور آخر کو زیادہ reliable سے کم کر سکتے ہیں، لیکن درمیان کے findings miss ہیں
- Tool outputs relevance میں context کے مقابلہ میں disproportionately کم ہو سکتے ہیں (جب 5 fields 40+ جمع ہو سکتے ہیں)
- Subsequent API requests میں full conversation history کی اہمیت

Key skills:

- Transactional facts کو summarized history کے ساتھ persistent “case facts” block میں نکالیں
- Verbose tool outputs کو relevant fields تک trim کریں
- Key findings کو aggregated data کے شروع میں explicit section headings رکھیں
- Subagents کے structured outputs میں metadata (dates, sources) شامل کروائیں

5.2 Effective Escalation Patterns Design اور Ambiguity Resolve کرنا

Key knowledge:

- Suitable escalation triggers: human کی explicit request, policy gaps/exceptions, اور پانا
- Immediate escalation (explicit request) کے اندر attempt-to-resolve (agent scope) کے مقابلہ میں
- Sentiment analysis اور model confidence self-ratings case complexity کے unreliable proxies ہیں
- Multiple customer matches کے heuristic guessing کے بجائے additional identifiers چاہئیں

Key skills:

- System prompt میں explicit escalation criteria few-shot examples کے ساتھ دیں
- Human کی explicit request کو بغیر اضافی investigation کے فوراً execute کریں
- Escalate ہو تو silent یا ambiguous کے لیے specific request کسی policy جب
- Tool results میں multiple matches کے additional identifiers ہوں تو

5.3 Multi-agent Systems میں Error Propagation Strategies کرنے

Key knowledge:

- Structured error context (failure type, query, partial results, alternatives) coordinator کو smarter recovery دیتا ہے
- Access failures (timeouts retry decision میں) اور valid empty results (no matches) میں فرق کریں
- Generic error statuses (“search unavailable”) coordinator سے valuable context چھپا دیتا ہے
- Silent suppression یا failure پر پورا workflow abort کرنا anti-patterns میں

Key skills:

- Structured error context failure type, کیا گیا attempt, partial results, possible alternatives واپس کریں
- Access failures کو valid empty results الگ کریں
- Transient failures subagents کے لیے صرف local recovery میں non-recoverable errors partial results کے ساتھ propagate کریں
- Synthesis میں coverage annotate کیا اچھی طرح supported اور کے ان gaps میں

5.4 Large Codebases Investigate کرتے وقت Context Efficiently Manage کرنا

Key knowledge:

- Long sessions میں context degradation: model unstable answers اور مخصوص classes دینے لگتا ہے
- Scratchpad files key findings کو context boundaries میں پار محفوظ رکھتے ہیں
- Subagents کو delegate سے verbose discovery output isolate ہو جاتی ہے
- Structured state persistence crash recovery ممکن بناتی ہے

Key skills:

- Specific questions subagents spawn کے لیے high-level coordination main agent میں رکھیں
- Key findings scratchpad files کے لیے refer محفوظ رکھتے ہیں اور بعد میں
- Key findings summarize کے لیے subagents spawn کے phase اگلا ہے
- Long investigations دوران context usage کے لیے کم کرنے /compact استعمال کریں

5.5 Human Oversight اور Confidence Calibration کے ساتھ Workflows Design کرنا

Key knowledge:

- Aggregate metrics (97% overall accuracy) specific document types یا fields پر کمزوری چھپا سکتا ہے
- Stratified random sampling high-confidence extractions میں error rates measure کرنا

- Field-level confidence calibration labeled validation sets ذریعہ
- Automation سند document type اور field segment حساب سے accuracy validate کریں

Key skills:

- New error patterns detect کریں stratified random sampling implement کریں
- Stable performance validate کریں accuracy analyze کریں حساب شد اور document type کریں
- Field-level confidence scores output کریں review thresholds calibrate کریں ذریعہ labeled data اور
- Low-confidence یا ambiguous-source extractions human review کریں route کی طرف

5.6 Multi-source Synthesis میں Provenance Preserve کرنا اور Uncertainty Handle کرنا

Key knowledge:

- محفوظ نہ رہیں mappings “claim → source” کہو جاتی ہیں اگر attribution کا دوران Summarization
- برقرار رہتی چاہئیں structured mappings کا دوران Aggregation
- conflict annotate کا ساتھ attribution منتخب کرنے کا بجائے value ایک arbitrarily کو conflicting statistics کریں handle کا
- publication/collection dates سمجھنے سے بچنے کا لیے contradiction کو Temporal differences شامل کریں

Key skills:

- Subagents کے “claim → source” mappings (URL، document name، quotes) output کرائیں
- Reports کو stable findings اور disputed ones میں الگ کریں
- Conflicting values کے annotations اور ساتھ محفوظ رکھیں
- Correct temporal interpretation کے لیے reconciliation کے ساتھ
- Correct temporal interpretation کے لیے publication dates شامل کریں
- Content type کے مطابق news prose، technical findings، financial data tables، structured lists میں render کریں

Claude Certified Architect — Foundations Certification

مطالعہ □ گائیڈ (سرکاری امتحانی گائیڈ کی بنیاد پر)

تعارف

Claude Certified Architect — Foundations

Claude- based سرٹیفیکیشن اس بات کی تصدیق کرتی ہے کہ ایک ماہر Claude Code، Claude Agent SDK، Claude API، اور Model Context Protocol (MCP) کے بنیادی ٹیکنالوجیز جن کو جانچنا ہے — امتحان کر سکتا ہے۔ یہ trade-off حل بنانا، وقت درست کرنا، یعنی وہ بنیادی ٹیکنالوجیز جن کو جانچنا ہے — امتحان کر سکتا ہے۔ یہ trade-off حل بنانا، وقت درست کرنا،

بنانا agentic systems امتحان کے سوالات حقیقی دنیا کے منظر ناموں پر مبنی ہوتے ہیں: کسٹمر سپورٹ کے لیے، multi-agent research pipelines، Claude Code کو CI/CD شامل کرنا، developer productivity، structured data بنانا، اور غیر ساختہ دستاویزات سے tools نکالنا

هدف امیدوار

کرتا آپ ship کے ساتھ پروڈکشن ایپلیکیشنز ڈیزائن اور Claude کے جو solution architect مثالی امیدوار ایک کے پاس کم از کم 6 ماہ کا عملی تجربہ ہونا چاہیے:

- Claude Agent SDK** — multi-agent orchestration، subagents کو delegate کرنا، tool integration، lifecycle hooks
- Claude Code** — CLAUDE.md، MCP servers، Agent Skills، planning mode
- Model Context Protocol (MCP)** — backend integration کے لیے tools اور resources
- Prompt engineering** — JSON schemas، few-shot examples، data extraction templates
- Context windows** — لمبی دستاویزات، multi-agent context passing
- CI/CD pipelines** — automated code review، test generation
- Escalation and reliability** — error handling، human-in-the-loop

امتحانی فارمیٹ

پیرامیٹر	قدر
سوال کی قسم	Multiple choice (میں سے 1 درست 4)
اسکورنگ	100–1000 scale، passing score 720
Guessing penalty	نہیں (سوال کا جواب دیں!)
Scenarios	8 4 (randomly selected) میں سے

امتحانی مواد: 5 ڈومینز

ڈومین	وزن
1. Agent architecture and orchestration	27%
2. Tool design and MCP integration	18%
3. Claude Code configuration and workflows	20%
4. Prompt engineering and structured output	20%
5. Context management and reliability	15%

امتحانى منظر نامہ

Scenario 1: Customer Support Agent

returns, billing disputes, اور account issues کے ساتھ Claude Agent SDK کے ساتھ agent MCP tools (get_customer, lookup_order, process_refund, escalate_to_human) کے ساتھ 80% first-contact resolution مناسب، escalation کے ساتھ۔

Scenario 2: Claude Code ساتھ Code Generation

code generation, refactoring, debugging, documentation اور custom slash commands کے ساتھ CLAUDE.md configuration آپ کو development میں استعمال کرتے ہوئے Claude Code آپ کے workflow میں integrate کرنے کے لیے استعمال کو سمجھنا اور planning mode کرنا، اور

Scenario 3: Multi-Agent Research System

□□ ساتھ مکمل رپورٹس تیار کرنی چاہئیں □ citations □ سسٹم کو report generation اور synthesis, tasks کو specialized subagents اور coordinator agent سونپنا □□

Scenario 4: Developer Productivity Tools

agent engineers کو unfamiliar codebases explore کرنے، boilerplate code اور routine tasks بنانے، استعمال MCP servers اور Built-in tools (Read, Write, Bash, Grep, Glob) میں مدد دینا اور automate کو تیز بنانے،

Scenario 5: Claude Code for Continuous Integration

Claude Code کو CI/CD pipeline میں ضم کریں تاکہ automated code reviews, test generation, pull request feedback اور false positives کم ہوں۔ Prompts حاصل ہوں۔

Scenario 6: Structured Data Extraction

کرتا ہے، validate کے ذریعے JSON schemas کو output، سسٹم غیر ساختہ، دستاویزات سے معلومات نکالتا ہے درست طور پر سنبھالنے جائیں، edge cases پر قرار رکھتا ہے اسے high accuracy اور

Scenario 7: Conversational AI Architecture Patterns

turns متعدد، context window management، ڈیزائن کرتے ہیں جن میں multi-turn conversational systems آپ اور مہم یا متضاد، tool design کو لے execution محفوظ، memory strategies، کا برقرار رکھنا instructions میں user inputs کو سنبھالنا شامل ہے

Scenario 8: Agentic AI Tools (ہماری مدد کریں —! مواد موجود نہیں)

میں شامل ہیں۔ یہ guide نہ دی ہے لیکن ابھی تک اس candidates کی اطلاع امتحان دینے والے scenario اس کریں share میں [GitHub Issues](#) کے سوالات دیکھیں، تو ان میں scenario اگر آپ نہ اصل امتحان میں اس شامل کر سکیں۔ آپ کا تعاون اس شخص کی مدد کرے گا جو امتحان کی تیاری کر coverage تاکہ ہم مکمل کر لیں۔

نظریاتی بنیادیں: حصہ 1

یہ حصہ و بنیادی نظریہ بیان کرتا ہے جس کی آپ کو امتحان میں کامیابی کے لیے ضرورت ہے۔ مواد کو topic کے مطابق — اس کے domains کے مطابق ترتیب دیا گیا ہے، نہ کہ امتحانی concepts اور technologies کی گہری سمجھ بھنی کے لیے۔

کی بنیادیں Claude API — Model Interaction: باب 1

دستاویزات: [Messages API](#) | [Prompt Engineering](#)

1.1 API Request Structure

Claude API میں عموماً یہ Claude Messages API request پر کام کرتا ہے request-response model ایک request-response model میں شامل ہوتا ہے:

```
{
  "model": "claude-sonnet-4-6",
  "max_tokens": 1024,
  "system": "You are a helpful assistant.",
  "messages": [
    { "role": "user", "content": "Hi!" },
    { "role": "assistant", "content": "Hello!" },
    { "role": "user", "content": "How are you?" }
  ],
  "tools": [...],
  "tool_choice": { "type": "auto" }
}
```

م فیلڈز:

- `model` — model selection (`claude-opus-4-6`, `claude-sonnet-4-6`, `claude-haiku-4-5`)
- `max_tokens` — response میں زیادہ سے زیادہ tokens
- `system` — system prompt (model کی تعریف)
- `messages` — conversation history (full history کے لیے ضروری)
- `tools` — available tools کی definitions
- `tool_choice` — tool selection strategy

1.2 Message Roles

roles میں تین array messages:

- `user` — user messages
- `assistant` — model responses (history کے لیے ضروری)

- `tool` — tool call results (عملاً `tool_result` content block)

محفوظ state کے درمیان Model requests بھیجیں conversation history میں مکمل API request م بات: ر آزاد ہوتی call نہیں رکھتا؛ ر

1.3 stop_reason

Claude API response میں `stop_reason` کے جو بتاتا ہے کہ:

Value	Description	Action
"end_turn"	Model جواب مکمل کر لیا	کو نتیجہ دکھائیں user
"tool_use"	Model tool call چاہتا ہے	واپس دیں result چلائیں اور tool
"max_tokens"	Token limit ختم ہو گئی	response truncated؛ limit میں
"stop_sequence"	Stop sequence مل گئی	کریں handle کے مطابق application logic

کرتے loop control ہیں — یہی signals سب سے اہم "end_turn" اور "tool_use" میں Agentic systems ہیں

1.4 System Prompt

System prompt متعین کرتا ہے behavioral rules اور context کے جو instruction ایک خاص

- `messages` array الگ ہوتا؛ الگ `system` field کا حصہ نہیں ہوتا؛
- user messages پر فوقیت رکھتا ہے
- ہو کر پوری گفتگو میں لاگو رہتا ہے load ایک بار
- کی وضاحت کے لیے استعمال ہوتا ہے output format اور role, constraints,

کو غیر ارادی طور پر متاثر کر سکتی ہے مثال tool selection wording کی system prompt: امتحان کے لیے اہم ضرورت سے زیادہ `get_customer` کو model کی تصدیق کریں "جیسی ہدایت customer کے طور پر" ہمیشہ استعمال کرنے پر لے جا سکتی ہے

1.5 Context Window

Context window اس میں شامل process ایک وقت میں model کے جس (tokens) و کل متن ہے:

- System prompt
- message history مکمل
- Tool definitions
- Tool results

اہم مسائل:

1. **Lost-in-the-middle effect:** درمیان کی input لمبے، مؤثر ہوتی ہیں، آغاز اور اختتام کی معلومات زیادہ مؤثر ہوتی ہیں، حل: اہم معلومات شروع یا آخر میں رکھیں details miss

2. **Tool results** واپس tool 40+ fields شامل کرتی ہیں اگر output میں tool call context کا جمع ہونا: ہر Tool results ضائع ہوتا ہے context کو مگر صرف 5 امیون تو
3. **Progressive summarization:** history compress کرنے پر numeric values, percentages, اور dates اکثر vague ہوتی ہیں

2 tool_use اور Tools: باب 2

Tool Use: دستاویزات

2.1 tool_use کیا ہے

براہ راست Model کو external functions call کرنے کے لیے Claude جس کے ذریعے mechanism tool_use واپس کرتا ہے result کو execute اس کے لیے code بنانا ہے: آپ کا structured tool call نہیں چلتا — وہ code درست ہے

2.2 Tool Definition

tool JSON schema کے ذریعے define ہوتا ہے:

```
{
  "name": "get_customer",
  "description": "Finds a customer by email or ID. Returns the customer profile, including name, email, order history, and account status. Use this tool BEFORE lookup_order to verify the customer's identity. Accepts an email (format: user@domain.com) or a numeric customer_id.",
  "input_schema": {
    "type": "object",
    "properties": {
      "email": {"type": "string", "description": "Customer email"},
      "customer_id": {"type": "integer", "description": "Numeric customer ID"}
    },
    "required": []
  }
}
```

Tool description نکات:

1. Description کا سبب بنتی selection غلط Minimal descriptions mechanism کا بنیادی tool selection ہیں
2. Description کا edge cases، input format، کیا کرتا ہے، کیا واپس کرتا ہے tool میں شامل کریں
3. Overlapping descriptions سے بچیں
4. Built-in tools اور MCP tools overlap کو ہٹانے کے لیے MCP tool واضح بنائیں

2.3 tool_choice

Value	Behavior	کب استعمال کریں
<code>{ "type": "auto" }</code>	Model خود ط کرتا ہے	default عام
<code>{ "type": "any" }</code>	Model tool call کو لازماً کرے گی	structured output جب چاہے
<code>{ "type": "tool", "name": "extract_metadata" }</code>	Model tool call کو لازماً کرے گی	forced first step / order ہے

2.4 JSON Schemas for Structured Output

reliable لینے کا سب سے structured output Claude استعمال کرنا `tool_use` کے ساتھ JSON schemas کی semantic correctness نافذ کرتا ہے، مگر required structure کم کرتا ہے اور syntax errors طریقہ کے ی ضمانت نہیں دیتا

اصول Design:

- رکھیں جو ہمیشہ ملنے چاہئیں required fields صرف وہ
- استعمال کریں nullable fields کے لیے missing data ممکن
- ضائع نہ ہو information شامل کریں تاکہ enum values جیسے "unclear" اور "other"

2.5 Syntax اور Semantic Errors

Error type	Example	Mitigation
Syntax	Invalid JSON, field type غلط	JSON schema کے ساتھ <code>tool_use</code>
Semantic	Totals match نہیں کرتے، value field غلط	Validation checks, feedback retry

بنانا Claude Agent SDK — Agentic Systems: باب 3

دستاویزات: [Agent SDK](#) | [Hooks](#) | [Subagents](#) | [Sessions](#)

3.1 Agentic Loop

چلانا sequence کی actions صرف جواب نہیں دیتا، بلکہ Claude میں Agentic loop

- Claude کو tools کے ساتھ request بھیجیں
- Response لیں
- چیک کریں `stop_reason`:
 - "tool_use" → tool چلائیں، result history پھر دوبارہ request میں ڈالیں

- "end_turn" → task کو دین user مکمل، نتیجہ

مکمل ہونے تک دہرائیں۔ 4.

Text parsing یا arbitrary iteration دیکھیں کہ `stop_reason == "end_turn"` کی لیے `signal: completion` درست قابلِ اعتماد نہیں ہے۔


3.2 AgentDefinition

```
agent = AgentDefinition(
    name="customer_support",
    description="Handles customer requests for returns and order issues",
    system_prompt="You are a customer support agent...",
    allowed_tools=["get_customer", "lookup_order", "process_refund",
"escalate_to_human"],
)
```

اصول اپنائیں کہ Least privilege کے allowed_tools اور، system_prompt، description، name: کم چیزیں

3.3 Coordinator اور Subagents

استعمال کرتی ہیں hub-and-spoke topology اکثر Multi-agent systems:



Coordinator task کو توڑتا ہے، subagents نتائج جوڑتا ہے، کام سونپتا ہے، منتخب کرتا ہے، errors handle کرتا ہے، جواب پہنچاتا ہے۔ final تک user، اور

نہیں کرتے۔ inherit خود بخود parent history الگ ہوتا ہے؛ وہ context کا subagents: کم اصول

3.4 Task Tool

Subagents Task tool کے ذریعے spawn کیے جاتے ہیں۔ Coordinator کے allowed_tools میں "Task" ہونا چاہیے۔

context passing: صحیح

- Task: "Analyze the document" کافی ہیں
- Task: "Analyze this document. Full text: ... Output schema: ..." درست ہے

ممکن ہیں کہ parallel subagents بھیج سکتا ہے، لہذا Task s multiple میں response ایک Coordinator

3.5 Hooks

کرتے ہیں کہ work پر points کے مخصوص lifecycle Hooks

PostToolUse tool result کو model پر لے کر normalize تک پہنچانے کے لیے:

```
@hook("PostToolUse")
def normalize_dates(tool_result):
    return normalized_result
```

PreToolUse policy violation block کر سکتا ہے:

```
@hook("PreToolUse")
def enforce_refund_limit(tool_call):
    if tool_call.name == "process_refund" and tool_call.args.amount > 500:
        return redirect_to_escalation(tool_call)
```

Critical business rules کو یقینی بنانے کے لیے hooks deterministic؛ prompt instructions probabilistic؛ یاد رکھیں rules کو یقینی بنانے کے لیے hooks کو یقینی بنانے کے لیے۔

باب 4: Model Context Protocol (MCP)

[MCP](#) | [Tools](#) | [Resources](#) | [Servers](#) : دستاویزات

4.1 MCP کیا ہے

MCP resource کو جوڑتا ہے اس کے تین بنیادی Claude کو external systems کو جو open protocol ہے:

1. **Tools** — actions کے لیے functions
2. **Resources** — context data (documentation, schemas, catalogs)
3. **Prompts** — predefined task templates

4.2 MCP Servers

MCP server ایک process جو tools/resources expose کرتا ہے Connect کے ذریعے tools discover ہوتا ہے اور descriptions کے مطابق استعمال ہوتا ہے۔

4.3 Configuration

Project config (`.mcp.json`) لے کر:

```
{
  "mcpServers": {
    "github": {
      "command": "npx",
      "args": ["-y", "@modelcontextprotocol/server-github"],
      "env": {"GITHUB_TOKEN": "${GITHUB_TOKEN}"}
    }
  }
}
```

User config سہ آتی ہے secrets environment variables میں ہوتی ہے؛ Project config version control (~/claude.json) personal/experimental servers کے لیے ہوتی ہے

4.4 isError

واپس کریں structured error کے بجائے Generic errors استعمال کریں `isError: true` میں MCP tool errors

```
{
  "isError": true,
  "content": {
    "errorCategory": "transient",
    "isRetryable": true,
    "message": "The service is temporarily unavailable."
  }
}
```

4.5 Resources

Resources کے لیے پڑھ سکتا ہے action بغیر agent میں جو data و Resources: schemas, docs, content catalogs, summaries، exploratory tool calls میں کم کرتے ہیں

5 اور Claude Code — Configuration Workflows

دستاویزات: [Claude Code](#) | [Memory / CLAUDE.md](#) | [Skills](#) | [MCP](#) | [Hooks](#) | [Sub-agents](#) | [GitHub Actions](#) | [Headless](#)

5.1 CLAUDE.md Hierarchy

تین سطحوں پر ہو سکتا ہے CLAUDE.md

- **User-level:** `~/.claude/CLAUDE.md` — پر لاگو user صرف اسی
- **Project-level:** `.claude/CLAUDE.md` یا `root` `CLAUDE.md` — لی تیم پوری
- **Directory-level:** subdirectories میں `CLAUDE.md` — folder conventions مخصوص

5.2 @path Syntax

CLAUDE.md میں @path سے external files refer تاکہ جا سکتا ہے میں تاکہ external files refer تاکہ:

Coding standards @./standards/coding-style.md میں ہیں
Test rules @./standards/testing-requirements.md میں ہیں

5.3 .claude/rules/

`.claude/rules/` rules کو topic سے لحاظ سے organize کرنا ہے اور `paths` ذریعہ conditional loading دیتا ہے:

```
---
paths: ["src/api/**/*"]
---
```

استعمال کریں explicit error handling اور async/await کہ لیں API files

5.4 Commands اور Skills

`.claude/commands/` project commands جبکہ `~/.claude/commands/` personal commands کے لیے ہے، جیسے `.claude/skills/` میں frontmatter کے ساتھ skills کے ملتی ہیں

5.5 Skills اور context: fork

`context: fork` skill کو isolated context میں چلاتا ہے `allowed-tools` اور tool access سے محدود کریں، `argument-hint` مانگیں required input سے

5.6 Planning Mode

Planning mode کے لیے بہترین unfamiliar codebases اور multiple approaches، تبدیلیوں architectural بڑی Direct execution کے لیے بہتر changes چھوٹے اور واضح

5.7 /compact اور /memory

`/compact` context compress کرنا ہے، اور `/memory` notes اور preferences میں مدد دیتا ہے

6.6 Self-correction

کریں discrepancy handle تو conflict دونوں نکال؛ Model stated value اور calculated value

7: Message Batches API

دستاویزات: [Message Batches](#)

7.1 Overview

Message Batches API asynchronous processing 50: % savings، up to 24 hours window، اور multi-turn tool calling supported، custom_id requests اور responses link میں

7.2 کب استعمال کریں

Pre-merge checks اور interactive tasks، synchronous API، overnight reports اور bulk jobs، استعمال کریں Batch API

7.3 custom_id

custom_id result کو original document، جوڑ، failures identify اور صرف، failed items دوبار، submit میں مدد دیتا

8: Task Decomposition Strategies

8.1 Fixed Pipelines

Predictable tasks، fixed pipeline، Document → Extraction → Validation → Final output

8.2 Dynamic Decomposition

Open-ended tasks، subtasks intermediate results، کی بنیاد پر بنتے ہیں

8.3 Multi-pass Code Review

Large PRs، per-file analysis، cross-file integration pass، attention dilution، کم

9 Escalation اور Human-in-the-Loop: باب 9

9.1 Escalate کب کریں

Explicit user request, policy gaps, progress نہ ہونا, threshold سے اوپر financial action, یا ambiguous matching میں Sentiment analysis اور self-rated confidence unreliable ہیں۔ Escalate کی صورت میں

9.2 Escalation Patterns

human کو hand off نہ کرنا یا explicit insistence یا policy gap نہ کرنے کی کوشش کریں، پھر اگر resolve نہ ہو، مسئلہ کریں۔

9.3 Structured Handoff

human شامل کریں تاکہ recommended action اور، actions taken, issue summary, customer ID پر Escalation ملا۔ context کو مکمل operator

9.4 Confidence Calibration

Field-level confidence scores, calibration on labeled data, اور stratified sampling استعمال کریں۔

10 Error Handling میں Multi-agent Systems: باب 10

10.1 Error Categories

Transient errors retryable ہیں، validation errors input fix ہیں، مانگتی business errors policy-driven ہیں۔ کی جاتی ہیں۔ اور permission errors generally escalate ہیں، اور

10.2 Anti-patterns

Generic “search unavailable” response, silent suppression, workflow abort یا پورا کرنا نقصان دہ۔ Structured errors واپس کریں۔

10.3 Structured Subagent Error

Structured error میں failure type, attempted query, partial results, alternative approaches, اور coverage شامل کریں۔ impact

10.4 Final Synthesis میں Coverage

Report میں، اور کہیں partially covered ہیں، کون سی sections fully covered میں واضح کریں کہ کون سی gaps باقی ہیں۔

11 Context میں Production Systems: باب 11 Management

11.1 Facts Separate Block میں

Transactional facts کو persistent case facts block تاکہ summarization میں رکھیں تاکہ critical data کے باوجود زائد و اضافہ نہ ہو۔

11.2 Tool Results Trimming

PostToolUse hook رکھیں تاکہ relevant fields سے صرف ضروری معلومات حاصل کی جاسکیں۔

11.3 Position-aware Input

Important findings اور action items شروع میں اور lost-in-the-middle effect کو کم سے کم رکھیں تاکہ آخر میں رکھیں تاکہ

11.4 Scratchpad Files

Verbose findings scratchpad تاکہ long investigations میں لکھیں تاکہ context محفوظ رہے۔

11.5 Subagents کو Delegate کرنا

Exploration subagents میں summary میں صرف main context میں دیں اور رکھیں۔

11.6 Structured State Persistence

ممکن ہو کہ crash recovery تاکہ export میں JSON file یا state manifest اپنی agent سے۔

12 Provenance رکھنا: باب 12 کو محفوظ رکھنا

12.1 Attribution Loss

Claim رکھیں تاکہ source URL، publication date، اور confidence کے ساتھ۔

12.2 Conflicting Data

کریں conflict flag ساتھ محفوظ رکھیں اور attribution دیں تو دونوں کو values مختلف sources اگر

12.3 Dates

دیکھیں publication dates سمجھنے کے لیے contradiction کو Temporal differences

12.4 Content Type کے مطابق Render

Financial data tables ، news prose ، میں technical findings structured lists اور time series ، میں دیکھائیں chronological order

13 Claude Code کے Built-in Tools : باب 13

13.1 Tool Selection Reference

Task	Tool	Example
تلاش کرنا file کے pattern	Glob	<code>**/*.test.tsx</code>
file contents میں search	Grep	function name, error message
پڑھنا file	Read	analysis کے لیے
بنانا file نیا	Write	scratch کے
precise edit	Edit	unique text match
shell command	Bash	git, npm, tests

13.2 Incremental Investigation

دیکھیں files consumer ، پھر usages ، پھر entry points ، پڑھیں ؛ files ایک ساتھ سب

13.3 Read + Write Fallback

کریں Write کریں ، پھر programmatically کریں ، تبدیلی Read کو تو Edit fail اگر

امتحانی ڈومین نوٹس : II حصہ

- C) Tool description میں instructions اور few-shot examples agent کو شامل کریں جن میں `dry_run=true` کا call کرنا ہمیشہ پورا ہوگا۔
- D) دو tools کو replace کریں: `preview_remove_member` ایک single-use confirmation اور `execute_remove_member` کو توکن کے واپس کرتا ہوگا؛ bind سے preview کو execution، درکار توکن کو واپس کرتا ہوگا [درست]

کے بغیر preview ناممکن ہو جاتا ہے کہ architectural approach سے Token-binding approach کیوں D کر سکتا ہے generate preview tool کے جو صرف token و literally کو execute tool — execution approach کے واحد orchestration infrastructure یا (A)، timing heuristics (C)، کی پابندی جو LLM instructions کے جو approach کے واحد (B) کرتی ہے constraint enforce پر code level پر انحصار کے بجائے

سوال 62

فیلٹرنگ کے بعد، `search_catalog` tool 12% fail وقت کا آپ کا Production monitoring کا **صورتحال** `query syntax errors` پر کامیاب ہوتا ہے، اور 4 `retry` میں جو 8% `network timeouts` ہوتا ہے، جس سے `return` یکساں طریقہ سے `error types` کامیاب نہیں ہوتا ہے۔ فی الحال دونوں `retries` ہوتے ہیں۔

کریں گے؟ modify کیسے □ error handling کی tool آپ

- A) System prompt میں few-shot examples demonstrate network errors کریں □ میں فرق کیسے کریں □ syntax errors
- B) uniformly exponential backoff retry logic apply کریں □ errors پر تمام
- C) Tool کو syntax errors کریں؛ □ automatic retry with backoff implement □ network timeouts □ اندر □ parameter validation details [درست] □ ساتھ فوری واپس کریں □
- D) □ ساتھ واپس کریں □ error type details □ boolean flag retryable کو errors تمام

کو tool — abstraction boundary کرنا صحیح retries handle کر لی transient errors پر Tool level پر کیوں C
 agent کر سکتا ہے بغیر deterministic retry logic implement کرے بارے میں یقینی علم ہے اور error type
 Uniform backoff (B) syntax کرے prompt instructions (A) follow کرے یا (D) interpret flag انحصار کرے و
 پر وقت ضائع کرتا ہے جو کبھی کامیاب نہیں ہوں گے

سوال 63

بہت کم risk اور risk tolerance کم، میری user، میں turns کی گفتگو کی Investment strategy: صورتحال
 "کرنا چاہیے؟ invest کرنا چاہتا ہوں" اب وہ پوچھتا ہے: "مجھے کس چیز میں returns maximize پھر" میں اپنے

سہ priority کی اصل recommendation user سہ بہتر طریقہ سہ یقینی بنانا ک approach کونسا م آنگ؟

- A) پوچھیں کہ کونسی چیز زیادہ اہم ہے [درست] user تضاد کو سامنے لائیں اور
- B) فرام کریں recommendations کہ لپے الگ الگ scenarios دونوں
- C) کہ ساتھ آگے بڑھیں preference سب سے حال میں بیان کی گئی
- D) تجویز کریں balanced portfolio تضاد کو حل کیے بغیر

مانگنا کی واحد clarification برا راست متضاد ہوں، تو تضاد سامنے لانا اور user کی preferences کیوں: جب A low risk کرنا اور Returns maximize کے اصل ارادہ سے ہم آہنگ ہو۔ user recommendation طریقہ کے بنیادی طور پر ناقابل مطابقت ادا ف میں جن کے لیے انسانی فیصلہ درکار ہے tolerance

سوال 64

jazz کے "مجھے User کرتے ہیں playlist preferences refine میں conversation turns کئی Users: صورتحال "پسند ہیں؟ genres پوچھتا ہے "آپ کو کون سے Claude، بعد messages پسند ہے" کے دو

سب سے زیادہ ممکنہ وجہ کیا ہے؟

- A) Claude کو conversation memory کے لیے vector database connection درکار ہے
- B) Model کی context window exceed ہو گئی ہے
- C) Claude API کو session_id parameter درکار ہے
- D) شامل نہیں کر رہی ہے [درست] messages میں بچھلے messages array application آپ کی

request کے stateless API call ہیں — server-side memory کے پاس Claude: کیوں D کا کوئی علم turns کے پاس بچھلے Claude، شامل کیے بغیر conversation history میں مکمل messages array کا حصہ نہیں ہیں؛ دو architecture کے Claude (C) session_id اور (A) Vector databases ہیں ہوتا ناممکن (B) context window overflow کے لیے exchange کے messages

سوال 65

History تک پہنچ گئی ہے conversation 78,000 tokens، بعد cooking session صورتحال: 40 منٹ کے شامل ہیں آپ کو اسم معلومات discussion اور عمومی، allergies, recipe scaling, clarified cooking terms، کم کرنے ہیں tokens محفوظ رکھتے ہوئے

کے درمیان بہترین توازن رکھتا ہے؟ token reduction اور approach preservation کونسا

- A) خلاصہ کریں conversation history پوری
- B) رکھیں tokens صرف سب سے حالیہ 20,000
- C) خلاصہ کریں، اور discussion نکالیں، عمومی (allergies, quantities, preferences) structured data اسم رکھیں [درست] verbatim کو exchanges حالیہ
- D) کریں retrieve کے ذریعہ متعلقہ حصہ semantic search کریں اور conversation externally store مکمل

Allergies معلومات محفوظ رکھتی ہے valuable پر سب سے زیادہ cost سب سے کم Hybrid approach: کیوں C (summarization) ہوتا ہے میں compact structured block ایک critical facts جیسے recipe quantities اور exchanges ہوتی ہے، اور حالیہ discussion summarize عمومی، (سہ بچاتے ہوئے precision loss کے دوران conversational coherence کے لیے verbatim میں Options A اور B dietary information اسم B کے لیے ضرورت سے زیادہ پیچیدہ ہے cooking session ایک D ہیں؛

سوال 66

ka preferences اور topics پر assistant کے conversations میں reports کرتے ہیں کہ طویل Users: صورتحال رکھتی ہے message pairs صرف آخری 25 implementation حساب کھو دیتا ہے آپ کی موجود

کیا ہے؟ solution سب سے مؤثر

- A) Hybrid approach: messages پرانے حالیہ messages کا خلاصہ کرتے ہوئے حالیہ messages پرانے
- B) vector similarity search پر conversation history مکمل
- C) Window 50 message pairs تک بڑھائیں
- D) آگے جوڑیں running summary کا خلاصہ کریں اور dropped messages میں turn کر

A: Hybrid approach کیوں A محفوظ رکھتی ہے exact recent context کے مسئلہ کے دونوں پہلوؤں کو حل کرتی ہے Hybrid approach کیوں A برقرار compressed representation کی preferences جبکہ پہلو کی (کے لیے ام conversational coherence) miss کو context ام (B) Vector search صرف اسی مسئلہ کو ملتوی کرتا ہے (C) بڑھانا Window رکھتی ہے semantically سے current query کر سکتی ہے جو

سوال 67

بڑھ جاتی latency سے زیادہ ہوتے ہیں تو 50 turns conversations reports کرتے ہیں کہ جب Users: صورتحال بھی costs اور

بنیادی وجہ کیا ہے؟

- A) شامل ہوتی ہے conversation history کے ساتھ پوری API request کر
- B) Model gradually responses generate کرتا ہے
- C) History سے جو جاتا ہے database operations کے ساتھ
- D) Model بناتا ہے internal user profile کی ضرورت والا processing زیادہ

A: Claude کی API پر stateless مکمل طور پر request کو messages array میں پوری request بڑھتی ہے، conversation history شامل کرنی ہوتی ہے جسے جسے conversation history کے درمیان کوئی Model calls دونوں بڑھاتا ہے cost اور directly processing latency ل جاتی ہے، جو internal state رکھتا ہے (D غلط ہے)

سوال 68

تک بڑھ گئی ہے جب conversation history 85,000 tokens، بعد weekly sessions: صورتحال: تین مہینوں کے discussions پچھلی assistant کے بارے میں کیا نتیجہ اخذ کیا تھا؟، تو theme کے isolation پوچھتا ہے "م نہ user کرنے کے بجائے عام جوابات دیتا ہے reference

کیا ہے؟ approach سب سے مؤثر

- A) Rolling window truncation
- B) Key conclusions capture کے ہوئے progressive summarization
- C) Relevant exchanges retrieve کے لیے [درست] semantic embeddings کرنے کے لیے
- D) Discussion conclusions mark کے لیے structured XML tags کرنے کے لیے

scale کو discussion □□ جو تین مہینوں کی approach واحد semantic search پر conversation history کیوں C
Rolling window کر سکتی □□□ specific relevant exchanges surface demand پر کر سکتی □□ جبکہ
کو Progressive summarization (B) discussions کا بیشتر حصہ ضائع کر دے گی □ history (A) truncation
بوجھتے ہیں □ users کھو دیتی □□ جن کے بارے میں specific conclusions ، کرتی □□ compress میں abstractions

سوال 69

کرتا ہے، system prompt guidelines میں 10-15 Claude، دوران QA testing: صورتحال
 اندر 1000 token limits ابھی Conversation آجائی 1000 deviation میں responses لیکن بعد 1000

کیا ؟ solution بہترین

- A) Behavioral guidelines میں منتقل کریں □ user message کو پلا
- B) conversation شروع کریں □ بعد نئی 20 turns
- C) Conversation breakpoints پر guidelines reinforce والے user-role messages insert [درست] کریں □
- D) Non-compliant responses کو regenerate لیں □ post-response validation کرنے کے لیے □ استعمال کریں □

history کا براہ راست مقابلہ کرتا ہے Behavioral reminders کا periodic injection instruction drift کو regular intervals پر constraints re-establish کرتا ہے Guidelines کو user کو پر Accumulate message کو preventive (D) corrective Post-response validation کم کرتا ہے authority ان کا (A) میں منتقل کرنا شامل کرتی ہے significant latency اور preventive

سوال 70

□□ teaching methodology اور adaptation rules □□ جو AI tutor 2,800 token system prompt میں **صورتحال:** آپ کو define 12 □□□ turns بعد □□، assistant proficiency levels □□□ کو نظر انداز کرنا شروع کر دیتا □□□

کیا fix سب سے مؤثر

- A) 5–4 turns میں inject کریں
- B) Verbose rules کو proficiency-level adaptation demonstrate کرنے والے few-shot examples سے replace کریں [درست]
- C) Critical rules کو system prompt میں رکھیں
- D) Responses evaluate کریں اور اگر difficulty level match نہ ہو تو regenerate کریں

B کیوں: Declarative rules 2,800 والا token system prompt drift کیونکہ abstract rules vulnerable لی concrete few-shot examples کو Verbose rules کا تقاضا کرتے ہیں reasoning س model میں turn ر clear کرنا لی match کو model کریں demonstrate proficiency-level adaptation correct کرنا جو replace ہوتا ہے reliably س زیادہ abstract instructions میں ، turns دیتا ہے — کئی behavioral patterns

سوال 71

clarifying کرنا، اور reasoning explain برقرار رکھنا، اپنی enthusiastic tone کو assistant **صورتحال**: آپ کے □
□ ہونی چاہئیں؟ define □ اس behavioral guidelines یوجہ □ □ ہیں □ □ questions

سوال 74

Assistant 4+ clarifying requests میں "جیس" venue book اکثر "پارٹی کے لیے" Users: صورتحال
abandonment % پوچھتا ہے، جس سے 35 questions

کرتا ہے؟ improve کو بہترین طریقہ سے approach trade-off کونسا

- A) Hidden defaults کے ساتھ آگے بڑھیں
- B) میں پوچھیں compound message ایک clarifying questions تمام
- C) Assumptions explicitly بیان کریں اور [درست] corrections بڑھیں
- D) Structured intake form استعمال کریں

دیتا ہے جبکہ غلط response کو فوری، مفید user بیان کرنا اور آگے بڑھنا Assumptions explicitly: کیوں C
کو نہیں بتاتا کہ کیا user (A) Hidden defaults کرنے کی صلاحیت برقرار رکھتا ہے correct کو assumptions
Structured کا تقاضا کرتی ہے upfront effort سے user پھر بھی (B) Compound question list کیا گیا ہے assume
form (D) کی بجائے زیادہ شامل کرتا ہے friction کم

سوال 75

turns rules follow استعمال کرتا ہے ابتدائی assistant contractor-persona system prompt صورتحال: آپ کا
Conversational length 2,500 tokens صرف دیتا ہے assistant generic advice تک 7 turn کرتا ہے، لیکن

سب سے زیادہ ممکنہ وجہ کیا ہے؟

- A) System prompts کے لیے initial behavior establish صرف
- B) Turns accumulate کے ساتھ model کے نوٹوں کی attention
- C) Accumulated assistant responses system prompt اثر کو dilute [درست] میں
- D) System prompt صرف ایک بار بھیجا جاتا ہے

System prompt کے جمع نوٹوں میں assistant responses میں conversation history کیوں: جیس جیس C
behavioral constraints کو reflect کرنے والے assistant-generated content بڑھتے ہوئے proportion کا text کرنے والے
بجائے اپنے پائلے system prompt instructions پر بھی token lengths چھوٹے Model کم ہوتا جاتا ہے relative
outputs کے patterns کو زیادہ follow کرتا ہے drift، کرتا ہے compound کو drift

سوال 76

کئی Assistant "میں مدد کر سکتے ہیں؟" report کرتے ہیں جیس "کیا آپ requests میں" Users: صورتحال
abandonment % جس سے 40، (کیا ہے؟ deadline؟ کیا مدد؟ report؟ کون سی) کرتا ہے respond سوالات پوچھ کر
ہوتا ہے

کیا ہے؟ solution بہترین

- A) Reasonable assumptions انہیں اور explicitly کریں، انہیں
- B) Respond کے ساتھ smaller model کرنے سے پائلے ambiguity classify کریں
- C) Assumptions predefined interpretations بیان کیے بغیر استعمال کریں
- D) Assistant تک محدود کریں clarifying question میں ایک turn کو

رکھتے ہیں۔ In control اور informed user کو ساتھ آگے بڑھنا Reasonable stated assumptions: کیوں A کرتی confuse کو Silent predefined interpretations (C) users کو مکمل طور پر ختم کرتا ہے۔ back-and-forth کی One-question limit (D) نہ ہو۔ match ان کے ارادے سے response میں جب latency اور infrastructure مسئلہ حل کیا۔ بغیر core UX (B) Smaller classification model ضرورت ہے۔ شامل کرتا ہے۔ complexity

عملی مشقیں

Exercise 1: Multi-tool Agent with Escalation Logic

Goal: tool integration, structured errors, اور escalation کے ساتھ agent loop بنائیں

Exercise 2: Configuring Claude Code for Team Development

Goal: CLAUDE.md, custom commands, path-specific rules, اور MCP servers configure کریں □

Exercise 3: Structured Data Extraction Pipeline

Goal: JSON schema, validation/retry loops, اور Message Batches API کے ساتھ extraction pipeline بنائیں

Exercise 4: Designing and Debugging a Multi-agent Research Pipeline

Goal: subagent orchestration, explicit context passing, error propagation, اور source tracking implement کریں۔ □

Appendix: Technologies and Concepts

Technology	Key aspects
Claude Agent SDK	agent loops, <code>stop_reason</code> , hooks, <code>Task</code> , <code>allowedTools</code>
MCP	servers, tools, resources, <code>isError</code> , <code>.mcp.json</code>
Claude Code	CLAUDE.md, <code>.claude/rules/</code> , <code>.claude/commands/</code> , <code>.claude/skills/</code> , planning mode
Claude Code CLI	<code>-p</code> , <code>--output-format json</code> , <code>--json-schema</code>
Claude API	<code>tool_use</code> , <code>tool_choice</code> , <code>stop_reason</code> , <code>max_tokens</code>

Message Batches API	50% savings, 24-hour window, <code>custom_id</code>
JSON Schema	required/optional, nullable, enum values
Few-shot prompting	ambiguous scenarios ❌ لے ❌ examples
Prompt chaining	sequential decomposition
Context window	token budget, lost-in-the-middle
Confidence calibration	field-level scoring, stratified sampling

Out-of-Scope Topics

❌: موضوعات امتحان میں شامل نہیں ہیں

- Claude models کی fine-tuning
- Authentication, billing, یا account management
- implementation کی تفصیلی programming languages مخصوص
- hosting/infrastructure کی MCP servers
- Claude کی internal architecture یا model weights
- Constitutional AI, RLHF, یا safety training
- Embeddings یا vector databases کی implementation details
- Computer use / browser automation
- Vision / image analysis
- Streaming API یا SSE
- Rate limiting اور detailed API cost calculations
- OAuth اور API key rotation details
- Cloud-provider-specific configs
- Performance benchmarks
- Prompt caching implementation details
- Token counting algorithms

Preparation Recommendations

1. بنائیں agent کو ساتھ ایک Claude Agent SDK
2. کریں configure پر real project کو Claude Code
3. کریں test اور MCP tools design
4. بنائیں Data extraction pipeline
5. کریں Prompt engineering practice
6. سیکھیں Context management patterns

7. Escalation اور human-in-the-loop workflows سمجھیں

8. Practice exam حل کریں