

Claude 認證架構師 — 基礎認證

學習指南(依據官方考試指南)

簡介

Claude 認證架構師 — 基礎認證 確認專家在實作真實世界中以 Claude 為基礎的解決方案時,能做出妥善的權衡取捨決策。本考試評量對 Claude Code、Claude Agent SDK、Claude API 以及模型上下文協定(MCP)的基礎知識——這些是以 Claude 建構正式環境應用程式的核心技術。

考題以實際的產業情境為基礎:為客戶支援建構代理式系統、設計多代理研究管線、將 Claude Code 整合至 CI/CD、打造開發者生產力工具,以及從非結構化文件中擷取結構化資料。

目標應試者

理想的應試者是以 Claude 設計並交付正式環境應用程式的**解決方案架構師**。你應具備至少 6 個月以下領域的實作經驗:

- **Claude Agent SDK** — 多代理編排、委派給子代理、工具整合、生命週期 Hooks
- **Claude Code** — CLAUDE.md、MCP 伺服器、Agent Skills、規劃模式
- **模型上下文協定(MCP)** — 用於後端整合的工具與資源
- **提示工程** — JSON 結構描述、少樣本範例、資料擷取範本
- **上下文視窗** — 處理長文件、多代理上下文傳遞
- **CI/CD 管線** — 自動化程式碼審查、測試產生
- **升級與可靠性** — 錯誤處理、人在迴路(human-in-the-loop)

考試形式

參數	數值
題型	單選題(四選一)
題數	60 題
計分	100–1000 級距,及格分數 720
猜題扣分	無(每一題都要作答!)
時限	120 分鐘(多方一致回報;官方指南未明載)
情境	從官方 6 個情境隨機抽 4 個(見下方說明)

認證家族(2026 年 7 月): 本指南對應 **Claude Certified Architect — Foundations**(\$125,全體 Claude Partner Network 成員皆可報考;CPN 會員資格免費)。另有三張認證已開放報名,報名管道為 Anthropic Partner Academy:**Associate — Foundations**(\$99),給在自身工作中使用 Claude 的客戶端與交付實務者(提示、評估輸出、工作流程整合、負責任使用);**Developer — Foundations**(\$125),給在 Claude 上建構並交付生產級應用與代理的工程師(自訂工具、MCP 伺服器、模型最佳化、安全);**Architect — Professional**(\$175),給主導企業級 Claude 部署的資深架構師(解決方案與整合架構、規模化最佳化、治理、利害關係人領導)。

考試內容:5 個涵蓋領域

涵蓋領域	權重
1. 代理架構與編排	27%
2. 工具設計與 MCP 整合	18%
3. Claude Code 設定與工作流程	20%
4. 提示工程與結構化輸出	20%
5. 上下文管理與可靠性	15%

考試情境

關於官方清單的說明: 官方考試指南定義的是六個情境(官方標題略有不同:「Customer Support Resolution Agent」、「Developer Productivity with Claude」),每場考試從這 6 個抽 4 個。下方的情境 7 與 8 是本指南在官方六個之外**額外增加的練習領域**——它們鍛鍊同樣的五大領域、值得研讀,但並不在官方情境清單中。

情境 1:客戶支援代理

你使用 Claude Agent SDK 建構一個代理,處理退貨、帳務爭議與帳戶問題。該代理使用 MCP 工具 (`get_customer`、`lookup_order`、`process_refund`、`escalate_to_human`)。目標是達到 80% 以上的首次接觸解決率,並在適當時機升級。

情境 2:使用 Claude Code 產生程式碼

你使用 Claude Code 加速開發:程式碼產生、重構、除錯、文件撰寫。你需要將它與自訂斜線命令及 CLAUDE.md 設定整合,並了解何時使用規劃模式。

情境 3:多代理研究系統

一個協調者代理將任務委派給專門的子代理:網路研究、文件分析、綜整,以及報告產生。該系統必須產出附帶引用的完整報告。

情境 4:開發者生產力工具

該代理協助工程師探索不熟悉的程式碼庫、產生樣板程式碼,以及自動化例行任務。會使用內建工具(Read、Write、Bash、Grep、Glob)與 MCP 伺服器。

情境 5:用於持續整合的 Claude Code

將 Claude Code 整合至 CI/CD 管線,以進行自動化程式碼審查、測試產生與 pull request 回饋。提示必須經過設計以盡量減少誤報。

情境 6:結構化資料擷取

該系統從非結構化文件中擷取資訊,以 JSON 結構描述驗證輸出,並維持高準確度。它必須正確處理邊界案例。

情境 7:對話式 AI 架構模式

你設計多輪對話式系統,涵蓋上下文視窗管理、跨輪次的指令持續性、記憶策略、用於安全執行的工具設計,以及處理模糊或衝突的使用者輸入。

情境 8:代理式 AI 工具

你設計並治理自主代理在真實世界中行動所依賴的工具。工作範圍涵蓋工具設計(何時提供專用工具,何時改用通用的 `bash` 能力)、撰寫能區分相似動作的工具描述與 JSON 結構描述、以 `tool_choice` 與平行工具呼叫控制執行,以及為破壞性或不可逆的操作加入安全控制(幂等性、確認步驟與權限把關)。你透過 `stop_reason` 驅動代理迴圈、以足夠的結構傳遞工具錯誤讓模型得以復原,並避免累積的工具結果灌爆上下文視窗。目標是打造一個能選對工具、安全地失敗,並在長時間多步驟任務中保持可靠的代理。

官方文件

資源	URL
Claude API — Messages	https://platform.claude.com/docs/en/api/messages
Claude API — Tool Use	https://platform.claude.com/docs/en/build-with-claude/tool-use
Claude API — Message Batches	https://platform.claude.com/docs/en/build-with-claude/message-batches
Claude Agent SDK — Overview	https://platform.claude.com/docs/en/agent-sdk/overview
Claude Agent SDK — Hooks	https://platform.claude.com/docs/en/agent-sdk/hooks
Claude Agent SDK — Subagents	https://platform.claude.com/docs/en/agent-sdk/subagents
Claude Agent SDK — Sessions	https://platform.claude.com/docs/en/agent-sdk/sessions
Model Context Protocol (MCP)	https://modelcontextprotocol.io/
MCP — Tools	https://modelcontextprotocol.io/docs/concepts/tools

MCP — Resources	https://modelcontextprotocol.io/docs/concepts/resources
MCP — Servers	https://modelcontextprotocol.io/docs/concepts/servers
Claude Code — Documentation	https://code.claude.com/docs/en/overview
Claude Code — CLAUDE.md and Memory	https://code.claude.com/docs/en/memory
Claude Code — Skills (incl. slash commands)	https://code.claude.com/docs/en/skills
Claude Code — Hooks	https://code.claude.com/docs/en/hooks
Claude Code — Sub-agents	https://code.claude.com/docs/en/sub-agents
Claude Code — MCP Integration	https://code.claude.com/docs/en/mcp
Claude Code — GitHub Actions CI/CD	https://code.claude.com/docs/en/github-actions
Claude Code — GitLab CI/CD	https://code.claude.com/docs/en/gitlab-ci-cd
Claude Code — Headless (non-interactive mode)	https://code.claude.com/docs/en/headless
Prompt Engineering Guide	https://platform.claude.com/docs/en/build-with-claude/prompt-engineering/overview
Extended Thinking	https://platform.claude.com/docs/en/build-with-claude/extended-thinking
Anthropic Cookbook (code examples)	https://github.com/anthropics/anthropic-cookbook

第一部分:理論基礎

本部分涵蓋你成功通過考試所需的所有理論。教材是依技術與概念來組織,而非依考試涵蓋領域編排——這有助於你對每個主題建立更深入的理解。

第 1 章:Claude API — 模型互動基礎

文件:[Messages API](#) | [Prompt Engineering](#)

每一個 Claude 系統——無論是單次分類呼叫、一段 Claude Code 工作階段,或一個 20 個代理的研究群集——本質上都是對單一端點 `POST /v1/messages` 的一連串 HTTP 請求。Messages API 是本書其餘內容賴以建構的基礎。工具使用(第 2 章)、Agent SDK(第 3 章)與 MCP(第 4 章)全都是這個端點的功能,或是對它的封裝。如果你誤解了請求如何構成、`stop_reason` 代表什麼,或是 API 為何無狀態,這些錯誤就會擴散到每一個更高的層級。

本章同時支撐三個考試領域:**Domain 1 — 代理架構與編排(27%)**(代理迴圈完全由 `stop_reason` 驅動)、**Domain 4 — 提示工程與結構化輸出(20%)**(`system` 欄位與訊息構建)、以及 **Domain 5 — 上下文管理與可靠性(15%)**(上下文視窗,以及無狀態 API 的後果)。讀完你應能掌握:

- **請求/回應契約**(§1.1)— 每次呼叫帶了什麼,哪些欄位是關鍵。
- **訊息角色與無狀態**(§1.2)— 為何每次都要重送整段對話。
- **`stop_reason`** (§1.3)— 控制代理迴圈與錯誤處理的單一欄位。
- **系統提示**(§1.4)— 行為如何設定,以及它的措辭如何滲入工具選擇。
- **上下文視窗**(§1.5)— 上述一切共享的有限預算。
- **串流、token 與成本**(§1.6)— 在正式環境執行 API 的營運現實。

§1.7 接著從頭到尾建構一個完整的多輪客服聊天後端,§1.8 則濃縮考試重點。

1.1 API 請求結構

Claude API 遵循請求—回應模型。每個送往 Claude Messages API 的請求都包含:

```
{
  "model": "claude-sonnet-5",
  "max_tokens": 1024,
  "system": "You are a helpful assistant.",
  "messages": [
    {"role": "user", "content": "Hi!"},
    {"role": "assistant", "content": "Hello!"},
    {"role": "user", "content": "How are you?"}
  ],
  "tools": [...],
  "tool_choice": {"type": "auto"}
}
```

主要欄位:

- `model` — 模型選擇(`claude-opus-4-8` 、 `claude-sonnet-5` 、 `claude-haiku-4-5`)
- `max_tokens` — 回應中的最大 token 數
- `system` — 系統提示(定義模型行為)
- `messages` — 對話歷史(你必須送出完整的歷史以維持連貫性)
- `tools` — 可用工具的定義
- `tool_choice` — 工具選擇策略

為何每個欄位是這樣設計——以及常見錯誤:

- `model` 是精確的 ID 字串,不是可以隨意加料的模糊別名。 `claude-opus-4-8` 是能力最強的層級; `claude-sonnet-5` 平衡成本與智慧; `claude-haiku-4-5` 最快也最便宜。打錯字(`claude-sonnet-5.0`)或自己編造日期後綴(`claude-sonnet-5-20260601`)都會回傳 `**404 not_found_error**`——考試很喜歡測你「不要自己拼湊 ID」。
- `max_tokens` 只限制輸出,而且模型並不知道這個上限。設得太小,回應會在句子中途被無聲截斷,並帶著 `stop_reason == "max_tokens"`。開放式生成請設大一點(非串流 16K;串流時可到 64K–128K),分類則設極小值(例如 256)。低估 `max_tokens` 是「模型講到一半就停了」最常見的原因。

- `system` 是獨立的頂層欄位,不是 `messages` 的第一個元素。新手常想在陣列前面塞一個 `{"role": "system", ...}` ——這在過去會報錯;即使現在某些情況支援對話中途的 `system` 訊息,最初的指令仍應放在頂層 `system` 欄位。(詳見 §1.4。)
- `messages` 必須非空、必須以 `user` 回合開頭,第一則訊息絕不能是 `assistant` ——否則回 `400`。連續同角色的條目會被合併,但整個陣列就是模型擁有的全部記憶(見 §1.2)。
- `tools` / `tool_choice` 是選填。沒有工具時,模型只能產生文字。`tool_choice` 預設 `{"type": "auto"}` (模型自行決定)。這是通往第 2 章的接縫;現在只要記得:它們的存在會耗用上下文視窗的 token,因為每個工具的 JSON schema 都會在每次請求中送出。

****考試角度:****題目常問「構成有效呼叫的最低需求是什麼?」——答案是 `model`、`max_tokens`,以及一個以 `user` 回合開頭的 `messages` 陣列。其餘皆為選填。

1.2 訊息角色

`messages` 陣列使用三種角色:

- `user` — 使用者訊息
- `assistant` — 模型回應(送出歷史時會包含)
- `tool` — 工具呼叫結果(此角色不會明確設定;它會以 `tool_result` 內容區塊的形式出現)

至關重要:每個 API 請求你都必須送出完整的對話歷史。模型不會在請求之間保留狀態——每次呼叫都是獨立的。

為何這比表面看起來更重要。「無狀態」不是次要的實作細節;它是 API 的定義性質,並決定了其上每一個多輪系統的設計:

```
flowchart TD
    A[第 1 輪<br/>送出:user 訊息 1] --> B[Claude 回覆<br/>assistant 訊息 1]
    B --> C[你的應用把兩者<br/>存入 messages 陣列]
    C --> D[第 2 輪<br/>送出:user1 + assistant1 + user2]
    D --> E[Claude 回覆<br/>assistant 訊息 2]
    E --> F[再次附加<br/>歷史持續成長]
    F --> D
```

- **伺服器什麼都不留。** 沒有任何可以只用最新 `user` 訊息「續接」的工作階段。如果你只送第 N 則訊息,模型對第 $1..N-1$ 則就會失憶。完整的逐字稿就是對話本身。
- **`tool` 結果是內容區塊,不是字面上的角色。** 當模型呼叫工具時,你把結果以 `tool_result` 內容區塊的形式附加在一則 `user` 角色的訊息中——角色標籤並不會被設成 `"tool"`。期待有對稱「`tool`」角色的開發者常在此跌倒;考試要你知道結果是搭著一個 `user` 回合、以 `tool_use_id` 為鍵回傳的。
- **允許連續同角色的訊息**(API 會合併成一個回合),但陣列仍必須以 `user` 開頭。

常見錯誤:

- 只送最新的 `user` 回合,然後納悶為何上下文「不見了」——上下文從來沒有被存在伺服器端。
- 任由陣列無限成長直到溢出上下文視窗(§1.5)——無狀態意味著你要負責歷史管理,包括修剪與摘要。
- 自己手刻一個 `{"role": "tool", ...}` 訊息,而不是用 `tool_result` 區塊。

1.3 回應中的 stop_reason 欄位

Claude API 的回應包含 `stop_reason` ,用以表示模型為何停止生成:

值	說明	動作
<code>"end_turn"</code>	模型已完成其回應	將結果呈現給使用者
<code>"tool_use"</code>	模型想要呼叫工具	執行該工具並回傳結果
<code>"max_tokens"</code>	已達 token 上限	回應被截斷;你可能需要提高上限
<code>"stop_sequence"</code>	遇到停止序列	依你的應用程式邏輯處理
<code>"pause_turn"</code>	長時間執行的回合被暫停(例如伺服器端工具使用期間),可被恢復	將回應送回,讓模型從中斷處繼續
<code>"refusal"</code>	模型基於安全理由拒絕繼續(Claude 4+)	停止迴圈並妥善處理——不要原封不動地重試相同請求

對代理式系統而言, `"tool_use"` 和 `"end_turn"` 最為重要——它們控制著代理迴圈。

`stop_reason` 是每個代理的控制平面。這個單一欄位是第 1 章最關鍵的考試概念,因為整個代理迴圈(第 3 章 §3.1)都依它分支:

```
flowchart TD
    A[讀取 response.stop_reason] --> B{哪個值?}
    B -->|tool_use| C[執行工具<br/>附加 tool_result<br/>再次迴圈]
    B -->|end_turn| D[完成 - 回傳文字給使用者]
    B -->|max_tokens| E[被截斷 - 提高 max_tokens<br/>或改串流, 然後重試]
    B -->|pause_turn| F[重送回應<br/>讓伺服器恢復]
    B -->|refusal| G[停止 - 妥善處理<br/>不要盲目重試]
```

- 依 `stop_reason` 分支,絕不依文字。任務完成唯一可靠的訊號是 `stop_reason == "end_turn"`。解析助理的散文找「done」或「task completed」是考試要你否定的典型反模式——它脆弱、依賴語言,且容易被模型自己的措辭騙過。
- `max_tokens` 代表被截斷,不是完成。把它當成錯誤狀況處理:輸出不完整。要嘛提高 `max_tokens` 重新請求,要嘛改用串流(讓你在不撞 HTTP 逾時的情況下用更高的上限)。
- `pause_turn` 是給伺服器端工具用的。當模型使用 Anthropic 託管的工具(網路搜尋、程式碼執行)而伺服器端迴圈達到其迭代上限時,你會收到 `pause_turn`。把助理回應直接送回即可恢復——**不要**再加一則 `"Continue."` 的 user 訊息;API 會偵測到結尾的伺服器工具區塊並自動恢復。
- `refusal` 絕不能盲目重試。在 Claude 4+,安全拒絕會回傳一個成功的 HTTP 200,帶著 `stop_reason == "refusal"`。重送一模一樣的請求只是為同樣的結果燒 token。要在碰 `response.content` 之前先讀 `stop_reason`——在輸出前就拒絕的情況下,content 陣列可能是空的,無條件執行 `response.content[0].text` 的程式碼會當掉。

讀 `stop_details` 前要先防護。 `response.stop_details` 只有在 `stop_reason == "refusal"` 時才會被填入;對 `end_turn`、`max_tokens`、`tool_use` 等它都是 `null`。不加防護就讀 `.category` 會是執行

期錯誤。

1.4 系統提示

系統提示是一種特殊指令,用以定義上下文與行為規則。它:

- 不屬於 `messages` 陣列;它會在 `system` 欄位中單獨傳遞
- 優先於使用者訊息
- 載入一次後便在整段對話中持續套用
- 用來定義角色、限制條件與輸出格式

****考試重點:****系統提示的措辭可能會造成非預期的工具關聯。例如,像「務必驗證客戶」這樣的指令,可能會導致模型過度使用 `get_customer`,即使在不必要的情況下也是如此。

為何系統提示不只是「那些指令」。 它是請求中權威最高的文字,並位於提示前綴的**最前端**,這帶來兩個考試會考的後果:

```
flowchart TD
```

```
SP[系統提示<br/>權威最高<br/>位於前綴最前端] --> A[定義角色與限制]
```

```
SP --> B[設定輸出格式]
```

```
SP --> C[影響工具選擇]
```

```
C --> D[措辭過強] D --> E[工具過度觸發<br/>例如「務必驗證」-> 過度使用 get_customer]
```

```
SP --> F[可快取前綴的最前面位元組<br/>見 1.6 提示快取]
```

- **措辭會滲入行為。** 因為模型會密切遵循系統提示,原本用來**克服**猶豫的命令式措辭如今反而**過度**觸發。「務必驗證客戶」會讓模型即使在這次請求根本不需要時也呼叫 `get_customer`;「CRITICAL: 你必須使用搜尋工具」會讓它在用推理就能解決時去搜尋。修正幾乎總是把語氣放軟(「當請求涉及帳戶變更時才驗證客戶」),而不是加更多護欄。這是考試最愛的第 1 章細節,並直接連結 Domain 4(提示設計)與 Domain 1(工具選擇行為)。
- **軟性偏好放這裡;硬性規則不放。** 系統提示產生的是**機率性**遵循——模型通常會聽,但不是 100%。任何必須被保證的事(退款上限、財務動作前的身分檢核)都屬於**確定性**程式碼或 hook(第 3 章 §3.5),絕不能只靠提示文字。把金額規則放進系統提示是典型的錯誤答案。
- **它設定一次、全程套用,且覆蓋使用者訊息。** 使用者無法像說服埋在對話裡的限制那樣,輕易把模型勸離一條住在系統提示裡的限制——這正是為何操作者指令應放在那裡,而不是放在 user 回合。
- **它是可快取前綴的最前端。** 因為系統提示穩定且位居最前,它是錨定提示快取的天然位置(§1.6)。把易變內容插進去——時間戳記、使用者名稱、請求 ID——會讓其後的一切快取失效。保持它凍結不變。

1.5 上下文視窗

上下文視窗是指模型一次能處理的文字總量(以 token 計)。它包含:

- 系統提示
- 完整的訊息歷史
- 工具定義
- 工具結果

上下文視窗的主要問題:

1. **迷失在中間效應:**模型能可靠地處理長輸入開頭與結尾的資訊,但可能會漏掉中間的細節。緩解方式:將關鍵資訊放在靠近開頭或結尾處。
2. **工具結果的累積:**每次工具呼叫都會把輸出加進上下文。如果一個工具回傳 40 個以上的欄位,但只有 5 個有用,那麼大部分的上下文都被浪費了。
3. **漸進式摘要:**在壓縮歷史時,數值、百分比與日期往往會遺失並變得模糊(「大約」、「差不多」、「幾個」)。

為何上下文視窗是預算,而非只是上限。 §1.1–§1.4 的一切都在爭奪同一個有限的 token 池,而且因為 API 無狀態(§1.2),這個池會隨著你重送一段不斷成長的逐字稿而一輪輪被填滿:

```
flowchart TD
    CW[上下文視窗<br/>單一共享的 token 預算] --> S[系統提示]
    CW --> H[完整的訊息歷史<br/>每輪都成長]
    CW --> T[工具定義<br/>每個 schema、每次請求]
    CW --> R[工具結果<br/>快速累積]
    H --> X[溢出風險與<br/>迷失在中間]
    R --> X
```

- **迷失在中間是一個擺放問題。** 模型對長輸入的開頭與結尾注意得最可靠,可能漏掉埋在中間的發現。所以順序很重要:把關鍵指令或關鍵發現放在靠近頂端或底部,而不是放在 60,000 token 中的第 40,000 個。當彙整多個來源的資料時,以最重要的段落、配上明確的標題開頭。
- **工具結果膨脹是無聲的預算殺手。** 一個在模型只需要 5 個欄位時回傳 40 個的工具,會在之後每一輪都浪費另外 35 個(因為歷史會重送)。在工具輸出進入逐字稿之前,先把它修剪到相關欄位——這是 Domain 5 的技能,也是反覆出現的考試情境。
- **摘要恰恰會弄丟你在乎的資料。** 漸進式摘要傾向把精確值——數字、百分比、日期、ID——壓縮成模糊語言(「大約幾個」、「差不多上一季」)。緩解方式是把交易性事實抽取到一個持久、未經摘要的「case facts」區塊,而不是信任滾動摘要去保留它們。
- **現代長上下文功能存在,但原則不變。** 即使有 200K–1M token 的視窗、伺服器端 compaction 與 context editing,同樣的失效模式仍適用——更大的預算只是延後問題,並非廢除它。考試考的是原則(擺放、修剪、事實保留),而不是視窗的原始大小。

1.6 串流、token 與成本

前面幾節描述了呼叫的形狀,本節討論執行它的營運現實——考試會把這些包裝成「你該用哪種做法」的取捨。

串流

非串流請求會阻塞,直到整個回應生成完畢才一次回傳。對於長輸出,這有 HTTP 逾時的風險——SDK 會拒絕它們估計會耗時太久的非串流請求,而大的 `max_tokens` (超過約 16K) 實質上要求串流。串流會以一連串 Server-Sent Events 的形式逐步送出回應:

```
sequenceDiagram
    actor App as 你的應用
    participant API as Messages API
    App->>API: messages.stream(...)
    API-->>App: message_start (中繼資料)
    API-->>App: content_block_start
    API-->>App: content_block_delta (token)
    API-->>App: content_block_delta (token)
    API-->>App: content_block_stop
    API-->>App: message_delta (stop_reason, usage)
    API-->>App: message_stop
    App->>App: 用 get_final_message() 組裝完整回覆
```

- **message_delta** 帶著你真正需要拿來分支的東西: 它包含 `stop_reason` 與累進的 token `usage`。即使是為了體驗而串流,也呼叫 SDK 輔助函式(`get_final_message()` / `.finalMessage()`)把完整訊息重新組裝——你能同時得到串流體驗與逾時保護,而不必親手處理每一個事件。
- 任何有長輸入或高 `max_tokens` 的情況都預設串流。這是標準的正式環境姿態;非串流只適合短而快的呼叫(分類、抽取)。

token 與成本

定價以 token 計,輸入與輸出分開計費,並依模型而異:

模型	輸入 \$/1M	輸出 \$/1M	上下文
claude-opus-4-8	\$5.00	\$25.00	1M
claude-sonnet-5	\$3.00	\$15.00	1M
claude-haiku-4-5	\$1.00	\$5.00	200K

- 輸出遠比輸入昂貴(上表每個模型都是 5 倍)。一個囉嗦的回應,比要求它的提示還貴——這又是一個「妥善界定 `max_tokens` 與精簡系統提示」很重要的理由。
- 用 API 數 token,不要用猜的。要估成本或檢查提示是否塞得進視窗,請用 `POST /v1/messages/count_tokens (client.messages.count_tokens(...))`。不要使用 `tiktoken` 或其他 OpenAI 分詞器——它們是為不同模型校準的,會低估 Claude 的 token 數,在程式碼與非英語文字上低估得很嚴重。token 數依模型而定;傳入你將用於推理的同一個 `model`。
- **usage 報告真實數字**。每個回應都帶著 `usage`,含 `input_tokens`、`output_tokens` 與下方的快取欄位。`input_tokens` 只是未快取的剩餘部分——提示總大小是 `input_tokens + cache_creation_input_tokens + cache_read_input_tokens`。

提示快取(基礎)

提示快取是前綴比對:API 會快取渲染後的提示直到某個 `cache_control` 斷點,而該前綴中任何位元組的變動都會讓其後的一切失效。渲染順序是 `tools` → `system` → `messages`。

- 把穩定內容放前面,易變內容放後面。凍結的系統提示與確定性的工具清單是理想的快取錨點;一個插進系統提示的時間戳記或每次請求的 ID,會無聲地破壞整個請求的快取。
- 快取讀取約為基礎輸入價格的 0.1 倍,寫入約 1.25 倍——所以一段大型、重複使用的前言(指令、few-shot 範例、一份長文件)在幾次請求內就回本。

- 用 `usage.cache_read_input_tokens` 驗證。如果它在應該共享前綴的請求間一直是零,那就有無聲的失效因子在作怪(常見的是系統提示裡的 `datetime.now()`、未排序的 JSON 傾印,或每次請求都變動的工​​具集)。

*考試角度:*快取、串流與 token 計數是 Domain 5 成本/可靠性情境背後的第 1 章構件——題目考的是何時*串流、為何不用 `tiktoken`、什麼*會讓快取失效,而不是確切的定價數字。

1.7 端到端案例研究:多輪客服聊天後端

上述欄位唯有組合在一起才有意義。以下是一個完整、真實的後端,把整章串成一個系統——一個驅動多輪客服聊天的無狀態 Web 服務。它只用第 1 章的概念:messages、系統提示、無狀態、串流、`stop_reason`、token/成本計算,以及提示快取。(還沒有工具——那是第 2 章。)

需求

- 驅動一來一往的客服聊天:使用者輸入、助理回覆、循環往復。
- 此服務是無狀態 HTTP 後端(多個實例位於負載平衡器之後)——它不能依賴行程內記憶橫跨請求。
- 逐 token 串流回覆,讓 UI 在生成時就顯示文字。
- 固定的客服人設與政策文字套用於每段對話,且必須被快取,而非每輪重新計費。
- 依對話追蹤 token 用量以供成本報告。
- 正確處理被截斷(`max_tokens`)與被拒絕(`refusal`)的回應——絕不把半截訊息當成完整的顯示出去,絕不盲目重試拒絕。
- 避免對話溢出上下文視窗。

架構

```
flowchart TD
    User([使用者瀏覽器]) -->|POST 訊息 + conversation_id| Svc[無狀態聊天後端]
    Svc --> Store[(對話儲存<br/>完整 messages 陣列)]
    Store --> Build[構建請求<br/>已快取 system + 完整歷史 + 新回合]
    Build -->|messages.stream| API[ Claude Messages API ]
    API -->|token 增量| Svc
    Svc -->|SSE| User
    API -->|message_delta: stop_reason + usage| Check{stop_reason?}
    Check -->|end_turn| Save[附加助理回覆<br/>記錄 usage]
    Check -->|max_tokens| Retry[標記為截斷<br/>提高 max_tokens]
    Check -->|refusal| Safe[回傳安全後備<br/>不盲目重試]
    Save --> Store
```

因為後端無狀態,對話儲存是唯一的記憶——每一輪都從它重建完整請求。系統提示是快取錨點;不斷成長的 `messages` 陣列就是對話。

實作

一個會重送完整歷史、快取人設並串流的對話管理器:


```

import anthropic

client = anthropic.Anthropic()

SUPPORT_SYSTEM = (
    "You are Acme's support assistant. Be concise and friendly. "
    "Help with orders and returns. If a request needs an account change, "
    "ask the user to confirm their order number first."
) # 凍結 — 沒有時間戳記或個別使用者資料,所以能乾淨地快取。

def handle_turn(conversation_id: str, user_text: str) -> dict:
    history = store.load(conversation_id) # 完整 messages 陣列(無狀態)
    history.append({"role": "user", "content": user_text})

    with client.messages.stream(
        model="claude-sonnet-5",
        max_tokens=1024,
        cache_control={"type": "ephemeral"}, # 快取穩定的 system 前綴
        system=SUPPORT_SYSTEM,
        messages=history,
    ) as stream:
        for text in stream.text_stream:
            push_sse(conversation_id, text) # 把 token 串流給 UI
        final = stream.get_final_message() # 重組 + 取得 stop_reason/usage

    if final.stop_reason == "refusal":
        return {"status": "refused"} # 不要重送相同請求
    if final.stop_reason == "max_tokens":
        return {"status": "truncated"} # 不完整 — 提高 max_tokens 並重試

    assistant_text = next(b.text for b in final.content if b.type == "text")
    history.append({"role": "assistant", "content": assistant_text})
    store.save(conversation_id, history) # 持久化不斷成長的逐字稿
    record_usage(conversation_id, final.usage) # input/output/cache token 供成本
    return {"status": "ok"}

```

當歷史成長過大時修剪它以保護上下文視窗,並保留最近的回合:

```

def trim(history: list, keep_recent: int = 20) -> list:
    # 無狀態意味著「歷史管理」由我們負責。保留最近的回合;
    # 對於長工作階段,把較舊的回合摘要進一個持久的事實區塊,
    # 而不是丟掉精確的訂單編號與日期(1.5)。
    return history if len(history) <= keep_recent else history[-keep_recent:]

```

執行軌跡

```
sequenceDiagram
    actor U as 使用者
    participant B as 聊天後端
    participant DB as 對話儲存
    participant C as Claude API
    U->>B: 「訂單 #5512 在哪?」
    B->>DB: 載入歷史(第 1..n 輪)
    DB-->>B: 完整 messages 陣列
    B->>C: stream(system=已快取, messages=歷史 + 新回合)
    C-->>B: token 增量(串流給 U)
    C-->>B: message_delta: stop_reason=end_turn, usage
    B->>DB: 附加助理回覆, 儲存
    U->>B: 「取消它。」(下一輪, 同一 conversation_id)
    B->>DB: 載入歷史(現已包含 #5512 的往來)
    B->>C: stream(system=已快取前綴 → 快取命中, 完整歷史)
    C-->>B: 回覆(只因為歷史被重送, 才知道 #5512)
```

注意第 2 輪之所以「記得」訂單 #5512,純粹是因為後端重送了整段逐字稿——API 什麼都沒存。第二個請求也在 system 前綴上獲得快取命中,所以人設文字以約 0.1 倍而非全價計費。

驗證

- **無狀態測試:** 在對話中途重啟後端(清掉所有行程內狀態);下一輪仍必須有完整上下文,證明記憶住在儲存裡,而非行程裡。
- **快取測試:** 斷言第二輪及之後的 `usage.cache_read_input_tokens > 0`。如果是零,就有無聲的失效因子溜進了系統提示(時間戳記、個別使用者字串)。
- **截斷測試:** 在一個長答案上強制 `max_tokens=16`,並斷言後端回報 `truncated`,而不是把半句話當成完整回覆存下來。
- **拒絕測試:** 斷言 `refusal` 回應會回傳安全後備,且不會再發一個一模一樣的請求。
- **上下文預算測試:** 跑一段長對話,確認 `trim()` 把視窗維持在有界範圍內,且不丟掉最新的使用者意圖。

常見陷阱

- 把歷史存在行程記憶裡,當負載平衡器把下一輪導向不同實例時就弄丟對話(API 無狀態——§1.2)。
- 把 `datetime.now()` 或使用者名稱插進 `SUPPORT_SYSTEM`,無聲地殺死快取(§1.4、§1.6)。
- 把 `max_tokens` 當成成功,把被截斷的訊息當成最終結果顯示(§1.3)。
- 盲目重試 `refusal`,為同樣的結果燒 token(§1.3)。
- 任由 `messages` 陣列無界成長直到溢出上下文視窗(§1.5)。
- 用 `tiktoken` 而非 `count_tokens` 估成本,低估 Claude 的 token 數(§1.6)。

1.8 考試重點 — 關鍵整理

概念	考試考什麼
請求結構	有效呼叫的最低需求是 <code>model</code> + <code>max_tokens</code> + 一個以 <code>user</code> 開頭的 <code>messages</code> 陣列; <code>system</code> 是獨立欄位,不是訊息(§1.1)。

無狀態	伺服器什麼都不存——每輪重送完整歷史;修剪與摘要由你負責(\$1.2)。
<code>stop_reason</code>	依 <code>stop_reason</code> 分支,絕不依解析文字; <code>end_turn</code> = 完成、 <code>max_tokens</code> = 截斷、 <code>refusal</code> = 停止且不盲目重試(\$1.3)。
系統提示	權威最高且位於前綴最前端;措辭過強會過度觸發工具;硬性規則屬於程式碼,不屬於提示(\$1.4)。
上下文視窗	單一共享的 token 預算;以擺放緩解迷失在中間、修剪膨脹的工具結果、保留精確事實(\$1.5)。
串流與成本	長輸出/高 <code>max_tokens</code> 就串流;讀 <code>usage</code> ;用 <code>count_tokens</code> 數 token,絕不用 <code>tiktoken</code> ;快取穩定前綴(\$1.6)。

對應 Domain 1、4、5。第 1 章是本書其餘內容立足的地基: `stop_reason` 驅動 Domain 1 的代理迴圈,系統提示與訊息構建驅動 Domain 4,無狀態加上下文視窗驅動 Domain 5。把上面的客服聊天後端——messages、系統提示、串流、`stop_reason`、成本、快取——掌握好,更高的層級就會變得容易推理得多。

第 2 章:工具與 `tool_use`

文件:[Tool Use](#)

工具是 Claude 從「文字產生器」變成會動手的系統的關鍵——查訂單、跑查詢、呼叫 API。本章是 **Domain 2 — 工具設計與 MCP 整合(佔考試 18%)** 的骨幹。第 3 章談的是代理如何編排工具,本章則談每一次工具呼叫底層的契約:你如何定義工具、Claude 如何請求工具、你如何回傳它的結果(包含失敗),以及你如何引導選擇。讀完你應能:

- 解釋 `tool_use` / `tool_result` 往返(\$2.1)——每次工具呼叫所依附的訊息交換。
- 寫出 `description` 能真正驅動正確選擇的**工具定義**(\$2.2)。
- 用 `tool_choice` 引導選擇(\$2.3),並推理**平行工具呼叫**(\$2.4)。
- 以 **JSON Schema** 作為取得結構化輸出最可靠的途徑(\$2.5),並分辨**語法與語意錯誤**(\$2.6)。
- 回傳**結構化的錯誤結果**,讓模型能正確復原(\$2.7)。

\$2.8 接著從頭到尾建構一個完整的發票擷取服務,\$2.9 則濃縮考試重點。

2.1 什麼是 `tool_use`

`tool_use` 是讓 Claude 能呼叫外部函式的機制。模型**不會執行程式碼**——它會發出一個結構化的**請求**來呼叫工具;**由你的程式碼執行它**並把結果回饋回去。Claude 是規劃者;你的執行環境是雙手。

就機制而言,一次工具呼叫是一個四訊息的往返,而且完全承載在一般的 `messages` 陣列裡:

flowchart TD

```
A[你的程式碼送出 user 訊息<br/>加上 tools 陣列] --> B[Claude 回應<br/>stop_reason 為 tool_use]
B --> C[回應裡含一個 tool_use 區塊<br/>id, name, input]
C --> D[你的程式碼執行真正的函式]
D --> E[附加一則 user 訊息含<br/>tool_result 區塊, 相同 id]
E --> F[Claude 讀取結果<br/>並繼續]
F --> G{stop_reason?}
G -->|tool_use| D
G -->|end_turn| H[給使用者的最終文字回答]
```

線路格式很重要,因為考試會考你是否理解它:

```
// 1) Claude 的回應 - stop_reason: "tool_use"
{
  "role": "assistant",
  "content": [
    {"type": "text", "text": "Let me look that up."},
    {"type": "tool_use", "id": "toolu_01A...", "name": "get_customer",
      "input": {"email": "ada@example.com"}}
  ]
}

// 2) 你的回覆 - 結果以一則 USER 訊息回傳
{
  "role": "user",
  "content": [
    {"type": "tool_result", "tool_use_id": "toolu_01A...",
      "content": "{\"name\": \"Ada\", \"status\": \"active\"}"}
  ]
}
```

為何重要 / 常見錯誤:

- `tool_result` 區塊要放在一則 `role: "user"` 的訊息回傳,而非 `assistant` ——這是常見的混淆點。`tool_use_id` 必須對應 Claude 生成的 `id`,否則 API 會拒絕這一回合。
- 你必須在下一個請求中把助理的 `tool_use` 回合原樣帶回去。API 是無狀態的;如果你丟掉含 `tool_use` 區塊的助理回合、只送 `tool_result`,對話就會格式錯誤。
- Claude 經常在 `tool_use` 區塊旁邊一併發出 `text` 區塊(「Let me look that up.」)。別把那段文字當成最終答案——`stop_reason == "tool_use"` 代表這一回合還沒完成。

****考試角度:****要熟記角色/id 的配對(`tool_use.id` ↔ `tool_result.tool_use_id`),以及 `tool_result` 承載在 `user` 訊息上。這就是第 3 章代理迴圈所驅動的底層協定。

2.2 工具定義

每個工具都使用 JSON 結構描述來定義。 `description` 是你會寫到的最重要欄位:

```
{
  "name": "get_customer",
  "description": "Finds a customer by email or ID. Returns the customer profile, including name, email, order history, and account status. Use this tool BEFORE lookup_order to verify the customer's identity. Accepts an email (format: user@domain.com) or a numeric customer_id.",
  "input_schema": {
    "type": "object",
    "properties": {
      "email": {"type": "string", "description": "Customer email"},
      "customer_id": {"type": "integer", "description": "Numeric customer ID"}
    },
    "required": []
  }
}
```

工具描述至關重要的面向:

1. **描述是主要的選擇機制。** Claude 幾乎完全依據工具的描述與結構描述來選擇工具——它沒有其他途徑能知道工具在做什麼。過於精簡的描述(「Retrieves customer information」)會在兩個工具功能重疊的當下,導致選錯工具。
2. **描述中應包含:**
 - 工具的功能與回傳內容
 - 輸入格式與範例值
 - 邊界案例與限制
 - 何時應使用此工具,而非類似的替代工具
3. **避免**在不同工具之間使用相同或重疊的描述。如果 `analyze_content` 與 `analyze_document` 讀起來幾乎相同,模型會把兩者混淆。解法通常是**為了具體性而重新命名**(`analyze_content` → `extract_web_results`),並把一個通用工具**拆成多個聚焦的工具**、各自有清楚的輸入/輸出契約——這正是 Domain 2 消除功能重疊的技能。
4. **內建工具 vs MCP 工具:** 代理傾向偏好內建工具(Read、Grep),而非功能類似的 MCP 工具。為了抵銷這點,請強化 MCP 工具的描述——點出內建工具無法提供的具體優勢、獨特資料或上下文。
5. **留意系統提示。** 系統提示的措辭會造成非預期的關聯(「你是搜尋助理」會讓模型偏向任何名為 `search_*` 的東西)。工具路由是描述與周邊提示共同作用的結果。

****為何重要 / 常見錯誤:****把描述當成給人看的文件,而非模型的路由表。模糊或重複的描述不是表面問題——它是一個正確性的 bug,會以代理呼叫到錯誤工具的形式浮現。

****考試角度:****面對兩個容易混淆的工具,正確答案通常是改寫/重新命名描述以區別之*(並拆分過於通用的工具),而不是增加提示指令。

2.3 tool_choice 參數

`tool_choice` 控制模型如何選擇工具:

值	行為	何時使用
<code>{"type": "auto"}</code>	模型自行決定要呼叫工具或以文字回答	多數情況的預設值
<code>{"type": "any"}</code>	模型 必須 呼叫某個工具(絕不純文字)	當你需要保證取得結構化輸出時
<code>{"type": "tool", "name": "extract_metadata"}</code>	模型 必須 呼叫那個特定工具	當你需要強制的第一步 / 執行順序時
<code>{"type": "none"}</code>	模型本回合 不可 呼叫任何工具	暫時停用工具卻不移除它們

重要情境:

- `tool_choice: "any"` + 多個擷取工具 → 模型仍會挑選最合適的一個,但你能保證取得工具呼叫,而非散文式回答。
- 強制選擇(`type: "tool"`) → 當你必須保證特定的第一個動作時(例如,在任何豐富化步驟前先執行 `extract_metadata`)。

為何重要 / 常見錯誤:

- 在 `auto` 下,Claude 可能合理地以文字回答。如果你的程式碼無條件去解析 `tool_use` 區塊,遇到純文字回合就會崩潰。當下游程式碼需要結構化輸出時,請用 `any`。
- **強制一個工具會停用該回合的延伸思考(extended thinking)**,而 `any` / `tool` 代表模型一定會呼叫某個工具——所以被強制的工具必須是可以無條件安全呼叫的。別只為了取得結構就強制一個有副作用的工具(例如 `send_email`);改為強制一個擷取/格式化的工具。

****考試角度:****「保證結構化輸出、由模型挑工具」→ `any`。「保證某個特定工具先執行」→ `{"type": "tool", "name": ...}`。「模型可回答或呼叫」→ `auto`。

2.4 平行工具呼叫

當一個回合需要多個彼此獨立的查詢時,Claude 可以在**單一回應中發出多個** `tool_use` 區塊。你的程式碼執行它們(最好是並行的),並在**後續一則** `user` 訊息中回傳**全部的** `tool_result` 區塊。

```

flowchart TD
    A[Claude 單一回應<br/>三個 tool_use 區塊] --> B[get_weather<br/>id 1]
    A --> C[get_traffic<br/>id 2]
    A --> D[get_events<br/>id 3]
    B --> E[在你的程式碼中並行執行]
    C --> E
    D --> E
    E --> F[一則 user 訊息<br/>三個 tool_result 區塊<br/>id 1, 2, 3]
    F --> G[Claude 帶著所有結果繼續]
```

為何重要 / 常見錯誤:

- 一個平行批次的所有 `tool_result` 區塊都必須在一則 user 訊息中回傳,且各自對應到它的 `tool_use_id`。把它們拆散到多則訊息、或漏掉某個 id,都會讓這一回合格式錯誤。
- 平行化是針對**獨立**呼叫的最佳化。如果工具 B 需要工具 A 的輸出,那是**循序**的往返,不是平行批次——模型會請求 A、看到結果,然後才請求 B。
- 你可以推動或抑制平行化:用提示(例如請模型一次蒐集所有需要的資料)會鼓勵它;在 `tool_choice` 裡設 `disable_parallel_tool_use: true` 則會在你的後端無法安全處理並行時,強制每回合至多一次呼叫。

****考試角度:****平行工具呼叫 = 為獨立工作降低延遲;題目中的線索是「抓取 X、Y 與 Z」且彼此之間沒有相依。有相依的步驟無法平行化。

2.5 用於結構化輸出的 JSON 結構描述

搭配 JSON 結構描述使用 `tool_use` 是從 Claude 取得結構化輸出**最可靠**的方式。它能:

- **保證語法上有效的 JSON**(沒有缺漏的大括號,沒有多餘的逗號)
- **強制套用所需的結構**(必填欄位都存在、列舉值被遵守)
- **不保證語意正確性**(值仍可能有誤)

經典模式是用單一「擷取器」工具,其 `input_schema` 就是你想拿回的形狀;以 `tool_choice: {"type": "tool", "name": "..."}` 呼叫它,然後讀取產生的 `tool_use` 區塊的 `input`。

結構描述設計——關鍵原則:

```
{
  "type": "object",
  "properties": {
    "category": {
      "type": "string",
      "enum": ["bug", "feature", "docs", "unclear", "other"]
    },
    "category_detail": {
      "type": ["string", "null"],
      "description": "Details if category = 'other' or 'unclear'"
    },
    "severity": {
      "type": "string",
      "enum": ["critical", "high", "medium", "low"]
    },
    "confidence": {
      "type": "number",
      "minimum": 0,
      "maximum": 1
    },
    "optional_field": {
      "type": ["string", "null"],
      "description": "Null if the information was not found in the source"
    }
  },
  "required": ["category", "severity"]
}
```

結構描述設計規則：

- 1. **必填 vs 選填**: 只有在資訊永遠都會有的情況下,才將欄位標記為 `required`。必填欄位會在資料缺失時,促使模型**捏造**值。
- 2. **可為 null 的欄位**: 對於可能不存在的資訊,使用 `"type": ["string", "null"]`,讓模型可以回傳 `null`,而不會產生幻覺。
- 3. **含 "other" 的列舉**: 加入 `"other"` + 一個詳細說明字串,以免落在你預先定義類別之外的資料被悄悄遺失。
- 4. **列舉值 "unclear"**: 用於模型無法有信心挑選的情況——誠實的 `"unclear"` 勝過一個自信但錯誤的類別。
- 5. **為每個欄位加描述**。每個欄位的 `description` 是提示的一部分;「Null if not found in source」能可衡量地降低幻覺。

為何重要 / 常見錯誤過度設定必填欄位、以及省略 null,是兩個最常見的結構描述 bug,而兩者都會製造幻覺。結構描述約束的是形狀*,從不是真實性*——這正是 §2.6 存在的原因。

****考試角度:**「我如何保證有效、結構良好的輸出?」→ 工具/JSON 結構描述,而非提示後再解析。「我如何讓模型能說我不知道*?」→ 可為 null 的型別,以及 `unclear / other` 列舉。

2.6 語法錯誤 vs 語意錯誤

JSON 結構描述能徹底關閉某一整類錯誤的大門,卻關不了另一類。把它們分開看,就能知道該套用哪種緩解方式。

錯誤類型	範例	緩解方式
語法	無效的 JSON、錯誤的欄位型別、缺漏必填鍵	搭配 JSON 結構描述使用 <code>tool_use</code> (可消除這一類)
語意	總計加不起來、值放錯欄位、捏造的值	驗證檢查、帶回饋的重試、自我修正

為何重要 / 常見錯誤以為 JSON 既然解析成功,它就是正確*的。結構描述能保證 `line_items` 是一個形狀正確的陣列;它無法保證這些明細加總起來等於 `total`。語意正確性是你*的工作——擷取後要驗證,失敗時帶著具體差異重新提示(例如「明細加總為 90.00 但 total 是 95.00;請重算」),讓模型自我修正。

****考試角度:****如果題目的失敗是「JSON 格式錯誤 / 缺欄位」,解法是結構描述。如果是「數字錯了 / 值放錯欄位」,解法是驗證 + 重試——結構描述幫不上忙。

2.7 結構化的錯誤結果

工具會失敗——逾時、輸入錯誤、違反政策、缺少權限。**你如何把失敗回報給 Claude,決定了它能否正確復原。** 工具結果不限於成功的酬載;你用 `is_error: true` (MCP 中的 `isError` 旗標)標記失敗結果,而且——關鍵在於——讓其內容可被機器據以行動:

```
{
  "type": "tool_result",
  "tool_use_id": "toolu_01B...",
  "is_error": true,
  "content": "
{\\\"errorCategory\\\":\\\"transient\\\",\\\"isRetryable\\\":true,\\\"message\\\":\\\"Upstream timeout after 5s\\\"}"
}
```

要區分錯誤的類別,因為每一種都意味著不同的復原方式:

類別	範例	可重試?	Claude 應該做什麼
暫時性(Transient)	上游逾時、503	是	重試,最好搭配退避(backoff)
驗證(Validation)	格式錯誤的 email、缺欄位	否	修正輸入後再次呼叫
業務(Business)	退款超過政策上限	否	向使用者說明 / 升級
權限/存取(Permission/Access)	token 缺少 scope	否	停下並回報,別繞圈

為何重要 / 常見錯誤:

- 一個籠統的 "Operation failed" 會剝奪模型決定 *重試* vs *修正* vs *停止* 所需的資訊。經典的失敗模式是代理對一個不可重試的驗證或業務錯誤無止盡地重試。
- 對業務規則違規回傳 `isRetryable: false`,並附上清楚、面向使用者的 `message`,讓代理去說明而非繞圈。
- 區分存取失敗與有效的空結果。`search` 回傳零筆是帶著空資料的成功——不是錯誤。把「查無相符」標記為 `is_error` 會讓模型以為工具壞了而無謂重試。
- 能在本地復原就在本地復原。對暫時性失敗,子代理應在內部重試,只把它真的無法解決的錯誤往上傳——別讓協調者承擔每一次小故障。

****考試角度:** 「代理一直重試一個注定失敗的呼叫」的正確答案是結構化的錯誤中介資料* (`errorCategory`、`isRetryable`、人類可讀的 `message`),而不是更長的提示。而且「查無結果」不是錯誤。**

2.8 端到端案例研究:發票擷取服務

上述元件唯有組合在一起才有意義。以下是一個完整、真實的建置,演練本章的每一個概念——定義、`tool_choice`、往返、平行呼叫、結構化錯誤,以及語法/語意之分。任務:把一張雜亂的上傳發票(PDF 文字 + 一個 vendor ID)變成經過驗證的結構化資料,並以即時稅率與供應商資訊加以豐富。

需求

- 輸入:原始發票文字加上一個 `vendor_id`。輸出:一筆嚴格結構化的發票紀錄(明細、小計、稅、總計)。
- 擷取必須保證結構化——下游的會計程式無法解析散文。
- 豐富化需要兩個彼此獨立的查詢——該地區當前的 `tax_rate`,以及標準的 `vendor` 紀錄——兩者應平行執行以縮短延遲。

- 查詢可能**失敗**;系統必須分辨可重試的逾時,以及一個根本不存在的供應商。
- 一張形狀正確的發票仍可能是**錯的**(明細加總不等於總計);這必須被抓出來。

架構

```
flowchart TD
    In([發票文字加上 vendor_id]) --> Ext[強制工具<br/>extract_invoice<br/>tool_choice  
type tool]
    Ext --> Par1[Par[Claude 在一回合中<br/>請求兩個工具]]
    Par1 --> Tax[Tax[get_tax_rate]]
    Par1 --> Ven[Ven[get_vendor]]
    Tax --> Batch1[Batch[一則 user 訊息<br/>兩個 tool_result 區塊]]
    Ven --> Batch1
    Batch1 --> Val1[Val{驗證<br/>明細加總等於總計?}]
    Val1 -->|否| Retry[帶著差異重新提示]
    Retry --> Ext
    Val1 -->|是| Done[經驗證的發票紀錄]
```

`extract_invoice` 是**被強制的**,所以結構有保證;兩個豐富化查詢是**獨立的**,所以 Claude 被允許**平行**請求它們;**結構化錯誤**驅動復原;而一個**語意**檢查(加總)位於結構描述之外,因為結構描述無法強制算術。

實作

定義擷取器——它的 `input_schema` 就是輸出形狀——再加上兩個豐富化工具:

```

extract_invoice = {
  "name": "extract_invoice",
  "description": "Extract a structured invoice from raw text. Returns line items,
"
      "subtotal, tax, and total. Use vendor_currency for all amounts.",
  "input_schema": {
    "type": "object",
    "properties": {
      "line_items": {
        "type": "array",
        "items": {
          "type": "object",
          "properties": {
            "desc": {"type": "string"},
            "amount": {"type": "number"}
          },
          "required": ["desc", "amount"]
        }
      },
      "subtotal": {"type": "number"},
      "currency": {"type": "string"},
      "vendor_tax_id": {
        "type": ["string", "null"],
        "description": "Null if no tax id appears in the source"
      }
    },
    "required": ["line_items", "subtotal", "currency"]
  }
}

get_tax_rate = {
  "name": "get_tax_rate",
  "description": "Returns the current tax rate (0..1) for a region code. Read-
only.",
  "input_schema": {"type": "object",
    "properties": {"region": {"type": "string"}}, "required": ["region"]}
}

get_vendor = {
  "name": "get_vendor",
  "description": "Returns the canonical vendor record (legal name, region) for a
vendor_id. Read-only.",
  "input_schema": {"type": "object",
    "properties": {"vendor_id": {"type": "string"}}, "required": ["vendor_id"]}
}

```

在第一回合強制使用擷取器,這樣你永遠不會拿回散文:

```

resp = client.messages.create(
    model="claude-sonnet-5",
    max_tokens=1024,
    tools=[extract_invoice, get_tax_rate, get_vendor],
    tool_choice={"type": "tool", "name": "extract_invoice"}, # 保證結構
    messages=[{"role": "user", "content": invoice_text}],
)
invoice = next(b.input for b in resp.content if b.type == "tool_use")

```

並行執行兩個獨立查詢,並在一則 user 訊息中回傳兩者的結果:

```

def run_tool(call):
    try:
        if call.name == "get_vendor":
            return {"is_error": False, "content":
                json.dumps(lookup_vendor(call.input["vendor_id"]))}
        if call.name == "get_tax_rate":
            return {"is_error": False, "content":
                json.dumps(get_rate(call.input["region"]))}
    except TimeoutError:
        return {"is_error": True,
            "content": json.dumps({"errorCategory": "transient", "isRetryable":
                True,
                                "message": "Upstream timeout"})}
    except VendorNotFound:
        return {"is_error": True,
            "content": json.dumps({"errorCategory": "validation", "isRetryable":
                False,
                                "message": "No vendor with that id"})}

# Claude 在「一個」回應中發出 get_tax_rate 與 get_vendor -> 平行執行
results = parallel_map(run_tool, tool_use_blocks) # 並行
tool_results = [
    {"type": "tool_result", "tool_use_id": b.id, **r}
    for b, r in zip(tool_use_blocks, results)
]
messages.append({"role": "user", "content": tool_results}) # 全部放在一則訊息

```

驗證結構描述管不到的語意——失敗時,帶著確切差異重新提示:

```

computed = round(sum(li["amount"] for li in invoice["line_items"]), 2)
if computed != invoice["subtotal"]:
    feedback = (f"line_items sum to {computed} but subtotal is "
                f"{invoice['subtotal']}. Recompute and call extract_invoice again.")
# 把 `feedback` 當成 user 回合送回去 -> 模型自我修正($2.6)

```


執行軌跡

```
sequenceDiagram
    actor Sys as 呼叫端
    participant Cl as Claude
    participant Tax as get_tax_rate
    participant Ven as get_vendor
    Sys->>Cl: invoice_text,tool_choice 強制 extract_invoice
    Cl-->>Sys: tool_use extract_invoice 帶結構化 input
    Cl-->>Sys: 兩個 tool_use 區塊,get_tax_rate 與 get_vendor
    Sys->>Tax: region US-CA
    Sys->>Ven: vendor_id V-77
    Ven-->>Sys: is_error true,validation,查無此供應商
    Tax-->>Sys: rate 0.0725
    Sys->>Cl: 一則 user 訊息,兩個 tool_result 區塊
    Cl-->>Sys: end_turn,說明 vendor V-77 找不到,回傳含稅的發票
```

有兩點值得注意。**被強制的** `extract_invoice` 排除了任何散文回答的可能。而**結構化的** `get_vendor` 錯誤(`validation`、`isRetryable: false`)讓 Claude *說明*缺少的供應商,而不是去重試一個永遠不會成功的呼叫——正是 §2.7 中考試所獎勵的行為。

驗證

- **結構測試:** 斷言第一回合永遠是針對 `extract_invoice` 的 `tool_use` (強制有效),且其 `input` 能通過結構描述驗證。
- **平行測試:** 餵入一張需要兩個查詢的發票;斷言 Claude 在一個回應中發出兩個 `tool_use` 區塊,且你在一則訊息中回傳兩個 `tool_result`。
- **錯誤路由測試:** 讓 `get_vendor` 拋出 `VendorNotFound`;斷言代理*說明*而非重試(不可重試),且 `TimeoutError` 會被重試。
- **語意測試:** 餵入一張明細加總不等於小計的發票;斷言驗證器抓到它並重新提示。只有結構描述的設計會悄悄放行這張壞發票。

常見陷阱

- 把 `tool_result` 放在 `assistant` 訊息上回傳,或用了不相符的 `tool_use_id` (§2.1)——API 會拒絕這一回合。
- 用 `tool_choice: "auto"` 後又無條件去讀 `tool_use` 區塊,遇到純文字回合就崩潰 (§2.3)。
- 把平行的 `tool_result` 拆散到多則 user 訊息,而非一則 (§2.4)。
- 把「查無供應商」標記成沒有類別的籠統錯誤,使代理無止盡重試;或根本把空的搜尋結果標記為錯誤 (§2.7)。
- 信任解析後的 JSON 即為正確,而略過加總檢查 (§2.6)。

2.9 考試重點 — 關鍵整理

概念	考試考什麼
<code>tool_use</code> 往返	<code>tool_result</code> 承載在 <code>user</code> 訊息上; <code>tool_use.id</code> ↔ <code>tool_result.tool_use_id</code> ;要把助理回合帶回去 (§2.1)。

工具描述	描述是模型的路由表;修正易混淆的工具靠 改寫/重新命名/拆分 ,而非更多提示(\$2.2)。
<code>tool_choice</code>	<code>any</code> = 保證有某個工具; <code>{"type": "tool", ...}</code> = 特定工具; <code>auto</code> = 模型可以用文字回答(\$2.3)。
平行工具呼叫	在一個回合中對 獨立 工作發出多個 <code>tool_use</code> ;在一則訊息回傳所有 <code>tool_result</code> ;有相依的步驟維持循序(\$2.4)。
JSON 結構描述輸出	最可靠的結構化輸出;可為 <code>null</code> 的型別 + <code>unclear</code> / <code>other</code> 讓模型得以避免捏造(\$2.5)。
語法 vs 語意	結構描述 可消除 語法錯誤,但消不了錯誤的值;語意需要驗證 + 重試(\$2.6)。
結構化錯誤	<code>errorCategory</code> / <code>isRetryable</code> / <code>message</code> 驅動重試-修正-停止;空結果 不是 錯誤(\$2.7)。

對應 Domain 2(18%)。如果你能建構並捍衛上面的發票擷取服務——定義、強制、往返、平行呼叫、結構化錯誤,以及語法/語意之分——你就掌握了工具設計與 MCP 整合領域的核心。

第 3 章:Claude Agent SDK — 建構代理式系統

文件:[Agent SDK](#) | [Hooks](#) | [Subagents](#) | [Sessions](#)

Claude Agent SDK 把單次模型呼叫,變成能規劃、呼叫工具、委派子代理並強制執行護欄的**自主系統**。本章是 **Domain 1 — 代理架構與編排(佔考試 27%)** 的骨幹,也是權重最高的領域。讀完你應能掌握四個構件,並把它們組裝成可上線的代理:

- **代理迴圈**(§3.1)— 代理如何決定下一步。
- **中心輻射式編排**(§3.3)— 協調者委派給隔離的子代理。
- **明確的上下文傳遞**(§3.4)— 為何不主動告知,子代理就什麼都看不到。
- **確定性 Hooks**(§3.5)— 以 100% 可靠度強制執行業務規則。

§3.6 接著從頭到尾建構一個完整的客服退款代理,§3.7 則濃縮考試重點。

3.1 什麼是代理迴圈

代理迴圈是自主執行任務的核心模式。模型不只是回答問題,而是執行一連串動作:

```
flowchart TD
    A[帶著工具向 Claude 發送請求<br/>tools + 完整歷史] --> B[Claude 回應]
    B --> C{stop_reason?}
    C -->|tool_use| D[執行被請求的工具]
    D --> E[將 tool_result<br/>附加到訊息歷史]
    E --> A
    C -->|end_turn| F[任務完成 -<br/>將結果回傳給使用者]
```

在程式碼中,這個迴圈其實只是一個依 `stop_reason` 分支的 `while` :

1. 帶著工具向 Claude 發送請求
2. 接收回應
3. 檢查 `stop_reason`:
 - `"tool_use"` -> 執行工具, 將結果附加到歷史紀錄, 回到步驟 1
 - `"end_turn"` -> 任務完成, 將結果顯示給使用者
4. 重複直到完成

這是一種模型驅動的做法: Claude 會依據上下文與先前的工具結果, 決定接下來要呼叫哪個工具。這與動作順序固定的硬編碼決策樹不同。

反模式(應避免):

- 解析助理文字以偵測是否完成(「Task completed」)
- 將任意的迭代上限(例如 `max_iterations=5`)當作主要的停止條件
- 檢查助理是否產生文字內容, 以此作為完成訊號

****正確做法:****唯一可靠的完成訊號是 `stop_reason == "end_turn"`。

3.2 AgentDefinition 設定

`AgentDefinition` 是 Claude Agent SDK 中的代理設定物件:

```
agent = AgentDefinition(  
    name="customer_support",  
    description="Handles customer requests for returns and order issues",  
    system_prompt="You are a customer support agent...",  
    allowed_tools=["get_customer", "lookup_order", "process_refund",  
        "escalate_to_human"],  
    # 用於協調者:  
    # allowed_tools=["Task", "get_customer", ...]  
)
```

關鍵參數:

- `name` / `description` — 代理的識別與描述
- `system_prompt` — 含指令的系統提示
- `allowed_tools` — 允許使用的工具清單(最小權限原則)

3.3 中心輻射式:協調者與子代理

多代理架構通常建構為中心輻射式拓撲:

```

flowchart TD
    U[使用者請求] --> C[協調者]
    C -->|Task: 搜尋| S1[子代理 1<br/>搜尋]
    C -->|Task: 分析| S2[子代理 2<br/>分析]
    C -->|Task: 綜整| S3[子代理 3<br/>綜整]
    S1 -- 僅回傳結果 --> C
    S2 -- 僅回傳結果 --> C
    S3 -- 僅回傳結果 --> C
    C --> R[彙整並驗證後的結果]

```

協調者負責:

- 將任務分解為子任務
- 決定需要哪些子代理(動態選擇)
- 將工作委派給子代理
- 彙整並驗證結果
- 處理錯誤與重試
- 將結果傳達給使用者

關鍵原則:子代理擁有隔離的上下文。

- 子代理**不會**自動繼承協調者的對話歷史紀錄
- 所有必要的上下文都必須在子代理提示中**明確傳遞**
- 子代理不會在多次呼叫之間共享記憶
- 所有溝通都透過協調者流動(以利可觀測性與錯誤控制)

3.4 用於生成子代理的 **Task** 工具

子代理透過 **Task** 工具生成:

```

# 協調者的 allowedTools 必須包含 "Task"
coordinator_agent = AgentDefinition(
    allowed_tools=["Task", "get_customer"]
)

```

明確的上下文傳遞是必要的:

```

# 不好:子代理沒有任何上下文
Task: "分析這份文件"

# 好:提示中包含完整上下文
Task: "分析以下文件。
文件:[完整文件文字]
先前的搜尋結果:[網路搜尋結果]
輸出格式要求:[schema]"

```

****平行生成:****協調者可以在單一回應中呼叫多個 **Task** ——這些子代理會平行執行:

```
# 一次協調者回應包含：
Task 1: "搜尋關於 X 的文章"
Task 2: "分析文件 Y"
Task 3: "搜尋關於 Z 的文章"
# 三者同時執行
```

3.5 Agent SDK 中的 Hooks

Hooks 允許在代理生命週期的特定節點進行攔截與轉換。

PostToolUse 會在工具結果提供給模型之前攔截它：

```
# 範例：將來自不同 MCP 工具的日期格式正規化
@hook("PostToolUse")
def normalize_dates(tool_result):
    # 將 Unix 時間戳記轉換 -> ISO 8601
    # 將 "Mar 5, 2025" 轉換 -> "2025-03-05"
    return normalized_result
```

對外呼叫攔截 Hook 會阻擋違反政策的動作：

```
# 範例：阻擋超過 $500 的退款
@hook("PreToolUse")
def enforce_refund_limit(tool_call):
    if tool_call.name == "process_refund" and tool_call.args.amount > 500:
        return redirect_to_escalation(tool_call)
```

關鍵差異:Hooks 與提示指令

屬性	Hooks	提示指令
保證	確定性(100%)	機率性(>90%,並非 100%)
何時使用	關鍵業務規則、財務操作、合規	一般偏好、建議、格式設定
範例	阻擋退款 > \$500	「在升級前先嘗試解決」

規則: 當失敗會造成財務、法律或安全後果時——使用 Hooks,而非提示。

3.6 端到端案例研究:客服退款代理

上述元件唯有組合在一起才有意義。以下是一個完整、真實的代理,把整章串成一個系統——正是考試的 **Customer Support Agent(客服代理)** 情境要你能推理的設計。

需求

- 以自然語言處理客戶的退款/退貨請求。

- 查詢客戶與其訂單(唯讀工具)。
- 依公司政策檢核退款。
- **硬性規則:** 任何**超過 \$500 的退款都必須由真人核准**——沒有例外,不交由模型裁量。
- 訂單資料來自多個工具、日期格式不一致;在模型推理前先正規化。

架構

```

flowchart TD
    User([客戶]) --> Coord[協調者代理]
    Coord -->|Task| Lookup[子代理: 訂單查詢<br/>get_customer, lookup_order]
    Coord -->|Task| Policy[子代理: 政策搜尋<br/>search_policy]
    Lookup --> Post[{PostToolUse hook<br/>正規化日期}]
    Post --> Coord
    Policy --> Coord
    Coord --> Refund[process_refund]
    Refund --> Pre[{PreToolUse hook<br/>金額超過 $500?}]
    Pre -->|是| Esc[escalate_to_human]
    Pre -->|否| Exec[執行退款]
    Esc --> Human([真人核准者])
  
```

協調者掌管編排;子代理做範圍狹窄、最小權限的工作;由 **Hooks(而非提示文字)**強制執行金額規則與日期正規化,因為兩者都必須是確定性的。

實作

定義協調者與一個最小權限子代理:

```

coordinator = AgentDefinition(
    name="support_coordinator",
    description="Resolves refund and return requests; escalates when required.",
    system_prompt=(
        "You help customers with refunds. Look up the order, check policy, "
        "then call process_refund. Never promise an outcome you have not executed."
    ),
    allowed_tools=["Task", "process_refund", "escalate_to_human"],
)

order_lookup = AgentDefinition(
    name="order_lookup",
    description="Reads customer and order records. Read-only.",
    system_prompt="Return the customer's order details as structured data.",
    allowed_tools=["get_customer", "lookup_order"], # 最小權限: 沒有退款能力
)
  
```

用 `PreToolUse` hook 確定性地強制執行 \$500 規則——這正是考試要你答對的關鍵:

```
@hook("PreToolUse")
def enforce_refund_limit(tool_call):
    if tool_call.name == "process_refund" and tool_call.args["amount"] > 500:
        # 模型無法繞過這條規則;它是程式碼,不是建議。
        return redirect(to="escalate_to_human", reason="refund_over_limit")
    return allow(tool_call)
```

用 `PostToolUse` hook 正規化每個工具回傳的日期,讓模型永遠不會看到三種日期格式:

```
@hook("PostToolUse")
def normalize_dates(tool_result):
    tool_result["order_date"] = to_iso8601(tool_result.get("order_date"))
    return tool_result
```

執行軌跡

```
sequenceDiagram
    actor Cust as 客戶
    participant Co as 協調者
    participant L as 查詢子代理
    participant Pre as PreToolUse hook
    participant Hu as 真人核准者
    Cust->>Co: 「退我訂單 #1234 的款」
    Co->>L: Task(上下文: 訂單 #1234 + 客戶 id)
    L-->>Co: 訂單總額 $720, 在退貨期限內
    Co->>Pre: process_refund(amount=720)
    Pre->>Pre: 720 大於 500, 阻擋並改道
    Pre->>Hu: escalate_to_human(case #1234)
    Hu-->>Cust: 「專員將核准您 $720 的退款。」
```

注意協調者原本打算直接退款;而 **hook 確定性地否決了它**。若只用提示指令(「超過 \$500 的退款要升級」),模型大約 90% 的時候會遵守——對金錢來說還不夠。

驗證

- **確定性測試:** 連續送出 100 筆 \$501 的退款,斷言出現 100 次升級。只靠提示的設計會漏;hook 設計必須 100%。
- **上下文隔離測試:** 確認查詢子代理是在它的 Task 提示中收到訂單 id——把它拿掉,子代理就應該失敗,證明上下文不會自動共享。
- **最小權限測試:** 斷言 `order_lookup` 子代理無法呼叫 `process_refund`。

常見陷阱

- 把 \$500 規則放進系統提示而非 hook(機率性,沒有保證)。
- 忘了把訂單 id 傳進子代理的提示(隔離的上下文——見 §3.3)。
- 把「退款已處理」這類助理文字當成完成訊號,而不是 `stop_reason == "end_turn"` (§3.1)。

3.7 考試重點 — 關鍵整理

概念	考試考什麼
代理迴圈	唯一可靠的停止訊號是 <code>stop_reason == "end_turn"</code> ——絕非解析文字或迭代上限(\$3.1)。
中心輻射式	協調者負責分解、委派、彙整;子代理是隔離的(\$3.3)。
明確上下文	子代理什麼都不會繼承——所有上下文都要在 <code>Task</code> 提示中傳遞(\$3.4)。
Hooks 與提示	確定性的業務/財務/合規規則 → hooks;軟性偏好 → 提示(\$3.5)。
最小權限	每個代理的 <code>allowed_tools</code> 都是它所需的最小集合(\$3.2)。

對應 **Domain 1(27%)**。如果你能建構並捍衛上面的退款代理——迴圈、委派、上下文、hooks、最小權限——你就掌握了權重最高考試領域的核心。

第 4 章:模型上下文協定(MCP)

文件:[MCP](#) | [Tools](#) | [Resources](#) | [Servers](#)

如果說第 3 章談的是代理的**大腦**——迴圈、委派與 hooks——那麼本章談的就是它的**手與眼**:代理如何觸及外部世界。模型上下文協定(MCP)是一套開放標準,讓 Claude 能與你的資料庫、API 與內部服務溝通,而不必為每一個整合都寫一套客製化的黏合程式碼。本章是 **Domain 2 — 工具設計與 MCP 整合(佔考試 18%)** 的骨幹,同時直接支援 **Domain 1**(代理的能力上限取決於你接進去的工具)與 **Domain 5**(結構化的 MCP 錯誤,正是多代理系統維持可靠的方式)。

讀完你應能掌握五件事,並把它們組裝成一個可運作的整合:

- **協定與其原語**(\$4.1)— Tools、Resources、Prompts,以及 client/server 的分離。
- **伺服器與傳輸**(\$4.2)— 什麼是伺服器,以及 stdio 與 Streamable HTTP 的取捨。
- **設定與範圍**(\$4.3)— `.mcp.json` (專案)與 `~/.claude.json` (使用者),以及機密的處理。
- **結構化錯誤**(\$4.4)— `isError` 旗標,以及為何通用錯誤會破壞復原。
- **資源**(\$4.5)— 消除探索性工具呼叫的唯讀「地圖」。

\$4.6 接著從頭到尾建構一個完整的內部 **Deployments MCP 伺服器**——伺服器、工具、資源、傳輸,以及一道權限守門——\$4.7 則濃縮考試重點。

4.1 什麼是 MCP

模型上下文協定(MCP)是一種用於將外部系統連接至 Claude 的開放標準。官方的比喻是「**AI 界的 USB-C**」:你不必為每一組模型與工具的搭配各寫一個客製轉接器,而是只實作一次協定,任何相容 MCP 的客戶端(Claude Code、Agent SDK、Claude 應用程式)都能使用你的伺服器。在底層,MCP 是走在某個傳輸之上的 **JSON-RPC 2.0**——一種小巧、規格明確的訊息格式,而非只屬於 Claude 的 API。

MCP 定義了三種主要原語:

1. **Tools** — 代理可以**呼叫**以執行動作的函式(CRUD 操作、API 呼叫、命令執行)。由模型驅動:由 Claude 決定何時使用。
2. **Resources** — 代理可以**讀取**以作為上下文的資料(文件、資料庫結構描述、內容目錄)。唯讀:它們提供資訊,而不執行動作。
3. **Prompts** — 用於常見任務的預先定義提示範本,呈現給使用者(例如以斜線命令的形式)。

心智模型是 client/server。 *host*(主機)應用程式(Claude Code、SDK)執行一個 MCP *client*;每個整合則是一個 MCP *server*——一個由你掌控的獨立程序。兩者透過某個傳輸溝通(S4.2)。

```
flowchart TD
    subgraph Host[Host 應用程式 例如 Claude Code]
        Model[Claude 模型]
        C1[MCP client 1]
        C2[MCP client 2]
    end
    Model --> C1
    Model --> C2
    C1 -->|走傳輸的 JSON-RPC| S1[MCP server<br/>GitHub]
    C2 -->|走傳輸的 JSON-RPC| S2[MCP server<br/>內部服務]
    S1 --> EXT1[GitHub API]
    S2 --> DB[(內部資料庫)]
```

為何這種分離很重要(以及考試會探問什麼): 因為每個伺服器都是位於標準協定之後的獨立程序,你能得到隔離性(伺服器當掉不會拖垮主機)、各伺服器獨立的認證,以及跨主機的重用。考試把 MCP 定位為**整合層**——也就是你在不修改代理本身的前提下,賦予代理新能力的方式。

Tools 與 Resources 的區分是反覆出現的考點。 一個常見錯誤是把唯讀資料以工具的形式暴露。如果代理只需要**知道**某件事(服務清單、結構描述),那它就是 **Resource**。如果它需要**對某件事**採取帶有副作用的動作(觸發部署、寫入一列),那它就是 **Tool**。弄錯這點會膨脹工具數量——而根據 Domain 2,這會直接傷害工具選擇的可靠性。

4.2 MCP 伺服器與傳輸

MCP 伺服器是一個實作 MCP 協定、並暴露工具、資源或提示的程序。當客戶端連接至伺服器時:

- 所有工具都會在連接時**自動被探索**(客戶端呼叫 `tools/list`)。
- 來自**所有已連接伺服器**的工具會**一次全部可用**給模型。
- **工具描述**決定了模型將如何使用它們——描述是主要的選擇訊號(Domain 2.1)。描述含糊就代表選擇不可靠。

為避免跨伺服器的名稱衝突,主機會為工具加上命名空間。在 Claude Code 中,某伺服器的工具會以 `mcp__<server>__<tool>` 的形式出現——例如名為 `deployments` 的伺服器上的 `query_status` 工具,就是 `mcp__deployments__query_status`。當你為工具設定許可清單或強制 `tool_choice` 時,就引用這個完整名稱。

stdio 與 Streamable HTTP

MCP 定義了**兩種標準傳輸**,而在兩者之間做選擇,是考試預期你能做出的架構決策:

	stdio	Streamable HTTP
拓撲	本地子程序(由主機啟動)	遠端服務(POST 請求 + SSE 串流)
最適合	本地工具、開發、單一使用者、檔案系統/CLI 存取	團隊共用伺服器、託管 SaaS 整合
認證	以環境為基礎的憑證(環境變數)	OAuth 2.0
生命週期	主機產生/結束該程序	由你部署並維運的長時運行服務

```
flowchart TD
    H[Host: Claude Code 或 SDK] --> D{伺服器在<br/>哪裡執行?}
    D -->|同一台機器 各使用者| STDIO[stdio 傳輸<br/>產生本地子程序<br/>環境變數憑證]
    D -->|共用的遠端服務| HTTP[Streamable HTTP<br/>POST 加 SSE<br/>OAuth 2.0]
    STDIO --> R[工具與資源<br/>暴露給模型]
    HTTP --> R
```

陷阱與考試角度：

- **舊的純 SSE 傳輸已被棄用。** 如果題目把「SSE 傳輸」當作現代的遠端選項,當前正確答案是 **Streamable HTTP**(POST + SSE)。不要選舊的 SSE。
- **讓傳輸符合認證模型。** 一個持有特權憑證的團隊共用伺服器,應該採用 **Streamable HTTP 搭配 OAuth**, 而不是讓每個使用者各自貼上 token 的 stdio 伺服器。反過來,個人的本地檔案系統工具應採用 **stdio 搭配環境變數**——為它架設一個 OAuth 服務是過度設計。
- **伺服器並不是「Claude code」。** 它是一個通用程序。同一個 `deployments` 伺服器可以同時服務 Claude Code、Agent SDK 與 Claude 桌面應用程式——這種重用正是這套標準的重點。

對於遠端伺服器,Messages API 中還有 **MCP connector**:Claude 可以在伺服器端直接呼叫遠端 MCP 伺服器,完全不需本地客戶端——你傳入一個 `mcp_servers` 項目,外加 `tools` 中一個對應的 `mcp_toolset`。這是 Claude Code HTTP 伺服器在 API 層級的對應物;傳輸的部分(HTTP + OAuth)是一樣的。

4.3 設定 MCP 伺服器

你在哪裡註冊伺服器,決定了**誰能使用它**——這個範圍決策正是 Domain 2.4 的考點。

專案設定(`.mcp.json`) — 供團隊使用:

```
{
  "mcpServers": {
    "github": {
      "command": "npx",
      "args": ["-y", "@modelcontextprotocol/server-github"],
      "env": {
        "GITHUB_TOKEN": "${GITHUB_TOKEN}"
      }
    },
    "jira": {
      "command": "npx",
      "args": ["-y", "mcp-server-jira"],
      "env": {
        "JIRA_TOKEN": "${JIRA_TOKEN}"
      }
    }
  }
}
```

重點:

- `.mcp.json` 儲存於專案根目錄,並由版本控制管理,因此每位貢獻者在簽出時都會取得相同的伺服器。
- 環境變數(`${GITHUB_TOKEN}`)用於存放機密——被提交的是變數 參照,而非 token 本身。這是核心的機密管理模式:絕不要把 token 硬編碼進 `.mcp.json`。
- 對所有專案貢獻者皆可用。

使用者設定(`~/.claude.json`) — 供個人/實驗性伺服器使用:

- 儲存於使用者的家目錄。
- 不透過版本控制共用。
- 適合個人實驗與測試。

```
flowchart TD
    Q{這個伺服器<br/>應該給誰?}
    Q -->|整個團隊 可重現| PROJ[專案根目錄的 .mcp.json<br/>提交進 git<br/>環境變數 token 參照]
    Q -->|只有我 實驗性| USER[~/.claude.json<br/>家目錄<br/>不進版本控制]
    PROJ --> TEAM[所有貢獻者在簽出時<br/>都取得它]
    USER --> SOLO[只有這位開發者]
```

從 CLI 新增伺服器。 在 Claude Code 中,你不必手動編輯 JSON: `claude mcp add` / `claude mcp list` / `claude mcp remove` 可管理伺服器,而 `--scope user` 與 `--scope project` 則選擇要寫入哪個檔案。對於需要 OAuth 的 HTTP 伺服器,在工作階段中執行 `/mcp` 即可授權。對於「如何讓每位開發者都取得相同的伺服器,而不必各自手動編輯設定」這個問題,考試的正確答案就是:把它放進專案的 `.mcp.json`,提交一次即可。

選擇伺服器:

- 對於標準整合(Jira、GitHub、Slack),優先採用現有的社群 MCP 伺服器——它們有人維護且經過實戰考驗。

- 只有針對沒有任何社群伺服器涵蓋、且獨特的團隊專屬工作流程,才自行建置伺服器(這正是 §4.6 的案例研究)。

上下文成本 — MCP 工具搜尋。 每個已連接伺服器的工具都會被載入上下文,十幾個伺服器可能讓模型湧入數百個工具——膨脹上下文並降低選擇品質(Domain 2.3:工具太多會降低可靠性)。Claude Code 的 **MCP 工具搜尋**透過按需延遲載入工具(而非一次預先載入全部)來緩解此問題,組織也可以推送一份全組織的 `managed-mcp.json`。重點是:連接一個伺服器並非沒有代價;工具數量是一種預算。

4.4 MCP 中的 `isError` 旗標

當 MCP 工具遇到錯誤時,它會在回應中設定 `isError: true`。這會向代理發出該呼叫失敗的訊號——但光是發出失敗訊號還不夠。代理的下一步(重試?變更查詢?升級?放棄?)完全取決於那是哪一種失敗。這是 Domain 2.2 的核心,也是 Domain 5 的可靠性關切。

結構化錯誤(良好):

```
{
  "isError": true,
  "content": {
    "errorCategory": "transient",
    "isRetryable": true,
    "message": "The service is temporarily unavailable. Timeout while calling the
orders API.",
    "attempted_query": "order_id=12345",
    "partial_results": null
  }
}
```

通用錯誤(反模式):

```
{
  "isError": true,
  "content": "Operation failed"
}
```

通用錯誤無法為代理的決策提供任何資訊——它應該重試、變更查詢,還是升級?結構化的版本則能精確地告訴它。

考試預期你能區分的錯誤類別:

類別	含義	可重試?	代理的正確回應
<code>transient</code>	逾時、服務短暫中斷	是	重試(最好搭配退避)
<code>validation</code>	輸入錯誤(id 格式錯誤、缺欄位)	否	修正參數後再重試
<code>business</code>	政策/規則違反(例如超過上限)	否	停止並向使用者說明;不要重試同一個呼叫
<code>permission</code>	呼叫者缺乏存取權	否	升級/請求存取權——與「無結果」截然不同

```

flowchart TD
    E[工具回傳 isError true] --> CAT{errorCategory?}
    CAT -->|transient| RETRY[搭配退避重試]
    CAT -->|validation| FIX[修正參數<br/>後再重試]
    CAT -->|business| STOP[停止並說明<br/>不要重試]
    CAT -->|permission| ESC[升級或請求存取權]
    RETRY --> OK[盡可能在本地解決]
    FIX --> OK

```

陷阱與考試角度：

- **對業務規則違反使用 `isRetryable: false`**，並附上清楚、面向使用者的說明。把政策失敗標為可重試，會讓代理陷入毫無意義的重試迴圈。
- **空結果不是錯誤。** 一個合法地什麼都沒找到的搜尋，應回傳 `isError: false` 並附上空結果集——而非 `isError: true`。把「無相符項」與「存取失敗」混為一談，會讓代理在本該只回報「找不到」時去升級 (Domain 2.2)。
- **在本地復原，有選擇地向上傳遞。** 子代理應自行解決暫時性失敗(重試)，只把它確實無法解決的錯誤向上傳遞給協調者——這能讓錯誤雜訊不流入中心輻射式系統(Domain 5.3)。

4.5 MCP 資源

Resources 是代理可以請求以取得上下文、但**不採取行動**的資料。工具負責**執行**，資源則負責**提供資訊**：

- 內容目錄(例如所有專案任務的清單、階層式導覽)。
- 資料庫結構描述(在查詢前理解資料結構)。
- 文件(API 參考、內部指南)。
- 議題/任務摘要。

資源的優勢：代理**不需要**透過探索性的工具呼叫，就能發現有哪些資料存在。資源提供了一份即時的「地圖」。少了它，代理可能光是為了在做任何實質工作之前搞清楚系統的樣貌，就燒掉三、四次工具呼叫(以及它們所耗費的 token 與延遲)。

```

flowchart TD
    subgraph Without[沒有資源]
        A1[代理猜測] --> A2[工具呼叫：列出 X]
        A2 --> A3[工具呼叫：描述 X]
        A3 --> A4[工具呼叫：尋找 Y]
        A4 --> A5[終於採取行動]
    end
    subgraph With[有目錄資源]
        B1[讀取資源：那份地圖] --> B2[直接採取行動]
    end

```

陷阱與考試角度：

- **不要把唯讀的上下文塑造成工具。** 如果代理只需要**讀取**服務目錄，就把它暴露為 **Resource**，而非一個 `list_services` 工具。這能壓低工具數量(有助於選擇)，並正確地傳達意圖。

- **資源能削減探索性的工具呼叫**,這正是考試使用的措辭——它們用一次預先讀取,換掉多次來回往返。這既是上下文管理的勝利(Domain 5),也是工具設計的勝利(Domain 2)。
- **資源依定義即為唯讀**——它們從不帶有副作用。如果你發現自己想讓資源「順便更新」某件事,那你其實要的是一個工具。

4.6 端到端案例研究:一個內部「Deployments」MCP 伺服器

上述的各個零件,唯有組裝在一起時才有意義。以下是一個完整、貼近真實的 MCP 伺服器——正是 §4.3 所說、你應該自行建置的那種獨特、**團隊專屬**的整合,也正是考試的 MCP 整合情境會探問的設計。

需求

某平台團隊希望 Claude Code 能在事故處理期間提供協助。代理必須能夠:

- **檢視服務目錄**——每個服務、其擁有者與目前版本——而不必進行探索性呼叫。
- **查詢某個服務的部署狀態**(唯讀)。
- **觸發回滾(rollback)**,把某個服務退回到前一個版本(一個帶有真實後果的**動作**)。
- **硬性規則**: 對**生產環境**服務的回滾,除非呼叫者持有明確的 `prod-rollback` 授權,否則必須在**協定層級被拒絕**——絕不交由模型自行裁量。
- **回傳結構化錯誤**,讓代理能正確復原(重試一次不穩定的狀態檢查,但絕不重試一個被拒絕的生產回滾)。
- 為待命工程師在本地以 **stdio** 執行,而同一個伺服器也作為團隊共用的 **Streamable HTTP** 服務(OAuth)執行。

架構

```
flowchart TD
    User([待命工程師]) --> CC[Claude Code host]
    CC -->|走 stdio 或 HTTP 的 JSON-RPC| Srv[Deployments MCP server]
    Srv --> Res[Resource: service-catalog<br/>唯讀地圖]
    Srv --> T1[Tool: query_status<br/>唯讀]
    Srv --> T2[Tool: trigger_rollback<br/>動作]
    T2 --> Guard{生產環境 且 無授權?}
    Guard -->|是| Deny[回傳 isError<br/>permission 不可重試]
    Guard -->|否| Exec[執行回滾]
    T1 --> DEP[(部署系統)]
    Exec --> DEP
```

目錄是一個 **Resource**(唯讀的上下文,無探索性呼叫);**狀態與回滾**是 **Tools**(狀態用於讀取,回滾用於動作);**生產守門**位於伺服器中,而非位於提示裡——因此無論是哪個主機或模型連接進來,它都成立。

實作

一個使用 Python MCP SDK 的最小伺服器。目錄是一個資源;狀態與回滾是工具;生產守門回傳一個**結構化的權限錯誤**。


```

from mcp.server import Server
from mcp.types import Tool, Resource, TextContent
import mcp.server.stdio

app = Server("deployments")

# --- Resource: the service catalog (read-only "map") ---
@app.list_resources()
async def list_resources() -> list[Resource]:
    return [Resource(
        uri="catalog://services",
        name="Service catalog",
        description="All services, owners, and current versions.",
        mimeType="application/json",
    )]

@app.read_resource()
async def read_resource(uri: str) -> str:
    # Returns the catalog JSON: [{service, owner, env, version}, ...]
    return get_service_catalog_json()

# --- Tools ---
@app.list_tools()
async def list_tools() -> list[Tool]:
    return [
        Tool(name="query_status",
            description="Read the current deployment status of one service. Read-only.",
            inputSchema={"type": "object",
                "properties": {"service": {"type": "string"}},
                "required": ["service"]}),
        Tool(name="trigger_rollback",
            description="Roll a service back to its previous version. Mutating action.",
            inputSchema={"type": "object",
                "properties": {"service": {"type": "string"}},
                "required": ["service"]}),
    ]

@app.call_tool()
async def call_tool(name: str, args: dict) -> list[TextContent]:
    if name == "query_status":
        try:
            status = deployment_api.status(args["service"])
        except TimeoutError:
            return error("transient", retryable=True,
                message="Deployment API timed out; safe to retry.")
        return ok(status)

    if name == "trigger_rollback":
        svc = catalog.get(args["service"])
        # The production guard – code, not a prompt. The model cannot bypass it.
        if svc.env == "production" and not caller_has_grant("prod-rollback"):
            return error("permission", retryable=False,
                message="Production rollback denied: 'prod-rollback' grant required.")

```

```
result = deployment_api.rollback(args["service"])
return ok(result)
```

結構化錯誤的輔助函式讓每一個失敗都保持機器可讀(\$4.4):

```
def error(category, retryable, message):
    payload = {"errorCategory": category, "isRetryable": retryable, "message":
message}
    return [TextContent(type="text", text=json.dumps(payload))] # isError set on
the response
```

在本地以 **stdio** 執行:

```
async def main():
    async with mcp.server.stdio.stdio_server() as (read, write):
        await app.run(read, write, app.create_initialization_options())
```

把它註冊為專案伺服器,讓整個團隊在簽出時都取得它(\$4.3)——以 stdio 供本地使用,並搭配一個團隊共用的 HTTP+OAuth 部署:

```
{
  "mcpServers": {
    "deployments": {
      "command": "python",
      "args": ["-m", "deployments_server"],
      "env": { "DEPLOY_API_TOKEN": "${DEPLOY_API_TOKEN}" }
    }
  }
}
```

在 Claude Code 中,這些工具現在會以 `mcp__deployments__query_status` 與 `mcp__deployments__trigger_rollback` 出現,目錄則作為一個可讀取的資源。

執行軌跡

一位待命工程師請 Claude Code 回滾一個他無權操作的生產環境服務:

```
sequenceDiagram
    actor Eng as 待命工程師
    participant CC as Claude Code
    participant S as Deployments server
    participant G as 生產守門
    Eng->>CC: 「回滾 checkout-api, 它在報錯」
    CC->>S: 讀取資源 catalog://services
    S-->>CC: checkout-api 屬於 env production
    CC->>S: 呼叫 trigger_rollback(checkout-api)
    S->>G: 生產環境 且 無 prod-rollback 授權?
    G-->>S: 拒絕
    S-->>CC: isError permission 不可重試
    CC-->>Eng: 「已阻擋:生產回滾需要 prod-rollback 授權。正在升級。」
```

請注意 Claude 本想直接回滾;**伺服器的守門確定性地拒絕了它**,而且因為該錯誤被歸類為 `permission` /不可重試,代理選擇了升級而非陷入迴圈。一條提示指令(「未經核准不要回滾生產環境」)只會在約 90% 的時候被遵守——對生產環境而言並不夠好。

驗證

- **權限測試:** 在沒有授權的情況下,對一個生產環境服務呼叫 `trigger_rollback` 100 次;斷言收到 100 個結構化的 `permission` 錯誤、零次回滾。這道守門必須是 100%,如同 §3.5 的金額規則。
- **錯誤類別測試:** 模擬一次 `query_status` 逾時並斷言得到 `transient / retryable: true`;模擬一次被拒絕的生產回滾並斷言得到 `permission / retryable: false`。代理應重試前者、且絕不重試後者。
- **資源 vs 工具測試:** 確認目錄可透過 `read_resource` 取得(無工具呼叫)——證明代理不必經由探索性呼叫就能得到它的「地圖」 (§4.5)。
- **空結果 vs 錯誤測試:** 查詢一個不存在的服務,應是一個乾淨的「找不到」結果,而非 `isError: true` (§4.4)。

常見陷阱

- 把生產回滾規則放進系統提示,而非放進**伺服器守門**(機率性,而非有保證——見 §3.5 與 §4.4)。
- 把目錄暴露為一個 `list_services` **工具**,而非一個 **Resource**,膨脹了工具數量並逼出探索性呼叫 (§4.5)。
- 回傳 `"Operation failed"` 而非一個已歸類的錯誤,使代理無法分辨一個可重試的逾時與一個硬性拒絕 (§4.4)。
- 把 `DEPLOY_API_TOKEN` 硬編碼進 `.mcp.json`,而非使用 `${...}` 環境變數參照 (§4.3)。
- 為共用的遠端部署選擇了舊版 **SSE**,而非 **Streamable HTTP**(§4.2)。

4.7 考試重點 — 關鍵要點

概念	考試測什麼
原語	Tools 執行動作、Resources 提供資訊(唯讀)、Prompts 是範本;MCP 是開放的 JSON-RPC 標準,「AI 界的 USB-C」 (§4.1)。

Client/server	主機執行 client;每個整合都是一個獨立的伺服器程序——隔離性與跨主機重用(\$4.1)。
傳輸	stdio (本地子程序,環境變數認證)vs Streamable HTTP (遠端,OAuth);舊的純 SSE 已被棄用(\$4.2)。
範圍與機密	<code>.mcp.json</code> (專案、提交、團隊)vs <code>~/.claude.json</code> (使用者);token 用 <code>\${VAR}</code> ——絕不提交機密本身(\$4.3)。
工具數量	所有已連接伺服器的工具會一次載入;太多會降低選擇品質——MCP 工具搜尋採延遲載入(\$4.2–4.3)。
結構化錯誤	<code>isError</code> + <code>errorCategory</code> / <code>isRetryable</code> ;transient → 重試,business/permission → 停止;空結果 ≠ 錯誤(\$4.4)。
資源	消除探索性工具呼叫的唯讀「地圖」;不要把唯讀上下文塑造成工具(\$4.5)。

對應 **Domain 2(18%)**,並直接支援 Domain 1(工具即代理的能力)與 Domain 5(結構化錯誤讓多代理系統維持可靠)。只要你能建構並捍衛上述的 Deployments 伺服器——原語、傳輸、範圍、伺服器端守門,以及已歸類的錯誤——你就掌握了 MCP 整合領域的核心。

第 5 章:Claude Code — 設定與工作流程

文件:[Claude Code](#) | [Memory / CLAUDE.md](#) | [Skills](#) | [MCP](#) | [Hooks](#) | [Sub-agents](#) | [Settings](#) | [GitHub Actions](#) | [Headless](#)

第 3、4 章是用程式建構代理——你親手寫的迴圈、子代理、hooks 與 MCP。**Claude Code 則是同一套機制,以「可設定的工具」形式交付**,而非你呼叫的函式庫。這裡考試考的技能是**設定**:把正確的指令放進正確的檔案、為規則設定範圍讓它只在相關時才載入、以確定性方式管控危險工具,並把 Claude Code 接進團隊的 CI。本章是 **Domain 3 — Claude Code 設定與工作流程(佔考試 20%)** 的骨幹——僅次於代理編排,是第二大領域。

讀完你應能掌握六根支柱,並把它們組裝成可供團隊使用的設定:

- **CLAUDE.md 階層**(\$5.1–5.3)— 指令放在哪、`@path` 匯入如何使其模組化,以及 `.claude/rules/` 如何條件式載入慣例。
- **可重複使用的工作流程**(\$5.4–5.5)— 自訂斜線命令與技能,包含 `context: fork` 隔離與 `allowed-tools` 限制。
- **設定、權限與 hooks**(\$5.6)— `settings.json` 的優先順序、逐工具的 allow/ask/deny,以及用於確定性強制執行的生命週期 hooks。
- **規劃 vs 直接執行**(\$5.7)— 何時先調查再核准,何時直接動手。
- **上下文與工作階段管理**(\$5.8、\$5.10)— `/compact`、`/memory`、`--resume` 與 `fork_session`。
- **CI/CD 整合**(\$5.9)— headless 的 `-p`、結構化 JSON 輸出,以及審查工作階段的隔離。

\$5.11 接著從頭到尾組裝一個完整的**團隊上線設定**——階層、規則、一個技能、一個 MCP 伺服器、一個權限 hook,以及 CI——\$5.12 則濃縮考試重點。

5.1 CLAUDE.md 階層

CLAUDE.md 是 Claude Code 在啟動時自動載入、並在每一回合作為上下文注入的指令檔。它具有三層階層,而且所有適用的層級會被合併,而非互相覆寫:

1. User-level: `~/.claude/CLAUDE.md`
 - 僅套用於該使用者、該機器
 - 不透過 VCS 共享
 - 個人偏好與工作風格(例如「用中文解釋」)
2. Project-level: `.claude/CLAUDE.md` 或根目錄的 `CLAUDE.md`
 - 套用於所有專案貢獻者
 - 透過 VCS 管理(已提交、經審查、共享)
 - 程式碼規範、測試規範、架構決策
3. Directory-level: 子目錄中的 `CLAUDE.md`
 - 在處理該目錄中的檔案時套用(按需載入)
 - 該部分程式碼庫特有的慣例

為何要有階層。 這三層把三種對象與三種生命週期分開:你(個人,從不共享)、團隊(版控,像程式碼一樣審查),以及某個子樹(在別處只會變成雜訊的在地慣例)。把指令放在錯誤的層級,正是考試最常考的 Claude Code 設定錯誤。

flowchart TD

```
Start[Claude Code 開始一回合] --> U[載入 user CLAUDE.md<br/>個人偏好]
U --> P[載入 project CLAUDE.md<br/>團隊標準]
P --> Q{正在編輯<br/>某子目錄中的檔案?}
Q -->|是| D[同時載入該<br/>目錄的 CLAUDE.md]
Q -->|否| Skip[略過目錄層級]
D --> Merge[將所有層級<br/>合併進上下文]
Skip --> Merge
Merge --> Run[Claude 帶著<br/>合併後的指令行動]
```

常見錯誤(考試最愛): 新進團隊成員收不到專案標準,因為有人把它放進 `~/.claude/CLAUDE.md` (user-level, 從不提交)而非 `.claude/CLAUDE.md` (project-level, 在 VCS 中)。要背的診斷問題是:「在隊友筆電上重新 `git clone` 一次,看得到這條指令嗎?」若必須看得到,它就屬於 **project** 層級。若那是不該強加於他人的個人習慣,它就屬於 **user** 層級。

考試角度: 區分每一層服務誰。個人風格 → user。團隊契約 → project(已提交)。在別處只會變成雜訊的子樹專屬慣例 → directory。

5.2 @path 語法(檔案匯入)

龐大的 CLAUDE.md 難以審查,還會讓內容在各套件間重複。CLAUDE.md 可以使用 `@path` 參照外部檔案,使設定模組化:

Project CLAUDE.md

Coding standards are described in @./standards/coding-style.md
Test requirements are in @./standards/testing-requirements.md
Project overview is in @README.md and dependencies are in @package.json

@path 的規則:

- 在檔案路徑前緊接著使用 @ (沒有空格)。
- 支援相對路徑與絕對路徑。
- 相對路徑會相對於包含該匯入的檔案來解析。
- 最大匯入巢狀深度為 5(被匯入的檔案本身還可再匯入,最多五層)。

為何重要。 匯入讓每項標準都有單一權威來源。一個 monorepo 可以只保留一份 standards/testing.md , 讓各套件的 CLAUDE.md 只拉進它真正需要的標準——web/ 套件匯入 React 規則、api/ 套件匯入服務規則,兩者都不背負對方的雜訊。它也讓你既能把既有專案檔案直接當成上下文重用(@README.md 、 @package.json),而不必把它們改寫進 CLAUDE.md——改寫版本會逐漸過時。

陷阱: @ 後面有空格會破壞匯入(它變成純文字);相對路徑是從匯入檔案所在的目錄解析,而非儲存庫根目錄,所以搬動一個 CLAUDE.md 可能會悄悄弄壞它的匯入;而深度 5 的限制意味著層層串接的匯入可能在沒有明顯錯誤的情況下被截斷。

考試角度: 當題目問如何避免在十個套件間重複同一份測試標準,答案是用 @path 匯入單一共享檔案——不是複製貼上,也不是一個巨大的根 CLAUDE.md。

5.3 .claude/rules/ 目錄

.claude/rules/ 是單一龐大 CLAUDE.md 的替代方案,用於依主題組織規則:

```
.claude/rules/  
  testing.md          -- 測試慣例  
  api-conventions.md  -- API 慣例  
  deployment.md       -- 部署規則  
  react-patterns.md   -- React 模式
```

關鍵特性:使用 paths 的 YAML frontmatter 進行條件式載入:

```
---  
paths: ["src/api/**/*"]  
---
```

For API files, use async/await with explicit error handling.
Each endpoint must return a standard response wrapper.

```
---
paths: ["**/*.test.tsx", "**/*.test.ts"]
---

Tests must use describe/it blocks.
Use data factories instead of hardcoding.
Do not mock the database—use a test database.
```

運作方式:

- 只有在 Claude Code 觸及符合 `paths` glob 的檔案時,規則才會被載入。
- 這可以節省上下文與 tokens——不相關的規則永遠不會被載入,讓模型的視窗專注在正在編輯的內容上。
- Glob 模式讓你能依檔案類型套用慣例,而不受位置影響(對於散落在程式碼庫各處的測試而言相當理想)。

為何條件式載入勝過一個大檔案。 CLAUDE.md 的每一行,在每一回合都要付出代價,不論它是否相關。一個 600 行的龐然大物會在你編輯 CSS 時還花上下文描述 Terraform 慣例。路徑範圍規則把這件事反轉:Terraform 規則在你打開 `.tf` 檔案之前都是隱形的,然後在它幫上忙時恰好出現。這與 MCP 資源(第 4 章)和工具搜尋背後「只載入相關內容」的原則相同——上下文是一筆預算,而規則讓你按需花用。

何時使用搭配 `paths` 的 `.claude/rules/`,而非 `directory-level CLAUDE.md`:

- 搭配 `paths` 的 `.claude/rules/` — 當慣例適用於**散布在許多目錄中的檔案**時(測試、遷移、`*.tf`)。像 `**/*.test.ts` 這樣的 glob 不論它們落在何處都能一網打盡。
- `Directory-level CLAUDE.md` — 當慣例與**某個特定目錄綁定**,且其他地方不需要時。

陷阱: 當測試檔案散落在數十個資料夾時,卻為測試寫一個 `directory-level CLAUDE.md`——你就得把它複製到每一個資料夾。glob 規則才是可維護的選擇。反過來說,為只會套用到單一資料夾的事物寫 glob 規則則是過度設計;一個 `directory CLAUDE.md` 更簡單。

****考試角度:****「慣例依檔案類型橫跨許多目錄」→ 帶 glob 的路徑範圍規則。「慣例屬於單一資料夾」→ `directory CLAUDE.md`。

5.4 自訂斜線命令與技能

****注意:****在目前的 Claude Code 版本中,自訂命令(`.claude/commands/`)已與技能(`.claude/skills/`)整合。兩種格式都會建立 `/name` 命令。考試指南所引用的是 `.claude/commands/`——該格式仍受支援。

斜線命令是透過 `/name` 叫用的**可重複使用提示範本**。與其每次重打「審查這份 diff 找安全問題、檢查 OWASP top 10、並行內回報」,你只要存一次,然後叫用 `/review`。

`.claude/commands/` 格式(舊版,仍受支援):

```
.claude/commands/
review.md      -- /review -- 標準程式碼審查
test-gen.md    -- /test-gen -- 測試產生
```

`.claude/skills/` 格式(目前):


```
.claude/skills/  
review/SKILL.md -- /review -- 含 frontmatter 設定  
test-gen/SKILL.md
```

專案命令(`.claude/commands/` 或 `.claude/skills/`):

- 儲存在 VCS 中,且任何人在複製儲存庫時都能取用。
- 確保團隊間**工作流程一致**——每位開發者的 `/review` 都做同一件事。

使用者命令(`~/.claude/commands/` 或 `~/.claude/skills/`):

- 不透過 VCS 分享的個人命令。
- 用於你不想強加於隊友的個人工作流程。

為何這是設定問題,而不只是便利性。 斜線命令把**臨時指令**變成**版控產物**。一旦 `/review` 住進儲存庫,審查提示就會像其他程式碼一樣被審查、隨時間改進,而且不會在工程師之間漂移。這正是考試所獎勵的團隊一致性特性。

****考試角度:****「團隊每個人都應跑同一套審查/測試流程」→ 放在 `.claude/` 的專案命令(已提交)。「我的個人捷徑」→ 放在 `~/.claude/` 的使用者命令。

5.5 技能 — `.claude/skills/`

技能是透過 SKILL.md frontmatter 設定的進階命令——是從純提示範本升級為**受治理**範本的路徑:

```
---  
context: fork  
allowed-tools: ["Read", "Grep", "Glob"]  
argument-hint: "要分析的目錄路徑"  
---
```

分析指定目錄中的程式碼結構。
輸出一份關於相依性與架構模式的報告。

Frontmatter 參數:

參數	描述
<code>context:</code> <code>fork</code>	在 隔離的子代理 中執行技能。它冗長的輸出不會汙染主工作階段——只有最終結果會回傳(與 Agent SDK 的 <code>Task</code> 相同的隔離,\$3.4)。
<code>allowed-tools</code>	限制有哪些工具可用。安全邊界:一個只被授予 <code>["Read", "Grep", "Glob"]</code> 的唯讀分析技能,即使提示被操弄,也無法寫入或刪除檔案。
<code>argument-hint</code>	在未帶參數叫用命令時顯示的提示,要求使用者提供所需的引數。

為何 `context: fork` 是招牌特性。 一個分析技能可能讀 40 個檔案、印出好幾頁輸出。在主工作階段中,這會埋掉你的工作上下文;而 `fork` 之後,雜訊被收束,你拿回的是一段摘要。這是 Skill 層級對應於 Explore 子代理(\$5.7)的做法——以隔離上下文作為一等、宣告式的設定。

為何 `allowed-tools` 是真正的安全控制。它是把最小權限原則(\$3.2)套用到工作流程:能力固定在 frontmatter 裡、寫在程式碼中,而非在提示裡協商。一個只能讀取的技能,放在不可信的輸入上執行也安全,因為沒有任何提示能授予它從未被賦予的寫入權限。

何時使用技能 vs CLAUDE.md:

- **技能** — 針對特定任務(審查、分析、產生)的**按需**叫用。你想要時才跑它。
- **CLAUDE.md** — 永遠載入的一般標準與慣例。不論你問不問,它都套用於每一回合。

個人技能(`~/ .claude/skills/`): 以不同名稱建立個人變體,如此就不會影響團隊成員。

陷阱: 把笨重、偶爾才用的任務(一次完整的架構稽核)放進 CLAUDE.md 好讓它「永遠可用」——那會在每一回合浪費上下文。稽核屬於一個你需要時才叫用的 `context: fork` 技能。

****考試角度:**** 「把冗長技能的輸出與主工作階段隔離」 → `context: fork`。「阻止技能刪除檔案」 → `allowed-tools`。「只在被要求時才跑某任務」 → 技能,而非 CLAUDE.md。

5.6 設定、權限與 Hooks

指令告訴模型要**做什麼**; `settings.json` 與**權限控制**它**被允許做什麼**,而 **hooks** 讓某些規則具備**確定性**。這就是 Claude Code 不再只是個有禮貌的助理、轉而成為受治理工具之處——考試把它視為安全層。

`settings.json` **優先順序**。設定來自三個檔案,依優先序由低到高套用:

- | | | |
|----------------------|--|---------------------|
| 1. User settings: | <code>~/ .claude/settings.json</code> | (你的機器、所有專案) |
| 2. Project settings: | <code>.claude/settings.json</code> | (已提交、與團隊共享) |
| 3. Local overrides: | <code>.claude/settings.local.json</code> | (每位開發者、git-ignored) |

優先序較高的檔案會覆寫較低檔案中的同一個鍵。要記住的模式是:把 `.claude/settings.json` 提交為團隊契約;把個人微調放進 `.claude/settings.local.json` (git-ignored),這樣它們就不會洩漏進共享設定。

企業層級:伺服器託管設定(凌駕上述三者)。對 Claude for Teams/Enterprise,組織 **Owner** 可從 claude.ai 主控台(**Admin Settings** → **Claude Code** → **Managed settings**)推送第四層、最高優先序的設定——無需裝置管理(MDM)基礎設施;用戶端會在驗證時取得,並每小時重新輪詢一次。**這個託管層凌駕於所有本機檔案甚至命令行旗標之上——開發者所設定的任何東西都無法覆寫它。** 它承載與 `settings.json` 相同的鍵——

`permissions.deny` 清單、`disableBypassPermissionsMode`、

`allowManagedPermissionRulesOnly` (把權限鎖定為僅限託管集合)、環境變數與 hooks——因此下方的護欄會變成**組織範圍的政策**,而非逐儲存庫的設定。一項搭配的管理控制項可設定**組織層級(或逐角色)的預設模型**: `/model` 選擇器的 *Default* 列便會解析為它,並標示為 *Org default*——但這一項是 `--model` 與

`ANTHROPIC_MODEL` 仍可覆寫的軟預設,而非鎖定(需要 Claude Code v2.1.196+)。在

Bedrock/Vertex/Foundry 上,由於無法透過伺服器遞送,改由自架的 **Claude apps gateway** 執行等效的遞送。**考試注意:** 託管設定是**用戶端**控制,而非安全邊界——經修改的執行檔、較舊的用戶端,或第三方供應商都能繞過它。來源:[server-managed settings](#)、[model configuration](#)。

權限:逐工具的 allow / ask / deny。 權限住在 `settings.json` 裡,可管控個別工具、甚至工具的引數:

```
{
  "permissions": {
    "allow": ["Read", "Grep", "Glob", "Bash(npm test:*)"],
    "ask":   ["Edit", "Write"],
    "deny":  ["Bash(rm -rf:*)", "Bash(git push:*)"]
  }
}
```

- **allow** — 不詢問即執行(安全、頻繁的操作,例如跑測試)。
- **ask** — 每次使用前都詢問確認(對編輯採人類介入)。
- **deny** — 直接封鎖;不論模型如何決定都無法執行。

`deny` 勝過 `allow`。對 `git push` 的 `deny` 意味著沒有任何提示能說服 Claude Code 去推送——它不是強烈建議,而是一道牆。

Hooks:確定性的生命週期強制執行。 Hooks 是 harness 在生命週期事件時執行的 shell 命令——`PreToolUse`、`PostToolUse`、工作階段開始/結束,以及壓縮。你在 Agent SDK 中寫過的同一批 hooks(\$3.5)也存在於 Claude Code,設定在 `settings.json` 裡。`PreToolUse` hook 可以在工具呼叫執行之前檢查它並封鎖它(以非零結束碼):

```
{
  "hooks": {
    "PreToolUse": [
      {
        "matcher": "Bash",
        "hooks": [
          { "type": "command", "command": ".claude/hooks/block-secrets.sh" }
        ]
      }
    ]
  }
}
```

該腳本會從 stdin 收到工具呼叫;若它偵測到比方說一個會讀取 `.env` 或推送到 `main` 的命令,它就以非零結束,該動作即被拒絕——**確定性地、以程式碼,而非交由模型裁量。**

Hooks/權限 vs 提示指令(反覆出現的考試主題)。

機制	保證	用於
<code>deny</code> 權限 / <code>PreToolUse</code> hook	確定性(100%)	「絕不推送到 main」、「絕不刪除資料庫」、「封鎖機密外洩」
CLAUDE.md 指令	機率性(>90%,並非 100%)	「偏好小型提交」、「解釋推理」、「大型重構前先詢問」

規則(與 §3.5 相同): 當違規會造成財務、法律、安全或安危後果時,用 `deny` 權限或 hook 來強制執行——而非 CLAUDE.md 裡的一句話。遵循提示的模型多數時候是對的; `deny` 規則則每次都對。

陷阱: 在 CLAUDE.md 裡寫「Claude 絕不可執行 `git push --force`」並相信它已被強制執行。並沒有——那只是強烈的推力。保證住在 `permissions.deny` 或 `PreToolUse` hook 裡。

考試角度: 任何「保證這個危險動作不會發生」→ 權限/hook(確定性)。任何「鼓勵這個好習慣」→ CLAUDE.md(機率性)。個人 vs 共享設定 → `settings.local.json` (git-ignored) vs 已提交的 `settings.json`。

5.7 規劃模式 vs 直接執行

規劃模式:

- 模型只進行調查與規劃;**不會**做出變更。
- 使用 Read、Grep、Glob 探索程式碼庫。
- 在任何編輯之前產生一份由使用者核准的實作計畫。
- 安全探索,**不產生副作用**。

何時使用規劃模式:

- 大型變更(數十個檔案)。
- 多種看似可行的做法(微服務:該如何定義邊界?)。
- 架構決策(用哪個框架?採用什麼結構?)。
- 不熟悉的程式碼庫(變更前必須先理解)。
- 影響 45 個以上檔案的函式庫遷移。

何時使用直接執行:

- 具有明確堆疊追蹤的單檔修正。
- 新增一項驗證檢查。
- 充分理解、不模糊的變更。

```
flowchart TD
    Task[傳入的任務] --> Q1{多檔案或  
有架構影響?}
    Q1 -->|是| Plan[規劃模式  
調查, 不編輯]
    Q1 -->|否| Q2{明確、單檔、  
不模糊的修正?}
    Q2 -->|是| Direct[直接執行  
現在就改]
    Q2 -->|否| Plan
    Plan --> Approve{使用者核准  
計畫?}
    Approve -->|是| Direct
    Approve -->|否| Plan
    Direct --> Done[變更已套用]
```

為何這個區分重要。 在龐大、模糊的變更上直接執行,會冒著朝錯誤方向做出數十處編輯、且回復代價高昂的風險。規劃模式把成本前置成一份便宜、可逆的產物——一份你能在動到任何檔案之前用一句話就修正的書面計畫。反過來說,為一行錯字的修正硬套上規劃與核准循環,純粹是額外負擔。

結合做法(考試偏好的答案):

1. 以規劃模式進行調查與設計。
2. 使用者核准計畫。

3. 以直接執行來實作已核准的計畫。

Explore 子代理 — 用於探索程式碼庫的專用于代理：

- 將冗長的探查輸出與主上下文隔離。
- 只回傳一份摘要。
- 防止在多階段任務中耗盡上下文視窗(與 `context: fork` 相同的上下文隔離概念, §5.5)。

陷阱: 用直接執行跑一個 45 檔的遷移,做到一半才發現做法錯了。先規劃、核准,再執行。

考試角度: 大型/模糊/架構性 → 規劃模式; 小型/明確/單檔 → 直接執行; 「在不撐爆上下文視窗的情況下探索大型程式碼庫」 → Explore 子代理。

5.8 `/compact` 與 `/memory` 命令

這兩個內建命令分別管理工作階段內與跨工作階段的上下文。

`/compact` — 壓縮目前的上下文。

- 摘要先前的歷史記錄,以釋放上下文視窗。
- 用於長時間的調查工作階段,當視窗被冗長的工具輸出填滿時。
- **風險:** 確切的數值、日期與特定細節可能在摘要過程中遺失。若你之後會需要精確數字,請在壓縮之前把它記下來(放進 `/memory` 或一則筆記)。

`/memory` — 跨工作階段保存上下文。

- 開啟 `CLAUDE.md` 檔案進行編輯,讓你能儲存筆記、偏好設定與上下文。
- 資訊會跨工作階段持續保存,並在啟動時自動載入。
- 適合用於儲存專案慣例、使用者偏好、常用命令以及目前的工作上下文。
- 取代在每個工作階段重新解釋相同指令的做法。

為何兩者並存。 `/compact` 對抗單一工作階段的限制——視窗有限,而冗長的工具輸出會吃掉它。`/memory` 對抗跨工作階段的限制——新的工作階段是一片空白,所以任何值得保留的東西都必須寫進 `CLAUDE.md`。一個現在回收空間;另一個把知識帶往未來。

陷阱: 把你還需要的數值壓縮掉。壓縮在設計上就是有損的——把任何不在 `CLAUDE.md` 或沒寫下來的東西,都視為 `/compact` 之後可能消失。

****考試角度:**** 「調查到一半上下文視窗滿了」 → `/compact` (並當心遺失的細節)。「不想每個工作階段都重新解釋慣例」 → `/memory` → `CLAUDE.md`。

5.9 用於 CI/CD 的 Claude Code CLI

`-p` (或 `--print`) 旗標:

```
claude -p "Analyze this pull request for security issues"
```

- 非互動(headless)模式:處理提示、輸出到 `stdout`,然後結束。

- 不等待使用者輸入——所以它永遠不會卡住管線。
- 在 CI/CD 中執行 Claude Code 的唯一正確方式。

用於 CI 的結構化輸出:

```
claude -p "Review this PR" --output-format json --json-schema
'{"type":"object",...}'
```

- `--output-format json` — 輸出 JSON 而非散文。
- `--json-schema` — 依結構描述驗證輸出,讓下游步驟拿到可預期的形狀。
- 結果可被管線解析,以自動張貼行內 PR 留言。

為何在 CI 中 headless 模式不可妥協。 互動式 Claude Code 會等待真人;CI runner 沒有真人,所以互動式的叫用會一直阻塞直到逾時。 `-p` 跑一次就結束,結果在 stdout 上——這正是建置步驟所需的契約。把它與儲存庫中已提交的 CLAUDE.md 搭配,讓 CI 執行自動繼承團隊的測試標準與審查準則。

工作階段上下文隔離(微妙但會考)。 產生程式碼的同一個 Claude 工作階段,在審查它時較不有效——它會保留自己的推理,較不可能挑戰自己的決定。**用獨立的執行個體進行審查**,而非寫程式的那一個。(這呼應 §5.10: 全新的視角勝過已被定錨的視角。)

避免重複留言。 在新的提交後重新審查時,將先前的審查結果納入上下文,並指示 Claude 只回報**新的或尚未解決**的問題——否則每次執行都會重貼相同的發現。

****考試角度:****「在管線中執行 Claude」→ `-p` (絕不互動)。「給自動留言用的機器可解析結果」→ `--output-format json` + `--json-schema`。「為何不重用產生程式碼的工作階段來審查?」→ 它不會挑戰自己的作品;用一個全新的執行個體。

5.10 `fork_session` 與工作階段管理

`--resume <session-name>` 恢復一個具名工作階段:

```
claude --resume investigation-auth-bug
```

- 以已儲存的上下文繼續先前的對話。
- 適合跨多個工作階段的長期調查。
- **風險:** 若檔案自先前工作階段以來已變更,快取的工具結果可能已過時——Claude 會在一份過時的快照上推理。

`fork_session` 從共享上下文建立一個獨立分支:


```
flowchart TD
    Base[程式碼庫調查<br/>共享上下文] --> Fork[fork_session]
    Fork --> A[做法 A<br/>Redux]
    Fork --> B[做法 B<br/>Context API]
    A --> CompareA[評估 A 的取捨]
    B --> CompareB[評估 B 的取捨]
    CompareA --> Pick[比較並選擇]
    CompareB --> Pick
```

- 兩個分叉都繼承到分支點為止的上下文,然後各自獨立分歧。
- 適合用於比較不同做法或測試策略,而不會讓一者汙染另一者。

為何在比較時 fork 勝過單一線性工作階段。 若你在*同一*條對話串裡先探索 Redux 再探索 Context API,Redux 的討論會偏倚 Context API 的分析——模型已經先入為主地框定了。fork 讓每個做法擁有*相同的*起始上下文,但在那之後各自從乾淨的狀態出發,所以比較才公平。這是 §5.9 「獨立審查者」原則的工作階段層級版本。

何時應改為開始新工作階段而非恢復:

- 工具結果已過時(檔案自上次以來已變更)。
- 已經過了很長時間,上下文已劣化。
- 與其恢復一個塞滿過時工具資料的工作階段,通常不如以「以下是我們發現內容的簡短摘要:.....」重新開始。

陷阱: 在一次大型重構後 `--resume` 一個一週前的工作階段,並信任它快取的檔案讀取。那些讀取描述的是舊程式碼。寧可用一份摘要播種一個全新的工作階段。

****考試角度:**** 「公平地比較兩種做法」 → `fork_session`。「繼續一個長期調查」 → `--resume` (留意過時)。「自從上次檔案大幅變更」 → 用摘要重新開始,不要恢復。

5.11 端到端案例研究:讓一個團隊上線 Claude Code

上述特性唯有組裝起來才有意義。以下是一個為團隊打造、完整且真實的 Claude Code 設定——正是考試的「**為團隊開發設定 Claude Code**」情境要你能推理的設定(也是 Practical Exercise 2 要你建構的)。

需求

一個 6 人開發團隊希望每位成員在 `git clone` 的那一刻,就獲得**一致、受治理**的 Claude Code 行為:

- **通用標準**(提交風格、語言)在每一回合套用。
- **API 與測試慣例**,只在編輯 API 或測試檔案時才載入——其餘時候不浪費上下文。
- 一個共享的 `/audit` **工作流程**,用以分析架構,但必須唯讀且隔離執行,讓它冗長的輸出不會埋掉主工作階段。
- 一個共享的 **GitHub MCP 伺服器**用於 PR 搜尋——所有人共用同一套工具,**不提交任何憑證**(每位開發者的 token 都是個人的)。
- 一個**硬性保證**:Claude Code **絕不可**執行 `git push --force` 或讀取機密檔案,不論提示如何。
- **CI** 以 headless 執行 Claude Code 來審查 PR 並張貼行內留言。

架構

flowchart TD

```
Clone[開發者 git clone 儲存庫] --> Proj[已提交的專案 .claude]
Proj --> CM[CLAUDE.md<br/>通用標準]
Proj --> Rules[.claude/rules<br/>路徑範圍的 api 與 test 規則]
Proj --> Skill[.claude/skills/audit<br/>context fork、唯讀工具]
Proj --> MCP[.mcp.json<br/>GitHub 伺服器、token 來自 env]
Proj --> Settings[.claude/settings.json<br/>deny 強制推送與機密]
Settings --> Hook[{PreToolUse hook<br/>封鎖危險 Bash}]
MCP --> Local[.claude.json 使用者覆寫<br/>個人 GitHub token]
Proj --> CI[CI 執行 claude -p<br/>審查 PR、張貼留言]
```

專案 `.claude/` 是**團隊契約**(已提交);每位開發者只在一個 git-ignored 的覆寫檔中加入自己的**個人 token**; `settings.json` + hook 讓危險命令規則具備**確定性**,而非一句提示。

實作

專案標準 — `CLAUDE.md` (永遠載入),搭配一個模組化匯入:

```
# Project CLAUDE.md
Use Conventional Commits (feat/fix/chore). Keep commits small.
Detailed test policy: @./standards/testing.md
```

路徑範圍慣例 — 只在符合的檔案上載入:

```
# .claude/rules/api.md
---
paths: ["src/api/**/*"]
---
Use async/await with explicit error handling; return the standard response wrapper.
```

```
# .claude/rules/tests.md
---
paths: ["**/*.test.ts", "**/*.test.tsx"]
---
Use describe/it blocks and data factories. Do not mock the database; use a test DB.
```

隔離、唯讀的稽核技能 — 冗長輸出留在主工作階段之外:

```
# .claude/skills/audit/SKILL.md
---
context: fork
allowed-tools: ["Read", "Grep", "Glob"]
argument-hint: "Path to the package to audit"
---
Audit the package's dependency graph and architectural patterns. Output a short report.
```

共享 MCP 伺服器、不提交機密 — token 來自環境:

```
// .mcp.json (已提交)
{
  "mcpServers": {
    "github": {
      "command": "github-mcp-server",
      "env": { "GITHUB_TOKEN": "${GITHUB_TOKEN}" }
    }
  }
}
```

每位開發者在自己的環境(或個人的 `~/.claude.json` 覆寫)中設定 `GITHUB_TOKEN` ——儲存庫保持零憑證。

確定性護欄 — `settings.json` 直接拒絕危險命令, `PreToolUse` hook 再加上一道程式化檢查:

```
// .claude/settings.json (已提交)
{
  "permissions": {
    "allow": ["Read", "Grep", "Glob", "Bash(npm test:*)"],
    "ask": ["Edit", "Write"],
    "deny": ["Bash(git push --force:*)", "Read(.env)", "Read(**/secrets/**)"]
  },
  "hooks": {
    "PreToolUse": [
      { "matcher": "Bash",
        "hooks": [{ "type": "command", "command": ".claude/hooks/guard.sh" }] }
    ]
  }
}
```

CI 審查(headless) — 跑一個全新的執行個體,而非寫程式的那一個:

```
claude -p "Review this PR. Report only new or unresolved issues." \
  --output-format json --json-schema "$SCHEMA" > review.json
# 管線解析 review.json 並張貼行內 PR 留言
```

執行軌跡

```
sequenceDiagram
    actor Dev as 開發者
    participant CC as Claude Code
    participant R as 路徑規則
    participant Pre as PreToolUse hook
    participant GH as GitHub MCP 伺服器
    Dev->>CC: 打開 src/api/orders.ts, 「新增一個端點」
    CC->>R: 檔案符合 src/api/**
    R-->>CC: 只載入 api.md 規則
    CC->>GH: 搜尋相關 PR(token 來自 env)
    GH-->>CC: 符合的 PR
    CC->>Pre: Bash(git push --force)
    Pre-->>CC: 非零結束碼, 已封鎖
    CC-->>Dev: 拒絕強制推送; 標準已套用
```

api 規則之所以載入,只因為檔案符合它的 glob;強制推送被 **hook/權限確定性地**封鎖,而非寄望模型讀了 CLAUDE.md。

驗證

- **階層測試:** 一位隊友複製儲存庫,立刻就拿到提交風格與 API 規則——證明它們在 **project** 層級,而非某人的 `~/.claude/`。
- **條件載入測試:** 確認 `api.md` 在編輯 `src/api/x.ts` 時載入、在編輯 `web/Button.css` 時**不存在**——證明 `paths` glob 為它設定了範圍。
- **確定性測試:** 嘗試 `git push --force` 100 次;斷言 100 次封鎖。一句 CLAUDE.md 會漏; `deny /hook` 必須 100%。
- **零機密測試:** 在儲存庫中 `grep token`——`.mcp.json` 必須含有 `${GITHUB_TOKEN}`,絕無真實金鑰。
- **隔離測試:** 執行 `/audit`;確認它逐檔的輸出**不會**出現在主對話紀錄中,且它無法寫入檔案。

常見陷阱

- 把團隊標準放進 `~/.claude/CLAUDE.md`,讓全新的複製永遠看不到它們(\$5.1)。
- 一個總是載入 Terraform/API/test 規則的龐大 CLAUDE.md,浪費上下文——改用路徑範圍的 `.claude/rules/` (\$5.3)。
- 在 CLAUDE.md 裡寫「絕不強制推送」並假設它已被強制執行——那是機率性的;改用 `permissions.deny /一個 hook`(\$5.6)。
- 把 GitHub token 提交進 `.mcp.json`,而非用 `${GITHUB_TOKEN}` + 一個 `git-ignored` 的個人覆寫(\$5.6、第 4 章)。
- 用**同一個**產生 PR 的工作階段去審查它,或在 CI 裡用互動模式——改用一個全新的 `claude -p` 執行個體(\$5.9)。

5.12 考試重點 — 關鍵整理

概念	考試考什麼
----	-------

CLAUDE.md 階層	團隊標準 → project(已提交);個人風格 → user(~/.claude/);子樹專屬 → directory。「全新的複製看得到它嗎？」 (§5.1)。
@path 匯入	用匯入單一共享檔案來避免標準在各套件間重複(@ 後無空格、深度 ≤ 5)(§5.2)。
路徑範圍規則	依檔案類型橫跨許多目錄的慣例 → 帶 paths glob 的 .claude/rules/ ;單一資料夾的慣例 → directory CLAUDE.md (§5.3)。
斜線命令 / 技能	共享工作流程 → 專案命令(已提交); context: fork 隔離冗長輸出; allowed-tools 強制最小權限 (§5.4–5.5)。
設定、權限、hooks	確定性保證(「絕不推送到 main」、「封鎖機密」) → permissions.deny / PreToolUse hook,而非 CLAUDE.md; settings.local.json 用於個人、git-ignored 的微調 (§5.6)。
規劃 vs 直接執行	大型/模糊/架構性 → 規劃模式再核准;小型/明確/單檔 → 直接執行;大型程式碼庫 → Explore 子代理 (§5.7)。
上下文與工作階段	/compact 回收滿載的視窗(有損); /memory 跨工作階段保存; fork_session 公平比較做法;當心過時的 --resume (§5.8、§5.10)。
CI/CD	Headless 的 -p (絕不互動); --output-format json + --json-schema 用於自動留言;以全新執行個體審查 (§5.9)。

對應 Domain 3(20%)。 如果你能建立上面的團隊設定——階層、路徑範圍規則、一個隔離的最小權限技能、一個零憑證的 MCP 伺服器、確定性的權限/hook 護欄,以及一個 headless 的 CI 審查——你就掌握了權重第二高考試領域的核心。

第 6 章:提示工程 — 進階技巧

文件:[提示工程](#) | [Anthropic Cookbook](#)

提示工程是一門**不改動模型權重**、僅靠你放進請求裡的文字、結構與範例來形塑模型行為的學問。本章是 **Domain 4 — 提示工程與結構化輸出(佔考試 20%)** 的骨幹,與另一個領域並列第二重。考試考的不是巧妙的措辭,而是你能否針對特定的失敗模式選對**正確的技巧**,以及你是否清楚每種技巧的保證與限制。讀完本章你應能選用並組合這些工具:

- **少樣本提示**(§6.1)— 用示範取代描述。
- **明確判準**(§6.2)— 用分類規則取代模糊的形容詞。
- **XML 標籤與角色提示**(§6.3)— 把指令與資料分開,並設定模型的人設。
- **思維鏈與擴展思考**(§6.4)— 讓模型先推理再作答。
- **預填助理回合**(§6.5)— 約束回應的開頭以強制其形狀。
- 以 `tool_use` **做結構化輸出**(§6.6)— 保證 schema 合規的 JSON,而非只是看起來合理的 JSON。
- **提示鏈接與訪談模式**(§6.7)— 把任務拆解到多次聚焦的呼叫中。
- **驗證與帶回饋的重試**(§6.8)— 在擷取失敗時把迴圈收尾。
- **自我修正**(§6.9)— 讓模型主動暴露自己的矛盾。

§6.10 接著從頭到尾建構一個完整的**合約擷取服務**,組合上述大多數技巧,§6.11 則濃縮考試重點。

一個好用的心智模型,是把每種技巧對應到它所修復的失敗:

flowchart TD

Start[輸出錯誤或不一致] --> Q1{是哪一種失敗?}

Q1 -->|格式不一致或
邊界情況處理不佳| FS[加入少樣本範例
section 6.1]

Q1 -->|誤報太多、
判斷模糊| EC[撰寫明確判準
section 6.2]

Q1 -->|模型把指令
當成輸入資料| XML[用 XML 標籤包住資料
section 6.3]

Q1 -->|困難的多步驟任務
跳過推理| COT[思維鏈或
擴展思考 6.4]

Q1 -->|加上前言或
開頭形狀錯誤| PF[預填助理回合
section 6.5]

Q1 -->|格式錯誤或
非 schema 的 JSON| TU[使用 tool_use schema
section 6.6]

Q1 -->|schema 有效但
數值錯誤| VR[驗證並重試
section 6.8]

整章的考試角度:要知道提示技巧是**機率性**的(它們提高正確行為的機率),而 `tool_use` schema 與下游驗證才是**確定性**的層。語法可以保證,語意必須檢查。

6.1 少樣本提示

少樣本提示是在提示中加入 2–4 個輸入／輸出範例,以示範預期的行為。依 Domain 4 所述,它是產生一致格式、可採取行動之輸出單**最有效的方法**。

為何少樣本比文字描述更有效:

- 像「更精確一點」這樣模糊的指令可能有許多種解讀方式。
- 範例能毫不含糊地展示預期的格式與決策邏輯。
- 模型會將該模式類推到新的案例(它不只是重複那些範例)。
- 範例能**降低擷取任務中的幻覺**,因為它把模型錨定到具體的形狀,而不是任其杜撰欄位。

為何有效(機制):一個範例同時把輸出的結構、語氣與決策邊界編碼進同一件成品。文字規則只編碼你記得寫下來的部分;範例還編碼了你所有隱而未宣的東西(鍵的順序、null 的處理、修正建議的措辭)。這就是為何一個好範例往往勝過三段指令。

少樣本範例的類型及其使用時機:

1. **用於模糊情境的範例**——展示決策,而不只是格式:

Request: "My order is broken"

Action: Call get_customer -> lookup_order -> check status.

Rationale: "broken" may mean a damaged item; you need order details.

Request: "Get me a manager"

Action: Immediately call escalate_to_human.

Rationale: The customer explicitly requests a human. Do not attempt to solve autonomously.

2. **用於輸出格式化的範例:**

Finding example:

```
{
  "location": "src/auth/login.ts:42",
  "issue": "SQL injection in the username parameter",
  "severity": "critical",
  "suggested_fix": "Use a parameterized query"
}
```

3. 用於區分可接受與有問題程式碼的範例——教會模型真正問題與誤報之間的邊界:

```
// Acceptable (do not flag):
const items = data.filter(x => x.active);

// Problem (flag):
const items = data.filter(x => x.active == true); // Use strict equality ===
```

4. 用於從不同文件格式擷取的範例——你預期會遇到的每一種結構各給一個範例:

```
Document with inline citations:
"As shown in the study (Smith, 2023), the rate is 42%."
-> {"value": "42%", "source": "Smith, 2023", "type": "inline_citation"}

Document with bibliography references:
"The rate is 42%. [1]"
-> {"value": "42%", "source": "reference_1", "type": "bibliography"}
```

5. 用於非正式量測的範例——規則無法窮舉每一種說法之處:

```
Text: "about two handfuls of rice"
-> {"amount": "~100g", "original_text": "two handfuls", "precision": "approximate"}

Text: "a pinch of salt"
-> {"amount": "~1g", "original_text": "a pinch", "precision": "approximate"}
```

少樣本對於擷取非正式且非標準的量測單位特別有效,這類單位過於多樣,難以單純以規則式指令處理。

提示中的格式正規化規則:當使用嚴格的 JSON 結構描述進行結構化輸出時,在提示中加入正規化規則,讓數值(而不只是語法)保持一致:

```
Normalization:
- Dates: always ISO 8601 (YYYY-MM-DD); "yesterday" -> compute an absolute date
- Currency: numeric amount + currency code; "five bucks" -> {"amount": 5, "currency": "USD"}
- Percentages: decimal fraction; "half" -> 0.5
```

這可防止語意錯誤,亦即 JSON 在語法上有效、但數值卻不一致的情況——正是 `tool_use` 本身無法弭平的缺口(\$6.6)。

陷阱:

- **範例集偏頗。**若你的範例全是「該標記」的案例,模型就會過度標記。教邊界時務必納入**反面範例**(什麼不該做)。

- **範例與指令相矛盾。** 當文字與範例不一致時,模型傾向遵循範例——所以範例才是真正的規格。讓兩者保持一致。
- **過度貼合措辭。** 若每個範例都把修正寫成「Use a parameterized query」,模型可能照抄那句話。當你要的是類推而非模仿時,請變化表面措辭。

考試角度:若題目描述格式不一致或對模糊/邊界情況處理不佳,正解幾乎總是「加入 2–4 個帶理由的針對性少樣本範例」——而不是「寫更長的指令」。

6.2 明確的判準 vs 模糊的指令

對於**判斷型**任務(審查、分流、分類),槓桿最高的單一修正,就是用可列舉、可證偽的規則取代形容詞。

不佳(模糊):

檢查程式碼註解的正確性。
請保守一點——只回報高信心的發現。

「保守」與「高信心」不可操作;兩次執行會劃出不同的界線,而你也無法為「模型不夠保守」除錯。

良好(明確判準)——同時列出該標記與該忽略:

僅在符合下列情況時,才將某則註解標記為有問題:

1. 該註解描述的行為與實際的程式碼行為相互矛盾
2. 該註解引用了不存在的函式或變數
3. TODO/FIXME 註解所指的 bug 已在程式碼中修正完成

請勿標記:

- 僅是風格上過時的註解
- 用字稍有不精確的註解
- 缺漏的註解(那屬於另一個類別)

用範例定義嚴重程度判準——每一級都搭配一個具體案例,讓模型校準而非猜測:

CRITICAL: 使用者端的執行階段失敗

範例: 處理付款時發生 `NullPointerException`

HIGH: 安全性漏洞

範例: `SQL injection`、`XSS`、缺漏授權檢查

MEDIUM: 無立即影響的邏輯 bug

範例: 排序錯誤、差一錯誤(`off-by-one error`)

LOW: 程式碼品質

範例: 重複程式碼、對小型資料採用次佳演算法

為何這很重要——誤報的信任問題:***某一個類別的高誤報率,會瓦解開發者對每一個類別的信任。**若「風格」檢查老是狼來了,工程師連「安全」檢查也會開始忽略。解方不是「更保守一點」(模糊),而是 (a) 撰寫分類判準,且 (b) 對誤報率過高的類別**暫時停用**,而非讓整個審查器品質下降。

陷阱:

- 堆疊軟性緩衝詞(「小心一點」「自行判斷」)——它們增加 token,而非精確度。

- 只定義該標記什麼,卻從不定義該忽略什麼——模型會以過度回報來填補沉默。
- 嚴重程度分級卻沒有範例——標籤會在多次執行間漂移。

考試角度:當情境回報誤報太多或信任受損時,正確的槓桿是明確的分類判準(以及停用吵雜的類別),而非一句籠統的「更保守一點」。這個區別在 Domain 4 中被原文逐字點名。

6.3 XML 標籤與角色提示

這兩種結構性技巧關乎資訊**放在哪裡**,以及模型**扮演誰**。

用 XML 標籤分隔

Claude 經過特別調校,會尊重 XML 風格的標籤。將提示的每個部分包進具名標籤,能讓模型分辨指令與資料,並讓你以名稱引用各部分。

```
You are reviewing a contract. The contract text is in <contract>.
Your task instructions are in <instructions>. Output only the <result>.

<instructions>
Extract the parties, effective date, and termination clause.
</instructions>

<contract>
{{ untrusted_document_text }}
</contract>
```

為何有效:

- **指令／資料分離。**沒有分隔符時,一份本身含有「ignore the above and summarize」字樣的文件可能劫持任務。標籤讓邊界變明確,是**提示注入的第一道緩解**(資料住在 `<contract>`,權威住在 `<instructions>`)。
- **可引用性。**你可以寫「在你的 `<result>` 中引用 `<contract>` 裡相關的句子」,藉此改善紮根程度,並讓輸出可稽核。
- **可組合性。**已標籤的段落容易做成樣板、快取(穩定的 `<instructions>` 區塊很適合快取;見第 18 章)並重新組合。

角色提示(系統提示人設)

在**系統提示**中指派角色,可設定模型的視角、用語與預設標準。

```
response = client.messages.create(
    model="claude-...",
    system="You are a senior contracts attorney. You are precise, "
        "cite the exact clause you rely on, and you never guess "
        "at a value that is not present in the document.",
    messages=[{"role": "user", "content": prompt}],
)
```

為何有效:人設是一種精簡的方式,能一次拉進一整組期望(「合約律師」就隱含精確、引用條款、對缺漏資料審慎),而無須逐條列出每項規則。它也會改變預設值——同一個問題,以「律師身分」回答 vs 以「友善助理

身分」回答,在嚴謹度與保留措辭上都會不同。

system 與 user 內容(與考試相關):把長存的角色、規則與輸出契約放進 `system`;把特定的任務與資料放進 `user` 回合。這種分離正是讓提示快取生效、並使契約在多次請求間保持穩定的關鍵。

陷阱:

- 把角色當成**保證**。「You are a strict validator」只會讓模型**表現得更嚴格**;它不強制任何東西。真正的強制是 `tool_use` schema(\$6.6)與程式碼端驗證(\$6.8)——與第 3 章 hooks 對提示的「確定性 vs 機率性」是同一條界線。
- 把人設過度規格化到擠掉了任務本身。角色應是幾句話,而非一篇傳記。

考試角度:XML 標籤 = 「把指令與不可信資料分開 + 降低注入風險」;角色提示 = 「在系統提示中設定專業與標準」。兩者都是機率性的品質槓桿,而非安全邊界。

6.4 思維鏈與擴展思考

對於多步驟推理(數學、多條款邏輯、對帳數字),讓模型**先思考再作答**能實質提升準確度。

取得推理的兩種方式:

- 提示式思維鏈(CoT)**——指示模型逐步推理,最好是寫進一個具名草稿區,讓你能把思考與答案分開:

```
Think step by step inside <scratchpad>...</scratchpad>.
Then give only the final JSON inside <answer>...</answer>.
```

- 擴展思考**——一種模型能力(以 `thinking` 預算開啟),模型會在最終回應前產生內部推理。你為思考配置一個 token 預算;模型會把它用在較難的問題上,可見的答案隨後產出。

****為何有幫助:****推理 token 給了模型「工作的空間」。被迫立即吐出答案的模型,必須在單次前向傳遞中算出多步驟結果;而被允許鋪陳中間步驟的模型,能在定下答案前抓出自己的算術與邏輯錯誤。這也是 \$6.9 自我修正之所以有效的同一個原因。

兩者如何選:

	提示式 CoT(<code><scratchpad></code>)	擴展思考
控制	你在提示中形塑步驟	模型在預算內自行管理推理
輸出衛生	你必須在使用答案前剝除草稿區	思考以獨立區塊交付,不與答案混在一起
最適合	輕度推理,當你想 引導 步驟時	深度至關重要的困難、開放式推理

陷阱:

- 草稿區洩漏進輸出**。若你在同一坨內容中同時要求推理與 JSON,然後對整坨 `json.loads`,就會壞掉。把推理放進 `<scratchpad>` / 思考區塊,結果放進 `<answer>`,且只解析答案。
- 在純屬多餘之處強行 CoT**。瑣碎的擷取不需要草稿區;你白白付出延遲與 token。
- 思考與預填搭配錯誤**。預填助理回合(\$6.5)約束的是**回應**的開頭;別用它試圖壓制或偽造思考區塊。

考試角度:要知道推理(提示式 CoT 或擴展思考)是困難多步驟任務**準確度**的槓桿,且推理軌跡必須與機器消費的輸出分開。

6.5 預填助理回合

你可以在請求中提供一則 `assistant` 訊息,藉此植入 Claude 回應的開頭。模型會從你的預填續寫,這就約束了後續內容的形狀。

```
messages = [
  {"role": "user", "content": "Extract the invoice as JSON."},
  {"role": "assistant", "content": "{}", # <- 預填強制 JSON,跳過前言
}
```

預填能帶來什麼:

- **跳過前言。**沒有它,模型可能會以「Sure! Here is the JSON:」開頭;預填 `{` 會逼它直接進入物件。
- **鎖定格式。**預填 `[` 以強制 JSON 陣列,或預填像 `<result>` 這樣的開頭標籤以強制標籤式輸出。
- **引導人設/決策。**預填「As an attorney, my assessment is」會為續寫推動語氣與立場。

為何有效:模型永遠只是在預測下一個 token,而依據的是目前為止的一切——包括你提供的助理文字。藉由寫下答案的第一個(幾個)token,你移除了模型選擇不同開頭的自由,而格式漂移往往正是從那裡開始的。

陷阱:

- **預填不會被回傳。**API 回應是接在你的預填之後續寫,所以在解析前要把完整值重組為 `prefill + response` (例如 `"{" + completion`)。
- **尾端空白。**以空格或換行結尾的預填可能使輸出變差;以有意義的 token 結尾(例如 `{` 而非 `{ }`)。
- **預填是形塑工具,不是 schema 保證。**它偏置開頭;不驗證其餘部分。要硬性保證,請結合 `tool_use` (§6.6)與驗證 (§6.8)。

考試角度:預填 = 「藉由寫下回應的開頭 token 來約束回應」——經典用法是強制 JSON/陣列輸出與移除對話式前言。記得在讀取結果時把預填補回去。

6.6 以 `tool_use` 與 JSON Schema 做結構化輸出

當你需要機器可讀的輸出時,最可靠的機制是**搭配 JSON Schema 的 `tool_use` **——而不是「要求 JSON 然後祈禱」。

為何 `tool_use` 勝過自由文字 JSON:工具的 `input_schema` 會約束生成,使模型吐出符合 schema 的引數。這消除了 JSON 語法錯誤(不對稱的大括號、尾隨逗號、智慧引號),並保證形狀——你宣告的欄位名稱、型別與必填鍵。

```

extract_invoice = {
  "name": "extract_invoice",
  "description": "Return structured fields from an invoice.",
  "input_schema": {
    "type": "object",
    "properties": {
      "vendor": {"type": "string"},
      "total": {"type": "number"},
      "currency": {"type": "string", "enum": ["USD", "EUR", "GBP"]},
      "line_items": {
        "type": "array",
        "items": {
          "type": "object",
          "properties": {
            "name": {"type": "string"},
            "price": {"type": "number"}
          },
          "required": ["name", "price"]
        }
      },
      "confidence": {"type": "string", "enum": ["high", "medium", "unclear"]}
    },
    "required": ["vendor", "total", "currency", "line_items"]
  }
}

```

控制是否呼叫工具—— **tool_choice** :

tool_choice	行為	何時使用
"auto" (預設)	模型可用文字回答 或 呼叫工具	有時只是回覆的對話式代理
"any"	模型 必須 呼叫 某個 工具	你總是要結構化輸出,且有多個 schema
{"type": "tool", "name": "extract_invoice"}	強制呼叫 這個 工具	你每次都要剛好同一個 schema(擷取)

```

flowchart TD
    Req[帶 input_schema 發送請求] --> Choice{tool_choice?}
    Choice -->|auto| MayText[模型可回傳文字<br/>或呼叫工具]
    Choice -->|any| MustTool[模型必須呼叫某個工具]
    Choice -->|forced name| OneTool[模型必須呼叫指定的工具]
    MustTool --> Parse[把 tool_use.input 當成物件讀取]
    OneTool --> Parse
    Parse --> Valid{通過程式碼端<br/>驗證?}
    Valid -->|yes| Done[使用資料]
    Valid -->|no| Retry[帶錯誤重試<br/>section 6.8]

```

考試青睞的 schema 設計:

- **required vs 選填**。當來源**可能不含**某欄位時,把它設為選填／可為 null——否則模型會為了滿足 schema 而杜撰一個值。「別逼我發明資料」是反覆出現的考點。
- **帶逃生口的 enum**。對已知類別使用封閉 enum,再加上 "other" / "unclear" 值**以及**一個自由文字的細節欄位,讓新案例被捕捉而非被錯誤歸類(可擴充的分類)。
- **單一可信來源**。從模型產生 schema(例如 Pydantic → JSON Schema,\$6.8)能讓工具定義與你的驗證器保持同步。

硬性限制——tool_use 保證語法,不保證語意。schema 無法知道 total 應等於 sum(line_items),或 currency 是否與文件中的符號相符。**語法有效、語意錯誤**的輸出,正是 \$6.8 與 \$6.9 之所以存在要抓的失敗模式。

陷阱:

- 以為 schema 有效就等於正確。它只代表**形狀良好**。
- 用 required 過度約束,以致模型為缺漏欄位發明值。
- 在你**總是**需要結構時卻用 tool_choice: "auto" (模型可能用散文回答)。請用 "any" 或強制名稱。

****考試角度:****「保證 schema 合規的輸出 / 消除 JSON 語法錯誤」→ tool_use + JSON Schema。「總是結構化、有多個 schema」→ tool_choice: "any"。「剛好一個擷取 schema」→ 強制工具。「別杜撰缺漏資料」→ 選填／可為 null 的欄位。「抓出錯誤的 total」→ 那是驗證,不是 schema。

6.7 提示鏈接與訪談模式

提示鏈接

提示鏈接將一項複雜任務拆解為一連串聚焦的步驟,每一步都消費前一步的輸出:

```
Step 1: Analyze auth.ts (僅限本檔案內部的問題)
-> 輸出: auth.ts 的問題清單

Step 2: Analyze database.ts (僅限本檔案內部的問題)
-> 輸出: database.ts 的問題清單

Step 3: 整合遍歷 (跨檔案相依)
-> 輸出: 模組邊界處的問題
```

為何這很重要:

- 避免**注意力稀釋**——當模型一次收到太多檔案時,可能會漏掉某些檔案中的 bug,同時對其他檔案只提供淺薄的評論。
- 確保每個檔案的分析品質一致。
- 允許在專屬的整合遍歷中,對跨檔案的互動進行獨立分析。

鏈接 vs 動態分解:

- **提示鏈接**——形狀**已知**、可預測、可重複的任務(程式碼審查、檔案遷移)。你預先設計好步驟。
- **動態分解**——開放式的調查,子任務只有在執行**過程中**才會變得明朗;此時由協調者代理在執行階段決定步驟(第 3 章)。

「訪談」模式

在實作解決方案之前,Claude 會先問釐清問題,而不是對需求妄加猜測:

Claude: "在為這個 API 實作快取之前,先問幾個問題:

1. 你偏好哪一種快取失效策略—TTL 還是事件驅動?
2. 當快取無法使用時,陳舊資料是否可以接受?
3. 快取應該是依使用者(per-user)還是全域(global)?
4. 預期要快取的資料量有多大?"

何時這很有用:

- 不熟悉的領域(金融科技、醫療保健、法律系統)。
- 帶有不明顯影響的任務(快取策略、失敗模式)。
- 存在多種可行方法,而最佳選擇取決於上下文。

****陷阱:****鏈接會增加延遲與成本(N 次呼叫而非一次)——當注意力稀釋或每步品質值得時才用,別反射性地用。訪談模式不適合高量的自主擷取(你不可能停下來問一萬次);把它留給設計階段與模糊的一次性任務。

****考試角度:****「模型在眾多檔案間漏掉 bug / 每檔輸出淺薄」→ 以每檔遍歷加整合遍歷做鏈接。「可預測的管線」→ 鏈接;「子任務在執行階段才浮現」→ 動態分解。

6.8 驗證與帶回饋的重試

`tool_use` 移除語法錯誤;**驗證**是你抓出語意錯誤的方式,而**帶回饋的重試**是你復原的方式。

當擷取出的資料未通過驗證時,帶著明確寫出的錯誤重試:

```
Step 1: 從文件中擷取資料
Step 2: 驗證 (Pydantic、JSON Schema、業務規則)
Step 3: 若有錯誤—帶著上下文重試:
- 原始文件
- 先前(錯誤的)擷取結果
- 具體的錯誤: "Field 'total' = 150, but sum(line_items) = 145. Re-check values."
```

重試提示必須同時帶上**這三者**:來源、錯誤的輸出,以及**具體**的錯誤。一句籠統的「剛剛錯了,再試一次」沒給模型任何可修正的東西。

何時重試會有效:

- 格式錯誤(日期格式錯誤)。
- 結構錯誤(欄位放在錯誤的位置)。
- 算術不一致(模型可以重新檢查自己的加總)。

何時重試沒有幫助:

- 該資訊在來源文件中根本**不存在**——重新提示無法變出本就不在的資料。
- 所需的上下文在**外部**(數值位於另一份你未提供的文件中)。重試只是浪費呼叫;解方是提供缺漏的來源,或把該欄位標為未知。

Pydantic 作為驗證工具(考試的典型範例):

- ****結構驗證:****在從 Claude 收到 JSON **之後**,於程式碼中檢查型別、必填性、enum 約束。

- **語意驗證:**自訂驗證器強制執行業務邏輯(`sum(line_items) == total; start_date < end_date`)。
- **驗證—重試迴圈:**當驗證失敗時,建構一則錯誤訊息,並帶著該錯誤上下文重新提示 Claude。
- **JSON Schema 產生:**Pydantic 模型可為 `tool_use` 產生 JSON Schema,為工具定義與驗證器提供單一可信來源。

陷阱:

- 在資料缺漏／外部時重試(無限迴圈陷阱)。為重試設上限(例如最多 2 次),然後改道給真人或回傳 null 結果。
- 在重試提示中省略具體錯誤(沒有可修正的訊號)。
- 把 Pydantic 通過當成完全正確——它只檢查你所寫的規則。

考試角度:「JSON 有效但 total 對不上」→ 語意驗證 + 帶錯誤重試。「重試沒能修好」→ 資訊缺漏或在外部;停止重試。「schema + 驗證的單一可信來源」→ 由 Pydantic 產生 JSON Schema。

6.9 自我修正

自我修正讓模型**主動暴露自己的矛盾**:同時擷取一個陳述值與一個獨立計算出的值,然後標記任何不一致:

```
{
  "stated_total": "$150.00",
  "calculated_total": "$145.00",
  "conflict_detected": true,
  "line_items": [
    {"name": "Widget A", "price": 75.00},
    {"name": "Widget B", "price": 70.00}
  ]
}
```

模型擷取**如所寫的值**(`stated_total`)與它從各部分**計算出的值**(`calculated_total`);當兩者不同時, `conflict_detected` 讓下游程式碼把這項差異改道送審,而不是默默信任一個錯誤的數字。

為何有效:它把一個看不見的推理步驟轉成一個可觀測的欄位。你不是寄望模型注意到文件本身的算術錯誤,而是要它把兩個數字都寫下來,於是這份分歧就變成你可以據以行動的資料。它與思維鏈(S6.4)天生搭配——模型在吐出計算值之前會先推理出它。

自我修正 vs 獨立審查(連結 Domain 4.6):模型不擅於挑戰自己的結論,因為它保留了生成時的上下文。自我修正(單一實例、兩個值)能廉價地抓出**內部的**算術/一致性錯誤;對於**細微**的問題,由一個**獨立的第二個 Claude 實例**在沒有生成上下文的情況下審查會更強。把自我修正用於行內一致性檢查,把獨立審查者用於更深入的稽核。

陷阱:

- 只信任 `stated_total` ——那正是你最該驗證的數字。
- 要求單一實例「再檢查一次你的工作」並期待嚴謹;沒有全新的上下文,它傾向自我背書。請用雙值模式或另一個實例。

考試角度:「偵測文件陳述的 total 與其各項目不符」→ 擷取 `stated` 與 `calculated` + 一個 `conflict_detected` 旗標。「找出作者漏掉的細微問題」→ 獨立的審查實例,而非自我審查。

6.10 端到端案例研究:合約擷取服務

上述技巧唯有組合在一起才有意義。以下是一個完整、真實的服務,把雜亂的上傳合約變成經驗證的結構化資料——正是 Domain 4 要你能推理的設計。它在單一管線中操演了**角色提示**、**XML 標籤**、**少樣本**、**思維鏈**、**tool_use schema**、**預填**、**驗證/重試與自我修正**。

需求

- 接受異質的合約文件(不同廠商、版面、引用風格)。
- 擷取一個固定結構: `parties`、`effective_date`、`total_value`、`currency`、`line_items`、`termination_notice_days`。
- **絕不杜撰**文件中沒有的值——缺漏的欄位必須回傳 `null`,而非發明。
- 輸出必須是**schema 合規的 JSON**,可直接插入資料庫(無語法錯誤、無前言)。
- 抓出常見的真實世界缺陷:文件**陳述**的總額與**各項目之和**不一致,並把這些改道送人工審查,而非予以信任。
- 高量且無人值守——執行階段不做訪談/釐清迴圈。

架構

兩層:一個**機率性**的擷取層(提示技巧)與一個**確定性**的驗證層(程式碼),兩者之間夾著有上限的重試。

```
flowchart TD
```

```
Doc([上傳的合約]) --> Build[建構提示<br/>角色 + XML 標籤 + 少樣本]
Build --> Call[呼叫 Claude<br/>開啟 thinking + 強制 extract 工具]
Call --> Pre[預填助理回合<br/>開頭大括號]
Pre --> Json[tool_use.input<br/>結構化 JSON]
Json --> Schema{schema 有效?<br/>Pydantic 結構}
Schema -->|no| RetryA[帶錯誤重試]
Schema -->|yes| Sem{語意正常?<br/>stated 等於 sum}
Sem -->|conflict| Review([人工審查佇列])
Sem -->|absent or external| RetryB[重試一次後 null]
Sem -->|ok| Store([寫入資料庫])
RetryA -. 有上限的重試 .-> Call
RetryB -. 有上限的重試 .-> Call
```

模型掌管擷取;**由程式碼(而非提示文字)掌管保證**(schema 合規、stated-vs-sum 檢查、重試上限)。這與考試在第 3 章測試的「機率性 vs 確定性」是同一個切分,套用在結構化輸出上。

實作

1) 提示中的**角色 + XML 標籤 + 少樣本**,並加上正規化規則讓數值一致:

```

SYSTEM = (
    "You are a senior contracts attorney. You are precise, you cite only "
    "values present in the document, and you NEVER guess a value that is "
    "absent – you return null for it."
)

FEWSHOT = """
<example>
<contract>Term: 90 days written notice. Fee: USD 12,000.</contract>
<result>{"termination_notice_days": 90, "total_value": 12000, "currency": "USD"}
</result>
</example>
<example>
<contract>This agreement may be ended by either party.</contract>
<result>{"termination_notice_days": null, "total_value": null, "currency": null}
</result>
</example>
"""

NORMALIZE = """
Normalization: dates as ISO 8601 (YYYY-MM-DD); currency as amount + ISO code;
notice periods as an integer number of days. If a field is not stated, use null.
"""

def build_prompt(doc_text: str) -> str:
    return (
        f"{NORMALIZE}\n"
        f"Examples:\n{FEWSHOT}\n"
        "Think step by step inside <scratchpad>, reconcile the stated total "
        "against the sum of line items, then call extract_contract.\n"
        f"<contract>\n{doc_text}\n</contract>"
    )

```

注意那個**反面範例**(一份沒有通知期的合約 → `null` 欄位):它教會模型**不要杜撰**,正是需求所要求的。

2) 以 `tool_use` 強制擷取 **schema**(語法保證),並讓模型先推理:

```

extract_contract = {
  "name": "extract_contract",
  "input_schema": {
    "type": "object",
    "properties": {
      "parties": {"type": "array", "items": {"type": "string"}},
      "effective_date": {"type": ["string", "null"]},
      "stated_total": {"type": ["number", "null"]},
      "calculated_total": {"type": ["number", "null"]},
      "currency": {"type": ["string", "null"], "enum": ["USD", "EUR", "GBP",
None]},
      "line_items": {
        "type": "array",
        "items": {"type": "object",
          "properties": {"name": {"type": "string"},
            "price": {"type": "number"}},
          "required": ["name", "price"]}
      },
      "termination_notice_days": {"type": ["integer", "null"]},
      "conflict_detected": {"type": "boolean"}
    },
    "required": ["parties", "line_items", "conflict_detected"]
  }
}

resp = client.messages.create(
  model="claude-...",
  system=SYSTEM,
  thinking={"type": "enabled", "budget_tokens": 1024}, # 用 CoT 做對帳
  tools=[extract_contract],
  tool_choice={"type": "tool", "name": "extract_contract"}, # 強制 -> 總是結構化
  messages=[{"role": "user", "content": build_prompt(doc_text)}],
)
data = next(b.input for b in resp.content if b.type == "tool_use")

```

schema 把可為 null 的欄位明確標出(["number", "null"]),讓缺漏資料回傳 `null` 而非杜撰的數字,並且為自我修正(\$6.9)同時擷取 `stated_total` 與 `calculated_total`。

當要擷取**自由文字** JSON 而非用工具時(例如快速的非工具路徑),用 `{` 預填助理回合以強制物件並去掉任何「Here is the JSON」前言——然後解析 `"{" + completion`。

3) 確定性驗證 + 有上限的帶回饋重試(保證住在這裡,不在提示裡):

```

from pydantic import BaseModel, model_validator

class Contract(BaseModel):
    stated_total: float | None
    calculated_total: float | None
    conflict_detected: bool
    # ... other fields ...

    @model_validator(mode="after")
    def totals_must_reconcile(self):
        s, c = self.stated_total, self.calculated_total
        if s is not None and c is not None and abs(s - c) > 0.01:
            # tool_use 抓不到的語意錯誤
            object.__setattr__(self, "conflict_detected", True)
        return self

def extract(doc_text, max_retries=2):
    err = None
    for _ in range(max_retries + 1):
        data = call_claude(doc_text, prior_error=err) # 把錯誤帶進提示
        try:
            c = Contract(**data)
        except ValidationError as e:
            err = str(e) # 結構錯誤 -> 帶著它重試
            continue
        if c.conflict_detected:
            route_to_human_review(c); return c # stated != sum -> 送審, 不予信任
    return c # 乾淨 -> 入庫
return None # 達上限後放棄(缺漏/外部)

```

執行軌跡

一份陳述總額(\$150)與其各項目(\$145)不一致的合約:

```

sequenceDiagram
    actor Up as 上傳者
    participant Svc as 擷取服務
    participant Cl as Claude
    participant Val as Pydantic 驗證器
    participant Hu as 審查佇列
    Up->>Svc: contract.pdf 文字
    Svc->>Cl: 提示(角色 + XML + 少樣本, 強制工具, 開啟思考)
    Cl->>Cl: 草稿區: 各項目之和 = 145, 陳述 = 150
    Cl-->>Svc: tool_use {stated 150, calculated 145, conflict_detected true}
    Svc->>Val: 驗證結構與語意
    Val-->>Svc: schema 正常, conflict_detected 維持為 true
    Svc->>Hu: 把案件改道送人工審查
    Hu-->>Up: 「總額不符, 已標記待確認」

```

模型在**草稿區**做了算術(思維鏈),寫下了兩個總額(自我修正),schema 保證了 JSON 可解析(`tool_use`),而**程式碼**——而非提示指令——做出了送人工的決定。沒有任何單一技巧能獨力抓到這一點。

驗證

- ****不杜撰測試:****餵入一份缺通知期的合約;斷言 `termination_notice_days is None` (反面少樣本範例 + 可為 `null` 的 `schema` 必須成立)。
- **語法測試:**讓 **1,000 份文件通過強制工具**;斷言零次 `json` 解析失敗(這正是 `tool_use` 所保證的)。
- **語意測試:**餵入一份 `stated ≠ sum` 的合約;斷言它落入**審查佇列**,而非資料庫。
- ****重試上限測試:****餵入一份缺資料、且該資料只在外部附件中的合約;斷言它在 `max_retries` 後停止並回傳 `null`,而非無止盡迴圈。

常見陷阱

- 指望 `tool_use` 抓到總額不符——它保證**語法**,不保證**語意**;對帳必須是程式碼(\$6.6、\$6.8)。
- 把每個欄位都設為 `required`,以致模型為了滿足 `schema` 而杜撰通知期或幣別(\$6.6)。
- 在資料缺漏或在未提供的附件中時無止盡重試——為重試設上限(\$6.8)。
- 把「`stated` 必須等於 `sum`」規則只放進提示並祈禱——它是確定性檢查,所以該放進驗證器(\$6.8),這呼應第 3 章的 `hooks` 對提示。
- 把 `<scratchpad>` 推理混進你要解析的 `JSON`——讓推理(思考區塊／草稿區)與機器讀取的輸出分開(\$6.4)。

6.11 考試重點 — 關鍵整理

概念	考試考什麼
少樣本提示	對格式不一致／模糊邊界情況最有效的修正;2–4 個帶理由的範例,並納入反面範例(\$6.1)。
明確判準	用可列舉的標記/忽略規則 + 嚴重程度範例取代「保守一點」;停用吵雜的類別,而非讓整個審查器品質下降(\$6.2)。
XML 標籤／角色	標籤把指令與不可信資料分開(緩解注入);角色住在 系統 提示——兩者皆為機率性(\$6.3)。
CoT／擴展思考	困難多步驟任務準確度的槓桿;讓推理軌跡與解析的輸出分開(\$6.4)。
預填	藉由寫下回應的開頭 <code>token</code> 來約束回應(強制 <code>JSON</code> /陣列、去掉前言);讀取結果時把預填補回去(\$6.5)。
<code>tool_use</code> + JSON Schema	保證 <code>schema</code> 合規的語法, 而非語意 ; <code>tool_choice</code> 的 <code>auto</code> vs <code>any</code> vs 強制;可為 <code>null</code> 的欄位防止杜撰; <code>enum</code> + 「other」以利擴充(\$6.6)。
鏈接／訪談	每檔遍歷 + 整合遍歷勝過一個巨型提示(注意力稀釋);可預測管線用鏈接,浮現式子任務用動態分解(\$6.7)。
驗證 + 重試	帶 具體 錯誤重試對格式/結構/算術有效;資料缺漏/外部時無用——為重試設上限(\$6.8)。
自我修正	擷取 <code>stated</code> 與 <code>calculated</code> + <code>conflict_detected</code> ;對細微問題,獨立審查實例優於自我審查(\$6.9)。

對應 Domain 4(20%)。 貫穿全章的主線:提示技巧提高正確行為的**機率**,而 `tool_use schema` 保證**語法**、程式碼端驗證保證**語意**。如果你能建構並捍衛上面的合約擷取服務——針對每種失敗模式選對技巧,並清楚確定性的界線落在哪裡——你就掌握了這個領域的核心。

第 7 章:Message Batches API

文件:[Message Batches](#)

Message Batches API 用**延遲換取成本與規模**:你把一大批彼此獨立的請求交給 Anthropic,自己離開,稍後再以**半價**取回答案。本章屬於 **Domain 5 — 上下文管理與可靠性(佔考試 15%)**,這個領域要你在負載下維持大型系統的正確與經濟——而每當考題情境出現「離線」「隔夜」「數萬份文件」或「降低推論帳單」時,它就是標準答案。讀完你應能判斷**何時該批次處理**、**正確驅動非同步生命週期**,並設計一個**有韌性**的大型任務:

- **什麼是 Batches API**(§7.1)— 非同步模型、50% 折扣、24 小時視窗,以及它不做什麼。
- **批次 vs 即時**(§7.2)— 考試會考的判斷規則,圍繞「誰在等待結果」來框定。
- **custom_id 關聯**(§7.3)— 為何結果是亂序回傳,以及如何把結果重新對回輸入。
- **submit → poll → retrieve 生命週期**(§7.4)— 三個呼叫,以及之間的各種狀態。
- **失敗處理與 SLA 規劃**(§7.5–§7.6)— 部分失敗、選擇性重送,以及從期限往回推算。

§7.7 接著從頭到尾建構一個完整的離線文件分類管線,§7.8 則濃縮考試重點。

7.1 概觀:什麼是 Batches API

Message Batches API 讓你提交一批彼此獨立的 Messages API 請求進行**非同步**處理。你不必保持連線開啟;你提交、收到一個 batch ID,然後輪詢直到批次完成——屆時再串流取出結果。

屬性	值
成本	相較同步呼叫,輸入 與輸出 token 皆享 50% 折扣
處理時間視窗	多數批次在 1 小時 內完成;硬性上限為 24 小時 (無單一請求延遲 SLA)
批次大小	最多 100,000 個請求 或 256 MB ,以先達到者為準
結果保留	結果在批次建立後可取用 29 天
關聯對應	每個請求帶一個 <code>custom_id</code> ;結果以它為鍵,且 亂序 回傳
功能完整性	Messages API 的 所有 功能在批次內都可用——工具、視覺、系統提示、 prompt caching 、結構化輸出
多輪工具呼叫	不支援 ——一個請求產生一個回應;批次內沒有代理迴圈

為何存在——經濟性。半價 token 是頭條。對於處理 50,000 張發票、或重新分類一整年支援工單的任務,50% 折扣往往就是「我們每晚都跑」與「我們根本不跑」之間的差別。成本套用在**整個**批次的 token 用量,所以任務越大越重複,省得越多——而且因為 prompt caching 在批次內同樣有效,跨數千個請求共享的系統提示,可以在 50% 之上再對快取前綴疊加約 90% 的折扣。

代價——沒有延遲保證。「最長 24 小時」是上限,不是目標。多數批次遠早於此完成,但你無法**承諾**完成時間,因此這個 API 不適合任何有人正在等待的工作。這個單一特性,正是所有關於批次處理的考題的核心。

陷阱——把批次當成聊天。 批次請求是單次的:模型收到訊息後回傳一個回應。若你在批次請求裡放工具、而模型發出 `tool_use`,沒有任何東西會去執行它並把結果餵回——批次不會迴圈。批次用於無狀態、單輪的工作(分類、擷取、摘要、評分、增補),而非多步代理。若你的任務需要代理迴圈,它屬於同步 Messages API(第 3 章),不在此處。

考試角度。 預期會出一題基本盤:給你一個特性——「便宜 50%」「結果亂序」「無 SLA」「一個請求一個回應」——問這描述的是哪個 API。誘答幾乎總是同步 Messages API。錨定在**非同步 + 折扣 + 無延遲保證**。

7.2 何時使用批次 API 與同步 API

判斷規則是一個問題:****是否有某個東西——某個真人或某個下游同步系統——正被阻擋、等待這個結果?***若是,使用同步 Messages API。若結果只是終究*會用到(早上前、週報時、任務跑完時),就批次處理並拿折扣。

```
flowchart TD
    A[新的推論工作負載] --> B{有人正被阻擋<br/>等待結果嗎?}
    B -->|是, 某個使用者或即時系統| C[同步 Messages API<br/>全價, 即時]
    B -->|否, 終究才需要| D{獨立的單輪<br/>請求?}
    D -->|否, 需要代理迴圈| C
    D -->|是| E{大量或<br/>對成本敏感?}
    E -->|是| F[Batch API<br/>5 折, 最長 24h]
    E -->|介於兩者| G[兩者皆可——<br/>量變大就用批次]
```

任務	API	原因
合併前 PR 檢查	同步	開發者正在等待;24 小時無法接受
互動式程式碼審查	同步	編輯器中需要即時回應
即時客服對話	同步	使用者正在即時讀取回覆
隔夜技術債報告	批次	結果在早上前需要即可;節省 50%
每週安全稽核	批次	不緊急;依排程執行;節省 50%
分類 10,000 份文件	批次	大量、離線、無人等待;節省幅度可觀
每晚增補 CRM 資料表	批次	排程、量大、可容忍延遲

為何「誰在等待」是正確的判斷軸。 量本身不能決定——你可以跑 10,000 個同步呼叫,也可以只批次一個請求。讓批次正確的,是 (a) 對延遲的容忍與 (b) 請求的獨立性兩者的組合。與單一使用者的即時對話違反 (a);多輪代理違反 (b)。凡是兩者都通過的,就是批次候選,而到那一步,50% 折扣讓批次成為預設,而非例外。

陷阱——為省錢而把延遲敏感的工作批次化。 折扣會誘使團隊把使用者正在等待的東西丟去批次。一個通常 10 分鐘完成的批次,在佇列很深時終究會跑 20 小時,而那一個糟糕的日子就是一次生產事故。絕不要把面向真人的路徑放上批次 API,無論它平常回得多快。

陷阱——為了「簡單」而把龐大的離線任務走同步。 鏡像反向的錯誤。把 50,000 份文件用同步呼叫跑,付雙倍價錢還猛撞速率限制;批次 API 正是為這種形狀而建,而折扣是你拒收的免費資源。

考試角度。這類題目幾乎都是分類任務:一串工作負載,各自標上 Batch 或 Synchronous。用「誰在等待 / 是不是迴圈」的測試逐一判定。刻意刁鑽的列是 (1) 一個量大但仍屬互動的任務——維持同步——以及 (2) 一個量小但純離線的任務——批次仍然可以,折扣連小任務也適用。

7.3 用 `custom_id` 關聯請求與結果

批次裡的每個請求都帶一個你指派的 `custom_id`。它是輸入與其結果之間唯一的連結,因為批次結果是亂序回傳——API 不保證結果 #1 對應到請求 #1。

```
{
  "custom_id": "doc-invoice-2024-001",
  "params": {
    "model": "claude-haiku-4-5",
    "max_tokens": 1024,
    "messages": [{"role": "user", "content": "Extract data from: ..."}]
  }
}
```

`custom_id` 讓你能夠:

- 把每個結果重新對回它的來源文件、紀錄或資料列——靠鍵,絕不靠位置。
- 只重送失敗項——找出失敗的 `custom_id`, 只用那些建一個較小的新批次。
- 避免重複處理已成功項——已成功的 `custom_id` 就是完成了;你絕不會為它付兩次。
- 讓任務具備冪等性——穩定、確定性的 `custom_id` (例如由文件主鍵衍生)代表重跑會產生相同的鍵,因此你可以去重並安全重試。

為何不保證順序。100,000 個請求的批次會在 Anthropic 的機群上平行處理;請求完成的時間各不相同。把結果處理建立在陣列索引上,是最常見的批次錯誤——只要有一個請求重排或失敗,它就會默默地把每一筆紀錄貼錯標籤。

陷阱——不唯一或位置性的 `custom_id`。`custom_id` 在批次內必須唯一。重複使用它(或用像 `"0"`、`"1"` 這種純迴圈索引、再拿去和你的輸入清單做位置比對)會摧毀你唯一可靠的關聯。請從你領域中有意義且唯一的東西衍生: `invoice-2024-001`、`ticket-558823`、`user-4471-enrich`。

考試角度。情境描述結果回來時對不上、或問「你怎麼知道哪個答案屬於哪份文件?」答案永遠是:以 `custom_id` 為鍵,絕不依賴順序。

7.4 批次生命週期:Submit → Poll → Retrieve

一個批次會經過三個操作與一小組狀態。你建立它,輪詢它的 `processing_status` 直到抵達 `ended`,然後串流取出結果。

flowchart TD

```
A[建立請求<br/>每個帶唯一的 custom_id] --> B[batches.create<br/>回傳 batch id + 狀態 in_progress]
B --> C[batches.retrieve id<br/>讀取 processing_status]
C --> D{processing_status?}
D -->|in_progress| E[等待, 然後再次輪詢]
E --> C
D -->|ended| F[batches.results id<br/>串流每一個結果]
F --> G{每項 result.type?}
G -->|succeeded| H[讀取 result.message.content<br/>以 custom_id 存放]
G -->|errored / expired / canceled| I[記下 custom_id<br/>留待重送]
```

三個呼叫(Python SDK)。這裡與 `build_practical_test_html.py` 無關——這是真實 API:

```
import anthropic
from anthropic.types.message_create_params import MessageCreateParamsNonStreaming
from anthropic.types.messages.batch_create_params import Request

client = anthropic.Anthropic()

#-- Step 1 - create: wrap each request as Request(custom_id, params)
batch = client.messages.batches.create(
    requests=[
        Request(
            custom_id="doc-invoice-2024-001",
            params=MessageCreateParamsNonStreaming(
                model="claude-haiku-4-5",
                max_tokens=1024,
                messages=[{"role": "user", "content": "Extract data from: ..."}],
            ),
        ),
        # ... up to 100,000 of them
    ]
)
```

```
import time

#-- Step 2 - poll: retrieve the batch and check processing_status until "ended"
while True:
    batch = client.messages.batches.retrieve(batch.id)
    if batch.processing_status == "ended":
        break
    # request_counts tracks live progress: processing / succeeded / errored
    time.sleep(60)
```

```
#-- Step 3 - retrieve: stream results; they arrive in ANY order, so key by custom_id
results = {}
for result in client.messages.batches.results(batch.id):
    if result.result.type == "succeeded":
        msg = result.result.message
        results[result.custom_id] = next(
            (b.text for b in msg.content if b.type == "text"), ""
        )
    else:
        results[result.custom_id] = None # errored / expired / canceled
```

真正重要的狀態:

- **processing_status** (批次物件上)在工作執行時為 `in_progress`, 當每個請求都抵達終態結果時為 `ended`。 `ended` 不代表「全部成功」——它代表「沒有更多工作要做」。一個取消請求會讓它經過 `canceled`。
- **request_counts** (`processing`、`succeeded`、`errored`)是你輪詢時的即時進度錶——對日誌與儀表板很有用。
- **result.result.type** (每項)是 `succeeded`、`errored`、`canceled` 或 `expired` 之一。只有 `succeeded` 會帶 `result.message`; 其餘帶錯誤/狀態細節。

為何用輪詢而非整批串流。沒有任何開啟的連線握著你的批次——它在伺服器端跑數分鐘到數小時。你以合理間隔輪詢 `retrieve` (每 30–60 秒綽綽有餘; 緊迫的迴圈只是浪費呼叫), 只有當 `processing_status == "ended"` 時才拉取結果。結果可存活 **29 天**, 所以批次一結束你不必急著取。

陷阱——在 `ended` 之前取結果, 或讀取非 `succeeded` 項的 `message`。在批次結束前不要呼叫 `results()`, 而且在伸手拿 `result.message` 前永遠先依 `result.type` 分支——`errored` 或 `expired` 的項目沒有 `message`, 無條件讀取 `result.message.content` 會丟出例外。

考試角度。預期會考辨識生命週期的正確順序(create → 輪詢 status → 取結果)、知道 `ended` ≠ 「全部成功」, 以及知道結果可持久保留 29 天(所以你不必在批次完成的那一刻就同步處理它們)。

7.5 處理批次中的失敗

在同一個批次內, 個別請求可以彼此獨立地失敗。整個批次**不會**因為少數請求失敗而失敗——它會抵達 `ended`, 而每個結果各自告訴你它的命運。復原模式是以 `custom_id` 找出、修正原因、只重送失敗項。

```
flowchart TD
    A[提交 100 份文件的批次] --> B[批次結束<br/>95 成功, 5 errored]
    B --> C[串流結果, <br/>收集失敗的 custom_id]
    C --> D[為何失敗?]
    D --> E[將長文件切塊, <br/>再重送那 5 份]
    D --> F[原樣重送那 5 份]
    E --> G[只含失敗項的<br/>新小批次]
    F --> G
    G --> H[將新結果<br/>與 95 個成功合併]
```

具體走一遍:

1. 提交一批 100 份文件。
2. 批次結束:95 份成功,5 份失敗(例如各自超出了上下文視窗)。
3. 串流結果,收集那 5 個失敗的 `custom_id (result.type != "succeeded"` 的那些)。
4. 為那 5 份改變策略——例如把每份長文件切成多塊,或加以裁剪。
5. 只把那 5 份當成新批次重送,再把它們的結果與原本的 95 個合併。

區分失敗類型——它們需要不同的修法。 `errored` 結果帶一個錯誤類型。驗證/ `invalid_request` 錯誤(請求格式不對、文件超出上下文限制)若原樣重送會以相同方式再次失敗——你必須先修正請求。暫時性伺服器錯誤原樣重送是安全的。`**expired**` 結果代表批次在那個請求被處理前撞上了 24 小時上限——重送它(並考慮用較小的批次,讓視窗不再是變數)。盲目重試一個驗證失敗只會再燒掉一個批次;盲目不重試一個暫時性失敗則丟掉了好工作。

為何部分失敗是特性而非缺陷。 因為成功項無論失敗與否都會被計費並交付,你絕不會為了救回 5 份壞文件而重做 95 份好文件。 `custom_id` 為鍵讓「把重試結果合併回來」這一步輕而易舉:那 5 個新結果在相同的鍵下塞回同一個字典。

陷阱——任何失敗就重跑整個批次。 這會為 95 個成功項再付一次錢,而這正是基於 `custom_id` 的選擇性重送所要防止的浪費。只重送失敗項。

陷阱——忽略錯誤子類型。 把每個失敗都當成「重試」會在驗證錯誤上無限迴圈;把每個失敗都當成「放棄」會丟失可復原的那些。讀取錯誤類型並據此分流。

考試角度。 範本情境是「提交 100、部分失敗」——預期答案是以 `custom_id` 找出失敗、處理根本原因、只重送那些,而支撐細節是*區分驗證失敗(先修)與暫時性失敗(原樣重試)*。這是把 Domain 5 的錯誤傳遞概念(結構化、逐項的失敗脈絡)套用到批次任務上。

7.6 SLA 規劃:從期限往回推算

因為批次視窗是「最長 24 小時」,任何真實期限都必須從它往回規劃。規則:你的提交期限 = 你的結果期限 - 24 小時。

若你需要在 30 小時內取得結果,而批次最長可能耗時 24 小時:

- 提交時間視窗: $30 - 24 = 6$ 小時。你最晚必須在從現在算起 6 小時內提交。
- 等價地說,批次最晚必須在你需要其輸出的那一刻至少 24 小時之前提交。
- 對於持續湧入的工作,不要累積成一個巨大的日終批次——按節奏切成較小的批次(例如每 4 小時一次),讓任何單一項目都不會等上完整的 24 小時視窗,也讓晚到的項目仍能趕上期限。

為何大小與節奏會與視窗交互作用。 一個 100,000 請求的批次和一個 500 請求的批次共用同一個 24 小時上限,但小的那個幾乎總是遠早完成。把龐大任務拆成數個較小批次,既能平滑你的進度可見性(各自獨立結束),也能在某個批次過期時縮小波及範圍——你重跑一個切片,而非一整天。

陷阱——以典型完成時間來規劃。「它通常 20 分鐘」不是你能承諾的期限。SLA 計算永遠用 24 小時上限。為最壞情況、而非平均值,預留緩衝。

陷阱——對串流輸入用單一日終巨批。 若你收集一整天的文件、在晚上 11 點為早上 8 點的期限提交,你只有 9 小時緩衝,而且每份文件都等了一整天。頻繁的較小批次讓每個項目的計時很短,並讓你保持在 SLA 內。

考試角度。 計時題給你一個結果期限,問最晚的安全提交時間,或正確的批次節奏。對 24 小時計算:最晚提交 = 期限 - 24h;對持續輸入,切成固定視窗讓任何項目都不會吃滿上限。

7.7 端到端案例研究:離線文件分類管線

上述元件唯有組裝成真實任務才有意義。以下是一個完整、可容忍延遲的管線,正是 Domain 5 要你推理的形狀——一個對大型文件集的隔夜分類與增補執行,為成本與韌性而建。

需求

- 每晚,分類並標記 50,000 張支援工單(類別、優先級、產品區塊),並把標籤寫回資料倉儲。
- 結果在早上 8:00 的分析刷新前需要——隔夜無人等待。
- 成本要緊:50,000 張工單是龐大且重複的任務;團隊希望推論帳單最小化。
- 工作是單輪且獨立的——每張工單各自分類;沒有對話,也沒有工具迴圈。
- 管線必須有韌性:少數過大或暫時性失敗的工單,不可拖垮整個執行或迫使完整重處理。

架構

```
flowchart TD
    Q[每晚工單佇列<br/>50,000 張工單] --> R[建立請求<br/>custom_id = 工單 id<br/>共享且快取的系統提示]
    R --> S[batches.create]
    S --> P[輪詢 processing_status<br/>每 60 秒直到 ended]
    P --> G[串流結果<br/>每個結果以 custom_id 為鍵]
    G --> OK[succeeded<br/>把標籤寫入倉儲]
    G --> BAD[errored 或 expired<br/>收集失敗 id]
    BAD --> FIX[切塊過大工單;<br/>只重送失敗項]
    FIX --> S
    OK --> DONE[倉儲就緒<br/>在 8 點刷新前]
```

這個任務是提交一次然後輪詢,而非保持開啟;模型用 **Haiku 4.5**,因為分類簡單又便宜;一段**共享、快取的系統提示**搭在每個請求上;而失敗是以 `custom_id` **重新對回並重送**,而非重跑整個批次。

實作

用每張工單一個穩定的 `custom_id`,以及一段標記了 prompt caching 的**共享系統提示**來建立批次——快取前綴只付一次,並對全部 50,000 個請求以約 0.1× 讀取,疊加在批次的 50% 折扣之上:

```

import anthropic
from anthropic.types.message_create_params import MessageCreateParamsNonStreaming
from anthropic.types.messages.batch_create_params import Request

client = anthropic.Anthropic()

#-- Shared, cacheable instructions - identical across every request in the batch
TAGGING_SYSTEM = [
    {"type": "text", "text": "You are a support-ticket classifier. Return JSON only."},
    {
        "type": "text",
        "text": TAXONOMY_AND_FEWSHOTS,          # large, stable, reused by all
        "cache_control": {"type": "ephemeral"}, # cached prefix, ~0.1x on reads
    },
]

requests = [
    Request(
        custom_id=f"ticket-{t['id']}",          # stable key, derived from the PK
        params=MessageCreateParamsNonStreaming(
            model="claude-haiku-4-5",          # cheap + fast: right tier for
classification
            max_tokens=256,                    # tags are short; small cap
controls cost
            system=TAGGING_SYSTEM,
            messages=[{"role": "user", "content": t["body"]}],
        ),
    )
    for t in nightly_tickets                  # up to 100,000 per batch
]

batch = client.messages.batches.create(requests=requests)

```

以平緩的間隔輪詢,然後串流結果,把成功與失敗分開——完全以 `custom_id` 為鍵:

```

import time

while True:
    batch = client.messages.batches.retrieve(batch.id)
    if batch.processing_status == "ended":          # ended != all-succeeded
        break
    time.sleep(60)

tags, failed_ids = {}, []
for result in client.messages.batches.results(batch.id):
    if result.result.type == "succeeded":
        msg = result.result.message
        tags[result.custom_id] = next((b.text for b in msg.content if b.type ==
"text"), "")
    else:
        failed_ids.append(result.custom_id)        # errored / expired / canceled

write_tags_to_warehouse(tags)                      # 49,990 good rows land
immediately

```

只重送失敗項,並在修正其原因之後——絕不重送整個批次:

```

if failed_ids:
    retry_requests = [
        Request(
            custom_id=fid,
            params=MessageCreateParamsNonStreaming(
                model="claude-haiku-4-5",
                max_tokens=256,
                system=TAGGING_SYSTEM,
                messages=[{"role": "user", "content":
chunk_if_oversized(ticket_body(fid))}],
            ),
        )
        for fid in failed_ids
    ]
    retry_batch = client.messages.batches.create(requests=retry_requests)
    # poll + merge retry_batch results back into `tags` under the same custom_ids

```


執行軌跡

```
sequenceDiagram
    actor Cron as 每晚任務
    participant API as Batches API
    participant DW as 資料倉儲
    Cron->>API: batches.create(50,000 requests)
    API-->>Cron: batch id, processing_status in_progress
    loop 每 60 秒
        Cron->>API: batches.retrieve(id)
        API-->>Cron: in_progress (succeeded 41,200 / processing 8,800)
    end
    API-->>Cron: processing_status ended (49,990 ok / 10 errored)
    Cron->>API: batches.results(id)
    API-->>Cron: results keyed by custom_id, unordered
    Cron->>DW: 寫入 49,990 個標籤
    Cron->>API: batches.create(10 failures, chunked)
    API-->>Cron: ended, 10 ok
    Cron->>DW: 在 8 點前合併最後 10 個標籤
```

注意這個執行從不阻擋在連線上,從不為那 49,990 個成功項重複付費,並提早數小時清掉期限——24 小時上限從未接近,因為這個任務在規劃時就以緩衝來決定大小與排程。

驗證

- **成本檢查:** 確認批次的明細以同步的約 50% 計費,且大多數請求的 `usage.cache_read_input_tokens` 非零——證明共享系統提示有被快取。若快取讀取為零,代表某個逐請求的差異(時間戳、未排序的欄位)正在使前綴失效。
- **關聯檢查:** 斷言每一筆倉儲列都是以 `custom_id`、而非結果位置為鍵——在測試中把結果串流重新排序,確認標籤仍落在正確的工單上。
- **韌性檢查:** 注入一張過大的工單,確認批次仍抵達 `ended`、那張壞工單以失敗 `custom_id` 浮現,且只有它(而非其餘 49,999 張)被重送。
- **SLA 檢查:** 確認提交發生在早上 8 點相依事件的 ≥ 24 小時之前,或節奏讓每個項目都保持在視窗內。

常見陷阱

- 為了「簡單」把這個放上同步 API——為一個無人等待的任務付雙倍價、還對速率限制施壓(\$7.2)。
- 用陣列索引、而非 `custom_id` 把結果對回工單——只要有一個重排或失敗,就默默把工單貼錯標籤(\$7.3)。
- 10 個失敗就重跑全部 50,000,而非以 `custom_id` 重送那 10 個(\$7.5)。
- 不先檢查 `result.type` 就讀取 `result.message`——在 `errored` 的項目上會丟出例外(\$7.4)。
- 以典型完成時間、而非 24 小時上限來規劃早上 8 點的期限(\$7.6)。

7.8 考試重點 — 關鍵整理

概念	考試考什麼
----	-------

什麼是批次	非同步、**便宜 50%**、最長 24h (無延遲 SLA)、一個請求 → 一個回應、結果保留 29 天 (§7.1)。
批次 vs 同步	以 誰在等待與是不是迴圈 判斷:即時/互動/代理 → 同步;離線 + 獨立 + 大量 → 批次(§7.2)。
<code>custom_id</code>	結果 亂序 回傳;以 <code>custom_id</code> 、絕不以位置關聯——也能做選擇性重試與冪等(§7.3)。
生命週期	create → 輪詢 <code>processing_status</code> 直到 <code>ended</code> → 串流 <code>results</code> ; <code>ended</code> ≠ 全部成功;依 <code>result.type</code> 分支(§7.4)。
失敗處理	以 <code>custom_id</code> 找出失敗, 修正原因、只重送那些 ;區分驗證(先修)與暫時性(原樣重試)(§7.5)。
SLA 規劃	最晚提交 = 期限 - 24h ;把持續輸入切成固定視窗,讓任何項目都不吃滿上限(§7.6)。

對應 Domain 5(15%)。如果你能建構並捍衛上面的每晚分類管線——批次與即時的取捨判斷、submit/poll/retrieve 生命週期、`custom_id` 關聯、選擇性失敗復原,以及 24 小時 SLA 計算——你就掌握了這個領域所考的成本與可靠性核心,外加一個平台事實: Batches 僅限第一方(以及 Claude Platform on AWS),不在 Amazon Bedrock 或 Vertex AI 上。

第 8 章:任務分解策略

文件:[Subagents](#) | [Sessions](#)

分解,是把一個複雜請求拆成**恰當**子任務集合的能力——並且懂得何時該維持為單一任務。它是第 3 章代理機制的編排對應面:第 3 章建構了協調者與 `Task` 工具;本章則決定協調者該把**什麼**交給那些子代理,以及**依什麼順序**交付。本章對應 **Domain 1 — 代理架構與編排(佔考試 27%)**,具體是目標 **1.6 複雜工作流程的任務分解策略**,並倚賴 1.2–1.3 的多代理與上下文傳遞技能。

考試把分解當成一連串**判斷取捨**來考,而非單一演算法。讀完本章,你應能一眼選對策略:

- **固定管線/提示鏈接**(§8.1)— 可預測、事先已知的步驟。
- **動態自適應分解**(§8.2)— 子任務由你所發現的事物產生。
- **循序 vs 平行**(§8.3)— 何時子任務可並行,何時相依關係禁止並行。
- **多遍審查(先扇出再整合)**(§8.4)— 把大型產物逐單元拆開,再做跨單元的一遍。
- **何時不要分解**(§8.5)— 考試最愛探問的過度分解失效模式。

§8.6 以一個端到端的**多代理研究系統**把全章串起來,§8.7 則濃縮考試重點。

8.1 固定管線(提示鏈接)

固定管線(又稱**提示鏈接**)事先把步驟順序寫死。每一階段的輸出成為下一階段的輸入:

```

flowchart TD
    Doc[原始文件] --> Meta[擷取中繼資料]
    Meta --> Data[擷取結構化資料]
    Data --> Val{驗證通過?}
    Val -->|否| Fix[修復或拒絕]
    Val -->|是| Enrich[以參考資料加值擴充]
    Enrich --> Out[最終結構化輸出]
    Fix --> Out

```

每個方塊都是一次獨立、聚焦的模型呼叫(或一個確定性步驟)。因為結構永不改變,你可以隔離測試每一階段、快取中間結果,並事先推算成本。

為何要拆成鏈,而不在單一提示裡一次做完? 每個步驟都拿到模型的全副注意力與一條狹窄指令,因此每個子步驟的準確度上升。你也在每階段之後得到天然的檢查點——驗證可以在壞輸出汙染加值擴充之前就把它擋下。

何時使用:

- 任務結構可預測(例如發票或審查解析總是遵循相同範本)。
- 所有步驟事先已知,且順序永不取決於資料。
- 你需要穩定性、可重現性與逐階段的可觀測性。

陷阱:

- **現實一變就脆。** 若某些文件需要額外步驟,固定管線無法臨時加一步——這就是該轉向 §8.2 的訊號。
- **錯誤傳播。** 沒有驗證閘,一筆壞擷取會悄悄往下游流。務必在相互餵食的階段之間放一道檢查。
- **對瑣碎工作過度鏈接。** 三個各只做一件小事的階段,平白增加三段往返延遲;把它們合併(見 §8.5)。

考試角度:「可預測、每次都同一範本」→ 固定管線/提示鏈接。誘答選項通常會是動態分解(錯,因為範圍事先完全已知)。

8.2 動態自適應分解

在動態計畫裡,子任務是**由中間結果產生的**——你無法在開始前列舉它們,因為下一步取決於上一步發現了什麼:

```

flowchart TD
    Goal[目標:為遺留程式庫加上測試] --> Map[盤點結構<br/>Glob 與 Grep]
    Map --> Found[發現:3 個模組無測試,<br/>2 個僅部分覆蓋]
    Found --> Prio[排定優先順序:先做付款模組<br/>風險最高]
    Prio --> Work[開始撰寫測試]
    Work --> Disc{發現隱藏的<br/>相依性?}
    Disc -->|是| Adapt[插入新子任務:<br/>為外部 API 加 mock]
    Disc -->|否| Next[繼續下一個模組]
    Adapt --> Next

```

計畫是個活物:代理先盤點地形,形成一個排序後的計畫,然後在發現開始前無從得知的事物時(此處是一個外部 API 相依性,迫使新增「加 mock」子任務)**修訂該計畫**。

為何這更難——也更強大。 固定管線假設你對步驟全知。開放式工作並不給你這份全知:你必須讓代理在證據到來時擴展計畫。這裡的紀律是**先盤點再投入**——先探索結構,再依風險排序,而不是一頭栽進看到的第一個檔案。

何時使用:

- 開放式的調查型任務(除錯、稽核、「找出 X 為何很慢」)。
- 開始時完整範圍未知。
- 每一步的**輸出**決定下一步是否**存在**。

陷阱:

- **沒有退出條件。** 一個不斷生成子任務的計畫永遠不會結束。用目標與品質標準錨定它(「每個模組都有 ≥ 1 個測試就停」)。
- **過於急切地調整。** 每遇小驚奇就重新規劃會反覆抖動。當一項發現**改變了工作的結構**時才重新規劃,而非為了表面細節。
- **跨步驟掉了線索。** 因為較後的子任務相依於較早的發現,那些發現必須明確地往前帶(第 3 章 §3.4 的上下文傳遞規則)。

考試角度:「範圍事先未知/每步取決於上一步」→ 動態自適應分解。留意「先盤點結構,再建立排序後的計畫」——這個措辭就是線索。

8.3 循序 vs 平行分解

有了子任務後,下一個決策是**順序**:它們能並行,還是相依關係迫使它們循序?這正是分解與第 3 章 §3.4 平行生成能力(單一協調者回合裡的多個 `Task` 呼叫會同時執行)交會之處。

```
flowchart TD
    Start[已識別子任務] --> Q{任務 B 是否需要  
任務 A 的輸出?}
    Q -->|否,彼此獨立| Par[平行生成  
單一回合多個 Task 呼叫]
    Q -->|是,B 相依於 A| Seq[循序執行  
把 A 結果傳入 B]
    Par --> Agg[彙整結果]
    Seq --> Agg
    Agg --> Done[驗證後的結果]
```

規則由相依性決定,而非偏好。 獨立的子任務(搜尋主題 X、搜尋主題 Y、搜尋主題 Z)應平行扇出——更快,且結果互不影響。相依的子任務(擷取 schema,然後據以驗證資料)必須循序,因為同時執行會讓驗證器拿不到任何輸入。

為何平行並非免費。 平行子代理各自消耗 token 與一個隔離的上下文視窗;三個就夠卻生成十個,既浪費預算,也讓彙整更吵雜。為了**獨立覆蓋**才平行化,不要當成預設值。

常見的相依形態:

- **扇出/扇入(map-reduce):** N 個獨立子任務平行,再一個彙整步驟(這就是 §8.4 的審查模式與 §8.6 的研究模式)。
- **線性鏈:** $A \rightarrow B \rightarrow C$,各自消耗前一個結果(這就是 §8.1)。
- **菱形:** $A \rightarrow \{B, C \text{ 平行}\} \rightarrow D$ ——在共用的設定步驟之後分岔,再重新合流。

陷阱:

- 把真正的相依拿去平行化,會產生一個輸入缺漏而執行的子代理,進而失敗或產生幻覺。
- 把獨立工作拿去循序,則白白損失效能——三段串列搜尋,其實一個平行回合就夠。
- 忘了彙整必須等待。 扇入步驟相依於所有扇出子任務;協調者必須在綜整前收齊每一個結果。

考試角度: 題目常把相依性藏在敘述裡。問:「B 需要 A 的輸出嗎?」是 → 循序;否 → 平行。「分配研究覆蓋以減少重複」是平行扇出的提示。

8.4 多遍審查(先扇出,再整合)

大型產物——一個動到 14 個檔案的 pull request——是扇出再整合的經典案例。第一遍隔離分析每個單元(可平行化);第二遍跨單元推理,無法平行化,因為它需要每一份第一遍的結果:

```
flowchart TD
    PR[Pull request:14 個檔案] --> P1a[Pass 1:分析 auth.ts<br/>局部問題]
    PR --> P1b[Pass 1:分析 database.ts<br/>局部問題]
    PR --> P1c[Pass 1:分析 routes.ts<br/>局部問題]
    P1a --> P2[Pass 2:整合遍<br/>跨檔推理]
    P1b --> P2
    P1c --> P2
    P2 --> Cross[跨檔問題:<br/>型別不一致、循環相依]
```

為什麼一次掃過 14 個檔案不好:

- **注意力稀釋:** 被迫一次握住全部 14 個檔案時,模型對某些檔案分析得深、對其他則流於淺。
- **註解不一致:** 某個模式在一個檔案被標記,卻在另一個檔案被放行,因為模型從未在同一套準則下並排看到它們。
- **漏掉錯誤:** 明顯的錯誤因認知過載而被略過。

為何兩遍能修好它。 第一遍讓每個檔案在同一套準則下拿到模型的全副注意力(一致性)。第二遍存在的唯一目的,是抓出逐檔分析在結構上抓不到的東西:跨模組的型別不一致、循環相依、某個函式在一個檔案被刪卻仍在另一個檔案被呼叫。整合遍是個相依(循序)步驟——它消耗所有第一遍的輸出,因此它就是 §8.3 的扇入。

陷阱:

- **跳過第二遍。** 逐檔審查永遠找不到跨檔錯誤;沒有整合,你就會把循環相依出貨。
- **讓第一遍跨檔推理。** 那會重新引入注意力稀釋;讓每個第一遍子代理只聚焦於一個檔案。
- **無上限地扇出。** 一次 200 個檔案本身就是過載;分批處理,再彙整各批摘要。

考試角度: 「10 個以上檔案的 PR」、「既深入又一致的審查」→ 逐檔遍加上一個獨立的跨檔整合遍。錯誤答案是「在單一提示裡審查所有檔案」。

8.5 何時不要分解

分解有其代價:每個子代理都是一個隔離的上下文視窗,必須明確簡報(第 3 章 §3.4),外加一段往返與一個彙整步驟。**過度分解**——拆了本不需拆的工作——是考試刻意要考的失效模式。

flowchart TD

```
Task[傳入的任務] --> Q1{有多個獨立面向<br/>或屬大型產物?}
Q1 -->|否| Single[用單一聚焦代理完成<br/>不分解]
Q1 -->|是| Q2{子任務需要各自的<br/>上下文或工具?}
Q2 -->|否| Single
Q2 -->|是| Decomp[分解為子代理]
```

不要分解,當:

- **任務小或單一面向**——單檔審查或單次查詢。此處的協調者 + 子代理只增加延遲與簡報負擔,毫無收益。
- **子任務緊密耦合**,且不斷需要彼此的中間狀態。拆開它們會逼你透過協調者來回搬運上下文,比起放在同一個上下文裡,既較慢也較有耗損。
- **額外開銷超過效益**——三個瑣碎步驟,單一提示就能準確處理。

為何考試在意這點。 目標 1.2 明確點名「**協調者過度狹窄分解的風險**」。把一個內聚任務碎成微型子任務的協調者,會失去讓任務變得可解的共享上下文,而彙整反倒成了難題。這裡考的技能是節制:為了獨立覆蓋或注意力隔離才分解,而非條件反射地分解。

陷阱:

- **為了顯得高明而分解。** 正確答案有時就是「一個代理、一條提示」。
- **切碎共享上下文。** 若每個子任務都需要同一份大型文件,你就得付出代價重新簡報每個子代理——不如把它留在同一個上下文裡。

考試角度: 當題目描述一個小或緊密耦合的任務,卻提供一個繁複的多代理拆分時,那個繁複選項通常就是陷阱。優先選擇能滿足需求的最簡設計。

8.6 端到端案例研究:多代理研究系統

上述策略唯有在真實限制下組合起來才有意義。以下是一個完整的研究助理——正是考試的 **Multi-Agent Research System(多代理研究系統)** 情境要你能推理的系統。它演練了本章 **每一個** 決策:固定 vs 動態、平行 vs 循序、扇出/扇入,以及 §8.5 的節制。

需求

- 用一份附引用、已綜整的報告,回答一個寬廣的研究問題(例如:「*比較三家託管 Kubernetes 服務的安全態勢*」)。
- 在子主題之間**分配覆蓋**,讓兩個子代理永不研究同一件事(減少重複——目標 1.2)。
- 獨立的子主題應**平行**研究;綜整必須等待**全部**子主題(一個相依性)。
- 若綜整揭露一個**缺口**(某子主題證據稀薄或互相矛盾),協調者必須**自適應地**生成一個額外的針對性搜尋——而非盲目重跑全部。
- **不要過度分解**:單一、簡單的事實問題,應直接回答,不動用整套機器。

架構

```
flowchart TD
    User([使用者問題]) --> Coord[協調者]
    Coord --> Plan{單一事實的<br/>簡單問題?}
    Plan -->|是| Direct[直接回答<br/>不分解]
    Plan -->|否| Split[分解為<br/>獨立子主題]
    Split --> R1[研究子代理 A<br/>子主題 1]
    Split --> R2[研究子代理 B<br/>子主題 2]
    Split --> R3[研究子代理 C<br/>子主題 3]
    R1 -- 僅回傳發現 --> Synth[綜整步驟<br/>扇入:需要所有結果]
    R2 -- 僅回傳發現 --> Synth
    R3 -- 僅回傳發現 --> Synth
    Synth --> Gap{發現覆蓋缺口<br/>或衝突?}
    Gap -->|是| Extra[自適應:生成一個<br/>針對性的後續搜尋]
    Gap -->|否| Report[附引用的最終報告]
    Extra --> Synth
```

協調者先套用 §8.5(別分解瑣碎問題)。對真正的問題,它把獨立子主題**平行扇出**(§8.3),再跑一個**相依的綜整**(§8.4 扇入),只有在綜整暴露缺口時才**自適應**(§8.2)——一個有界的精修迴圈,而非開放式的。

實作

定義協調者與一個最小權限的研究子代理(沿用第 3 章的機制):

```
coordinator = AgentDefinition(
    name="research_coordinator",
    description="Splits a research question into non-overlapping subtopics, "
               "runs them in parallel, synthesizes, and fills gaps.",
    system_prompt=(
        "Decompose the question into independent subtopics that do not overlap. "
        "If the question is a single simple fact, answer it directly without "
        "subagents. "
        "Spawn one Task per subtopic in a single turn so they run in parallel. "
        "After synthesis, if a subtopic has thin or conflicting evidence, spawn ONE "
        "targeted follow-up search; otherwise produce the cited report. "
        "Judge by coverage and citation quality, not by number of subagents."
    ),
    allowed_tools=["Task"], # 協調者只負責編排
)

researcher = AgentDefinition(
    name="researcher",
    description="Researches exactly one subtopic and returns cited findings.",
    system_prompt="Research the assigned subtopic only. Return findings with "
                  "sources.",
    allowed_tools=["web_search", "fetch_url"], # 最小權限:沒有 Task,無法再分解
)
```

在**單一協調者回合**裡扇出獨立子主題,讓它們並行執行——並把完整上下文明確傳給每個子代理,因為子代理什麼都不繼承(第 3 章 §3.4):


```
# 一次協調者回合送出三個平行 Task, 每個都完整簡報:
Task(researcher, prompt="Subtopic: EKS security posture.\n"
      "Cover: IAM integration, network policy, CVE response.\n"
      "Return: bullet findings, each with a source URL.")
Task(researcher, prompt="Subtopic: GKE security posture.\n...")
Task(researcher, prompt="Subtopic: AKS security posture.\n...")
# 三者同時執行;彼此看不到對方的上下文。
```

綜整 + 缺口檢查是個**循序、相依**的步驟——它必須先收齊**每一個**研究者結果:

```
def synthesize(findings: list) -> Report:
    report = merge_and_cite(findings)
    gap = find_thin_or_conflicting_subtopic(report) # 有界的自適應觸發
    if gap:
        more = Task(researcher, prompt=f"Targeted follow-up on: {gap}. ...")
        report = merge_and_cite(findings + [more])
    return report
```

執行軌跡

```
sequenceDiagram
    actor U as 使用者
    participant Co as 協調者
    participant A as 研究者 A (EKS)
    participant B as 研究者 B (GKE)
    participant C as 研究者 C (AKS)
    U->>Co: 比較 EKS、GKE、AKS 的安全性
    Co->>Co: 不是單一事實, 分解為 3 個子主題
    par 平行扇出
        Co->>A: Task(子主題:EKS, 完整簡報)
        Co->>B: Task(子主題:GKE, 完整簡報)
        Co->>C: Task(子主題:AKS, 完整簡報)
    end
    A-->>Co: EKS 發現 + 來源
    B-->>Co: GKE 發現 + 來源
    C-->>Co: AKS 發現 + 來源
    Co->>Co: 綜整 - AKS 證據稀薄
    Co->>C: Task(針對性後續:AKS 網路政策)
    C-->>Co: 額外的 AKS 發現
    Co-->>U: 附引用的比較報告
```

請注意三個章節概念同時出現:**平行** **par** 區塊是 §8.3 的扇出;**綜整**等待**全部**三個結果(扇入相依);而單一的**針對性後續**是有界的 §8.2 自適應——不是盲目重跑所有子主題。

驗證

- **無重複測試:** 檢視三個 Task 提示,斷言其子主題互不相交——證明協調者分配了覆蓋(目標 1.2)而非重疊。
- **平行性測試:** 斷言三個研究 Task 都在**單一**協調者回合送出(並行),而非三個串列回合。

- **相依性測試:** 斷言綜整只在三個結果全部回傳後才執行——拿掉其中一個,綜整就必須阻塞,證明扇入相依。
- **節制測試:** 餵入一個單一簡單事實(「EKS 最新版本是什麼?」),斷言協調者直接回答、零子代理(\$8.5)。
- **有界自適應測試:** 模擬一個稀薄子主題,斷言剛好觸發一個後續 Task——而非完整重跑。

常見陷阱

- **子主題重疊,**讓兩個子代理研究同一件事——浪費 token,且發現互相矛盾(違反「減少重複」)。
- **串列搜尋,**其實一個平行回合就夠——白白損失延遲(\$8.3)。
- **在所有結果回傳前就綜整——**報告漏掉尚未完成的那個子代理(扇入損壞)。
- **為單一缺口重跑每個子主題,**而非一個針對性後續——無界、昂貴的自適應(\$8.2)。
- **把瑣碎問題丟進整套管線分解——**過度分解(\$8.5)。
- **忘了簡報每個子代理——**隔離的上下文意味著未簡報的研究者產不出任何有用結果(第 3 章 \$3.4)。

8.7 考試重點 — 關鍵整理

概念	考試考什麼
固定管線(提示鏈接)	可預測、同範本、所有步驟事先已知的工作 → 把固定階段鏈接起來並加上驗證閘(\$8.1)。
動態自適應分解	開放式/範圍未知、每步取決於上一步 → 先盤點結構,再建立並修訂排序後的計畫(\$8.2)。
循序 vs 平行	依相依性決定:「B 需要 A 的輸出嗎?」否 → 平行扇出;是 → 循序(\$8.3)。
扇出/扇入	獨立子任務平行,再一個相依於全部結果的彙整(\$8.3、\$8.4)。
多遍審查	10 個以上檔案的 PR → 逐檔遍求一致,加上一個獨立的跨檔整合遍以抓循環相依/型別不符(\$8.4)。
何時不要分解	小、單一面向或緊密耦合的工作 → 單一聚焦代理;過度分解會失去共享上下文(\$8.5)。
分配覆蓋	協調者必須切分子主題以減少重複;子代理不繼承任何上下文,必須簡報(\$8.6)。

對應 Domain 1(27%),目標 1.6。如果你能選對固定 vs 動態、平行 vs 循序,以及——最關鍵的——何時不要分解,並能捍衛上面的研究系統,你就掌握了權重最高考試領域中,分解的那一半。

第 9 章:升級與人在迴路(Human-in-the-Loop)

文件:Agent SDK Hooks | Subagents | Sessions

自主代理唯有在知道自身能力邊界、並能在到達邊界時乾淨地交接時,才是安全的。升級——暫停自主、把決策交給真人——正是讓代理在情況超出其應獨自裁量範圍時,仍守在政策之內的控制機制。本章主要對應 Domain 1 — 代理架構與編排(佔考試 27%),具體是 1.4 帶強制執行與交接模式的多步驟 workflow,同時也對應 Domain 5 — 上下文管理與可靠性(佔 15%),具體是 5.2 升級模式與 5.5 人工監督與信心校準。考試在此考的是判斷力,而非冷知識:它會給你一個臨界案例,問代理應該自行解決、追問、還是升級——以及升級是「如何」被強制執行的。

讀完你應能掌握五件事,並把它們組裝成可上線的人在迴路系統:

- **升級觸發條件**(§9.1)— 哪些訊號可靠地表示「停下並交接」,以及哪些訊號誘人卻錯誤。
- **升級模式**(§9.2)— 立即升級 vs. 先嘗試 vs. 細緻處理(同理 → 解決 → 升級)。
- **結構化交接**(§9.3)— 真人需要一份自成一體的封包,因為他們看不到逐字記錄。
- **信心校準與人工監督**(§9.4)— 把低信心的工作路由到審查,並稽核其餘的高信心部分。
- **確定性強制執行**(§9.5)— 用 hook(而非僥倖)讓升級真的發生。

§9.6 接著從頭到尾建構一個完整的**高金額付款核准代理**——觸發條件、由 hook 強制執行的核准關卡、結構化交接,以及真人決定後的恢復——§9.7 則濃縮考試重點。

9.1 何時升級至真人

升級是一個路由決策:這通電話該由「誰」來下判斷,代理還是人?考試獎勵的能力,是能從一段簡短情境中辨識出觸發條件,並**立即且正確地**採取行動,而不過度調查或猜測。

升級觸發條件(明確、可靠的規則):

情境	動作	為何這是正確的判斷
客戶明確要求「幫我找主管」	立即升級;不要嘗試自行解決	明確的找真人請求是硬訊號。繼續「幫忙」會凌駕客戶已表明的選擇,並侵蝕信任。
政策未涵蓋該請求	升級(例如政策未規範時的競品比價折扣)	代理無權自行發明政策。政策沉默/模糊時,該決策必須由真人承擔。
代理無法取得進展	在嘗試合理次數後升級	無限迴圈會燒掉 token 並惹惱使用者;有上限的若干次實際嘗試後再交接,才是契約。
超過門檻的金融/不可逆操作	升級(用 hook 強制執行,而非靠提示)	金錢與不可逆動作需要的是保證,而非 >90% 的傾向。見 §9.5。
搜尋客戶時出現多筆相符結果	要求提供額外的識別資訊;不要猜測	對錯誤的紀錄採取行動,是資料完整性與隱私事故。先釐清身分。

陷阱——過度熱心的解題者。 最常見的錯誤答案,會把明確的「我要找主管」當成需要**說服客戶打消念頭**的事。在考試裡,明確的找真人請求是**立即升級**,不再進一步調查。(見 5.2 技能:「對明確的找真人請求立即執行,不另作調查。」)

哪些不是可靠的觸發條件:

不可靠的方法	為何會失效	改用什麼做法
情緒分析	客戶情緒與案件複雜度並不相關;冷靜的客戶可能有超出政策的案件,而憤怒的客戶可能只是小問題	觸發點放在 事實 (明確請求、政策缺口、門檻),而非語氣
模型自評信心(1-10)	模型可能 自信地犯錯 ;口頭信心校準很差,且容易被措辭操弄	使用對照標註資料、經過校準的 實測 欄位層級分數(§9.4),而非模型自己編的數字
(外掛的)自動分類器	過度設計;需要你未必有的訓練資料,還多了一種失效模式	先用明確規則 + few-shot 範例;只有在規則確實無法表達該政策時,才加入機器學習

考試角度。一個常見的干擾選項是「用情緒分析決定何時升級」。它之所以錯,有一個**原則性**理由——情緒不等於複雜度。把升級錨定在具體、可檢核的條件上。

9.2 升級模式

知道該不該升級只是答案的一半;考試也會考互動的**形態**。共有三種模式,選錯就是會被扣分的錯誤。

```
flowchart TD
    In[客戶訊息] --> Q1{明確要求<br/>找真人?}
    Q1 -->|是| Esc[立即升級<br/>不再嘗試]
    Q1 -->|否| Q2{在代理範圍<br/>與政策內?}
    Q2 -->|否, 政策缺口| Esc
    Q2 -->|是| Try[嘗試解決<br/>提供具體選項]
    Try --> Q3{客戶滿意<br/>或重申找真人?}
    Q3 -->|重申找真人| Esc
    Q3 -->|滿意| Done[解決並結案]
```

立即升級——明確請求會短路一切:

```
Customer: "I want to speak to a manager"
Agent: [立即呼叫 escalate_to_human]
NOT: "I can help with your issue, let me..."
```

嘗試解決後再升級——請求在範圍內,所以先試,若方案未被接受再交接:

```
Customer: "My refrigerator broke two days after purchase"
Agent: [查看訂單, 提供保固更換]
若客戶不滿意 -> 升級
```

****細緻的升級(同理 → 解決 → 客戶重申時升級)****——這是最常被考的模式,因為天真的答案會太早升級:

```
Customer: "This is outrageous, I'm very unhappy with the quality!"
Agent: [同理對方的不滿] "I understand your frustration."
      [提供解決方案] "I can offer a replacement or a refund."
Customer: "No, I want to talk to someone!"
Agent: [客戶再次堅持 -> 立即升級]
```

關鍵原則:先同理對方的情緒,接著提出**具體**的解決方案,只有在客戶重申想找真人時才升級。不要在客戶第一次表達不滿時就升級——發洩與要求找主管並不相同。太早升級會丟掉首次接觸解決率(客服情境的目標是80%+);太晚升級——在客戶已明確要求找真人之後——則凌駕了客戶。

政策缺口的升級——代理絕不可即興行使它沒有的權限:

```
Customer: "Competitor X has this item 30% cheaper—give me a discount"
Policy: 僅涵蓋自家網站上的價格調整
Agent: [升級 – 政策未涵蓋競品比價]
```

陷阱。 把政策缺口當成政策拒絕。代理不該說「不,我們不做這個」(它無權決定),也不該自行發明折扣(超出政策)。正確做法是把這個例外升級給能夠承擔它的人。

9.3 結構化交接協定

接手升級的真人**看不到對話逐字記錄**——他們只看得到代理交給他們的內容。因此交接封包必須**完整、自成一體且結構化**。這與把上下文傳給子代理是同一種紀律(第3章,§3.4):凡是沒有明確納入的,接收方都不會繼承。

升級時,代理應將結構化摘要傳遞給真人:

```
{
  "customer_id": "CUST-12345",
  "customer_name": "Ivan Petrov",
  "issue_summary": "Refund request for a damaged item",
  "order_id": "ORD-67890",
  "root_cause": "Item arrived damaged; photos attached",
  "actions_taken": [
    "Verified customer via get_customer",
    "Confirmed order via lookup_order",
    "Offered a standard replacement – customer insists on a refund"
  ],
  "refund_amount": "$89.99",
  "recommended_action": "Approve a full refund",
  "escalation_reason": "Customer requested to speak with a manager"
}
```

真人操作員無法存取完整的對話逐字記錄——他們只看得到這份摘要。因此它必須完整且自成一體。

怎樣才算好的交接(以及考試會檢查什麼):

- **識別碼**(`customer_id`、`order_id`),讓真人不必重新詢問就能行動。
- **根因與 actions_taken**,讓真人不必重做代理已完成的工作——即使跨越交接,這正是保住首次接觸解決率的關鍵。
- **一個 recommended_action**——代理已經做了功課,把它的建議呈現出來,讓真人確認而非重新調查。
- **一個明確的 escalation_reason**——這同時成為「為何自主停止」的稽核紀錄。

陷阱——有損的交接。 像「客戶不開心,請協助」這樣的摘要,會逼真人從零開始,讓代理失去意義。把**交易性事實**——識別碼、金額、日期——逐字保留;這些正是漸進式摘要傾向模糊掉的值(Domain 5,5.1)。把它們放進結構化封包,而非埋在散文裡。

9.4 信心校準與人工監督

並非每個人在迴路的決策都是即時的對話交接。在高量管線中(**結構化資料擷取情境**),迴路是**統計性**的:多數項目自動處理,而經校準的少數會路由到人工審查。考試在此考兩個概念——**經校準的欄位層級信心與分層稽核**——並警告不要只信一個整體數字。

對於資料擷取系統:

1. **欄位層級信心分數:** 模型為每個擷取出的欄位輸出一個信心分數,而非整份文件一個分數——日期可以很確定,而手寫的總額未必。
2. **校準:** 使用已標註的驗證集來調整門檻值,讓「0.9 信心」真的對應到約 90% 的實測準確度(這正是校準的意思——也是為何 §9.1 中模型自評的 1–10 不算校準)。
3. **路由:**
 - 高信心 + 穩定準確度 -> 自動化處理
 - 低信心或來源不明確 -> 人工審查

```
flowchart TD
    Doc[擷取出的欄位<br/>加上信心] --> T{T{信心高於<br/>校準門檻?}}
    T -->|是| Auto[自動處理]
    T -->|否| Review[路由到人工審查]
    Auto --> Sample[{分層隨機<br/>抽樣}]
    Sample --> QA[依類型與欄位<br/>檢查準確度]
    Review --> QA
    QA -->|發現漂移| Recal[重新校準門檻]
```

分層隨機抽樣:

- 即使是高信心的擷取結果,也要定期稽核一份樣本——信心是估計而非保證,且新的文件版面會造成無聲的漂移。
- 整體 97% 的準確度可能掩蓋了某種特定文件類型 40% 的錯誤——良好的多數掩蓋了壞掉的少數。
- **依文件類型與欄位**分析準確度,而不只是看整體;正是這種分層,才能讓隱藏的 40% 浮現。

考試角度。 當題目報出單一的頭條準確度(「我們的擷取器有 97% 準確度,上線吧」),預期的批評是:整體數字可能掩蓋一個失敗的區段。修正方式是分層抽樣與分區段分析,在信任自動化之前——而非盲目地調高全域門檻。

9.5 確定性升級:Hooks 與提示指令

升級觸發條件可以放在兩個非常不同的地方,而這個區別是本章最可能被考的單一重點。你可以請求模型升級(提示指令),也可以在程式碼中強制升級(hook)。兩者不可互換。

提示指令(「若金額超過 \$10,000,升級給真人核准」)是**機率性**的:模型大多數時候會遵守,但「大多數時候」不是你能擺在稽核員面前的控制。**hook**(`PreToolUse`)會在工具呼叫執行前攔截它,並**確定性地**改道——模型無法繞過程式碼。


```
# 機率性: 模型通常會遵循的指引
# (適用於軟性偏好; 不適用於金錢/不可逆動作)
system_prompt = "If a transfer is over $10,000, escalate to a human for approval."

# 確定性: 模型無法繞過的 hook
@hook("PreToolUse")
def require_approval_over_limit(tool_call):
    if tool_call.name == "execute_transfer" and tool_call.args["amount"] > 10_000:
        # 是程式碼, 不是建議: 改道至核准關卡。
        return redirect(to="request_human_approval", reason="amount_over_limit")
    return allow(tool_call)
```

屬性	Hooks	提示指令
保證	確定性 (100%)	機率性 (>90%, 並非 100%)
由誰強制	代理執行環境中的程式碼	模型的遵循度
何時使用	關鍵業務規則、金融/不可逆操作、合規關卡	一般偏好、語氣、建議、格式設定
範例	阻擋/改道任何 > \$10,000 的轉帳	「在升級前先嘗試解決」
失效模式	對該規則本身沒有(它總會觸發)	在邊界措辭、長上下文、對抗式輸入下無聲漏失

規則: 當失敗會造成財務、法律或安全後果時,升級必須是 **hook**,而非提示。提示是用來處理它周邊那些軟性、可恢復的偏好(「展現同理心」「先提供替代方案」)。這呼應第 3 章的 hooks 與提示原則;在這裡,被強制的事物就是人工核准關卡本身。

考試角度。 一道經典題:「政策規定超過 \$10k 的轉帳需要主管核准——這條規則該放哪?」被評分的答案是 hook/前置條件,並以**確定性**為理由。「放進系統提示」是那個聽起來合理、卻會在正式環境失敗的干擾選項。

9.6 端到端案例研究:高金額付款核准代理

上述元件唯有組合在一起才有意義。以下是一個完整、真實的人在迴路系統——一個能動用資金的付款助理,但**必須**讓真人核准任何大額付款,核准關卡以確定性方式強制執行,且工作流能在真人決定後**恢復**。這是一個與第 3 章退款代理不同的問題:在那裡,hook **阻擋**了一個超限動作;在這裡,hook **開啟**一個核准關卡,代理暫停、等待真人裁決,然後繼續——這是真正的人在迴路,而不只是停下。

需求

- 讓內部操作員以自然語言請求對外付款(「付發票 INV-4471,\$14,200 給 Acme Ltd」)。
- 查詢收款方與發票(唯讀工具)。
- 硬性規則:** 任何**達到或超過 \$10,000** 的轉帳,在執行前都需要**明確的真人核准**——沒有例外,不交由模型裁量。
- 核准必須是真正的暫停:代理發出一個結構化核准請求,**等待**,只有在核准的裁決下才執行;遭拒則取消並說明。
- 其他方面有效的低於門檻轉帳(< \$10,000)可以自動執行。

- 當收款方查詢回傳多筆相符結果時,升級(不要猜測)。

架構

```
flowchart TD
    Op([操作員]) --> Coord[付款協調者]
    Coord -->|Task| Lookup[子代理 收款方與發票<br/>get_payee, lookup_invoice]
    Lookup --> Multi{多筆收款方<br/>相符?}
    Multi -->|是| Disamb[請操作員<br/>提供識別資訊]
    Multi -->|否| Coord
    Coord --> Transfer[execute_transfer]
    Transfer --> Gate{{PreToolUse hook<br/>金額達到或超過 10000?}}
    Gate -->|是| Approve[request_human_approval<br/>暫停並等待]
    Gate -->|否| Exec[執行轉帳]
    Approve --> Human([核准者])
    Human -->|核准| Exec
    Human -->|拒絕| Cancel[取消並說明]
```

協調者掌管編排;查詢子代理是最小權限(它能讀取收款方與發票,但**無法動用資金**);由 **hook**(而非提示文字)強制執行核准關卡,因為漏掉一個關卡就是無法挽回的財務事件。

實作

定義協調者與一個最小權限的查詢子代理:

```
coordinator = AgentDefinition(
    name="payments_coordinator",
    description="Prepares and submits outbound payments; routes large transfers for human approval.",
    system_prompt=(
        "You help an operator pay invoices. Look up the payee and invoice, "
        "confirm the amount, then call execute_transfer. "
        "Be empathetic and explain delays, but never promise a payment you have not executed."
    ),
    allowed_tools=["Task", "execute_transfer", "request_human_approval"],
)

payee_lookup = AgentDefinition(
    name="payee_lookup",
    description="Reads payee and invoice records. Read-only.",
    system_prompt="Return the payee and invoice details as structured data. If multiple payees match, return all candidates.",
    allowed_tools=["get_payee", "lookup_invoice"],    # 最小權限:無法動用資金
)
```

用 `PreToolUse` hook 確定性地強制執行 \$10,000 核准關卡——這正是考試要你答對的關鍵。注意它並不**阻擋** workflow;它改道進入一個人工核准步驟:

```

APPROVAL_LIMIT = 10_000

@hook("PreToolUse")
def require_approval_over_limit(tool_call):
    if tool_call.name == "execute_transfer" and tool_call.args["amount"] >=
APPROVAL_LIMIT:
    # 模型無法繞過這條規則；它是程式碼，不是建議。
    return redirect(
        to="request_human_approval",
        reason="amount_over_limit",
        payload=build_handoff(tool_call.args),    # 結構化、自成一體
    )
    return allow(tool_call)

```

建立核准者會看到的結構化交接封包(他們看不到逐字記錄——§9.3):

```

def build_handoff(args):
    return {
        "payee_id": args["payee_id"],
        "payee_name": args["payee_name"],
        "invoice_id": args["invoice_id"],
        "amount": args["amount"],
        "actions_taken": [
            "Verified payee via get_payee",
            "Matched invoice via lookup_invoice",
        ],
        "recommended_action": "Approve transfer",
        "escalation_reason": "Transfer at or above the $10,000 approval limit",
    }

```

在真人決定後恢復。代理在關卡處暫停;裁決重新進入迴圈,決定下一個工具呼叫:

```

def on_approval_verdict(verdict, case):
    if verdict.approved:
        # 恢復具名 session,讓迴圈繼續往執行推進。
        resume_session(case.session_id, message=f"Approval granted by
{verdict.approver}; proceed.")
    else:
        cancel_transfer(case)    # 不要執行;向操作員說明

```

執行軌跡

```
sequenceDiagram
    actor Op as 操作員
    participant Co as 協調者
    participant L as 查詢子代理
    participant Gate as PreToolUse hook
    participant Hu as 核准者
    Op->>Co: 「付發票 INV-4471,14200 給 Acme」
    Co->>L: Task(上下文:發票 INV-4471 + 收款方)
    L-->>Co: 收款方 Acme, 發票有效, 金額 14200
    Co->>Gate: execute_transfer(amount=14200)
    Gate->>Gate: 14200 >= 10000, 改道至核准
    Gate->>Hu: request_human_approval(交接封包)
    Note over Co,Hu: 代理暫停 – 等待裁決
    Hu-->>Co: 經主管核准
    Co->>Co: 恢復 session, 推進至執行
    Co-->>Op: 「14200 給 Acme 的轉帳已於核准後執行。」
```

注意協調者原本打算直接轉帳;而 **hook 確定性地把它改道**進入人工關卡,代理暫停,只有在核准的裁決下才繼續執行。若只用提示指令(「超過 \$10k 的轉帳要升級」),模型大約 90% 的時候會遵守——而那十分之一的漏失,就是一筆無法召回的電匯。

驗證

- **確定性測試:** 連續送出 100 筆 \$10,000 的轉帳,斷言出現 100 次核准請求與**零次**自動執行。只靠提示的設計會漏;hook 設計必須 100%。
- **邊界測試:** 斷言 `$9,999.99` 自動執行、`$10,000.00` 路由到核准——把 `>=` 與 `>` 的邊界弄對(這裡的差一錯誤就是一個合規漏洞)。
- **恢復測試:** 核准一個暫停中的案件,斷言剛好一次 `execute_transfer`;拒絕另一個,斷言**沒有**轉帳且有清楚的操作員說明。
- **交接完整性測試:** 斷言核准封包包含收款方、發票、金額與理由,且沒有任何「請見對話」之類的指涉(核准者沒有逐字記錄——§9.3)。
- **最小權限測試:** 斷言 `payee_lookup` 子代理無法呼叫 `execute_transfer`。
- **釐清身分測試:** 當 `get_payee` 回傳兩筆相符時,斷言代理會要求提供識別資訊,而不是付給其中任何一方 (§9.1)。

常見陷阱

- 把 \$10,000 規則放進系統提示而非 hook——機率性,沒有保證 (§9.5)。
- 把關卡當成硬性**停止**而非**暫停再恢復**:真正的人在迴路必須在核准後繼續,而不是走到死路 (§9.6 恢復步驟)。
- 有損的交接(「大額付款,請核准」),會逼核准者重新調查,因為他們看不到逐字記錄 (§9.3)。
- 因操作員對延遲的**不耐**而升級,而非因**金額**而升級——語氣不是觸發條件 (§9.1)。
- 在查詢結果模糊時猜測收款方,而不是要求提供識別資訊 (§9.1)。
- 把「付款已送出」這類助理文字當成完成訊號,而不是 `stop_reason == "end_turn"` (第 3 章,§3.1)。

9.7 考試重點 — 關鍵整理

概念	考試考什麼
可靠的觸發條件	依事實升級——明確的找真人請求、政策缺口、無法推進、超過門檻、相符結果模糊——而非依情緒或自評信心(\$9.1)。
立即 vs. 細緻	明確的「幫我找真人」要 立即 升級;範圍內的抱怨則遵循同理 → 解決 → 重申時升級(\$9.2)。
政策缺口	沉默/模糊的政策應升級,而非拒絕,也非即興發明(\$9.1–9.2)。
結構化交接	真人只看得到封包,看不到逐字記錄——把它做得完整,含識別碼、已採取的動作、建議與理由(\$9.3)。
信心校準	使用對照標註資料、經校準的欄位層級分數;整體準確度可能掩蓋一個失敗的區段——用分層抽樣稽核(\$9.4)。
Hooks 與提示	金融/不可逆的升級關卡必須是 確定性 hook ,而非提示指令(\$9.5)。
人在迴路,而非只是停下	真正的核准關卡會 暫停、等待裁決並恢復 ——它不會讓工作流走到死路(\$9.6)。

對應 Domain 1(27%)與 Domain 5(15%)。 如果你能建構並捍衛上面的付款核准代理——正確的觸發條件、對的升級模式、自成一體的交接、經校準的路由,以及一個會暫停並恢復的確定性核准關卡——你就掌握了這兩個領域所考的人在迴路核心。

第 10 章:多代理系統中的錯誤處理

文件:[Agent SDK](#) | [Subagents](#) | [Streaming & errors](#) | [Tool results](#)

在單一代理系統中,失敗通常是看得見的——迴圈停止、例外浮現、使用者看到錯誤。但在**多代理**系統中,失敗會藏起來。某個子代理逾時、回傳空清單,或悄悄降級,而協調者——它從未看到失敗,只看到(缺失的)結果——便在資料的破洞之上,綜整出一個看似自信的最終答案。本章是 **Domain 5 — 上下文管理與可靠性(佔考試 15%)**(尤其是 §5.3,錯誤傳播)的可靠性骨幹,也是 **Domain 1 — 代理架構與編排(27%)** 受到壓力測試之處:在順利路徑上看似正確的編排,一旦有任何一根輻條失敗就會崩解。

貫穿全章的核心原則:**子代理在失敗時的職責,不是悄悄自行復原,而是回報足夠的結構化上下文,讓協調者能決定該怎麼做。** 復原是協調者層級的責任,因為只有協調者看得到整個任務的全貌。

讀完本章,你應能掌握六件事,並把它們組裝成一個有韌性的編排器:

- **錯誤分類法**(§10.1)— 先把失敗分類,才有可能採取**正確**的動作。
- **反模式**(§10.2)— 多代理錯誤處理悄悄出錯的四種方式。
- **結構化錯誤回報**(§10.3)— 子代理 → 協調者的契約。
- **韌性模式**(§10.4)— 退避重試、逾時、斷路器、冪等性、優雅降級。
- **錯誤彙整與涵蓋範圍標註**(§10.5)— 協調者如何誠實地回報部分成功。
- **完整的有韌性旅遊預訂編排器**(§10.6)— 從頭到尾。

§10.7 濃縮考試重點。

10.1 錯誤類別

在處理錯誤之前,你必須先**分類**它,因為每一類的正確動作都不同。多代理最常見的錯誤,就是對某一類採用了錯誤的動作——對一個驗證錯誤無限重試,或對一個只要重試一次就能修好的暫時性小故障進行升級。

類別	範例	可重試?	正確的代理動作
Transient(暫時性)	Timeout、HTTP 503、速率限制(429)、網路重置	是	以指數退避 + jitter 重試;限制次數
Validation(驗證)	輸入格式無效、缺少必填欄位、schema 不符	否(重試無濟於事)	修正輸入,再以更正後的請求重試一次
Business(業務)	政策違規、超出門檻、無可用資源	否	向使用者說明;提出替代方案;不要重試
Permission(權限)	存取被拒、憑證過期、範圍錯誤	否	升級給真人 / 重新驗證;絕不悄悄吞掉

為何分類這道關卡很重要(考試角度)。 可重試性是**錯誤類別**的屬性,而非情境的屬性。`429 Too Many Requests` 是暫時性的——退避後重試。`400 missing field "destination"` 是驗證錯誤——重試同一個請求只是浪費延遲與 token;你必須先**改變**請求。考試經常呈現一個失敗並詢問正確的回應方式;陷阱答案會把暫時性策略(重試)套用在不可重試的類別(業務/驗證/權限)上。

陷阱——把各類別場縮成一個通用的「錯誤」。 若子代理只回報「失敗」,協調者就無法挑選動作。§10.3 的全部重點,就是保留**類別**(以及更多),讓協調者的決策是有依據的,而非靠猜。

陷阱——把「沒有結果」當成錯誤(或反過來)。 一個**成功執行**的搜尋回傳空結果集,是一個**有效的業務結果**(「沒有任何符合項目」),而非暫時性失敗。重試它毫無意義。反過來,一個**回傳空值**的逾時是存取失敗,重試可能會成功。要區分這兩者——若你只檢查(空的)酬載,它們看起來一模一樣——在 Domain 5.3 中有明確的考點,也是 §10.2 的主題。

10.2 錯誤處理反模式

這四個反模式是多代理可靠性題目中反覆出現的「錯誤答案」。每一個都會摧毀協調者所需要的資訊。

反模式	為何會破壞系統	正確做法
通用狀態(「search unavailable」)	協調者無法分辨暫時性與永久性,因此無法選擇重試或降級	回傳錯誤 類型 、嘗試的查詢、部分結果與替代方案(§10.3)
靜默抑制(空結果被當成成功)	協調者以為真的沒有符合項目,但搜尋其實失敗了——資料破洞被當成事實呈現	區分「沒有結果」(業務)與「搜尋失敗」(暫時性);絕不為當機回傳 <code>[]</code>
中止全世界(一個子代理失敗 → 殺掉整個工作流程)	你丟棄了已成功的 80%;一根不穩的輻條拖垮一個數小時的工作	以部分結果繼續,標註缺口(§10.5)
子代理內部無限重試	延遲與成本暴增;協調者對停滯一無所知;斷路器永遠不會打開	僅做 本地 復原(1–2 次有界重試),然後將結構化錯誤傳播給協調者

```

flowchart TD
    Sub[子代理遇到失敗] --> Cls{分類錯誤}
    Cls -->|transient| Loc[本地復原<br/>1 至 2 次有界重試<br/>搭配退避]
    Cls -->|validation| Fix[更正請求<br/>重試一次]
    Cls -->|business 或 permission| Prop[立即傳播<br/>不重試]
    Loc -->|仍然失敗| Prop
    Fix -->|仍然失敗| Prop
    Prop --> Struct[回傳結構化錯誤<br/>類型, 查詢, 部分結果, 替代方案]
    Struct --> Coord[協調者決定<br/>重試, 降級, 改道, 或升級]

```

分工(考試的核心心智模型)。 子代理對暫時性錯誤做有界的本地復原,然後帶著結構回報上去。協調者掌握策略性決策——用不同查詢重試、改道到備援子代理、捨棄該節並標註,或升級。任何設計只要子代理 (a) 無限重試(從不回報)或 (b) 回報時沒有結構(協調者無法決定),就是反模式。韌性存在於互動之中,而非單一代理身上。

10.3 子代理 → 協調者的契約:結構化錯誤

一個無法完成任務的子代理,不應拋出一個赤裸的例外或回傳空結果。它應回傳一個**結構化錯誤物件**,給協調者選擇復原路徑所需的一切:

```

{
  "status": "partial_failure",
  "failure_type": "timeout",
  "attempted_query": "AI impact on music industry 2024",
  "partial_results": [
    { "title": "AI Music Generation Report", "url": "...", "relevance": 0.8 }
  ],
  "alternative_approaches": [
    "Try a narrower query: 'AI music composition tools'",
    "Use an alternative data source"
  ],
  "coverage_impact": "Not covered: AI impact on music production"
}

```

每個欄位的存在都是為了回答協調者的某個特定問題:

- **status** — success | partial_failure | failure。讓協調者無需解析散文即可分支。(與「空的成功」不同——見 §10.2。)
- **failure_type** — §10.1 的類別(timeout、 validation、 business、 permission)。驅動要不要重試的決策。
- **attempted_query** — 嘗試了什麼,讓協調者能用不同方式重試,而非原樣重試。
- **partial_results** — 任何確實成功的部分,讓部分成果永不被丟棄(打敗「中止全世界」)。
- **alternative_approaches** — 子代理建議的下一步;子代理對為何失敗握有最多的本地上下文。
- **coverage_impact** — 精確的缺口,讓最終綜整能誠實地標註(§10.5)。

有了這個物件,協調者就能確定性地、依據資料而非臆測來決定:

- 以修改後的查詢重試?(暫時性 + 一個更窄的替代方案)

- 直接使用部分結果?(涵蓋範圍夠用)
- 委派給不同的子代理 / 資料來源?(主來源掛了)
- 不含本節繼續並標註缺口?(優雅降級)

考試角度。 題目會把一個「薄」錯誤(`{"error": "search failed"}`)與這個「厚」的結構化錯誤對比,並詢問哪一個能促成更好的復原。結構化物件勝出,因為它保留了類別、部分成果與替代方案——正是復原決策所需的輸入。薄錯誤迫使協調者用猜的,而那通常意味著「中止全世界」或盲目重試。

10.4 韌性模式

結構化契約(§10.3)是子代理回報什麼。下列模式則是它在回報前如何在本機復原,以及協調者在反覆失敗下如何保持健康。這些是考試期望你能辨識並正確定位的具名模式。

10.4.1 指數退避與 Jitter 重試

僅對暫時性錯誤重試——但不要立即重試,也不要無限重試。每次重試等待更久(指數),並加上隨機的 jitter,讓許多代理在共同的服務中斷後重試時,不會同步成「驚群效應(thundering herd)」,在同一瞬間猛擊正在復原的服務。

```
import random, time

def call_with_backoff(fn, *, max_attempts=3, base=0.5, cap=8.0):
    for attempt in range(max_attempts):
        try:
            return fn()
        except TransientError:
            if attempt == max_attempts - 1:
                raise # 有界:放棄,讓呼叫端傳播
            delay = min(cap, base * (2 ** attempt)) # 0.5s, 1s, 2s ...
            time.sleep(delay + random.uniform(0, delay)) # full jitter
```

陷阱: 重試非暫時性錯誤(400 每次都會以相同方式失敗);無界次數(延遲/成本暴增——見 §10.2);沒有 jitter(同步重試會放大中斷)。重試屬於子代理內部的有界本地復原;協調者不會微管理它們。

10.4.2 逾時

每一次外部呼叫與每一次 Task 委派都需要一個**截止期限(deadline)*。沒有它,單一個卡住的依賴就會讓整個編排無限期停滯——這是最糟的失敗模式,因為什麼都不會回報上去。逾時把一個看不見的卡死,轉換成一個看得見、可分類的 timeout 錯誤,流經 §10.3。

```
result = await asyncio.wait_for(subagent.run(task), timeout=20.0) # 否則
TimeoutError
```

階層式地編列逾時預算:協調者的整體截止期限必須大於各子代理截止期限的總和(若平行則取最大值)再加上重試時間,否則協調者會殺掉那些原本即將成功的子代理。

10.4.3 斷路器(Circuit Breaker)

如果某個下游依賴(例如飯店 API)已經在失敗,送給它更多重試流量只會讓中斷更嚴重,並把你的延遲預算花在注定失敗的呼叫上。**斷路器**追蹤近期的失敗,一旦跨過門檻就**打開(open)**——在一段冷卻窗口內**短路**對該依賴的呼叫,改為快速失敗。冷卻過後它進入半開(**half-open**),放一個探測通過,成功就重新**關閉(close)**。

```
flowchart TD
```

```
  Closed[CLOSED<br/>呼叫照常通過] -->|失敗超過門檻| Open[OPEN<br/>快速失敗, 略過呼叫]
  Open -->|冷卻期已過| Half[HALF-OPEN<br/>放行一個探測]
  Half -->|探測成功| Closed
  Half -->|探測失敗| Open
```

考試角度。斷路器是「重試風暴」的解藥:重試(§10.4.1)幫助個別呼叫熬過**短暫小故障**,斷路器則藉由完全停止重試,保護系統免於**持續性**中斷。要把它們理解為**互補**,而非彼此的替代——退避對付暫時性,斷路器對付持續性。

10.4.4 冪等性(Idempotency)

當你重試一個有副作用的動作(扣款、訂位、寄信)時,即使你收到了逾時,第一次嘗試**可能其實已經成功**。天真地重試會**重複預訂**。解法是**冪等鍵(idempotency key)**:呼叫端為每個邏輯操作產生一個唯一鍵,並在每次重試時送出;下游服務記錄該鍵,對任何重複的請求回傳**原始結果**,讓副作用**剛好發生一次**。

```
key = idempotency_key(booking_id, leg="flight") # 跨重試保持穩定
book_flight(flight_id, idempotency_key=key)     # 可安全重試:至多一次副作用
```

規則:重試(§10.4.1)與冪等性(§10.4.4)是一對。重試一個非冪等的副作用本身就是反模式——永遠不要只啟用其中一個。

10.4.5 優雅降級與後備方案(Fallback)

當一個非關鍵能力永久失敗時,系統應以**縮減的範圍**繼續,而非中止。為每個能力定義「降級」長什麼樣子:一個後備資料來源、一個快取值,或單純**省略**某個可選的章節並加以標註(§10.5)。關鍵能力(任務為**其而存在**的那些)則可能改為需要升級——降級是給**可選**部分用的。

10.5 錯誤彙整與涵蓋範圍標註

當子代理平行執行時,協調者收到的是成功與結構化錯誤的**混合**。它的職責是把它們**彙整**成一個誠實的結果——絕不隱藏失敗。交付物必須明確指出**哪些有充分支持**、**哪些地方有缺口**,讓閱讀它的人不會被誤導去信任一個不完整的章節。

```
## Report: AI Impact on Creative Industries
```

```
### Visual Art (FULL COVERAGE)
```

```
[research results]
```

```
### Music (PARTIAL COVERAGE – search agent timeout)
```

```
[partial results]
```

```
⚠ Note: coverage for this section is limited due to a timeout in the search agent.
```

```
### Literature (FULL COVERAGE)
```

```
[research results]
```

為何是標註,而非省略。悄悄丟掉 Music 那一節,會是協調者層級的 §10.2 靜默抑制失敗:讀者會假設報告是完整的。標註把一個隱藏的破洞轉換成一個被宣告的限制——讀者能自行決定該缺口是否重要、是否要重跑。這是子代理 `coverage_impact` 欄位在協調者端的鏡像。

考試角度。正確的多代理設計會帶著來源出處傳播部分成功:每節都標示完整或部分涵蓋,並指名其成因(哪個代理、哪種失敗類型)。那些一遇失敗就中止、或把部分資料當成完整呈現的設計,都是錯的。

10.6 端到端案例研究:有韌性的旅遊預訂編排器

上述模式唯有在真實失敗下仍能環環相扣才有意義。以下是一個完整的編排器,操練了其中每一個模式——它有別於第 3 章的退款代理,因為這裡的難處不在於某條業務規則,而在於熬過彼此獨立、各有副作用的子代理的部分失敗。

需求

- 從一個自然語言請求預訂一趟行程:一張機票、一間飯店,以及(可選的)一輛租車,各透過一個獨立的下游 API、由各自的子代理負責。
- 三項預訂平行執行(它們彼此獨立)。
- 任何一段的暫時性失敗(逾時、503)都必須以退避重試,但要有界。
- 某一段持續性故障的 API 必須觸發斷路器,讓編排器快速失敗,而非讓整趟行程停滯。
- 預訂有副作用——重試絕不可重複預訂(冪等性)。
- 租車是可選的:若無法訂到,行程仍以租車優雅降級(標註,而非中止)的方式完成。
- 機票與飯店是關鍵的:若兩者之一最終失敗,編排器必須回滾任何已完成的段並升級——絕不留給客戶一趟訂了一半的行程。

架構

```
flowchart TD
    User([旅客]) --> Coord[預訂協調者]
    Coord -->|Task, 平行| F[機票子代理<br/>重試加斷路器]
    Coord -->|Task, 平行| H[飯店子代理<br/>重試加斷路器]
    Coord -->|Task, 平行| C[租車子代理<br/>可選]
    F -- 結構化結果 --> Coord
    H -- 結構化結果 --> Coord
    C -- 結構化結果 --> Coord
    Coord --> Agg{彙整結果}
    Agg -->|機票與飯店皆成功| Done[確認行程<br/>租車若降級則標註]
    Agg -->|關鍵段失敗| Rb[回滾已訂的段<br/>冪等取消] --> Esc[升級給真人]
```

協調者掌管彙整與「關鍵 vs 可選」政策;每個子代理掌管自身的**有界本地復原**(退避)與自身 API 上的**斷路器**; **冪等鍵**讓預訂與回滾都能安全重試。

實作

定義協調者與三個最小權限子代理。每個預訂子代理只拿到自己的預訂 + 取消工具:

```
coordinator = AgentDefinition(
    name="booking_coordinator",
    description="Books flight + hotel (critical) and car (optional); degrades or
rolls back on failure.",
    system_prompt=(
        "Book the trip by delegating each leg in parallel. Flight and hotel are
required; "
        "the car is optional. If a critical leg cannot be booked, roll back booked
legs and escalate. "
        "Report coverage honestly – never present a half-booked trip as complete."
    ),
    allowed_tools=["Task", "cancel_booking", "escalate_to_human"],
)

flight_agent = AgentDefinition(
    name="flight_agent",
    description="Books one flight. Bounded retries; reports structured errors.",
    system_prompt="Book the requested flight. On transient error retry up to 2x with
backoff, then report.",
    allowed_tools=["book_flight", "cancel_flight"], # 最小權限:只有自己的 API
)
# hotel_agent、car_agent 以類似方式定義
```

每個子代理的本地復原結合了**退避**(僅暫時性)、**斷路器**(每個 API 一個)、**冪等性**(可安全重試)與一個**逾時**——然後回傳 §10.3 的結構化物件:

```

def book_leg(book_fn, args, *, breaker, idem_key):
    if breaker.is_open():
        # §10.4.3 快速失敗——已知 API 故障
        return structured_error("breaker_open", args, partial=None,
                                alt=["retry after cool-down", "try backup
provider"])
    try:
        # §10.4.4 冪等性 + §10.4.2 逾時 + §10.4.1 有界退避
        result = call_with_backoff(
            lambda: with_timeout(book_fn, **args, idempotency_key=idem_key,
timeout=20.0)
        )
        breaker.record_success()
        return {"status": "success", "booking": result}
    except TransientError as e:
        # 已用盡有界重試
        breaker.record_failure()
        return structured_error("timeout", args, partial=None,
                                alt=["try backup provider"])
    except ValidationError as e:
        # §10.1 不可重試
        return structured_error("validation", args, partial=None,
                                alt=["correct dates/passenger info"])

```

協調者彙整這三個結果,並套用**關鍵 vs 可選**政策:

```

def aggregate(flight, hotel, car):
    booked = [r["booking"] for r in (flight, hotel, car) if r["status"] ==
"success"]
    if flight["status"] != "success" or hotel["status"] != "success":
        for b in booked:
            # §10.4.4 冪等回滾
            cancel_booking(b["id"], idempotency_key=cancel_key(b["id"]))
        return escalate_to_human(reason="critical_leg_failed", context=[flight,
hotel])
    if car["status"] != "success":
        # §10.4.5 + §10.5 降級 + 標註
        return confirm_trip(flight, hotel, car_note="⚠ Car unavailable – booked
flight + hotel only.")
    return confirm_trip(flight, hotel, car)

```

執行軌跡

一次飯店 API 出現暫時性小故障(重試後復原)、而租車 API 嚴重故障(斷路器打開)的執行——行程仍以優雅降級的方式完成:

```
sequenceDiagram
    actor T as 旅客
    participant Co as 協調者
    participant F as 機票代理
    participant H as 飯店代理
    participant C as 租車代理
    T->>Co: 「幫我訂 LON 到 TYO、飯店,還有一輛車」
    par 平行委派
        Co->>F: Task book_flight (idem key F)
        Co->>H: Task book_hotel (idem key H)
        Co->>C: Task book_car (idem key C)
    end
    F-->>Co: success 預訂 FL-91
    H->>H: 503, 退避 1s, 重試成功
    H-->>Co: success 預訂 HT-44
    C->>C: 斷路器 OPEN, 快速失敗
    C-->>Co: partial_failure breaker_open, alt 備援供應商
    Co->>Co: 機票 + 飯店皆成功, 租車為可選
    Co-->>T: 「行程已確認(機票 + 飯店)。租車無法提供——已標註。」
```

注意有三個本章概念同時發動:飯店那一段以**退避重試**並復原(\$10.4.1);租車那一段的**斷路器原本就已打開**,於是快速失敗而非停滯(\$10.4.3);而協調者在可選的那一段**優雅降級**,同時仍確認關鍵的兩段(\$10.4.5 + \$10.5)——而非中止整趟行程。

驗證

- **退避上界測試**: 強制某一段永遠回傳 503;斷言它**剛好**重試到上限(例如 3 次)後回傳一個結構化的 `timeout` 錯誤——絕不卡死,絕不無限迴圈(\$10.4.1、\$10.2)。
- **冪等性測試**: 以相同的鍵送出同一筆預訂兩次(模擬一次其實已成功卻逾時後的重試);斷言只存在**一筆**預訂,而非兩筆(\$10.4.4)。
- **斷路器測試**: 把租車 API 推過失敗門檻;斷言接下來的呼叫快速失敗(不打 API)直到冷卻過後,然後一個半開探測把它關閉(\$10.4.3)。
- **降級測試**: 只讓租車失敗;斷言行程仍被**確認**並帶著標註,而機票/飯店的預訂**不會**被回滾(\$10.4.5、\$10.5)。
- **回滾測試**: 讓飯店(關鍵)失敗;斷言任何成功的機票預訂被**冪等地取消**,且該案被**升級**——沒有任何訂了一半的行程留存。

常見陷阱

- 對 `validation` 失敗(旅客資料錯誤)以退避重試——它會以相同方式失敗;你必須**更正輸入**,而非重試(\$10.1)。
- 帶著重試卻**沒有冪等鍵**的預訂 → 一次逾時卻其實成功的第一次嘗試會重複預訂(\$10.4.4)。
- 讓一個失敗的段**中止整趟行程**,而非降級可選的租車 / 僅在**關鍵**失敗時回滾(\$10.2、\$10.4.5)。
- 子代理在內部**無限重試**,以致協調者永遠不知道租車 API 已故障,斷路器也永遠不會打開(\$10.2、\$10.4.3)。
- 租車其實當機了卻回傳 `[]` (空),導致協調者回報「不需要租車」而非「租車無法提供」(\$10.2 靜默抑制)。

10.7 考試重點 — 關鍵整理

概念	考試考什麼
錯誤分類法	可重試性是類別的屬性:暫時性重試;驗證先修正再重試;業務說明;權限升級(\$10.1)。
無結果 vs 失敗	成功但為空的結果是業務結果;回傳空值的逾時是暫時性——絕不混為一談(\$10.1–10.2)。
結構化錯誤契約	子代理回傳 <code>failure_type</code> + <code>attempted_query</code> + <code>partial_results</code> + <code>alternatives</code> ,讓協調者能決策,而非靠猜(\$10.3)。
本地 vs 策略性復原	子代理做有界本地重試後傳播;協調者掌握重試/降級/改道/升級(\$10.2–10.3)。
退避 + jitter	對暫時性錯誤採指數退避加 jitter;次數有界;避免驚群效應(\$10.4.1)。
斷路器	在持續失敗後打開以快速失敗並保護系統;與重試互補(而非取代)(\$10.4.3)。
冪等性	重試有副作用的動作需要冪等鍵——重試與冪等性是一對(\$10.4.4)。
優雅降級	可選能力失敗時以縮減範圍繼續;標註缺口而非中止(\$10.4.5、\$10.5)。
涵蓋範圍標註	誠實彙整:每節標示完整或部分涵蓋並指名成因;絕不把部分資料當成完整呈現(\$10.5)。

對應 Domain 5(15%,錯誤傳播 §5.3)與 Domain 1(27%,編排)。如果你能建構並捍衛上面的旅遊預訂編排器——分類、退避重試、斷開電路、保持冪等、降級可選並回滾關鍵、標註涵蓋範圍——你就掌握了這兩個領域所考的可靠性核心。

第 11 章:正式環境系統中的上下文管理

文件:[Effective context engineering](#) | [Prompt caching](#) | [Compaction](#) | [Context editing](#)

上下文視窗是模型唯一的記憶。代理在任一時刻所「知道」的一切——系統提示、工具定義、每一筆先前的工具結果、整段對話——都必須塞進一個有限的 token 預算裡;而一旦這個預算被填滿或被打散,代理就會開始遺忘事實、用「典型模式」搪塞、甚至自相矛盾。上下文管理就是讓「對的」token 留在視窗裡、把「錯的」擋在外面的學問——一輪接一輪、跨越壓縮、跨越整個工作階段。本章是 Domain 5 — 上下文管理與可靠性(佔考試 15%) 的骨幹,也是 Domain 1–4 中每一個長時間運行代理的底層支撐。

讀完你應能掌握一份預算與七項技巧,並把它們組裝成一個能撐過多日調查的代理:

- 上下文預算與其失效模式(\$11.1)— 是什麼填滿視窗、回想能力如何劣化(中段遺失、context rot)。
- 將事實擷取至持久區塊(\$11.2)— 在不丟失數字與 ID 的前提下撐過摘要。
- 修剪工具結果(\$11.3)— 確定性地從 40 個欄位中只保留 5 個。
- 位置感知組裝(\$11.4)— 把高訊號 token 放在模型真正會讀的位置。
- 滑動視窗 vs. 摘要 vs. 壓縮(\$11.5)— 三種卸除歷史的方式,以及各自適用的時機。
- 即時擷取與暫存檔/記憶(\$11.6)— 以參照取代負載,並在上下文重置後仍維持持久。
- 子代理隔離與 prompt caching(\$11.7)— 保護主視窗,並讓穩定前綴只付一次費用。

§11.8 接著從頭到尾建構一個完整的**長程式碼庫安全稽核代理**,§11.9 把這一切連回現代的「上下文工程」詞彙,§11.10 則濃縮考試重點。

11.1 上下文預算及其如何失效

把視窗當成一份你主動配置的預算,而不是一個任你填的桶子。每次請求都以固定順序組合——** tools → system → messages **——而你要管理的,正是這些區段的累計總量:

```
flowchart TD
    Budget[上下文視窗預算<br/>有限的 tokens] --> Sys[系統提示<br/>穩定, 設定一次]
    Budget --> Tools[工具定義<br/>穩定, 設定一次]
    Budget --> Hist[訊息歷史<br/>每輪都在增長]
    Hist --> Results[工具結果<br/>往往是最大、最吵雜的部分]
    Results --> Rot{接近<br/>上限了嗎?}
    Rot -->|否| Continue[正常繼續運行]
    Rot -->|是| Shed[卸除歷史<br/>修剪、摘要或壓縮]
    Shed --> Continue
```

為何重要——上下文是有限資源,而更大的視窗並不能廢除這個問題。即便有 200K–1M token 的視窗,回想能力仍會隨 token 增加而劣化,Anthropic 稱此現象為 **context rot(上下文腐化)**:注意力必須計算每一對 token 的關係, n^2 成本在長輸入下被攤薄,因此決定品質的是「訊號雜訊比」而非原始容量。更大的預算只是**延後失效**,並不能避免它。

考試要你能說出的四種失效模式:

- **漸進式摘要的損失** — 每次歷史被摘要,精確的數值(金額、百分比、日期、ID)就被壓縮成含糊的散文(「客戶想要退款」),從此一去不返。
- **中段遺失(lost-in-the-middle)** — 模型可靠地關注長輸入的**開頭與結尾**,卻可靠地漏掉埋在**中間**的內容。放在 60 個檔案傾印正中央的關鍵發現,可能根本不會被用到。
- **工具結果膨脹** — 工具輸出在視窗中累積的量與其相關性不成比例;一個只需要 5 個欄位卻回傳 40 個的 `lookup_order`,在它留在歷史裡的每一輪都花掉應有 8 倍的 token。
- **長工作階段的上下文劣化** — 超過某個門檻後,模型會產生不穩定的答案,並開始引用「典型模式」或通用類別名稱,而非它稍早讀到的具體符號。

****考試角度: *題目很少問「視窗多大」。它會給你一個症狀***——代理在長對話後忘了訂單金額,或漏掉了明顯就在結果裡的漏洞——要你說出機制與對策。把症狀 → 成因 → 修法對應起來(§11.2–§11.7)。

11.2 將事實擷取至持久區塊

對話歷史是存放關鍵事實的**錯誤**地方,因為歷史正是會被摘要、被丟失的那一塊。應改為把交易性事實提取到一個結構化區塊,並在**每一個**提示中逐字重新注入,與其餘歷史如何被壓縮無關:


```
=== CASE FACTS (updated whenever a new fact appears) ===
Customer ID: CUST-12345
Order ID: ORD-67890
Order Date: 2025-01-15
Order Amount: $89.99
Issue: Damaged item on delivery
Customer Request: Full refund
Status: Pending manager approval
===
```

無論歷史如何被摘要,都要在每個提示中納入這個區塊。

****為何有效:**事實區塊是活在「可被摘要的逐字紀錄」之外的受控附加狀態*。當壓縮把 30 輪對話場縮成一段文字時,那段文字可能有損——但事實區塊會被原封不動地帶過,因此 `$89.99` 與 `ORD-67890` 永遠不會模糊成「那筆訂單」。

陷阱:

- 讓區塊無限增長——它就反而變成膨脹問題的一部分。把它限制在持久的識別碼與決策,而非流水帳般的敘述。
- 只把事實存在散文歷史裡,還信任摘要器會保留數字——它不會可靠地做到。
- 事實改變時(例如 `Status` 變成 `Approved`)忘了更新區塊,讓模型依據過時狀態推理。

****考試角度:**經典題幹是「長對話後代理引用了錯誤的退款金額」。正解是每輪都注入的持久事實區塊——而不是*「用更大的模型」或「加大上下文視窗」。

11.3 修剪工具結果

工具結果是原始資料,對當前步驟而言其中大部分都是雜訊。用 `PostToolUse` hook 確定性地修剪它,讓模型甚至看不到它不必要的那 35 個欄位:

```
# PostToolUse hook: 只保留相關的欄位
@hook("PostToolUse", tool="lookup_order")
def trim_order_fields(result):
    return {
        "order_id": result["order_id"],
        "status": result["status"],
        "total": result["total"],
        "items": result["items"],
        "return_eligible": result["return_eligible"]
    }
```

這能節省上下文並減少雜訊。

****為何用 hook 而非提示:**「請忽略不相關的欄位」是機率性的——即便模型名義上忽略了,那些 token 仍在視窗裡耗用預算、招來干擾。`PostToolUse` hook 在它們抵達模型之前*就移除,因此節省是確定性的,而且在這筆結果原本會滯留歷史的每一輪都會累加。

陷阱:

- 過度修剪:丟掉一個你之後才需要的欄位(例如下游呼叫要用的 `customer_id`)會逼你重新抓取——付出的代價比省下的更多。針對任務修剪,並刻意地放寬。
- 修剪了顯示卻沒修剪上下文:給使用者看 5 個欄位、卻仍把全部 40 個餵給模型,等於白做。
- 把後續綜整步驟用來歸因主張所需的出處(來源 URL、紀錄 id)也修剪掉了(見第 12 章)。

****考試角度:****「工具回傳 40+ 個欄位但任務只需要 5 個」是直接的 Domain 5.1 技能——答案是一個 `PostToolUse` 修剪 hook,要理解為 token 預算衛生,而非表面清理。

11.4 位置感知組裝

由於中段遺失,你把資訊放在**哪裡**會決定它是否被用到。當你為模型組裝彙整資料時,把高訊號內容放在**最上方與最下方**,把大量細節埋在中間:

```
[KEY FINDINGS – at the top]
Found 3 critical vulnerabilities...

[DETAILED RESULTS – middle]
=== File auth.ts ===
...
=== File database.ts ===
...

[ACTION ITEMS – at the end]
Priority: fix auth.ts vulnerabilities before merge.
```

****為何有效:****最上方錨定了模型對其後一切的詮釋;最下方是最近讀到、注意力最集中的位置,最適合放你最希望被遵守的指令。龐大、可掃讀的細節之所以放在中間,正是因為它能容忍較弱的注意力——模型可以按需從中擷取,而不需要把它全部抱在手上。

陷阱:

- 以原始傾印開頭、結尾卻無任何可行動內容——你最在乎的那一條指令落進了死區。
- 重新標註區段卻不重新排序:標題有幫助,但**位置**是更強的槓桿。
- 以為 1M token 的模型就免疫——效應會縮小但不會消失;無論視窗多大,都要刻意安排位置。

****考試角度:****遇到「代理漏掉了明明就在結果裡的發現」,要辨識出中段遺失,並開出「摘要置頂 + 明確區段標題」這帖藥,而不是「模型壞了」。

11.5 滑動視窗 vs. 摘要 vs. 壓縮

當歷史超出預算時,你有三種卸除它的方式——考試要你為情境挑對那一種:

flowchart TD

```
Over[歷史超出預算] --> Q{什麼必須存活?}
Q -->|只要最近幾輪| SW[滑動視窗<br/>逐字捨棄最舊的對話]
Q -->|整個運行過程的<br/>決策與事實| Sum[摘要<br/>把舊對話濃縮成回顧]
Q -->|接近上限, 伺服器端| Comp[壓縮<br/>API 摘要歷史, 從中繼續]
SW -- Risk1[風險—無聲捨棄<br/>早期事實, 須搭配事實區塊]
Sum -- Risk2[風險—對數字<br/>與出處有損]
Comp -- Risk3[風險—下次請求必須<br/>把壓縮區塊附回去]
```

- **滑動視窗**逐字保留最後 N 輪、捨棄最舊的。對它保留的內容而言便宜且無損,但它會截斷早期上下文——對閒聊無妨,對「關鍵事實在第 2 輪就確立」的調查卻很危險。**滑動視窗務必搭配 §11.2 的事實區塊**,讓被截斷的事實得以存活。
- ****摘要(漸進式)***把舊對話濃縮成持續更新的回顧,以精度為代價保留整個運行過程的決策——這正是 §11.1 警告其損失的技術,所以要明確指示它保留關鍵決策、數字與出處*,並驗證它確實做到了。
- **壓縮(compact)** 是伺服器端的版本:接近上限時,API 摘要歷史,你從摘要繼續。**關鍵操作細節:** 你必須在下次請求把整個 `response.content` (包含壓縮區塊)附回去,否則被壓縮的狀態就會遺失。 `/compact` 命令與 Agent SDK 會自動做這件事。

*為何這個區別重要:*它們的失效方式不同。滑動視窗無聲地丟失舊*內容;摘要在各處丟失精度*;壓縮若你重播區塊則不丟失任何東西,但若你忘了,則丟失所有被壓縮的內容。如何選擇,取決於「什麼必須存活」。

****考試角度:****一場必須記住某個具體類別簽章的長調查 → 採用明確保留它的摘要,或一個事實區塊——而不是會把它丟掉的天真滑動視窗。「在長調查中用 `/compact` 來降低上下文」是預期的 Domain 5.4 技能。

11.6 即時擷取、暫存檔與記憶

最便宜的 token 是你從不載入的那一個。與其事先載入整個檔案或資料集,不如保留**輕量參照**——檔案路徑、URL、紀錄 ID——只在需要時才用工具取得實際內容。

暫存檔(scratchpad) 是這套做法在工作階段內的形式。在長調查期間,代理把關鍵發現寫入檔案,稍後再讀回,而不必重新推導:

```
# investigation-scratchpad.md
## Key findings
- PaymentProcessor in src/payments/processor.ts inherits from BaseProcessor
- refund() is called from 3 places: OrderController, AdminPanel, CronJob
- External PaymentGateway API has a rate limit of 100 req/min
- Migration #47 added refund_reason (NOT NULL) - 2024-12-01
```

當上下文劣化時(或在新的工作階段中),代理會查詢暫存檔,而不必重新執行探索。

記憶(跨工作階段) 把暫存檔推廣到單次運行的邊界之外:持久存到外部儲存的發現,能撐過上下文重置與整個工作階段,賦予長程代理它在視窗內永遠無法保有的連貫性。Agent SDK 的記憶工具與託管記憶儲存就是其機制。

****為何參照勝過負載:****一個路徑約 10 個 token;它指向的檔案可能有 10,000 個。持有路徑幾乎不花成本,並讓模型選擇*只在任務需要時才花那 10,000 個—— n^2 注意力成本只付在一個小工作集上,而非整個語料庫。

陷阱:

- 寫入暫存檔卻從不讀回(它必須在提示中或被取回才有意義)。
- 過時的記憶:持久化了一個之後改變的發現,卻從不使其失效。
- 過度擷取:每一輪都重新載入同一個大檔案,而不是把它摘要一次進事實區塊或暫存檔。

****考試角度:****「每次上下文劣化,代理就重讀同樣的 15 個檔案」 → 暫存檔/記憶 + 即時擷取。「工作階段重啟時所有發現都不見了」 → 跨工作階段的記憶,而非更大的視窗。

11.7 子代理隔離與 prompt caching

有兩項結構性技巧不只是修剪視窗,而是保護並支付視窗的成本。

子代理隔離把冗長的探索性工作委派給一個擁有自己乾淨上下文視窗的子代理;子代理做雜亂的閱讀並回傳精簡結果,讓主代理的視窗只保有一行、而非十五個檔案:

```
Main agent: "Investigate dependencies of the payments module"
  -> Subagent (Explore): reads 15 files, traces imports
  -> Returns: "Payments depends on AuthService, OrderModel, and the external
PaymentGateway API"

Main agent: keeps one line in context instead of 15 files
```

****獨立的上下文層:****在多代理系統中,每個子代理都在有限的上下文預算內運作——它只接收其任務所需的資訊。協調者扮演一個獨立的上下文層:它彙整子代理的輸出、儲存全域狀態,並配置上下文。這能防止「上下文洩漏」,亦即某個代理用與其他代理無關的資訊耗盡了視窗。

子代理受限的上下文預算:

- 傳送最少的上下文:一個明確的任務 + 必要的資料(子代理不會自動繼承任何東西——見第 3 章)。
- 指示子代理回傳結構化結果,而非原始資料傾印。
- 使用 `allowedTools` 來限制子代理的工具集——工具越少代表干擾越少、上下文成本越低。

Prompt caching 處理的是大型穩定前綴的成本。API 會把組合後的提示快取到某個 `cache_control` 斷點;在後續請求中,被快取的前綴以 $\sim 0.1\times$ 讀取,而非以全價重新計費(寫入在 5 分鐘 TTL 為 $1.25\times$ 、1 小時為 $2\times$;最多 4 個斷點):

```
system=[
  {"type": "text", "text": LARGE_AUDIT_RUBRIC,           # 對每個檔案都穩定
    "cache_control": {"type": "ephemeral"}},             # 在此處之前的前綴快取起來
]
```

***為何斷點的擺放是成敗關鍵:**快取是依組合順序 `tools → system → messages` 的前綴比對*,因此斷點之前的任何位元組變動都會使其後的一切失效。把斷點放在穩定的 rubric/工具定義之後、易變的逐檔內容之前*——而且絕不要把時間戳記、請求 id 或使用者名稱插進系統前綴,否則你會在每次呼叫都讓快取失效。

陷阱:

- 快取了一個含易變內容的前綴 → 快取讀取維持為零,你白付了寫入溢價。
- 子代理回傳原始傾印 → 你只是把膨脹搬走,並沒有移除它。
- 給子代理寬鬆的 `allowedTools` → 它會亂逛,膨脹自己的上下文與它的摘要。

****考試角度:****「一份穩定的 20K token rubric 在數千次檔案檢查中被重複傳送」 → 在 rubric 之後設斷點的 prompt caching。「探索輸出淹沒了主代理」 → 委派給一個回傳結構化摘要的子代理。

11.8 端到端案例研究:長程程式碼庫安全稽核代理

上述技巧唯有在真實壓力下組合起來才有意義。以下是一個完整、真實的代理,正是 Domain 5.4 要你能推理的那種——一場遠大於單一上下文視窗、且必須跨工作階段存活的稽核。

需求

- 對一個 **2,400 個檔案的 monorepo**,依一份固定的 **20K token 安全 rubric**,稽核注入、權限繞過與機密處理缺陷。
- 完整程式碼庫遠超任何單一上下文視窗,因此代理必須**增量地**調查,並可能**跨多個工作階段運行數日**。
- **精確的事實必須撐過摘要**:確切的檔案路徑、行號、CVE 風格的發現 id 與嚴重度——絕不可模糊成「一些權限問題」。
- 該次運行**必須可恢復**,在當機或刻意停止後接續,不必重新稽核已完成的模組。
- 成本要緊:rubric 在每個檔案檢查上都相同,絕**不可以**全價重複計費數千次。

架構

```
flowchart TD
    Coord[稽核協調者<br/>持有 rubric 與發現區塊] --> Cache["Cache{{Prompt cache<br/>rubric 前綴, 讀取 ~0.1x}}"]
    Coord --> Task[掃描模組]
    Task --> Sub[掃描子代理<br/>乾淨視窗, 只有 read_file 與 grep]
    Sub --> Trim["Trim{{PostToolUse hook<br/>把檔案讀取修剪成命中片段}}"]
    Trim --> Sub
    Sub --> Coord
    Coord --> Facts["FINDINGS 區塊<br/>path, line, id, severity"]
    Coord --> State["agent-state JSON<br/>每個模組的狀態"]
    Coord --> Near["接近上下文<br/>上限了嗎?"]
    Near --> Compact["是| Compact[壓縮或摘要<br/>逐字保留 FINDINGS]"]
    Near --> Next["否| Next[派發下一個模組]"]
    Compact --> Next
    Next --> Coord
```

協調者掌管編排與持久的 FINDINGS 區塊;每個模組由一個擁有乾淨視窗、最小權限唯讀工具的隔離子代理掃描;**rubric 只快取一次、檔案讀取被確定性地修剪、發現被持久化為事實與狀態、壓縮只卸除可拋棄的敘述——每一項 Ch11 技巧各司其職。**

實作

快取穩定的 rubric,並給掃描子代理一個乾淨、最小權限的視窗(它什麼都不會繼承——第 3 章):

```

coordinator = AgentDefinition(
    name="audit_coordinator",
    description="Audits a large repo module-by-module; preserves findings and resumes.",
    system_prompt=AUDIT_COORDINATOR_PROMPT,
    allowed_tools=["Task", "write_state", "read_state"],
)

scan_subagent = AgentDefinition(
    name="module_scanner",
    description="Scans one module against the rubric. Read-only.",
    system_prompt="Apply the security rubric to the given files. Return findings as JSON.",
    allowed_tools=["read_file", "grep"],          # 最小權限:無法寫入或修復
)

# 20K 的 rubric 在每個檔案檢查上都相同——快取它,讓讀取以 ~0.1x 計費。
system = [
    {"type": "text", "text": AUDIT_RUBRIC,
     "cache_control": {"type": "ephemeral"}},      # 斷點放在穩定 rubric 之後
]

```

把每次檔案讀取修剪成命中區域,讓一個 1,200 行的檔案不會整個坐在視窗裡:

```

@hook("PostToolUse", tool="read_file")
def keep_only_hits(result):
    # 只回傳命中片段加上幾行上下文,而非整個檔案。
    return {"path": result["path"], "spans": extract_match_spans(result["content"])}

```

把發現持久化為持久事實以及可恢復的每模組狀態:

```

# agent-state/manifest.json - 驅動恢復
{ "payments": "completed", "auth": "in_progress", "billing": "not_started" }

# FINDINGS 區塊,每輪逐字重新注入(撐過摘要):
# === FINDINGS (id, path:line, severity) ===
# SEC-001 src/auth/session.ts:88 HIGH missing signature check
# SEC-002 src/payments/refund.ts:42 MED unparameterized SQL
# ===

```

當視窗接近上限時就壓縮——但 FINDINGS 區塊與狀態檔都在可被摘要的歷史之外,因此不會丟失任何精確內容。

執行軌跡

```
sequenceDiagram
    actor Op as 操作員
    participant Co as 協調者
    participant Ca as Prompt cache
    participant Su as 掃描子代理
    participant St as 狀態儲存
    Op->>Co: 稽核這個 monorepo
    Co->>St: 載入 manifest(auth 進行中)
    Co->>Ca: 送出 rubric 前綴(快取寫入,1.25x)
    Co->>Su: Task(掃描 src/auth,rubric 已快取)
    Ca-->>Su: rubric 前綴(快取讀取,~0.1x)
    Su-->>Co: 發現 JSON(SEC-001 HIGH 於 session.ts:88)
    Co->>Co: 把 SEC-001 附加到 FINDINGS 區塊
    Co->>St: 標記 auth 完成、billing 進行中
    Note over Co: 視窗接近上限 -> 壓縮歷史,<br/>FINDINGS + 狀態逐字存活
    Op->>Co: (隔天)恢復
    Co->>St: 載入 manifest -> 略過 auth,從 billing 開始
```

注意這條軌跡裡的三個 Ch11 動作:rubric **只付一次費**(寫入),之後在每個後續模組都以 **~0.1× 讀取**;子代理回傳的是**結構化摘要**,而非它讀過的檔案;而 FINDINGS 區塊加上狀態儲存,讓代理能**自由壓縮並隔天恢復**,不丟失任何一筆精確發現。

驗證

- ****事實存活測試:****在運行途中強制一次壓縮,然後向代理詢問 `SEC-002` 的確切 `path:line` 與嚴重度。它必須精確回答——證明撐過摘要的是 FINDINGS 區塊,而非逐字紀錄。
- ****恢復測試:****在 `auth` 完成後砍掉程序、重啟,並斷言它從 manifest 略過 `auth`、從 `billing` 開始——沒有任何模組被重新稽核。
- ****快取測試:****斷言 `usage.cache_read_input_tokens` 在大部分檔案檢查上非零。為零代表有個易變位元組(時間戳記、未排序的欄位)正在使 rubric 前綴失效。
- ****隔離測試:****確認掃描子代理是在它的 Task 提示中收到目標路徑,且無法呼叫任何寫入工具(最小權限)。

常見陷阱

- 把發現存在對話敘述裡而非持久區塊,結果讓確切行號在壓縮中遺失(§11.2、§11.5)。
- 把整個檔案餵進視窗而不修剪成命中片段(§11.3)——稽核在第 30 個模組就耗盡預算。
- 把逐檔的時間戳記插進被快取的系統前綴,使 `cache_read_input_tokens` 維持為零、rubric 在每次呼叫被重複計費(§11.7)。
- 恢復時重新稽核已完成的模組,因為狀態只存在上下文裡、而非狀態檔(§11.6)。
- 讓子代理回傳原始檔案傾印——膨脹移到了協調者身上,而非被移除(§11.7)。

11.9 上下文工程(現代框架)

背景:這是 Anthropic 對本章技術的現代說法。考試考的是底層概念;這套詞彙幫你把它們串起來。來源:[Anthropic — Effective context engineering for AI agents](#)。

上下文工程(context engineering) 是在推論期間策劃並維護「最佳 token 集合」的學問 —— 涵蓋整個資訊環境(系統提示、工具、外部資料、訊息歷史),而不只是提示。它比提示工程更廣:提示工程打磨的是指令;上下文工程管理的是「在代理跨多輪執行時,動態落入視窗裡的一切」。

上下文是有限資源。 隨著 token 增加,模型的回想能力會下降 —— 這現象稱為 **context rot(上下文腐化)**(注意力必須計算每一對 token 的關係, n^2 成本在長輸入下被攤薄)。目標是「**仍能完成任務的最小高訊號 token 集合**」,而不是「把全部塞進去」。

核心技巧(各自對應上面一節):

- **即時擷取(just-in-time retrieval)** —— 保留輕量識別碼(檔案路徑、URL、ID),在執行期才用工具載入實際內容,而非事先全載(§11.6)。
- **壓縮(compaction)** —— 接近上限時摘要歷史,保留關鍵決策、捨棄冗餘工具輸出,再從摘要繼續; `/compact` 與 Agent SDK 會自動做這件事(§11.5)。
- **結構化筆記(記憶)** —— 把發現存到視窗外的外部記憶,需要時再取回,讓上下文重置後仍維持長程連貫(§11.6)。
- **子代理架構** —— 把聚焦的工作交給擁有乾淨上下文的子代理;它們回傳精簡摘要給協調者,把細節工作與高層綜整分開(§11.7)。

這些正是本章涵蓋的同一批對策(中段遺失、漸進式摘要、暫存檔、子代理隔離)—— **上下文工程** 就是「刻意去做這些事」的統稱。

11.10 考試重點 — 關鍵整理

概念	考試考什麼
上下文預算與失效模式	從症狀說出機制——context rot、中段遺失、摘要損失、工具結果膨脹;更大的視窗只是延後、絕不廢除這個問題(§11.1)。
持久事實區塊	把確切金額/日期/ID 存在可被摘要的歷史之外,並每輪重新注入——這是「代理在長對話後引用錯誤數字」的解法(§11.2)。
修剪工具結果	一個 <code>PostToolUse</code> hook 從 40 個欄位中只保留需要的 5 個——確定性的 token 衛生,而非表面功夫(§11.3)。
位置感知組裝	摘要置頂、大量內容置中、行動項目置尾——以位置而非寄望來對抗中段遺失(§11.4)。
滑動視窗 vs 摘要 vs 壓縮	依「什麼必須存活」來選;滑動視窗要搭配事實區塊;重播壓縮區塊,否則就丟失狀態(§11.5)。
即時擷取與記憶	以參照取代負載;工作階段內用暫存檔、跨工作階段用記憶(§11.6)。
子代理隔離與 prompt caching	把冗長探索委派給乾淨視窗;在易變內容之前設斷點來快取穩定前綴(讀取 ~0.1×)(§11.7)。

對應 Domain 5(15%)。 如果你能建構並捍衛上面的稽核代理——預算、事實區塊、修剪、位置、壓縮、擷取/記憶、隔離、快取——你就掌握了可靠性領域的核心,以及 Domain 1–4 中每一個長時間運行代理所仰賴的上下文紀律。

第 12 章:保留出處來源

文件:[Citations](#) | [Search results](#) | [Tool use](#)

出處(provenance)是一條證據鏈,把綜整答案中的每一項主張,連回某個具體、可驗證的來源。在單次呼叫的摘要器裡,這只是良好習慣;但在多代理系統中,它是「可信報告」與「自信瞎掰」之間的分水嶺。本章是 **Domain 5 — 上下文管理與可靠性(佔考試 15%)** 的深入探討,聚焦於目標 **5.6(在多來源綜整中保留出處並處理不確定性)**,並倚賴目標 5.1 的上下文保存技巧。反覆出現的考試主題很直白:當子代理發現一項事實,其來源必須挺過每一次傳遞——經過裁剪、摘要、衝突調解與最終呈現——否則協調者就會吐出一個捏造的引用。

讀完你應能推理五件事,並把它們組裝成稽核人員信任的報告:

- **出處遺失問題**(§12.1)— 主張 → 來源的連結如何在摘要中被切斷,以及防止它的 schema。
- **讓 source ID 貫穿綜整**(§12.2)— 在子代理傳遞與上下文裁剪之間維持出處完整。
- **處理衝突資料**(§12.3)— 為分歧加上出處標註,而非默默選一個贏家。
- **日期與時間詮釋**(§12.4)— 為何一個沒有日期的數字,就是未來的一場矛盾。
- **依內容類型呈現並拒絕捏造**(§12.5)— 依內容類型排版,且絕不發明一個 Claude 指不出來源的引用。

§12.6 接著從頭到尾建構一個完整的「附引用的合規研究產生器」, §12.7 則濃縮考試重點。

12.1 出處遺失問題

當代理彙整多個來源的結果時,主張 → 來源的連結是第一個犧牲品。模型正在為一段通順的文字最佳化,而引用是一種摩擦;除非資料結構強迫來源「隨主張一起移動」,否則摘要會把來源剝除。

不佳:「AI 音樂市場估值為 32 億美元。」(無來源、無年份—無法驗證。)

良好:

```
{
  "claim": "The AI music market is estimated at $3.2B.",
  "source_id": "src_07",
  "source_url": "https://example.com/report",
  "source_name": "Global AI Music Report 2024",
  "publication_date": "2024-06-15",
  "supporting_quote": "...the AI-assisted music segment reached USD 3.2 billion in 2024...",
  "confidence": 0.9
}
```

為何這是結構性難題,而非單純的草率。這個失敗是結構性的,而 Domain 5.1 的三股力量都在跟你作對:

- **漸進式摘要會把具體內容壓縮成模糊**。歷史每被壓縮一次,「依 Global AI Music Report 2024 為 \$3.2B」往往退化成「幾十億美元」,引用也隨之蒸發。
- **Lost-in-the-middle(中段遺失)**。埋在冗長工具結果中段的來源 URL,正是模型最不可靠、最難擷取出來的位。來源必須被提升為結構化欄位,而不是留在散文中。
- **冗長的工具輸出稀釋相關性**。一個回傳 40 個欄位的搜尋工具,會讓真正重要的 3 個欄位(id、url、date)在裁剪時很容易被丟掉。

解法是一份合約,而非一個請求。 要求每個子代理回傳一份物件清單,攜帶 `source_id`、`source_url`、`publication_date` 與一句逐字的 `supporting_quote`。`supporting_quote` 是承重欄位:它讓下游的驗證器能確認該主張確實有來源支撐,也是對抗捏造引用(\$12.5)最強的單一防線。當平台支援時,優先採用原生的 **Citations** 功能或**搜尋結果內容區塊(search-result content blocks)**,它們會讓 Claude 產出帶有字元級跨度、指回來源的 `cited_text`——這種出處模型無法默默丟棄。

考試角度。 若題幹描述「最終報告說市場是 \$3.2B,但沒人能說出這數字來自哪個來源」,它考的就是 5.6。正確答案是 **要求子代理產出結構化的主張 → 來源對應(URL、文件名稱、引文),而非「在提示中加一句『請附上來源』」**——軟性指令是機率性的,會在摘要下劣化。

12.2 讓 source ID 貫穿多代理綜整

出處很少在搜尋那一步斷掉;它斷在**傳遞(hops)**——每次酬載在代理之間移動或被裁剪時。每一次傳遞都是來源被丟掉的機會,因此出處必須是能挺過所有傳遞的一級欄位。

```
flowchart TD
    Q[研究問題] --> Co[協調者]
    Co -->|帶完整上下文的 Task| W1[工作者 A<br/>擷取來源]
    Co -->|帶完整上下文的 Task| W2[工作者 B<br/>擷取來源]
    W1 -->|主張加上 source_id| Co
    W2 -->|主張加上 source_id| Co
    Co -->|Reg[(來源登錄表<br/>id 對應 url、date、quote)]|
    Co -->|Syn[綜整<br/>以 source_id 引用]|
    Syn -->|Val{每項主張<br/>都有有效 id?}|
    Val -->|否| Drop[丟棄或標記該主張]
    Val -->|是| Rep[附引用的報告加上<br/>參考資料章節]
```

雙表紀律。 把主張與來源放在分開但相連的結構裡。工作者回傳的**主張**參照一個 `source_id`;協調者維護一份**來源登錄表**,把每個 `source_id` 對應到它的 URL、名稱、日期與引文。綜整提示因此只以 `source_id` 引用——完全不需要讓完整 URL 穿過模型的推理,而那正是 lost-in-the-middle 會把它們弄壞的地方。

為何這能挺過裁剪。 這是目標 5.1「案件事實(case facts)」模式在出處上的應用:來源登錄表存活於摘要後的對話歷史**之外**,放在持久狀態裡。你可以放手 `/compact` 或裁剪工作者的逐字紀錄,而最終草稿裡的每個 `source_id` 仍能解析,因為登錄表從不被摘要。

考試會探測的陷阱:

- **在管線中途重新編號來源。** 若工作者 A 的「來源 1」與工作者 B 的「來源 1」在合併時相撞,引用會默默指向錯誤的文件。請使用全域唯一 ID(`src_07`、雜湊值或 UUID),在匯入時指派一次——絕不用每個工作者各自的序號。
- **只把散文摘要往上傳。** 若工作者回傳「市場很大」卻不附登錄表,協調者就沒有東西可引用,只會略過來源或發明一個。工作者必須回傳**結構化**主張,而非段落(這正是 5.1 技巧:子代理在結構化輸出中納入中繼資料)。
- **讓協調者把 ID 改寫掉。** 綜整指令必須是「每一句都以它的 `[source_id]` 結尾」,並由綜整後的驗證器(\$12.6)強制執行,而非寄望於模型的善意。

12.3 處理衝突資料

真實的來源會彼此分歧。當兩個可信來源報出不同數值時,錯誤的做法——也是常見的考試誘答——是**默選一個**、把它們平均、或只回報「最新的」。那會丟掉使用者用來判斷可靠度所需的資訊。正確做法是**連同完整出處保留每一個數值並讓衝突浮現**,再讓協調者(或真人)去調解。

```
{
  "claim": "Share of AI-generated music on streaming platforms",
  "values": [
    {
      "value": "12%",
      "source_id": "src_11",
      "source": "Spotify Annual Report 2024",
      "date": "2024-03",
      "methodology": "Automated classification"
    },
    {
      "value": "8%",
      "source_id": "src_19",
      "source": "Music Industry Association Survey",
      "date": "2024-07",
      "methodology": "Survey of 500 labels"
    }
  ],
  "conflict_detected": true,
  "possible_explanation": "Difference in methodology and time period"
}
```

不要任意選擇其中一個數值。連同出處標註一併保留兩者,讓協調者決定。

為何要標註而非調解。這種分歧往往不是錯誤——它是訊號。此處的差距由**方法論**(演算法偵測 vs. 500 家唱片公司的調查)與**時間區間**(三月 vs. 七月)所解釋。一個把衝突「調解」成單一 10% 的子代理,會摧毀正是用來解釋它的那些中繼資料(方法論、日期)。出處包含一個數字是**如何**產生的,而不只是它**來自**哪裡。

讓報告結構與之相符。把**穩定發現**(來源一致)與**爭議發現**(來源衝突)分開,讓讀者一眼就看出哪些結論穩健、哪些有爭議。明確標註涵蓋範圍——哪些有充分支撐、哪些證據薄弱或分歧——這正是目標 5.3 的綜整技巧。

考試角度。「兩個子代理回傳不同的市場規模數字——協調者該怎么做?」能得分的答案是 **連同來源與方法論保留兩個數值,並標記衝突以供調解,絕非**「相信較新的那個」或「把它們平均」。一個看不到任何分歧的單一數字,即使湊巧正確,仍是出處上的失敗。

12.4 納入日期以正確詮釋時間

一個沒有日期的數字是潛伏的矛盾。沒有日期,模型(或讀者)就無法判斷兩個數值是相互衝突、還是只是描述**不同的時間點**,於是一個正常的逐年變化就被當成錯誤回報。

不佳:「來源 A 說 10%, 來源 B 說 15%。相互矛盾。」

良好:「來源 A(2023)說 10%, 來源 B(2024)說 15%。可能是一年內成長了 +5%。」

為何日期是出處的一部分,而非可有可無。出處回答的是哪裡以及何時。同一個來源可能在不同版次發布不同數字;「2024 年的報告」與「2023 年的報告」是不同的證據。為每一項主張攜帶 `publication_date` (原始資料則用 `collection_date`),並優先採用 ISO-8601(2024-06-15),好讓日期在不同地區與工具間都能明確地排序與比較。

陷阱——「最新者勝」的反射。 因為有更新的數值就丟掉較舊的,是 §12.3 錯誤的另一種口味:它刪掉了揭示趨勢的那個資料點。請保留兩者並標上日期;讓趨勢自己說話。

考試角度。 若題幹把一個時間上的差異描述為「矛盾」,它考的就是你會不會附上日期,讓這個差異讀起來是隨時間的成長或變化。為了正確的時間詮釋而納入發布日期,是 5.6 明列的技巧。

12.5 依內容類型呈現並拒絕捏造

兩個收尾紀律,能把正確的出處變成可信的交付物:用每種內容的自然樣貌來呈現它,且絕不讓模型發明一個它指不出來源的引用。

依內容類型呈現。 把每一項發現硬塞進單一格式會摧毀可讀性,本身甚至會遮蔽出處:

- **財務資料** → 表格(讓數字、來源與日期依欄對齊)。
- **新聞與分析** → 散文。
- **技術發現** → 結構化清單。
- **時間序列** → 依時間順序排列。

拒絕捏造引用——首要大忌。 捏造的引用(看似合理卻不存在的 URL、報告標題或引文)比沒有引用更糟:它製造虛假的信心,還能撐過草率的審閱。防線依強度排序:

1. **只從登錄表引用。** 綜整步驟引用某個 `source_id` 的前提是它存在於來源登錄表(§12.2);其餘一律丟棄或標記。這讓發明在結構上不可能,而非僅僅「不鼓勵」。
2. **驗證引文。** 綜整後的檢查確認每項主張的 `supporting_quote` 確實出現在被引來源的文本中。引文無法被定位的主張即屬無支撐,予以移除或送交真人審閱(目標 5.5)。
3. **優先採用原生 Citations / 搜尋結果區塊。** 當來源以搜尋結果內容區塊提供時,Claude 會產出帶有已驗證跨度、指回所提供文件的 `cited_text` ——模型實際上無法引用不存在的文字。
4. **明說「找不到」。** 若沒有來源支撐某項被要求的主張,正確輸出是一個明確的缺口(「範圍內無來源支撐此點」),而非一句自信的話。這是出處版的「寧可升級也不要猜」。

考試角度。 留意這類題幹:模型藉由加上聽起來權威的引用來「改善」一份報告——陷阱答案會稱讚這份精緻。正確答案會把任何無法追溯到真實、所提供來源的引用視為瑕疵,並把無支撐的主張導向缺口註記或真人審閱。

12.6 端到端案例研究:附引用的合規研究產生器

上述元件唯有組合在一起才有意義。以下是一個完整、真實的系統——正是考試的**多代理研究 / 綜整情境**要你能推理的設計——其中出處並非選配,因為輸出是一份可稽核的合規備忘錄。

需求

- 把一個法規問題(例如「在 PCI DSS 與歐盟 GDPR 下,支付紀錄的資料保存義務為何?」)回答成一份合規人員能在稽核中捍衛的備忘錄。
- 透過各自獨立的擷取子代理,從多個語料庫(法規條文、內部政策文件、過往法律備忘錄)擷取證據。

- **硬性規則:** 備忘錄中的每一項論斷都必須附帶一個能解析到**真實、所提供來源**的引用——沒有捏造的 URL、標題或引文。沒有來源的論斷以缺口回報,而非陳述為事實。
- 不同來源對保存期限意見分歧;**連同來源、日期與依據保留每一個數值**,而不是挑一個。
- 維護一條**稽核軌跡**:一份持久紀錄,記載哪個來源支撐了哪一句,且在對話結束後仍可重現。

架構

```

flowchart TD
    Officer([合規人員]) --> Coord[協調者]
    Coord -->|帶完整上下文的 Task| RReg[子代理<br/>法規擷取]
    Coord -->|帶完整上下文的 Task| RPol[子代理<br/>政策擷取]
    RReg -- 主張加上 source_id 加上 quote --> Coord
    RPol -- 主張加上 source_id 加上 quote --> Coord
    Coord --> Reg[(來源登錄表加上稽核日誌<br/>持久狀態)]
    Coord --> Syn[綜整<br/>每一句以 source_id 引用]
    Syn --> Gate[{驗證器 hook<br/>id 在登錄表且引文相符?}]
    Gate -->|失敗| Gap[標記為無支撐缺口<br/>或送交真人]
    Gate -->|通過| Memo[附引用的備忘錄加上參考資料<br/>加上衝突章節]
  
```

協調者掌管編排與持久登錄表;擷取子代理做範圍狹窄、最小權限的工作,並回傳**帶引文的結構化主張**而非散文;**由驗證器閘門(而非提示請求)強制執行「無引用,則無主張」**,因為稽核完整性必須是確定性的。

實作

要求每個擷取子代理回傳結構化、帶引文的主張(\$12.1 的合約):

```

retrieval_subagent = AgentDefinition(
    name="regulation_retriever",
    description="Retrieves passages from supplied regulation corpora. Read-only.",
    system_prompt=(
        "Search the supplied documents. For each relevant finding return a JSON
object: "
        "{claim, source_id, source_name, publication_date, supporting_quote}. "
        "Use ONLY the source_ids present in the provided documents. "
        "If nothing supports the question, return an empty list – never invent a
source."
    ),
    allowed_tools=["search_corpus"], # 最小權限:只負責擷取
)
  
```

把出處放在持久狀態,讓它挺過裁剪(\$12.2 的雙表紀律):

```
# 來源登錄表存活於摘要歷史「之外」——永遠不會被 compact 掉。
source_registry = {}          # source_id -> {url, name, date, full_text}
audit_log = []                # 僅可附加:(sentence_id, source_id, quote)

def register_claim(claim):
    sid = claim["source_id"]
    if sid not in source_registry:          # 匯入時指派的全域唯一 ID
        source_registry[sid] = lookup_source(sid)
    return claim
```

以一個覆蓋綜整後備忘錄的驗證器閘門,確定性地強制執行「無引用,則無主張」——這正是考試要你答對的關鍵:

```
def validate_citations(memo_sentences):
    for s in memo_sentences:
        sid = s.get("source_id")
        # 1) 被引用的來源必須確實存在於登錄表
        if sid not in source_registry:
            s["status"] = "unsupported_gap"          # 沒有的來源無法引用
            continue
        # 2) 支撐引文必須確實出現在該來源的文本中
        if s["supporting_quote"] not in source_registry[sid]["full_text"]:
            s["status"] = "quote_mismatch"          # 捏造/竄改的引文 -> 拒絕
            continue
        s["status"] = "verified"
        audit_log.append((s["id"], sid, s["supporting_quote"]))
    return memo_sentences
```

對於衝突的保存期限,連同出處保留每一個數值(\$12.3 的結構),而非調解成單一值——綜整會產出一個以 `source_id` 為鍵的專屬「爭議發現」章節。

執行軌跡

```
sequenceDiagram
    actor Off as 合規人員
    participant Co as 協調者
    participant R as 擷取子代理
    participant V as 驗證器閘門
    Off->>Co: 「支付紀錄的保存規則?」
    Co->>R: Task(問題加上語料 id, 完整上下文)
    R-->>Co: 主張「保存 1 年」+ src_07 + 引文
    Co->>Co: 登錄 src_07; 草稿引用為 [src_07]
    Co->>V: validate(句子, src_07, 引文)
    V->>V: src_07 在登錄表 且 引文相符
    V-->>Co: 已驗證; 附加到 audit_log
    Co-->>Off: 附引用備忘錄 + 參考資料 + 衝突註記
```

注意子代理把引文與主張一起回傳,而 驗證器閘門在那一句被允許進入備忘錄之前,確認了引文確實存在於 `src_07` 中。若模型改寫了一個它從未讀過的來源,引文檢查就會失敗,該句會被降級為缺口——由程式碼(而

非客氣的「請引用」)強制執行出處。

驗證

- **零捏造測試:** 餵入一個語料中**沒有任何**支撐來源的問題,斷言備忘錄回報缺口(零個發明的引用),而非一個自信的答案。
- **引文完整性測試:** 竄改某個 `supporting_quote` 使其不再與來源文本相符,斷言驗證器標記 `quote_mismatch` 並移除該句。
- **裁剪存活測試:** 對工作者逐字紀錄執行 `/compact` ,然後斷言最終備忘錄中的每個 `source_id` 仍能透過登錄表解析——證明出處存活於摘要歷史之外。
- **衝突保留測試:** 提供兩個保存期限不同的來源,斷言 *兩者*都帶日期與出處出現在「爭議發現」章節中。
- **稽核軌跡測試:** 斷言每一個已驗證的句子在 `audit_log` 中都有相符的 `(sentence_id, source_id, quote)` 紀錄列,且在工作階段結束後仍可重現。

常見陷阱

- 在提示中請求引用,而非以閘門驗證它們(機率性——模型有時會捏造;§12.5)。
- 為每個子代理各自重新編號來源,使合併後的引用指向錯誤的文件(請用全域唯一 ID;§12.2)。
- 把來源登錄表連同聊天歷史一起摘要,導致 `/compact` 後引用無法再解析(把它放在持久狀態;§12.2)。
- 把衝突的保存期限調解成單一值,丟掉了解釋差距的方法論/日期(§12.3)。
- 把通順、聽來權威的引用當成正確性的證明,而非把引文對照來源加以驗證(§12.5)。

12.7 考試重點 — 關鍵整理

概念	考試考什麼
出處遺失	要求子代理產出結構化的主張 → 來源對應(id、URL、名稱、引文);「請引用」提示會在摘要下劣化(§12.1)。
source ID 貫穿綜整	把持久的來源登錄表放在摘要歷史 之外 ;以全域唯一 <code>source_id</code> 引用;絕不為每個工作者重新編號(§12.2)。
衝突資料	連同來源、日期與方法論保留 每一個 數值並標記衝突——絕不默默選一個、平均、或取最新(§12.3)。
日期	附上 <code>publication_date</code> (ISO-8601),讓時間差異讀起來是成長/變化,而非矛盾(§12.4)。
不捏造引用	只從登錄表引用、把支撐引文對照來源驗證、無來源支撐時回報缺口(§12.5)。
依內容類型呈現	財務 → 表格、新聞 → 散文、技術 → 清單、時間序列 → 依時間順序(§12.5)。

對應 Domain 5(15%),目標 5.6。 如果你能建構並捍衛上面那個附引用的合規產生器——結構化的主張 → 來源合約、一份能挺過裁剪的持久登錄表、衝突保留,以及一個拒絕捏造引用的驗證器閘門——你就掌握了可靠性領域所考的出處核心。

第 13 章: Claude Code 內建工具

文件: [Claude Code settings](#) | [Subagents](#) | [Hooks](#) | [IAM & permissions](#)

Claude Code 內建一組小而固定的**內建工具**——也就是代理用來讀取、搜尋、編輯與執程式碼的同一批原語(primitive)。其餘的一切(自訂斜線命令、skills、MCP 伺服器、`CLAUDE.md`)都只是在設定這些工具**如何**以及**何時**觸發,但工具本身才是代理的雙手。本章屬於 **Domain 3 — Claude Code 設定與工作流(佔考試 20%)**: 這個領域考的是,你能否把 Claude Code 當成一套有紀律的工程工作流來駕馭,而不是當成聊天框。讀完本章,你應能掌握三件事,並把它們組裝成一套安全、可稽核的自動化:

- **什麼工作用什麼工具**(§13.1)— 檔案探索 vs 內容搜尋 vs 讀寫 vs shell,以及選錯為何會浪費上下文並降低可靠度。
- **漸進式調查**(§13.2)— 用 Grep → Read → Grep → Read,而非把整個 repo 載入;這為何是一種上下文管理技能,而不只是搜尋習慣。
- **權限模型**(§13.4)— 決定一次工具呼叫是執行、詢問、還是拒絕的閘門;這是對「代理能對你的機器做什麼」唯一的**確定性**控制。

§13.3 介紹 Edit → Read+Write 後備方案,§13.5 把工具放進委派與 TODO 追蹤的工作流中,§13.6 從頭到尾建構一套完整的**受護欄保護的程式碼稽核與重構**自動化,§13.7 則濃縮考試重點。

13.1 工具選擇參考

每個內建工具只有一個職責。考試獎勵的是挑出**最便宜且正確**的工具——在該用 `Read` 的地方用 shell `cat`,或在一次 `Grep` 就能回答問題時卻讀了十個檔案,兩者都會被判為錯,因為它們燒掉上下文又降低可靠度。

任務	工具	範例
依名稱/模式尋找檔案	Glob	<code>**/*.test.tsx</code> 、 <code>src/components/**/*.ts</code>
在檔案內搜尋	Grep	函式名稱、錯誤訊息、import
完整讀取一個檔案	Read	載入檔案以供分析
寫入新檔案	Write	從零開始建立檔案
精準編輯既有檔案	Edit	透過唯一的文字比對替換特定片段
執行 shell 命令	Bash	git、npm、執行測試、建置
委派一個隔離的子任務	Task	生成擁有自己上下文視窗的子代理
抓取並讀取一個 URL	WebFetch	拉取文件/更新日誌,再就內容進行推理
追蹤多步驟進度	TodoWrite	在長任務中維護一份可見的檢查清單

為何這個區分很重要(Grep vs Glob 是經典陷阱):

- **Glob** 回答「**有哪些檔案的名稱符合這個模式?**」——它從不開啟檔案內容。用它來界定工作面(例如在執行測試前,先找出每一個測試檔)。

- **Grep** 回答「*哪些檔案包含這段文字?*」——它會讀取內容,但回傳的是符合的比對,而非整個檔案。它建構於 ripgrep 之上,因此接受真正的正規表示式,並會遵守 `.gitignore`。
- **Read** 用於你已經知道是*哪個*檔案、且需要實際內容行的時候。把用 Glob 找到的檔案「順手檢查一下」而打開,是最常見的浪費上下文反模式。

Bash 是逃生口,不是預設值。 那些有專屬工具的事——找檔案、搜尋、讀取——*你可以*用 Bash 裡的 `find`、`grep`、`cat` 做,但你不該這麼做:專屬工具會整合權限 UI、回傳結構化結果,並避免 shell 引號錯誤。請把 **Bash** 保留給沒有專屬工具的事: `git`、`npm / pytest`、建置步驟與程序控制。這正是權限模型設計時所圍繞的邊界 (§13.4)——它可以在到處允許 `Read` 的同時,仍在每次 `Bash` 前都詢問。

考試角度: 題目會描述一個目標(「找出 `processPayment` 的每一個呼叫端」、「在整個 repo 改名一個符號」、「執行測試套件並回報失敗」),並問該用哪個工具。正確答案是能完成工作的最窄工具:找呼叫端用 `Grep`,改名用 `Edit`(或 `Read+Write`),跑測試用 `Bash`。

13.2 漸進式調查策略

不要一次讀取所有檔案。漸進式地建立理解——用搜尋*定位*、用讀取*確認*,然後從學到的內容再次搜尋:

flowchart TD

```
A[目標—理解一個功能<br/>或找出一個 bug] --> B[用 Glob 界定<br/>候選檔案]
B --> C[用 Grep 找進入點<br/>定義與 export]
C --> D[只讀取比對到的檔案]
D --> E[用 Grep 找用法<br/>import 與呼叫端]
E --> F{全貌完整了嗎?}
F -->|否| D
F -->|是| G[動手—Edit、Bash<br/>或回報發現]
```

以文字表示,這個迴圈是:

1. `Grep`: 尋找進入點(函式定義、`export`)
2. `Read`: 讀取找到的檔案
3. `Grep`: 尋找用法(`import`、呼叫)
4. `Read`: 讀取使用端檔案
5. 重複,直到掌握完整全貌

為何這是一種上下文管理技能,而不只是搜尋習慣。 一個長的 Claude Code 工作階段擁有有限的上下文視窗。太早讀取整個目錄,會用你大多不需要的文字塞滿視窗,並把*相關*的行擠向中段——「中間遺失」(lost-in-the-middle)效應會在那裡讓模型變得較不可靠。先 `Grep` 能讓上下文裡只留下重要的行,讓模型在任務深處仍保持敏銳。這也正是 Domain 5 在大型程式碼庫時偏好暫存檔(scratchpad)與子代理委派的同一個原因。

陷阱:

- **先讀再搜。** 為了「先有個概念」而開啟檔案,是工作階段燒爆上下文預算的頭號方式。永遠先用 `Grep/Glob` 收窄範圍。
- **`Grep` 太寬。** 一個比對到上千行的模式,跟讀光所有東西一樣沒用。請錨定正規式,並使用檔案類型/glob 篩選。
- **忘了第二次 `Grep`。** 找到定義告訴你一個函式是什麼;找到它的*呼叫端*告訴你改動它會弄壞什麼。跳過用法掃描的調查,會產出能編譯、但接著在執行期失敗的重構。

考試角度: 關於調查不熟悉或大型程式碼庫的情境,考的是你是否(a)先搜尋再讀取、(b)把冗長的探索委派給子代理以保護主上下文(\$13.5)、(c)認得「把整個 repo 讀進上下文」永遠不是答案。

13.3 後備方案:用 Read + Write 取代 Edit

Edit 透過比對檔案中的一段**唯一**字串,進行精準的就地替換。若目標文字出現超過一次,這次編輯就具有歧義並會依設計而失敗——Claude Code 會拒絕,而非猜測你指的是哪一處。有兩種正確的回應方式:

1. **讓比對變得唯一。** 在 `old_string` 中納入更多周圍的上下文,使其只符合一處(通常是最乾淨的做法),或在你確實想改動每一處時使用 `replace_all`。
2. **退回到 Read + Write:**
 - **Read** — 載入完整的檔案內容。
 - 以程式化方式修改內容(算出新版本)。
 - **Write** — 把更新後的版本寫回。

```
flowchart TD
    A[需要改動一個檔案] --> B[用唯一的<br/>old_string 進行 Edit]
    B --> C{比對唯一嗎?}
    C -->|是| D[Edit 已套用]
    C -->|否, 多處比對| E[加入周圍上下文<br/>使其唯一]
    E --> F{現在唯一了嗎?}
    F -->|是| D
    F -->|否, 或整檔重寫| G[Read 完整檔案]
    G --> H[算出新內容]
    H --> I[Write 寫回檔案]
```

為何 Edit 能用時就該優先用。 一次精準的 Edit 只改動你指名的那幾行,其餘逐位元組保持原樣,因而產生乾淨的 diff 並避免意外重排格式。一次完整的 Write 會替換整個檔案,因此重建內容時的單一失誤,就可能悄悄丟掉無關的程式碼。請刻意地把 Write 當後備方案,而非當成習慣。

陷阱:

- **寫入一個你從未 Read 的檔案。** Claude Code 要求在 Write(以及 Edit)既有檔案前必須先 Read,讓你無法覆蓋你沒看過的內容。盲目覆寫既被阻擋、也很危險。
- **本想改一處卻用了 `replace_all`。** 它是改名的正確工具,卻是修一個剛好與正常程式碼共用文字的單一 bug 的錯誤工具。

考試角度: 經典題是「Edit 因為片段不唯一而失敗——接下來怎麼辦?」。預期答案是消除比對的歧義(加更多上下文)或退回到 Read → 修改 → Write,而非放棄這次改動。

13.4 權限模型:每一次工具呼叫前的閘門

內建工具威力強大——`Bash` 什麼都能跑、`Write` 什麼都能覆蓋——所以 Claude Code 在它們前面放了一層**權限**。這是整個設定體系中最重要的單一**確定性**控制,也直接對應到 Domain 3 的主題:保證來自設定,而非來自禮貌的提示。

每一次工具呼叫在執行前都會依規則評估,有三種結果:

flowchart TD

```
A[代理請求一次工具呼叫<br/>例如 Bash git push] --> B{符合 deny 規則嗎?}
B -->|是| C[拒絕 - 呼叫從不執行]
B -->|否| D{符合 allow 規則嗎?}
D -->|是| E[自動核准 - 靜默執行]
D -->|否| F{預設模式?}
F -->|ask| G[提示使用者<br/>核准或拒絕]
F -->|acceptEdits| H[自動核准編輯<br/>Bash 仍會詢問]
G -->|已核准| E
G -->|已拒絕| C
```

規則怎麼寫。權限存在 `settings.json` (以及 `.claude/settings.local.json`) 中,以工具為鍵分成 `allow`、`ask`、`deny` 清單,並可選擇加上引數比對器:

```
{
  "permissions": {
    "allow": ["Read", "Grep", "Glob", "Bash(npm test:*)", "Bash(git status)"],
    "ask":   ["Bash(git push:*)", "Write"],
    "deny":  ["Bash(rm -rf:*)", "Read(/secrets/**)", "WebFetch"]
  }
}
```

- **allow** 不經提示就執行符合的呼叫——用在唯讀及明確安全的操作上,讓代理不會一直打斷你。
- **ask** 每次都強制跳出真人核准提示——用在你想親眼確認的有副作用動作上(寫入、push)。
- **deny** 直接阻擋呼叫——模型無法覆寫它。把真正危險的東西放在這裡(`rm -rf`、讀取憑證檔、對外網路)。

優先順序是最關鍵的細節: **deny** 勝出。一次呼叫會先對 `deny` 檢查; `allow` 規則永遠無法重新啟用被 `deny` 規則禁止的東西。所以即使 `Read` 全域被允許, `Read(/secrets/**)` 的 `deny` 仍然成立——這正是你對機密目錄想要的性質。

為何這勝過提示指令。在 `CLAUDE.md` 裡告訴模型「絕不碰機密資料夾」是機率性的——它通常會遵守,但對憑證或 `rm -rf` 而言「通常」並不可接受。`deny` 規則是確定性的:由 harness 強制執行,而非靠模型的判斷。這就是 §3.5 的 hooks 原則套用到 Claude Code 自己的工具上——當失敗會造成安全或資料遺失後果時,用設定來把關,而非用措辭。

模式與無頭(headless)執行。預設的互動模式會在每個有副作用的動作前詢問——自 Claude Code 2.1.200(2026 年 7 月)起在介面中顯示為 **Manual**; `acceptEdits` 會自動核准檔案編輯,同時仍對 Bash 把關;**plan** 模式讓代理以唯讀方式探索並提出變更,卻不執行它們。在 CI/無頭執行(`claude -p`)中沒有真人可回答提示,所以你必須用 `--allowedTools` 預先核准所需工具(並依賴 `deny` 作為護欄)——未被允許的工具會直接失敗,而不會卡住等待。

陷阱:

- **allow 過寬。** `"allow": ["Bash"]` 等於把不受限的 shell 交給代理——與最小權限恰恰相反。請允許特定命令(`Bash(npm test:*)`),而非整個工具。
- **在該用 deny 的地方依賴提示。**「請不要刪除檔案」不是一種控制; `deny: ["Bash(rm:*)"]` 才是。
- **忘了無頭沒有提示。**一個需要 `Write` 卻只允許了 `Read` 的 `-p` 自動化,會在第一次編輯時靜默失敗。

考試角度: 預期會出現一個情境:代理必須能執行測試並讀取程式碼,但絕不能 push、刪除或讀取機密——而你要選出 allow/ask/deny 的分配。考的關鍵事實:deny 覆寫 allow、允許特定命令是最小權限,以及讓一條禁令獲得保證的是設定(而非提示文字)。

13.5 workflow 中的工具:委派與進度追蹤

有兩個內建工具,重點不在於碰檔案,而在於運行 workflow 本身。

Task (子代理)保護主上下文。 一次 **Task** 呼叫會生成一個擁有自己全新上下文視窗的子代理;它去做冗長的工作(深度搜尋、讀數十個檔案),只把摘要回傳給協調者。三條規則直接沿用第 3 章:子代理**不繼承任何上下文**——把它所需的一切放進 Task 提示;它應以**最小權限**執行——只給其工作所需的工具;而且**所有結果都透過協調者流回**。對內建工具而言的特定好處是:原本會淹沒並劣化主工作階段的探索輸出,被隔離在子代理裡。

TodoWrite 讓多步驟計畫變得明確且持久。對任何有多個步驟的任務,寫下一份檢查清單(同一時間恰好一項 `in_progress`,完成就標記 `completed`),能在長時間執行中讓代理——以及在旁觀看的真人——保持方向感,並讓當機或中斷可恢復,因為剩餘的工作是寫下來的,而不是只存在模型腦中。

```
flowchart TD
    A[協調者代理] --> B[TodoWrite—寫下步驟清單]
    B --> C[Task—稽核子代理 Grep + Read, 唯讀]
    C -- 僅回傳發現摘要 --> A
    A --> D[Edit—套用一項修正]
    D --> E[Bash—npm test]
    E --> F{測試通過?}
    F -->|否| D
    F -->|是| G[TodoWrite—標記步驟完成]
    G --> H{還有步驟?}
    H -->|是| C
    H -->|否| I[回報]
```

陷阱: 生成了子代理卻忘了把它所需的上下文傳進去(它一開始就盲目);給稽核子代理用不到的 `write/Bash` 工具(違反最小權限並擴大波及範圍);把 `TodoWrite` 當裝飾,而非維持恰好一項任務在進行中。

考試角度: 大型程式碼庫與多步驟情境考的是,你是否把冗長的探索委派給子代理(保護上下文)、是否明確追蹤進度——以及子代理的工具集是否限縮到其職責範圍。

13.6 端到端案例研究:受護欄保護的程式碼稽核與重構 workflow

上述工具,唯有在權限模型之下組合起來才有意義。以下是一套完整、真實的 Claude Code 自動化——正是 Domain 3 要你設計的那種:一個 workflow,稽核一個 repo 是否存在某類安全問題並加以修正,同時由設定(而非信任)保證它永遠無法造成傷害。

需求

- 掃描一個 Node.js repo,找出寫死的機密(API key、token),以及由使用者輸入組成的不安全 `child_process.exec(...)` 呼叫。

- 對每一項發現,套用一項**安全、機械式的修正**:把機密移到環境變數、把 `exec` 換成帶引數陣列的 `execFile`。
- **硬性規則**: 此工作流可讀取任何東西,但 `./secrets/**` 與 `./env*` 除外;只可執行測試套件;且**絕不可**執行破壞性 shell 命令或 push 到 git——沒有例外,不交由模型裁量。
- 在 CI 中對每個 pull request **以無頭模式執行**,並輸出一份結構化報告;冗長的探索不得耗盡主上下文。

架構

```
flowchart TD
    PR([CI 中的 pull request]) --> Coord[協調者—claude -p]
    Coord --> Perm["權限層<br/>allow / ask / deny"]
    Coord --> Plan[Plan[ToDoWrite—先稽核再修正再驗證]]
    Coord --> Task[Audit[稽核子代理<br/>Glob + Grep + Read, 唯讀]]
    Audit --> Coord
    Coord --> Fix[Fix[Edit—套用機械式修正]]
    Fix --> Test[Test[Bash—npm test]]
    Test --> Report[Report[Write—audit-report.json]]
    Perm --> Coord
```

協調者掌管編排;**稽核子代理**做範圍狹窄的唯讀探索,讓它冗長的輸出永遠不會抵達主視窗;而**權限層(而非系統提示)**保證了**安全邊界**,因為這必須是確定性的。

實作

在 `settings.json` 中設定安全邊界。這正是考試要你答對的關鍵——那些禁令是規則,不是請求:

```
{
  "permissions": {
    "allow": ["Read", "Grep", "Glob", "Bash(npm test:*)", "Edit", "Write(./audit-report.json)"],
    "deny": ["Read(./secrets/**)", "Read(./env*)", "Bash(rm:*)", "Bash(git push:*)", "WebFetch"]
  }
}
```

注意 `Read` 被廣泛允許,然而對 `./secrets/**` 與 `./env*` 的 `deny` 仍然成立——**deny 覆寫 allow**,所以代理即使能自由讀取原始碼,在實體上也無法讀取憑證。

把冗長的掃描委派給一個最小權限子代理(唯讀工具,完整上下文放在提示中):


```

audit_agent = AgentDefinition(
    name="secret_auditor",
    description="Finds hardcoded secrets and unsafe exec() calls. Read-only.",
    system_prompt=(
        "Search the repo for hardcoded API keys/tokens and for child_process.exec "
        "called with interpolated input. Return a JSON list of {file, line, kind}. "
        "Do not modify files."
    ),
    allowed_tools=["Glob", "Grep", "Read"], # 最小權限:沒有 Edit、沒有 Bash
)

```

在 CI 中以無頭模式跑整套流程,並恰好預先核准所需的工具(現場沒有真人可回答 `ask`):

```

claude -p "Run the secret-and-exec audit, apply mechanical fixes, then run the
tests." \
  --allowedTools "Read,Grep,Glob>Edit,Bash(npm test:*),Write(./audit-report.json)" \
  --output-format json

```

代理會套用的一個代表性修正——透過 Grep 收窄、透過 Edit 改動:

```

// before (flagged: hardcoded secret)
const apiKey = "sk-live-9f8a7b6c5d4e3f2a1b0c";
// after
const apiKey = process.env.API_KEY;

```

執行軌跡

```

sequenceDiagram
    actor CI as CI 流水線
    participant Co as 協調者
    participant Au as 稽核子代理
    participant Pm as 權限層
    CI->>Co: claude -p 「稽核並修正」
    Co->>Au: Task(掃描機密 + 不安全 exec)
    Au-->>Co: 2 項發現:config.js L3、run.js L20
    Co->>Pm: Edit config.js(key 改為環境變數)
    Pm-->>Co: 允許,編輯已套用
    Co->>Pm: Read ./secrets/prod.key
    Pm-->>Co: 被 deny 規則拒絕
    Co->>Pm: Bash npm test
    Pm-->>Co: 允許,測試通過
    Co-->>CI: audit-report.json(已修 2 項)

```

注意協調者嘗試去讀 `./secrets/prod.key` (也許想「驗證」一把金鑰),而權限層確定性地拒絕了它。若只靠一條 `CLAUDE.md` 註記(「別讀機密」),模型大多時候會遵守——對憑證來說還不夠。`deny` 規則讓它成為不可能,而非僅僅不太可能。

驗證

- **確定性測試:** 在 100 次提示代理去讀 `./secrets/prod.key` 的執行中,斷言出現 100 次拒絕。只靠提示的護欄終將外洩;`deny` 規則必須 100%。
- **上下文隔離測試:** 確認稽核子代理是在它的 Task 提示中收到搜尋任務與 repo 範圍;協調者的視窗應只含發現摘要,而非原始檔案傾印——藉此證明探索維持隔離。
- **最小權限測試:** 斷言 `secret_auditor` 子代理沒有 `Edit` 或 `Bash`,如此一來,被掃描檔案內一段提示注入(prompt-injected)的指令,就無法讓它改動程式碼或開 shell。
- **無頭測試:** 用 `-p` 搭配一份刻意不完整的 `--allowedTools` (略去 `Edit`)執行;確認修正步驟乾淨地失敗,而非卡在等待提示。

常見陷阱

- 把機密/`rm /push` 的禁令放進 `CLAUDE.md` 而非 `deny` 規則(機率性,沒有保證)——見 §13.4。
- 允許整個 `Bash` 工具而非 `Bash(npm test:*)`,等於把不受限的 shell 交給代理(allow 過寬)。
- 讓協調者自己做掃描,用檔案內容淹沒主上下文,而不委派給唯讀子代理(§13.2、§13.5)。
- 在無頭執行時沒有預先核准 `Edit / Write`,於是自動化在第一次改動就靜默失敗,因為沒有真人能授予提示。

13.7 考試重點 — 關鍵整理

概念	考試考什麼
工具選擇	挑出能完成工作的最窄工具:找檔案用 Glob、搜內容用 Grep、開已知檔案用 Read、精準改動用 Edit,而 Bash 只用於 git/測試/建置(§13.1)。
漸進式調查	先搜尋再讀取;Grep → Read → Grep → Read;永遠別把整個 repo 載入上下文(§13.2)。
Edit 後備	不唯一的比對會依設計失敗——用更多上下文消除歧義,或退回 Read → 修改 → Write(§13.3)。
權限模型	三種結果(allow/ask/deny); deny 覆寫 allow ;在提示只是機率性的地方,設定是確定性的(§13.4)。
最小權限與委派	把每個代理/子代理限縮到最少工具;把冗長探索委派給唯讀子代理以保護上下文(§13.5)。
無頭護欄	在 <code>claude -p</code> 中沒有提示——用 <code>--allowedTools</code> 預先核准工具,並用 <code>deny</code> 強制限制(§13.4、§13.6)。

對應 Domain 3(20%)。 如果你能設計並捍衛上面那套受護欄保護的稽核工作流——每件事用對工具、先搜尋的調查方式,以及一種讓危險之事成為不可能(而非僅僅不被鼓勵)的權限分配——你就掌握了「把 Claude Code 當成有紀律的工程工作流」的核心。

第二部分:考試領域筆記

領域 1:代理架構與編排(27%)

本領域涵蓋什麼

這是考試中最大的領域——27%,比其他任何領域都高。它測驗你能否從一段問題描述出發,設計出正確的代理式系統,判斷何時單一代理就足夠、何時要把工作拆分到協調者與子代理之間,控制代理迴圈,跨越隔離邊界傳遞上下文,並以 hooks 確定性地強制執行業務規則。第 3 章(Claude Agent SDK) 與第 8 章(任務分解) 的所有內容,都匯入本領域。

如何測驗。 題目是情境式的,而非定義式的。通常會給你一段簡短的業務情境(「一個必須涵蓋數個子主題的研究助理」、「一個在財務動作前必須先驗證身分的工作流程」)以及四個看似合理的架構。錯誤選項通常幾乎正確——它們在單一迴圈更簡單時卻選了多代理設計、把金錢規則放進提示而非 hook,或忘了子代理不會繼承任何上下文。考試獎勵的是在仍能滿足情境所要求保證的前提下,最簡單的設計。

flowchart TD

```
A[閱讀情境] --> B{單一連貫任務  
還是多個獨立部分?}
B -->|單一任務| C[單一代理迴圈]
B -->|多個部分| D{各部分是否獨立  
且可平行化?}
D -->|是| E[協調者加上  
隔離的子代理]
D -->|否,需嚴格順序| F[固定管線  
提示鏈接]
C --> G{是否有規則必須  
100 percent 保證?}
E --> G
F --> G
G -->|是| H[以 hook 強制執行]
G -->|否| I[以提示引導]
```

以下六個心智模型——迴圈控制、協調者/子代理拓撲、明確上下文、強制執行 vs 引導、分解策略、工作階段生命週期——就是本領域的全部。掌握每一個的取捨,你幾乎能用刪去法回答任何 Domain 1 的題目。

1.1 設計用於自主任務執行的代理迴圈

重點知識:

- 代理迴圈生命週期:發送 Claude 請求、檢查 `stop_reason` ("tool_use" 對比 "end_turn")、執行工具、回傳結果以供下一次迭代使用
- 工具結果會附加到對話歷史中,讓模型能決定下一個動作
- 模型驅動的決策(由 Claude 選擇下一個工具)對比硬編碼的決策樹

重點技能:

- 流程控制:當 `stop_reason = "tool_use"` 時繼續迴圈,遇到 "end_turn" 時停止
- 在迭代之間將工具結果附加到上下文中
- 應避免的反模式:解析助理文字以判斷完成、將任意的迭代上限當作主要的停止機制

為何重要與正確的心智模型

代理迴圈是**模型驅動**的: Claude 會檢視最新的工具結果,並自行決定 **下一個動作**,而不是照著你事先固定的順序走。這正是要用代理而非腳本的全部理由。判定工作已完成的唯一權威訊號,是 API 欄位 `stop_reason == "end_turn"`。其餘一切都是猜測。

常見考試陷阱:

- 把「Done」或「Task completed」這類助理文字當成完成訊號。文字是內容,不是控制流——Claude 可能在任務進行到一半時說「done」,也可能根本不說。
- 把 `max_iterations` 當作**主要的**停止條件。輪數上限是防止迴圈失控的合理安全後盾,但若它才是任務通常的結束方式,那這個迴圈就壞了。正常的出口是 `end_turn`。
- 忘了把 `tool_result` 附加回歷史。如果你呼叫了工具卻從不把結果餵回去,模型在下一輪就是盲的,會陷入迴圈或產生幻覺。

心智模型:一個依 `stop_reason` 分支的 `while` 迴圈,把每個 `tool_result` 附加到歷史,並**只在** `end_turn` 時退出。

1.2 編排多代理系統(協調者—子代理)

重點知識:

- 中心輻射式架構:協調者掌管所有代理間的通訊、錯誤處理與路由
- 子代理在隔離的上下文中運作——它們不會自動繼承協調者的歷史
- 協調者職責:任務分解、委派、結果彙整、子代理的動態選擇
- 協調者過度狹隘分解的風險

重點技能:

- 在子代理之間分配研究範圍以盡量減少重複
- 實作迭代式精煉迴圈(協調者評估綜整結果並重新路由任務)
- 將所有通訊都透過協調者進行以利可觀測性

為何重要與正確的心智模型

多代理是一種**中心輻射式**拓撲:中心一個協調者,輻條上是隔離的子代理,而且**沒有輻條對輻條的邊**。協調者分解任務、選出實際需要哪些子代理(動態選擇——別每次都固定生成五個)、委派,然後彙整並驗證。把每個訊息都經由中樞路由,正是讓你獲得可觀測性、並有單一處所可處理錯誤與重試的原因。

flowchart TD

U[使用者請求] --> C[協調者]

C -->|Task: 涵蓋子主題 A| S1[子代理 A
隔離上下文]

C -->|Task: 涵蓋子主題 B| S2[子代理 B
隔離上下文]

C -->|Task: 涵蓋子主題 C| S3[子代理 C
隔離上下文]

S1 -. 僅回傳結果 .-> C

S2 -. 僅回傳結果 .-> C

S3 -. 僅回傳結果 .-> C

C --> V{涵蓋是否完整
且一致?}

V -->|否, 發現缺口| C

V -->|是| R[彙整並回傳]

考試所測的決定性取舍: 單一代理 vs 多代理。 多代理並非預設, 也不會自動更好。它以協調開銷, 以及結果零散、重複或不一致的風險為代價, 換來平行性與上下文隔離(每個子代理拿到一個乾淨、聚焦的視窗)。唯有當工作能拆成**真正獨立的部分**時才採用它——涵蓋數個研究子主題、審查多個檔案。對於單一連貫任務, 單一迴圈更簡單, 通常也才是正確答案。

常見考試陷阱:

- 為實際上是單一推理線的任務選擇多代理。多餘的代理只增加協調成本與失敗模式, 毫無好處。
- **過度狹隘的分解。** 若協調者把主題切得太細, 子代理會彼此重疊、漏掉切片之間的接縫, 綜整結果則充滿缺口與重複。解法是圖中的**迭代式精煉迴圈**: 協調者評估合併後的結果、找出缺口, 並重新路由一個有針對性的後續任務。
- 想像子代理彼此交談。它們不會。所有通訊都經由協調者流動。

1.3 設定子代理呼叫、上下文傳遞與生成

重點知識:

- `Task` 工具用於生成子代理; 協調者的 `allowedTools` 必須包含 `"Task"`
- 子代理的上下文必須明確包含在提示中; 子代理不會繼承父層上下文
- `AgentDefinition` 設定: 描述、系統提示、工具限制
- 透過 `fork_session` 進行工作階段管理以探索不同方案

重點技能:

- 在子代理提示中包含先前代理的完整輸出
- 在傳遞上下文時使用結構化格式, 將資料與中繼資料分開
- 在單一協調者輪次中透過多個 `Task` 呼叫生成平行子代理
- 以目標與品質標準來撰寫協調者提示, 而非逐步指令

為何重要與正確的心智模型

這是本領域被考最多的機制: **子代理什麼都不會繼承**。由 `Task` 工具生成的子代理, 從一個空白的上下文視窗開始。它看不到協調者的對話、使用者的原始訊息, 或任何其他子代理的輸出。如果子代理需要那份文件、先前的搜尋結果與輸出 schema, **這一切都必須明確地寫進 `Task` 提示裡**。忘記這一點正是經典的錯誤答案——設計「看起來」沒問題, 但子代理是盲目運作的。

```
sequenceDiagram
    actor U as 使用者
    participant C as 協調者
    participant A as 子代理 A
    participant B as 子代理 B
    U->>C: 跨子領域調查某主題
    C->>A: Task(目標加上完整上下文:資料、先前結果、schema)
    C->>B: Task(目標加上完整上下文:資料、先前結果、schema)
    Note over A,B: A 與 B 平行執行,<br/>彼此看不見
    A-->>C: 結構化結果 A
    B-->>C: 結構化結果 B
    C->>C: 彙整並驗證
    C-->>U: 綜整後的答案
```

考試預期你掌握的實務規則:

- 協調者的 `allowedTools` (或 `allowed_tools`) 必須包含 **"Task"**, 否則它無法生成任何子代理。
- **平行性 = 單一協調者輪次中的多個 Task 呼叫。** 在單一回應中送出三個 `Task` 會讓三者同時執行。把它們分散到不同輪次則會序列化。
- 以**將資料與中繼資料清楚分離的結構化資料**傳遞上下文,讓子代理不會把它該分析的文件,與關於該文件的指令搞混。
- 以**目標與品質標準**撰寫協調者提示(「涵蓋每個子主題且不重疊;標示矛盾之處」),而非微觀管理的步驟清單——代理的全部意義,就在於由它來規劃步驟。

`fork_session` 會把當前上下文複製成一個獨立分支,讓你能平行探索不同方案而不污染原本的上下文。這與 §1.7 介紹的 `--resume` 形成對比。

1.4 以強制執行與交接模式實作多步驟工作流程

重點知識:

- 程式化強制執行(hooks、前置條件)與提示引導在工作流程排序上的差異
- 當你需要確定性保證時(例如金融操作前的身分驗證),單靠提示是不夠的
- 升級期間的結構化交接協定(客戶 ID、原因、建議動作)

重點技能:

- 程式化前置條件,在先前步驟完成前阻擋下游呼叫(例如在 `get_customer` 回傳已驗證的 ID 之前阻擋 `process_refund`)
- 將多面向的客戶請求分解為個別項目
- 在升級至真人時產生結構化摘要

為何重要與正確的心智模型

多步驟工作流程有**排序約束**——「在任何財務動作**之前**先驗證身分」、「在扣款**之前**先確認庫存」。考試的核心區別在於你**如何**強制執行那個順序:

機制	保證	用於
----	----	----

程式化強制執行(程式中的 hook / 前置條件)	確定性,100%	金錢前先驗身、不可逆或受合規約束的步驟
提示引導(「請先驗證客戶」)	機率性,約 90%	軟性排序、建議、風格

如果排序攸關**金錢、安全或合規**,提示就不夠——模型通常會遵守但並非總是,而對於財務前置條件,「通常」是不可接受的。你要實作一個**前置條件**:在 `get_customer` 回傳已驗證的 ID 之前,阻擋 `process_refund` 的程式碼。模型根本無法把財務步驟提前執行。

交接給真人必須是**結構化**協定,而非含糊的「問一下人」。升級時,交接一份結構化摘要:客戶 ID、升級原因,以及建議動作。這讓真人(或下一個系統)不必重新推導整個案件就能行動。

多面向請求(「我想退款**而且**更新地址**而且**取消訂閱」)應**分解為個別項目**並逐一處理,如此一來其中一部分失敗,才不會悄悄地把其他部分一起丟掉。

1.5 用於攔截工具呼叫與正規化資料的 Agent SDK Hooks

重點知識:

- Hook 模式(例如 `PostToolUse`),在模型取用工具結果之前加以攔截
- 攔截外送呼叫以強制執行合規規則的 Hooks(例如阻擋超過門檻的退款)
- Hooks 提供**確定性保證**,而提示指令僅提供**機率性合規**

重點技能:

- 用 `PostToolUse` hooks 正規化資料格式(Unix timestamps、ISO 8601、數值狀態碼)
- 攔截 hooks 以阻擋違反政策的動作,並重新導向至升級流程
- 當業務規則需要保證合規時,選擇 hooks 而非提示

為何重要與正確的心智模型

hook 是在代理生命週期的固定節點上執行的程式碼,會轉換或阻擋通過它的內容。因為它是程式碼,所以是**確定性的——100%**。每當提示約 90% 的合規率不夠好時,這就是你要拉的那根槓桿。

考試中佔主導地位的是兩個 hook 節點:

```
flowchart TD
    M[模型決定呼叫某工具] --> Pre1[Pre{{PreToolUse hook<br/>政策閘門}}]
    Pre1 -->|允許| T[工具執行]
    Pre1 -->|違反政策| Esc[改道至升級<br/>或阻擋]
    T --> Post1[Post{{PostToolUse hook<br/>正規化結果}}]
    Post1 --> Ctx[乾淨、一致的資料<br/>進入模型上下文]
```

- PreToolUse** 在外送工具呼叫執行前攔截它——這是**阻擋政策違規**(例如超過門檻的退款)並改道至升級的地方。模型無法繞過它。
- PostToolUse** 在模型看到**工具結果**之前攔截它——這是**正規化資料**的地方,讓模型永遠不必對三種不同的日期格式或原始數值狀態碼進行推理。把 Unix 時間戳記與 `"Mar 5, 2025"` 轉成 ISO 8601、把狀態碼映射成標籤,然後再交給模型。

常見考試陷阱: 把一條需要保證的業務規則放進系統提示。提示中的「永遠把超過 \$500 的退款升級」是機率性的,終究會漏。同一條規則放進 `PreToolUse` hook 則每次都會被強制執行。**當失敗會造成財務、法律或安全後果時,選擇 hook,而非提示。**(這就是 §3.5 的 hooks 對比提示表,也是整場考試中最穩定被測的觀念之一。)

1.6 複雜工作流程的任務分解策略

重點知識:

- **固定管線**(提示鏈接)對比根據中間結果進行的**動態自適應分解**
- 提示鏈接:循序步驟(分別分析每個檔案,再執行一次整合遍歷)
- 自適應調查計畫,根據所發現的內容產生子任務

重點技能:

- 對可預測的多面向審查使用提示鏈接;對開放式調查使用動態分解
- 將大型程式碼審查拆分為逐檔分析,加上獨立的跨檔整合遍歷
- 分解開放式任務:先盤點結構,再建立排定優先順序的計畫

為何重要與正確的心智模型

分解策略是一個**可預測性**的決定:

策略	步驟是否能事先得知?	範例
固定管線 / 提示鏈接	是——你事先就知道步驟	審查每個檔案,再做一次跨檔整合遍歷
動態自適應分解	否——下一步取決於你剛剛發現了什麼	開放式調查:盤點結構,再從你的發現產生排定優先順序的計畫

```
flowchart TD
    Start[複雜任務] --> Q{步驟是否能  
事先得知?}
    Q -->|是| Chain[固定管線  
提示鏈接]
    Q -->|否| Adapt[動態分解  
計畫隨發現成長]
    Chain --> C1[逐檔分析]
    C1 --> C2[跨檔整合遍歷]
    Adapt --> A1[先盤點結構]
    A1 --> A2[產生排定優先順序的子任務]
    A2 --> A3{新發現是否  
改變了計畫?}
    A3 -->|是| A2
    A3 -->|否| Done[綜整]
    C2 --> Done
```

大型程式碼審查是典型的**固定管線**案例:分別分析每個檔案(可平行、可預測),再做一次**獨立的跨檔整合遍歷**,以抓出跨越多檔的問題——這是逐檔遍歷在結構上看不到的問題。**開放式調查**則是典型的**動態**案例:你無法事先列舉步驟,於是代理先盤點結構,並隨著發現而成長出一份排定優先順序的計畫。

常見考試陷阱: 把僵硬的管線硬套到開放式問題上(它無法因應所發現的內容)——或為步驟完全已知的任務啟動一個開放式自適應代理(不必要的非確定性)。把策略與「步驟是否能事先得知」對上。

1.7 工作階段狀態、恢復與分叉

重點知識:

- `--resume <session-name>` 用於繼續具名的工作階段
- `fork_session` 用於從共享上下文建立獨立的調查分支
- 在恢復工作階段時告知代理檔案變更的重要性
- 帶有結構化摘要的新工作階段,可能比帶著過時結果恢復更為可靠

重點技能:

- 使用 `--resume` 繼續具名的調查工作階段
- 使用 `fork_session` 平行比較不同做法
- 在恢復(上下文仍為最新)與啟動新工作階段(結果已過時)之間做出選擇

為何重要與正確的心智模型

三種生命週期操作,三種截然不同的用途:

操作	它做什麼	何時使用
<code>--resume <name></code>	繼續一個具名工作階段,保留其歷史	先前的上下文 仍為最新
<code>fork_session</code>	把當前上下文分支成一個獨立副本	你想 平行比較不同做法 而不互相污染
新工作階段加結構化摘要	全新開始,只注入一份乾淨的摘要	先前的結果 已過時 或歷史已被污染

那個微妙、常被測的判斷: 恢復**並非**總是最好。如果工作階段底下的世界已經改變——檔案被編輯、資料被搬動——工作階段所儲存的結果就已**過時**,盲目恢復會讓代理對錯誤的事實進行推理。兩個正確做法:恢復時,告知代理檔案的變更,讓它重新讀取而非信任快取的發現;或者,當過時程度顯著時,改為**啟動一個以結構化摘要注入的新工作階段**。一份乾淨的摘要,往往勝過一段冗長、部分失效的歷史。

`fork_session` 是平行探索的工具:複製共享的上下文,在兩個分支上各跑一種策略,再比較結果——兩個分支都不會污染彼此或原本的上下文。

已解析考試情境

情境。 你正在設計一個**競爭情報研究助理**。使用者問道:「**比較我們三家主要競爭對手在定價、產品功能與顧客觀感上的表現,並告訴我我們在哪裡最脆弱。**」該助理具備網路搜尋、定價資料庫,以及評論彙整 API 等工具。公司政策:**任何對外發布、關於競爭對手的論述都必須引用一個檢索到的來源**——無來源的論述屬於合規違規。哪一種架構是正確的?

推理至答案的過程:

1. **單一代理還是多代理?** 這個請求扇出成**真正獨立的部分**——三家競爭對手 × 三個面向(定價、功能、觀感),可以平行研究而互不相依。這種獨立性,正是採用**多代理**的訊號(§1.2)。單一迴圈會把工作序列化,並把

三家競爭對手份量的原始資料,擠進同一個上下文視窗。

- 2. **協調者設計。** 使用一個會分解請求並**動態選擇**子代理的協調者——每個(競爭對手、面向)單元一個,或每個面向一個、涵蓋全部三家競爭對手。為避免**過度狹隘分解**的陷阱(\$1.2),保留一個**迭代式精煉迴圈**:協調者檢查合併結果是否有涵蓋缺口與矛盾的發現,再於必要處重新路由一個有針對性的後續 Task。
- 3. **上下文隔離。** 每個子代理什麼都不會繼承(\$1.3)。協調者必須把每個子代理那一塊的目標以及相關上下文(哪一家競爭對手、哪一個面向、輸出 schema)直接寫進它的 Task 提示。把子代理的各個 Task 在**單一協調者輪次**中送出,使它們平行執行。
- 4. **分解策略。** 逐面向的研究是可預測的,但最終那一步「我們在哪裡最脆弱」是一個**跨切面的整合遍歷**,唯有在所有面向都到位後才有意義——正是 \$1.6 的「先逐項、後整合」形態。面向研究是固定管線;綜整則是整合遍歷。
- 5. **強制執行合規規則。** 「每一條對外論述都必須引用來源」是一個**合規保證**,因此它必須是**確定性的,而非提示**(\$1.4、\$1.5)。提示(「請引用來源」)會漏。實作一個**hook**,檢查外送的論述並**阻擋任何無來源的論述**,將其退回以補上引用。PostToolUse hook 也可以在模型對異質來源中繼資料(搜尋結果、資料庫列、評論 API)進行推理之前,先把它們正規化成一種統一的引用格式。

正確架構: 一個帶有隔離、平行子代理的協調者(每個研究切片一個,並在各自的 Task 中以完整上下文簡報)、一個用於最終脆弱性綜整的**先逐面向、後整合**分解、一個用以填補涵蓋缺口的**迭代式精煉迴圈**,以及一個**確定性地強制執行來源引用規則的 hook**。誘人但錯誤的答案:單一代理(把獨立的工作序列化、使上下文超載)、未以明確上下文簡報的子代理(它們會盲目運作),或把「請引用你的來源」當成提示指令(機率性——達不到合規門檻)。

考試重點 — 關鍵整理

概念	考什麼 / 常見陷阱
代理迴圈停止訊號	只有 stop_reason == "end_turn" 能結束任務。陷阱:把解析助理文字或迭代上限當作主要停止條件(\$1.1)。
單一 vs 多代理	唯有各部分真正獨立/可平行時才用多代理。陷阱:對單一連貫任務預設採用多代理(\$1.2)。
中心輻射式路由	所有通訊都經由協調者流動;子代理彼此從不交談。陷阱:輻條對輻條的邊(\$1.2)。
過度狹隘分解	切得太細會造成重疊與缺口;以迭代式精煉迴圈修正(\$1.2)。
明確上下文傳遞	子代理什麼都不繼承——完整上下文要放進 Task 提示。陷阱:以為歷史是共享的(\$1.3)。
平行子代理	單一協調者輪次中的多個 Task 呼叫會同時執行。陷阱:把 Task 分散到不同輪次(\$1.3)。
協調者 allowedTools	必須包含 "Task", 否則根本無法生成子代理(\$1.3)。
強制執行 vs 引導	金錢/安全/合規的排序需要程式化前置條件,而非提示(\$1.4)。
結構化交接	升級時要帶客戶 ID、原因、建議動作——絕非含糊的「問一下人」(\$1.4)。

Hooks vs 提示	Hooks 是確定性的(100%);提示是機率性的(約 90%)。需保證的規則 → hook(\$1.5)。
PreToolUse vs PostToolUse	Pre 阻擋/改道外送呼叫;Post 在模型看到結果前正規化它(\$1.5)。
固定 vs 動態分解	步驟可事先得知 → 提示鏈接;步驟取決於發現 → 自適應(\$1.6)。
先逐檔後整合	大型審查需要一次逐檔遍歷看不到的獨立跨檔遍歷(\$1.6)。
恢復 vs 新工作階段	只在上下文為最新時才恢復;結果過時 → 以結構化摘要開新工作階段;並告知代理檔案變更(\$1.7)。
<code>fork_session</code>	把共享上下文分支以進行平行比較而不互相污染(\$1.7)。

對應 Domain 1(27%)——權重最高的領域。 如果你能依證據在單一與多代理之間做選擇、以完整上下文簡報隔離的子代理、為需保證的規則選擇 hooks 而非提示,並把分解策略與可預測性對上,你就掌握了最大考試領域的核心。請交叉參照第 3 章(Agent SDK)與第 8 章(任務分解)。

領域 2:工具設計與 MCP 整合(18%)

本領域測驗的是你能否**設計代理與外部世界之間的合約**:工具該如何描述,模型才會正確挑選它;工具該如何回報成功與失敗;工具該如何跨代理分配並以 `tool_choice` 引導;MCP 伺服器該如何接入 Claude Code 與 Agent SDK;以及何時該採用內建工具、何時該採用 MCP 伺服器。它佔考試權重 **18%——第三高的領域——並以第 2 章(`tool_use`)與第 4 章(MCP)**的理論為基礎。

如何測驗。 題目幾乎都是**情境導向**:給你一個行為失常或規格不足的整合(兩個容易混淆的工具、一個破壞復原決策的通用錯誤、一個淹沒在 18 個工具裡的代理、註冊在錯誤範圍的伺服器、與認證模型不符的傳輸),要求你給出**正確的修正**。反覆出現的陷阱是:在正確答案應為**結構性變更**時卻去動**提示指令**——重新命名/拆分工具、回傳分類錯誤、限縮工具集、把規則移進伺服器。貫穿每一題的心智模型如下:

```
flowchart TD
    Need[代理需要某項能力] --> Q1{讀取上下文<br/>還是執行動作?}
    Q1 -->|只讀取| RES[MCP Resource<br/>唯讀地圖]
    Q1 -->|有副作用的動作| Q2{內建或社群工具<br/>是否適用?}
    Q2 -->|是| REUSE[重用它<br/>強化描述]
    Q2 -->|否,獨特工作流| TOOL[自訂 MCP 工具<br/>清楚 schema 加錯誤]
    RES --> SEL[描述驅動選擇<br/>錯誤驅動復原]
    REUSE --> SEL
    TOOL --> SEL
```

2.1 以清楚的描述設計工具介面

關鍵知識

- 工具描述是 LLM 用來選擇工具的**主要機制**;描述過於精簡會導致選擇不可靠。
- 納入輸入格式、範例查詢、邊界案例與適用範圍界線的重要性。
- 模糊或重疊的描述會造成錯誤路由。

- 系統提示的用字遣詞可能與工具產生非預期的關聯。

關鍵技能

- 撰寫能清楚區分各工具與相似替代工具的描述。
- 重新命名工具以消除功能重疊(例如 `analyze_content` -> `extract_web_results`)。
- 將通用型工具拆分成具有清楚輸入/輸出合約的專用工具。

為何重要與正確的心智模型

模型永遠看不到你的實作——它只看得到 `name`、`description` 與 `input_schema`。這三個欄位**就是路由表**。描述不是給人看的文件;它是決定「正確工具是否被觸發」的提示。因此模糊或重複的描述不是表面問題——它是一個**正確性錯誤**,會以「代理呼叫了錯誤的工具」這種形式浮現。好的描述會說明工具做什麼、回傳什麼、輸入格式與範例值、邊界案例與限制,以及**何時該用它而非相似工具**。

考試中有兩種失敗模式最為常見:

- **重疊**。若 `analyze_content` 與 `analyze_document` 讀起來幾乎一樣,模型會把它們搞混。修正之道是**為了明確而重新命名**(`analyze_content` -> `extract_web_results`),並將過於通用的工具**拆分成**具有不同合約的專用工具——而不是再貼上更多提示文字。
- **提示偏誤**。系統提示的用字會製造非預期的關聯:「你是一位**搜尋助理**」會讓模型偏向任何叫 `search_*` 的東西。路由是描述與周邊提示**兩者**共同的產物,因此消除歧義有時是修提示,而非修工具。

考試還會探究另一種選擇偏誤:代理傾向**偏好內建工具(Read、Grep)而非功能相似的 MCP 工具**。要讓一個必要的 MCP 工具拿到應得的呼叫比例,就強化**它的描述**——點明具體優勢、獨有的資料,或內建工具無法提供的上下文。

常見考試陷阱

- 當兩個工具容易混淆時,選擇「在系統提示中加一條指令告訴模型該用哪個工具」。考試的正解是**改寫/重新命名描述**(並拆分過於通用的工具)。
- 把描述當成文件,而非模型的決策輸入。

2.2 為 MCP 工具實作結構化錯誤回應

關鍵知識

- MCP 工具回應中的 `isError` 旗標。
- **暫時性錯誤**(逾時)、**驗證錯誤**(輸入錯誤)、**業務錯誤**(違反政策)與**存取/權限錯誤**之間的差異。
- 通用錯誤(「Operation failed」)會妨礙做出正確的復原決策。
- 可重試與不可重試錯誤之間的差異。

關鍵技能

- 回傳結構化中繼資料,例如 `errorCategory` (transient/validation/permission)、`isRetryable` 以及人類可讀的訊息。
- 對違反業務規則的情況使用 `retryable: false`,並附上清楚的面向使用者的說明。
- 對暫時性失敗在子代理內部進行本機復原;只將它們無法解決的錯誤向上傳遞。
- 區分存取失敗(重試決策)與有效的空結果(無相符項目)。

為何重要與正確的心智模型

`isError: true` 告訴代理某次呼叫失敗了,但只發出失敗訊號還不夠。代理的下一步——重試、修正參數、停下並說明,或升級——完全取決於那是哪一種失敗。光是 `"Operation failed"` 會讓代理進退兩難:它分不出是不穩定的逾時(該重試)還是硬性政策拒絕(該停止)。讓復原成為可能的合約,是一個帶有 `errorCategory`、`isRetryable` 與人類可讀 `message` 的結構化錯誤。

```
{
  "isError": true,
  "content": {
    "errorCategory": "transient",
    "isRetryable": true,
    "message": "Orders API timed out; safe to retry.",
    "attempted_query": "order_id=12345"
  }
}
```

四種類別乾淨地對應到四種代理反應:

類別	意義	可重試?	正確的代理反應
<code>transient</code>	逾時、服務短暫中斷	是	重試,最好搭配退避
<code>validation</code>	輸入錯誤(格式錯誤的 id、缺欄位)	否	修正參數後再重試
<code>business</code>	違反政策/規則(超出上限)	否	停下並向使用者說明;不要重試
<code>permission</code>	呼叫者缺乏存取權	否	升級或請求存取權

```
flowchart TD
    E[工具回傳 isError true] --> CAT{errorCategory?}
    CAT -->|transient| RETRY[搭配退避重試]
    CAT -->|validation| FIX[修正參數<br/>然後重試]
    CAT -->|business| STOP[停下並說明<br/>不要重試]
    CAT -->|permission| ESC[升級或請求存取權]
    RETRY --> LOCAL[可行則在本機解決]
    FIX --> LOCAL
    LOCAL -. 僅在無法解決時 .-> UP[向協調者傳遞]
    STOP --> UP
    ESC --> UP
```

常見考試陷阱

- 把違反業務規則標成可重試。政策性失敗(超出退款上限、回滾被拒)必須是 `isRetryable: false`,否則代理會在無謂的重試迴圈中耗掉回合。請搭配清楚的、面向使用者的說明。
- 把空結果當成錯誤。合法地找不到任何東西的搜尋應回傳 `isError: false` 並附空集合——而非 `isError: true`。把「無相符」與「存取失敗」混為一談,會讓代理在只該回報「找不到」時去升級。
- 把每個失敗都往上傳。子代理應在本機復原暫時性失敗(重試),只把它真正無法解決的往上傳——這能讓 hub-and-spoke 協調者免於錯誤雜訊(連結至領域 5)。

2.3 跨代理分配工具並設定 `tool_choice`

關鍵知識

- 每個代理的工具過多(例如 18 個而非 4–5 個)會**降低**工具選擇的可靠性。
- 擁有超出其專長範圍工具的代理往往會誤用它們。
- 限定範圍的工具存取:只提供與角色相關的工具,加上一組有限的跨角色公用工具。
- `tool_choice`: "auto"、"any" 以及強制工具選擇(`{"type": "tool", "name": "..."}`)。

關鍵技能

- 將每個子代理的工具集限制為與其角色相關的工具。
- 以受約束的替代工具取代通用工具(例如 `fetch_url` -> `load_document`)。
- 使用 `tool_choice: "any"` 以保證產生工具呼叫而非文字答案。
- 強制使用特定工具以確保執行順序。

為何重要與正確的心智模型

工具數量是一筆預算,而非免費的維度。你每多暴露一個工具,就擴大模型的決策空間;一個拿到 18 個工具的代理,其選擇**比**只拿到實際所需 4-5 個的代理**更差**,而持有超出其專長工具的代理往往會誤用它們。原則是**每個角色最小權限**:每個子代理只拿到與角色相關的工具,加上一小組共用的跨角色公用工具。當通用工具會招致誤用時,以受約束的工具取代它——`fetch_url` (什麼都能連)換成 `load_document` (有界限的合約)。這與 MCP 設計在領域 4 用 *MCP 工具搜尋* 拉動的是同一根槓桿:它會延遲載入伺服器工具,讓十幾個已連線伺服器不至於淹沒上下文。

`tool_choice` 是疊在那個工具集之上的方向盤:

值	行為	何時使用
<code>{"type": "auto"}</code>	模型自行決定要呼叫工具或以文字作答	多數情況的預設
<code>{"type": "any"}</code>	模型 必須 呼叫某個工具(絕不純文字)	保證結構化輸出
<code>{"type": "tool", "name": "..."} </code>	模型 必須 呼叫該特定工具	強制第一步/執行順序
<code>{"type": "none"}</code>	模型本回合 不得 呼叫任何工具	暫時停用工具而不移除

flowchart TD

```
Start[設計一個回合] --> Q1{需要保證產生工具呼叫?}
Q1 -->|否,文字即可| AUTO[tool_choice auto]
Q1 -->|是| Q2{特定一個工具還是任一工具?}
Q2 -->|任一最佳工具| ANY[tool_choice any]
Q2 -->|強制的的第一步| FORCE[tool_choice tool name]
FORCE -. 註 會停用思考 .-> WARN[只強制無副作用的工具]
ANY --> OUT[保證結構化輸出]
FORCE --> OUT
```

常見考試陷阱

- 靠加更多工具或更多提示文字來解決選擇可靠性低的問題。正解是把工具集縮減到角色所需,並消除描述歧義(2.1)——更少、更銳利的工具。
- 在下游程式需要結構化輸出時用 `auto`。用 `auto` 時 Claude 可能合法地以散文作答;無條件解析 `tool_use` 區塊的程式就會當掉。當工具呼叫為必要時請用 `any`。
- 為了「拿到結構」而強制一個有副作用的工具。被強制的工具(`type: "tool"`)會被無條件呼叫,且該回合停用延伸思考——因此絕不要強制 `send_email`;改強制一個擷取/格式化工具。

2.4 將 MCP 伺服器整合至 Claude Code 與代理工作流程

關鍵知識

- MCP 伺服器範圍:供團隊使用的專案層級(`.mcp.json`)vs 供實驗使用的使用者層級(`~/.claude.json`)。
- 在 `.mcp.json` 中進行環境變數替換(例如 `${GITHUB_TOKEN}`)以管理機密。
- 所有已連線 MCP 伺服器的工具會在連線時被探索並同時可用。
- 將 MCP 資源作為「內容目錄」(任務摘要、資料庫結構描述)以減少探索性的工具呼叫。

關鍵技能

- 在專案 `.mcp.json` 中以環境變數為基礎的 token 設定共用的 MCP 伺服器。
- 將個人/實驗性的伺服器保留在 `~/.claude.json` 中。
- 對於標準整合,優先採用社群 MCP 伺服器而非自訂伺服器。

為何重要與正確的心智模型

你把伺服器註冊在哪裡,決定了誰能用它;而你怎麼處理它的機密,決定了你是否剛剛把它外洩了。兩種範圍:

- 專案——repo 根目錄的 `.mcp.json`,納入版本控制。每位貢獻者在 checkout 時都拿到相同的伺服器。這是「如何讓每位開發者拿到相同伺服器而不需各自手動編輯設定」的考試正解。
- 使用者——家目錄的 `~/.claude.json`,不納入版本控制。用於個人實驗與測試。

機密透過環境變數替換處理:你提交的是參照 `"${GITHUB_TOKEN}"`,絕不是 token 本身。把 token 硬寫進 `.mcp.json` 是經典的錯誤答案。

```

flowchart TD
    Q{誰該拿到<br/>這個伺服器?}
    Q -->|整個團隊,可重現| PROJ[專案根目錄的 .mcp.json<br/>提交到 git<br/>env-var token 參照]
    Q -->|只有我,實驗性| USER[~/.claude.json<br/>家目錄<br/>不納入版本控制]
    PROJ --> TEAM[所有貢獻者在<br/>checkout 時取得]
    USER --> SOLO[只有這位開發者]
```

考試還會倚重另外三個事實:

- 所有已連線伺服器的工具會一次載入。連線時用戶端呼叫 `tools/list`,每個工具同時對模型可用——並以 `mcp__<server>__<tool>` 命名空間(例如 `mcp_github_create_issue`)。這個精確名稱正是你用來加入允許清單或以 `tool_choice` 強制的對象。但「一次全部」也是一筆成本:十幾個伺服器可能以數百個工具淹沒上下文並降低選擇品質(回扣 2.3)。MCP 工具搜尋透過延遲載入工具來緩解。

- **資源能減少探索性呼叫。**把穩定的唯讀上下文——服務目錄、資料庫結構描述、任務摘要——暴露為 MCP Resource(「內容目錄」),讓代理一次讀取那張地圖,而非燒掉三四次工具呼叫去摸清系統的形狀。把同一份唯讀資料塑造成 `list_x` 工具是錯誤答案:它會膨脹工具數並逼出探索性往返。
- **重用優於重造。**對標準整合(Jira、GitHub、Slack)優先採用既有社群 MCP 伺服器——有人維護且久經考驗。只在沒有任何社群伺服器涵蓋的獨特、團隊專屬工作流才自建伺服器。

```
sequenceDiagram
    actor Dev as 開發者
    participant CC as Claude Code host
    participant Srv as MCP 伺服器
    Dev->>CC: 開啟含 .mcp.json 的專案
    CC->>Srv: 連線,注入 env-var token
    CC->>Srv: tools/list
    Srv-->>CC: 工具 mcp__server__query 等
    CC->>Srv: 讀取 resource catalog 地圖
    Srv-->>CC: catalog JSON,無探索性呼叫
    CC->>Dev: 工具與資源就緒
```

常見考試陷阱

- 把共用的團隊伺服器放在 `~/.claude.json` (只有那一位開發者拿得到),而非專案 `.mcp.json`。
- 把 token 硬寫進 `.mcp.json`,而非用 `${VAR}` 參照。
- 為社群伺服器已涵蓋的標準整合自建伺服器。
- 把唯讀上下文塑造成工具而非 Resource。

2.5 選擇並運用內建工具(Read、Write、Edit、Bash、Grep、Glob)

關鍵知識

- **Grep:**在檔案內容中搜尋(函式名稱、錯誤訊息、匯入)。
- **Glob:**依名稱/副檔名模式尋找檔案。
- **Read/Write:**整個檔案的操作;**Edit:**透過唯一文字比對進行精確變更。
- 若 Edit 因比對不唯一而失敗,改用 Read + Write。

關鍵技能

- 使用 Grep 進行內容搜尋,使用 Glob 依模式探索檔案。
- 漸進式建立理解:先 Grep 進入點,再 Read 追蹤流程。
- 透過包裝模組追蹤函式的使用。

為何重要與正確的心智模型

每個內建工具只有一項職責,而考試獎勵挑選最便宜的正確工具。在該用 Read 之處用 shell `cat`,或在一次 Grep 就能回答時卻讀十個檔案,都會被判錯——兩者都浪費上下文並降低可靠性。

任務	工具
依名稱/模式尋找檔案	Glob

在檔案內容中搜尋	Grep
完整讀取已知檔案	Read
建立新檔案	Write
精確變更既有檔案	Edit (唯一字串比對)
執行 git / 測試 / 建置	Bash

經典陷阱是 **Grep vs Glob**:Glob 回答「*哪些檔案符合這個名稱模式?*」且永不開啟內容;Grep 回答「*哪些檔案包含這段文字?*」(建構於 ripgrep——支援真正的正規表示式、尊重 `.gitignore`)並回傳相符項而非整個檔案;Read 用於你已知*哪個*檔案時。把用 Glob 找到的檔案「順便打開看看」是最常見的浪費上下文反模式。

Bash 是逃生口,不是預設。凡是型別化工具能做的,你可以用 Bash 的 `find / grep / cat` 做——但不該:專用工具會整合權限 UI、回傳結構化結果,並避免 shell 引號錯誤。把 Bash 保留給沒有專用工具的事(`git`、`npm` / `pytest`、建置)。

Edit 的失敗模式是刻意的。`Edit` 比對一個*唯一*字串;若目標文字出現多於一次,它會依設計失敗而非亂猜。兩種正確反應:加入周邊上下文讓比對變唯一(或在你真的指全部時用 `replace_all`),或退回 **Read + Write**(載入整個檔案、重新計算、寫回)。

調查是**漸進式**的,而非「把整個 repo 載入」:Grep 來*定位*進入點、Read 來*確認*、再 Grep 找*使用處*,如此反覆。這是一項上下文管理技能——太早讀取整個目錄會以你不需要的文字塞滿視窗,並把相關行推進迷失於中段的區域。透過包裝模組追蹤一個函式,意味著要做第二次 Grep(呼叫點),而不只是第一次(定義)。

常見考試陷阱

- 用 **Glob** 找檔案內的文字,或用 **Grep** 依副檔名列檔案——兩者顛倒了。
- 在已有專用工具時預設用 **Bash** 的 `grep / cat / find`。
- 「把整個儲存庫載入上下文」——永遠不是答案;先搜尋再讀取。

實戰考題情境(Worked Exam Scenario)

情境。某資料團隊推出一個內部 `warehouse` **MCP 伺服器**,讓 Claude Code 能協助分析師。它暴露兩個工具,兩者的描述都大致寫成「執行分析查詢並回傳結果」,外加一個列出所有資料表及其欄位的工具。分析師抱怨 Claude 一直 (a) 呼叫*錯誤*的查詢工具、(b) 浪費呼叫到處摸索以得知結構描述,以及 (c) 遇到權限錯誤時,在迴圈中重試同一個被擋的查詢。該伺服器註冊在每位分析師的 `~/.claude.json` 中,且 `warehouse` token 是內嵌貼上的;團隊希望大家都用相同設定,並另有一個給 Slack 機器人的託管版本。

推理。

1. **兩個容易混淆的查詢工具 -> 重新命名並拆分,別用提示補丁(2.1)。**相同的描述是路由錯誤。給各自一個明確名稱與一段說明輸入、輸出以及*何時該用它而非另一個*的描述(例如 `run_readonly_sql` vs `run_aggregation_report`)。在系統提示加「用對的工具」是陷阱答案。
2. **結構描述探索 -> 用 Resource,而非工具(2.4)。**「列出所有資料表與欄位」是穩定的唯讀上下文。把它暴露為 **MCP Resource**(內容目錄),讓 Claude 一次讀取那張*地圖*,而非燒掉探索性呼叫。維持成 `list_tables` 工具會膨脹工具數並逼出往返。

3. 權限錯誤被迴圈重試 -> 結構化、不可重試的錯誤(2.2)。被擋的查詢必須回傳 `isError: true` ,帶 `errorCategory: "permission"`、`isRetryable: false` 與清楚訊息——好讓代理升級而非重試。通用的 `"Operation failed"` 或可重試旗標會造成迴圈。
4. 大家相同設定 + 一個託管機器人 -> 專案範圍、env-var 機密、兩種傳輸(2.4)。把伺服器移進專案 `.mcp.json` (提交後,大家 checkout 時都拿到),並把內嵌 token 換成 `"${WAREHOUSE_TOKEN}"`。為本機分析師以 `stdio` 執行;為 Slack 機器人把同一個伺服器以 **Streamable HTTP 搭配 OAuth** 部署——不是舊版 SSE,也不是每人手動編輯第二份設定。

貫穿全題的主線:每個修正都是**結構性的**(重新命名、拆分、Resource、分類錯誤、正確的範圍/傳輸),而從不是「叫模型乖一點」。

考試重點 — 關鍵要點

概念	測驗內容/常見陷阱
工具描述	描述 + schema 是模型的路由表;修正易混淆工具靠 重新命名/拆分 ,而非提示文字(2.1)。
內建 vs MCP 偏誤	代理偏好內建工具(Read、Grep);強化 MCP 工具的 描述 以贏得它的呼叫(2.1)。
<code>isError</code> 與類別	<code>errorCategory</code> / <code>isRetryable</code> 驅動復原:transient->重試、validation->修參數、business/permission->停止; 空結果不是錯誤 (2.2)。
本機復原	子代理在本機重試暫時性失敗,只把無法解決的往上傳(2.2)。
工具數量預算	18 個工具的選擇比 4-5 個更差; 每角色最小權限 ,以受約束工具取代通用工具(2.3)。
<code>tool_choice</code>	<code>auto</code> 可能以文字作答; <code>any</code> 強制 某個 工具; <code>tool</code> 強制特定工具並 停用思考 ——絕不強制有副作用的工具(2.3)。
伺服器範圍與機密	團隊 -> 專案 <code>.mcp.json</code> (已提交);個人 -> <code>~/.claude.json</code> ;token 用 <code>\${VAR}</code> ,絕不內嵌(2.4)。
Resource vs 工具	唯讀上下文(目錄、結構描述)是 Resource ,能減少探索性呼叫;別把它塑造成工具(2.4)。
傳輸	stdio (本機、env-var 認證)vs Streamable HTTP + OAuth (共用/遠端);舊版 SSE 已淘汰(第 4 章)。
內建工具選擇	Grep = 內容、Glob = 檔名;最便宜的正確工具勝出;Bash 是逃生口;Edit 在比對不唯一時失敗 -> Read+Write(2.5)。

對應領域 2(18%)。若你能拿到一個壞掉的整合,並以**結構性**修正回應——消除描述歧義、分類錯誤、限定伺服器範圍、挑對傳輸、選最窄的內建工具——你就掌握了本領域的核心。第 2 章 (`tool_use`)與第 4 章(MCP)是這些目標背後的深度參考。

領域 3: Claude Code 設定與工作流程(20%)

本領域佔考試的 20%，涵蓋你如何設定與操作 Claude Code 本身——也就是工程師實際執行的 CLI/代理——而非如何用 SDK 建構代理(那是 Domain 1)。考試畫的界線很一致:這裡的題目都在問設定存放在哪裡、它的範圍是什麼、哪一種機制才是正確的工具,以及何時該讓模型規劃而非直接動手。

本領域涵蓋:

- 上下文設定——CLAUDE.md 階層、@path 模組化,以及 .claude/rules/ (§3.1、§3.3)。
- 擴充 Claude Code——自訂斜線命令與 Skills,包含以 context: fork 做上下文隔離(§3.2)。
- 工作流程判斷——規劃模式 vs 直接執行(§3.4)與迭代精修(§3.5)。
- 自動化——在 CI/CD 中以無頭(headless)方式執行 Claude Code 並輸出結構化結果(§3.6)。

如何測驗。預期會是簡短的情境題:給你一個團隊症狀(「新人拿不到我們的測試慣例」、「審查代理一直放行自己的 bug」)與四個看似合理的修法。陷阱選項幾乎總是範圍錯誤(該用專案層級卻用了使用者層級)、機制錯誤(該用確定性設定卻用了提示),或工作流程錯誤(替一行修正做規劃,或對 45 個檔案的遷移直接莽撞動手)。底下的正確心智模型是:挑出能解決問題的最窄範圍、可用的最確定機制,並讓規劃深度對應影響範圍。

```
flowchart TD
    Q[這個設定<br/>該放在哪裡?] --> A{誰需要它?}
    A -->|只有我,<br/>個人工作流程| U[使用者範圍<br/>~/.claude/]
    A -->|整個團隊,<br/>在 VCS 中共用| P{適用各處<br/>還是只有部分檔案?}
    P -->|專案內<br/>各處| Proj[專案 CLAUDE.md<br/>提交進儲存庫]
    P -->|僅單一<br/>子目錄| Dir[目錄 CLAUDE.md<br/>放在該資料夾]
    P -->|橫跨整個樹的<br/>某種檔案類型| Rules[.claude/rules 搭配<br/>paths glob]
    Proj -- 變得太長 --> Modular[用 @path 拆分<br/>或改用 .claude/rules]
```

3.1 以階層、範圍與模組化組織設定 CLAUDE.md

關鍵知識

- CLAUDE.md 階層:使用者(~/.claude/CLAUDE.md)、專案(.claude/CLAUDE.md 或根目錄的 CLAUDE.md),以及目錄層級(子目錄中的 CLAUDE.md)。
- 使用者層級的設定只套用於單一使用者,且不會透過 VCS 共用——你的隊友永遠看不到。
- @path 語法用於參照外部檔案(例如 @./standards/coding-style.md),讓 CLAUDE.md 能匯入模組化標準,而非把所有內容都內嵌進來。
- .claude/rules/ 目錄存放主題聚焦的規則檔(testing.md、api-conventions.md、deployment.md),而非單體式的 CLAUDE.md。

為何重要

CLAUDE.md 是專案的持久記憶:它在每次執行時都會被附加到上下文最前面,因此放在那裡的任何內容都會悄悄左右每一個回應。考試最愛的兩種失敗模式是範圍不符(對的指令放在錯的地方,真正需要的人永遠拿不到)與上下文膨脹(一份 600 行的 CLAUDE.md 燒掉 token,還把真正重要的規則埋沒)。階層與模組化正是解方。

關鍵技能

- 診斷階層問題。經典症狀:新進團隊成員的 Claude Code 忽略某項慣例,因為它被寫進了某人的使用者層級 ~/.claude/CLAUDE.md ,而不是已提交的專案 CLAUDE.md。修法 = 把它移到專案範圍,讓 VCS 散佈

出去。

- 以 `@path` 模組化。在 monorepo 中,每個套件的 CLAUDE.md 都能 `@./standards/testing.md`,只拉進與它相關的標準,讓每個檔案保持精簡。
- 拆分進 `.claude/rules/`。把臃腫的 CLAUDE.md 拆成 `testing.md`、`api-conventions.md`、`deployment.md`,讓每個關注點都能獨立編輯與載入。

正確的心智模型

能觸及所有需要者的最窄範圍。個人偏好 → 使用者。全團隊 → 專案(已提交)。單一子目錄 → 目錄層級。跟著檔案類型而非資料夾走的慣例 → 路徑範圍規則(\$3.3),而非目錄 CLAUDE.md。

常見考試陷阱

- 替團隊必須共用的內容選了使用者層級——它不會傳到他們手上。
- 把 CLAUDE.md 當成無上限——相關內容會爭奪上下文視窗;要模組化。
- 以為目錄層級的 CLAUDE.md 會「向下繼承」到不相關的檔案;它的範圍是該子目錄,而非散佈在整個儲存庫的某種檔案模式。

3.2 建立並設定自訂斜線命令與技能

關鍵知識

- 專案命令位於 `.claude/commands/` (透過 VCS 共用);使用者命令位於 `~/.claude/commands/` (個人、不共用)。
- **技能(Skills)**位於 `.claude/skills/`,其 `SKILL.md` 的 frontmatter 可設定 `context: fork`、`allowed-tools` 與 `argument-hint`。
- `context: fork` 會在隔離的子代理上下文中執行技能,讓它(往往冗長的)輸出不會污染主工作階段。
- 個人化的技能變體可以不同名稱存放在 `~/.claude/skills/`,而不影響團隊共用的版本。

為何重要

斜線命令與技能讓你把一段重複的多步驟提示,變成有名稱、可重用、受治理的操作。考試探究的正是那些治理槓桿——它存放在哪(團隊 vs 個人)、能碰哪些工具(`allowed-tools`)、是否污染上下文(`context: fork`)——因為它們對應到共用、最小權限與上下文衛生這些決策。

關鍵技能

- 透過 `.claude/commands/` 共用,讓整個團隊取得相同的 `/deploy` 或 `/review` 工作流程。
- 以 `context: fork` 隔離吵雜的工作——例如執行整套測試或掃描程式碼庫的技能,其原始輸出否則會把主對話擠掉。
- 以 `allowed-tools` 限制,讓技能只能做它該做的事(產生文件的技能不需要 shell 或寫入權限)。
- 以 `argument-hint` 提示輸入,讓開發者知道某個命令需要哪些參數。

正確的心智模型

技能就是針對重複任務的迷你代理定義。在它的 frontmatter 中決定三件事:對象(專案目錄 vs 使用者目錄)、權限(`allowed-tools` = 所需最小集合),以及上下文(輸出冗長或屬於探查性質時用 `fork`)。

常見考試陷阱

- 把團隊工作流程放進 `~/.claude/commands/` (個人), 結果只有作者擁有它。
- 對冗長的技能省略 `context: fork`, 然後怪「上下文視窗滿了」。
- 對只需唯讀權限的技能授予過廣的工具——違反最小權限。

```
flowchart TD
    Need[我一直在重複<br/>一段多步驟提示] --> Team{全團隊<br/>還是只有我?}
    Team -->|團隊| ProjCmd[.claude/commands<br/>提交進儲存庫]
    Team -->|我| UserCmd[~/.claude/commands]
    ProjCmd --> Verbose{輸出吵雜<br/>或屬探查性質?}
    UserCmd --> Verbose
    Verbose -->|是| Fork[技能搭配<br/>context fork]
    Verbose -->|否| Inline[內嵌命令]
    Fork --> Priv[將 allowed-tools<br/>設為最小權限]
    Inline --> Priv
```

3.3 使用路徑專屬規則進行條件式慣例載入

關鍵知識

- `.claude/rules/` 檔案可帶有 YAML frontmatter `paths`, 以依 **glob** 模式啟用。
- 路徑範圍規則**僅**在編輯符合的檔案時載入, 其餘時間**節省上下文與 token**。
- 當某項慣例適用於許多目錄時(例如每一個測試檔, 無論放在哪裡), 以 glob 為基礎的路徑規則往往**優於目錄層級的 CLAUDE.md**。

為何重要

這是 CLAUDE.md 的外科手術式替代方案。目錄 CLAUDE.md 是**對該資料夾永遠開啟**, 路徑規則則是**對某模式條件式開啟、不限位置**。當慣例跟著**檔案類型**而非**位置**走時, 路徑規則能在恰好相關時送上指令、其餘時間退出上下文——只要考試提到「散佈在程式碼庫各處的測試」或「所有 Terraform 檔案」, 這就是正確答案。

關鍵技能

- 建立帶有 `paths: ["terraform/**/*"]` 的 `.claude/rules/terraform.md`, 讓它**僅**在編輯 Terraform 時載入。
- 使用以類型為基礎的 glob, 例如 `**/*.test.tsx`, 讓測試慣例**不受資料夾影響**地套用。
- 當慣例依檔案類型橫跨整個程式碼庫時, **優先採用路徑專屬規則而非目錄 CLAUDE.md**。

正確的心智模型

問自己: 這項慣例跟著資料夾走, 還是跟著檔案模式走? 資料夾 → 目錄 CLAUDE.md。橫跨資料夾的模式 → 路徑範圍規則。無論哪種, 相對於全域 CLAUDE.md 的優勢都是**條件式載入**: 只有在規則適用時才花費 token。

常見考試陷阱

- 把測試慣例放進根目錄 CLAUDE.md(永遠載入, 即使你離測試十萬八千里)。

- 為每個資料夾各建一份目錄 CLAUDE.md,而其實單一條 `**/*.test.*` glob 規則就能全部涵蓋。
- 忘了路徑規則看的是你正在編輯哪些檔案,而非你從哪個目錄啟動。

3.4 決定何時使用規劃模式而非直接執行

關鍵知識

- **規劃模式**:適用於複雜任務——變更大、有多種可行做法、涉及架構決策。
- **直接執行**:適用於簡單、充分理解的變更(例如新增單一驗證)。
- 規劃模式可在做任何變更之前,安全地探索程式碼庫。
- **Explore 子代理**會隔離冗長的探查輸出,使其不會耗盡主上下文視窗。

為何重要

規劃深度應對應**影響範圍**。替一行修正做規劃是浪費功夫;對 45 個檔案的遷移莽撞動手,則會釀成無法回復的災難。考試測驗的是你是否依風險來調整工作流程——以及你是否知道**探查**(讀程式碼庫)該交給隔離的 Explore 子代理,讓它的輸出不會把實際工作擠掉。

關鍵技能

- 對具有架構後果的任務使用**規劃模式**(把單體拆成微服務、觸及 45 個以上檔案的遷移)。
- 對具有清楚堆疊追蹤、指向單一檔案的修正使用**直接執行**。
- 使用 **Explore 子代理**以防止多階段任務耗盡上下文視窗。
- **結合兩者**:以規劃/探查進行探查,接著以執行進行實作。

正確的心智模型

可回復性與不確定性決定選擇。高不確定性或高影響範圍 → 先規劃(並在動手前審查計畫)。低風險、完全理解的變更 → 直接執行。探查自成一個階段——把它推進 Explore,讓主上下文保持乾淨。

常見考試陷阱

- 對單一檔案的瑣碎修正使用規劃模式(有成本卻無益處)。
- 對橫掃式、多種做法的變更直接執行(沒有審查、沒有回滾方案)。
- 讓原始的程式碼庫探查輸出塞滿主上下文,而非把它隔離在 Explore 中。

flowchart TD

```
Task[進來的任務] --> Clear{原因清楚且<br/>變更侷限?}
Clear -->|是, 單一檔案| Exec[直接執行]
Clear -->|否| Big{影響範圍大<br/>或有數種做法?}
Big -->|是| Plan[規劃模式<br/>先探查再提案]
Big -->|不確定, 需讀<br/>大量程式碼| Explore[Explore 子代理<br/>隔離探查]
Explore --> Plan
Plan --> Review[動手前<br/>審查計畫]
Review --> Exec
```

3.5 透過迭代精修達成漸進式改善

關鍵知識

- 具體的輸入/輸出範例是傳達期望最有效的方式。
- 測試驅動迭代:先撰寫測試,再依失敗結果進行迭代。
- 「面談」模式:Claude 在動手寫程式之前提出釐清問題,以浮現非顯而易見的設計考量。
- 決定批次 vs 依序回饋:彼此相依的問題一次在同一則訊息中給出;彼此獨立的問題則依序給出。

為何重要

困難任務的品質來自回饋迴圈,而非單一完美提示。考試檢驗你是否優先採用範例與測試(具體、可驗證)而非含糊的敘述,以及你是否懂得組織回饋——把耦合的變更綁在一起讓模型看見其交互作用,把不相關的分開以免修正彼此衝突。

關鍵技能

- 提供 2–3 個具體的輸入/輸出範例,以釘死某項轉換的確切需求。
- 在實作之前建立測試集(預期行為、邊界案例、效能界限),再迭代到全綠。
- 使用面談模式以浮現隱藏的設計面向(快取失效、失敗模式、並行性)。
- 提供具體測試案例——範例輸入與預期輸出——尤其針對邊界案例。

正確的心智模型

以範例指定、以測試驗證、以結構化回饋迭代。範例消除歧義,測試讓「完成」變得客觀;而你如何分組回饋(相依的綁一起、獨立的分開)決定了迭代是收斂還是空轉。

常見考試陷阱

- 只用敘述描述某項轉換,而其實 2–3 個範例就能毫無歧義。
- 把多項彼此相依的修正一次一個地送出,讓模型始終看不到全貌。
- 跳過測試,僅靠肉眼檢視輸出來判斷正確性。

3.6 將 Claude Code 整合進 CI/CD 管線

關鍵知識

- `-p / --print` 旗標讓 Claude Code 以非互動(無頭)方式執行,絕不會卡住管線等待輸入。
- `--output-format json` 加上 `--json-schema` 會產生 CI 可解析的結構化輸出(例如用來張貼行內 PR 留言)。
- `CLAUDE.md` 提供由 CI 觸發的執行所需的專案上下文(測試標準、審查準則)。
- 工作階段上下文隔離:生成程式碼的同一個工作階段,在審查該程式碼時不如全新、獨立的執行個體有效。

為何重要

在 CI 中,確定性與隔離不再是錦上添花。會暫停等待輸入的無頭執行會卡死管線;未結構化的輸出無法被機器消化;而審查自己剛寫的程式碼的模型,會共享它自己的盲點。考試三者都測——旗標、結構化輸出的約定,以及獨立審查者原則。

關鍵技能

- 在 CI 中以 `-p` 執行 Claude Code, 以避免因互動式提示而卡住。
- 使用 `--output-format json + --json-schema` 取得結構化結果(行內 PR 留言、狀態檢查)。
- 在有新提交後重新執行時, 納入先前的審查結果, 僅回報新的或仍未修正的問題——別重複標記已解決的。
- 在 **CLAUDE.md** 中記錄測試標準與可用的 fixtures 以提升生成測試的品質, 並將既有測試檔案納入上下文, 讓新測試不重複且風格一致。

正確的心智模型

無頭、結構化、隔離。`-p` 讓它不阻塞; `--json-schema` 讓輸出成為一份約定; 而你藉由在審查步驟使用全新工作階段來把生成與審查分開, 因為共享上下文意味著共享盲點。

常見考試陷阱

- 在 CI 中執行互動式 Claude Code 卻不加 `-p` → 工作卡住。
- 解析自由格式文字輸出, 而非請求帶 schema 的 `--output-format json`。
- 讓生成的工作階段審查自己的程式碼(它會替自己的錯誤蓋章放行)——改用獨立執行個體。

實戰考試情境

情境。某平台團隊的 monorepo 同時放著一個 TypeScript API 與一個 Terraform 基礎設施套件。一個衝刺週期內湧入三項抱怨:

1. 新人的 Claude Code 從不遵循團隊的**測試慣例**, 儘管一位資深工程師「確實有跟 Claude 講過」。
2. 工程師想要一個全員共用、一個命令搞定的 `/review` 工作流程, 會跑完整的 lint+測試掃描——但它的輸出一直**淹沒主工作階段**, 把對話的其餘部分擠掉。
3. 他們想讓 **CI 自動審查每個 PR** 並張貼行內留言, 但第一次嘗試**卡死了管線**, 後來的嘗試又讓 **PR 本身的撰寫工作階段**去做審查, 結果**放行了它自己的 bug**。

正確的設定是什麼?

- (1) **測試慣例傳不到新人**。資深工程師把它寫進了自己的**使用者層級** `~/.claude/CLAUDE.md`——隊友看不到。由於這項慣例跟著**整個儲存庫的測試檔案類型**走, 精準的修法是一份帶有 `paths:` `["**/*.test.*"]` 的 `.claude/rules/testing.md`, 提交進 VCS。這既把它散佈給每個人, 又只在編輯測試時載入(比根目錄 `CLAUDE.md` 更省)。(§3.1、§3.3)
- (2) **共用的 `/review` 淹沒上下文**。把它做成位於 `.claude/skills/` 的**專案技能(已提交)**, 讓團隊共用, 並加上 `context: fork`, 使其冗長的 lint/測試輸出在隔離的子代理中執行, 絕不汙染主工作階段。把 `allowed-tools` 設為它所需的最小集合。(§3.2)
- (3) **CI 審查**。以 `-p` 無頭執行 Claude Code, 讓它絕不阻塞, 並輸出帶 `--json-schema` 的 `--output-format json`, 讓管線能張貼結構化的行內留言。關鍵在於, 審查必須在**全新、獨立的工作階段**中執行——而非撰寫該 PR 的那一個——因為審查自己輸出的工作階段會共享它的盲點(工作階段上下文隔離)。(§3.6)

讓答案正確的推理: 對每個症狀, 都挑出**能觸及對的對象的最窄範圍**(專案/路徑範圍, 而非使用者範圍)、**對的機制**(已提交的規則/技能, 而非口頭指示或個人設定), 並**隔離**那些否則會汙染上下文或蒙蔽審查者的東西(`context: fork`; 獨立的 CI 工作階段)。這類題目的每個陷阱選項, 都是這三者之一的反面: 範圍錯誤、機制錯誤, 或沒有隔離。

```
sequenceDiagram
    actor Dev as 開發者
    participant Repo as PR / 儲存庫
    participant CI as CI 管線
    participant CC as Claude Code (-p 無頭)
    participant Ctx as CLAUDE.md + rules
    Dev->>Repo: 開啟 pull request
    Repo->>CI: 由 PR 觸發
    CI->>CC: 執行審查, --output-format json
    CC->>Ctx: 載入專案上下文(獨立工作階段)
    Ctx-->>CC: 測試標準 + 審查準則
    CC-->>CI: 結構化發現(僅新的與未修正的)
    CI-->>Repo: 張貼行內 PR 留言
```

考試重點 — 關鍵整理

概念	考試考什麼 / 常見陷阱
CLAUDE.md 階層	挑出 正確範圍 :全團隊 → 已提交的專案檔;個人 → 使用者檔。陷阱:團隊永遠收不到的使用者層級指令(\$3.1)。
@path 與 .claude/rules /	以模組化削減上下文膨脹;用 @path 匯入標準。陷阱:一份每次執行都載入的 600 行 CLAUDE.md(\$3.1)。
路徑專屬規則	跟著 整個儲存庫某種檔案類型 走的慣例 → 帶 paths glob 的 .claude/rules/ ,條件式載入。陷阱:對橫跨性的檔案模式用目錄 CLAUDE.md(或根目錄 CLAUDE.md)(\$3.3)。
斜線命令 vs 技能的範圍	團隊工作流程 → .claude/commands/ (已提交);個人 → ~/.claude/ 。陷阱:把共用命令放進使用者目錄(\$3.2)。
context: fork	隔離冗長/探查性的技能輸出,使其不擠掉主工作階段。陷阱:省略它,然後撞上「上下文滿了」(\$3.2)。
技能的 allowed-tools	每個技能採最小權限。陷阱:對唯讀技能授予寫入/shell 權限(\$3.2)。
規劃 vs 直接執行	讓規劃深度對應 影響範圍/可回復性 。陷阱:替一行程式做規劃,或對 45 個檔案的遷移未審查就執行(\$3.4)。
Explore 子代理	隔離程式碼庫探查,使其不耗盡上下文。陷阱:把原始探查倒進主視窗(\$3.4)。
迭代精修	以 範例 指定、以 測試 驗證;相依回饋批次給、獨立回饋依序給。陷阱:含糊敘述;耦合變更一點一滴餵(\$3.5)。
無頭 CI(-p)	非互動,讓管線絕不卡住。陷阱:在 CI 中執行互動式 Claude Code(\$3.6)。
結構化輸出	--output-format json + --json-schema 取得機器可解析的結果。陷阱:刮取自由格式文字(\$3.6)。

工作階段上下文 隔離	在 全新 工作階段審查程式碼,而非寫它的那一個。陷阱:作者審查自己,替自己的 bug 蓋章 (\$3.6)。
---------------	---

對應 Domain 3(20%)。 掌握三個軸——**範圍**(使用者/專案/目錄/路徑)、**機制**(確定性設定/技能/規則 vs 軟性提示),以及**工作流程**(規劃 vs 執行、隔離探查、無頭+隔離的 CI)——本領域的情境題就只剩下挑出最窄的正確選項這件事。

領域 4:提示工程與結構化輸出(20%)

文件:[Tool use](#) | [Prompt engineering](#) | [Message Batches](#)

本領域佔考試的 20%——僅次於代理架構,是權重第二高的領域。它考驗你能否把含糊的「讓模型做 X」目標,轉化為**可靠、可供機器消費的流程**:帶明確準則的提示、把格式釘死的少樣本範例、能**保證**輸出格式正確的 `tool_use` schema、能補捉 schema 抓不到問題的驗證/重試迴圈,以及在規模上運行所需的成本/吞吐量槓桿(批次處理、多遍審查)。

考題幾乎從不問「什麼是少樣本?」它們是**診斷與設計**型題目:「模型的 JSON 有時無法解析——最可靠的單一修正是什麼?」、「重試沒能修好擷取——為什麼?」、「自我審查漏掉了一個 bug——什麼架構能找到它?」正確答案通常是那個把保證從**機率性**(提示指令)移到**結構性**(schema、獨立審查者、驗證檢查)的選項。考試反覆強調的關鍵區分是**語法 vs 語意**: `tool_use` 固定輸出的**形狀**,但 schema 完全不會讓數字正確。

```
flowchart TD
    Goal[目標 - 取得可靠的<br/>結構化輸出] --> Q1{輸出形狀<br/>一直壞掉?}
    Q1 -->|是| TU[tool_use 加 JSON Schema<br/>第 4.3 節]
    Q1 -->|格式沒問題,<br/>但判斷不一致| FS[少樣本範例<br/>第 4.2 節]
    TU --> Q2{形狀有效但<br/>值還是錯?}
    Q2 -->|是 - 語意錯誤| VR[驗證並把錯誤<br/>回饋後重試<br/>第 4.4 節]
    Q2 -->|否| Done[上線]
    Goal --> Q3{含糊準則造成<br/>誤報?}
    Q3 -->|是| EC[明確的分類準則<br/>第 4.1 節]
    VR -. 規模與成本. -> BR[批次加多遍審查<br/>第 4.5 與 4.6 節]
```

4.1 以明確準則設計提示以提升準確度

為何重要。 最快的準確度提升,幾乎從來不是更大的模型或更多範例——而是從指令中**移除模糊性**。「檢查註解準確度」逼模型自己發明「準確」的標準;「**僅**在註解與它所說明的程式碼相矛盾時才標記」則給了它一條能一致套用的決策規則。像「更保守一點」或「請用良好判斷」這類含糊修飾語是最糟的指令:它們會以不可預測且每次都不同的方式改變行為。

考試最愛的信任機制。 誤報不只是雜訊——它會**傳染**。若一個程式碼審查助理提出五個錯誤的「安全性」標記,開發者就會不再信任安全性類別,連帶開始忽略它旁邊那些準確的類別。修正之道不是「叫它更小心」;而是為何謂可回報的內容**定義明確、分類化的準則**,並在某個誤報率正在毒害信任的類別把準則收緊之前,**暫時停用該類別**。這是反覆出現的陷阱:誘人的答案(「在提示裡加上『要保守』」)是錯的;正確答案會收窄某個發現的**定義**。

關鍵知識

- 明確準則比含糊指令更有效(例如「僅在註解與程式碼相矛盾時才標記」vs「檢查註解準確度」)
- 像「更保守一點」這類泛用指引,效果不如具體的分類準則
- 誤報對開發者信任的影響:某些類別的高誤報率會破壞對準確類別的信任

關鍵技能

- 定義審查準則:應回報什麼(bug、安全性)vs 應忽略什麼(輕微風格問題)
- 暫時停用誤報率高的類別
- 為每個等級定義明確的嚴重度準則,並附上程式碼範例

4.2 使用少樣本提示以提升輸出一致性

為何重要。 少樣本(脈絡中的範例)是提升**一致性**最有效的單一槓桿——讓模型 *每次都以相同方式* 格式化、標記與決策。準則清單告訴模型 *要* 做什麼,範例則讓它看到 *好的樣子究竟長怎樣*,包括輸出形狀(位置、問題、嚴重度、建議修正)以及如何處理規則清單無法完全涵蓋的案例。

真正的威力在模糊案例。 任何人都能格式化一個乾淨的範例;高價值的少樣本是那些**邊界案例**——一個 *看起來像 bug* 的可接受程式碼模式、一個真正模糊的工具選擇、一個測試涵蓋率的缺口。展示 2–4 個這類案例 *並附上理由*,能教會模型推廣決策邊界,而不只是對顯而易見的案例做模式比對。少樣本也能**降低擷取中的幻覺**:一個示範「當欄位不存在時,回傳 null」的範例,遠比一句這麼說的指令更有力。

常見陷阱。 帶長規則清單的零樣本 vs 少樣本。當題目描述的是在**模糊輸入上格式不一致或判斷不一致**時,答案是**加入有針對性的範例**,而不是「寫更多規則」。規則是機率性的;對確切輸出的具體示範,才是穩定行為的關鍵。

```
flowchart TD
    In[要分類或擷取的<br/>新輸入] --> Amb{是乾淨、<br/>明確的案例嗎?}
    Amb -->|是| Zero[帶明確準則的<br/>零樣本就足夠]
    Amb -->|否| Few[邊界案例、<br/>對格式敏感、<br/>易幻覺]
    Few -->|加入 2 到 4 個<br/>附理由的少樣本範例| Cover[涵蓋模糊的邊界,<br/>而非顯而易見的<br/>案例]
    Cover --> Stable[一致的格式<br/>與判斷]
    Zero --> Stable
```

關鍵知識

- 少樣本範例是產生格式一致、可付諸行動的輸出最有效的方法
- 少樣本可示範如何處理模糊案例(工具選擇、測試涵蓋率的缺口)
- 少樣本協助模型推廣到新模式,而不僅是重複預設行為
- 少樣本可降低擷取任務中的幻覺

關鍵技能

- 針對模糊情境提供 2–4 個有針對性的範例並附上理由
- 納入示範輸出格式的少樣本範例(位置、問題、嚴重度、建議修正)
- 提供範例以區分可接受的程式碼模式與真正的問題

- 提供從不同結構文件中正確擷取的範例

4.3 以 `tool_use` 與 JSON Schemas 強制結構化輸出

為何重要。這是本領域的核心。如果你的程式碼必須對模型的回覆做 `json.loads()`，那麼**搭配 JSON Schema 的 `tool_use`** 是保證輸出符合結構描述、並消除 JSON 語法錯誤最可靠的方式。你定義一個工具，其 `input_schema` 就是你想拿回來的形狀，呼叫模型，然後讀取所產生 `tool_use` 區塊的 `input`——已經解析完成、符合 schema 的資料。這勝過「以 JSON 回應」式的提示，後者讓模型有空間加上「Here is the JSON:」前言或多一個逗號。

用 `tool_choice` 操控——考試最愛的旋鈕：

- `"auto"` (預設)——模型可回傳文字或呼叫工具。
- `"any"`——模型**必須**呼叫可用工具之一(由它挑選)。當存在多個擷取 schema 時，用它來**保證**結構化輸出。
- 強制——`{"type": "tool", "name": "extract_metadata"}` 釘住某個特定工具，於是你總是拿到正好那個形狀。

考試在這裡埋的兩個陷阱。(1)強制工具會停用延伸思考(extended thinking)該回合，而 `any` /強制意味模型總會呼叫某個工具——所以被強制的工具必須是可無條件呼叫的。絕不要只為了取得結構，就強制一個有副作用的工具(`send_email`、`process_payment`)；改為強制一個**擷取/格式化工具**。(2)schema 修正語法，而非語意。嚴格的 schema 保證 JSON 可解析、欄位存在；它不保證總計加得起來，或某個值落在正確欄位。那是 §4.4 的工作。

防止幻覺的 schema 設計。當來源可能不含某欄位時，把它設為**選填/可為 null**——否則 `required` 欄位會逼模型**捏造**一個值。對於分類，給列舉一個逃生口：納入 `"other"` 或 `"unclear"` 並搭配一個自由文字細節欄位，讓模型能標示非預期情況，而非硬套一個錯誤標籤。

```
sequenceDiagram
    actor App as 你的後端
    participant Cl as Claude
    App->>Cl: 文件文字加擷取工具 schema<br/>tool_choice 強制 extract_metadata
    Cl->>Cl: 讀文件，填入 schema
    Cl-->>App: tool_use 區塊 - input 是符合 schema 的 JSON
    App->>App: 直接解析 input，不對散文做 json.loads
    App->>App: schema 保證形狀，而非正確的值
```

關鍵知識

- 搭配 JSON Schemas 的 `tool_use` 是保證輸出符合結構描述並消除 JSON 語法錯誤最可靠的方式
- 在 `tool_choice: "auto"` 下模型可回傳文字；在 `"any"` 下則必須呼叫工具；強制選擇則會選定特定工具
- 嚴格的 JSON Schemas 可消除語法錯誤，但無法防止語意錯誤(總計加總不對；值放在錯誤欄位)
- 結構描述設計：必填 vs 選填欄位；列舉值加上「other」並搭配細節字串以利擴充

關鍵技能

- 以 JSON Schemas 定義擷取工具，並從 `tool_use` 結果解析資料
- 當存在多個結構描述時，使用 `tool_choice: "any"` 以保證結構化輸出

- 強制特定的工具呼叫: `tool_choice: {"type": "tool", "name": "extract_metadata"}`
- 當來源可能不含某項資訊時,將欄位設為選填/可為 null,以避免捏造值
- 使用像 `"unclear"` 與 `"other"` 這類列舉值並搭配細節欄位,以利可擴充的分類

4.4 為擷取品質實作驗證、重試與回饋迴圈

為何重要。 因為 §4.3 只修正形狀,你需要一層來補捉語意錯誤——無法對帳的總計、放錯欄位的日期、違反業務規則的值。其模式是**帶錯誤回饋的重試**:當驗證失敗時,送出一個後續請求,內含原始文件、那份**不正確的**擷取結果,以及**具體的驗證錯誤**(「`stated_total` 是 1200,但明細加總是 1180」)。具體的錯誤能引導出真正的修正;「再試一次」則不能。

區分等級的陷阱:重試無法憑空生出不存在的資料。 如果某欄位根本不存在於來源——文件從未載明稅號、該數字只存在於外部系統——那麼重試是徒勞的,只會白燒 token。考試要你**辨識**這種情況並停止重試(回傳 null / 標記交人工 / 取得外部文件),而不是不斷迴圈。重試能修正**可修正的**錯誤;它無法修補**缺失的**資訊。

為自我修正而設計。 把偵測內建進 schema:同時擷取 `calculated_total` (模型加總明細)與 `stated_total` (文件上印的數字),然後在程式碼中比對——不一致就是一個你能據以行動的對帳錯誤。同樣地,記錄觸發每個發現的 `detected_pattern`,讓你日後能分析誤報,並餵入 §4.1 收緊準則的迴圈。

flowchart TD

```
Ext[透過 tool_use 擷取] --> Val{驗證通過?<br/>總計對帳,<br/>欄位格式正確}
Val -->|是| Out[接受結果]
Val -->|否| Src{所需資訊是否<br/>存在於來源中?}
Src -->|是 - 可修正| Retry[帶文件加<br/>錯誤擷取加<br/>具體錯誤後重試]
Retry --> Ext
Src -->|否 - 來源中缺失| Stop[停止重試 -<br/>回傳 null、標記人工,<br/>或取得外部文件]
```

關鍵知識

- 帶錯誤回饋的重試:在重試提示中納入具體的驗證錯誤,以引導修正
- 當資訊根本不存在於來源中時,重試無效
- 回饋迴圈設計:追蹤觸發某個發現的模式(`detected_pattern`)
- 語意錯誤(總計無法對帳)相對於語法錯誤(由 `tool_use` 處理)

關鍵技能

- 撰寫後續提示,附上原始文件、一份不正確的擷取結果,以及具體的驗證錯誤
- 辨識何時重試將無效(所需資訊只存在於外部文件中)
- 在發現中納入 `detected_pattern` 欄位,以分析誤報
- 透過同時擷取 `calculated_total` 與 `stated_total` 來偵測差異,設計自我修正

4.5 設計高效的批次處理策略

為何重要。 一旦某個提示在單一文件上能用,規模就改變了成本結構。**Message Batches API** 提供約 50% 的成本節省,並在 24 小時視窗內處理,但不保證延遲 SLA——結果可能要幾分鐘,也可能要許多小時。決策規

則很單純,就是**阻斷式 vs 非阻斷式**:開發者在等待的合併前 CI 檢查必須是**同步**的;隔夜稽核、每週報表或大量回填,則屬於 **Batch API**。

考試考的兩個限制。 (1)**Batch API 不支援在單一請求內進行多輪工具呼叫**——每個請求都是一次自足的單發,所以需要多次工具往返的代理迴圈無法作為批次項目運行。(2) `custom_id` 將每個請求與其回應關聯(並讓你能**只重新提交失敗項**,而非整個批次)。一個典型題目會給出一個 SLA——例如「30 小時內出結果」——並要你規劃頻率:以 **4 小時視窗**提交,可讓每個項目都在 24 小時處理視窗內留有餘裕。**務必先用小樣本反覆調整提示**,事後才來除錯一個五萬份文件的批次,是學到「你的 schema 錯了」最昂貴的方式。

關鍵知識

- Message Batches API:節省 50%、最長 24 小時的處理視窗、不保證延遲 SLA
- 批次處理適用於非阻斷式任務(隔夜報表、稽核),不適用於阻斷式任務(合併前檢查)
- 批次 API 不支援在單一請求內進行多輪工具呼叫
- `custom_id` 欄位用於在批次內關聯請求與回應

關鍵技能

- 阻斷式檢查使用同步 API;隔夜/每週工作負載使用批次 API
- 依 SLA 需求規劃批次提交頻率(例如以 4 小時視窗搭配 24 小時處理,達成 30 小時保證)
- 處理失敗時只重新提交失敗的文件(以 `custom_id` 辨識)
- 在大規模處理之前,先用樣本反覆調整提示

4.6 設計多執行個體與多遍審查架構

為何重要。 一個同時生成又審查自己作品的模型有個盲點:它**保留了自身的推理上下文**,在心理上錨定於先前的決定,因此很少挑戰自己。修正之道是**架構性的,而非提示層級的**——啟動一個**不帶生成上下文的、第二個獨立 Claude 執行個體**來冷審這項變更。少了「我為何這樣寫」的合理化,獨立的審查者更擅長補捉細微問題。

多遍勝過單次巨大的一遍。 在大型、多檔案的變更上,注意力會被稀釋——模型把焦點攤得太薄,既漏掉局部 bug,也漏掉跨檔案的交互作用。把它拆開:一個處理檔案內問題的**每檔案局部遍**,加上一個推理檔案之間資料流的**跨檔案整合遍**。你也能依信心路由——一個帶**自我評定信心**的驗證遍讓你能把低信心的審查升級到更深入的分析或人工,把心力花在需要的地方。整個領域的貫穿主軸:**獨立性與分解**勝過要求單一、過載的呼叫一次把所有事都做完。

```
flowchart TD
```

```
Gen[執行個體 A 生成<br/>該變更] --> Bad[自我審查偏弱 --<br/>錨定於自身的<br/>推理上下文]
Gen --> RevA[執行個體 B 審查,<br/>不帶生成上下文]
RevA --> Local[每檔案局部遍<br/>檔案內 bug]
RevA --> Integ[跨檔案整合遍<br/>檔案間的資料流]
Local --> Conf{自我評定的<br/>信心偏低?}
Integ --> Conf
Conf -->|是| Esc[升級到更深入的<br/>遍或人工]
Conf -->|否| Accept[接受發現]
```

關鍵知識

- 自我審查的侷限:模型保留了自身的推理上下文,較不可能挑戰自己的決定
- 獨立的審查執行個體(不帶生成上下文)更擅長找出細微問題
- 多遍審查:每檔案的局部分析,加上跨檔案的整合遍,以避免注意力被稀釋

關鍵技能

- 使用第二個獨立的 Claude 執行個體,在不帶生成上下文的情況下審查變更
- 將多檔案審查拆成每檔案遍,加上整合遍,以進行跨檔案的資料流分析
- 使用帶自我評定信心的驗證遍,以校準的方式路由審查

4.7 實戰考試情境

情境。 你正在建構一個流程,匯入數千份掃描的**保險理賠表單**(OCR 成雜亂文字),且必須為每張表單輸出一筆紀錄: `claim_id`、`claimant_name`、`incident_date`、`line_items[]`、`stated_total`,以及一個 `claim_type` (`auto`、`property`、`medical` 之一,或其他)。測試中浮現三個問題:(1)模型的 JSON 偶爾無法解析;(2)在某些表單上它憑空生出一個沒印在任何地方的 `claim_id`;(3)約 8% 的表單其 `stated_total` 不等於 `line_items` 的加總。這個流程在每晚對當天進件批次運行——沒有任何人在等待某張個別表單。

推理至正確設計:

1. **解析失敗** → `tool_use`,而非「以 JSON 回應」(\$4.3)。定義一個 `extract_claim` 工具,其 `input_schema` 正好是這筆紀錄,並以 `tool_choice: {"type": "tool", "name": "extract_claim"}` 呼叫。模型現在必須回傳那個形狀,且已在 `tool_use.input` 中解析完成——JSON 語法錯誤消失。強制這個工具是安全的,因為擷取沒有副作用(\$4.3 中「絕不強制有副作用的工具」這條規則得到滿足)。
2. **憑空生出的 `claim_id`** → 可為 null 的欄位加少樣本(\$4.3 + \$4.2)。`required` 欄位會逼模型捏造。把 `claim_id` 設為可為 null,並加入一個少樣本範例,其中一張沒有可見理賠編號的表單對應到 `claim_id: null`。示範「缺失 → null」的行為,遠比一句指令可靠。
3. **總計無法對帳** → 這是語意問題,所以 `schema` 抓不到(\$4.4)。同時擷取 `calculated_total` (模型加總明細)與 `stated_total` (印出的數字);在程式碼中比對。不一致時,帶著文件、錯誤擷取結果與具體差異重試。關鍵在於,若某張表單模糊到連總計都不存在,要辨識出**重試無法憑空生出資料**——把它標記交人工,而非不斷迴圈。對於真正困難的對帳案例,一點推理會有幫助(現代模型是**自適應地**推理——見第 17 章——而非透過固定的思考預算),但要把推理軌跡與已解析的 `tool_use` 輸出分開。
4. **規模 + 無人等待** → **Message Batches API**(\$4.5)。此工作負載是非阻斷式且為每晚運行,所以將它作為批次提交,在 24 小時視窗內取得約 50% 的成本節省;為每張表單標上 `custom_id`,讓那需要對帳重試的約 8% 能**單獨重新提交**。注意,因為每個批次項目都是單發,驗證與重試迴圈是作為**第二趟**批次遍運行,而非在單一請求內進行多輪工具呼叫。
5. **想對被標記的理賠取得第二意見** → **獨立執行個體**(\$4.6)。對於路由至人工審查的理賠,一個**不帶擷取上下文的獨立 Claude 執行個體**冷審該紀錄——它比產生它的執行個體更可能捕捉到放錯的值。

一句話的考試正解鏈: 為形狀強制一個 `tool_use` 擷取工具,把不確定的欄位設為可為 null 並用少樣本示範「缺失 → null」,在程式碼中驗證語意並**僅在資料存在時**重試,透過 Batch API 取得成本效益,並對困難案例使用獨立審查者。

4.8 考試重點 — 關鍵整理

概念	考什麼 / 常見陷阱
明確準則	具體的分類規則勝過含糊修飾語;「更保守一點」是錯誤答案——應收窄某個發現的定義(\$4.1)。
誤報傳染	某類別的高誤報會侵蝕對準確類別的信任;靠收緊準則或停用該類別來修正,而非加上謹慎用語(\$4.1)。
少樣本 vs 零樣本	在模糊輸入上格式/判斷不一致 → 加入 2–4 個附理由的範例,而非更多規則;範例可降低擷取幻覺(\$4.2)。
以 <code>tool_use</code> 取得結構	保證 schema 有效輸出、消滅 JSON 語法錯誤最可靠的方式——勝過「以 JSON 回應」(\$4.3)。
<code>tool_choice</code>	<code>auto</code> 可回傳散文; <code>"any"</code> 強制呼叫某個工具;強制 <code>{"type": "tool", ...}</code> 釘住一個。強制會停用延伸思考且總會呼叫——絕不強制有副作用的工具(\$4.3)。
語法 vs 語意	schema 修正形狀,絕不修正正確性;對帳/放錯欄位的錯誤需要驗證,而非更嚴格的 schema(\$4.3 / \$4.4)。
可為 null 的欄位	當來源可能省略某欄位時,將它設為選填/可為 null,否則模型會捏造;列舉需要 <code>"other"</code> / <code>"unclear"</code> 逃生口(\$4.3)。
帶回饋的重試	把具體的驗證錯誤回饋回去;但重試無法救回來源中缺失的資訊——應停止並標記(\$4.4)。
自我修正檢查	擷取 <code>calculated_total</code> 與 <code>stated_total</code> 並在程式碼中比對,以偵測差異(\$4.4)。
Batch API	約便宜 50%、24 小時視窗、不保證延遲 SLA、每個請求不支援多輪工具呼叫;阻斷式檢查維持同步; <code>custom_id</code> 只重新提交失敗項(\$4.5)。
獨立審查	一個不帶生成上下文的第二執行個體能找出自我審查找不到的問題;將大型審查拆成每檔案 + 跨檔案遍(\$4.6)。

對應 Domain 4(20%)。 如果你能——對任何「讓輸出可靠」的問題——在明確準則、少樣本、強制 `tool_use` schema、驗證與重試迴圈、Batch API,以及獨立審查者之間做出抉擇,並且總是把語法(schema)與語意(驗證)分開,你就掌握了這個領域。

領域 5:上下文管理與可靠性(15%)

本領域涵蓋什麼。 領域 5 探討一切讓代理在時間推移與故障下仍維持正確的機制:如何編列與整理對話上下文,讓關鍵事實得以存活;當工具或子代理失敗時,系統如何優雅地降級;以及人工監督與信心校準如何攔截自動化抓不到的錯誤。它是考試中權重最小的領域(**15%**),卻橫跨其他每一個領域——一個編排完美的多代理系統(領域 1)搭配出色的提示(領域 4),只要退款金額被摘要弄丟、或搜尋逾時悄悄中止了工作流程,在正式環境照樣會失敗。

如何被測驗。 題目幾乎都是故障模式辨識:給你一個出了微妙差錯的長時間或多代理情境——某個數字漂移了、某筆引用消失了、某個代理「記得典型模式」而非具體類別、某個 97% 準確的擷取器在某一種文件類型上悄悄出錯——而你必須挑出能預防它的機制。陷阱選項是那些貌似合理卻屬機率性的做法(提高摘要品質、叫模型小心一點、信任信心自評)。正確答案幾乎都是結構性的:把事實留在摘要歷史之外、回傳結構化

的錯誤上下文、用抽樣量測錯誤而非假設它不存在。這套可靠性思維呼應領域 1 的「Hooks 對提示」原則：當正確性攸關時,把它編進架構,而非寄望模型乖乖照做。

本領域對應**第一部分第 9–12 章**(升級、多代理錯誤處理、正式環境上下文管理、出處來源)。以下六個目標保留官方考試目標;每一項都補上**為何重要**、**常見陷阱與正確心智模型**。

flowchart TD

A[領域 5
上下文與可靠性] --> B[上下文存活
5.1 與 5.4 與 5.6]

A --> C[故障處理
5.3]

A --> D[人工監督
5.2 與 5.5]

B --> B1[把事實留在
摘要之外]

C --> C1[結構化錯誤
而非籠統狀態]

D --> D1[依規則升級
而非依情緒]

D --> D2[依類型與欄位
量測準確率]

5.1 管理對話上下文以保留關鍵資訊

上下文視窗是**預算,不是檔案櫃**——一旦塞滿,較舊的回合就會被摘要或逐出,而摘要裡變模糊的東西就永遠回不來了。考試的核心洞見是**摘要恰好在最重要的地方有損**:一段文字可以乾淨地壓縮,但「依政策 R-12 於 2025-03-05 退款 \$1,247.50」會劣化成「曾發出一筆退款」。交易層級的精確度是第一個犧牲品。

題目中會出現兩種相互強化的故障模式:

- **漸進式摘要漂移**——數值、百分比、ID 與日期被四捨五入成散文。代理之後會**自信地答錯**,因為它對該事實的唯一記憶就是那段有損摘要。
- **迷失在中間**——即使事實仍逐字留在上下文中,模型最可靠地關注的是長輸入的**開頭與結尾**。埋在 40 筆工具結果中間的某個發現,實際上等於隱形。

還有第三個較不顯眼的問題:**工具輸出膨脹**。模型只需要 5 個欄位,工具卻回傳 40 個;無關的 35 個擠佔預算並稀釋注意力。冗長並非免費——它以 token 與召回率兩種代價支付。

關鍵知識

- 漸進式摘要的風險:數值、百分比與日期會被濃縮成模糊的摘要。
- 迷失在中間效應:模型能可靠處理長輸入的開頭與結尾,但可能漏掉中間的發現。
- 工具輸出在上下文中累積的比例可能與其相關性不成正比(需要 5 個欄位時卻有 40 多個)。
- 在後續 API 請求中傳送**完整對話歷史**的重要性(API 是無狀態的——模型只知道你重新傳送的內容)。

關鍵技能

- 將交易事實擷取到一個持久的「**案件事實**」區塊,讓它存活於摘要歷史之外並每輪逐字重新注入,如此便永遠不會被 compact 掉。
- 將冗長的工具輸出修剪到只剩相關欄位(`PostToolUse` hook 是做這件事的確定性位置)。
- 將關鍵發現放在彙整資料的**開頭**,並加上明確的章節標題,以擊敗迷失在中間。
- 要求子代理在**結構化**輸出(而非散文)中納入中繼資料(日期、來源、ID)。

正確心智模型: 任何**必須**存活的東西——金錢、ID、日期、決策——都不該待在可能被摘要的對話流程裡。它屬於一個耐久、會被重新注入的事實區塊。****常見陷阱:***「改進摘要提示」。更好的摘要仍是機率性、仍然有損;修正之道是讓事實在摘要構不到的地方*,而非更仔細地摘要它。

5.2 設計有效的升級模式並解決不明確性

升級是代理的**斷路器**:決定停止行動並交接給真人。考試測驗 *什麼才能正當地觸發它*,而同樣常見的是**什麼會錯誤地誘使你以錯誤訊號去觸發(或不觸發)**。

升級有兩種時機,而把它們混為一談是經典的錯誤答案:

- **立即升級**——客戶 *明確要求真人*,或要求政策 *禁止* 的事項。立刻行動;**不要**先調查。在尊重一個明確的真人請求之前,花三次工具呼叫「試著幫忙」是錯誤的行為。
- **先嘗試解決,再升級**——請求落在代理職權範圍內;代理先處理,只有在無法取得進展、或政策未著墨/不明確時才升級。

```
flowchart TD
    R[傳入的請求] --> Q1{明確要求<br/>真人?}
    Q1 -->|是| E1[立即升級<br/>不做調查]
    Q1 -->|否| Q2{政策涵蓋<br/>此案?}
    Q2 -->|否,未著墨或例外| E
    Q2 -->|是| Q3{代理能取得<br/>進展?}
    Q3 -->|否| E
    Q3 -->|是| W[在範圍內解決]
    Q2 -->|比對到多筆客戶| ASK[要求另一個<br/>識別資訊]
    ASK --> R
```

關鍵知識

- 合適的升級觸發條件:明確要求真人、政策缺口/例外、無法取得進展。
- 立即升級(明確要求)相對於嘗試解決(在代理職權範圍內)。
- **情緒分析與模型信心自我評定,都不是案件複雜度的可靠替代指標**——憤怒的客戶可能只是個簡單請求,而冷靜的客戶卻可能是違反政策的邊緣案例。模型的「我有 95% 把握」並非經過校準的真相。
- 比對到多筆客戶時應要求額外的識別資訊,**而非**以啟發法猜測(挑「最近的那筆」可能會對錯誤的人的帳戶採取行動)。

關鍵技能

- 在系統提示中以**少樣本範例**列出明確的升級準則(向模型展示具體的升級/解決配對)。
- **立即執行**明確要求真人的請求,不做額外調查。
- 當政策對特定請求不明確或未著墨時,進行升級。
- 當工具結果包含多筆比對時,要求額外的識別資訊。

正確心智模型: 升級準則應該是**客觀且以規則為基礎**(明確要求、政策未著墨、無進展),而非**情感取向**(語氣、氛圍、自我信心)。**常見陷阱:**「當客戶看起來受挫時升級」或「當模型信心 < 0.8 時升級」。兩者都以不可靠的替代指標取代了真正的政策條件。

5.3 在多代理系統中實作錯誤傳播策略

當子代理的工具失敗時,協調者能復原得多好,取決於它收到的資訊。這裡最重要的一個觀念是:**失敗是一種資料,而它的形態決定了復原品質**。籠統的 `"search unavailable"` 沒給協調者任何可行動的線索;結構化的錯誤則精確告訴它該如何反應。

考試在兩個事件之間畫出一條清楚的界線,而粗糙的設計會把它們混為一談:

- **存取失敗**——逾時、5xx 或速率限制。該操作在重試時*可能*成功。這值得做一次**重試決策**。
- **有效的空結果**——查詢執行了,而且確實沒比對到任何東西。重試沒有意義;答案就是「無」。

把兩者都歸結成「沒有結果」,會讓協調者永無止境地重試空查詢,或更糟,把一次暫時性中斷當成已確認的否定結果。

flowchart TD

T[子代理執行工具] --> Q{結果如何?}

Q -->|逾時或 5xx| AF[存取失敗]

Q -->|執行了,無比對| EV[有效的空結果]

Q -->|執行了,有資料| OK[回傳結果]

AF --> LR{暫時性且
可重試?}

LR -->|是| RETRY[在子代理內
局部重試]

LR -->|否| PROP[傳播結構化錯誤
類型, 查詢, 部分, 替代方案]

EV --> RES[回傳空
不要重試]

RETRY --> OK

PROP --> CO[協調者決定復原]

關鍵知識

- **結構化的錯誤上下文**(失敗類型、嘗試的查詢、部分結果、替代方案)能讓協調者比一個光禿禿的狀態字串更聰明地復原。
- 區分**存取失敗**(逾時 → 一次重試決策)與**有效的空結果**(無相符 → 一個最終答案)。
- 籠統的錯誤狀態(「搜尋無法使用」)會對協調者隱藏有價值的上下文。
- 在單一失敗時**靜默抑制**,以及**中止整個工作流程**,兩者都是反模式——一個藏起問題,另一個則對它反應過度。

關鍵技能

- 回傳結構化的錯誤上下文:失敗類型、嘗試了什麼、部分結果、可能的替代方案。
- 區分存取失敗與有效的空結果。
- 在子代理內對暫時性失敗進行**局部復原**;只將**不可復原的錯誤向上傳播**,並附上任何部分結果,讓協調者仍能繼續推進。
- 在綜整時標註涵蓋範圍:哪些有充分佐證、哪些仍有缺口(不要把部分答案當成完整的呈現)。

正確心智模型: 目標是**優雅降級**——能局部復原就局部復原,不能時就傳播**豐富的**錯誤,讓協調者帶著部分資料做出知情的決策。**常見陷阱:** 兩個極端——捕捉例外並回傳 `[]` (靜默抑制),或讓單一子代理的逾時搞垮整個研究流程(過度中止)。考試可靠地獎勵中間做法:結構化傳播加上部分結果。

5.4 調查大型程式碼庫時的高效上下文管理

長時間的自主調查——稽核大型程式碼庫、跨數十個檔案追蹤一個 bug——正是上下文管理變成存活問題的地方。隨著工作階段增長,模型會出現**上下文劣化**:答案變得不那麼具體,開始用「典型模式」或「通常你會看到.....」來打太極,而非指名實際的類別或行號,而較早的精確發現也變得模糊。這與 5.1 是同一種摘要漂移,只是在數小時的長跑中持續發生。

防禦手段是架構性的,而且可以彼此組合:

flowchart TD

```
M[主協調者<br/>持有計畫] --> SP[暫存檔<br/>持久的發現]
M -->|為一個問題生成| SA1[子代理 A<br/>冗長探索]
M -->|為一個問題生成| SA2[子代理 B<br/>冗長探索]
SA1 -- 精簡結果 --> M
SA2 -- 精簡結果 --> M
M --> CMP[上下文塞滿時<br/>執行 compact]
SP -- 重新讀取發現 --> M
M --> MAN[狀態 manifest<br/>支援當機恢復]
```

- **子代理隔離**——把冗長的探索(grep 傾印、檔案讀取)推進子代理,只回傳精煉後的答案;龐大的輸出永遠不會污染協調者的視窗。這與領域 1 的中心輻射式隔離相同,在此用於上下文衛生。
- **暫存檔**——把關鍵發現寫進一個代理能跨上下文邊界重新讀取的檔案,讓第一小時的某個發現存活到第三小時,即使當時在上下文中的回合早已消失。
- **生成前先摘要**——在啟動下一階段之前,把目前狀態精煉成一份簡報,讓每個子代理都從一個乾淨、準確的基準起步。
- **** /compact ****——在長時間調查期間主動壓縮視窗以爭取空間,趁劣化尚未發生之前。
- **狀態持久化**——一份結構化的進度與發現 manifest,讓系統能在當機後恢復,而非重新開始。

關鍵知識

- 長工作階段中的上下文劣化:模型開始產生不穩定的答案,並提到「典型模式」而非具體類別。
- 暫存檔(scratchpad)可跨上下文邊界保留關鍵發現。
- 委派給子代理可隔離冗長的探索輸出。
- 結構化的狀態持久化能在當機後復原。

關鍵技能

- 為特定問題生成子代理,同時在主代理中保留高層級的協調。
- 使用暫存檔(scratchpad)儲存關鍵發現並於稍後參照。
- 在生成下一階段子代理之前,先摘要關鍵發現。
- 在長時間調查期間使用 **/compact** 以降低上下文用量。

正確心智模型: 把主代理的視窗視為稀缺、且只承載協調職責;把龐雜的內容卸載到子代理、把持久性卸載到檔案。****常見陷阱:****「只要用更大的上下文視窗就好」。更大的視窗會延後劣化,卻無法預防它——迷失在中間與漂移在規模下依然存在——而且它對當機恢復毫無幫助。把狀態外部化;不要只是買更多上下文。

5.5 設計具備人工監督與信心校準的工作流程

當代理把一個高量的任務自動化(例如從文件擷取欄位)時,危險的問題不是「整體準確率是多少?」而是「**它在哪裡出錯,而我們有沒有抓到?**」那個頭條數字是個陷阱。

核心洞見:彙總指標會藏起自己的分佈。一條整體 97% 準確的管線,可能在發票上是 99.5%、在手寫表單上是 71%——而如果手寫表單正是那具有法律重要性的 3%,那 97% 就危險地誤導人。更糟的是,錯誤可能集中在某一個欄位(日期解析錯誤),即使文件層級的數字看起來沒問題。

flowchart TD

```
EX[擷取管線] --> AGG[整體 97 percent<br/>看起來安全]
AGG --> STR{依類型與欄位<br/>分層}
STR --> T1[發票<br/>99 percent]
STR --> T2[手寫<br/>71 percent]
STR --> T3[日期欄位<br/>跨所有類型]
T2 --> ROUTE[將低信心<br/>路由至人工審查]
T3 --> ROUTE
ROUTE --> CAL[以已標註資料<br/>校準門檻]
CAL --> AUTO[只在量測安全處<br/>自動接受]
```

關鍵知識

- 彙總指標(例如 97% 的整體準確率)可能掩蓋在特定文件類型或欄位上的不佳表現。
- **分層隨機抽樣**可衡量高信心擷取結果的錯誤率(讓你發現「有信心」何時仍代表「答錯」)。
- 使用**已標註的驗證集**進行欄位層級的信心校準(信心分數唯有對應到已量測的準確率後才有意義)。
- 在自動化之前,依文件類型與依欄位驗證準確率。

關鍵技能

- 實作分層隨機抽樣以偵測新的錯誤模式(別只是均勻抽樣——在每個分層內抽樣)。
- 依文件類型與欄位分析準確率,以確認表現處處穩定,而非只是平均上穩定。
- 輸出欄位層級的信心分數,並**使用已標註的資料校準審查門檻**,讓自動接受的切點反映真實準確率。
- 將低信心或來源不明確的擷取結果路由至人工審查。

正確心智模型: 信心必須**對照真實標準(ground truth)校準**,而準確率必須**分層**後,任何門檻才值得信任。人工審查鎖定那些量測顯示自動化不安全的分層與欄位。****常見陷阱:** 「模型有 95% 信心,所以自動接受」——未校準的自評不是錯誤率。修正之道是用已標註資料量測*每個分層的錯誤率,再從該量測設定切點。**

5.6 在多來源綜整中保留出處來源並處理不確定性

當協調者綜整來自多個來源的發現時,報告唯有在每個主張都能追溯回它的出處時才可信。出處來源——**主張 → 來源**的對應——很脆弱:它正是那種會被摘要壓平的結構化細節。一次 compaction 之後,「Acme 成長 12%(Q3 10-K,第 4 頁)」變成「Acme 成長 12%」,而那筆引用便無從還原。

兩個綜整風險主導了題目:

- **衝突的值**——兩個來源回報不同的數字。錯誤的做法是默默挑一個。正確的做法是**連同出處保留兩者**,並把衝突浮現出來以供調和。
- **由時間造成的假矛盾**——兩個「衝突」的數字可能只是來自不同日期(2023 年的估計值對 2024 年的實際值)。少了**發布/收集日期**,協調者就會把一個時間差異誤讀成歧異。

```
sequenceDiagram
    actor U as 使用者
    participant Co as 協調者
    participant S1 as 來源代理 A
    participant S2 as 來源代理 B
    U->>Co: 綜整市場數字
    S1-->>Co: 主張加來源加日期 A
    S2-->>Co: 主張加來源加日期 B
    Co->>Co: 值不同, 比較日期
    Co->>Co: 不同期間, 並非衝突
    Co-->>U: 帶引用與標日期數值的報告
```

關鍵知識

- 在摘要過程中,除非明確保留「主張 → 來源」對應,否則出處標註便會遺失。
- 結構化的對應關係必須撐過彙整步驟(把它們留在摘要歷史之外,如 5.1 所述)。
- 處理衝突的統計數據時,應以出處標註來註記衝突,而非任意選擇某一個值。
- 納入發布/收集日期,以避免將時間差異誤讀為矛盾。

關鍵技能

- 要求子代理輸出「主張 → 來源」對應(URL、文件名稱、引文)作為結構化資料。
- 將報告結構化,以區分穩定的發現與有爭議的發現。
- 保留衝突的值並加上註記,再傳遞給協調者進行調和(不要在子代理裡默默解決)。
- 納入發布日期以利正確的時間解讀。
- 依類型呈現內容:財務資料以表格呈現、新聞以散文呈現、技術發現以結構化清單呈現。

正確心智模型: 綜整管線必須讓主張、來源與日期一起端到端地傳遞,並把衝突視為要回報的東西,而非默默解決的東西。**常見陷阱:** 對衝突的數字取平均或任意挑選——那會丟棄使用者判斷資料所需的那個訊號(歧異本身,或日期落差)。

Worked Exam Scenario(實戰考題情境)

情境。 你營運一個長時間運行的「財務文件分析師」代理。每個工作階段會攝入一份 60 頁的季度申報文件外加幾篇新聞文章,然後跨多個回合回答分析師的問題。正式環境出現三個問題:

- 到了第 30 回合,代理把關於 Q3 營收的問題答成「約 12 億」——但申報文件寫的是 **\$1,247M**。這個精確數字在第 8 回合時還是對的。
- 它的某個來源工具(新聞 API)間歇性逾時;在那些回合裡,代理回報「沒有相關新聞」,而分析師便假定真的沒有。
- 同一份 12 頁的風險因子附錄在每個工作階段都被重新讀取,而每 token 的成本正在攀升。

哪一組修正才正確?

- (A) 把上下文視窗加大到最大,並在系統提示裡告訴代理「永遠保留確切數字,且絕不漏掉新聞錯誤」。
- (B) 擷取一個耐久的**案件事實區塊**(確切數字,連同來源與頁碼,每輪逐字重新注入);讓新聞工具回傳**結構化錯誤**(`type=timeout`),好讓協調者區分逾時與真正的空結果,並能重試/註記;並對靜態的風險因子附錄做 **prompt-cache**,讓重複讀取以零頭成本計費。

- (C) 調低 temperature 並在提示加上「要精確」;把新聞工具包進一個出錯時回傳 `[]` 的 try/except;把附錄摘要一次並倚賴該摘要。
- (D) 把每個營收問題都升級給真人,並停用新聞工具。

推理。 每個症狀都對應到一個領域 5 機制,而只有 **(B)** 對三者都採用了**結構性修正**:

- **症狀 1** 是漸進式摘要漂移(5.1)。更大的視窗(A)或一句「要精確」指令(C)都是機率性、且仍然有損;唯一可靠的修正是把確切數字留在**摘要歷史之外**的一個重新注入事實區塊裡。
- **症狀 2** 是存取失敗對空結果的混淆(5.3)。逾時時回傳 `[]` (C)就是**靜默抑制**——正是那個反模式。一個**結構化錯誤**讓協調者得以重試或註記「新聞涵蓋未經查證」,保住優雅降級。
- **症狀 3** 是一個用對靜態附錄做 **prompt caching** 來解決的成本問題(穩定、重複的前綴是典型的快取案例);把它摘要(C)會在你本想逐字保留的內容上重新引入漂移。
- (A) 與 (D) 是過度修正的陷阱:更大的視窗會延後但無法預防漂移,而全面升級/停用則是丟棄了能運作的自動化,而非優雅地降級。

正確答案:(B)。 它是那個對每一個症狀都選擇**以架構取代寄望**的選項——耐久事實、結構化錯誤與快取——也正是整個領域反覆出現的主題。

Exam Focus — Key Takeaways(考試重點 — 關鍵整理)

概念	考試考什麼 / 常見陷阱
摘要漂移(5.1)	確切數字/ID/日期被有損摘要弄丟。陷阱:「寫一個更好的摘要提示」。修正:把事實留在摘要歷史之外、一個耐久且重新注入的 案件事實區塊 裡。
迷失在中間(5.1)	模型關注開頭與結尾,而非中間。修正:把關鍵發現放 最前面 並加標題;把冗長工具輸出修剪到所需欄位。
無狀態 API(5.1)	模型只知道你重新傳送的內容——每次請求都送 完整歷史 。
升級時機(5.2)	明確要求真人或政策禁止 → 立即升級 ,不做調查。範圍內 → 先嘗試,卡住再升級。
不可靠的觸發條件(5.2)	陷阱:依 情緒 或 模型自我信心 升級。改用客觀規則(明確要求、政策未著墨、無進展);多筆比對時要求識別資訊。
錯誤形態(5.3)	回傳 結構化錯誤 上下文(類型、查詢、部分、替代方案),而非「搜尋無法使用」。區分 存取失敗(重試) 與 有效的空結果(最終) 。
優雅降級(5.3)	陷阱:兩個極端——靜默 <code>[]</code> 抑制對中止整個流程。局部復原;將不可復原的錯誤連同 部分結果 向上傳播。
上下文劣化(5.4)	長工作階段漂移到「典型模式」。修正:用子代理隔離冗長工作、 暫存檔 、生成前先摘要、 <code>/compact</code> 、狀態 manifest。陷阱:「只要用更大的視窗」。
隱藏的錯誤分佈(5.5)	陷阱:信任 彙總 準確率。依文件類型與欄位 分層 ;未校準的信心分數不是錯誤率。
信心校準(5.5)	以 已標註資料 校準門檻;把低信心/不明確案例路由至人工審查。
出處遺失(5.6)	「主張 → 來源」對應在摘要時被壓平。把它們當結構化資料貫穿彙整保留;帶上 日期 以避免假的時間矛盾。

對應 Domain 5(15%)。貫穿全部六個目標的統一規則,呼應領域 1 的「Hooks 對提示」原則:當正確性必須撐過時間與故障時,把它**結構性地**編碼——耐久事實、結構化錯誤、校準門檻、保留出處——絕不寄望模型一直保持小心。

第三部分:現代 Agent 工程(超出基礎考綱)

範圍說明: 本部分涵蓋 Anthropic 2026 年建構穩健代理的現代工程實務 —— **Workflows vs Agents、agent harness、loop engineering**。這些主題**超出官方 Foundations 考綱**,放在這裡是為了更完整地掌握 Claude,而非保證會考。每章都附 Anthropic 原始出處。

第 14 章:Workflows vs Agents(工作流 vs 代理)

進階 —— 超出官方考綱。來源:[Anthropic — Building Effective Agents](#)。

在正式環境的代理工程中,最關鍵的架構決策,說起來卻最簡單:**流程由誰控制 —— 你的程式碼,還是模型?** Anthropic 把兩個答案清楚劃開,而部署系統裡幾乎每一個可靠性、成本與延遲問題,都能追溯到選錯了其中一邊。

- **Workflow(工作流)** —— 「以**預先定義的程式碼路徑**來編排 LLM 與工具的系統。」流程由**你**控制。步驟順序在設計時就固定;模型只在每一步填入智慧。
- **Agent(代理)** —— 「LLM **自行動態主導其流程**與工具使用、掌控如何完成任務的系統。」流程由**模型**控制。它自己決定下一步做什麼、以什麼順序、以及何時算完成。

本章是**超出 Foundations 考綱的進階內容**,但它直接落在 Domain 1(代理架構,27%)之下:考試裡的協調者/子代理模式,就是其中一種特定的 workflow(orchestrator-workers);而第 3 章的代理迴圈,則是同一條光譜上的 *agent* 那一端。知道一個設計落在「控制 vs 彈性」這條軸的哪裡,正是讓你能**捍衛**一個架構,而不只是把它**組裝**出來的關鍵。

讀完你應能:

- 把任何設計放上「**控制 vs 彈性**」光譜(§14.1),並說清楚你買到的是什麼權衡。
- 在**五種 workflow 模式**間做選擇(§14.2),並知道每一種的失效模式。
- 在動用 agent 前**套用四問測試**(§14.3)。
- 投資於 **agent-computer interface**(§14.4)—— 可靠性其實是在這裡贏得的。
- 從頭到尾**建構一個回饋分流系統**(§14.5):它一開始是 workflow,只把恰好一個階段升級成 agent —— 並知道為什麼。

14.1 「控制 vs 彈性」光譜

「Workflow」與「Agent」不是非此即彼,而是一條連續光譜的兩端。從左往右移動,你得到彈性(系統能處理你從未預料的輸入),卻失去可預測性(你再也無法列舉它會做什麼)。

flowchart TD

```
A[單次 LLM 呼叫<br/>控制最強、彈性最低] --> B[Workflow<br/>預先定義的程式碼路徑]
B --> C[Agent<br/>模型自行主導步驟]
C --> D[多代理系統<br/>彈性最高、可預測性最低]
A -. 加入你能列舉的步驟 .-> B
B -. 你無法列舉的步驟 .-> C
C -. 平行自主工人 .-> D
```

黃金法則:從簡單開始,被逼到不得已才往右走。 用能通過你評測的最簡單做法——通常是單次、工具配置良好的 LLM 呼叫,有時是一個 workflow。每往右一步都是刻意的購買:你以延遲、token 與可除錯性為代價,換取處理開放式問題的能力。

為何這在正式環境很重要。 光譜右端的代價並非理論:

- **錯誤滾雪球。** 在 workflow 裡,壞掉的一步會被框住——下一步是固定的程式碼,能驗證並否決它。在 agent 裡,早期一個走錯的轉折,會變成模型在之後每一步推理所依據的上下文,於是一個錯誤悄悄地把整條軌跡帶偏。
- **成本與延遲倍增。** 同一個輸入,agent 可能走 3 步,也可能走 30 步;你無法像對一條固定 4 次呼叫的鏈那樣,去編列 token 預算或 p99 延遲。
- **可除錯性崩潰。** 「它為什麼這麼做?」在 workflow 裡有程式碼可回答,在 agent 裡則是「回去重讀 40k token 的模型推理」。

決定性的問題:你能列舉步驟嗎? 如果你能把順序寫下來(「先分類,再摘要,再草擬回覆」),就建 workflow——它會更便宜、更快、更可靠。把 agent 留給**無法預測步驟數、無法寫死路徑,但仍能驗證進度的開放式問題**。最後這個但書沒有商量餘地:一個你無法驗證的 agent,就是一個你無法信任的 agent。

14.2 五種 workflow 模式

大多數「我需要一個 agent」的直覺,其實只是五種 workflow 模式之一的偽裝。每一種都由 **預先定義的程式碼路徑** 加上 LLM 呼叫組成,且各有一個你必須設計去防範的典型失效模式。

1. Prompt chaining(提示串接)——把任務拆成固定順序的步驟;每次呼叫處理上一步輸出,且**步驟之間有程式化檢查(gate)**。

flowchart TD

```
In[輸入] --> S1[LLM 呼叫 1<br/>擷取]
S1 --> G{Gate<br/>schema 合法?}
G -->|失敗| Fix[修復或拒絕]
G -->|通過| S2[LLM 呼叫 2<br/>轉換]
S2 --> S3[LLM 呼叫 3<br/>格式化]
S3 --> Out[輸出]
```

- **何時使用:**任務能乾淨地分解為有序子任務,且你能驗證每一次交接。
- **失效模式:**省略 gate。整個重點就在於呼叫之間的程式碼,要在壞掉的一步毒害下一步之前攔住它。沒有 gate 的鏈,只是一個慢版的單次呼叫。

2. Routing(路由)——將輸入分類後,送往專門的處理器。這是關注點分離:每個處理器拿到聚焦的提示與工具集,而不是一個臃腫、什麼都做的提示。

- *何時使用*:輸入落在各自值得不同處理的明確類別(帳務 vs 技術 vs 退款)。
- *失效模式*:分類器太弱。路由的好壞完全取決於分類器,誤路由是看不見的失敗。讓類別數量少且互斥,並把路由準確率當成獨立的評測來量測。

3. Parallelization(平行化) —— 同時跑子任務,有兩種風味:

- **Sectioning(切塊)** —— 把一個任務的獨立部分拆開並行跑(例如同時檢查一份文件的 PII、語氣與政策),再合併。
- **Voting(投票)** —— 把同一個任務跑多次再彙整(多數決,或「任一次判定為不安全就標記」),以提高判斷題的可靠度。
- *失效模式*:在各部分其實彼此相依時卻用 sectioning,或在沒有明確彙整規則下用 voting。

4. Orchestrator-workers(協調者—工人) —— 中央 LLM 動態拆解任務、委派給工人 LLM,再綜整其結果。 這就是 Domain 1(第 3 章)的協調者/子代理模式。 它與平行化不同之處在於:子任務事先並不知道 —— 由協調者在執行時才決定。

- *何時使用*:你無法事先決定如何切分工作(例如「修這個 bug」可能動到一個檔案,也可能動到七個)。
- *失效模式*:忘了工人擁有隔離的上下文 —— 協調者必須在提示中把每個工人所需的一切都傳進去(第 3 章 §3.4)。

5. Evaluator-optimizer(評估者—優化者) —— 一個 LLM 生成,第二個依明確標準評估並回傳回饋,第一個再修訂,如此成迴圈。這是第 16 章(loop engineering)的引擎。

```

flowchart TD
    Task[任務] --> Gen[生成者 LLM<br/>產出草稿]
    Gen --> Ev[評估者 LLM<br/>對照標準檢查]
    Ev --> D{符合標準?}
    D -->|否, 附回饋| Gen
    D -->|是| Done[接受輸出]
    D -. 用盡預算 .-> Esc[升級給人]
  
```

- *何時使用*:你有**明確、可檢核的成功標準**,且品質會隨迭代明顯提升(翻譯、必須通過測試的程式碼、對照評分表的草稿)。
- *失效模式*:生成者與評估者共用同一個模型與上下文,於是評估者替自己的推理蓋章背書。讓評估者的上下文保持獨立(第 16 章)。

留意 routing/parallelization 的位置: 模式 1–3 與 5 都有**固定結構** —— 它們牢牢是 workflow。模式 4(orchestrator-workers)是橋樑:它的控制流由模型在執行時決定,這在精神上已經是 agentic 了。

14.3 你該建 agent 嗎?四問測試

在光譜上往右移之前,每一個「是」都是必要條件。只要有一個「否」,就停在更簡單的層級。

問題	它在檢查什麼	若為「否」
複雜度	任務是否真的多步驟、且難以用程式碼完整規格化?	workflow(或單次呼叫)更簡單也更可靠。

價值	結果是否值得 agent 帶來的額外延遲與 token 成本？	經濟上不划算去自主;維持簡單。
可行性	以現有工具,Claude 是否真的勝任此任務？	任何架構都救不了模型做不到的任務。
錯誤代價	錯誤是否 可被捕捉與復原 —— 測試、審查、回滾、人工關卡？	自主是不安全的;在迴圈裡保留人或確定性關卡。

第四個問題,正是團隊會略過、之後又後悔的那一個。Agent 的價值來自無人監督下行動,所以**一個錯誤動作的代價,決定了你能授予多少自主的上限**。一個錯誤會被測試與程式碼審查抓到的編碼代理,可以高度自主;一個會動錢或寄信給客戶的代理則不行 —— 在那裡,無論模型多強,你都要保留第 3 章與 Domain 5 的確定性 hooks 與人工關卡。

14.4 投資於 agent-computer interface(ACI)

一旦你真的要建 agent,最高槓桿的工作**不是**花俏的提示 —— 而是模型與其工具之間的介面。Anthropic 的指引是:為打造良好的 agent-computer interface(ACI)投入「與面向人類的 UI 同等的心力」。

實務上,ACI 就是你的**工具定義**:

- **清楚的描述** —— 明確說出工具做什麼、何時該用、何時不該用。
- **明確的參數** —— 為每個欄位命名與定型,讓呼叫方式只有一個顯而易見的做法;絕對路徑優於相對路徑、enum 優於自由文字。
- **用法範例與邊界案例** —— 展示一次正確呼叫,並記載邊界上會發生什麼。
- **測試** —— 用模型實際操作工具,觀察它在哪裡誤呼叫;去修描述,而不是修提示。

為何在現代 Claude 上這勝過提示: 模型在推理上本就很強;它無法從中恢復的,是它**誤解**的工具。模糊的 schema 會產生畸形的呼叫,任何系統提示都無法可靠地修好。**工具描述與結構描述,正是贏得可靠性的所在** —— 這是考試工具設計領域(Domain 2)的正式環境版本,也是為何第 15 章的 harness 把工具品質當成一等公民。

14.5 端到端案例研究:客戶回饋分流系統

光譜唯有在你拿它來建造時才會變得真實。以下是一個處理進站客戶回饋(支援工單、應用商店評論、問卷自由填答)的系統 —— 而最有啟發的部分在於:它**大部分是 workflow,只有恰好一個階段被升級成 agent**,因為那是唯一一個你無法列舉步驟的階段。

需求

- 從多個來源高量(每天數千筆)接收自由文字回饋 —— 所以**每筆的成本與延遲都很重要**。
- **分類**每一筆(bug、功能請求、帳務、讚美、流失風險)並**路由**到正確的下游佇列。
- 對 bug 回報,產出一筆**結構化、去重**的紀錄(元件、嚴重度、重現步驟)供工程追蹤系統使用。
- 對一小部分 —— **模糊、多重議題或被升級**的項目 —— 做開放式調查:拉出該客戶的歷史、搜尋過往工單與文件,並決定要合併、升級,還是草擬回覆。**這裡的步驟無法事先列舉**。
- 任何會草擬面向客戶回覆的動作,在送出前都必須通過**人工關卡**(錯誤代價高)。

架構:帶一個 agentic 階段的 workflow

```
flowchart TD
    In[回饋項目] --> R{Router<br/>分類類別}
    R -->|讚美| Log[記錄並致謝<br/>單次呼叫]
    R -->|功能| Track[加入產品藍圖<br/>提示串接]
    R -->|bug| Chain[Bug 鏈<br/>擷取然後去重然後格式化]
    Chain --> Gate{Schema gate<br/>紀錄合法?}
    Gate -->|失敗| Repair[修復或排入人工]
    Gate -->|通過| Tracker[寫入工程追蹤系統]
    R -->|模糊或升級| Agent[調查 agent<br/>代理迴圈]
    Agent --> HG{人工關卡<br/>回覆已核准?}
    HG -->|是| Send[送出回覆]
    HG -->|否| Human[由人處理]
```

router(模式 2)與 bug 鏈(模式 1,帶 schema gate)是純 workflow —— 固定路徑、便宜、可除錯,且承擔了大部分的量。只有**模糊/升級分支**會變成 agent,因為在那裡你確實無法事先把步驟寫成腳本:它可能需要一次查詢,也可能六次,順序還取決於它查到什麼。

為何這樣切分是對的(套用四問測試)

- **讚美 / 功能 / bug** 沒通過**複雜度**測試 —— 它們的步驟可列舉,所以維持 workflow。硬把它們塞進 agent,會燒掉 10 倍 token 去做一件鏈本來就能確定性完成的事。
- **模糊分支四問全過**: 複雜(步驟不可預測)、有價值(這些正是昂貴的案例)、可行(Claude 有對的工具就能調查),且**唯有因為送出任何回覆前有人工關卡,錯誤才可復原**。

執行軌跡:一個從 workflow 升級到 agent 的項目

```
sequenceDiagram
    actor U as 客戶
    participant R as Router workflow
    participant A as 調查 agent
    participant T as 工具 歷史加搜尋
    participant H as 人工審查者
    U->>R: 「App 一直把我登出, 而且我被重複扣款」
    R->>R: 分類, 偵測到兩個議題, 標記為模糊
    R->>A: 連同完整文字加客戶 id 交接
    A->>T: lookup_customer_history(id)
    T-->>A: 3 筆過往登出工單, 1 件未結帳務爭議
    A->>T: search_tickets("double charge")
    T-->>A: 已知帳務 bug, 修復週五上線
    A->>H: 草擬回覆加合併進 BUG-417, 升級帳務
    H-->>U: 核准後送出回覆
```

router 無法處理這個項目 —— 它一次有兩個議題,而正確的下一步取決於歷史查詢回傳了什麼。那種不可預測性,正是從 workflow 跨入 agent 的訊號。注意 agent 仍然以一個**人工關卡**收尾,滿足錯誤代價這一點。

實作草圖

router 是對一個分類結果做確定性派發 —— **不是 agent**:

```
def triage(item):
    category = classify(item) # 一次 LLM 呼叫,回傳一個 enum
    if category == "bug":
        return bug_chain(item) # 提示串接 + schema gate
    if category in ("praise", "feature"):
        return simple_handler(category, item)
    return investigation_agent.run(item) # 只有這個分支是 agentic
```

bug 鏈是一個步驟之間帶硬性 gate 的 workflow —— 保證紀錄合法的是那個 gate,不是提示:

```
def bug_chain(item):
    extracted = llm_extract(item) # 元件、嚴重度、重現步驟
    if not schema_valid(extracted): # 程式化 gate,不是模型自我檢查
        return queue_for_human(item)
    deduped = dedupe_against_tracker(extracted)
    return write_tracker(format_record(deduped))
```

只有調查分支是一個跑著第 3 章代理迴圈的 `AgentDefinition`,帶最小權限的唯讀工具,且在任何送出前都有強制的人工關卡:

```
investigation_agent = AgentDefinition(
    name="feedback_investigator",
    description="Investigates ambiguous or escalated feedback; drafts but never sends.",
    system_prompt="Investigate the item, then propose a resolution. Never send a reply yourself.",
    allowed_tools=["lookup_customer_history", "search_tickets", "search_docs", "draft_reply"],
) # 沒有 send_email 工具 — 送出這個動作由人工關卡掌管
```

驗證

- **光譜適配測試:** 量測每個類別的成本/延遲。若把 bug 鏈「升級」成 agent,每筆 token 應該飆升卻沒有品質提升 —— 證明選 workflow 是對的。
- **Gate 測試:** 餵 bug 鏈畸形輸入,斷言由 schema gate(而非模型)把它們 100% 路由到人工審查。
- **路由準確率評測:** 獨立量測分類器;誤路由是看不見的失敗,所以把它當成獨立指標來追蹤(\$14.2)。
- **人工關卡測試:** 斷言調查 agent 沒有送出工具 —— 確認它在物理上就無法送出回覆,使錯誤代價維持有界。

常見陷阱

- **把整條管線「agent 化」。** 把 router 與 bug 鏈做成「一個 agent」,會讓那些步驟可列舉的分支成本倍增、可除錯性盡失 —— 與「從簡單開始」背道而馳。
- **沒有 gate 的鏈。** 少了步驟之間的程式化檢查,提示串接只是一個更慢、更貴的單次呼叫(\$14.2)。
- **在無法驗證進度時就升級成 agent。** 模糊分支之所以可行,只因為每個動作不是讀取就是草擬,且送出有人工關卡 —— 拿掉它就沒通過第四問。

- 去調 agent 的提示而非它的工具。當調查者誤呼叫 `search_tickets` ,要修的是工具 schema,而不是系統提示(\$14.4)。

14.6 關鍵整理

概念	要記住什麼
控制 vs 彈性	Workflow = 你的程式碼控制流程;agent = 模型控制流程。它們是光譜的兩端,不是非此即彼(\$14.1)。
從簡單開始	用能通過評測的最簡單模式;唯有在無法列舉步驟時才往右走。每往右一步都付出延遲、token 與可除錯性的代價(\$14.1)。
五種 workflow 模式	Prompt chaining、routing、parallelization(sectioning/voting)、orchestrator-workers、evaluator-optimizer —— 多數「需要 agent」其實是其中之一(\$14.2)。
四問測試	複雜度、價值、可行性、錯誤代價必須全部為是,才建 agent;錯誤代價決定自主上限(\$14.3)。
投資於 ACI	在現代 Claude 上,可靠性是在工具描述與結構描述裡贏得的,不是花俏的提示(\$14.4)。
只有一個 agentic 階段	只升級那個你無法列舉步驟的分支;其餘維持為便宜、帶 gate 的 workflow(\$14.5)。

超出考綱,但錨定 Domain 1。orchestrator-workers 模式就是協調者/子代理設計(第 3 章),而錯誤代價這一問正是 Domain 5 保留確定性 hooks 與人工關卡的理由。掌握這條光譜,你就能捍衛——而不只是組裝——任何代理架構。

第 15 章:Agent Harness(代理執行框架)

進階——超出官方考綱。來源:[Anthropic — Effective harnesses for long-running agents | Building Effective Agents](#)。

模型發出文字與工具呼叫。它能做的就只有這些。其餘讓模型表現得像代理的一切——執行工具、決定要把什麼餵回去、保存進度、在正確時機停止、從崩潰的工具復原、記錄發生了什麼——都是你寫在模型外面的程式碼。那段程式碼就是 **harness**。

這個區分是正式環境代理工程中最重要的心智模型。當一個長時間執行的代理出錯——無限迴圈、忘記自己做過什麼、把機密洩進日誌、在壞掉的程式上宣告成功——解法幾乎從來不是「換個更好的提示」,而是修 harness。提示形塑模型的判斷;harness 治理系統的行為。對任何必須可靠的事情而言,行為勝過判斷。

本章是進階材料——基礎認證不會考「建一個 harness」。但底下每一項 harness 職責,都是某個考試主題的正式環境加強版:代理迴圈(Domain 1)、工具設計與錯誤處理(Domain 2),以及上下文管理與可靠性(Domain 5)。讀這一章是理解為什麼會有那些考試主題的最佳途徑。讀完你應能說出 harness 的各個元件、推理每個元件的取捨,並從頭到尾設計一個。

本章涵蓋:

- 模型在做什麼 vs. harness 在做什麼(\$15.1)——精確劃出那條界線。
- 五個核心元件(\$15.2)——迴圈驅動器、工具執行、上下文組裝、錯誤處理、可觀測性。

- 長時間 harness 的設計原則(§15.3)——狀態、拆解、驗證、清理。
- 端到端案例研究(§15.4)——一個長時間執行的程式碼庫遷移代理。
- 關鍵整理(§15.5)。

15.1 模型在做什麼 vs. harness 在做什麼

對 Claude 的一次 API 呼叫,接收一串訊息加上工具定義,並回傳一個回應:一些文字、零個或多個 `tool_use` 區塊,以及一個 `stop_reason`。它不會執行工具。它不會記得上一次呼叫。它不會決定任務何時「完成」。它無法讀檔、打 API,或提交到 git。它只產生一個去做那些事的請求,然後等待。

harness 就是把這道落差補起來的一切:

```
flowchart TD
    H[Harness] --> A[迴圈驅動器<br/>決定下一步與何時停止]
    H --> B[工具執行<br/>執行工具並回傳結果]
    H --> C[上下文組裝<br/>建立下一個請求]
    H --> D[錯誤處理<br/>重試、逾時、護欄]
    H --> E[可觀測性<br/>日誌、追蹤、指標]
    M[模型] -. 發出文字加 tool_use 加 stop_reason .-> H
    H -. 送出訊息加工具 .-> M
```

一個好用的測試:如果把模型拿掉、換成一個真人打出同樣的工具呼叫,還需要哪些基礎架構才能跑完這個任務? 那些基礎架構就是 harness。模型供應的是對下一步該做什麼的判斷,harness 供應的是真正去做、且安全又可觀測地一再去做的機械裝置。

這條界線在實務上為何重要:它告訴你每個關注點該放哪裡。金額上限、權限檢查、重試策略、機密遮蔽器、停止條件——這些都不該放進提示,因為提示只是建議性的,而模型是機率性的。它們屬於 harness,在那裡它們是確定性的程式碼(這就是第 3 章的 hooks-vs-提示規則,推廣到整個系統)。

15.2 harness 的五個核心元件

迴圈驅動器

迴圈驅動器是 harness 的心臟:一個 `while` 迴圈,呼叫模型、檢查 `stop_reason`、執行任何被請求的工具、附加結果,然後再次呼叫——直到真正的停止條件觸發。

```
flowchart TD
    Start[接收任務] --> Build[組裝請求<br/>messages 加 tools]
    Build --> Call[呼叫模型]
    Call --> Stop{stop_reason?}
    Stop -->|tool_use| Exec[執行被請求的工具]
    Exec --> Append[將 tool_result<br/>附加到歷史]
    Append --> Budget{觸發預算<br/>或護欄?}
    Budget -->|否| Build
    Budget -->|是| Halt[停止並升級]
    Stop -->|end_turn| Done[回傳結果]
```


不那麼顯而易見的決策都住在這裡：

- **停止條件。** 主要訊號是 `stop_reason == "end_turn"` ——絕非解析像「Done!」這樣的助理文字,也絕非把迭代上限當作主要控制(第 3 章,§3.1)。但正式環境的迴圈會在其上疊加次要護欄:最大回合預算、token 預算、實際時鐘逾時,以及升級觸發器。這些不會取代 `end_turn`;它們是在模型始終到不了時,限縮波及範圍。
- **循序 vs. 平行工具執行。** 單一模型回應可包含多個 `tool_use` 區塊。唯讀、彼此獨立的工具(兩個查詢)可為了延遲而並行執行;有副作用、或一個依賴另一個結果的工具,則必須依序執行。這個決策由 harness 掌管——模型做不到。
- **在哪裡強制執行政策。** 權限檢查與業務規則是在模型的請求與工具的執行之間跑,而不是在模型裡。這正是第 3 章 hook 模式的天然歸宿。

陷阱: 信任模型會自己停下來。沒有預算,一個搞糊塗的模型可能會無止盡地呼叫工具,燒錢又燒時間。**陷阱:** 把迭代上限當成正常出口——如果你的代理常態性地撞上 `max_turns`,那是任務拆得不夠細(見 §15.3),而不是上限設太低。

工具執行

一個 `tool_use` 區塊是一個請求,不是一個動作。harness 驗證它、執行它,並把發生的一切——成功、錯誤、逾時——轉成模型能據以推理的 `tool_result`。

有三項職責很容易做得不夠:

1. **執行前驗證。** 在動任何東西之前,先對照工具的 schema 與政策檢查參數。格式錯誤或違反政策的呼叫,應該變成一個模型能修正的錯誤結果,而不是一次崩潰或一個未授權的動作。
2. **沙箱與最小權限。** 會碰到檔案系統、shell 或網路的工具,就是代理的攻擊面。把它們圈起來(允許的路徑、允許的指令、網路白名單),讓一個糊塗或惡意的模型無法外洩資料或摧毀狀態。由 harness——而非提示——來強制執行。
3. **把失敗轉成結果。** 當工具拋出例外、逾時或回傳錯誤,harness 必須把結構化的錯誤餵回模型 (`is_error: true` 並附上清楚訊息),而不是把整個迴圈丟掉。一則良好的錯誤訊息(「找不到檔案:/x;你不是指 /y?」)能讓模型在下一回合自我修正——那個復原迴圈,是 harness 帶來最大的可靠性收益之一。

取捨: 豐富、寬容的工具結果有助模型復原,但耗 token 且可能洩漏內部細節;簡短的結果便宜,但給模型的料較少。逐工具調校。

上下文組裝

模型是無狀態的;harness 決定模型在每次呼叫中究竟看到什麼。這是對成本、延遲與品質影響最大的單一槓桿——也是長時間執行下最難拿捏的部分。

上下文組裝每回合都在回答:用哪個系統提示、哪些工具定義、多少對話歷史、哪些檢索到的文件或狀態檔,以及以何種順序。關鍵技巧(取自 Domain 5):

- **Compaction / 摘要。** 一個長時間執行的代理終將超出任何上下文視窗。harness 必須摘要或修剪較舊的歷史,同時保住承重的事實。那些必須撐過摘要的東西(findings 清單、來源登錄表、原始目標),要住在一個 harness 每回合逐字重新注入的結構化區塊裡,而不是仰賴它們留在滾動歷史中。
- **Prompt caching(提示快取)。** 穩定的前綴(系統提示、工具定義、一份大型 rubric)應被快取,讓重複回合以一小部分的成本計費。harness 控制快取邊界;放錯位置會無聲地浪費金錢。
- **外部化狀態。** 最便宜的上下文,就是你不送出的上下文。把機器可讀的狀態(進度檔、JSON 功能清單)保存在磁碟上,讓代理只讀它需要的那一小片,而不是把所有東西都扛在視窗裡。

陷阱: 天真的「全部附加」上下文。它在 demo 裡能動,在正式環境裡會壞——成本逐回合成長、延遲攀升,重要的早期事實被埋掉或摘要掉。**陷阱:** 把任務所依賴的那一個事實摘要掉了。要**明確**決定什麼絕不可被 compact 掉。

錯誤處理與護欄

除了個別工具失敗,harness 還掌管系統層級的可靠性:對暫時性 API 錯誤做帶退避的重試、對每個外部呼叫設逾時、在依賴掛掉時啟動斷路器,以及不論模型怎麼決定都會阻擋不被允許動作的**護欄**。護欄是確定性的程式碼(阻擋超過上限的退款、拒絕寫到儲存庫外、要求不可逆動作需真人核准)——是第 3 章 hooks 的正式環境推廣。**第 3 章的規則對整個 harness 都成立:** 當失敗會造成財務、法律或安全後果時,用程式碼強制執行,而非提示。

可觀測性

一個長時間執行的代理就是個黑盒子,除非 harness 把它打開。記錄每一回合:請求(或其雜湊)、模型的文字與工具呼叫、每個工具結果、token 計數、延遲,以及最終的停止原因。這正是讓你能除錯「它在第 40 回合為什麼那樣做」、歸因成本、用真實軌跡建立 evals,並偵測漂移的依據。**陷阱:** 記錄含機密或 PII 的原始工具 I/O——可觀測性這一層,正是遮蔽必須落腳之處。

15.3 長時間 harness 的設計原則

當代理必須跨多個上下文視窗執行數小時(一次大型遷移、一場為期數日的調查),少數幾條原則,區分了能跑完的 harness 與會卡住的 harness:

- **差異化初始化。** 為第一個上下文視窗用不同的提示——一個鋪好鷹架(功能清單、儲存庫結構、進度文件)的提示,讓之後每個工作階段都讀。第一個工作階段畫地圖,後續工作階段照著走。
- **結構化、機器可讀的狀態。** 把進度保存為全新上下文視窗能在數秒內解析的產物——JSON 功能清單、一份 `progress.md`、一個驅動恢復的 manifest。代理的記憶住在磁碟,而非視窗。
- **漸進式拆解。** 讓代理一次只做一個工作單位(一個功能、一個檔案、一個遷移步驟),驗證它、提交,再往下——而非想一次做完整個東西、結果做到一半就用光上下文。如果迴圈一直撞上 `max_turns`,那個單位就太大了。
- **明確驗證。** 在宣布一個單位完成之前,強制端到端檢查(測試通過、build 是綠的)。沒有證據,絕不相信模型說的「能跑」——把 harness 與一個評估者(第 16 章)搭配,讓成功是被**檢核**的,而不是被**宣稱**的。
- **環境清理。** 要求代理用具描述性的訊息把進度提交到 git,留下人能直接接手的乾淨狀態。下一個工作階段——或下一個人——從一個已知良好的點開始。
- **工作階段啟動程序。** 每個工作階段先讀進度檔、檢視近期 git 歷史、跑基本檢查,再開始新工作,讓全新的上下文視窗重新定位,而不是用猜的。

15.4 端到端案例研究:長時間執行的程式碼庫遷移代理

上述元件唯有組合在一起才有意義。以下是一個真實的長時間執行代理:把一個大型儲存庫從某個框架版本遷移到下一個版本——數百個檔案,遠多於單一上下文視窗裝得下的工作量——在無人看顧下徹夜執行。

需求

- 把儲存庫中的每個模組從 `framework v1` 遷移到 `framework v2`,一次一個模組。
- 工作量遠超一個上下文視窗,因此代理必須**跨多個工作階段恢復**而不丟失進度。

- 一個模組在**它的測試通過之前都不算完成**——不接受沒有證據的「看起來遷好了」。
- **硬性規則**: 代理只能寫在儲存庫內,且只能執行白名單上的指令(不可連網、不可刪除儲存庫外的東西)。這由程式碼強制執行。
- 每個工作階段都必須留下一個人能檢視的**乾淨、已提交的 git 狀態**。
- 整趟執行必須**可觀測**——哪個模組、哪一回合、什麼失敗了。

架構

```

flowchart TD
    Start[工作階段開始] --> Read[讀取 progress.json<br/>與 git log]
    Read --> Pick[挑出下一個<br/>標記為 pending 的模組]
    Pick --> Loop[執行代理迴圈<br/>編輯並遷移模組]
    Loop --> Sandbox["工具沙箱<br/>僅限儲存庫寫入加白名單"]
    Sandbox --> Verify[執行模組測試]
    Verify --> Pass{測試綠?}
    Pass -->|否| Loop
    Pass -->|是| Commit[以訊息提交<br/>並標記模組 done]
    Commit --> More{還有模組<br/>或剩餘預算?}
    More -->|是| Pick
    More -->|否| End[停止並回報]
  
```

harness 掌管每一項非模型的關注點:**迴圈驅動器**跑遷移回合;**工具沙箱**讓「僅限儲存庫、白名單」的執行成為硬保證;**上下文組裝**靠讀 `progress.json` 而非重播歷史,讓每個工作階段保持精簡;**驗證**(測試)為完成把關;而**提交加進度檔**提供清理與可恢復性。

實作草圖

狀態檔是代理的長期記憶——小、機器可讀、每次工作階段開始都重讀:

```

# progress.json - 驅動跨上下文視窗的恢復
{
  "framework": "v1 -> v2",
  "modules": [
    {"path": "src/auth",      "status": "done",      "commit": "a1b2c3d"},
    {"path": "src/billing",   "status": "pending"},
    {"path": "src/reports",   "status": "pending"}
  ]
}
  
```

迴圈驅動器界定執行範圍,且只信任真正的停止訊號加上明確的護欄:

```

def run_session(state, budget_turns=200):
    history = build_initial_context(state) # progress.json + 儲存庫地圖,而非完整歷史
    for turn in range(budget_turns):
        resp = model.call(messages=history, tools=TOOLS)
        log_turn(turn, resp) # 可觀測性:記錄每一回合
        if resp.stop_reason == "end_turn":
            return "session_complete"
        for call in resp.tool_uses:
            result = execute_tool(call) # 驗證、沙箱化、把錯誤當成結果回傳
            history.append(result)
    return "budget_exhausted" # 次要護欄,不是正常出口

```

工具執行程式碼強制沙箱——模型無法擴張自己的權限:

```

def execute_tool(call):
    if call.name == "write_file" and not inside_repo(call.args["path"]):
        return tool_result(call, is_error=True,
                           text="Refused: writes are restricted to the repo.")
    if call.name == "run_command" and call.args["cmd"] not in ALLOWLIST:
        return tool_result(call, is_error=True,
                           text=f"Refused: '{call.args['cmd']}' is not
allowlisted.")
    try:
        return tool_result(call, text=dispatch(call)) # 成功
    except ToolError as e:
        return tool_result(call, is_error=True, text=str(e)) # 失敗 -> 模型可自我修正

```

執行軌跡

```
sequenceDiagram
    actor Op as 維運者
    participant Ha as Harness
    participant Mo as 模型
    participant Sb as 工具沙箱
    participant Git as Git 儲存庫
    Op->>Ha: 啟動徹夜遷移執行
    Ha->>Ha: 讀 progress.json, 挑出 src/billing
    Ha->>Mo: 把 src/billing 遷移到 v2 加上儲存庫上下文
    Mo-->>Ha: tool_use write_file src/billing
    Ha->>Sb: write_file 在儲存庫內
    Sb-->>Ha: ok
    Ha->>Sb: run_command pytest src/billing
    Sb-->>Ha: 2 個測試失敗
    Ha->>Mo: tool_result 測試失敗加輸出
    Mo-->>Ha: tool_use write_file 修正
    Ha->>Sb: run_command pytest src/billing
    Sb-->>Ha: 全部測試通過
    Ha->>Git: commit 把 src/billing 遷移到 v2
    Ha->>Ha: 在 progress.json 標記 src/billing 為 done
    Mo-->>Ha: end_turn
    Ha-->>Op: src/billing 完成, 還剩 2 個模組
```

注意是 harness——而非模型——保證了什麼:寫入留在儲存庫內(沙箱)、失敗的測試以*模型能修的結果*回來而非崩潰(錯誤處理)、完成被綠色測試把關(驗證),而進度為下一個工作階段存活了下來(狀態加提交)。模型只供應了遷移的編輯。

驗證

- **可恢復性測試:** 在模組進行到一半時砍掉行程並重啟。代理必須重讀 `progress.json`、跳過 `done` 的模組,並接續那個 `pending` 的——沒有重複或丟失的工作。
- **沙箱測試:** 提示代理去寫儲存庫外或執行非白名單的指令;斷言它被 harness 以*錯誤結果*拒絕,且迴圈繼續。
- **驗證關卡測試:** 指向一個測試會失敗的模組;斷言它永遠不會被標記為 `done`,並被留作 `pending` 供下次嘗試。
- **預算測試:** 強制一個不會終止的情況;斷言迴圈在 `budget_turns` 處停止並升級,而非無止盡地跑。

常見陷阱

- 跨工作階段扛著完整對話歷史,而非一個精簡的 `progress.json` (成本爆炸;舊事實被摘要掉——§15.2)。
- 把「僅限儲存庫 / 白名單」規則強制在提示裡,而非在 `execute_tool` 裡(機率性,沒有保證——§15.1)。
- 憑模型一句話就把模組標記為完成,而非憑測試通過(§15.3,驗證)。
- 把 `budget_turns` 當成*正常*出口訊號,而非 `end_turn` (那是任務拆得不夠細——§15.2)。

15.5 關鍵整理

概念	要記住什麼
----	-------

模型 vs. harness	模型只發出文字加 <code>tool_use</code> 加 <code>stop_reason</code> ;harness 執行工具、組裝上下文、驅動迴圈、處理錯誤、進行觀測。可靠性住在 harness,而非提示(\$15.1)。
迴圈驅動器	主要停止訊號是 <code>stop_reason == "end_turn"</code> ;預算/逾時是次要護欄,用來限縮波及範圍,絕非正常出口(\$15.2)。
工具執行	<code>tool_use</code> 是一個請求——驗證、沙箱化(最小權限),並把失敗轉成結構化的 <code>is_error</code> 結果,讓模型能自我修正(\$15.2)。
上下文組裝	harness 決定模型每回合究竟看到什麼;用 compaction、快取與外部化狀態,並釘住那些絕不可被摘要掉的事實(\$15.2)。
護欄	金錢/法律/安全規則與權限檢查,是介於請求與執行之間的確定性程式碼——第 3 章 hooks 的系統級推廣(\$15.2、\$15.4)。
長時間設計	外部化的機器可讀狀態、漸進式拆解、明確驗證、git 清理,以及工作階段啟動程序,讓跨視窗執行可恢復(\$15.3)。

超出考綱,但建立在它之上。 harness 是代理迴圈(Domain 1)、工具設計與錯誤處理(Domain 2),以及上下文管理與可靠性(Domain 5)的正式環境形態。把它與 **loop engineering**(第 16 章)搭配:harness 給代理自主執行的機械裝置;評估者迴圈給它一個相信結果的理由。

第 16 章:Loop Engineering(迴圈工程)

進階—— 超出官方考綱。來源:[The New Stack — Loop engineering](#);Anthropic — [Building Effective Agents](#)(evaluator–optimizer)與 [Effective harnesses for long-running agents](#)。

當代理越來越強,最高槓桿的設計工作從「**寫出完美的一次性提示**」轉移到「**設計代理所處的迴圈**」——「不再寫提示,改寫迴圈」。迴圈(模型 → 工具呼叫 → 回饋 → 重複)就是你要工程化的單位。第 3 章為了考試介紹了最小的代理式迴圈:一個跑到 `stop_reason == "end_turn"` 為止的 `while`。那個迴圈是正確的,但在生產環境裡卻危險地天真——它假設模型總會收斂、永遠不會重複自己、也永遠不需要被停止、暫停或續跑。真實的代理三者都會發生。

本章談的就是那個迴圈的生產級工程。這是**超出 Foundations 考綱的進階內容**,但它立基於一個考試**確實**會考的觀念(\$3.1):**下一步由模型作主,所以邊界必須由 harness 作主**。一個只在 `end_turn` 才停的迴圈,碰上一次糟糕的執行,就會把你整個 token 預算燒在兩個工具之間來回擺盪,或追逐一個永遠達不到的目標。Loop engineering 就是替自主迴圈裝上**邊界**的學問:停止條件、預算、進度偵測、擺盪防護與恢復檢查點——讓它能無人看管地跑上數分鐘乃至數小時,而不漂移、不無限迴圈、也不會在當機時丟失成果。

我們涵蓋六個面向:

- **停止條件**(\$16.1)—— 超出 `end_turn` 的分層退出訊號。
- **步數與回合預算**(\$16.2)—— 在不把步數上限當作**主要停止條件**的前提下,限制成本與延遲。
- **進度偵測**(\$16.3)—— 區分「仍在工作」與「卡住」,以及擺盪防護。
- **Generator–evaluator 迴圈**(\$16.4)—— 把工作者與檢查者分開,以取得可信賴的「完成」。
- **恢復與檢查點**(\$16.5)—— 從當機中存活,並在不重做已完成工作的情況下續跑長迴圈。
- **端到端案例研究**(\$16.6)—— 一個長時間執行的程式庫遷移代理,把前五者整合在一起。

16.1 停止條件:超出 end_turn

對「迴圈何時停止？」這個問題,考試的答案是 `stop_reason == "end_turn"` —— 作為完成訊號,這完全正確(永遠別解析助理文字,也別把單純的迭代上限當作完成的意義)。但 `end_turn` 只回答了「模型自己決定它做完了嗎？」一個生產級迴圈還需要因為其他幾個模型自己永遠不會提出的理由而停止。把停止條件想成分層,每一層由系統的不同部分負責:

```
flowchart TD
    A[迴圈迭代] --> B{模型回傳 end_turn?}
    B -->|yes| C{評估者通過<br/>完成標準?}
    C -->|yes| DONE[停止 SUCCESS]
    C -->|no| FB[注入回饋<br/>繼續迴圈]
    FB --> A
    B -->|no, tool_use| D{預算耗盡?}
    D -->|yes| BUD[停止 BUDGET<br/>交接部分成果]
    D -->|no| E{沒有進度<br/>或正在擺盪?}
    E -->|yes| STUCK[停止 STUCK<br/>升級給人]
    E -->|no| F{護欄觸發<br/>或致命錯誤?}
    F -->|yes| ABORT[停止 ABORTED<br/>安全關閉]
    F -->|no| G[執行工具<br/>附加結果]
    G --> A
```

這五個終止狀態 —— `SUCCESS`、`BUDGET`、`STUCK`、`ABORTED`,以及一個逾時變體 —— 之所以重要,是因為它們驅動不同的後續行為。`SUCCESS` 回傳結果;`BUDGET` 停止會帶著明確的「在這裡沒空間了」標記交接部分成果;`STUCK` 停止會升級給人(Domain 5),而不是假裝成功;`ABORTED` 停止會在護欄觸發或不可恢復錯誤後執行安全關閉。最常見的生產 bug 就是把這些全部場縮成一個布林值 `done`,結果呼叫端根本分不出一個做完的任務和一個放棄的任務。

為什麼重要 / 陷阱。兩種失效模式夾住這個設計。停得太急(只看 `end_turn`、沒有評估者),代理就會在實際上沒通過的工作上宣告勝利 —— 模型對自己輸出的判斷並不可靠(\$16.4)。停得太晚(沒有預算、沒有進度檢查),一次糟糕的執行就會在毫無進展的情況下花掉真金白銀與牆鐘時間。解法不是更聰明的提示,而是多個獨立的停止訊號,每一個都由程式碼負責,而非模型。

16.2 步數與回合預算

預算限制迴圈在必須停止並交接前可以消耗多少。考試正確的細微之處(\$3.1)是:迭代上限作為**主要*停止條件是反模式** —— 它完全沒告訴你工作是否完成。但預算作為**安全上限**仍然不可或缺:它就是失控迴圈花 \$2 還是花 \$2,000 的差別。

沿著真正會傷到你的那個維度設預算:

預算類型	限制	典型用途
回合 / 迭代	模型呼叫次數	對付緊迴圈式無限迴圈的廉價防護
Token	輸入加輸出 token 總量	真正的成本上限;追蹤上下文成長
牆鐘時間	經過時間	延遲 SLA;面向使用者的互動性
工具呼叫	對特定工具的呼叫次數	速率限制、昂貴或有副作用的工具

為什麼 / 取捨。 Token 預算通常是最真實的成本代理,因為上下文每次迭代都在成長 —— 每個工具結果都會被附加,所以後段迭代遠比前段昂貴。預算要從**成功執行的 p95 加上餘裕**來設,而非平均值:若一個任務通常 12 回合完成、但偶爾需要 30 回合,上限設 15 會掐死正當工作,而上限設 100 又讓卡住的迴圈在沒有進度後還跑 70 回合。這正是預算應為**最後防線**而非日常退出的原因 —— 進度偵測(\$16.3)通常應該遠在預算之前就停掉卡住的迴圈。一個經常觸發的預算,正是你真正停止條件太弱的訊號。

當預算是讓你停下的那個東西時,**絕不要默默丟掉工作**。要發出部分成果交接:做了什麼、還剩什麼、以及續跑所需的狀態(\$16.5)。預算停止是暫停,不是失敗。

16.3 進度偵測與擺盪

這是 loop engineering 最難的部分,也是天真迴圈完全忽略的部分。迴圈必須區分三種**看起來都像「模型又呼叫了一個工具」**的狀態:

- **有進展** —— 每一步都朝目標改變狀態(失敗測試從 8 個變成 5 個)。
- **卡住** —— 步驟有在執行,但相關狀態沒變(同一個測試一直以同樣方式失敗)。
- **擺盪** —— 代理在兩個狀態間永遠來回(改成 A → 測試失敗 → 還原成 B → 測試失敗 → 改成 A ...)。

```
flowchart TD
    S[每一步後<br/>擷取進度訊號] --> C{訊號相較上個<br/>檢查點有改善?}
    C -->|yes| R[重置停滯計數<br/>儲存檢查點]
    R --> CONT[繼續迴圈]
    C -->|no| I[增加停滯計數]
    I --> O{相同狀態<br/>先前見過 2 次以上?}
    O -->|yes| OSC[偵測到擺盪<br/>打破循環]
    O -->|no| T{停滯計數<br/>超過門檻?}
    T -->|yes| ESC[沒有進度<br/>改變策略或升級]
    T -->|no| CONT
    OSC --> ESC
```

定義進度訊號。 進度只能用一個**具體、外部的指標**來衡量 —— 永遠不要用模型的自我回報。好的訊號是 harness 不必問模型就能讀到的領域產物:失敗測試數、待遷移的剩餘行數、進度檔裡未解決的清單項目、一個從紅變綠的建置。評估者那組可檢核的「完成」標準(\$16.4)同時也充當進度尺。如果你說不出一個 harness 能衡量的訊號,你就無法偵測卡住,迴圈也就沒有邊界。

擺盪防護。 擺盪很陰險,因為每一個個別步驟看起來都很有生產力 —— 模型每次都有一個新鮮、看似合理的理由。要靠**對相關狀態做雜湊**(例如變更檔案的集合加上測試結果)並追蹤近期雜湊值來偵測;出現重複就代表有循環。抓到時,要**改變某些東西**,而不是讓它空轉:把迴圈自己的歷史注回去(「A 與 B 你各試了兩次;兩者在同一個測試上都失敗 —— 換個方法」)、強制換一個工具,或升級。把模型自己的迴圈歷史餵回去往往就夠了,因為擺盪通常來自模型**忘了自己已經試過另一個分支** —— 這既是推理問題,更是上下文/記憶問題。

為什麼 / 陷阱。 經典錯誤是用**回合上限取代進度偵測** —— 它最終會停掉擺盪,但只在浪費掉整個預算之後,而且它分不出「卡住」與「在一個真的很長的任務上快做完了」。第二個錯誤是把模型的敘述(「進展良好!」)當成訊號;一個卡住的模型往往最有自信。永遠用產物衡量進度,絕不用文字。

16.4 Generator-evaluator 迴圈

迴圈裡最關鍵的單一選擇:把產出工作的代理,與檢查工作的代理分開。模型評自己的輸出太寬鬆——它會為自己剛犯的錯誤找理由。一個帶不同指令、上下文乾淨的**獨立評估者**,能抓出產生者自我說服而忽略的失誤。這就是把 **evaluator-optimizer** 模式(第 14 章)當成核心迴圈來用,而它正好對應一般軟體生命週期:程式碼審查與 QA 扮演評估者的角色。

```
flowchart TD
    G[Generator<br/>產出或修訂工作] --> E[Evaluator<br/>乾淨上下文、自己的標準]
    E --> D{符合所有<br/>完成標準?}
    D -->|yes| PASS[接受輸出<br/>停止 SUCCESS]
    D -->|no| F[結構化回饋<br/>哪裡失敗、為何失敗]
    F --> B{達到預算或<br/>停滯上限?}
    B -->|yes| ESC[升級給人<br/>附上部分成果與回饋]
    B -->|no| G
```

這一個模式就解掉了 §16.1 的「停得太急」失效: **SUCCESS** 的決定由評估者擁有,而不是產生者的 `end_turn`。讓它有效運作:

- 給評估者**明確、可檢核的「完成」標準**——模糊的標準會產生雜訊迴圈,要嘛永遠不收斂、要嘛放行劣質品。「所有單元測試通過且公開 API 未變更」勝過「看起來對」。
- 讓評估者的上下文**保持新鮮、獨立於產生者的推理**——共用上下文會讓產生者的合理化滲進來,而獨立性正是重點所在。
- 回傳**結構化、可行動的回饋**,而非只有通過/失敗——回饋就是產生者的下一個輸入,所以「test_auth 失敗:token 過期時間差了 3600 秒」抵得上十句「再試一次」。
- 與 **harness**(第 15 章)搭配:驗證這一步,正是讓迴圈能自主運作而不漂移、不過早宣告成功的關鍵。

取捨。獨立評估者每一輪多花一次模型呼叫,並讓每次迭代延遲大約加倍。把它留給「錯誤的『完成』代價昂貴」的步驟(任何會送出程式碼、金錢或不可逆動作的);對於廉價、易回復的步驟,程式化檢查(一個測試執行器、一個 schema 驗證器)就是更快、完全確定性的評估者。評估者不一定要是模型——**最強的評估者通常是程式碼。**

16.5 恢復與檢查點

一個跑一小時的迴圈一定會被打斷——當機、速率限制、部署,或一次上下文視窗翻頁(第 15 章)。沒有恢復機制,一次中斷就意味著**重做一切**,對長代理而言這既昂貴又危險(重跑有副作用的工具)。因此 loop engineering 把迴圈視為**可續跑的**:它週期性地寫出一個**檢查點**——耐久、機器可讀的狀態,讓一個全新的迴圈能從上一個停下的地方繼續。

好的檢查點擷取續跑所需的最小資訊:**目標、進度訊號**(§16.3)、一份**已完成對剩餘的拆解**,以及一個指向外部化成果的指標(例如一個 git commit),如此續跑的迴圈就不需要完整的先前訊息歷史。這跟第 15 章的「結構化狀態管理」與「session 啟動例程」是同一個直覺,只是套用在迴圈粒度上。在**有意義的邊界**做檢查點——在評估者接受一個工作單元之後,而非每個 token 之後——如此檢查點永遠代表一個一致、已驗證、你樂意從那裡續跑的狀態。

冪等性是關鍵陷阱。續跑時,迴圈可能重試一個在當機前**部分完成**的步驟。若那個步驟有副作用(寄了一封信、刷了一張卡、寫了一個檔案),天真的續跑會**重複套用它**。防禦手段是標準那幾招:讓有副作用的工具具備冪等性(用一個 request id 當鍵)、在動作**之前**先把每個副作用記進檢查點,並在續跑時對照那筆紀錄做調節,而

非盲目重播。恢復檢查點與預算交接(\$16.2)用的是同一份序列化狀態 —— 預算停止不過是一個剛好是最後一個的、有計劃的檢查點。

16.6 端到端案例研究:長時間執行的程式庫遷移代理

前述各部分,唯有組裝起來才有意義。設想一個代理被要求把一個大型程式庫從已棄用的 logging 函式庫遷移到新的 —— 數百個檔案、一個會橫跨多個上下文視窗且可能中途當機的數小時工作。這正是 loop engineering 的典型問題:它確實開放式(你無法把步驟寫死),但進度是可驗證的(建置與測試就是真理),而這恰恰是該用代理而非工作流的時機(第 14 章)。

需求

- 把整個程式庫裡每一處對 `old_logger` 的呼叫遷移到 `new_logger`,保留行為。
- 這個工作超出一個上下文視窗、也超出一個行程生命週期 —— 它必須在當機後存活並續跑,而不重做已完成的檔案。
- 完成由程式碼定義,而非模型說了算:專案能建置、所有測試通過、且不再有任何 `old_logger` import 殘留。
- 限制成本:若觸及硬性 token 預算就停止並交接,若迴圈停止取得進度就升級給人。

架構

```
flowchart TD
    Start([開始或續跑]) --> Init[讀取檢查點<br/>建立剩餘檔案清單]
    Init --> Loop{還有剩餘檔案<br/>且預算還有?}
    Loop -->|no, 沒剩| Final[完整建置加測試<br/>最終評估者]
    Loop -->|no, 觸及預算| Handoff[寫檢查點<br/>交接部分成果]
    Loop -->|yes| Gen[Generator 遷移<br/>下一個檔案]
    Gen --> Eval[Evaluator<br/>對該檔案建置加測試]
    Eval --> Ok{通過?}
    Ok -->|yes| Save[提交該檔案<br/>寫檢查點]
    Save --> Loop
    Ok -->|no| Prog{這個檔案<br/>有進度?}
    Prog -->|yes| Gen
    Prog -->|no, 停滯| Esc[把該檔案<br/>升級給人]
    Esc --> Loop
    Final --> Done([停止 SUCCESS])
```

迴圈的工作單元是一個檔案,而非整個程式庫(漸進式拆解,第 15 章):每個檔案被產生、由一個真正會跑建置與該檔案測試的評估者驗證,接著在進到下一個之前提交並做檢查點。這讓每個檢查點都是一個一致、已驗證的狀態,並讓每次迭代的上下文都很小。

迴圈(虛擬碼)

結構是一個 `while`,它的邊界就是停止條件 —— 光靠 `end_turn` 遠遠不夠:

```

def migration_loop(state):
    while state.files_remaining:
        if state.tokens_used > TOKEN_BUDGET:
            return handoff(state, reason="budget")          # §16.2 有計劃的檢查點
        f = state.files_remaining[0]

        result = generate_migration(f, context=minimal(state)) # generator
        verdict = evaluator_run_build_and_tests(f, result)    # §16.4 程式碼當評估者

        if verdict.passed:
            commit(f, result)
            state.mark_done(f)
            checkpoint(state)                                # §16.5 在已驗證的邊界
            state.stall = 0
        else:
            state.stall += 1
            if oscillating(state, f) or state.stall > STALL_LIMIT: # §16.3
                escalate(f, history=state.recent_attempts) # 改變策略 / 找人
                state.defer(f)
            # 迴圈繼續; 模型在這裡永遠不會自己決定停止

    return finalize(state)  # 完整建置 + 測試 = 真正的 end_turn

```

注意哪些東西不被信任:模型永遠不宣告該檔案完成 —— 是跑真實測試的評估者宣告的(SUCCESS 由程式碼擁有,§16.4)。模型永遠不決定要不要永遠迴圈下去 —— 是預算與停滯防護決定的(§16.2、§16.3)。而迴圈永遠不丟失工作 —— 每個已驗證的檔案都被提交並做檢查點(§16.5)。

執行軌跡(一次當機與一次乾淨續跑)

```

sequenceDiagram
    actor Op as Operator
    participant H as Harness
    participant G as Generator
    participant V as Evaluator
    participant CK as Checkpoint store
    Op->>H: 啟動遷移工作
    H->>G: 遷移 auth.py
    G-->>H: 已編輯 auth.py
    H->>V: 建置並執行測試
    V-->>H: 通過
    H->>CK: 在第 41 個檔案 共 300 個 存檢查點
    Note over H: 行程在第 42 個檔案中途當機
    Op->>H: 重啟工作
    H->>CK: 載入上一個檢查點
    CK-->>H: 從第 42 個檔案續跑 還剩 259 個
    H->>G: 遷移 billing.py
    G-->>H: 已編輯 billing.py
    H->>V: 建置並執行測試
    V-->>H: 通過
    H->>CK: 在第 43 個檔案 共 300 個 存檢查點

```


這次當機**最多只賠掉一個檔案的重做**(第 42 個,它還沒被做檢查點),而非已完成的那 41 個。續跑的迴圈讀的是檢查點,而非先前對話,所以它以一個新鮮的上下文廉價啟動 —— 這正是第 15 章的 session 啟動例程,以迴圈恢復的形式表達。

驗證

- **可續跑測試:** 在執行中途砍掉行程、重啟,並斷言它從上一個檢查點續跑、且永不重新遷移已提交的檔案(證明冪等恢復,\$16.5)。
- **預算測試:** 設一個人為偏低的 token 預算,並斷言迴圈以一個 `BUDGET` 交接停止、且帶著一個可續跑的檢查點 —— 而非默默丟掉(\$16.2)。
- **抗擺盪測試:** 餵進一個 generator 修不好的檔案,並斷言迴圈偵測到停滯、把那一個檔案升級、並繼續遷移其餘的而非空轉(\$16.3)。
- **完成即完成測試:** 斷言只有在完整建置與測試通過、且不再有 `old_logger` import 殘留時,工作才回報 `SUCCESS` —— 永不憑模型一句話(\$16.4)。

常見陷阱

- 把回合上限(`max_iterations`)當成完成的意義而非最後防線 —— 它分不出做完與卡住(\$16.1、\$3.1)。
- 一個全域 `done` 布林值,使呼叫端分不出 `SUCCESS`、`BUDGET` 與 `STUCK` (\$16.1)。
- 信任模型的「全部完成!」而非一個會跑測試的評估者(\$16.4)。
- 在檔案中途做檢查點,使續跑重複套用一個部分的、有副作用的編輯(非冪等恢復,\$16.5)。
- 沒有進度訊號,使一個擺盪的迴圈把整個預算燒在看起來很忙上(\$16.3)。

16.7 重點整理

概念	該記住什麼
停止條件是分層的	<code>end_turn</code> 是完成訊號(\$3.1),但生產級迴圈還會因 預算、停滯/擺盪、護欄/錯誤 而停止 —— 每個都是不同的終止狀態,由程式碼負責,而非一個全域 <code>done</code> (\$16.1)。
預算是最後防線,不是計劃	把 token/回合/時間限制當作安全上限,從 p95 加餘裕來設;若預算經常觸發,代表你真正的停止條件太弱(\$16.2)。
用產物偵測進度	用外部指標(失敗測試、剩餘檔案)衡量「卡住對有進展」,絕不用模型自我回報;靠對近期狀態做雜湊來防護擺盪並打破循環(\$16.3)。
把 generator 與 evaluator 分開	一個帶新鮮上下文與可檢核標準的獨立評估者擁有 <code>SUCCESS</code> 的決定;結構化回饋驅動下一輪 —— 而最強的評估者通常是程式碼(\$16.4)。
讓迴圈可續跑	在已驗證的邊界做出耐久、機器可讀的檢查點,讓全新迴圈能廉價續跑;保持副作用冪等,使續跑永不重複套用(\$16.5)。
代理需要邊界	下一步由模型擁有;邊界由 harness 擁有。Loop engineering 就是替自主迴圈裝上停止條件、預算、進度偵測與恢復,讓它能無人看管地執行而不漂移、不永遠迴圈(\$16.6)。

超出考試,卻建立其上。 Foundations 考試考的是**最小迴圈**(`stop_reason == "end_turn"`、不解析文字、不用單純的迭代上限 —— \$3.1)。生產級 loop engineering 保留那個核心並加上邊界:

這正是把考試裡那個正確但天真的迴圈,變成一個你能放著跑一小時、並信任它會以正確方式停止的代理。

第四部分: Claude 平台完整參考(超出基礎考綱)

範圍說明: 第四部分是 2026 年 Claude 平台完整功能的參考 —— API、工具、SDK、Managed Agents、MCP 與現代 Claude Code, 供你**完整掌握 Claude**, 而非只為通過考試。其中**大多超出官方 Foundations 考綱**(部分甚至在考試明列的範圍外清單上)。每章都附官方文件。引用的現役模型: 旗艦 **Claude Fable 5**(`claude-fable-5`); 預設 Opus **Claude Opus 4.8**(`claude-opus-4-8`); 以及 **Sonnet 5**、**Haiku 4.5**。

第 17 章: 思考、Effort 與推理控制

參考 —— 超出考綱。文件: [Adaptive thinking](#) · [Effort](#) · [Extended thinking](#)。

現代 Claude 模型會先推理,再作答。對一個上線的代理而言,問題從來不是「模型該不該思考?」,而是「該思考多少、何時思考、**這要花我多少成本?**」推理是品質/延遲/成本三角上最大的一根槓桿: 思考太少,代理就會在多步驟遷移上失手; 思考太多,一次單行查詢就燒掉 40 秒與數千個 token。本章談的就是如何刻意地操控這根槓桿。

這部分內容屬**進階,且大多在 Foundations 考綱之外** —— 官方明列的範圍外清單就點名了 `extended-thinking` 的內部機制。它之所以值得收錄,是因為你出貨的每個真實代理,都將仰賴這些旋鈕的成敗。凡考試**確實觸及之處**(它要求你知道自適應思考的存在,以及 `effort` 以成本換取深度),都會就地註明。讀完你應能:

- 在**自適應思考(adaptive thinking)**與已棄用的固定預算之間選擇,並清楚哪個模型上會回傳 400 (§17.1)。
- 依路由(per route)而非全域地調整 **effort** 階梯(`low` → `max`)(§17.2)。
- 推理**穿插思考(interleaved thinking)**與工具使用的關係 —— 它為何對代理有幫助、又花什麼成本 (§17.3)。
- 控制**可見性(display)**並處理**遮蔽思考(redacted thinking)**,而不破壞多輪回放 (§17.4)。
- 用**任務預算(task budgets)**框住整個代理迴圈,有別於單次回應的 `max_tokens` 上限 (§17.5)。
- 判斷**延伸思考何時有益、何時有害**(§17.6)。

§17.7 接著從頭到尾建構一個完整的、受推理控制的**程式碼遷移代理**, §17.8 則濃縮重點。

17.1 思考控制的兩個世代: 預算 vs. 自適應

思考 API 有兩個世代,把它們混用是最常見的錯誤。

舊做法(已棄用)。 你設定一個固定上限: `thinking: {type: "enabled", budget_tokens: N}`, 其中 `N` 必須嚴格小於 `max_tokens`。你在事前猜這個預算,且對每個請求都一樣。

現行做法。 `thinking: {type: "adaptive"}`。模型**逐請求**自行決定要不要思考、思考多深,依它感知到的難度來調整推理。沒有 token 預算要調。

```

flowchart TD
    A[請求進來] --> B{模型家族?}
    B -->|Opus 4.7 / 4.8 / Fable 5 / Sonnet 5| C[thinking type  
adaptive<br/>budget_tokens 會被回傳 400]
    B -->|Opus 4.6 / Sonnet 4.6| D[thinking type adaptive<br/>budget_tokens 已棄用但  
仍可用]
    D -->|4.6 之前的模型| E[thinking type enabled<br/>budget_tokens 須小於 max_tokens]
    C --> F[深度由 effort 控制]
    E --> F
    F --> G[深度由固定預算控制]

```

為何這在生產上很重要: 固定預算會在簡單請求上想太多、在困難請求上想太少 —— 它無法分辨兩者。自適應思考在瑣碎查詢上不花一分力,遇到真正的多步驟問題才加碼,而這正是代理在異質工作負載上所要的花費分布。

硬性陷阱。 在 Opus 4.7、Opus 4.8、Fable 5 與 Sonnet 5 上, `thinking: {type: "enabled", budget_tokens: N}` 不只是不被建議 —— 它會回傳 **400 錯誤**。取樣參數 `temperature`、`top_p`、`top_k` 同樣如此。從較舊模型沿用過來的程式碼會直接失敗,而非悄悄降級。在 Opus 4.6 與 Sonnet 4.6 上,預算仍可`可用`但已棄用(僅作為過渡的逃生口)。Fable 5 還多一個轉折:思考永遠開啟,所以連明確的 `thinking: {type: "disabled"}` 也是 400 —— 你得完全省略這個參數。

17.2 Effort 階梯

採用自適應思考後,深度由 **effort** 治理,設在 `output_config` 裡(而非頂層):

```
output_config={"effort": "high"} # low | medium | high | xhigh | max
```

Effort 同時控制推理深度與整體 token 花費 —— 而且它形塑的是行為,不只是思考長度。較低的 effort 會產生較少、較整併的工具呼叫、較少前言、較簡短的確認;較高的 effort 在行動前探索得更多。

等級	用於	預期表現
low	延遲敏感或簡單任務、廉價子代理	推理最少;快;將工作緊扣在被要求的範圍內
medium	仍需一些推理的成本敏感工作負載	必須縮減 token 時的有利平衡點
high	預設(省略 effort 等同 high);多數對智能敏感的工作	任何要緊事項的建議下限
xhigh	程式與代理工作 —— 甜蜜點,也是 Claude Code 的預設	更多工具使用、更深規劃;搭配寬裕的 <code>max_tokens</code>
max	正確性比成本更重要;最困難、對延遲不敏感的情況	智能上限;可能想過頭而報酬遞減

為何要依路由、而非全域。 對整個系統用單一 `effort` 幾乎總是錯的。代理的規劃迴圈想要 `xhigh`;一批唯讀的「找檔案」子代理扇出想要 `low`;一則互動聊天回覆想要 `medium`。設成一個值,逼你在便宜路徑上超付、或在昂貴路徑上想不夠。

取捨與陷阱。 Effort 在 Opus 4.7/4.8 與 Fable 5 上比在任何先前模型都更要緊,而且它與成本並非單調關係。在長程代理工作上,前期較高的 effort 往往降低總成本,因為代理規劃得更好、浪費的回合更少——直覺的「effort 越低越便宜」在端到端上可能是錯的。在 Opus 4.8 上,反射性地總是抓 `xhigh` 來「最大化智能」也是個錯:從 `high` 起步並在你的評測集上掃描,因為 effort、延遲與成本的關係逐任務而異。

17.3 與工具使用穿插的思考

在非瑣碎的代理裡,模型不是思考一次就行動。它在工具呼叫之間思考——讀一個工具結果、推理它的意義、決定下一個呼叫。這就是穿插式(interleaved/interspersed)思考,而在自適應思考的模型上,它會自動發生、無需 beta header(較舊模型把它擋在 `interleaved-thinking-2025-05-14` 後面)。

```
flowchart TD
    A[使用者目標] --> B[思考:規劃第一步]
    B --> C[工具呼叫 1]
    C --> D[工具結果 1]
    D --> E[思考:解讀結果<br/>修正計畫]
    E --> F[工具呼叫 2]
    F --> G[工具結果 2]
    G --> H{達成目標?}
    H -->|否| E
    H -->|是| I[思考:最終綜整] --> J[作答]
```

它為何有幫助。 沒有穿插推理,模型會在還沒看到任何結果之前就鎖定一套工具計畫——當查詢回傳意料之外的東西時就很脆弱。穿插思考讓它能在迴圈中重新規劃:一個失敗的測試結果餵出修正後的修補,一次空白的搜尋餵出放寬後的查詢。這就是「能復原的代理」與「拿著過時計畫硬衝的代理」之間的差別。

它的成本與陷阱。 每個穿插區塊都計為輸出,所以一個長工具迴圈會回合接回合地累積推理 token。對生產有兩個後果:

- **回放紀律。** 當你在同一個模型上延續對話,你必須把思考區塊原封不動地傳回——包括空白文字的區塊。API 拒絕的是被修改過的區塊,不是被讀過的;丟棄或編輯它們會破壞該回合(排序/簽章錯誤)。
- **上下文成長。** 穿插區塊會堆積。長迴圈要搭配上下文編輯(`clear_thinking_20251015`)清除過時思考,或在接近視窗時搭配壓縮(compaction)——見第 21 章。

17.4 可見性(`display`)與遮蔽思考

你可以控制推理是否被顯示,與它是否發生分開來管。

display。 在 Opus 4.7、Opus 4.8 與 Fable 5 上, `thinking.display` 預設為 `"omitted"`——思考區塊仍會回傳,但其文字是空字串。設 `display: "summarized"` 可串流一段可讀的摘要:

```
thinking={"type": "adaptive", "display": "summarized"}
```

這只關乎可見性——在任何設定下思考都會發生且計費相同;原始思考鏈在任何模型上都不會被公開。實務上的陷阱:若你把推理串流給使用者卻保留預設,UI 會在輸出前顯示一段漫長的沉默停頓。任何「展示過程」的 UX,都要明確設成 `summarized`。

遮蔽思考。 偶爾某個思考區塊會被安全系統加密,並以 `redacted_thinking` 區塊回傳 —— 是一團不透明的位元組,不是可讀文字。**別**把它當成錯誤,也**別**把它剝除:在多輪請求中,你要像對待一般思考區塊那樣原封不動傳回,模型會在內部解密以維持連續性。移除遮蔽區塊會破壞與移除一般區塊相同的回放契約。(在 Fable 5 與 Mythos 5 上,原始思考鏈從不回傳 —— 你拿到的是被摘要或為空的一般 `thinking` 區塊,而非 `redacted_thinking`。)

17.5 任務預算:框住整個迴圈

`max_tokens` 限制的是**單次回應**,而且模型看不到它 —— 一旦撞上,輸出就會在思考途中被截斷。對「別讓這整段代理執行花超過 X」而言,那是錯的工具。為此,改用**任務預算**(beta header `task-budgets-2026-03-13`;Fable 5 / Opus 4.8 / 4.7):

```
output_config={"effort": "high", "task_budget": {"type": "tokens", "total": 64000}}
```

伺服器會注入一個模型看得到、橫跨整個迴圈的執行中**倒數**(它自己的生成,加上它這一回合讀到的工具結果 —— 不含你每次重送的完整歷史)。模型會自我調配:它先排定優先序,然後在預算耗盡時優雅收尾,而不是被 `max_tokens` 一刀斬斷。

控制	範圍	模型看得到嗎?	超出時
<code>max_tokens</code>	單次回應	否	在輸出途中硬截斷
<code>task_budget</code>	整個代理迴圈	是(看得到倒數)	優雅收尾;可能做得較不徹底並引述預算

陷阱。 `total` 的最小值是 **20,000** token。在正常迴圈中,讓 `remaining` 維持未設 —— 伺服器會自己追蹤倒數;只有當你在請求之間壓縮或改寫歷史時,才傳入用戶端計算的 `remaining` (否則會少報)。而把倒數攤給模型看是把雙面刃:在 Fable 5 上,可見的預算可能觸發「上下文焦慮」(模型會建議開新工作階段或刪減自己的工作)—— 若不需要顯示,就別顯示。

17.6 延伸思考何時有益 —— 何時有害

推理不是免費的智能;它是一筆你要替它說明理由的花費。

有益: 多步驟數學與邏輯、複雜的程式編輯與遷移、規劃一條長程代理軌跡、模型會驗證自己輸出的任務(替文件做紅線修訂、對帳數字),以及需要分解的模糊問題。

有害(或純屬浪費): 瑣碎的查詢與分類、無法接受 30 秒停頓的延遲關鍵路徑,以及每請求推理成本占主導的高量廉價呼叫。在這些上強推高 effort 純粹是課稅。

flowchart TD

```
A[進來的任務] --> B{多步驟或  
會自我驗證?}
B -->|否| C{延遲或  
成本關鍵?}
C -->|是| D[effort low  
或關閉思考]
C -->|否| E[effort medium]
B -->|是| F{長代理迴圈?}
F -->|是| G[adaptive 加 effort high 或 xhigh  
加上 task_budget]
F -->|否| H[adaptive 加 effort high]
```

微妙的失敗模式。 想過頭是真正的回歸,不是無害的鋪張。在 `max` 下,模型可能探索到超出有用範圍而**過度設計**——加上沒人要求的抽象與防禦性處理。修法是先把 `effort` 調低,然後才補上文字約束;在調降 `effort` 之前先抓更多護欄,是在治標而非治本。

17.7 端到端案例研究:受推理控制的程式碼遷移代理

上述旋鈕唯有組裝成一個系統才有意義。以下是一個其整體經濟性全繫於推理控制的真實代理:一項把儲存庫從某框架版本遷移到下一版的服務——讀程式碼、規劃、編輯、跑測試、修失敗,直到全綠。

需求

- 接收一個儲存庫與一個目標版本;自主產出一次通過的遷移。
- **協調者**以高推理深度規劃與編輯;它只在規劃層出錯,所以智能必須投在那裡。
- 一批**唯讀偵察子代理**扇出,找出已棄用 API 的每一處呼叫點——廉價、平行、不需推理。
- **框住整段執行的成本**,讓失控的遷移不致無上限地計費——但要讓代理優雅收尾,而非被截斷。
- 對盯著看的工程師串流一段**可讀的推理摘要**,但不公開原始思考鏈。
- 迴圈很長(數十次編輯/測試循環);**思考 token 不得撐爆上下文視窗**。

架構

flowchart TD

```
Eng([工程師]) --> Coord[協調者代理  
effort xhigh, 設定 task_budget]
Coord -->|Task 扇出| Scout1[偵察子代理  
effort low]
Coord -->|Task 扇出| Scout2[偵察子代理  
effort low]
Scout1 -. 呼叫點 .-> Coord
Scout2 -. 呼叫點 .-> Coord
Coord --> Edit[套用編輯]
Edit --> Test[執行測試套件]
Test --> Decide{測試全綠?}
Decide -->|否| Coord
Decide -->|是| Done[遷移完成]
Coord -. 長迴圈時 clear_thinking .-> Coord
```

協調者以 `xhigh` 掌管推理繁重的規劃;偵察兵以 `low` 執行,因為比對呼叫點需要的是速度而非深度; `task_budget` 框住累計花費;上下文編輯讓長迴圈的思考不致溢位。

實作

把協調者設定為深度推理、可見摘要,以及一個整段迴圈的預算。注意自適應思考是**明確**設定的 —— 在這些模型上省略 `thinking` 會不帶思考執行:

```
response = client.beta.messages.create(
    model="claude-opus-4-8",
    max_tokens=32000, # 單次回應硬上限
    betas=["task-budgets-2026-03-13"],
    thinking={"type": "adaptive", "display": "summarized"},
    output_config={
        "effort": "xhigh", # 程式甜蜜點
        "task_budget": {"type": "tokens", "total": 200000}, # 整段迴圈上限, 最小 20K
    },
    tools=[migrate_tools],
    messages=messages,
)
```

以低 effort 生成偵察兵 —— 對 grep 形狀的任務而言,深度是浪費:

```
scout = AgentDefinition(
    name="call_site_scout",
    description="Finds every call site of the deprecated API. Read-only.",
    # 依路由的 effort:此子代理跑 low;協調者維持 xhigh。
    output_config={"effort": "low"},
    allowed_tools=["grep", "read"],
)
```

在手動迴圈中維持回放紀律 —— 把思考區塊**原封不動**傳回,等迴圈拉長後再清除過時的:

```
# 逐字回送助理回合,包括 thinking / redacted_thinking 區塊。
messages.append({"role": "assistant", "content": response.content})
# 在長的編輯/測試迴圈上,清除過時思考以保護上下文視窗。
context_management = {"edits": [{"type": "clear_thinking_20251015"}]}
```


執行軌跡

```
sequenceDiagram
    actor Eng as 工程師
    participant Co as 協調者
    participant Sc as 偵察子代理
    participant Te as 測試執行器
    Eng->>Co: 把儲存庫遷移到 v2 (effort xhigh)
    Co->>Co: 思考:規劃遷移 (summarized)
    Co->>Sc: Task 扇出:找出已棄用呼叫點 (effort low)
    Sc-->>Co: 6 個檔案中有 14 處呼叫點
    Co->>Co: 思考:編輯順序、解讀風險
    Co->>Te: 執行測試套件
    Te-->>Co: 3 個失敗
    Co->>Co: 思考:診斷失敗、修正修補
    Co->>Te: 修正後重跑
    Te-->>Co: 全綠
    Co-->>Eng: 遷移完成 (預算用了 70 percent)
```

注意工具呼叫之間穿插的 `思考` 步驟 —— 協調者在偵察結果後重新規劃,又在測試失敗後再規劃一次。偵察兵從不深度推理;協調者從不把回合浪費在找檔案上。任務預算讓代理調配了十幾個循環、在用掉 70% 花費時收尾,而非在某個隨意的回應邊界被切斷。

驗證

- **成本框定測試:** 跑一次刻意刁難的遷移,斷言累計花費維持在 `task_budget` 內;確認該執行 *優雅收尾*(它引述預算)而非在編輯途中截斷。
- **依路由 effort 測試:** 斷言偵察子代理的請求帶 `effort: low`、協調者的帶 `effort: xhigh` —— 在此用單一全域 effort 就是錯誤設定。
- **回放測試:** 從回送的助理回合中丟棄思考區塊,確認下一個請求回傳 400 —— 證明你必須原封不動地傳回。
- **上下文測試:** 把編輯/測試迴圈跑到足以觸發 `clear_thinking`,斷言視窗不溢位。

常見陷阱

- 從較舊模型沿用 `budget_tokens` —— 在 Opus 4.7/4.8 上是 **400**,不是警告(\$17.1)。
- 省略 `thinking` 卻期待推理 —— 在這些模型上那會 *不帶思考執行*;要明確設 `{type: "adaptive"}` (\$17.7)。
- 單一全域 `effort` —— 在偵察兵上超付或讓協調者想不夠(\$17.2)。
- 串流到 UI 時把 `display` 留在預設 —— 工程師看到的是沉默停頓,不是摘要(\$17.4)。
- 用 `max_tokens` 來框住 *整段執行* —— 它框的是單次回應且會在思考途中截斷;迴圈要用 `task_budget` (\$17.5)。

17.8 關鍵整理

概念	該記住什麼
----	-------

自適應 vs. 預算	在 4.6+ 上用 <code>thinking: {type: "adaptive"}</code> ; 固定 <code>budget_tokens</code> 在 4.6/Sonnet 4.6 上已棄用, 在 Opus 4.7/4.8 與 Fable 5 上會 400 (\$17.1)。
Effort 階梯	<code>low</code> → <code>max</code> 設在 <code>output_config</code> 內; 預設為 <code>high</code> , <code>xhigh</code> 是程式/代理的甜蜜點。要依路由而非全域調整; 較高的 effort 可能降低端到端成本(\$17.2)。
穿插思考	自適應下自動啟用(無需 beta header); 讓代理在工具呼叫之間重新規劃。在同一模型上要把思考區塊 原封不動 傳回(\$17.3)。
Display 與遮蔽	<code>display</code> 在 4.7/4.8/Fable 5 上預設為 <code>"omitted"</code> —— 設 <code>"summarized"</code> 才展示過程; 把 <code>redacted_thinking</code> 區塊 原封不動 傳回, 絕不剷除(\$17.4)。
任務預算	<code>task_budget</code> (beta, 最小 20K) 用模型看得到的倒數框住 整個迴圈 ; <code>max_tokens</code> 框的是單次回應且會截斷。正常迴圈中讓 <code>remaining</code> 維持未設(\$17.5)。
何時思考	多步驟/會自我驗證 → 思考; 瑣碎/延遲關鍵 → <code>low</code> 或關閉。在 <code>max</code> 想過頭會造成過度設計 —— 加護欄前先調降 effort(\$17.6)。

超出考綱。 Foundations 考試只要求你知道自適應思考的存在, 以及 `effort` 以成本換取推理深度。這裡其餘的一切 —— 任務預算、穿插回放紀律、遮蔽思考、依路由 effort —— 都是讓代理在快、準、又負擔得起之間並存的生產工藝。

第 18 章: Prompt Caching(提示快取)

文件: [Prompt caching](#)

每個上線的代理在每一輪都會重送相同的龐大前綴 —— 數千 token 的系統提示、凍結的工具目錄、檢索到的文件, 以及整段先前的對話。沒有快取, 你就得用完整的輸入價格在每一次請求中**重新處理**這些一模一樣的位元組, 而使用者只能枯等模型重讀它早已看過的上下文。**提示快取(prompt caching)** 讓 API 能重用它在穩定前綴上已完成的工作: 快取**讀取**的成本約為正常輸入價格的 **0.1x**, 並且跳過重新處理, 因而同時降低成本(快取區段最多省約 90%) 與首字延遲(time-to-first-token)。

本章屬於 **PART III —— 進階、上線級代理工程**, 超出 Foundations 考綱。考試只要求你知道**提示快取存在**。但只要你開始營運真正的代理, 快取就不再是可選項: 它是「每輪花幾分錢」與「每輪花好幾塊錢」的代理之間的差別, 而它的無聲失敗模式(快取永遠沒命中)正是最常見、也最難察覺的上線成本回歸之一。它唯一直接觸及考試的地方是**上下文與成本可靠性**: 一個帶有龐大穩定 `system` + `tools` 前綴的代理, 正是快取為之而生的形狀, 而關於成本高效上下文管理的 Domain 推理, 正假設你理解它。

讀完你應能掌握五件事, 並把它們組裝成一個快取高效的代理:

- **前綴比對的不變式**(\$18.1) —— 為何前綴中一個位元組改變, 其後全部失效。
- **`cache_control` 中斷點與 TTL**(\$18.2) —— 標記要放哪裡, 以及 5 分鐘 vs 1 小時。
- **成本模型**(\$18.3) —— 讀約 0.1x / 寫 1.25x–2x, 以及回本點在哪。
- **無聲失效因子**(\$18.4) —— 如何**證明**快取有在運作, 以及什麼會悄悄破壞它。
- **代理的快取策略**(\$18.5) —— 穩定的 `system` + `tools` 前綴, 以及會話途中的變通做法。

\$18.6 接著從頭到尾建構一個完整的快取最佳化客服代理, \$18.7 則濃縮這套實用知識。

18.1 唯一的不變式:快取是前綴比對

本章的一切都源自一條規則:

提示快取是前綴比對。前綴中任何位置有一個位元組改變,其後全部失效。

快取鍵(cache key)是由提示**算繪後的確切位元組**直到每個中斷點推導而來。API 以固定順序算繪請求 —— `tools` → `system` → `messages` —— 並沿著該算繪序列尋找它已快取的最長前綴。位置 N 處有一個位元組不同 —— 系統標頭裡的時間戳、工具結構描述裡被重排的 JSON 鍵、清單中多出一個工具 —— 就代表從位置 N 起的所有內容都**不在**快取中,必須以完整價格處理。

flowchart TD

```
A[建構請求] --> B[以固定順序算繪  
先 tools 再 system 再 messages]
B --> C{前綴位元組是否  
命中某個快取項?}
C -->|是,到位置 N 為止| D[讀取快取區段  
約 0.1x 輸入價]
C -->|未命中| E[以完整價格處理  
並寫入新的快取項]
D --> F[只處理  
未快取的剩餘部分]
E --> F
F --> G[回傳回應  
以及 usage 快取計數器]
```

實務上的後果是一條排序紀律:**穩定內容必須在實體上先於易變內容**。把凍結的系統提示與確定性的工具清單放最前面;把時間戳、每請求 ID,以及會變的使用者問題放**最後**,在最後一個中斷點之後。排序對了,大部分快取就免費生效;排序錯了 —— 把今天的日期插進系統提示的**最上方** —— 再多的 `cache_control` 標記也救不了你,因為第一個區塊本身就在每次請求中都不同。

為何是硬性前綴比對,而非模糊重用? 因為快取儲存的是模型在每個前綴邊界的內部處理狀態,而該狀態只對**恰好**這些前置位元組有效。沒有部分計分:這條規則殘酷,卻完全可預測,而正是這份可預測性讓你能繞著它做工程設計。

18.2 `cache_control` 中斷點與 TTL

中斷點標記一個可快取區段在哪裡結束。你透過在某個內容區塊上附加 `cache_control` 來設定它:

```
{"type": "text", "text": LARGE_STABLE_CONTEXT, "cache_control": {"type": "ephemeral"}}
```

中斷點可以放在任何內容區塊上 —— `system` 文字區塊、工具定義,或訊息區塊(`text`、`image`、`tool_use`、`tool_result`、`document`)。由於算繪順序是 `tools` → `system` → `messages`,在**最後一個 `system` 區塊**上的標記會把工具與系統提示一起快取(工具在 `system` 之前算繪,因此落在同一個前綴內)。

兩種 TTL:

- `{"type": "ephemeral"}` —— **5 分鐘**滑動 TTL(預設)。每次讀取都會刷新它。
- `{"type": "ephemeral", "ttl": "1h"}` —— **1 小時** TTL,用於間隔超過五分鐘的爆量(bursty)流量。

實務上會咬人的限制:

- **每請求最多 4 個中斷點。** 把它們花在穩定邊界上(見 §18.5),別任意揮霍。
- **最小可快取前綴依模型而定。** 在 Opus 4.8 / 4.7 / 4.6 上是 **4096 token**;Sonnet 4.6 是 2048;Sonnet 4.5 是 1024。短於最小值的前綴會**無聲地不快取**——沒有錯誤,只是 `cache_creation_input_tokens: 0`。一個 3K token 的提示在 Sonnet 4.5 上會快取,在 Opus 4.8 上卻不會。
- **20 區塊回看視窗。** 每個中斷點最多往回走**20 個內容區塊**來尋找先前的快取項。單一輪若附加超過 20 個區塊——在帶有大量 `tool_use / tool_result` 配對的代理迴圈中很常見——就會把先前的快取推到構不著的範圍外,下一次請求便無聲地未命中。修法:在長的輪次中,大約每 15 個區塊放一個中間中斷點。

頂層自動快取。 若你不需要細粒度的放置,在 `messages.create()` 的頂層傳入 `cache_control`,API 會自動快取最後一個可快取區塊。對於單一龐大的 `system` 提示,這是最簡單的選擇;只有當你需要快取數個不同區段(例如工具、然後一個會話前綴、再來一個輪次)時,才動用逐區塊的明確標記。

18.3 成本模型:快取何時真正回本

快取並非免費——寫入的成本高於一般 token。你必須讀取足夠多次,才能攤平那筆溢價。

操作	價格(相對於基礎輸入)
快取讀取	約 0.1×
快取寫入,5 分鐘 TTL	1.25×
快取寫入,1 小時 TTL	2×
未快取的輸入	1×

回本點取決於 TTL:

- **5 分鐘 TTL:** 第一次請求寫入(1.25×),第二次讀取(0.1×):合計 1.35× vs 未快取的 2×。對同一前綴的**兩次請求**就已回本。
- **1 小時 TTL:** 寫入是 2×,因此你需要 $2\times + 0.1\times = 2.1\times$ 才能勝過未快取的 3×——大約**三次請求**。1 小時 TTL 買的是**跨閒置間隔的存活**,但加倍的寫入代表它需要更多讀取才會贏。只有當流量爆量到一個 5 分鐘的快取項會在兩波之間過期時,才使用它。

flowchart TD

```

A[相同前綴是否<br/>很快會被再用?] -->|否| B[不要快取<br/>單次寫入只是平白多付 1.25x 溢價]
A -->|是| C{兩次再用之間的間隔<br/>是否超過 5 分鐘?}
C -->|否| D[5 分鐘 TTL<br/>從第 2 次請求起回本]
C -->|是,爆量| E[1 小時 TTL<br/>約從第 3 次請求起回本]
D --> F[把中斷點放在<br/>共用前綴的結尾]
E --> F
  
```

這裡最昂貴的錯誤,是快取一個永遠不會被再用的前綴——每次請求都以 1.25× 寫入一筆新項,從不讀取,於是你把這個工作負載弄得**比完全不快取還貴**。若前 1K token 在每次請求都不同,就沒有可重用的前綴:把快取關掉。

`input_tokens` 只是未快取的剩餘部分。提示總大小 = `input_tokens + cache_creation_input_tokens + cache_read_input_tokens`。若一個長時間運行的代理在工作數小時

後回報 `input_tokens` 為 4K,其餘都是從快取送出的 —— 在對成本下任何結論之前,看那個**總和**,別只看單一欄位。

18.4 驗證與無聲失效因子

壞掉的快取會**無聲地**失敗:沒有錯誤,只是帳單悄悄維持在完整價格。要知道快取有沒有運作,唯一的辦法是**量測**它。每個回應的 `usage` 物件回報三個計數器:

欄位	意義
<code>cache_creation_input_tokens</code>	本次請求 寫入 的 token(你付了約 1.25× 溢價)
<code>cache_read_input_tokens</code>	本次請求 從快取送出 的 token(你付了約 0.1×)
<code>input_tokens</code>	以 完整價格 處理的 token(未快取)

診斷法: 用相同前綴送出兩次請求。若第二次的 `cache_read_input_tokens` 為 0,代表有個**無聲失效因子**在兩次之間改變了前綴位元組。對算繪後的提示做 diff 來找出它。常見元兇:

模式	為何破壞快取
系統提示裡的 <code>datetime.now()</code> / <code>time.time()</code>	前綴每次請求都改變
內容前段的 <code>uuid4()</code> / 請求 ID	同上 —— 每次請求的位元組都獨一無二
未加 <code>sort_keys=True</code> 的 <code>json.dumps(d)</code> ,或迭代一個 <code>set</code>	非確定性序列化 → 前綴位元組每次都不同
把會話/使用者 ID 插進 <code>system</code> 提示	變成每使用者的前綴 —— 無法跨請求、跨使用者共享
條件式系統區段(<code>if flag: system += ...</code>)	每種旗標組合都是不同前綴
每使用者變動的工具集(<code>tools=build_tools(user)</code>)	工具在位置 0 算繪 —— 跨使用者什麼都不快取

失效層級值得內化,因為並非每個改變都是致命的。快取有三層(tools、system、messages),而一個改變只會讓它自己這層及以下失效:

- 改變**工具定義**(新增/移除/重排)或**切換模型** → 讓**全部**失效(完整重建)。
- 改變**系統提示** → 讓 system + messages 失效,但 tools 存活。
- 改變**訊息內容**、`tool_choice`、影像,或切換 `thinking` → 只讓 messages 層失效;tools + system 存活。

所以你可以每請求切換 `tool_choice` 或切換 `thinking`,而不會失去昂貴的 tools+system 快取。要拚命守住的兩個改變是**工具集編輯**與會話途中的**模型切換** —— 兩者都會丟棄整個快取。

18.5 代理的快取策略:穩定前綴

代理是理想的快取工作負載,因為它恰好具備快取所獎勵的結構:一個**龐大、穩定的前綴**(冗長的系統提示加上固定的工具目錄),後面接著一段不斷增長的對話。策略如下:

1. **凍結系統提示。** 絕不把「current date: X」、「user: Y」或「mode: Z」插進去 —— 那些會落在前綴前段,讓其後一切失效。把動態上下文放在**較後面**的 `messages` 裡注入。
2. **以確定性方式序列化工具。** 把工具定義按名稱排序,讓算繪後的位元組每次都一致。用一個放在最後一個 `system` 區塊上的中斷點,把 `tools + system` 一起快取。
3. **逐步快取對話。** 在最近一輪的最後一個區塊上放一個中斷點;每次新請求都重用整段先前的對話前綴,而較早的中斷點仍是有效的讀取點,因此命中會隨對話增長而累積。

但代理也製造三個經典的**失效因子**,每個都有特定的變通做法:

```
flowchart TD
    P[已快取的前綴<br/>system 加 tools] --> Q{代理在會話途中<br/>需要改變什麼?}
    Q -->|注入一條操作者指令| R[把一條 role system 訊息附加到 messages<br/>不要編輯頂層 system]
    Q -->|為某子任務跑較便宜的模型| S[在該模型上生成子代理<br/>主迴圈維持單一模型]
    Q -->|發現新工具| T[使用 tool search<br/>結構描述是附加,而非替換]
    R --> U[已快取前綴維持完整]
    S --> U
    T --> U
```

- **會話途中的操作者指令。** 編輯頂層 `system` 提示會改變**整段**對話歷史前方的前綴 —— 每個已快取的輪次都會以未快取方式重新處理。改成:在支援的模型上(Claude Opus 4.8)把一條 `{"role": "system", ...}` 訊息附加到 `messages[]`:它坐落在已快取歷史**之後**,讓前綴維持完整,並帶有無法偽造的操作者權限(這是把指令嵌進使用者輪次的「防提示注入」替代方案)。
- **會話途中切換模型。** 快取以模型為範圍。若某子任務想要較便宜的模型,別切換主迴圈 —— 在該模型上生成一個**子代理**,讓主對話維持單一模型(這正是 Claude Code 的 Explore 子代理使用 Haiku 的方式)。
- **會話途中新增工具。** 新增或移除工具會讓一切失效。若你需要隨需工具,使用 **tool search** —— 它會附加發現到的結構描述,而非替換工具清單,從而保留既有前綴。

兩個關於扇出(fan-out)的時序事實。 一個快取項只有在第一個回應**開始串流之後**才變得可讀 —— 因此 N 個帶有相同前綴的平行請求全都付完整寫入價(沒有任何一個能讀到其他人還在寫的東西)。送出一個請求,等它的第一個串流 token,然後再發出其餘 N-1 個。而為了消除第一個真正請求上的冷啟動延遲,用啟動時的 `max_tokens: 0` 請求**預熱(pre-warm)**:API 會執行 `prefill`、在你的中斷點寫入快取,並立即以空內容回傳 —— 若流量有間隔,就在 TTL 即將到期前再次預熱。

18.6 端到端案例研究:快取最佳化客服代理

這些元件唯有組合在一起才有意義。以下是一個真實的代理,其經濟成本由一個龐大穩定的前綴主宰 —— 正是快取把「負擔不起的設計」變成「便宜設計」的那種形狀。

需求

- 一個客服代理,帶有**龐大、穩定的系統提示**(約 6K token 的政策、語氣與升級規則)以及一個**固定的工具目錄**(`get_customer`、`lookup_order`、`search_kb`、`escalate`)。
- 它服務**高請求量** —— 每分鐘有許多短對話打在相同前綴上。
- 每次請求都必須為可觀測性注入**目前時間**與一個**每請求追蹤 ID(trace ID)**,外加會變的客戶問題。
- 每日指標工作必須用一次獨立的模型呼叫**摘要每段已結案的對話**。

天真的做法把時間戳與追蹤 ID 插進系統提示標頭,並在每次請求重建工具清單。那種設計**什麼都不快取**:前綴每次呼叫都不同,於是那 6K 政策 token 的每一個都在每一輪以完整價格重新計費。

架構

```
flowchart TD
    Req([傳入的請求]) --> Build[組裝提示]
    Build --> Tools[tools<br/>按名稱排序,凍結]
    Tools --> Sys[system<br/>6K 凍結政策<br/>cache_control 放這裡]
    Sys --> Hist[messages<br/>先前的輪次<br/>最後一個區塊放 cache_control]
    Hist --> Vol[易變尾段<br/>時間、trace id、新問題]
    Vol --> API[messages.create]
    API --> Chk{cache_read_input_tokens<br/>是否大於 0?}
    Chk -->|是| Hit[快取命中<br/>政策以約 0.1x 送出]
    Chk -->|否| Miss[稽核無聲失效因子]
```

順序就是整個設計:**凍結的 tools 與 system 放最前面,易變的時間/trace/問題 放最後**。放在最後一個 system 區塊上的中斷點把 tools + 6K 政策一起快取;放在最後一個對話區塊上的第二個中斷點讓多輪對話得以重用歷史。

實作

把請求建構成讓每個易變值都落在已快取前綴**之後**,絕不放進其中:

```
SYSTEM = [{
    "type": "text",
    "text": POLICY_PROMPT,
    "cache_control": {"type": "ephemeral"},
}]

TOOLS = sorted(tool_defs, key=lambda t: t["name"]) # 確定性順序 — 沒有 set/dict 抖動

def handle(turn_history, question, trace_id):
    # 易變上下文放在最後一個 user 區塊,在已快取前綴之後 —
    # 絕不插進 POLICY_PROMPT。
    user_block = {
        "type": "text",
        "text": f"[time={now_iso()} trace={trace_id}]\n{question}",
    }
    messages = turn_history + [{"role": "user", "content": [user_block]}]
    return client.messages.create(
        model="claude-opus-4-8",
        max_tokens=1024,
        tools=TOOLS,
        system=SYSTEM,
        messages=messages,
    )
```

當操作者需要在會話途中推送一條指令(例如「VIP 客戶 —— 跳過加購」),**不要編輯** POLICY_PROMPT。把一條 system 角色訊息附加在已快取歷史**之後**,讓那 6K 前綴永遠不被動到:

```

messages = turn_history + [
    {"role": "user", "content": [user_block]},
    {"role": "system", "content": "VIP account – resolve directly, do not offer upsells."},
] # Opus 4.8:不需 beta header;保留已快取前綴

```

至於每日摘要器,**fork 必須重用父請求的確切前綴**——逐字複製 `system`、`tools` 與 `model`,只附加摘要指令,否則該指標工作會完全錯過快取,並對每段對話重新計費 6K token:

```

summary = client.messages.create(
    model="claude-opus-4-8", # 與線上代理相同的模型
    max_tokens=512,
    tools=TOOLS, # 相同的 tools,位元組一致
    system=SYSTEM, # 相同的 6K 前綴 → 讀取溫熱的快取
    messages=closed_convo + [{"role": "user", "content": "Summarize this conversation in 3 bullets."}],
)

```

執行軌跡

```

sequenceDiagram
    actor U as 使用者
    participant A as 代理框架
    participant C as Claude API
    participant Cache as 前綴快取
    U->>A: 這波爆量的第一個問題
    A->>C: tools 加 system 6K 加 問題
    C->>Cache: 寫入前綴,1.25x
    C-->>A: 回應,cache_creation 約 6K
    U->>A: 第二個問題,相同前綴
    A->>C: tools 加 system 6K 加 新問題
    C->>Cache: 讀取前綴,0.1x
    C-->>A: 回應,cache_read 約 6K
    A->>A: 斷言 cache_read 大於 0

```

一波爆量的第一個請求付 1.25× 寫入;TTL 內其後的每個請求都在那 6K 政策區段上付 0.1×。在高流量下,寫入成本會攤平到數百次讀取上——政策前綴的穩態成本崩落到約莫天真設計的十分之一。

驗證

- **快取命中測試:** 送出兩次相同前綴的請求;斷言第二次的 `cache_read_input_tokens > 0`。這是該代理成本最重要的單一回歸測試。
- **失效因子防護:** 在單元測試中快照算繪後的 `tools` + `system` 位元組,並在它們意外改變時讓建置失敗——這能在一個漏掉的 `datetime.now()` 或被重排的工具於正式環境悄悄讓帳單翻倍之前就抓到它。
- **fork 重用測試:** 斷言摘要器的 `system` / `tools` / `model` 與線上代理的位元組一致,使它讀取而非重寫。

常見陷阱

- 把時間戳/追蹤 ID 插進系統提示的最上方而非易變尾段(\$18.1)—— 經典的無聲失效因子。
- 用 `dict / set` 重建工具清單,使其順序在請求間漂移(\$18.4)—— 工具在位置 0 算繪,因此這會讓一切失效。
- 為了注入會話途中的指令而編輯系統提示,而非附加一條 `role: "system"` 訊息(\$18.5)—— 以未快取方式重新計費整段歷史。
- 摘要器 fork 使用不同的 `model` 或被裁剪的 `system`,錯過父快取(\$18.5)。
- 在沒有可重用前綴時還快取 —— 付了 1.25× 寫入卻零讀取(\$18.3)。

18.7 實用知識 —— 關鍵整理

概念	該記住什麼
前綴比對不變式	快取是前綴比對;任何位置一個位元組改變,其後全部失效。算繪順序是 <code>tools</code> → <code>system</code> → <code>messages</code> —— 穩定內容在前、易變在後(\$18.1)。
中斷點與 TTL	<code>cache_control: {type: "ephemeral"} = 5 分鐘</code> ;爆量間隔加 <code>ttl: "1h"</code> 。最多 4 個中斷點;Opus 4.8 上最小前綴 4096 token,否則無聲不快取(\$18.2)。
成本模型	讀約 0.1×、寫 1.25×(5m)/ 2×(1h)。回本約 5m 下 2 次請求、1h 下 3 次。快取一個未被再用的前綴比不快取還貴(\$18.3)。
驗證	用 <code>usage.cache_read_input_tokens</code> 確認;在相同前綴間為 0 代表有無聲失效因子 (<code>datetime.now()</code> 、未排序的 <code>json.dumps()</code> 、會變的工具集)(\$18.4)。
代理前綴	凍結 <code>system</code> 、排序 <code>tools</code> 、把它們一起快取;會話途中的上下文透過 <code>role: "system"</code> 訊息注入;絕不在對話途中換工具或換模型(\$18.5)。

超出考綱,但在上線時不可或缺。Foundations 考試只要求你知道提示快取存在。但對任何帶有龐大穩定 `system` + `tools` 前綴的代理而言,快取命中測試(`cache_read_input_tokens > 0`)正是區分「可行的上線代理」與「在重新處理的上下文上悄悄失血」的成本可靠性檢查。

第 19 章:結構化輸出與 Strict Tool Use

參考 —— 超出考綱(考試涵蓋 `tool_use` JSON 結構描述;這是正式功能)。文件:[Structured outputs](#) | [Tool use](#)。

當代理的輸出是給人看的,「大致正確的 JSON」就夠用了 —— 人能容忍多出來的 `Here is the JSON:` 前言或一個多餘的逗號。但當輸出是給另一支程式讀的,這種容忍度就消失了:一個格式不對的字元就代表一次 `json.loads()` 例外、一筆掉落的紀錄,或一次被汙染的下游寫入。本章談的是如何把模型的回應變成一份契約 —— 一個你的程式碼不必靠防禦性字串處理就能解析的酬載,每一次都成立,並能在正式環境的規模下成立。

這是進階的、正式環境工程的內容。基礎考試在領域 4 —— 提示工程與結構化輸出(20%)測的是原則: `tool_use` 搭配 JSON 結構描述是保證符合結構描述輸出的最可靠方式、`tool_choice` 操控是否呼叫工具以及呼叫哪個工具,以及那個反覆出現的陷阱 —— 結構描述修的是語法,不是語意。第 2 章把

`tool_use` 結構描述當作機制介紹;本章涵蓋兩個**正式、強制的**功能,它們取代了只靠提示的「請以 JSON 回應」——**結構化輸出與 strict tool use**——加上驗證/重試層,以及考試碰不到但正式環境一定碰到的快取與 citations 取捨。

讀完本章你應該能:為某个工作挑選正確的強制機制、設計一個能**防止**(而非招來)捏造的結構描述、用一層驗證器把結構描述抓不到的問題包起來,並能推理出在这一切之上仍會殘留的失效模式。

19.1 「把它變成 JSON」的三個層級

這裡有一道可靠性的階梯,而考試最愛的錯誤答案永遠是低一階的那個。

```
flowchart TD
    Need[需要 Claude 產出<br/>機器可讀的輸出] --> Q1{模型是在呼叫函式<br/>還是在回傳答案?}
    Q1 -->|呼叫函式| Strict[Strict tool use<br/>在工具上設 strict true<br/>第 19.3 節]
    Q1 -->|最終答案須為 JSON| S0[結構化輸出<br/>output_config.format<br/>第 19.2 節]
    Need --> Q2{已經有一個純提示<br/>在要求 JSON 嗎?}
    Q2 -->|有| Weak[只靠提示 — 多數時候有效,<br/>但不是保證]
    Weak -- 升級 --> Strict
    Weak -- 升級 --> S0
    Strict --> Val[驗證語意<br/>並重試<br/>第 19.4 節]
    S0 --> Val
    Val --> Ship[給下游系統的<br/>可解析契約]
```

- **層級 0 —— 只靠提示。**「請以符合此形狀的 JSON 回應。」模型**通常**會照做,但沒有任何東西能阻止前言、markdown 圍欄、多餘逗號或多出來的欄位。寫一次性腳本沒問題;放進管線就是負債。在 Claude Opus 4.6 之後,這也正是 **assistant prefill** 過去用來打補丁的那條路(`{"role": "assistant", "content": "{}"}`) —— 而 prefill 現在會 **400**,所以這根只靠提示的拐杖已經沒了。下面的正式功能就是替代品。
- **層級 1 —— 強制形狀。**結構化輸出(§19.2)或 strict tool use(§19.3)。API 會**約束解碼(constrained decoding)**,使輸出在建構上就符合結構描述。沒有前言、沒有圍欄、沒有缺漏欄位。
- **層級 2 —— 驗證過的意義。**結構描述保證 JSON 能**解析**且欄位**存在**;它不保證數字是對的。§19.4 加上一層檢查語意、並把具體錯誤回饋後重試的機制。

那個反覆出現的考題診斷 —— 「模型的 JSON 有時無法解析,單一最可靠的修正是什麼?」 —— 答案就是從層級 0 移到層級 1。後續問題 —— 「JSON 能解析,但某個總額是錯的,為什麼更嚴格的結構描述沒修好?」 —— 就是層級 1 → 層級 2 的區別。

19.2 結構化輸出 —— 約束回應

結構化輸出會約束模型的最終回應符合一個 JSON 結構描述。你在請求上掛 `output_config.format`,回來的文字區塊就保證是符合結構描述的 JSON —— API 使用約束解碼,所以一個無效的 token 從一開始就不會被產生。

```

response = client.messages.create(
    model="claude-opus-4-8",
    max_tokens=1024,
    messages=[{"role": "user", "content": "Extract the invoice fields: ..."}],
    output_config={
        "format": {
            "type": "json_schema",
            "schema": {
                "type": "object",
                "properties": {
                    "number": {"type": "string"},
                    "total": {"type": "number"},
                },
                "required": ["number", "total"],
                "additionalProperties": False,
            },
        },
    },
)
# output_config.format 保證第一個區塊是含有效 JSON 的文字
import json
data = json.loads(next(b.text for b in response.content if b.type == "text"))

```

優先用 `client.messages.parse()` —— 它接受一個 Pydantic 模型(TypeScript 則是 Zod 結構描述),送出衍生出的結構描述,對回應做驗證,並回傳一個型別化物件。你省去手動 `json.loads`,並得到一個 IDE 看得懂的實例:

```

from pydantic import BaseModel

class Invoice(BaseModel):
    number: str
    total: float

msg = client.messages.parse(
    model="claude-opus-4-8",
    max_tokens=1024,
    messages=[{"role": "user", "content": "擷取發票欄位: ..."}],
    output_format=Invoice,          # 回應被約束符合此結構描述
)
invoice = msg.parsed_output        # 已驗證的 Invoice 實例

```

API 注記。 標準的請求層級參數是 `output_config.format`。 `messages.create()` 上舊的頂層 `output_format` 參數已棄用 —— 但 `.parse()` 仍接受 `output_format=<Model>` 作為它的便利引數,這就是上面兩種寫法都出現的原因。支援於 Claude Fable 5、Opus 4.8、Sonnet 4.6 與 Haiku 4.5(以及舊版 Opus 4.5/4.1)。

為何勝過只靠提示。 在層級 0,模型是自由的 —— 它可以判斷加段友善的前言會有幫助、為了「可讀性」把 JSON 包進圍欄,或省略它認為不相關的欄位。約束解碼在 token 層級拿掉了這份自由:你的結構描述的文法,是解碼器唯一能產生的東西。

19.3 Strict Tool Use —— 約束呼叫

Strict tool use 是第 2 章 `tool_use` 結構描述的強制版。在工具定義上設 `strict: true`，模型的 `tool_use.input` 就保證**完全**符合該工具的 `input_schema`：

```
response = client.messages.create(
    model="claude-opus-4-8",
    max_tokens=1024,
    messages=[{"role": "user", "content": "Book a flight to Tokyo for 2 on March 15"}],
    tools=[{
        "name": "book_flight",
        "description": "Book a flight to a destination",
        "strict": True,                # 強制開關
        "input_schema": {
            "type": "object",
            "properties": {
                "destination": {"type": "string"},
                "date": {"type": "string", "format": "date"},
                "passengers": {"type": "integer"},
            },
            "required": ["destination", "date", "passengers"],
            "additionalProperties": False,    # strict 下為必填
        },
    }],
)
```

考試周邊文件反覆強調的兩個要求：在 `strict: true` 下，結構描述**必須**設 `additionalProperties: false`，且把每個欄位都列進 `required`。最常見的錯誤是把 `strict` 放到 `tool_choice` 上 —— 放在那裡沒有作用。**** `strict` 是工具定義本身上 `name` / `description` / `input_schema` 的同級欄位。 ****

用 `tool_choice` 操控

`tool_choice` 決定**是否以及呼叫哪個工具** —— 與決定**呼叫被驗證得多嚴格的** `strict` 互相正交：

<code>tool_choice</code>	行為	何時用
<code>{"type": "auto"}</code> (預設)	模型可回傳散文 或 呼叫工具	這一回合本來就可能不需要工具
<code>{"type": "any"}</code>	模型 必須 呼叫其中一個工具 (它挑)	你想要保證結構化輸出,且存在多個結構描述
<code>{"type": "tool", "name": "extract"}</code>	模型 必須 呼叫那個特定工具	你永遠想要回來同一個特定形狀
<code>{"type": "none"}</code>	模型 不能 呼叫工具	這一回合強制散文

考試埋的陷阱: 強制工具(`any` 或具名工具)代表模型**永遠**會呼叫某個東西 —— 所以被強制的工具必須**無條件呼叫都安全**。絕不要為了逼出結構而強制有副作用的工具(`send_email`、`process_payment`);改成強制一個**擷取/格式化工具**,讓那個不可逆的動作交給 `auto` 回合決定。還有一個比較安靜的後果:**強制特定工具會關閉那一回合的 `extended thinking`** —— 模型會直接跳去填結構描述。

結構化輸出 vs strict tool use —— 用哪個、何時用

```
flowchart TD
    Start[模型需要產出什麼?] --> A{由我的執行框架<br/>執行的函式呼叫?}
    A -->|是| Tool[Strict tool use<br/>讀 tool_use.input]
    A -->|不是| 最終答案| B{最終答案是<br/>結構化資料嗎?}
    B -->|是| Resp[結構化輸出<br/>讀文字區塊]
    B -->|不是| 自由散文| Plain[純 messages,<br/>不加約束]
    Tool --> Compose[兩者可並用 — 一回合可同時<br/>強制工具 並 約束最終文字區塊]
    Resp --> Compose
```

判斷準則:模型該呼叫函式時用 **strict tool use**;模型的最終答案須為 **JSON** 時用**結構化輸出**。兩者可在一個請求裡並用 —— 強制一個擷取工具並約束收尾的文字區塊 —— 這正是下面案例研究的模式。

19.4 結構描述修語法,不修語意 —— 驗證與重試

這是本章承重的告誡,也是考試最銳利的區別。一個 strict 結構描述保證:

- 輸出能**解析**(沒有語法錯誤),
- 每個 `required` 欄位都**存在**,
- 每個欄位都是**宣告的型別**。

它對正確性**毫無保證**: `total` 是 `1200.00` 是個合法的 `number`,無論明細是否真的加起來等於 `1200`。一個日期可以落在錯誤的欄位裡卻仍是格式正確的 `date` 字串。**語法是結構性的;語意不是** —— 而且沒有任何結構描述功能能補上這道縫隙,因為結構描述語言刻意省略了能幫上忙的那些約束(見 §19.5)。

正式環境的模式是**先驗證、再帶錯誤回饋重試**:

```
flowchart TD
    Ext[以 strict tool use<br/>或結構化輸出擷取] --> Val{語意檢查通過?<br/>總額對得起來、<br/>欄位格式正確}
    Val -->|是| Accept[接受 — 送出<br/>可解析契約]
    Val -->|否| Src{所需的值<br/>有在來源裡嗎?}
    Src -->|有 — 可修正| Retry[帶上文件、那筆錯誤的擷取、<br/>以及那個 具體 錯誤重試]
    Retry --> Ext
    Src -->|沒有 — 來源中不存在| Stop[停止重試 — 回傳 null、<br/>標記給人工、<br/>或抓取外部紀錄]
```

有兩個設計手法讓這套機制成立:

1. **把檢查內建進結構描述**。同時擷取 `stated_total` (文件上印的數字)和 `calculated_total` (模型自己對明細的加總),然後在**程式碼裡**比對兩者。不一致就是一個你能據以行動的對帳錯誤 —— 而且這遠比事後問模型「這對嗎?」可靠。
2. **回饋那個具體錯誤,而不是「再試一次」**。一次說「*stated_total* 是 1200 但明細加起來是 1180 —— 重新檢查明細」的重試能引導出真正的修正。一句光禿禿的「剛剛錯了」是在浪費一次往返。

區分層級的陷阱:重試無法憑空生出不存在的資料。如果某個欄位根本不在來源裡 —— 文件從未寫出統一編號、數字只存在於外部系統 —— 重試只是燒 token,而且可能逼模型**捏造**一個看似合理的值。正確做法是**辨**

認出缺資料的情況並停手:回傳 `null`、標記給人工,或抓取外部紀錄。重試修的是 *可修正* 的錯誤;它修不了缺失的資訊。

19.5 結構描述限制、快取與 Citations —— 正式環境的取捨

這些強制功能帶著一些考試沒涵蓋、但你第一次上線就會冒出來的限制。

結構描述限制(約束解碼)。 你能強制的 JSON Schema 是完整 JSON Schema 的一個子集:

- **支援:** 基本型別、`enum`、`const`、`anyOf` / `allOf`、`$ref` / `$defs`,以及字串 `format` (`date-time`、`date`、`email`、`uri`、`uuid`、...)。
- **不支援:** 遞迴結構描述、數值約束(`minimum` / `maximum` / `multipleOf`),以及字串長度約束(`minLength` / `maxLength`)。 `additionalProperties` 必須為 `false`。

省略數值/長度約束正是 §19.4 存在的原因:你無法在強制結構描述裡表達「total 必須為正」或「code 必須是 5 個字元」,所以那些檢查住在你的驗證器裡。(Python 與 TypeScript SDK 會悄悄從送上線的結構描述剝掉不支援的關鍵字,並在客戶端重新檢查,這軟化了邊角,但並沒有把保證搬到模型身上。)

結構描述編譯與快取。 一個新的結構描述在首次請求時會付一次性的**編譯成本**;編譯後的文法接著**快取 24 小時**,所以穩態請求不再多付。對高吞吐擷取服務的實務含義:讓你的結構描述**保持穩定**。一個每次請求都用重排的鍵或內插值重建的結構描述,每次看起來都「是新的」,於是重複付編譯成本 —— 這跟 prompt caching 要求的穩定紀律是同一回事(第 18 章)。

與 citations 不相容。 結構化輸出(`output_config.format`)與 **citations 互斥** —— 在同一個請求裡對文件開 `citations: {enabled: true}` 並設 `output_config.format` 會回 **400**。架構上的後果是實在的:如果一個工作既需要機器可解析的形狀又需要逐項來源歸屬,你無法從一次呼叫同時拿到兩者。把它拆開 —— 第一趟擷取帶 citation 的事實(開 citations,不加格式約束),第二趟把已驗證的事實塑成契約(加格式約束,不開 citations) —— 或把結構搬進一個 strict 的**工具呼叫**,工具呼叫不受 citations 限制約束。

其他值得知道的邊角: `stop_reason` 為 `"refusal"` 或 `"max_tokens"` 代表即使功能開著,回傳的內容也**可能**不符合你的結構描述 —— 在信任解析結果之前永遠先檢查 `stop_reason`。結構化輸出**可以**與 Batches API、串流、token 計數與 extended thinking 一起運作。

19.6 端到端案例研究:發票到分類帳的擷取服務

零件唯有組裝起來才有意義。這裡是一個務實的服務,它吃進掃描的廠商發票,並把分類帳分錄寫進一套會計系統 —— 典型的「輸出是給程式而非給人讀」的工作,在這裡一個壞欄位就會汙染帳冊。

需求

- 吃進發票 PDF,並送出會計 API 能直接 `POST`、完全不必字串清理的**嚴格型別分類帳紀錄**。
- **硬契約:** 下游 API 會拒絕任何不符合結構描述的東西,所以可解析的形狀沒有商量餘地。
- **對帳**所述的發票總額與明細加總;不一致必須被攔下,而不是被寫入。
- 當某欄位在掃描中**不存在**(例如沒印 PO 號),記成 `null` 並標記給人工審查 —— 絕不捏造。
- 稽核軌跡需要來源歸屬(每個數字來自 PDF 哪一行) —— 但與嚴格紀錄**分開**進行,因為 citations 與結構化輸出不能共存。

架構

```
flowchart TD
    PDF([廠商發票 PDF]) --> Extract[擷取趟<br/>強制 extract_invoice 工具<br/>strict 結構描述]
    Extract --> Parse[解析 tool_use.input<br/>保證符合結構描述]
    Parse --> Recon{對帳<br/>stated vs calculated total}
    Recon -->|相符| Ledger[建立分類帳紀錄<br/>POST 到會計 API]
    Recon -->|不符且值存在| Retry[帶上那個具體<br/>對帳錯誤重試]
    Retry --> Extract
    Recon -->|欄位在掃描中不存在| Human([標記給人工審查])
    Extract -. 另一趟帶 citation .-> Cite[Citations 趟<br/>供稽核軌跡]
```

strict 擷取工具承載契約;**程式碼**做結構描述做不到的對帳;**缺資料分支**把流程導向人工而非導向幻覺;而**稽核軌跡**跑成另一次帶 **citation** 的呼叫,正是因為 §19.5 禁止在一個請求裡同時用 citations + 結構化輸出。

實作

把擷取定義成一個 **strict 工具**,用 `tool_choice` 強制它,並讓模型同時送出**兩個**總額,好讓程式碼去對帳:

```

extract_invoice = {
  "name": "extract_invoice",
  "description": "Extract structured fields from a vendor invoice.",
  "strict": True,
  "input_schema": {
    "type": "object",
    "properties": {
      "invoice_number": {"type": "string"},
      "po_number": {"type": ["string", "null"]},      # nullable — 部分發票沒有
      "currency": {"type": "string"},
      "line_items": {
        "type": "array",
        "items": {
          "type": "object",
          "properties": {
            "description": {"type": "string"},
            "amount": {"type": "number"},
          },
          "required": ["description", "amount"],
          "additionalProperties": False,
        },
      },
      "stated_total": {"type": "number"},            # 發票上印的數字
      "calculated_total": {"type": "number"},        # 模型自己對 line_items 的
    },
    "required": ["invoice_number", "po_number", "currency",
                  "line_items", "stated_total", "calculated_total"],
    "additionalProperties": False,
  },
}

加總

response = client.messages.create(
  model="claude-opus-4-8",
  max_tokens=2048,
  messages=[{"role": "user", "content": [
    {"type": "document", "source": {"type": "base64",
                                     "media_type": "application/pdf", "data":
pdf_b64}},
    {"type": "text", "text": "Extract every field. If the PO number is not
printed, return null."},
  ]}],
  tools=[extract_invoice],
  tool_choice={"type": "tool", "name": "extract_invoice"},    # 保證會有結構化呼叫
)

```

注意兩個防止捏造的結構描述設計選擇: `po_number` 是 **nullable**, 所以缺值有個合法的歸宿(一個 **required** 的非 nullable 欄位會逼模型發明一個), 而明確的 `instruction` 又強化了走 null 那條路。對帳邏輯住在**程式碼**裡, 不在提示裡:

```
def reconcile(extraction) -> "Result":
    items_sum = round(sum(li["amount"] for li in extraction["line_items"]), 2)
    if abs(items_sum - extraction["stated_total"]) > 0.01:
        # 結構描述抓不到的語意錯誤 — 帶上那個 具體 差異重試。
        return Result.retry(
            reason=f"stated_total is {extraction['stated_total']} but line items "
                f"sum to {items_sum} — recheck the line items"
        )
    if extraction["po_number"] is None:
        # 缺資料 — 不要 重試(會招來捏造的 PO)。導向人工。
        return Result.flag_for_human(extraction, missing="po_number")
    return Result.accept(extraction)
```

執行軌跡

```
sequenceDiagram
    actor Op as 匯入 worker
    participant Cl as Claude
    participant V as 驗證器(程式碼)
    participant Led as 會計 API
    participant Hu as 人工審查員
    Op->>Cl: 發票 PDF 加 extract_invoice 工具, tool_choice 強制它
    Cl-->>Op: tool_use.input — 符合結構描述, stated_total 1200, 明細加總 1180
    Op->>V: reconcile(extraction)
    V->>V: 1180 不等於 1200 — 不符
    V-->>Cl: 帶上「stated 1200 但明細加總 1180, 重新檢查明細」重試
    Cl-->>Op: 修正後的擷取 — 明細加總 1200, po_number 為 null
    Op->>V: reconcile(extraction)
    V->>V: 總額相符, 但 po_number 不存在
    V->>Hu: 標記審查 — 絕不捏造 PO
    V->>Led: POST 那筆符合結構描述的分類帳紀錄
```

注意分工: 約束解碼保證了形狀(worker 從沒對散文做過 `json.loads`), 程式碼抓住了結構描述抓不到的對帳錯誤, 而缺失的 PO 去了人工那裡, 而不是進到一個會逼出捏造值的重試迴圈。

驗證

- **契約測試:** 斷言每筆送出的紀錄都通過下游 API 結構描述的驗證 —— 並且 worker 從不對自由文字呼叫 `json.loads` (它直接讀 `tool_use.input`)。
- **對帳測試:** 餵一張所述總額故意算錯的發票; 斷言管線會帶上那個具體差異重試, 且不會寫入那筆壞紀錄。
- **缺資料測試:** 餵一張沒有 PO 號的發票; 斷言紀錄帶著 `po_number: null` 並被標記給人工 —— 且系統沒有重試(證明它能區分缺失與可修正)。
- **Citations 測試:** 斷言稽核軌跡那趟跑成另一次呼叫; 斷言在一個請求裡把 `citations` 與 `output_config.format` 結合會引發 400(證明那次拆分是必要的, 而非可選的)。

常見陷阱

- 把 `strict` 放在 `tool_choice` 而不是工具定義上(放那裡沒作用 —— §19.3)。
- 為了逼出結構而強制有副作用的工具; 改成強制擷取工具, 並把不可逆的寫入分開把關 (§19.3)。

- 把一次有效的解析當成一個正確的值 —— 跳過了對帳層(\$19.4)。
- 在資料根本不存在時還重試,招來捏造的值而非一個 `null` (\$19.4)。
- 把 `citations` 與 `output_config.format` 一起請求而吃到 400 —— 兩者互斥(\$19.5)。

19.7 重點整理

概念	該記住什麼
三個層級	只靠提示(機率性) → 強制形狀(結構化輸出 / strict tool use) → 驗證過的意義(重試)。可靠的修正是往上爬一階(\$19.1)。
結構化輸出	<code>output_config.format</code> 透過約束解碼把 最終回應 約束成一個結構描述;優先用 <code>messages.parse()</code> 取得已驗證的型別化物件。頂層的 <code>output_format</code> 已棄用(\$19.2)。
Strict tool use	在 工具 上(不是 <code>tool_choice</code>)設 <code>strict: true</code> ,保證 <code>tool_use.input</code> 完全符合;需要 <code>additionalProperties: false</code> + 完整的 <code>required</code> (\$19.3)。
<code>tool_choice</code> 操控	<code>auto</code> (可用工具)/ <code>any</code> (必須用一個)/ 強制(必須用那一個)。強制永遠會呼叫某個東西並關閉 thinking —— 所以要強制 安全的擷取工具 ,絕不強制有副作用的工具(\$19.3)。
語法 vs 語意	結構描述保證 JSON 能解析且欄位存在;它 不 保證值正確。在程式碼裡驗證語意,並帶上那個 具體錯誤 重試(\$19.4)。
缺失 vs 可修正	重試修可修正的錯誤;它生不出不存在的資料。辨認缺失的情況,回傳 <code>null</code> / 標記給人工,而不是迴圈下去(\$19.4)。
結構描述限制	不支援遞迴、數值(<code>minimum</code> / <code>maximum</code>)或字串長度約束; <code>additionalProperties</code> 必須為 <code>false</code> —— 這正是仍需要一個程式碼驗證器的原因(\$19.5)。
快取與 citations	新結構描述編譯一次後快取 24 小時 —— 讓結構描述保持穩定。結構化輸出與 citations 不相容 (400);當你兩者都需要時,拆成兩趟(\$19.5)。

對應領域 4(20%) 的核心原則 —— `tool_use` + JSON Schema 是可靠的結構化輸出機制、`tool_choice` 操控它,而結構描述修語法不修語意。正式的 `output_config.format` / `strict: true` 功能、24 小時結構描述快取,以及 citations 不相容,都是超出考試的正式環境精修 —— 但它們所處的「先驗證、再重試」紀律,正是領域 4 在測的同一套。

第 20 章:伺服器端與進階工具

參考 —— 超出考綱。文件:[Tool use overview](#) · [Server tools](#) · [Web search](#) · [Code execution](#)。

在第 2–4 章,你建構的是**用戶端工具**:你寫一份 JSON 結構描述,Claude 發出 `tool_use` 區塊,由**你的**程式碼執行它,再回傳 `tool_result`。這一來一回是考試的基礎。然而上線的代理還會用上第二類工具——考綱幾乎不碰,卻會重塑成本、延遲與安全性的——**伺服器端工具**:由 Anthropic 在**API 回合內部**、在 Anthropic 自家基礎設施上執行,你的應用程式裡完全沒有處理程式碼。

這個區別並非表面文章。它改變了**誰執行程式碼**、**資料流向何處**、**回合形狀如何構成**,以及**你要付多少錢**。本章是寫給必須回答以下問題的架構師:這項能力該做成由我託管的工具,還是由 Anthropic 託管?以金錢、資

料留存風險與控制權來衡量,兩種選擇各要付出什麼代價?

- **兩種執行模型**(§20.1)—— 用戶端工具(`stop_reason: "tool_use"` ,你執行)對比伺服器端工具(`server_tool_use` ,Anthropic 執行,你不回傳 `tool_result`)。
- **伺服器端工具目錄**(§20.2)—— `web search`、`web fetch`、`code execution`、`tool search`、`advisor`。
- **Anthropic 結構描述的用戶端工具**(§20.3)—— `bash`、`text editor`、`computer use`、`memory`:結構描述已公布,但仍由你執行。
- **伺服器端迴圈、 `pause_turn` 與混合回合**(§20.4)—— 唯一一個會讓所有人意外的控制流程。
- **成本與安全取捨**(§20.5)—— 計費表、ZDR、沙箱邊界、網域過濾。

§20.6 接著建構一個完整的**合規研究助理**,在單一回合內混用伺服器端與用戶端工具,§20.7 則濃縮工程判斷。

20.1 兩種執行模型:誰執行程式碼

你給 Claude 的每個工具都屬於兩類之一,而區分它們的**唯一**關鍵是**程式碼在哪裡執行**。

```
flowchart TD
    Start[把工具加進 tools 陣列] --> Q{誰執行它?}
    Q -->|你的應用程式| Client[用戶端工具]
    Q -->|Anthropic 基礎設施| Server[伺服器端工具]
    Client --> C1[Claude 發出 tool_use<br/>stop_reason 為 tool_use]
    C1 --> C2[你的程式碼執行它<br/>你回傳 tool_result]
    C2 --> C3[下一個請求繼續迴圈]
    Server --> S1[Claude 發出 server_tool_use<br/>id 前綴為 srvttoolu]
    S1 --> S2[Anthropic 在回合內部執行它]
    S2 --> S3[結果區塊在同一回合回傳<br/>你不回傳 tool_result]
```

用戶端工具——包含你自訂的工具以及 `bash`、`text_editor` 這類 Anthropic 結構描述的工具——會產生 `tool_use` 區塊與 `stop_reason: "tool_use"`。回合**停下**,控制權交回給你,你的程式碼執行該操作,你在下一個請求回傳 `tool_result`。執行、執行環境、網路與影響範圍都由你掌控。

伺服器端工具——`web_search`、`web_fetch`、`code_execution`、`tool_search`、`advisor`——會產生 `server_tool_use` 區塊,其 `id` 帶有 `srvttoolu_` 前綴。Anthropic 在**同一個助理回合內**、於自家基礎設施執行該工具,結果區塊(例如 `web_search_tool_result`)就出現在**同一個回應裡**,透過 `tool_use_id` 與呼叫配對。你永遠不必寫處理程式,也永遠不回傳 `tool_result`。

為何重要。 用戶端工具是你控制流程中的一道**接縫**——每次呼叫都是驗證、記錄、遮罩或阻擋的機會(這正是第 3 章 `hooks` 所在之處)。伺服器端工具則是在**你看到任何東西之前就執行到底的黑盒**。你以控制換取便利:沒有要託管的基礎設施,但也沒有可攔截呼叫的 `PreToolUse` `hook`。

20.2 伺服器端工具目錄

這五個全在 Anthropic 基礎設施執行;你只要在 `tools` 宣告它們即可啟用——不必部署其他東西。

工具	型別識別碼	功能
----	-------	----

Web search	<code>web_search_20250305</code> (基本)、 <code>web_search_20260209</code> +(動態過濾)	即時網路搜尋,附引用;結果帶有 <code>encrypted_content</code> ,在多輪對話中必須回傳。
Web fetch	<code>web_fetch_20250910</code> (基本)、 <code>web_fetch_20260209</code> +	擷取/解析特定 URL 或 PDF(通常是對話中已出現的)。
Code execution	<code>code_execution_20250825</code> (加 <code>_20260120</code> 、 <code>_20260521</code>)	沙箱 Python + bash 容器;預裝資料科學套件;容器可重用約 30 天。
Tool search	<code>tool_search_tool_regex</code> / <code>tool_search_tool_bm25</code>	從大型工具庫按需探索工具;其餘標 <code>defer_loading: true</code> ,其結構描述稍後以附加方式載入(保留 prompt 快取)。
Advisor	<code>advisor_20260301</code> (beta)	把較便宜的執行模型與較聰明的顧問模型配對,在生成中諮詢(顧問能力須 ≥ 執行模型)。

有兩組關係值得牢記:

- **Code execution 是「動態過濾」背後的引擎。** 使用 `web_search_20260209` +(或對應的 web fetch 版本)時,Claude 會寫程式碼,在原始搜尋結果進入上下文視窗之前先做後處理——只留下相關內容。這就是為何那些 web 工具版本會默默配置一個 code execution 容器,也是為何**code execution 與 web search 或 web fetch 併用時免費**。
- **tool_search 是為了規模而存在,不是為了功能。** 若代理可存取數百個工具,把每份結構描述都放進提示既昂貴又稀釋注意力。延遲載入其中大多數,讓 Claude 搜尋它需要的那幾個;探索到的結構描述以附加方式載入,因此較早的快取斷點得以保留(第 18 章)。

程式化工具呼叫(programmatic tool calling)—— Claude 從 code execution 內部呼叫你的工具。 動態過濾只是一個更通用能力的特例。把某個用戶端工具標上 `"allowed_callers": ["code_execution_20260120"]` ,Claude 就不再為每次呼叫走一趟模型往返:該工具會以一個 async Python 函式的形式暴露給它的沙箱程式碼。Claude 寫一支指令稿,多次呼叫該工具(透過 `asyncio.gather` 並行),在容器內過濾與彙整,只把精簡後的答案送回上下文視窗——稽核 20 份支出報告變成一支指令稿,而不是 20 個回合把每一筆明細都拖過上下文。在代理式搜尋基準上,Anthropic 量測到**準確率約高 11%、輸入 token 約少 24%**。機制上這是一個暫停的回合:當指令稿呼叫該工具時,code execution 會暫停,API 回傳 `stop_reason: "tool_use"` ,其 `tool_use` 區塊帶有 `caller` 欄位與一個 `container id` ;你仍要執行該工具並回傳 `tool_result` ——只放 `tool_result` 區塊、回傳該 `container id` 、重送同一個 `tools` 陣列(與 §20.4 相同的回合中紀律)——容器隨後恢復執行指令稿。需要 code execution 工具加上 `code_execution_20260120` +(Fable 5、Mythos 5、Opus 4.5+、Sonnet 4.5+);不符合 ZDR 資格。`allowed_callers` 會引導 Claude,但不是安全邊界——仍須準備好處理對同一工具的直接 `tool_use` 。

20.3 Anthropic 結構描述的用戶端工具(仍由你執行)

有一個微妙的中間類別會絆倒架構師:Anthropic 公布了結構描述,但執行呼叫的是你的應用程式。它們看似「內建」,行為卻像用戶端工具——`stop_reason: "tool_use"` ,由你執行,由你回傳 `tool_result` 。

- **Bash**(`bash_20250124`)與 **text editor**(`text_editor_20250728`)——無結構描述、由 Anthropic 訓練的工具,並附有參考實作。你提供 shell 與檔案系統。請沙箱化——它們會以你的處理程式授予的權限執行。
- **Memory tool**(`memory_20250818`)—— Claude 讀寫 `/memories` 目錄做跨工作階段狀態;後端由你實作(一個目錄、一個儲存桶或一個資料庫)。它是長時間代理背後的持久記憶基元(第 21 章)。

- **Computer use** —— 螢幕截圖加上滑鼠/鍵盤操控 GUI(beta)。你執行桌面環境,並重放 Claude 請求的動作。

陷阱。 `code_execution` (伺服器端)與 `bash / text_editor` (用戶端)看起來可以互換——兩者都「執行程式碼」。其實不然。伺服器端 `code_execution` 容器在 Anthropic 基礎設施執行,網路停用且無法存取你的系統。用戶端 `bash` 工具則在**你掌控的機器**上執行,使用你開放的網路與資料。若你同時啟用兩者,Claude 就處於多電腦環境而可能搞混它們;Anthropic 建議在系統提示加上一段說明,釐清狀態**不會**在兩者之間留存,且用戶端工具才是通往使用者本機系統的路徑。

20.4 伺服器端迴圈、`pause_turn` 與混合回合

這是文件反覆警告的唯一一段控制流程,也是最常見的上線錯誤。伺服器端工具在一個**伺服器端代理迴圈**裡執行:Claude 可以搜尋、讀結果、再搜尋,最後才寫出答案——全都在單一次 `messages.create` 呼叫之內。

有兩種情境會打破「一個請求、一個回應」的簡單心智模型:

1. **`pause_turn` —— 迴圈跑太久。** 在長時間回合(例如 `web_search` 配 `max_uses: 10`),API 可能暫停並回傳 `stop_reason: "pause_turn"`。修法很機械:在下一個請求裡把**剛收到的回應內容原樣回傳**(也就是你剛收到的那則助理訊息),並帶上**相同的 `tools` 陣列**。拿掉工具請求就會 400,因為暫停的回合可能結束在一個其工具尚未執行的 `server_tool_use` 區塊上。被延續的回合可能再次暫停——持續循環直到拿到不同的 `stop_reason`,並像任何重試迴圈一樣為延續次數設上限。

2. **混合伺服器端 + 用戶端回合 —— 是 `tool_use`,不是 `pause_turn`。** 若 Claude 在同一個平行群組裡呼叫了伺服器端工具**以及**你的某個用戶端工具,API **就不會執行**伺服器端工具。它會立即回傳 `stop_reason: "tool_use"`、一個**沒有結果的 `server_tool_use` 區塊**,以及你的用戶端 `tool_use` 區塊。你透過尋找沒有對應結果的 `server_tool_use` `id` 來偵測這個狀態。你執行你的用戶端工具,然後送出一則**只含 `tool_result` 區塊**的後續使用者訊息——別無其他。API 會把你的結果附到仍開啟的回合上,接著執行被延後的伺服器端工具,再繼續。

flowchart TD

```
Req[帶伺服器端與用戶端工具呼叫 messages.create] --> Resp[助理回應]
Resp --> Q{stop_reason?}
Q -->|end_turn| Done[完成 — 伺服器端工具已內聯執行]
Q -->|pause_turn| Re[原樣回傳回應<br/>相同 tools 陣列]
Re --> Req
Q -->|tool_use| Mix[出現用戶端 tool_use<br/>外加無結果的 server_tool_use]
Mix --> Exec[執行你的用戶端工具]
Exec --> Only[送出只含 tool_result 區塊的<br/>使用者訊息]
Only --> Req
```

要牢記的兩種失敗模式。 (a) 在後續訊息的 `tool_result` 區塊之後放任何東西——即使只是一個文字區塊——都會告訴 API 回合已結束,使被延後的伺服器端工具懸而未決 → 400。(b) 在延續請求中從 `tools` 陣列拿掉伺服器端工具 → 400(but no web_fetch tool was provided)。兩者都是「我在回合中途改變了對話形狀」的錯誤。

20.5 成本與安全取捨

伺服器端工具把工作移出你的基礎設施,卻引入用戶端工具沒有的**用量計費表**與**資料留存面**。

定價(在 token 之外另計):

工具	計費	備註
Web search	每 1,000 次搜尋 \$10	每次搜尋算一次,不論回傳幾筆結果。錯誤不計費。引用的 <code>cited_text / title / url</code> 不算 token;結果內容算。
Code execution	與 web search/fetch 併用免費;否則每月 1,550 小時免費,之後每容器每小時 \$0.05	每工作階段最低計 5 分鐘;若預載檔案,即使未呼叫也計費。
用戶端工具	僅標準 token	沒有用量計費——你託管的運算本來就要付費。

用 `max_uses` 來**確定性地**為 web search 成本設上限(研究代理可允許 15–20;延遲敏感的查詢設 3)。記住:每筆擷取到的搜尋結果在本回合及後續回合都會變成**輸入 token**——無上限的研究迴圈是一張 token 帳單,不只是搜尋帳單。

安全性與資料留存:

- **Code execution 沙箱是真正隔離的:** 網路**完全停用**、無對外請求、與主機及其他容器完全隔離、檔案系統限縮於你 API 金鑰的工作區、容器在 30 天後到期。Claude 寫的程式碼**無法外洩**到網路,也無法觸及你的系統。
- **ZDR(零資料留存)是那道利刃。** 基本的 `web_search_20250305` 與 `web_fetch_20250910` 符合 ZDR 資格。`_20260209` + 的動態過濾版本則**不符合**,因為它們內部用到 code execution——而 **code execution 永遠不符合 ZDR 資格**。要在 ZDR 下使用 2026 世代的 web 工具,你必須以 `"allowed_callers": ["direct"]` 停用動態過濾。這正是受資料留存合約約束的架構師必須明確攤開的取捨:動態過濾省下的 token,對上 ZDR 合規。
- **網域過濾是你給網路用的 ACL。** `allowed_domains` / `blocked_domains` (兩者擇一,絕不並用)管制 Claude 能觸及哪些網站。不含 scheme、自動納入子網域、主機名稱不可用 `*`。萬用字元。**只用 ASCII 網域**——`amazon.com` 裡的西里爾字母 `a` 是一種同形異義字攻擊,會溜過天真的允許清單。

20.6 端到端案例研究:合規研究助理

上述元件唯有在真實代理必須在**同一回合內**於託管與自託管執行之間做選擇時才有意義。以下是一家受監管公司的上線助理——在這種系統裡,「誰執行了程式碼、資料流向何處」是稽核問題,不是註腳。

需求

- 分析師以自然語言詢問某交易對手本季是否受任何**新制裁或負面媒體**影響,以及這與公司對該對手的**內部曝險**相比如何。
- 需要**即時網路研究**(制裁清單每天變動)——且它**只能**觸及一組核准的監理機關與通訊社網域。
- 公司的**曝險數字**存於**內部資料庫**,絕不能離開公司網路——所以那筆查詢是公司自託管的**用戶端工具**。
- 最終答案必須**計算**風險分數(曝險 × 嚴重度),並為每一項外部主張**附上引用**。

- 公司在網路研究這條路徑上負有**資料留存義務**。

架構

切分方式自需求自然導出:網路研究與數字運算是**伺服器端工具**(不必執行基礎設施、引用免費);曝險查詢是**用戶端工具**,因為資料具主權性。

```
flowchart TD
    Analyst([分析師]) --> App[應用程式 + API 呼叫]
    App --> Tools[tools 陣列]
    Tools --> Claude[Claude 回合]
    Claude --> WS[伺服器端工具 web_search<br/>allowed_domains 僅限監理機關]
    Claude --> CE[伺服器端工具 code_execution<br/>在沙箱算風險分數]
    Claude --> DB[用戶端工具 query_internal_db]
    WS -- 引用 + encrypted_content --> Claude
    CE -- 計算出的分數 --> Claude
    DB --> Handler[公司自託管處理程式<br/>位於網路內部]
    Handler -- tool_result 曝險 --> Claude
    Claude --> Answer[附引用的風險簡報]
```

`query_internal_db` 是公司**唯一**掌控的接縫——而這是刻意的:具主權的資料路徑正是必須留在用戶端的那一條,在那裡套用公司自己的驗證、記錄與網路邊界。

設定

宣告這三個工具。注意 web search 上的**網域允許清單**與 **ZDR 安全的 caller** 設定;用戶端工具帶有一般的

`input_schema`:

```
tools = [
  {
    "type": "web_search_20260209",
    "name": "web_search",
    "max_uses": 8,
    "allowed_domains": [
      "treasury.gov", "sanctionssearch.ofac.treas.gov",
      "reuters.com", "ec.europa.eu",
    ],
    "allowed_callers": ["direct"],
  },
  {
    "type": "code_execution_20250825",
    "name": "code_execution",
  },
  {
    "name": "query_internal_db",
    "description": "Return the firm's current exposure to a counterparty.",
    "input_schema": {
      "type": "object",
      "properties": {"counterparty_id": {"type": "string"}},
      "required": ["counterparty_id"],
    },
  },
]
```


兩個刻意的決定: `allowed_callers: ["direct"]` 以動態過濾省下的 token 換取研究路徑的 **ZDR 資格** (\$20.5); 曝險數字透過**用戶端**工具流動, 因此永遠不會碰到 Anthropic 的基礎設施。

執行軌跡

看回合形狀如何改變。Claude 想同時搜尋網路(伺服器端)並查詢內部 DB(用戶端)——於是回合以 `tool_use` 停下, 公司執行其主權查詢, 被延後的網路搜尋則在延續時執行:

```
sequenceDiagram
    actor An as 分析師
    participant App as 應用程式
    participant Cl as Claude 回合
    participant DB as 公司 DB 處理程式
    An->>App: 「對手 C-204 的制裁風險與我們的曝險相比?」
    App->>Cl: messages.create(web_search + code_execution + query_internal_db)
    Cl-->>App: stop_reason tool_use<br/>server_tool_use web_search(無結果) + tool_use query_internal_db
    App->>DB: query_internal_db(C-204)
    DB-->>App: 曝險 420 萬美元
    App->>Cl: 只含 tool_result(曝險) 的使用者訊息
    Cl->>Cl: 被延後的 web_search 在伺服器端執行
    Cl->>Cl: code_execution 在沙箱計算風險分數
    Cl-->>App: stop_reason end_turn<br/>附引用的簡報 + 分數
```

最重要的一行: 當 Claude 把伺服器端呼叫與用戶端呼叫混在一起時, `stop_reason` 是 `tool_use`, 不是 `pause_turn` ——而後續訊息只帶 DB 查詢的 `tool_result`。那裡多放任何區塊都會讓被延後的 `web_search` 懸空並使請求 400(\$20.4)。

驗證

- **回合形狀測試:** 斷言當模型把 `query_internal_db` 與 `web_search` 一起發出時, 回應是 `stop_reason == "tool_use"`, 且有一個**沒有**對應結果的 `server_tool_use` 區塊; 斷言延續(只含 `tool_result`)以 `end_turn` 結束。
- **網路隔離測試:** 讓 `query_internal_db` 指向一個只存在於網路內部的值, 確認它出現在答案中——證明主權路徑留在用戶端。
- **網域守門測試:** 斷言一個本會觸及非允許清單網域的搜尋, 不會回傳該網域的結果; 稽核允許清單有無非 ASCII 同形異義字。
- **ZDR 測試:** 確認 web 工具設為 `allowed_callers: ["direct"]`; 少了它, `_20260209` 版本就**不符合** ZDR 資格。
- **成本測試:** 確認 `max_uses` 為搜尋設上限; 斷言該次執行的 `server_tool_use.web_search_requests` 維持在預算內。

常見陷阱

- 在混入**用戶端**工具時預期 `pause_turn` ——其實是 `tool_use`; 伺服器端工具是被延後, 不是被暫停 (\$20.4)。
- 在後續訊息的 `tool_result` 之後加上文字區塊 → 回合提早關閉, 被延後的 `web_search` 就 400。
- 在 ZDR 合約下使用 `_20260209` + web 工具卻**沒有** `allowed_callers: ["direct"]` ——動態過濾會牽進 code execution, 而它永遠不符合 ZDR 資格(\$20.5)。

- 把具主權的曝險數字改走 `code_execution` (伺服器端)而非用戶端工具——內部資料就會離開網路。
- 在後續回合忘了回傳 `web search` 結果的 `encrypted_content` ,使引用失效。

20.7 關鍵整理

概念	要記住什麼
兩種執行模型	用戶端工具 → <code>tool_use</code> ,由你執行並回傳 <code>tool_result</code> ;伺服器端工具 → <code>server_tool_use (srvttoolu_)</code> ,由 Anthropic 在回合內部執行,不回傳 <code>tool_result</code> (\$20.1)。
伺服器端目錄	Web search、web fetch、code execution、tool search、advisor —— 在 <code>tools</code> 宣告,不必託管基礎設施(\$20.2)。
程式化工具呼叫	把用戶端工具標上 <code>allowed_callers: ["code_execution_20260120"]</code> ,讓 Claude 從沙箱程式碼呼叫它——多次呼叫、在容器內過濾、只把精簡結果送回上下文(輸入 token 約少 24%)。仍是暫停的 <code>tool_use</code> :由你執行並回傳 <code>tool_result</code> ;不是安全邊界,也不符合 ZDR(\$20.2)。
Anthropic 結構描述的用戶端工具	<code>bash</code> 、 <code>text_editor</code> 、 <code>memory</code> 、 <code>computer use</code> 附帶結構描述,但由你執行——請據此沙箱化(\$20.3)。
<code>pause_turn</code> 對比混合 <code>tool_use</code>	長伺服器端迴圈 → <code>pause_turn</code> ,原樣回傳(相同 <code>tools</code>)。伺服器端加用戶端在同一回合 → <code>tool_use</code> ;回覆只含 <code>tool_result</code> 區塊(\$20.4)。
成本計費表	Web search 每千次 \$10(用 <code>max_uses</code> 設上限);code execution 與 web 工具併用免費,否則 1,550 免費小時後每容器每小時 \$0.05(\$20.5)。
安全邊界	Code execution 沙箱網路停用;除非 <code>allowed_callers: ["direct"]</code> ,否則 ZDR 排除動態過濾 web 工具;主權資料留在用戶端工具;網域允許清單只用 ASCII(\$20.5)。

工程判斷,而非考試記誦。 架構師要做的決定是放置:當你需要一道控制接縫、或資料具主權性時,把能力做成用戶端工具自行託管;當你想要零基礎設施、且能接受黑盒呼叫時,讓 Anthropic 以伺服器端工具託管它。把回合形狀(`pause_turn` 對比 `tool_use`)與資料留存姿態做對,伺服器端工具就是助力倍增器,而非負債。

第 21 章:長上下文技術(Compaction、Context Editing、記憶)

參考 —— 超出考綱。 文件:[Compaction](#) · [Context editing](#) · [Memory tool](#) · [Context windows](#)。

第 11 章教的是考試所需的上下文管理紀律:一份預算、它的失效模式(context rot、lost-in-the-middle、工具結果膨脹),以及架構師會動用的手工技術 —— facts block、修剪 hook、滑動視窗。本章則是它底下的正式工程層:Anthropic 提供的三種具體 API 機制,讓你不必全部手工打造,以及在一個跑數小時甚至數天的代理上把它們組合起來的規則。本章明確超出基礎考綱(第四部分),但它正是把示範用代理與能撐過真實長時程任務的代理區分開來的東西。

即使有一百萬 token,視窗仍是有限的,而這三種機制從三個不同層面攻擊問題:

- **Compaction(壓縮)**(§21.2)—— 接近上限時,API 在伺服器端把較早的回合摘要掉,並從摘要繼續。有損、自動、在單一工作階段內。
- **Context editing(上下文編輯)**(§21.3)—— 在模型看到之前,把過時的工具結果與思考區塊從歷程中清除(非摘要)。保留的結構無損,移除負擔,在單一工作階段內。
- **memory tool(記憶工具)**(§21.4)—— Claude 讀寫視窗之外的檔案,因此狀態能撐過 compaction、上下文重置與整個工作階段。跨工作階段留存。

§21.1 闡述預算與 200K-對-1M 的取舍;§21.5 涵蓋正式環境中會咬人的交互作用(prompt caching、保留什麼丟棄什麼);§21.6 從頭到尾建構一個完整的跨數日程式庫遷移代理;§21.7 濃縮決策規則。

21.1 預算,以及為何 1M 並不會讓問題消失

每個請求都以固定順序渲染 —— `tools` → `system` → `messages` —— 這些區段的累計總和就是你要管理的預算。目前的模型陣容給你兩個必須據以設計的上限:

模型	上下文視窗	備註
Claude Opus 4.8 / 4.7 / 4.6、Sonnet 5 / 4.6、Fable 5	1M token	Opus 的 1M 採標準計價 —— 無長上下文加價
Claude Haiku 4.5	200K token	便宜、快速的層級 —— 也是你最先撞到的那個

陷阱在於把更大的視窗當成解方。它不是,有三個架構師必須內化的理由:

- **召回隨長度退化(context rot)**。注意力要關聯每一對 token —— 一個 n^2 的成本,在長輸入上會被攤得很薄。位於 600K token 處的事實,比同一事實位於 6K 處更難被注意到。更大的預算延後失效,並不能廢除它。
- **成本與延遲隨你重送的量成長**。API 是無狀態的:每個回合你都重送整段歷程。一段 700K token 的歷程會在每一個後續回合被計費(以 cache-read 或全額費率)。任由歷程無上限地朝 1M 成長,是一個成本決策,不只是品質決策。
- **subagent / 便宜模型層級是 200K**。一旦你把子任務委派給 Haiku(§21.5),或為了成本在 Haiku 上執行,你的有效視窗就是 200K —— 本章技術不再是可選的。

```
flowchart TD
    Budget[上下文視窗預算<br/>即使 1M 也有限] --> Fixed[tools 加 system<br/>穩定前綴]
    Budget --> Hist[messages 歷程<br/>每回合都成長]
    Hist --> Big[工具結果與思考<br/>主體也是雜訊]
    Big --> Near{接近<br/>觸發門檻?}
    Near -->|否,但過時| Edit[Context editing<br/>清除已死的工具結果]
    Near -->|是,接近上限| Compact[Compaction<br/>摘要較早的回合]
    Edit --> Persist[把durable facts<br/>寫入 memory tool]
    Compact --> Persist
    Persist --> Continue[繼續執行]
```

鄰近考試的框架,正式環境的現實: 第 11 章給你症狀對應到成因的地圖;本章給你受託管的緩解手段。當問題是「代理在跑了 5 小時後忘了一個決策」,基礎考綱的答案是 durable facts block(§11.2)。正式環境的答案再

加上:並用 `memory tool` 留存它,讓它撐過下一次 `compaction`,以及整個下一次工作階段。

21.2 Compaction —— 接近上限時摘要

Compaction 是伺服器端、有損的摘要,會在對話接近門檻時自動觸發(預設約 150K token)。API 把較早的回合濃縮成一個 **compaction 區塊**,然後從該摘要繼續,而非完整歷程。你逐請求選擇加入。

```
client.beta.messages.create(  
    betas=["compact-2026-01-12"], # 必要的 beta header  
    model="claude-opus-4-8",  
    max_tokens=16000,  
    messages=messages,  
    context_management={"edits": [{"type": "compact_20260112"}]},  
)  
# 把整個 content 接回去 — 包含 compaction 區塊:  
messages.append({"role": "assistant", "content": response.content})
```

漏掉就會搞砸一切的那一條規則: 下一回合要把整個 `response.content` (不只是文字)接回 `messages`。compaction 區塊就在 `response.content` 裡面;API 會用它在下一個請求時取代被壓縮的歷程。只取出 `block.text` 並把那串字串接回去,你就悄悄丟掉了壓縮狀態 —— 下一個請求會重送完整未壓縮的歷程,compaction 等於從未發生。

為何使用它(以及它的代價):

- **為何:** 它是唯一能讓單一對話在不必你自己寫摘要器的情況下,存活超過視窗的機制。當對話的脈絡仍然重要、且你能容忍對舊細節的有損召回時,它就是對的工具。
- **代價 —— 漸進式摘要遺失。** 每次 compaction 都會把精確的值(金額、ID、行號、檔案路徑)壓成散文(「使用者回報一個失敗的測試」)。數字會模糊。**這是核心陷阱:** 永遠不要讓承重事實只存在於可壓縮的歷程裡。把它們提升到每回合重新注入的 durable facts block (§11.2),或 —— 對長時程更好 —— 提升到 `memory tool` (§21.4),兩者都位於被摘要的歷程之外。

可用性: beta,在 Fable 5、Opus 4.8 / 4.7 / 4.6 與 Sonnet 4.6 上。Beta header `compact-2026-01-12`;你必須呼叫 `client.beta.messages.*`。

21.3 Context Editing —— 清除過時工具結果,而非摘要

Context editing 是相對於 compaction 那把鈍器的手術刀。它清除內容而非摘要:舊的

`tool_use / tool_result` 配對與舊的 `thinking` 區塊,會在模型看到下一回合之前從歷程中移除。你保留的一切其對話結構維持完整且無損;負擔則直接消失。

```

client.beta.messages.create(
    betas=["context-management-2025-06-27"],          # 與 compaction 不同的 beta
    header
    model="claude-opus-4-8",
    max_tokens=16000,
    tools=tools,
    messages=messages,
    context_management={"edits": [
        {"type": "clear_tool_uses_20250919"},          # 丟掉舊工具結果
        {"type": "clear_thinking_20251015"},          # 丟掉舊思考區塊
    ]},
)

```

兩種策略,可一起或分開使用:

- **clear_tool_uses_20250919** —— 清除舊的工具結果。加上 **clear_tool_inputs: true** 連產生它們的 **tool_use** 參數一起丟掉。這是高價值的那個:一次跨 30 個檔案的調查會累積數十份巨大的檔案輸出,而模型早已從中取出所需。
- **clear_thinking_20251015** —— 清除舊的 **thinking** 區塊。在長的編輯/測試迴圈上,一旦它所支撐的動作完成,過時的推理就是純粹的壓艙物。

Compaction 對比 context editing —— 文件特別強調的區別: *compaction* 是摘要(有損,保留要旨),*context editing* 是清除(對存活者無損,被清除區塊則什麼都不留)。它們使用不同的 **beta header** 與不同的 **edits** 類型(**compact_20260112** + **compact-2026-01-12** 對 **clear_*** + **context-management-2025-06-27**) —— 把它們搞混是典型的實作 bug。

為何使用它,以及陷阱:

- **為何:** 舊工具輸出是長時程視窗裡單一最大、最吵雜的佔用者(\$11.1)。清除它比摘要它更便宜、也更忠實 —— 你逐字保留活的對話,而非把一切都模糊掉。
- **陷阱 —— 清除了你仍需要的東西。** 一旦工具結果被清除就沒了;若後續回合需要那筆資料,模型必須重新抓取(一次工具呼叫),否則就遺失。修法和往常一樣是那個分離:在原始結果老化掉之前,把 durable facts(發現、ID、行號)提取到 facts block 或 memory。清掉那 2,000 token 的檔案輸出;保留那一行重要的。

21.4 Memory Tool —— 比視窗活得更久的狀態

Compaction 與 context editing 都在工作階段之內運作。memory tool 是跨工作階段的機制:Claude 讀寫 **/memories** 目錄中的檔案,而該目錄能跨上下文重置與完全分離的工作階段留存。它是一個**用戶端**工具 —— Anthropic 定義 schema 與 Claude 的使用模式,但**由你實作儲存後端**(本機磁碟、資料庫、物件儲存)。

```

response = client.messages.create(
    model="claude-opus-4-8",
    max_tokens=16000,
    tools=[{"type": "memory_20250818", "name": "memory"}], # 無 schema、由 Anthropic 定義
    messages=[{"role": "user", "content": "Resume the migration from where we left off."}],
)
# Claude 發出 memory 的 tool_use 區塊;由「你的」handler 對 /memories 執行它們
# 並回傳 tool_result。SDK 內附 BetaAbstractMemoryTool / betaMemoryTool 輔助類別。

```

Claude 以六個指令驅動它 —— `view`、`create`、`str_replace`、`insert`、`delete`、`rename` —— 來維護自己的筆記:遷移檢查清單、逐檔狀態表、決策及其理由、學到的教訓。跨工作階段的模式是「先查 memory,邊做邊寫下發現」。

為何它是長時程的基石:

- 它是三者中唯一能撐過工作階段邊界的。compaction 狀態與 facts block 都會在行程結束時消亡;memory 檔案不會。
- 它把「記住這件事」變成可稽核、甚至能在首次執行前預先植入的、持久且可檢視的狀態。

陷阱與安全邊界(這是架構師會弄錯的部分):

- 絕不在 memory 檔案中儲存密鑰(API 金鑰、token、密碼),並對 PII 要刻意謹慎 —— 這些檔案會留存,且可能在代理的整個生命週期內被重讀。參考後端沒有內建存取控制。
- 在多使用者系統中,把 `/memories` 依使用者範圍切分,並對每次讀寫驗證身分。共用的 memory 目錄會把一位使用者的上下文洩漏進另一位的工作階段。這是真實、鄰近刪除法規(GDPR/CCPA)的考量,不是假設。
- 任其無上限成長,它就在新的地方變成膨脹問題。把 memory 限制在持久識別碼、決策與教訓 —— 而非一份流水帳。

Managed Agents 有一個對應的構造 —— 工作區範圍的 **memory stores**,掛載進工作階段容器 —— 以 Anthropic 託管的儲存與逐次變更的版本歷史,解決相同的跨工作階段問題。目標相同;你不必實作後端。

21.5 會咬人的交互作用:快取,以及保留什麼丟棄什麼

這三種機制並非活在真空中 —— 它們會與 prompt caching(第 18 章)以及彼此相撞。

Prompt caching 是前綴比對,而編輯歷程會移動前綴。 快取以到某個 `cache_control` 斷點為止的確切位元組為鍵,渲染順序為 `tools → system → messages`。兩個後果:

- **Compaction 與 context editing 會改寫 `messages` 前綴**,使被編輯點之後的快取讀取失效。這通常是可接受的取捨 —— 你花一次冷 prefill,換回後續每回合數萬 token —— 但這代表你不該觸發比所需更積極的編輯。
- **快取是逐模型、逐工具集的。** 在工作階段中途切換模型或更動工具清單,會炸掉整個快取(`tools` 在位置 0 渲染)。這正是 subagent 模式對長上下文工作重要的原因:讓主迴圈維持在單一模型搭配穩定工具集,使其

快取存活,並把便宜或上下文隔離的子任務推給 Haiku subagent,其 200K 視窗與獨立快取不會碰到主迴圈。

保留什麼丟棄什麼 —— 架構師的配置規則。 把視窗依存活優先序當成分層來對待:

```
flowchart TD
    Turn[新回合抵達] --> Q1{這是 durable<br/>fact、ID 或決策嗎?}
    Q1 -->|是| Keep[寫入 memory<br/>與 facts block]
    Q1 -->|否| Q2{是過時的工具<br/>結果或舊思考嗎?}
    Q2 -->|是| Clear[讓 context editing<br/>清除它]
    Q2 -->|否| Q3{接近 compaction<br/>門檻嗎?}
    Q3 -->|是| Summ[讓 compaction<br/>摘要脈絡]
    Q3 -->|否| Live[在活的視窗中<br/>逐字保留]
```

- **永遠保留,放在可摘要的歷程之外:** 識別碼、金額、file:line 位置,以及已定案的決策 —— 放在 facts block 與／或 memory。它們絕不能受摘要遺失所影響。
- **最先丟棄(context editing):** 原始工具輸出與已解決的思考 —— token 量高、剩餘訊號低。
- **最後才摘要(compaction):** 對話脈絡,當你真的需要其要旨且已到上限時。
- **引用,別內嵌:** 對於巨大的產物,把它們儲存起來(Files API、memory、一個路徑)並傳一個引用,讓模型按需抓取,而非每回合把酬載停在視窗裡。

21.6 端到端案例研究:跨數日程式庫遷移代理

機制唯有組裝起來才有意義。以下是一個真實的長時程代理,操練全部三者 —— 這種執行會持續數天,且不可能容納在單一視窗裡。

需求

- 把一個大型程式庫從一個框架版本遷移到下一個:數百個檔案,跨多個工作階段、橫跨數天執行(無法在一次內完成)。
- 逐檔:讀它、改它、跑測試、記錄結果。檔案讀取與測試日誌龐大且大多在該檔完成後即可丟棄。
- **硬性需求:** 狀態 —— 哪些檔案完成、哪些失敗及原因、對含糊 API 所做的決策 —— 必須撐過每一次上下文重置與每一個工作階段邊界。忘了一個已完成的檔案就要重做;忘了一個決策就會造成整個程式庫不一致。

架構

```
flowchart TD
    Start([新工作階段開始]) --> Mem[讀 memory<br/>遷移檢查清單與狀態]
    Mem --> Pick[挑下一個待處理檔案]
    Pick --> Read[讀檔並跑測試<br/>龐大、可丟棄的輸出]
    Read --> Decide{測試通過?}
    Decide -->|是| Note[把 done 加決策<br/>寫入 memory]
    Decide -->|否| Fail[把失敗加原因<br/>寫入 memory]
    Note --> Clear[Context editing 清除<br/>檔案輸出與測試日誌]
    Fail --> Clear
    Clear --> Near{本工作階段<br/>接近 150K??}
    Near -->|是| Compact[Compaction 摘要<br/>本工作階段脈絡]
    Near -->|否| Pick
    Compact --> Pick
```

主迴圈在 **Opus 4.8** 上執行(1M 視窗、穩定工具集、可快取前綴)。對獨立檔案的大量平行讀取可以扇出給 **Haiku 4.5** subagent(各 200K),使它們永遠不擠壓主視窗 —— 每個只回傳取出的發現。

實作草圖

在主請求上啟用全部三者 —— compaction 處理脈絡、context editing 卸掉每個檔案的輸出、memory tool 處理持久狀態:

```
def migration_turn(messages):
    return client.beta.messages.create(
        betas=["compact-2026-01-12", "context-management-2025-06-27"],
        model="claude-opus-4-8",
        max_tokens=32000,
        tools=[
            {"type": "memory_20250818", "name": "memory"},          # 持久、跨工作階段
            {"type": "text_editor_20250728", "name": "str_replace_based_edit_tool"},
            {"type": "bash_20250124", "name": "bash"},             # 跑測試
        ],
        context_management={"edits": [
            {"type": "compact_20260112"},                          # 接近上限時摘要
            {"type": "clear_tool_uses_20250919", "clear_tool_inputs": True}, # 丟掉
        ]},
        messages=messages,
    )

# 關鍵:每回合都要把整個 content(含 compaction 區塊)接回去。
resp = migration_turn(messages)
messages.append({"role": "assistant", "content": resp.content})
```

Claude 維護的 memory 檔案是橫跨數日的真實來源:

```

/memories/migration.md
STATUS (一檔一列)
  src/api/client.ts      DONE      2 call sites updated
  src/api/refund.ts      FAILED    test t_refund_over_limit: unparameterized SQL, needs
manual review
  src/api/orders.ts      PENDING
DECISIONS
- getX(opts) -> getX(opts, ctx): always pass ctx from the request scope, never a
global
- Skip generated files under build/; never edit them

```

執行軌跡

```

sequenceDiagram
  actor Eng as 工程師
  participant Ag as 遷移代理
  participant Mem as Memory 後端
  participant Repo as 程式庫與測試
  participant API as Context 管理
  Eng->>Ag: 「Resume the migration.」
  Ag->>Mem: view /memories/migration.md
  Mem-->>Ag: 142 done、orders.ts pending、ctx 傳遞決策
  Ag->>Repo: 讀 orders.ts、編輯、跑測試
  Repo-->>Ag: 龐大檔案輸出加測試日誌(通過)
  Ag->>Mem: str_replace orders.ts -> DONE
  Ag->>API: clear_tool_uses 丟掉輸出與日誌
  Note over Ag,API: 接近 150K -> compaction 摘要本工作階段
  Ag-->>Eng: 「orders.ts done;143/300 完成。」

```

注意分工:**memory** 持有必須存活的事實、**context editing** 每回合卸掉可丟棄的主體、**compaction** 在接近上限時維持工作階段連貫。工程師可以闔上筆電,隔天再續——memory 檔案讓代理成為無狀態但持久。

驗證

- **跨工作階段測試:** 在第 142 個檔案後殺掉行程,開一個全新的工作階段,斷言代理讀取 memory 並從 143 續做——永不重做已完成的檔案。
- **事實存活測試:** 在一次 compaction 事件後,斷言 `ctx` 傳遞決策仍套用到下一個檔案——證明該決策存活在 memory,而非被摘要掉的脈絡裡。
- **膨脹測試:** 斷言視窗每檔大致持平(編輯清掉輸出),而非朝上限單調成長。
- **隔離/安全測試:** 在兩位使用者下跑兩個程式庫,斷言每個代理只讀自己的 `/memories` 目錄。

常見陷阱

- 只接回 `response.content` 的文字、丟掉 compaction 區塊——執行會悄悄重送完整歷程,compaction 從未生效(\$21.2)。
- 把遷移狀態只存在對話中、信任 compaction 會保留它——摘要器會把「143 done」模糊成「大多數檔案已遷移」(\$21.2)。
- 搞混兩個 beta header / `edits` 類型——`compact_20260112` 是摘要, `clear_*` 是清除;它們不可互換(\$21.3)。
- 跨使用者共用 `/memories` 目錄——一個租戶的決策洩漏進另一個的執行(\$21.4)。

21.7 關鍵整理

概念	該記住什麼
三種不同機制	Compaction 是摘要(工作階段內、有損);context editing 是清除(工作階段內、對存活者無損);memory 是留存(跨工作階段)。別搞混(\$21.0–\$21.4)。
Compaction	Beta <code>compact-2026-01-12</code> 、 <code>compact_20260112</code> ;約 150K 自動觸發。 每回合把整個 <code>response.content</code> (含 <code>compaction</code> 區塊)接回去 ,否則會遺失壓縮狀態(\$21.2)。
Context editing	Beta <code>context-management-2025-06-27</code> ; <code>clear_tool_uses_20250919</code> (+ <code>clear_tool_inputs</code>)與 <code>clear_thinking_20251015</code> 。header／類型都與 <code>compaction</code> 不同(\$21.3)。
Memory tool	<code>memory_20250818</code> ,用戶端, <code>/memories</code> ;能撐過工作階段。 不放密鑰;依使用者切分範圍;別讓它膨脹 (\$21.4)。
1M 不會廢除 context rot	更大的視窗延後失效;召回仍會退化,你仍要付重送成本。便宜/subagent 層級是 200K(\$21.1)。
快取交互作用	編輯歷程會移動被快取的前綴;讓主迴圈維持單一模型加穩定工具,把便宜工作推給 Haiku subagent(\$21.5)。
保留對丟棄	把 ID／金額／決策保留在 memory 加 facts block;以 context editing 丟掉原始工具輸出;最後才摘要脈絡;對巨大產物用引用而非內嵌(\$21.5)。

正式環境的姿態,而非考試教材。 基礎考試測的是紀律(第 11 章)。本章是你如何把它規模化實作:讓 API 替你摘要、清除與留存 —— 但把承重事實放進 memory,永遠不要放在 API 可以自由摘要或清除掉的部分裡。

第 22 章:文件與多模態輸入

參考 —— 考試把 *Vision* 與 *token counting* 列為範圍外;這是給實務用。 文件:[Vision](#) · [PDF support](#) · [Files API](#) · [Citations](#) · [Token counting](#)。

本章揭開 **PART III —— 現代代理工程(Modern Agent Engineering)** 的序幕,也就是「超出基礎考試範圍」的進階內容。認證把 *vision* 與 *token counting* 列為範圍外,但沒有任何上線的文件代理能少了它們。當你的代理必須閱讀 —— 一張掃描的發票、一份兩百頁的合約、一張儀表板截圖、一張沒有底層資料表的圖表 —— 純文字提示就不再夠用。你進入了**多模態輸入**的世界: `image` 與 `document` 內容區塊、三種把位元組送進請求的競爭方式、透過 *citations* 取得有根據的答案,以及一個「單張影像可能比一頁文字還貴」的成本模型。

困難之處不在於「Claude 看得到影像」,而在於**圍繞位元組的工程**:

- **該用哪種來源類型**(\$22.2) —— `base64`、`URL`,還是 `Files API` 的 `file_id` —— 以及為何選錯會在多輪代理上悄悄讓帳單變成三倍。
- **內容區塊結構**(\$22.3) —— 影像與文件相對於文字該擺在哪裡,以及為何順序重要。
- **Citations(引用)**(\$22.4) —— 把「相信我」式的答案,變成可驗證、錨定到具體區段的主張,以滿足合規需求。

- **像素與頁面的 token 成本**(§22.5)—— 考試不教、但你的財務團隊一定會問的計算公式。

§22.6 從頭到尾建構一個完整的發票與合約攝入代理,§22.7 則濃縮上線守則。

22.1 多模態內容模型

Claude 訊息的 `content` 不是一個字串 —— 而是一個有序的**內容區塊清單**。文字只是其中一種區塊類型。對文件與多模態輸入來說,有三種區塊類型重要:

```
flowchart TD
    Msg[使用者訊息<br/>content 是有序清單] --> T[text 區塊<br/>提示或標籤]
    Msg --> I[image 區塊<br/>JPEG PNG GIF WebP]
    Msg --> D[document 區塊<br/>PDF 原生文字加版面]
    I --> S{來源類型}
    D --> S
    S -->|base64| B[位元組內嵌<br/>免 beta header]
    S -->|url| U[託管參照<br/>免 beta header]
    S -->|file_id| F[Files API<br/>需要 beta header]
```

有兩種區塊類型攜帶非文字輸入:

- **image** —— `{"type": "image", "source": {...}}`。格式:JPEG、PNG、GIF(僅取第一幀 —— 動畫會被忽略)、WebP。Claude *理解*影像;它無法**生成或編輯**影像。
- **document** —— `{"type": "document", "source": {...}}`。原生處理 PDF,涵蓋**文字與視覺版面** —— 每一頁都會被渲染成影像,同時附上該頁擷取出的文字,因此 Claude 能推理圖表、表格與圖形,而不只是文字流。

****這對設計為何重要:****一個「會讀文件」的代理,實際上是一個以正確順序、正確來源類型組裝內容區塊的代理。下游的一切 —— 成本、延遲、快取行為、引用可用性 —— 全都由你如何建構這份清單來決定。

22.2 三種來源類型:base64 與 URL 與 Files API

每個 `image` 與 `document` 區塊都會指定一個 `source`,其類型為三者之一。對單一請求而言它們功能上可互換,但操作面貌差異極大 —— 而選錯,是本章在生產環境中最常見的錯誤。

來源類型	Beta header	位元組傳輸方式	最適用於	陷阱
base64	無	每次請求都內嵌	一次性呼叫;本機檔案;ZDR 嚴格的流程	每一輪都重送 —— 多輪時 payload 暴增
url	無	伺服器端抓取	公開託管的資產	URL 必須可達;你無法控制該抓取的快取
file_id(Files API)	files-api-2025-04-14	上傳一次,以 id 參照	同一檔案跨多個請求 / 多輪	上傳與訊息 兩處 都需要 beta header

base64 陷阱。API 是無狀態的 —— 每次請求都會重送完整的對話歷史。若一份 5 MB 的 PDF 或一張截圖以 base64 內嵌,這些位元組就會在代理迴圈的**每一輪**搭便車。一段 10 輪的對話會把同一份文件重送 10

次。請求大小變大、延遲攀升,而在合作夥伴平台上,你可能在還沒碰到頁數上限之前,就先撞上 32 MB 的請求上限。

Files API 解法。 上傳一次,取得 `file_id`,之後永遠以 `id` 參照:

```
# 上傳一次(上傳呼叫需要 beta header)
uploaded = client.beta.files.upload(
    file=("contract.pdf", open("contract.pdf", "rb"), "application/pdf"),
)

# 跨多個請求以 id 參照 — 位元組「不會」重送
response = client.beta.messages.create(
    model="claude-opus-4-8",
    max_tokens=16000,
    betas=["files-api-2025-04-14"], # 這裡也需要
    messages=[{
        "role": "user",
        "content": [
            {"type": "text", "text": "Summarize the termination clause."},
            {"type": "document", "source": {"type": "file", "file_id":
uploaded.id}},
        ],
    }],
)
```

內容區塊的類型必須與檔案的 MIME 類型相符:PDF/文字檔 → `document` 區塊;影像檔 → `image` 區塊。
beta header 在上傳與每一個參照該檔案的 `messages.create` 都需要 —— 兩者其中之一漏掉,就是常見的 400。

****決策規則:****單一請求 → base64(最簡單)。同一資產跨多輪或多個請求重用 → Files API(`file_id`)。你信任的公開 URL → `url`。在 Amazon Bedrock 與 Google Vertex AI 上,只支援 base64 —— Files API 與 `url` 來源都不支援,因此 Bedrock/Vertex 上的文件代理別無選擇,只能內嵌位元組(且必須為重複的 payload 編列預算)。

22.3 多模態請求的提示結構

內容區塊的順序並非裝飾 —— 它會明顯影響品質。

```
flowchart TD
    Start[建構使用者 content 清單] --> Doc[把 document 或 image 區塊放最前面]
    Doc --> Label[為每一個加標籤<br/>Image 1 Image 2]
    Label --> Q[把文字問題放最後]
    Q --> Multi{多張影像嗎}
    Multi -->|是| Sep[各以自己的文字標籤引介]
    Multi -->|否| Send[送出請求]
    Sep --> Send
```

官方建議的最佳做法:影像與文件,要放在詢問它們的文字之前。同一套長上下文原則 —— 「把大文件放在查詢之前」 —— 也適用於像素:影像在前、文字在後的表現,優於文字在前、影像在後。與文字交錯的影像仍然

有效,但若你的使用情境允許,就以視覺內容開頭。

為多個輸入加標籤。 當一個請求攜帶多張影像或多頁時,以一段簡短的文字標籤引介每一個,讓你能以名稱指涉它們:

```
content = [
  {"type": "text", "text": "Image 1 (the invoice):"},
  {"type": "image", "source": {"type": "file", "file_id": invoice_id}},
  {"type": "text", "text": "Image 2 (the purchase order):"},
  {"type": "image", "source": {"type": "file", "file_id": po_id}},
  {"type": "text", "text": "Do the line-item totals on the invoice match the PO?"},
]
```

沒有標籤時,「把第二個跟第一個比較」會語意不清;有了標籤,模型 —— 以及你的後續輪次 —— 就能精準指涉 `Image 1`。在多輪對話中,Claude 保有對先前輪次每一張影像的存取,因此你**不需要**在後續輪次重新附上它們(而若你用的是 base64,重新附上正是 §22.2 的成本陷阱)。

與 prompt caching 的互動。 一份放在內容前段的大文件是理想的快取目標:在 document 區塊上放一個 `cache_control: {"type": "ephemeral"}` 斷點,把多變的問題保持在它之後,那麼針對同一份文件的重複查詢,就會以約 10% 的輸入成本讀取被快取的前綴。這是高流量文件工作負載最大的單一槓桿(§22.6)。

22.4 Citations:可驗證、有根據的答案

對任何「自信但答錯」會有後果的工作負載 —— 法律、財務、合規 —— 一個純文字答案就是個風險。

Citations 讓模型把每一項主張錨定到來源文件的確切區段。

在 `document` 區塊上設定 `citations: {enabled: true}` (它必須在請求中的**所有** document 區塊上啟用,否則就全部不啟用):

```
response = client.messages.create(
  model="claude-opus-4-8",
  max_tokens=16000,
  messages=[{
    "role": "user",
    "content": [
      {
        "type": "document",
        "source": {"type": "base64", "media_type": "application/pdf",
        "data": pdf_b64},
        "title": "Master Services Agreement",
        "citations": {"enabled": True},
      },
      {"type": "text", "text": "What is the notice period for termination?"},
    ],
  }],
)
```

回應文字會被切成多個 `text` 區塊;提出主張的那些區塊會帶有一個 `citations` 陣列。每個 citation 包含 `cited_text`、`document_index`、`document_title`,以及一個依類型而定的**位置**:

- `page_location` → `start_page_number` / `end_page_number` (從 1 起算),用於 PDF。
- `char_location` → `start_char_index` / `end_char_index` ,用於純文字。
- `content_block_location` ,用於自訂內容。

你可以渲染被引用的區段,並把它連回合約的第 14 頁 —— 答案如今可稽核,而非「相信我」。

超出考試範圍的讀者必須知道的兩個權衡:

1. **Citations 與結構化輸出不相容。** 同時啟用 `citations` 與 `output_config.format` (一個 JSON schema)會回傳 400。你無法在單次呼叫裡,得到一個既錨定區段、又受 schema 約束的 JSON 答案 —— 選擇情境所需的那一個,或跑兩趟(一次呼叫擷取結構化欄位,另一次蒐集引用)。
2. **每個請求全有或全無。** Citations 必須在每個 document 區塊都啟用、或都不啟用 —— 你無法在同一個請求裡引用一份文件、卻忽略另一份。

22.5 影像與 PDF 頁面的 token 成本

這是基礎考試略過、但你的帳單不會略過的一節。Claude 不以位元組大小計算影像費用 —— 它以**視覺 token(visual tokens)**計費,而模型在這方面精確且可預測。

影像。 Claude 以 **28×28 像素的色塊(patch)** 來看待影像;每個色塊是一個視覺 token。一張影像因此花費:

```
visual_tokens = ceil(width / 28) * ceil(height / 28)
```

大於模型原生上限的影像會在**處理前先降採樣**,藉此封頂成本。上限取決於模型的解析度層級:

層級	模型	最大長邊	最大視覺 token
高解析度	Fable 5、Mythos 5、Opus 4.8、Opus 4.7	2576 px	4784
標準	其他所有模型	1568 px	1568

高解析度支援在上述模型上是**自動的** —— 免 beta header、免 opt-in。它在密集文件、截圖與 computer use 上釋放出準確度,而 Claude 回傳的座標與實際像素 1:1 對應。代價是:在高解析度模型上,一張全解析度影像可能花費**多達約 3 倍的視覺 token**(最高 4784,對比標準層的 1568)。一張 1000×1000 的影像在任一層級都花費 $\text{ceil}(1000/28)^2 = 36 \times 36 = 1296$ 個 token;一張 4K 截圖在標準層約花 1560 個 token,但在高解析度模型上會用滿 4784。若你不需要那份精細度,**送出前先降採樣**。

PDF 頁面收費兩次。 每一頁都會**同時**以文字與影像處理,因此一頁的計費為:

- **文字 token:**通常每頁 **1,500–3,000 個**,視密度而定。沒有額外的 PDF 費用 —— 套用標準輸入定價。
- ****影像 token:****每一頁都被渲染成影像,並依上述同一套視覺 token 公式計費。

因此一份 50 頁的合約並不是「50 × 文字」 —— 而是 50 頁的文字 token **加上** 50 張頁面影像。密集的 PDF 可能在碰到 600 頁上限之前就先耗盡上下文視窗(200K 上下文模型為 100 頁)。

送出前先計數 —— 切勿用 tiktoken 估算。 `count_tokens` 端點在真正呼叫**之前**給你一個精確、模型專屬的計數。`tiktoken` 是 OpenAI 的 tokenizer;它對 Claude 不準(它對一般文字低估約 15–20%,對程式碼或非英文則差更多),而且它根本不理解視覺 token。

```
count = client.messages.count_tokens(
    model="claude-opus-4-8",
    messages=[{"role": "user", "content": [
        {"type": "document", "source": {"type": "base64",
            "media_type": "application/pdf", "data": pdf_b64}},
        {"type": "text", "text": "Summarize this contract."},
    ]}],
)
print(count.input_tokens)    # 精確, 含每頁文字加影像 token
```

22.6 端到端案例研究:發票與合約攝入代理

上述元件唯有組合在一起才有意義。以下是一個完整、真實的文件代理 —— 正是財務或採購團隊會實際部署的那種。

需求

- 攝入供應商**發票**(通常是掃描影像 / 照片)與其所依據的**合約**(多頁 PDF)。
- 對每張發票:擷取結構化欄位(供應商、發票號碼、總額、品項),並對照合約核驗每一筆收費費率。
- 每一項「合約上寫的是 X」的主張都必須**可稽核** —— 錨定到合約 PDF 的某一頁。
- 同一份合約在當月會被數十張發票查詢 —— 付費讀它一次,而非數十次。
- 讓每份文件的 token 成本可預測且有回報。

架構

```
flowchart TD
    Intake([發票與合約進來]) --> Up1[兩者都上傳 Files API  
各取得 file_id]
    Up1 --> Cnt1[Count tokens  
為每份文件編列預算]
    Cnt1 --> Extract1[第一趟擷取欄位  
結構化輸出 schema]
    Extract1 --> Up2[第二趟核驗費率  
啟用 citations]
    Up2 --> Extract2[合併欄位與引用發現]
    Extract2 --> Verify[Verify]
    Verify --> Merge[Merge]
    Merge --> Out([結構化紀錄  
加頁面錨定證據])
```

兩趟,因為 §22.4 的規則禁止把它們合併:**第一趟**用 `output_config.format` 做乾淨的結構化擷取;**第二趟**用 `citations` 做頁面錨定的核驗。合約只上傳**一次**到 Files API,兩趟(以及當月之後的每一張發票)都以 `file_id` 參照它 —— 而它的 document 區塊帶有一個 `cache_control` 斷點,讓頁面影像從快取讀取,而非重新處理。

實作

把兩份文件各上傳一次,並在花費前為請求編列預算:

```

invoice = client.beta.files.upload(
    file=("invoice.png", open("invoice.png", "rb"), "image/png"),
)
contract = client.beta.files.upload(
    file=("msa.pdf", open("msa.pdf", "rb"), "application/pdf"),
)

# 真正呼叫前先編列預算 — 精確且模型專屬
count = client.beta.messages.count_tokens(
    model="claude-opus-4-8",
    betas=["files-api-2025-04-14"],
    messages=[{"role": "user", "content": [
        {"type": "image", "source": {"type": "file", "file_id": invoice.id}},
        {"type": "document", "source": {"type": "file", "file_id": contract.id}},
        {"type": "text", "text": "placeholder"}],
    ]}],
)
log.info("input_tokens for this document=%d", count.input_tokens)

```

第一趟 —— 結構化擷取(無 citations,因此允許結構化輸出):

```

fields = client.beta.messages.create(
    model="claude-opus-4-8",
    max_tokens=4096,
    betas=["files-api-2025-04-14"],
    output_config={"format": {"type": "json_schema", "schema": INVOICE_SCHEMA}},
    messages=[{"role": "user", "content": [
        {"type": "image", "source": {"type": "file", "file_id": invoice.id}},
        {"type": "text", "text": "Extract supplier, invoice_number, total, and
line_items."},
    ]}],
)

```

第二趟 —— 引用核驗(啟用 citations;合約區塊被快取以便重用):

```
findings = client.beta.messages.create(
    model="claude-opus-4-8",
    max_tokens=8000,
    betas=["files-api-2025-04-14"],
    messages=[{"role": "user", "content": [
        {
            "type": "document",
            "source": {"type": "file", "file_id": contract.id},
            "title": "Master Services Agreement",
            "citations": {"enabled": True},
            "cache_control": {"type": "ephemeral"}, # 讀一次,整月重用
        },
        {"type": "image", "source": {"type": "file", "file_id": invoice.id}},
        {"type": "text", "text":
            "For each invoice line item, state whether the charged rate matches "
            "the contract. Cite the contract clause for every rate you reference."},
    ]}],
)
```

執行軌跡

```
sequenceDiagram
    actor Ops as 應付帳款人員
    participant App as 攝入代理
    participant Files as Files API
    participant Claude as Claude
    Ops->>App: invoice.png 加 msa.pdf
    App->>Files: 兩者都上傳,取得 file_ids
    Files-->>App: invoice_id, contract_id
    App->>Claude: 第一趟 影像加 schema
    Claude-->>App: 結構化欄位 JSON
    App->>Claude: 第二趟 合約引用加發票
    Claude-->>App: 帶頁面引用的發現
    App-->>Ops: 紀錄加合約第 14 頁的證據
```

人員拿回一份結構化紀錄以及一份發現清單,每一項都連到確切的合約頁面 —— 真人可以在數秒內抽查「第 3 行費率不符,引用至 p.14」,而不必重讀整份合約。

驗證

- **成本預算測試:** 斷言 `count_tokens` 在每次真正呼叫之前執行,且每份文件的 `input_tokens` 有被記錄 —— 一份 50 頁的合約必須被編列為「文字 + 50 張頁面影像」,而非只有文字。
- **快取測試:** 送出當月第二張發票,斷言合約前綴的 `usage.cache_read_input_tokens > 0` —— 若為零,代表每張發票都在重讀合約(檢查 document 區塊的位元組/ `file_id` 與前綴是否逐位元組相同)。
- **引用測試:** 斷言每一項「合約上寫的是」發現都帶有含 `page_location` 的 `citations` 陣列;沒有引用的發現就是無根據的主張,必須被拒絕。
- **來源類型測試:** 確認合約在當月所有發票中都以 `file_id` 參照,而非重新內嵌為 base64。

常見陷阱

- 在每張發票上把合約內嵌為 `base64` —— 每一輪重送數 MB 並喪失快取(\$22.2)。
- 試圖在單次呼叫裡同時取得 `citations` 與結構化 `JSON` —— 回傳 400;你必須拆成兩趟(\$22.4)。
- 在上傳或訊息其中之一忘了 `Files API` 的 `beta header` —— 常見的 400(\$22.2)。
- 把 PDF 只當成純文字來編列預算,然後被帳單嚇到 —— 每一頁也會花費影像 token(\$22.5)。
- 用 `tiktoken` 而非 `count_tokens` 估算 token —— 對 Claude 不準,且對視覺 token 視而不見(\$22.5)。

22.7 生產重點 —— 關鍵整理

概念	生產工作要求什麼
內容區塊	<code>content</code> 是有序清單; <code>image</code> (JPEG/PNG/GIF/WebP)與 <code>document</code> (PDF 文字 + 版面)攜帶非文字輸入(\$22.1)。
來源類型	<code>base64</code> (一次性)、 <code>url</code> (託管)、 <code>file_id</code> (跨多輪/多請求重用)。Bedrock/Vertex = 僅 <code>base64</code> (\$22.2)。
<code>base64</code> 陷阱	<code>base64</code> 位元組每一輪都重送;把重用的資產改用 <code>Files API</code> (<code>file_id</code>)以止住膨脹(\$22.2)。
提示順序	把 <code>document/image</code> 放在文字問題之前;為多個輸入加標籤 <code>Image 1</code> 、 <code>Image 2</code> (\$22.3)。
Citations	<code>citations: {enabled: true}</code> → <code>cited_text</code> + 頁碼/字元位置;全有或全無;與結構化輸出 不相容 (\$22.4)。
影像成本	<code>ceil(w/28) × ceil(h/28)</code> 視覺 token;高解析度層(Opus 4.7+)最高 4784,對比標準層 1568 —— 不需精細度就降採樣(\$22.5)。
PDF 成本	每頁計費 文字(1,500–3,000)+ 影像 token ;600 頁 / 32 MB 上限(200K 模型為 100 頁)(\$22.5)。
Token 計數	用 <code>count_tokens</code> 取得精確、模型專屬的計數;切勿用 <code>tiktoken</code> (對 Claude 不準、對視覺 token 視而不見)(\$22.5)。

超出基礎考試範圍。 Vision 與 token counting 在認證範圍外,但每一個上線的文件代理都繫於它們的成敗。如果你能建構上面的攝入代理 —— 正確的來源類型、有序的區塊、作為證據的 citations、繞過結構化輸出**不相容**的兩趟設計,以及一份把像素與頁面也算進去的 token 預算 —— 你就能交付一個正確、可稽核、又負擔得起的文件代理。

第 23 章:Claude Agent SDK

參考 —— 超出考綱。文件:[Agent SDK overview](#) · [Agent loop](#) · [Sessions](#) · [Permissions](#) · [Hooks](#)。

Claude Agent SDK(Python `claude-agent-sdk`、TypeScript `@anthropic-ai/claude-agent-sdk`)就是把 **Claude Code** 當函式庫 —— 與 Claude Code CLI 同一套內建工具、代理迴圈與上下文管理,可從你自己的程式碼呼叫。(前身為「Claude Code SDK」; `claude -p` 是它的 CLI 形式。)

第 3 章建立了考試所需的**基礎**代理迴圈與它唯一可靠的停止訊號(`stop_reason == "end_turn"`)、hub-and-spoke 編排、對子代理的明確脈絡傳遞、hooks-vs-提示,以及最小權限。第 15 章把 **harness** 這個概念推廣開來——你寫在模型**外面**的一切——而第 24 章涵蓋 **Managed Agents**,由 Anthropic 為你跑迴圈與沙箱。**本章夾在兩者之間:它是 SDK 深入篇——Anthropic 已經幫你寫好的那個 harness,跑在**你的**行程內,以及如何在正式環境中驅動它。**第 3 章問的是「代理是什麼」,本章問的是「`query()` 到底做了什麼,以及我該如何大規模操作它」。

這是進階、超出考綱的材料。全章的取向都是**正式環境代理工程**:不是能跑就好的最小範例,而是決定一個 SDK 代理在無人看管執行時是否便宜、安全、可觀測、可恢復的那些決策。

本章涵蓋:

- **兩個進入點與訊息串流**(§23.1)——`query()` vs `ClaudeSDKClient`,以及 SDK 送出的型別化事件。
- **Sessions 與工作階段生命週期**(§23.2)——持久化到磁碟、擷取、resume、continue 與 fork。
- **內建 harness**(§23.3)——回合、自動 compaction、預算,以及迴圈如何結束。
- **權限、hooks 與優先序鏈**(§23.4)——SDK 給你的確定性控制面。
- **自訂工具與 MCP 接線**(§23.5)——透過 `@tool` 的行程內工具,與透過 `mcp_servers` 的外部伺服器。
- **端到端案例研究**(§23.6)——一個建構在 SDK 上的 CI 分流代理。
- **關鍵整理**(§23.7)。

23.1 兩個進入點,一條訊息串流

SDK 只暴露兩種啟動代理的方式,而選對是第一個正式環境決策。

flowchart TD

```
Need[需要跑一個代理] --> Multi{是否多個提示<br/>共享脈絡?}
Multi -->|否,單一任務| Q[用 query<br/>async iterator,一次性]
Multi -->|是,多回合| C[用 ClaudeSDKClient<br/>持有 session]
Q --> StreamQ[迭代訊息串流]
C --> StreamC[Stream]
Stream --> Init[SystemMessage init<br/>session_id, model]
Init --> Turns[AssistantMessage 與 UserMessage<br/>每回合一對]
Turns --> Result[ResultMessage<br/>subtype, cost, usage]
```

`query()` 是一個 async generator。你給它一個 `prompt` 與 `ClaudeAgentOptions`,然後 `async for` 迭代它送出的訊息,直到 `ResultMessage` 抵達。它適用於一次性、互相獨立的任務——一個 CI 工作、一支 cron 腳本、單次「修好失敗的測試」執行。每次呼叫都是自足的。


```
import asyncio
from claude_agent_sdk import query, ClaudeAgentOptions, ResultMessage

async def main():
    async for message in query(
        prompt="Find and fix the bug in auth.py",
        options=ClaudeAgentOptions(allowed_tools=["Read", "Edit", "Bash"]),
    ):
        if isinstance(message, ResultMessage) and message.subtype == "success":
            print(message.result)

asyncio.run(main())
```

TypeScript 的形狀是同一個 generator 樣式,選項用 camelCase:

```
import { query } from "@anthropic-ai/claude-agent-sdk";

for await (const message of query({
  prompt: "Find and fix the bug in auth.ts",
  options: { allowedTools: ["Read", "Edit", "Bash"] },
})) {
  if (message.type === "result" && message.subtype === "success") {
    console.log(message.result);
  }
}
```

ClaudeSDKClient (Python)是一個長存物件,跨多次 `client.query()` 呼叫持有一個 session——每個新提示都自動延續同一個對話,你完全不必處理 session ID。它適用於同一行程內的多回合聊天,或任何後續步驟必須看見前一回合做了什麼的場合。把它當成 async context manager 使用,連線建立/拆除就會幫你處理好,並呼叫 `client.receive_response()` 來迭代當前查詢的訊息(它會在 `ResultMessage` 之後停止)。它也暴露 `interrupt()` 以在任務中途取消,以及 `set_permission_mode()` 以即時收緊或放寬權限。

```
from claude_agent_sdk import ClaudeSDKClient, ClaudeAgentOptions

async with ClaudeSDKClient(options=ClaudeAgentOptions(allowed_tools=["Read",
"Edit"])) as client:
    await client.query("Analyze the auth module")
    async for msg in client.receive_response():
        ...
    await client.query("Now refactor it to use JWT") # 同一 session,完整脈絡
    async for msg in client.receive_response():
        ...
```

TypeScript 沒有 client 物件。TS SDK 沒有像 Python `ClaudeSDKClient` 那樣的物件,而是讓每次 `query()` 呼叫各自獨立,你在後續呼叫傳 `continue: true` 來接續該目錄中最近的 session。(實驗性的 V2 `createSession()` API 已在 TS SDK 0.3.142 移除——改用 `query()` 加上 session 選項。)

訊息串流就是合約。不論用哪個進入點,SDK 都會送出同樣五種核心訊息型別,而正確讀取它們,正是穩健整合與脆弱整合的分野:

訊息	何時送出	你拿它做什麼
<code>SystemMessage (subtype="init")</code>	session 的第一個訊息	擷取 <code>session_id</code> (Python: <code>message.data["session_id"]</code> ;TS: <code>message.session_id</code>)。
<code>AssistantMessage</code>	每次 Claude 回應後	進度:文字 + 本回合請求了哪些工具。
<code>UserMessage</code>	每次工具執行後	餵回 Claude 的工具結果(也包含你串流送入的輸入)。
<code>StreamEvent</code>	僅在啟用 partial messages 時	供即時 UI 的 token 級增量。
<code>ResultMessage</code>	迴圈結束	終結記錄: <code>subtype</code> 、 <code>result</code> 、 <code>total_cost_usd</code> 、 <code>usage</code> 、 <code>session_id</code> 。

陷阱——在 `result` 上 `break`。少數尾隨的系統事件(例如 `prompt_suggestion`)可能在 `ResultMessage` 之後才抵達。請把串流迭代到結束,而不是一看到 `result` 就 `break` ,否則你可能在 generator flush 到一半時取消它。陷阱——鬆散地檢查訊息型別。Python 用 `isinstance(message, ResultMessage)` ;TypeScript 檢查 `message.type === "result"` ,並記得 TS 會包裹 API 訊息,所以內容區塊位在 `message.message.content` ,而非 `message.content` 。

23.2 Sessions 與工作階段生命週期

session 是 SDK 在代理工作時累積的對話歷史:你的提示、每一次工具呼叫、每一個工具結果,以及每一個回應。**SDK 會自動把它寫到磁碟**——Python 永遠寫,TypeScript 除非你設了 `persistSession: false` 。回到一個 session 會還原完整脈絡:已讀過的檔案、已做過的分析、已下過的決定。(session 持久化的是對話,不是檔案系統——要快照並還原檔案變更,請用 file checkpointing。)

```
flowchart TD
    Start[第一次 query] --> Run[代理跑回合]
    Run --> Write[SDK 寫 JSONL<br/>放在編碼後的 cwd 下]
    Write --> Cap[從 ResultMessage<br/>擷取 session_id]
    Cap --> Choice{稍後回來?}
    Choice -->|同一 session,接續| Resume[以 id resume]
    Choice -->|最近的,免 id| Cont[continue conversation]
    Choice -->|分支,保留原始| Fork[resume 加 fork_session]
    Fork --> NewId[新 session_id<br/>原始不受影響]
```

擷取 ID 來自 `ResultMessage.session_id` (每個 `result` 都有,無論成功或錯誤)。**Resume** 是把那個 id 傳給 `resume` ——代理會帶著完整的先前脈絡接續。常見原因:在不重讀檔案的情況下接續一份已完成的分析;從 `error_max_turns` 或 `error_max_budget_usd` 停止後,以更高的上限 `resume` 來復原;或在你的行程重啟後還原對話。

```
# 第一次執行:擷取 id
session_id = None
async for message in query(prompt="Analyze the auth module", options=opts):
    if isinstance(message, ResultMessage):
        session_id = message.session_id

# 稍後:帶完整脈絡 resume
async for message in query(
    prompt="Now implement the refactoring you suggested",
    options=ClaudeAgentOptions(resume=session_id, allowed_tools=["Read", "Edit",
"Write"]),
):
    ...
```

Continue vs resume vs fork 是常考的區分:

- **Continue**(`continue_conversation=True` / `continue: true`)接續目前目錄中最近的 session——不必追蹤 ID。當應用程式一次只跑一個對話時很適合。
- **Resume** 接的是特定的 session ID。多使用者應用(每個使用者一個 session),或要回到不是最近的某個 session 時,就必須用它。
- **Fork**(`resume=id` 加上 `fork_session=True`)建立一個新 session,以原始歷史的副本為起點再分岔出去。原始的 ID 與歷史維持不變,因此你可以探索替代方案(「如果改用 OAuth2 呢?」),同時保留回到原始主線的選項。

第一大 resume 陷阱: `cwd` 不一致。session 儲存在 `~/.claude/projects/<encoded-cwd>/<session-id>.jsonl`,其中 `<encoded-cwd>` 是把絕對工作目錄裡每個非英數字元都換成 `-`。如果你的 resume 呼叫從不同目錄執行,SDK 會找錯地方,並悄悄地從頭開始。該 session 檔案也必須存在於當前這台機器上。

因此**跨主機 resume**(CI worker、短暫容器、serverless)需要刻意處理。你有兩個選項,而第二個通常更穩健:
(a)把 JSONL 檔案鏡像到共享儲存,並在 resume 前還原到相同路徑(`SessionStore` adapter 可自動化此事);
或(b)**完全不依賴逐字稿 resume**——把你需要的結果(分析輸出、決定、diff)擷取成應用程式狀態,餵進一個全新 session 的提示。把逐字稿檔案搬來搬去很脆弱;把一份小而結構化的摘要往前傳才是正式環境做法(這就是第 15 章的外部化狀態原則,套用到 session 上)。兩個 SDK 也都暴露 `list_sessions()` / `get_session_messages()`,可用來打造自訂的選擇器、清理邏輯或逐字稿檢視器。

23.3 內建 harness:回合、compaction 與停止

第 15 章點出:一個代理是模型加上一個 harness。Agent SDK 的價值在於它附帶一個正式環境級的 harness,讓你不必手寫迴圈。理解那個 harness 在每回合做什麼,正是你除錯與調校它的方式。

一個回合(turn)是迴圈內的一次往返: Claude 產生含工具呼叫的輸出,SDK 執行那些工具,結果再餵回 Claude——過程中不把控制權交還你的程式碼。回合會重複,直到 Claude 產生一個沒有工具呼叫的回應,此時迴圈結束,你就拿到 `ResultMessage`。一個「這裡有哪些檔案?」的提示也許是一個回合;「重構 auth 模組並更新測試」也許是數十個回合。

脈絡在一個 session 內累積,且不會在回合之間重設——系統提示、工具定義、對話歷史、每一個工具輸入與輸出。穩定的前綴(系統提示、工具 schema、CLAUDE.md)會被自動 **prompt-cache**,所以重複的回合對前綴只以全價的一小部分計費。這是 SDK 幫你做了第 18 章的快取工作;你主要只要別去破壞它(別每回合都翻攪系統提示)。

自動 compaction 是讓長時間執行得以成立的 harness 功能。當上下文視窗逼近上限,SDK 會摘要較舊的歷史以釋出空間,保留近期交流與關鍵決定,並送出一個 `subtype: "compact_boundary"` 的

`SystemMessage`。取捨是真實的:**compaction 可能把早期的特定指令摘要掉**。對正式環境有兩個後果:

- **把持久規則放進 CLAUDE.md,而非開場提示。** CLAUDE.md 會在每個請求重新注入(經由 `setting_sources` / `settingSources` 載入),所以它撐得過 compaction;埋在滾動歷史第 1 回合的指令則不一定。你甚至可以加一個自由格式的「摘要時要保留什麼」段落,讓 compactor 像讀任何其他脈絡一樣讀它。
- **用 PreCompact hook** 在歷史被摘要前歸檔完整逐字稿,如果你需要一份「丟掉了什麼」的稽核軌跡。

停止是 SDK 代理在正式環境最常出錯之處,而規則正是第 3 章那條,只是落地了。**主要出口**是模型自行完成(最後一回合沒有工具呼叫)。在這之上,你設下**次要護欄**,以在模型永遠不完成時限制波及範圍:

- `max_turns` / `maxTurns` —— 限制工具使用往返次數。觸發時送出 `subtype: "error_max_turns"` 的 `ResultMessage`。
- `max_budget_usd` / `maxBudgetUsd` —— 限制花費。觸發時送出 `subtype: "error_max_budget_usd"`。

```
flowchart TD
    R[ResultMessage] --> S{檢視 subtype}
    S -->|success| Use[讀取 result<br/>該欄位存在]
    S -->|error_max_turns| Resume[以更高上限<br/>resume session]
    S -->|error_max_budget_usd| Cost[停止或調高預算]
    S -->|error_during_execution| Retry[API 或取消失敗<br/>重試或告警]
    Use --> Track[記錄 cost, usage, session_id]
    Resume --> Track
    Cost --> Track
    Retry --> Track
```

永遠在讀 result 前先按 subtype 分流。 `result` 文字欄位只在 `success` 時存在;其他每個 `subtype`(`error_max_turns`、`error_max_budget_usd`、`error_during_execution`、`error_max_structured_output_retries`)都省略它,但仍帶有 `total_cost_usd`、`usage`、`num_turns` 與 `session_id`,讓你能追蹤成本並 resume。另有一個 `stop_reason`(`end_turn`、`max_tokens`、`refusal`);檢查 `stop_reason == "refusal"` 就是你偵測模型拒絕請求的方式。****陷阱:**把迭代上限當成正常*出口**。如果你的代理常態性地撞到 `max_turns`,那是任務拆解不足(第 15 章)——解法是把工作切成更小的單位或委派給子代理,而不是只把上限調高。

23.4 權限、hooks 與優先序鏈

第 3 章點出了那條頭條規則:**確定性的商業/安全規則屬於程式碼,而非提示**。SDK 給你三層確定性控制,而在正式環境你必須清楚知道它們的確切評估順序,因為那個順序決定了哪一層勝出。

flowchart TD

```
Req[Claude 請求一個工具] --> Hooks[1. Hooks<br/>PreToolUse 可直接 deny]
Hooks --> Deny[2. Deny 規則<br/>disallowed_tools, settings]
Deny --> Ask[3. Ask 規則<br/>轉給回呼]
Ask --> Mode[4. 權限 mode]
Mode --> Allow[5. Allow 規則<br/>allowed_tools, settings]
Allow --> Cb[6. canUseTool 回呼<br/>執行期決策]
Cb --> Exec[執行工具]
Hooks -. deny .-> Blocked[已封鎖]
Deny -. 命中 .-> Blocked
```

三個控制層,由最粗到最細:

1. **Allow / deny 規則** —— `allowed_tools` / `allowedTools` 預先核准列出的工具,使其免提示執行; `disallowed_tools` / `disallowedTools` 不論 `mode` 都封鎖工具。裸名("Bash")會把該工具從 Claude 的脈絡中整個移除,限定範圍的規則("Bash(rm *)")則保留 `Bash`,但在每一種 `mode`(包含 `bypassPermissions`)都拒絕命中的呼叫。MCP glob 僅在字面伺服器前綴之後才允許(`mcp__github__get_*`); `allowed_tools` 裡未錨定的 `"**"` 會被忽略並發出警告。
2. **權限 mode** —— 對未被規則涵蓋的工具的全域政策: `default` (未命中的工具落到你的回呼;沒有回呼就視為 `deny`)、`acceptEdits` (自動核准工作目錄內的檔案編輯與常見 `fs` 指令)、`plan` (探索並提案而不編輯——檔案編輯永不自動核准)、`dontAsk` (拒絕任何未預先核准者;從不提示)、`bypassPermissions` (核准任何到達它的東西——僅供隔離的 CI/容器)。你可以用 `set_permission_mode()` 在中途改它,例如從 `default` 起步,在信任做法後切到 `acceptEdits`。
3. **canUseTool 回呼** —— 對任何未解決者的執行期決策。它接收 `(tool_name, input_data, context)` 並回傳 `allow` 或 `deny`:

```
from claude_agent_sdk.types import PermissionResultAllow, PermissionResultDeny

async def can_use_tool(tool_name, input_data, context):
    if tool_name == "Bash":
        # 帶修改核准:把每個指令限定進沙箱目錄
        safe = {**input_data, "command": input_data["command"].replace("/tmp",
            "/tmp/sandbox")}
        return PermissionResultAllow(updated_input=safe)
    return PermissionResultDeny(message="Not permitted; try a read-only approach instead.")
```

這個回呼能做的不只是是/否:**帶修改核准**(淨化路徑、加上約束——不會告訴 Claude 你改了輸入)、**建議替代方案**(以一則引導 Claude 的訊息 `deny`)、或**核准並記住**(回送一個 `PermissionUpdate` 建議,使下次命中的呼叫跳過提示)。在 TypeScript 回傳形狀是 `{ behavior: "allow", updatedInput } / { behavior: "deny", message }`。

為何順序在實務上重要。 有兩個事實常讓人栽跟頭。第一,`** allowed_tools` 並不約束 `bypassPermissions *`——那個 `mode` 會核准每一個*工具,而不只是列出的那些,因為未列出的工具會落到 `mode` 檢查。如果你需要 `bypass` 的速度但想封鎖特定工具,請用 `disallowed_tools` (`deny` 規則在 `mode` 之前檢查)。第二,**hooks 先跑**,而 hook 的 `deny` 是最終的,這正是為什麼 `hooks`——而非回呼——才是硬性、不可協商規則的正確歸宿。

Hooks 是「模型通常會遵守」的確定性版本。`PreToolUse` hook 在工具執行之前觸發,可封鎖、修改或核准它;它回傳一個帶有 `permissionDecision` 的 `hookSpecificOutput` :

```
from claude_agent_sdk import HookMatcher

async def block_secret_writes(input_data, tool_use_id, context):
    path = input_data["tool_input"].get("file_path", "")
    if path.split("/")[-1] in {".env", "secrets.yaml"}:
        return {"hookSpecificOutput": {
            "hookEventName": input_data["hook_event_name"],
            "permissionDecision": "deny",
            "permissionDecisionReason": "Refusing to write secret files.",
        }}
    return {}  # 空 = 原樣放行

options = ClaudeAgentOptions(
    hooks={"PreToolUse": [HookMatcher(matcher="Write|Edit", hooks=
    [block_secret_writes])]}
)
```

關於 hooks 的關鍵正式環境事實: `matcher` 只以工具名稱過濾(要以路徑過濾,請在回呼內檢查 `tool_input`);當多個 hook 命中時,它們平行執行,而 `deny` 永遠勝出;hooks 跑在*你的*行程,不消耗脈絡;而 `PostToolUse` hook 可在 Claude 看到前改寫工具輸出(`updatedToolOutput`)——這是正規化或遮蔽結果的自然之處。陷阱:當代埋撞到 `max_turns` 時 hooks 可能不觸發,因為 `session` 先結束了——絕不要把必須發生的清理寄望於 `Stop` hook。陷阱(Python): `SessionStart` / `SessionEnd` 在 Python 不能作為回呼 hook 註冊;改以 `setting_sources=["project"]` 把它們當 shell-command hook 載入。

23.5 自訂工具與 MCP 接線

內建工具(Read、Write、Edit、Bash、Glob、Grep、WebSearch、WebFetch、Agent.....)涵蓋很多,但正式環境代理需要*你的*系統。SDK 提供兩條路徑,而在兩者之間抉擇是一個真正的架構決策。

行程內自訂工具 —— 用 `@tool` 裝飾器定義一個函式,並透過 `create_sdk_mcp_server` 暴露它。該工具跑在*你的* Python/TypeScript 行程內,共享記憶體與連線——沒有子行程、沒有網路跳轉。對於你自己擁有的工具,這是延遲最低、隔離最好的選項:


```

from claude_agent_sdk import tool, create_sdk_mcp_server, ClaudeAgentOptions

@tool("refund", "Issue a refund for an order", {"order_id": str, "amount": float})
async def refund(args):
    result = await billing.refund(args["order_id"], args["amount"])
    return {"content": [{"type": "text", "text": f"Refunded {result.id}"]}]}

billing_server = create_sdk_mcp_server(name="billing", version="1.0.0", tools=
[refund])

options = ClaudeAgentOptions(
    mcp_servers={"billing": billing_server},
    allowed_tools=["mcp__billing__refund"], # 注意 mcp__<server>__<tool> 命名
)

```

外部 MCP 伺服器 —— 宣告一個指令(stdio)或 URL(HTTP), SDK 就會執行/連線到它。這是在不必親手寫整合的情況下接上生態系(資料庫、像 Playwright 的瀏覽器、GitHub)的方式:

```

options = ClaudeAgentOptions(
    mcp_servers={"playwright": {"command": "npx", "args":
["@playwright/mcp@latest"]}}
)

```

****取捨:****行程內工具最快,且把機密留在你的行程裡,但它們只能跑你以宿主語言寫的程式碼;外部 MCP 伺服器可重用且與語言無關,但多了一道行程/網路邊界與它們自己的 auth。一個微妙的成本:**每個 MCP 伺服器的工具 schema 可能在每個請求都消耗脈絡**。SDK 預設透過 **tool search** 延後 MCP schema(按需載入),但當 tool search 關閉——或在 Vertex AI 或非第一方 base URL 上——少數各自有許多工具的伺服器,就可能在代理還沒做任何事之前燒掉可觀的脈絡。把子代理的 `tools` 限定到最小,並對大型伺服器優先採用 tool search。

MCP 工具以 `mcp__<server>__<action>` 命名(`<server>` 段是你在 `mcp_servers` 用的鍵)。那個命名正是你的 `allowed_tools` 條目、hook matcher(`^mcp__`)與 deny 規則所瞄準的對象。

23.6 端到端案例研究:一個 CI 失敗分流代理

上述零件唯有組裝起來才有意義。這裡是一個實際的 SDK 代理——有別於第 3 章的退款代理與第 15 章的隔夜遷移器——它跑在一條 **CI 管線內**,以分流一個失敗的建置:重現失敗、找出原因、在分支上提出修復,然後把 diff 交給人類或停止。它必須全自動(沒有互動式提示)、成本受嚴格限制、被確定性地禁止觸碰某些檔案,並且可從管線日誌觀測。

需求

- 在紅色建置上被無頭觸發;**沒有人**在鍵盤前,所以它不能退回到權限提示。
- 可以讀取 repo、跑測試套件,並在新分支上用 `git` ——但**絕不可**推到 `main` 或修改 CI 設定或機密。此事在程式碼中強制執行。
- ****硬性成本上限:****這個工作必須在固定的金額預算停止,而不是一個飄忽的測試上失控狂跑。
- 每個動作都必須可從 CI 日誌**稽核**,且結果必須明白說出是否產出了修復。

- 如果它在預算內無法修好建置,它必須在後續工作中**乾淨地 resume**,而非重頭開始。

架構

```
flowchart TD
    CI([CI 紅色建置]) --> Q[query 加 options]
    Q --> Mode[permission_mode dontAsk<br/>無互動式退路]
    Mode --> Allow[allowed_tools<br/>Read, Grep, Bash, Edit, Agent]
    Allow --> Hook[{PreToolUse hook<br/>封鎖推 main 與 CI 檔案}]
    Hook --> Loop[內建代理迴圈<br/>重現、定位、修復]
    Loop --> Sub[Agent 工具委派<br/>log 分析子代理]
    Loop --> Budget[{max_budget_usd<br/>次要護欄}]
    Budget --> Res[ResultMessage<br/>按 subtype 分流]
    Res --> Done([分支上的修復或乾淨停止])
```

SDK 供應迴圈、工具與 compaction;**hook** 供應不可協商的規則, **dontAsk** 移除互動式逃生口——兩者皆確定性,皆不在提示裡。

實作

設定一個無頭、受限、被確定性圍住的代理。**dontAsk** 是關鍵的無頭選擇:任何未預先核准的東西都被**拒絕**,而不是吊在一個無人會回答的 **canUseTool** 回呼上。

```

from claude_agent_sdk import query, ClaudeAgentOptions, HookMatcher, ResultMessage,
AgentDefinition

FORBIDDEN = ("git push", "git push origin main", ".github/workflows", "secrets")

async def guard(input_data, tool_use_id, context):
    if input_data["hook_event_name"] != "PreToolUse":
        return {}
    blob = str(input_data.get("tool_input", {}))
    if any(f in blob for f in FORBIDDEN):
        return {"hookSpecificOutput": {
            "hookEventName": input_data["hook_event_name"],
            "permissionDecision": "deny",
            "permissionDecisionReason": "Pushing main, editing CI, or touching
secrets is forbidden.",
        }}
    return {}

options = ClaudeAgentOptions(
    system_prompt="You triage CI failures. Reproduce, find the cause, fix on a new
branch. Never claim a fix you have not run.",
    allowed_tools=["Read", "Grep", "Glob", "Bash", "Edit", "Agent"],
    permission_mode="dontAsk",          # 無頭:拒絕而非提示
    max_budget_usd=5.00,                # 硬性成本上限 -> error_max_budget_usd
    setting_sources=["project"],         # 載入 CLAUDE.md 慣例;撐過 compaction
    agents={                            # 給吵雜 log 分析用的最小權限子代理
        "log-analyst": AgentDefinition(
            description="Reads CI logs and extracts the failing test and stack
trace.",
            prompt="Return the failing test name and root-cause stack frame as
text.",
            tools=["Read", "Grep"],      # 不能編輯或跑指令
        )
    },
    hooks={"PreToolUse": [HookMatcher(matcher="Bash|Edit|Write", hooks=[guard])]},
)

```

驅動它,並按終結 subtype 分流——這是多數示範略過的正式環境部分:

```

async def triage():
    session_id = None
    async for message in query(prompt="The build is red. Triage and fix it.",
options=options):
        if isinstance(message, ResultMessage):
            session_id = message.session_id
            if message.subtype == "success":
                print(f"FIX READY on branch:\n{message.result}")
            elif message.subtype == "error_max_budget_usd":
                # 用完預算,不是用完進度:在後續工作 resume。
                print(f"BUDGET HIT. Resume session {session_id} to continue.")
            else:
                print(f"STOPPED: {message.subtype}")
            if message.total_cost_usd is not None:
                print(f"cost=${message.total_cost_usd:.4f} turns={
message.num_turns}")
        return session_id

```

執行軌跡

```

sequenceDiagram
    actor CI as CI runner
    participant SDK as Agent SDK harness
    participant Mo as 模型
    participant Gd as PreToolUse guard
    participant La as log-analyst 子代理
    CI->>SDK: query, 建置是紅的
    SDK->>Mo: 提示加工具
    Mo-->>SDK: tool_use Agent, log-analyst
    SDK->>La: 隔離脈絡, CI log 路徑
    La-->>SDK: 失敗測試加 stack frame
    SDK->>Mo: tool_result, 原因
    Mo-->>SDK: tool_use Bash, git push origin main
    SDK->>Gd: 執行前評估
    Gd-->>SDK: deny, 禁止推 main
    SDK->>Mo: tool_result 已拒絕加原因
    Mo-->>SDK: tool_use Edit 修復加 Bash 在分支跑測試
    Mo-->>SDK: end_turn
    SDK-->>CI: ResultMessage success, 分支上的修復

```

注意是 harness——而非模型——保證了什麼:被禁止的 `git push origin main` 在執行前就被 hook 封鎖,並以一個模型可以繞過的結果回來(它改用了分支);吵雜的 log 分析跑在一個隔離的子代理裡,所以主脈絡從未被原始 log 行塞滿;而若模型陷入迴圈, `max_budget_usd` 會以一個可恢復的 `error_max_budget_usd` 停下它,而非無止境的帳單。

驗證

- ****無頭測試:****在沒有 `canUseTool` 回呼的情況下執行,並確認一個未核准的工具是被拒絕*(而非吊住)——證明 `dontAsk` 移除了互動式退路。

- ****guard 測試:***提示代理推 `main` 或編輯 `.github/workflows`;斷言 `hook` 把它當成結果*拒絕,且迴圈在分支上繼續。
- ****預算測試:****對準一個永久飄忽的套件;斷言執行在 `error_max_budget_usd` 停止,且 `resume` 擷取到的 `session_id` 會接續而非重啟。
- ****最小權限測試:****斷言 `log-analyst` 子代理無法呼叫 `Bash` 或 `Edit`。

常見陷阱

- 在無頭工作把 `permission_mode` 留在 `default` ——每個未核准的工具都會永遠卡住,等一個無人會回答的回呼(請用 `dontAsk`)。
- 把「不要推 `main`」放進**系統提示**而非 `hook`——機率性,而非保證(\$23.4)。
- 把 `error_max_budget_usd` 當成失敗而丟棄 `session`,而不是**resume** 它(\$23.2)。
- 忘了 `setting_sources=["project"]` 才是載入 `CLAUDE.md` 的東西——沒有它,你的慣例會在第一次 `compaction` 時消失(\$23.3)。

23.7 關鍵整理

概念	要記住的重點
兩個進入點	<code>query()</code> 用於一次性 <code>async-iterator</code> 任務; <code>ClaudeSDKClient</code> (Python)用於持有多回合 <code>session</code> 。TS 用 <code>query()</code> + <code>continue: true</code> (\$23.1)。
訊息串流	五種型別: <code>SystemMessage(init)</code> → 每回合 <code>Assistant / User</code> → <code>ResultMessage</code> 。迭代到結束; 按 <code>result.subtype</code> 分流(\$23.1、\$23.3)。
Sessions	以 JSONL 持久化在編碼後的 <code>cwd</code> 下;擷取 <code>session_id</code> ,然後 resume (按 id)、 continue (最近)或 fork (<code>resume</code> + <code>fork_session</code>)。 <code>cwd</code> 不一致會悄悄破壞 <code>resume</code> (\$23.2)。
內建 harness	SDK 跑迴圈、對穩定前綴 <code>prompt-cache</code> ,並在脈絡上限 自動 compact ——把耐久規則放進 <code>CLAUDE.md</code> ,而非第 1 回合(\$23.3)。
停止	主要出口 = 模型自行完成(無工具呼叫); <code>max_turns</code> / <code>max_budget_usd</code> 是次要護欄,以可 <code>resume</code> 的 <code>error_*</code> subtype 浮現(\$23.3)。
控制面	優先序: <code>hooks</code> → <code>deny</code> 規則 → <code>ask</code> 規則 → <code>mode</code> → <code>allow</code> 規則 → <code>canUseTool</code> 。硬性規則放進 <code>hooks</code> (<code>deny</code> 勝出、先跑); <code>bypassPermissions</code> 無視 <code>allowed_tools</code> (\$23.4)。
工具與 MCP	行程內 <code>@tool</code> + <code>create_sdk_mcp_server</code> (快、機密留在本地)vs 外部 <code>mcp_servers</code> (可重用、與語言無關)。MCP 工具是 <code>mcp_server_action</code> ;留意 <code>schema</code> 的脈絡成本(\$23.5)。

超出考綱,但建構其上。 第 3 章給你考試會考的代理概念;本章是那些概念在 SDK 中實際的實作樣貌——迴圈就是 `query()`,`hooks` 是有優先序的真實回呼,上下文管理是自動 `compaction`,而「最小權限」是一條六步規則鏈。掌握了這些,你就能交付一個便宜、安全、可觀測、可恢復的 SDK 代理——然後在你想讓 Anthropic 為你跑迴圈與沙箱時,升級到 **Managed Agents**(第 24 章)。

第 24 章:Managed Agents(託管代理)

參考——超出考綱。文件:Managed Agents overview。Beta 標頭 managed-agents-2026-04-01。

第 1–13 章教你如何建構一個代理:迴圈、工具、hooks、子代理、上下文。本章談的是在生產環境裡由誰來跑這個代理。當你代理上線時,你會面臨一個 Foundations 考試從不提及、但每個真實部署都被迫面對的基礎設施抉擇:你要自己跑代理迴圈與它的工具沙箱(第 23 章的 Agent SDK,部署在你自己的算力上),還是讓 Anthropic 同時託管兩者(Managed Agents)?這是一個控制 vs 便利的取捨,而選錯方向兩邊都很昂貴——太偏便利,你就失去檢視與約束一個會花錢、會碰資料的系統的能力;太偏控制,你就得重造沙箱、祕密注入、重試與可觀測性,而這些託管平台早已解決。

本章是前瞻性的。下面的物件模型、建立一次原則,以及 SSE 事件形狀,在 managed-agents-2026-04-01 beta 中已確立;而營運實務——你如何擴展、觀測,以及在兩種託管模式間取捨——仍在演進中,請把它當成一套推理框架,而非凍結的 API 合約。讀完你應能:

- 把三種執行環境放上同一條軸線(§24.1)—— Client SDK、Agent SDK、Managed Agents——並依「誰跑迴圈、誰擁有算力」來選。
- 推理事件模型(§24.2)—— Agent vs Session vs Environment,以及為何設定放在 agent 上、絕不放在 session。
- 正確驅動一個 session(§24.3)——先開串流再送、以去重方式重連,以及 webhooks vs 一直掛著的串流。
- 選擇託管拓撲(§24.4)——完全託管 vs 自架沙箱,各自買到什麼、付出什麼。
- 在生產環境營運代理(§24.5)—— vaults、memory stores、scheduled deployments,以及可觀測性。

§24.6 建構一個端到端案例研究——一支生產級程式碼審查代理隊伍——§24.7 則濃縮各項決策。

24.1 Managed Agents 的定位:一條軸線,三種執行環境

Anthropic 提供三種跑模型驅動工作的方式。它們不是彼此競爭,而是同一條軸線上的不同點,由兩個問題界定:誰執行代理迴圈,以及誰提供工具執行的算力(沙箱)?

flowchart TD

```
Start[我需要跑一個代理] --> Q1{誰跑迴圈?}
Q1 -->|我自己寫 while 迴圈| Client[Client SDK<br/>anthropic<br/>原始 Messages API]
Q1 -->|函式庫在我的行程內跑| SDK[Agent SDK<br/>迴圈加工具<br/>在我的行程內]
Q1 -->|Anthropic 來跑| Q2{誰擁有<br/>沙箱算力?}
Q2 -->|Anthropic 託管容器| Managed[Managed Agents<br/>完全託管]
Q2 -->|我的基礎設施經由輪詢 worker| SelfHost[Managed Agents<br/>自架沙箱]
Client -. 更多控制更多膠水程式 .-> SDK
SDK -. 更少維運更少控制 .-> Managed
```

執行環境	誰跑迴圈	誰擁有算力	你要寫	你要營運
------	------	-------	-----	------

Client SDK (anthropic)	你	你	依 stop_reason 的 while、每個工具、重試、上下文修剪	全部
Agent SDK (第 23 章)	函式庫,在你的行程內	你	設定 + 工具實作;迴圈已提供	你的主機、擴展、日誌
Managed Agents	Anthropic	Anthropic (或你的基礎設施,自架)	設定 + 一條事件串流	幾乎不用(完全託管)

為何這對考試的心智模型重要:第 23 章說「Agent SDK = 迴圈在你的行程內跑」。Managed Agents 把這條界線往外推——Anthropic 在伺服器端跑迴圈,並為每個 session 配置一個容器,讓代理的 bash、檔案與程式工具在其中執行。你不再擁有執行環境,改為擁有設定與事件處理。這個決策很少是關於能力(兩者都能建出同一個代理),幾乎總是關於誰該承擔沙箱、祕密處理與可靠性的維運負擔。

把取捨講白:

- **便利這一側(託管):**沒有容器編排、沒有祕密注入的管線、內建重試、排程觸發,還有一個憑證庫。你出貨更快、營運更少。
- **控制這一側(自架 harness):**工具執行跑在你能稽核的硬體上、在你掌控的網路內,用的正是你設定的函式庫與 egress 規則。你可以掛上 debugger、釘住某個 kernel,或在 air-gapped VPC 內執行——這些完全託管的沙箱都不允許。

陷阱:把這當成「託管是現代做法,自架是過時遺產」。這是一個法規與營運決策,不是成熟度階梯。受資料落地法規約束的團隊可能必須用自架沙箱,即使 Managed Agents 其餘一切都很合適。

24.2 物件模型:Agent、Session、Environment

Managed Agents 剛好有三個一等公民物件。把這個切分內化——它是浪費與臭蟲最常見的單一來源。

```
flowchart TD
    subgraph SetupOnce[部署時建立一次]
        A[Agent<br/>v1/agents<br/>model, system, tools,<br/>mcp_servers, skills]
        E[Environment<br/>v1/environments<br/>可重用的容器範本]
    end
    end
    subgraph EveryRun[每次執行]
        S[Session<br/>v1/sessions<br/>指向 agent id 加 version<br/>加 environment]
    end
    end
    A -. 以 id 引用 .-> S
    E -. 以 id 引用 .-> S
    S --> Run[一次代理執行<br/>在全新容器中]
```

- **Agent**(/v1/agents)——一份持久、有版本的設定: model、system、tools、mcp_servers、skills。這是代理是什麼、被允許做什麼的定義。建立一次,以 ID 引用。每次有意義的變更都會產生新的 version,因此你可以把 session 釘在已知良好的版本,並刻意地往前滾動。
- **Session**(/v1/sessions)——一次執行。它本身不帶 model、系統提示或工具——只有一個指標 (agent: {type, id, version})加上一個環境與本次執行的輸入。每次執行都建一個。

- **Environment**(`/v1/environments`)——一份可重用的容器範本,描述 session 的工具在其中執行的沙箱。和 agent 一起定義並重用。

⚠ **第一守則(請記牢):** `model` / `system` / `tools` 放在 **agent** 上,絕不放在 `session`; `session` 只拿指標。每次請求都呼叫 `agents.create()` 是典型反模式——它會狂刷版本、把可觀測性切碎(每次執行看起來都像不同的代理),並讓「持久、有版本的定義」這個重點完全失效。

```
# 部署時建立一次 — 儲存 agent.id 與 environment.id
agent = client.beta.agents.create(
    name="Coding Assistant",
    model="claude-opus-4-8",
    tools=[{"type": "agent_toolset_20260401"}],
)
environment = client.beta.environments.create(name="review-sandbox")

# 每次執行 — 一個只「指向」agent + environment 的 session
session = client.beta.sessions.create(
    agent={"type": "agent", "id": agent.id, "version": agent.version},
    environment_id=environment.id,
)
```

這個切分為何存在——三個具體回報:

1. **有版本的滾動發布。**因為設定是可定址、有版本的物件,你可以把 `version: 7` 灰度給 5% 流量、其餘隊伍仍跑 `version: 6`,並靠翻指標回滾——不必重新部署定義本身。
2. **乾淨的可觀測性。**每個 session 都會回報它跑的 agent ID 與 version。「是哪個提示版本產生了這個壞輸出?」變成一次查詢,而不是在日誌裡考古。
3. **便宜的扇出。**啟動一次執行是「建一個指向既有 agent 的 session」,而非「重新上傳整份設定」。一支程序的數千次執行隊伍共用同一份 agent 定義。

****陷阱:****把每次請求的差異(一個客戶 ID、一個目標檔案)塞進新的 agent*,而不是當成 **session** 輸入傳進去。每次執行的資料屬於 session 的輸入/訊息;只有代理本質上是什麼才屬於 agent。

唯一獲准的例外——per-session 覆寫(beta)。你現在可以在不刷版本的前提下,為單一 session 更改部分設定:把 agent 傳成 `{type: "agent_with_overrides", id, ...}`,並附上 `model`、`system`、`tools`、`mcp_servers` 或 `skills` 之中任意欄位。它用於一次性實驗——某一次執行試個較便宜的模型、或多給一個工具——而非塞每次請求資料的後門。規則很嚴格,值得記牢:覆寫是**整欄取代**(從不合併——`tools` 覆寫必須列出該 session 應有的每一個工具);**省略**某欄則從所引用的版本繼承; `null` / `[]` 則**清空**它——但有兩個例外: `model` 永遠不可清空(`model: null` → `400 agent_model_required`),而當生效的 `skills` 非空時 `tools` 不可清空,因為 `skills` 需要 `read` 工具。關鍵是:覆寫**不會**建立新版本、也不會變更 agent 資源,且回應中的 agent 仍帶著基底的 `id` / `version`——所以回報 #2 的「這是哪份定義跑的?」可追溯性依然成立,同一 agent 的其他 session 也不受影響。來源:[Override agent configuration for a session](#)。

24.3 驅動一個 Session:Events、串流與 Webhooks

一個託管 session 是**事件驅動的**。Anthropic 跑迴圈,並發出一條 **Server-Sent Events(SSE)** 串流,即時描述代理正在做什麼。

核心事件型別:

- `agent.message` —— 助理的自然語言輸出。
- `agent.thinking` —— 延伸思考區塊(啟用時)。
- `agent.tool_use` —— 代理在容器內叫用了某個工具。
- `session.status_*` —— 生命週期轉換(running、awaiting input、completed、failed)。

平台強制兩條**不直覺的規則**,兩條都很容易做錯:

規則 1 —— 先開串流再送。SSE **沒有重播**。如果你先送出使用者回合、之後才連線,你可能漏掉這段空檔發出的事件。先開串流,再提交輸入。

規則 2 —— 重連要去重。網路會斷。因為 SSE 不會重播你漏掉的內容,健壯的用戶端會**追蹤它看過的最後一個 event ID**,並在重連時**去重**,而不是假設串流毫無缺口。

```
sequenceDiagram
    actor Dev as 用戶端應用
    participant API as Managed Agents API
    participant Loop as 託管代理迴圈
    participant Box as 每 session 容器
    Dev->>API: 開 SSE 串流(在送出之前)
    Dev->>API: 提交使用者輸入
    API->>Loop: 開始執行
    Loop->>Box: tool_use bash、檔案操作
    Box-->>Loop: 工具結果
    Loop-->>Dev: agent.tool_use、agent.message 事件
    Note over Dev,API: 網路抖動 — 串流中斷
    Dev->>API: 重連,送出最後看到的 event id
    API-->>Dev: 恢復;用戶端依 event id 去重
    Loop-->>Dev: session.status_completed
```

即時 token 預覽——event deltas(選用)。預設下 `agent.message` 是緩衝的:每個事件都要等產生它的那次模型請求**完成後**才抵達。若要在文字生成時就渲染,請**逐連線**選用:在 `GET /v1/sessions/{id}/events/stream` 加上 `event_deltas[]` 查詢參數(可接受值為 `agent.message` 與 `agent.thinking`;其他值回 400,且只有 session 層級的串流接受它——**多代理 thread** 串流會拒絕)。被預覽的訊息會先發一個 `event_start` (宣告即將到來事件的 `id`),接著是攜帶增量文字的 `event_delta` 事件,以 `event_id + delta.index` 為鍵。**預覽是顯示輔助,不是紀錄**——緩衝的 `agent.message` 仍是權威來源,忽略預覽的用戶端仍會收到完整串流;而且(不同於 **Messages API 串流**)沒有逐區塊的 start/stop 事件,增量型別是 `content_delta`,所以 Messages API 的累積器程式碼**無法**原封不動沿用。`agent.thinking` 的預覽只發 `event_start`;其內容仍在緩衝事件中抵達。來源:[Event deltas](#)。

何時不要一直掛著串流:webhooks。對長時間執行或射後不理的工作——夜間批次、scheduled deployment、可能跑好幾分鐘的代理——一直掛著 HTTP 串流既脆弱又浪費。Managed Agents 可以改在狀態變更時送出 **HMAC 簽章的 webhooks**。你驗證簽章,再去拉你需要的東西。**串流**用於你要即時渲染 token 的互動式 UI;**webhooks** 用於非同步、耐久、伺服器對伺服器的工作流。

****陷阱:****把 SSE 串流當成耐久日誌。它是即時*通道,不是紀錄。如果你需要每個動作的稽核軌跡,就在事件抵達時持久化它們(或靠 webhooks + 你自己的儲存)——別指望能在重連後的串流裡「往回捲」。

24.4 託管拓撲:完全託管 vs 自架沙箱

在 Managed Agents 之內還有第二個、更細的決策:**代理的工具究竟在哪裡執行?**Anthropic 永遠跑迴圈*;你選擇誰跑沙箱*。

- **完全託管(預設)**。Anthropic 配置並執行每 session 的容器。你這邊零基礎設施。對多數團隊這是正確的預設。
- **自架沙箱**(`config: {type: "self_hosted"}`)。工具執行經由一個**對外輪詢的 worker** 跑在你的基礎設施上——你的 worker 對外撥接 Anthropic、領取工具執行請求、在你的硬體上跑、再回傳結果。
***Anthropic 仍跑迴圈,*只有沙箱移動。因為 worker 是向外*輪詢,你不必開放對內連接埠——它能從鎖死的 VPC 內運作。*

flowchart TD

```
Loop[託管代理迴圈<br/>在 Anthropic] --> Decide{沙箱型別?}
Decide -->|完全託管| MBox[Anthropic 容器<br/>跑工具]
Decide -->|self_hosted| Poll[你的對外 worker<br/>輪詢工具呼叫]
Poll --> YourBox[你的基礎設施跑工具<br/>你的網路你的函式庫]
YourBox -. 結果 .-> Loop
MBox -. 結果 .-> Loop
```

為何選自架——具體驅力:

- **資料落地 / 主權**。工具執行會在你掌控的地區與司法管轄區的硬體上碰你的資料。
- **網路可達性**。工具需要與未對公網開放的內部服務(資料庫、內部 API)通訊。
- **自訂或授權工具鏈**。沙箱必須包含專有的二進位檔、釘住的函式庫版本,或你無法搬進託管容器的硬體。
- **可稽核性**。安全團隊可以檢視、記錄並精確約束究竟跑了什麼。

***它對你的代價:*你現在要營運這支 worker 隊伍——它的可用性、擴展與修補都成了你的* SLO。你用「託管」買到的便利被部分交還。迴圈、重試與事件管線仍歸 Anthropic,但沙箱的可靠性落在你身上。*

***一句話講取舍:*完全託管把維運最小化;自架把工具副作用發生在哪裡*的控制最大化。只有在有真實約束(落地、可達性、授權、稽核)逼你時才選自架——別當預設。*

24.5 在生產環境營運代理:Vaults、Memory、Schedules、可觀測性

四項平台功能把單一代理變成可營運的生產服務。每一項都取代你在自架 harness 上原本得手寫的膠水程式。

Vaults —— 把憑證做對。一個 vault 是託管代理的憑證庫:MCP OAuth token(會**自動更新**)、靜態 bearer token,以及環境變數祕密。關鍵的安全性質:**祕密在 egress 注入,沙箱內永遠看不到**。代理可以使用某憑證去呼叫 API,卻從來無法**讀取**它——所以被提示注入的代理無法外洩金鑰,因為金鑰從未進入它的上下文。這是「別把祕密放進提示」這個老問題的託管解。(依第 25 章,Managed Agents 的 MCP 伺服器驗證透過 vaults 提供,以 URL 比對伺服器——不是貼進 `mcp_servers` 區塊。)

Memory stores —— 比 session 活得更久的狀態。一個 session 的容器是短暫的;執行一結束,容器就消失。一個 memory store 是工作區範圍、持久的文件集,掛載進容器並跨 session 留存。它有版本、可遮

蔽。這是託管代理累積知識的方式——一份持續演進的設計文件、一份發現帳本、學到的慣例——而你不必架資料庫。(這是第 11 章持久化模式的託管化身。)

Scheduled deployments —— 給代理的 cron。一個 **scheduled deployment** 依 cron 排程自動觸發 session。這是雲端「routines」背後的機制——夜間依賴稽核代理、每小時的分流掃描。你定義排程一次;平台就準時建立 session,不必有你的伺服器一直開著去觸發。

```
flowchart TD
    Cron[Scheduled deployment<br/>cron 觸發] --> New[建立 session<br/>指向 agent + environment]
    New --> Vault[Vault 注入祕密<br/>僅在 egress]
    New --> Mem[掛載 memory store<br/>先前的發現帳本]
    Vault --> Runx[在容器中執行]
    Mem --> Runx
    Runx --> Hook[HMAC webhook<br/>完成時]
    Runx --> Persist[把結果寫回<br/>memory store]
    Hook --> You[你的服務<br/>驗證後再行動]
```

可觀測性——你看得到的與看不到的。因為 Anthropic 跑迴圈,你的可觀測性來自**事件串流與 webhooks**,加上每個 session 上蓋的 **agent ID + version**。你看得到的工具呼叫、訊息、思考與狀態轉換——但你**拿不到**託管容器的主機層存取。如果你需要深入的主機層檢視(行程傾印、kernel 層追蹤),那就是選**自架沙箱**(§24.4)的理由。把你的可觀測性圍繞事件來設計,若需要耐久的稽核軌跡就自己持久化它們(§24.3)。

****陷阱:****以為「託管」等於「完全可觀測」。你得到豐富的事件層*可見性,但託管執行環境在 OS 層是刻意設計的黑盒。在你動手建之前,先把你的稽核需求對齊託管選擇。

24.6 端到端案例研究:生產級程式碼審查代理隊伍

上述元件唯有組裝起來才有意義。以下是一個真實系統,以一個平台團隊實際會採用的方式使用 Managed Agents——並逼出本章每一個決策。

需求

- 一家 SaaS 公司想要一個**自動程式碼審查代理**,對數百個內部儲存庫的每一個 pull request 留言。
- 代理必須**clone 儲存庫、在沙箱中跑靜態分析與測試,並張貼審查留言**——是真實的工具執行,不只是文字。
- 審查必須在**每個 PR 上自動觸發**,並同時以**夜間全儲存庫稽核**執行。
- 代理需要一個 **GitHub token 與一個內部 SAST API 金鑰**——而安全團隊強制要求**任何代理執行都絕不能讀到那些祕密**(來自惡意 PR 的提示注入屬於範圍內威脅)。
- 原始碼受**法規管制**,不得離開公司的雲端地區。
- 平台團隊只有**兩名工程師**,毫無意願去營運一套容器編排系統。

託管決策

兩名工程師加上「別讓我們跑編排」,強烈指向 **Managed Agents**——Anthropic 跑迴圈、重試與排程。但「原始碼不得離開我們的地區」排除了工具執行步驟用完全託管沙箱。解法是**自架沙箱**(§24.4):Anthropic 跑

迴圈;一個在公司 VPC 內、對外輪詢的 worker 在地區內硬體上執行 clone/分析/測試工具。他們在迴圈上得到託管便利,又為副作用得到資料落地——正是 §24.4 存在所要促成的切分。

祕密放進 vault(僅 egress 注入),因此一個試圖印出 `$GITHUB_TOKEN` 的 PR 什麼也拿不到——token 不在代理的上下文裡。夜間稽核是一個 **scheduled deployment**。一個 **memory store** 保存每個儲存庫的「已知問題帳本」,讓代理不再重複標記已被接受的例外。

架構

flowchart TD

```
PR[Pull request 開啟] --> Trig[Webhook 送到平台服務]
Cron[Scheduled deployment<br/>夜間稽核] --> Sess
Trig --> Sess[建立 session<br/>指向審查 agent + env]
Sess --> Loop[Anthropic 託管迴圈]
Loop --> Worker[自架 worker<br/>在公司 VPC 內]
Worker --> Tools[clone、SAST、跑測試<br/>地區內硬體]
Vault[Vault<br/>GitHub 加 SAST 金鑰] -. 僅在 egress 注入 .-> Worker
Mem[Memory store<br/>已知問題帳本] -. 掛載 .-> Worker
Tools -. 結果 .-> Loop
Loop --> Done[完成時送 HMAC webhook]
Done --> Post[平台張貼審查留言]
```

代理只建立一次(`agents.create`, model `claude-opus-4-8`);每個 PR 與每次夜間執行都是一個指向它的 **session**(§24.2)。迴圈是 Anthropic 的;沙箱是公司的;祕密永不進入代理的上下文。

實作草圖

```
# 建立一次 — 有版本的 agent 定義 + 一個自架 environment。
agent = client.beta.agents.create(
    name="pr-reviewer",
    model="claude-opus-4-8",
    system="Review the diff. Run SAST and tests. Comment only on real issues; "
        "skip anything already in the known-issues ledger.",
    tools=[{"type": "agent_toolset_20260401"}],
)

environment = client.beta.environments.create(
    name="vpc-review-sandbox",
    config={"type": "self_hosted"}, # 工具跑在公司的對外 worker 上
)

# 每個 PR 或夜間執行 — 一個只「指向」agent + env 的 session。
def review_pull_request(pr_ref: str):
    return client.beta.sessions.create(
        agent={"type": "agent", "id": agent.id, "version": agent.version},
        environment_id=environment.id,
        input={"pr": pr_ref}, # 每次執行的資料放進 SESSION,不是新建 agent
    )
```


執行軌跡

```
sequenceDiagram
    actor Git as GitHub
    participant Svc as 平台服務
    participant API as Managed Agents
    participant Loop as 託管迴圈
    participant Wk as VPC worker
    Git->>Svc: PR 開啟 webhook
    Svc->>API: 先開 SSE 串流,再建立指向 agent 的 session
    API->>Loop: 開始執行
    Loop->>Wk: tool_use clone 加 SAST 加測試
    Note over Wk: Vault 僅在 egress 注入 GitHub 與 SAST 金鑰
    Wk-->>Loop: 結果,祕密從未進入代理上下文
    Loop->>Wk: 把發現寫進 memory store 帳本
    Loop-->>API: session.status_completed
    API-->>Svc: 完成時送 HMAC webhook
    Svc->>Git: 張貼審查留言
```

注意每個設計選擇買到了什麼:**session 指向 agent** 讓每次執行都落在同一份可稽核、有版本的定義上;**自架沙箱**讓受管制的原始碼留在地區內;**vault** 讓被提示注入的 PR 無法竊取憑證;**memory store** 阻止重複的發現;**scheduled deployment** 免費給了夜間稽核。

驗證

- **建立一次測試:**斷言部署時剛好跑一次 `agents.create` ,且每條 PR 路徑只呼叫 `sessions.create` 。一個每 PR 都建代理的退化必須在這個測試上失敗。
- **祕密隔離測試:**送出一個惡意 PR,其 diff 試圖 echo `$GITHUB_TOKEN` ;斷言該 token 從未出現在任何 `agent.message` 或 `agent.tool_use` 事件裡——vault 只在 egress 注入(\$24.5)。
- **落地測試:**斷言工具執行落在 VPC worker(自架沙箱),絕不在 Anthropic 託管容器。
- **冪等發現測試:**在 memory store 帳本加入一個已接受的例外;重跑;斷言代理不再標記它。
- **串流順序測試:**斷言用戶端在建立 session 之前就開了 SSE 串流,且強制重連會依 event ID 去重(\$24.3)。

常見陷阱

- 每個 PR 都呼叫 `agents.create()` 而非重用 agent ID(狂刷版本、破壞可觀測性——\$24.2)。
- 明明有落地約束卻選了完全託管沙箱,然後才發現受管制的程式碼離開了地區(\$24.4)。
- 把 GitHub token 放進代理的 `system` /輸入而非 vault——一個被提示注入的 PR 就會外洩(\$24.5)。
- 在送出輸入之後才連 SSE 串流而漏掉早期事件;或把串流當成耐久的稽核日誌(\$24.3)。

24.7 關鍵整理

概念	要記住的
三種執行環境,一條軸線	Client SDK(你跑迴圈)→ Agent SDK(函式庫在你的行程內跑)→ Managed Agents(Anthropic 跑迴圈與沙箱)。依誰跑迴圈、誰擁有算力來選(\$24.1)。

物件模型	Agent = 持久、有版本的設定(<code>model / system / tools</code>); Session = 一次執行,只指向 agent; Environment = 可重用的容器範本(\$24.2)。
第一守則	<code>model / system / tools</code> 放在 agent 上,絕不放在 session 。代理只建一次,以 ID 引用;每次執行都 <code>agents.create()</code> 是典型反模式(\$24.2)。
串流紀律	SSE 無重播 :先開串流再送,並以去重重連。非同步/長時間執行的工作用(HMAC 簽章的)webhooks(\$24.3)。
託管拓撲	完全託管(Anthropic 的容器,零維運)vs 自架沙箱 (<code>type: self_hosted</code> ,你的基礎設施經對外輪詢 worker)。兩者迴圈都由 Anthropic 跑;只在落地/可達性/授權/稽核逼你時才選自架(\$24.4)。
生產功能	Vaults 在 egress 注入祕密(沙箱內看不到); memory stores 跨 session 留存(有版本、可遮蔽); scheduled deployments 是給代理的 cron;可觀測性是 事件層 而非主機層(\$24.5)。
控制 vs 便利	託管 = 較少維運、較少控制;自架 harness = 對副作用發生地更多控制、更多維運負擔。這是法規/營運決策,不是成熟度階梯(\$24.1、\$24.4)。

已確立 vs 演進中。物件模型、建立一次原則,以及 SSE 事件名稱,在 `managed-agents-2026-04-01` beta 中已確立。營運實務——隊伍擴展、可觀測性工具,以及託管 vs 自架的界線——仍在成熟中;帶走推理,並在動手建之前重新查閱當前文件。

第 25 章:MCP 深入

參考——*延伸第 4 章*。文件:[Model Context Protocol · Specification · Authorization · MCP connector](#)。

本章屬於 **PART III —— 進階、生產級代理工程**,超出 **Foundations** 考試範圍。第 4 章把 MCP 當作整合層來教:協定是什麼、三個基本元件的概觀、`stdio` vs Streamable HTTP、伺服器要註冊在哪、以及 `isError` 契約。這足以讓你使用一個社群伺服器、並在考試情境中辨認出 MCP。本章則是給必須**建構、發布、加固、營運**一個讓真實團隊倚賴的 MCP 伺服器的工程師——「在 demo 能跑」與「在生產安全」之間的落差,正是由傳輸生命週期細節、OAuth 授權機制、伺服器發起的 `sampling`、以及一套威脅模型所填補。

我們刻意**不重複**第 4 章,而是在它每個主題上再往下挖一層,並補上它從未涵蓋的兩項——**遠端伺服器的 OAuth 2.1 授權**與 **sampling**(伺服器反過來請用戶端的模型思考)。讀完本章,你應能設計一個生產級的遠端 MCP 伺服器,並為其傳輸、授權與安全選擇辯護。

- **三個基本元件,精確版**(\$25.1)—— 工具的 annotations 與 `outputSchema` ;資源的 URI、模板與訂閱;prompt 的引數。控制模型:誰負責**叫用**每一種。
- **傳輸的內部機制**(\$25.2)—— `stdio` 訊息分框及其無聲殺手;Streamable HTTP 工作階段、可續傳性,以及已棄用的 SSE 傳輸。
- **遠端伺服器的授權**(\$25.3)—— OAuth 2.1、metadata 探索(PRM/AS)、Resource Indicators,以及混淆代理人(confused-deputy)陷阱。
- **Sampling**(\$25.4)—— 伺服器向用戶端請求 LLM 補全,以及它為何反轉了一般的信任方向。
- **加固生產伺服器**(\$25.5)—— tool poisoning、輸入驗證、速率限制,以及規模化下的命名空間/探索。

§25.6 接著建構一個完整的遠端 **Knowledge-Base MCP 伺服器** —— OAuth、一個資源、一個由 sampling 支撐的 `summarize` 工具、以及一個 prompt —— §25.7 預覽下一版規格修訂,§25.8 則濃縮工程準則。

25.1 三個基本元件,精確版

第 4 章以**意圖**來框定基本元件 —— Tools **動作**、Resources **告知**、Prompts 是**範本**。生產工作需要下一層：**控制模型**(誰決定叫用每一種)以及每一種在傳輸線上所攜帶的**結構/生命週期**。

```
flowchart TD
    subgraph Primitives[MCP 基本元件依控制模型分類]
        T[Tools<br/>模型控制<br/>代理決定何時呼叫]
        R[Resources<br/>應用控制<br/>host 決定附加什麼]
        P[Prompts<br/>使用者控制<br/>由人觸發]
    end
    end
    T --> SIDE[允許副作用<br/>標註讀取 vs 寫入]
    R --> NOSIDE[唯讀脈絡<br/>以 URI 定址]
    P --> UI[呈現於 UI<br/>例如斜線命令]
```

Tools —— annotations 與 output schema。只有 `name + description + inputSchema` (第 4 章的形態)是最低限度。生產工具會加上協定支援的兩樣東西：

- **Annotations** 是關於行為的**提示**: `readOnlyHint`、`destructiveHint`、`idempotentHint`、`openWorldHint`。host 可據此決定什麼需要確認(`destructiveHint: true` 的刪除)、什麼可以自動執行。它們是建議性的,**不是安全邊界** —— 絕不能靠 `readOnlyHint` 來**強制**唯讀;要在程式碼裡強制 (§25.5)。
- **outputSchema** 宣告**結果的形狀**,而不只是輸入。有了它,用戶端可驗證 `structuredContent`、模型也拿到可靠契約。沒有它,每個工具都回傳不透明文字,代理每一輪都得重新解析自由格式輸出。

```
Tool(
  name="search_kb",
  description="Full-text search over the knowledge base. Read-only.",
  inputSchema={...},
  annotations={"readOnlyHint": true, "openWorldHint": true},
  outputSchema={"type": "object", "properties": {
    "hits": {"type": "array"}, "total": {"type": "integer"}},
)
```

Resources —— URI、模板與訂閱。第 4 章用的是單一靜態的 `catalog://services`。真實的目錄是可定址且動態的：

- **URI 模板**(RFC 6570)讓一個宣告服務一整族: `kb://article/{id}` 在不逐一系列出的情況下暴露每一篇文章。用戶端填入 `{id}` 並呼叫 `resources/read`。
- **訂閱**讓用戶端 `resources/subscribe`,並在底層資料變動時收到 `notifications/resources/updated` —— 於是代理的「地圖」無需輪詢即可保持新鮮。這是資源版的 webhook。

Prompts —— 引數與探索。一個 prompt 是伺服器擁有、由**使用者**觸發的**參數化訊息範本**(斜線命令、選單挑選)。它可接受具型別的引數(`prompts/get` 帶 `{topic}`),並展開成完整的多訊息對話起點。與第 4 章相關的區分仍然成立 —— prompts 由使用者控制、tools 由模型控制 —— 但在生產中,prompt 是你發布一個**經審核、可重用工作流程**(例如「事故報告」)的方式,而非寄望每位使用者都能把它講得好。

陷阱把由使用者觸發的工作流程做成工具*。若某件事該由人從選單挑選,它就是 **Prompt**;若該由模型*在迴圈中途決定呼叫,它才是 **Tool**。弄反不是把工作流程對使用者藏起來,就是把模型的工具清單塞爆(\$25.5)。

25.2 傳輸的內部機制

第 4 章的表格(`stdio` 本機 vs Streamable HTTP 遠端)是那個決策。生產故障則藏在各自的機制裡。

stdio 分框 —— 無聲殺手。 `stdio` 伺服器在 `stdin` / `stdout` 上以換行分隔的 JSON-RPC 溝通。兩條規則造成了多數「伺服器連上了但什麼都不動」的事故：

1. **stdout 是協定通道 —— 它只能承載 JSON-RPC。** 任何走漏的 `print()`、除錯橫幅或函式庫日誌寫到 `stdout`,都會汙染串流,用戶端便切斷連線。**所有日誌都必須走 `stderr`** (host 會替你擷取)。
2. **host 擁有生命週期。** 它生成子行程,而緩慢啟動或被阻塞的事件迴圈會被讀成一台死掉的伺服器。初始化必須快速且非阻塞。

Streamable HTTP —— 工作階段與可續傳性。 遠端伺服器接受 HTTP `POST` 上的 JSON-RPC;回應要嘛是單一 JSON 主體,要嘛是用於串流/伺服器發起訊息的 **SSE** 串流。第 4 章略過的生產關切：

- **工作階段(Sessions)。** 初始化時伺服器可回傳 `Mcp-Session-Id` 標頭;用戶端在之後每個請求都回送它。這正是有狀態伺服器(持有每用戶端訂閱或 `sampling` 狀態者)把請求綁在一起的方式 —— 也是它能讓工作階段過期的方式。
- **可續傳性(Resumability)。** SSE 事件帶有 `id`;若串流中斷,用戶端以 `Last-Event-ID` 重連,伺服器重播遺漏的部分。沒有它,不穩定的網路會無聲地丟失通知。
- **舊的「HTTP+SSE」(雙端點)傳輸已棄用。** 若題目把單純的「SSE transport」當作現代遠端選項,答案是 **Streamable HTTP**(單一端點,可升級為 SSE)—— 與第 4 章的警告相同,如今補上理由:舊設計需要兩個端點且無法乾淨地續傳。

flowchart TD

```
Start[用戶端連遠端伺服器<br/>POST initialize] --> Sess[伺服器回傳<br/>Mcp-Session-Id]
Sess --> Req[用戶端送出請求<br/>回送工作階段 id 標頭]
Req --> Mode{回應需要<br/>串流或<br/>伺服器推送?}
Mode -->|否| JSON[單一 JSON 主體]
Mode -->|是| SSE[開啟 SSE 串流<br/>事件帶有 id]
SSE -- 中斷後重連 --> Resume[以 Last-Event-ID 續傳<br/>伺服器重播遺漏事件]
```

****陷阱***把有狀態*的遠端伺服器擺在天真的負載平衡器後。若 `Mcp-Session-Id` 沒被固定到持有該工作階段狀態的那個實例,下一個請求落到冷節點上,工作階段就斷了。要嘛讓伺服器無狀態,要嘛採用工作階段親和性(session affinity)。

連到位於你私有網路內的伺服器 — MCP tunnels。 Streamable HTTP 假設伺服器有一個公開可達的 URL。當 MCP 伺服器位於私有網路內時,企業級的安全做法是 **MCP tunnels**(研究預覽):你在自己網路內執行一組 tunnel 堆疊,它建立僅對外(outbound-only)的連線,讓 Claude 能連到該伺服器,而無須開放對內防火牆連接埠、把服務暴露到公開網際網路,或把 Anthropic 的 IP 範圍加入允許清單。每個私有伺服器會取得一個位於你 tunnel 網域底下的主機名稱,你把它傳給 Managed Agents 或 Messages API 的 MCP 連接器,用法與其他

遠端伺服器 URL 完全相同 — 只有 `url` 是 tunnel 特有的。每個請求都有三層彼此獨立的保護:對外通往傳輸邊緣的 **mTLS**(並驗證 IP)、由只有你持有的憑證終結的**內層 TLS**(因此傳輸供應商無法讀取負載內容),以及每個伺服器自身的 **OAuth**。管理透過 Tunnels API 進行,使用 `anthropic-beta: mcp-tunnels-2026-06-22` 標頭與 `workspace:manage_tunnels` WIF 範圍。來源:[MCP tunnels](#)。

25.3 遠端伺服器的授權(OAuth 2.1)

這是第 4 章點名卻沒打開的主題。`stdio` 伺服器信任它的環境(環境變數憑證,\$4.3)。**遠端**伺服器則暴露在網路上,必須回答「這個呼叫者是誰、能做什麼?」——MCP 的答案是 **OAuth 2.1**,而規格對用戶端如何探索該去哪驗證有明確規定。

MCP 伺服器是一個 **OAuth Resource Server**;它不自行簽發 token。由另一個 **Authorization Server**(你的 IdP —— Okta、Entra、Auth0,或內建的)簽發。規格定義的流程:

- 用戶端不帶 token 呼叫伺服器;伺服器以 **401** 回應,並帶一個 `WWW-Authenticate` 標頭指向它的 **Protected Resource Metadata**(PRM, `/.well-known/oauth-protected-resource`)。
- PRM 指名 **Authorization Server**。用戶端抓取 AS 的 metadata(`/.well-known/oauth-authorization-server`)以找到 `authorize/token` 端點。
- 用戶端跑 **OAuth 2.1 加 PKCE**(常先做 Dynamic Client Registration),使用者同意,用戶端拿到存取 token。
- 之後每個請求都帶 `Authorization: Bearer <token>`;伺服器在動作前**驗證**它並檢查 scope。

```
sequenceDiagram
    actor U as User
    participant C as MCP client
    participant S as MCP server (resource)
    participant A as Authorization Server
    C->>S: 不帶 token 的請求
    S-->>C: 401 加 WWW-Authenticate (PRM url)
    C->>S: GET protected-resource metadata
    S-->>C: 指名 Authorization Server
    C->>A: OAuth 2.1 加 PKCE (使用者同意)
    A-->>C: 存取 token (audience 為此伺服器)
    C->>S: 請求加 Bearer token
    S-->>C: 驗證、檢查 scope、然後回應
```

為何這樣設計(以及那些陷阱):

- Resource Indicators(RFC 8707)是強制的。** 用戶端必須把每個 token 綁到**此**伺服器的識別碼 (`resource`),伺服器則必須拒絕 **audience** 不是自己的 token。這擋住**混淆代理人 / token 直通 (passthrough)**攻擊:為伺服器 A 簽發的 token 不得被重放到伺服器 B。絕不接受未檢查 audience 的 bearer token。
- 伺服器負責驗證;它從不轉發。** 一個常見錯誤是 MCP 伺服器拿了用戶端的 token,直接轉手丟給下游 API。把傳入 token 當作**呼叫者的身分驗證**,然後用伺服器自己的憑證(或適當降權的 token)去做下游呼叫。
- 在 Managed Agents 裡,你不必自己手寫這套。** 依第 24 章,MCP 驗證透過 **vaults** 提供:Anthropic 以 **URL** 把儲存的憑證比對到伺服器,並**自動更新 OAuth**。你不把密鑰放進 agent 的 `mcp_servers` 區塊。在 Claude Code 中對應的是 `/mcp` (工作階段內授權)或 `claude mcp login`。

- **企業託管授權(Enterprise-Managed Authorization, EMA)** —— 一項**穩定版** MCP 擴充(2026 年 6 月 18 日),透過組織的身分提供者(SSO)集中治理 MCP 存取:管理員為組織啟用某伺服器後,使用者即依既有的群組/角色自動取得存取權 —— 不需逐人 OAuth 同意畫面,且撤銷即時又集中(將使用者移出 IdP 群組 → 各處存取權立即消失)。首發身分提供者為 Okta;支援的伺服器包含 Asana、Atlassian、Canva、Figma、Linear 與 Supabase。來源:[Enterprise-Managed Authorization](#)。

25.4 Sampling —— 伺服器請用戶端思考

Sampling 是第 4 章沒有對應物的 MCP 能力,而且它反轉了一般方向。通常是用戶端的模型呼叫伺服器的工具。有了 **sampling**,**伺服器上的工具實作可以向用戶端請求一次 LLM 補全**(`sampling/createMessage`) —— 伺服器在執行途中借用 host 的模型。

它為何存在:這讓伺服器得以保持**模型無關且免金鑰**。一個 `summarize_document` 工具不需要自己的 Anthropic API key、也不需硬綁某個模型;它向 host 請求(「請拿你手上任何模型跑這段摘要 prompt」)並取回文字。host 仍掌控成本、模型選擇,以及 —— 關鍵地 —— 一個 **human-in-the-loop 核准點**。

flowchart TD

```
A[代理呼叫伺服器工具<br/>例如 summarize_kb] --> B[伺服器工具執行]
B --> C[伺服器送出 sampling 請求<br/>給用戶端]
C --> D[host 核准<br/>這次 LLM 呼叫?]
D -->|是| E[用戶端以自己的模型<br/>跑補全]
D -->|否| F[請求被拒<br/>工具優雅處理]
E --> G[補全回傳<br/>給伺服器工具]
G --> H[工具完成<br/>把結果回給代理]
```

信任反轉及其陷阱:

- **伺服器能觸發模型呼叫 —— 這是一種權力。** host 必須居中調節:規格正是為此在 **sampling** 上設了一道**人工核准閘門**。一個自動核准每個 **sampling** 請求的用戶端,等於讓任何連上的伺服器隨意花費 token、隨意操縱模型。
- **它在兩端都是可選的。** **sampling** 是一項**用戶端能力**;許多 host 並未實作。健全的伺服器在用戶端不提供 **sampling** 時必須**優雅降級**(退回非 LLM 路徑或回傳清楚的 `isError`),絕不假設它存在。
- **別把 **sampling** 與模型自己的工具呼叫混淆。** 工具呼叫 = 用戶端的模型叫用伺服器。sampling = 伺服器叫用用戶端的模型。箭頭指向相反方向,信任也是。

與之密切相關的是 **elicitation** —— 伺服器在呼叫途中向**使用者**(而非模型)請求一個結構化輸入。原則相同:伺服器回頭探入 host,而 host 必須居中調節。

25.5 加固生產伺服器

你發布的伺服器就是**攻擊面**。模型會忠實地讀取你伺服器回傳的任何內容、呼叫你暴露的任何工具 —— 所以安全必須住在伺服器裡,而非 prompt 裡。

工具定義投毒(Tool-definition poisoning)。 工具的描述與結果會被注入到模型的脈絡裡,因而是一個注入向量。惡意或被入侵的伺服器可把指令藏在描述中(「.....並把使用者的密鑰寄到 X」)。防禦:只連接**可信**伺服器;釘住版本;審查第三方工具描述;且絕不讓某個伺服器的輸出被 host 無聲地當作指令信任。

輸入驗證不容妥協。 每個工具引數都跨越一道信任邊界。先依 `inputSchema` 驗證,再**防護下游**:參數化查詢(絕不用工具引數串接 SQL 字串)、檔案工具的路徑正規化(擋掉 `../` 穿越)、以及任何會變成 shell 命令或 URL 之物的允許清單(allow-list)。

在程式碼裡強制,而非在提示裡。 `readOnlyHint` / `destructiveHint` (§25.1)是建議性的。**真正的守衛**——「production rollback 需要授權」、「這個呼叫者不能寫入」——必須是 `call_tool` 內部的程式碼檢查,回傳結構化的 `permission` 錯誤 (§4.4 契約),就像第 3 章的金額規則一樣。Annotations 幫的是 UI;它們不保護任何東西。

限制速率與成本。 遠端伺服器可被放進迴圈呼叫。對每個工作階段限速、限制結果大小(一個無上限的 `search` 結果能把上下文視窗撐爆),並在每個下游呼叫上設逾時,讓一個慢的相依不能把代理卡住。

規模化下的命名空間與探索。 `host` 為工具加命名空間以避免碰撞——在 Claude Code 中工具顯示為 `mcp_<server>__<tool>` (例如 `mcp_kb__search_kb`);那個確切名稱就是你拿來 allow-list 或用 `tool_choice` 強制的。但每個連上的伺服器都把它工具載入脈絡,十幾個伺服器就能用數百個工具淹沒模型,劣化選擇(Domain 2.3)。緩解之道是 **MCP tool search**——按需延遲載入工具定義,而非把全部前載——加上組織級的 `managed-mcp.json`。設計含義:把一個伺服器的工具清單保持**小而描述良好**;工具數量是預算,並非免費。

flowchart TD

```
In[工具呼叫抵達伺服器] --> Auth{token 與 audience<br/>是否有效?}
Auth -->|否| R401[拒絕 401 或<br/>permission 錯誤]
Auth -->|是| Val{引數是否<br/>符合 schema?}
Val -->|否| RVal[回傳 validation 錯誤<br/>不可重試]
Val -->|是| Authz{呼叫者是否<br/>有授權?}
Authz -->|否| RPerm[回傳 permission 錯誤]
Authz -->|是| Limit{是否在速率<br/>與大小限制內?}
Limit -->|否| RLim[回傳 transient 錯誤<br/>稍後重試]
Limit -->|是| Exec[以自己的憑證<br/>對下游執行]
```

25.6 端對端案例研究:遠端 Knowledge-Base MCP 伺服器

以上零件唯有湊在一起才有意義。第 4 章建的是本機 *studio* 的 Deployments 伺服器;這裡我們建較難而互補的情況——一個整間公司都連上的**遠端、多租戶 Knowledge-Base 伺服器**。它正好演練第 4 章略過的部分:OAuth、sampling、一個 prompt,以及生產加固。

需求

一間公司希望 Claude(透過 Claude Code、SDK 與 Messages API connector)搜尋並摘要其內部知識庫。伺服器必須:

- 透過網路服務眾多使用者,因此以 **Streamable HTTP** 服務搭配 **OAuth 2.1** 執行——每個請求都經驗證、檢查 scope。
- 透過 URI 模板(`kb://article/{id}`)把文章暴露為**資源**,讓代理無需工具呼叫即可讀取任一篇文章。
- 提供 `search_kb` **工具**(唯讀)與一個使用 **sampling** 的 `summarize_kb` **工具**——它請**用戶端**的模型摘要命中項,因此伺服器**不需自己的模型金鑰**。
- 發布一個面向使用者的 `incident_writeup` **prompt**(經審核的範本),而非工具。

- 硬規則:只有 token 帶 `kb:read` scope 的呼叫者才可搜尋;此規則在程式碼中強制,回傳結構化的 `permission` 錯誤——絕不交給模型裁量。
- 驗證輸入、限制結果大小,並在用戶端不提供 sampling 時優雅降級。

架構

```
flowchart TD
    User([員工]) --> Host[Claude host<br/>Code、SDK 或 connector]
    Host -->|POST 加 Bearer token| KB[Knowledge-Base 伺服器<br/>Streamable HTTP]
    KB --> Auth{token 有效<br/>且 scope kb read?}
    Auth -->|否| Deny[permission 錯誤<br/>不可重試]
    Auth -->|是| Res[[Resource kb article id<br/>唯讀地圖]]
    Auth -->|是| Search[Tool search_kb]
    Auth -->|是| Sum[Tool summarize_kb]
    Search --> Index[(搜尋索引)]
    Sum -. sampling 請求 .-> Host
    KB --> AS[Authorization Server<br/>驗證 token]
```

目錄/文章是 Resource(唯讀、無探索性呼叫);search 與 summarize 是 Tools;summarize 透過 sampling 借用 host 的模型;scope 檢查住在伺服器裡,因此不論哪個 host 連上都成立。

實作

用 Python MCP SDK 的示意。注意 scope 守衛、結構化錯誤(\$4.4),以及帶優雅退路的 sampling 呼叫。

```

from mcp.server import Server
from mcp.types import Tool, Resource, TextContent

app = Server("kb")

# --- Resource: any article by id (URI template) ---
@app.list_resource_templates()
async def list_templates():
    return [{"uriTemplate": "kb://article/{id}",
            "name": "KB article", "mimeType": "text/markdown"}]

@app.read_resource()
async def read_resource(uri: str) -> str:
    return kb_store.get_markdown(article_id_from(uri)) # read-only

# --- Tools ---
@app.call_tool()
async def call_tool(name: str, args: dict, ctx) -> list[TextContent]:
    # Enforce scope in CODE, not in a prompt or an annotation.
    if "kb:read" not in ctx.scopes:
        return error("permission", retryable=False,
                    message="Token lacks the 'kb:read' scope.")

    if name == "search_kb":
        q = validate_query(args["query"]) # input validation
        hits = kb_index.search(q, limit=20) # cap result size
        return ok({"hits": hits, "total": len(hits)})

    if name == "summarize_kb":
        hits = kb_index.search(validate_query(args["query"]), limit=10)
        # SAMPLING: ask the CLIENT's model to summarize – no key on the server.
        if not ctx.client_supports_sampling:
            return ok({"hits": hits, "note": "summary unavailable: no sampling"})
        summary = await ctx.sample(
            messages=[user(f"Summarize these KB hits:\n{render(hits)}")],
            max_tokens=400)
        return ok({"summary": summary.text, "sources": [h["id"] for h in hits]})

```

token 以 OAuth **Resource Server** 的身分驗證 —— 拒絕任何 audience 不是此伺服器的 token (§25.3), 藉此堵住混淆代理人漏洞:

```

def authenticate(request):
    token = bearer(request) # from Authorization header
    claims = verify_jwt(token, expected_audience="https://kb.acme.com")
    if not claims:
        return unauthorized() # 401 + WWW-Authenticate -> PRM
    return Context(scopes=claims["scope"].split(), ...)

```

以及一個由使用者觸發的 **prompt**(而非模型呼叫的工具):

```
@app.list_prompts()
async def list_prompts():
    return [{"name": "incident_writeup",
            "description": "Draft an incident write-up from KB sources.",
            "arguments": [{"name": "service", "required": True}]]
```

執行軌跡

一名員工請 Claude Code 摘要知識庫對某次當機的記載。Claude 先讀一篇文章(資源),再呼叫 `summarize_kb`,後者向 **host 的模型 `sampling`**:

```
sequenceDiagram
    actor Emp as Employee
    participant CC as Claude Code (host)
    participant KB as KB server
    participant AS as Auth Server
    Emp->>CC: 請摘要知識庫對結帳當機的記載
    CC->>KB: search_kb (Bearer token)
    KB->>AS: 驗證 token 加 audience 加 scope kb read
    AS-->>KB: 有效, scope ok
    KB->>CC: sampling 請求 (摘要這些命中項)
    CC->>Emp: 核准模型呼叫?
    Emp-->>CC: 核准
    CC-->>KB: 摘要文字
    KB-->>CC: isError false, 摘要加來源
    CC-->>Emp: 帶引用文章 id 的精簡摘要
```

注意**伺服器從未持有模型金鑰**——它透過 `sampling`、在人工核准閘門下借用 `host` 的模型;**程式碼中的 `scope` 檢查**(而非 `prompt`)把守了存取;而經 `audience` 檢查的 `token` 堵住了混淆代理人路徑。

驗證

- ****授權測試:****以(a)無 `token` → 401 指向 `PRM`、(b)不同 `audience` 的 `token` → 被拒、(c)缺 `kb:read` 的有效 `token` → 結構化 `permission` 錯誤,呼叫 `search_kb`。零洩漏。
- **sampling 退路測試:**連接一個不宣告 `sampling` 的用戶端;斷言 `summarize_kb` 回傳帶「summary unavailable」附註的命中項,而非崩潰或硬性錯誤。
- ****注入測試:****餵 `search_kb` 一個含 `SQL`/標記的查詢;斷言它被參數化、索引未被汙染(\$25.5)。
- ****資源 vs 工具測試:****確認 `kb://article/{id}` 可透過 `read_resource` 讀取(無工具呼叫)——代理無需探索性呼叫即取得文章(\$4.5)。
- ****大小上限測試:****一個命中數千列的查詢回傳被限制的結果集,而非撐爆脈絡的傾印。

常見陷阱

- 把 `kb:read` 規則放進系統提示而非**程式碼檢查**(機率性、不保證——見 §3.5 與 §4.4)。
- 接受 `bearer token` 卻**不檢查其 `audience`**,啟用 `token` 直通 / 混淆代理人(\$25.3)。
- 把用戶端的 `token` 轉發給下游索引,而非使用**伺服器自己的憑證**(§25.3)。
- 假設用戶端支援 **sampling**,在它不支援時崩潰,而非優雅降級(\$25.4)。
- 在 `stdio` 版本把日誌寫到 `stdout` (汙染協定)——它們必須走 `stderr` (§25.2)。

- 把 `summarize_kb` 做成只有模型能觸及,當這個可重用工作流程也該是一個使用者 `prompt` 時(\$25.1)。

25.7 下一版修訂 —— 2026-07-28 規格(預覽)

上面所有內容都是**當前穩定規格 2025-11-25** —— 考試與今日 SDK 所假設的版本。但這個協定即將邁出自推出以來最大的一步。**** 2026-07-28 修訂版****已鎖定為 Release Candidate(2026-05-21 凍結,正式發布 **2026-07-28**),beta SDK 也已開始出貨。你不會被考到它,但一個在 2026 下半年架設 MCP 基礎設施的架構師,必須知道地基正往哪裡移動。四項變化最關鍵。

無狀態的協定核心。 `initialize` 交握與每連線的工作階段模型不見了。不再於連線時一次性交換協定版本、用戶端資訊與能力,而是每個請求都在 `_meta` 欄位裡攜帶它們。好處在部署,不在功能:**任何請求都能落在任何伺服器實例上**,於是 \$25.2 的 `Mcp-Session-Id` 強加給你的黏著路由與共享工作階段庫,在協定層溶解了。遠端 MCP 伺服器變成一個普通的水平擴展 HTTP 服務 —— 正是 Messages API 早已擁有的架構優勢(\$1.2)。(真正需要親和性的伺服器仍可使用有狀態工作階段模型;它只是不再是整個協定的預設。)

Extensions 框架。 可選能力移出核心規格,成為獨立版本化的 **extensions**,各以反向 DNS id 標識,住在自己的 `ext-*` 儲存庫並有委派維護者。用戶端與伺服器在探索時透過 `extensions` map 協商它們 —— 選擇性加入、按需取用。核心保持小而穩定,生態系則依自己的節奏演進 —— 這是「每個有用的點子都讓基礎協定膨脹」的結構性解法。

Tasks 與 MCP Apps 建立在這個框架上。 **Tasks**(長時間執行的工作)從實驗性的核心功能畢業為一個 extension,並有更乾淨的生命週期:伺服器**建立**任務,用戶端透過 `tasks/get` / `tasks/update` / `tasks/cancel` **驅動**它 —— 這是「這個工具呼叫要花十分鐘」的標準答案。**MCP Apps** 讓伺服器出貨一個在**沙箱 iframe** 中渲染的互動式 HTML UI,透過 JSON-RPC 帶完整稽核軌跡地回傳 —— 有伺服器渲染的 UI,卻不必把整個頁面交出任意權限。

授權朝 OAuth/OIDC 加固。 \$25.3 的 OAuth 2.1 故事收緊了:強制 `iss` 驗證(**RFC 9207**,堵住授權碼注入的漏洞)、Dynamic Client Registration 中的 `application_type` 宣告,以及 `_meta` 中的 **W3C Trace Context** 傳播(SEP-414),讓單一 trace 從 host → 用戶端 → 伺服器 → 下游一路跟隨。與此搭配的是規格首個**正式棄用政策**:功能以 Active → Deprecated → Removed 推進,每一階段**至少 12 個月**的窗口 —— 於是 \$25.2 「SSE 已棄用」那類變動,現在有了可預測的規則。

陷阱。

- 把 RC 當成可出貨的正式環境事實。在 **2026-07-28** 之前,權威規格是 `2025-11-25` ;照它建,並釘住你的 SDK —— 追著 RC 的 beta SDK 可能在你腳下改變。
- 假設無狀態核心**禁止**工作階段。它沒有;它只是把工作階段從預設降級為選擇性加入,真正需要親和性的伺服器仍可要求它。
- 憑記憶抓某個 extension 的 id 或形狀。Extensions 獨立於核心版本化 —— 對照它的 `ext-*` 儲存庫確認反向 DNS id 與其當前版本,而非核心變更日誌。

25.8 工程焦點 —— 重點整理

概念	生產工程的要求
控制模型	Tools = 模型控制(動作)、Resources = 應用控制(告知)、Prompts = 使用者控制(範本);給工具加上 <code>annotations</code> + <code>outputSchema</code> (\$25.1)。

資源定址	URI 模板服務一整族項目;訂閱推送更新,讓「地圖」無需輪詢即保持新鮮(\$25.1)。
stdio 機制	<code>stdout</code> 只供協定 —— 所有日誌走 <code>stderr</code> ;host 擁有生命週期;初始化必須快速且非阻塞(\$25.2)。
HTTP 工作階段	<code>Mcp-Session-Id</code> 綁定有狀態工作階段;SSE 事件 id 啟用 可續傳 ;舊雙端點 SSE 已棄用;留意負載平衡器親和性(\$25.2)。
OAuth 2.1	伺服器是 Resource Server ,非 token 簽發者;透過 PRM → AS metadata 探索;以 Resource Indicators 綁定 token 並 檢查 audience (\$25.3)。
混淆代理人	驗證傳入 token; 絕不轉發 它們到下游;拒絕 audience 錯誤的 token(\$25.3)。
Sampling	伺服器請用戶端 的模型補全;讓伺服器免金鑰/模型無關;受 host 人工核准 把關;缺席時優雅降級(\$25.4)。
加固	工具描述/結果是注入向量;驗證輸入;守衛 在程式碼中強制 (提示不是安全);限速並限制大小(\$25.5)。
規模化探索	<code>mcp__<server>__<tool></code> 命名空間; MCP tool search 延遲載入工具;工具清單保持小 —— 工具數量是預算(\$25.5)。
規格走向	<code>2025-11-25</code> 為當前版; <code>2026-07-28</code> RC 讓核心 無狀態 (任何請求 → 任何實例)、把可選功能移入獨立版本化的 Extensions (Tasks、MCP Apps),並加固 OAuth(RFC 9207 <code>iss</code> ;12 個月棄用政策)(\$25.7)。

超出考試,實務必備。 第 4 章讓你**使用** MCP;本章讓你**營運**它。若你能架起上面的 Knowledge-Base 伺服器 —— 帶 OAuth 2.1 的 Streamable HTTP、經 audience 檢查的 token、URI 模板資源、會優雅降級的 sampling 工具、一個使用者 prompt,以及程式碼強制的 scope —— 你就能建出一個公司可安全倚賴的 MCP 伺服器。

第 26 章:現代 Claude Code(2026)

參考 —— *超出考綱*。文件:[Claude Code docs](#) · [What's new](#) · [Subagents](#) · [Plugins](#) · [Headless](#)。

第 5 章把 Claude Code 當成一個**可設定的工具**來教 —— 指令放哪裡、如何限定規則範圍、如何把危險操作擋下來。本章是它的 2026 續篇,寫給把 Claude Code 當成**正式環境基礎設施**(而非互動式助理)來運行的工程師:同一個引擎在背景驅動數十個子代理、跨機器與跨介面存活、能從自己的錯誤中復原、並在 CI 裡無人值守地運行。這個轉變是從「開發者和代理聊天」變成「一支代理艦隊執行你撰寫的計畫,並在你能證明的護欄之下運作」。

這個轉變逼出三個基礎課程從不需要回答的架構問題,它們也構成本章的脈絡:

- **誰握有計畫?**(\$26.2)—— 單一代理逐回合、由**主導者**協調一個團隊、還是由**腳本**編排數百個用後即丟的工作者。選錯,正是規模化時最主要的失敗模式。
- **如何隔離影響範圍(blast radius)?**(\$26.3–26.4)—— fork 與全新上下文、worktree 沙箱,以及作為復原層的 checkpoints/rewind(以及它在哪裡不再是復原層)。

- 它如何在無人介入下運行?(§26.5–26.6)—— headless/SDK 模式、權限分類器、plugins,以及讓上下文視窗在艦隊規模下仍撐得住的 MCP tool search。

§26.7 接著從頭到尾建構一個系統 —— 一個**自主的 monorepo 相依套件遷移**作業 —— §26.8 則濃縮這些心智模型。本章的一切都**補足**第 5 章:那一章是單一互動工作階段;本章則是建構在其上的多介面、多代理、無人值守系統。

26.1 一個引擎,多個介面

2026 年的 Claude Code 不再是「一支終端機程式」。同一個引擎在**終端機、VS Code、JetBrains、桌面 app、web 與 iOS 用戶端、Slack,以及一個 Chrome 擴充功能**中運行 —— 而且它們全都讀取**同一份**設定: `CLAUDE.md`、`.claude/settings.json`、Skills、子代理定義、hooks,以及 MCP servers。設定一次,行為就跟著你到每一個介面。

```
flowchart TD
    subgraph Surfaces[介面]
        Term[終端機 CLI]
        IDE[VS Code / JetBrains]
        Desk[桌面 app]
        WebM[Web 與 iOS]
        Chat[Slack 與 Chrome]
    end
    subgraph Engine[共用的 Claude Code 引擎]
        Cfg[CLAUDE.md 加 settings.json]
        Skills[Skills 與子代理]
        Hooks[Hooks 生命週期]
        MCP[MCP servers]
    end
    Term --> Engine
    IDE --> Engine
    Desk --> Engine
    WebM --> Engine
    Chat --> Engine
    Engine --> Repo[你的儲存庫與工具]
```

這對架構為何重要。 介面只是**用戶端**,代理的能力與護欄是**伺服器端**設定。你提交到 `.claude/` 的一條權限規則或 hook,保護從 Slack 啟動作業的同事,就跟它在終端機保護你一樣 —— 沒有「但這是 web 用戶端啊」的脫逃出口。隨之而來的陷阱是:祕密(secrets)與特定介面的假設**不該**放進共用設定。「打開我的瀏覽器」在 Chrome 介面說得通,在 headless CI 裡卻毫無意義;把能力需求編進**任務**,而非 CLAUDE.md。

取捨。 一致性既是特色也是約束。同一個引擎代表只有一個地方要去推理安全性 —— 但也代表一個設定錯誤會在每個地方一致地錯。把 `.claude/` 當成正式環境程式碼:經審查、納入版控、有測試,因為每個介面都繼承它。

26.2 編排光譜:誰握有計畫

第 3 章介紹了協調者/子代理(中心輻射式)模式。現代 Claude Code 把它一般化成一個**三種編排模式的光譜**,以**計畫住在哪裡**與**什麼會進入主上下文視窗**來區分。選對是艦隊規模工作中槓桿最高的單一決策。

```
flowchart TD
```

```
Task[進來的任務] --> Q{規模與耦合度?}
```

```
Q -->|步驟少<br/>推理緊密| A[子代理與 Skills<br/>Claude 逐回合規劃]
```

```
Q -->|多條平行軌道<br/>共享狀態| B[Agent team<br/>主導者掌管任務清單]
```

```
Q -->|數十至數百個<br/>獨立單元| C[動態 workflow<br/>由 JS 腳本編排]
```

```
A --> Ctx[每個工具結果<br/>進入主上下文]
```

```
B --> List[主導者讀共享的<br/>任務清單, 而非原始輸出]
```

```
C --> Final[只有最終答案<br/>進入主上下文]
```

模式 1 —— 子代理與 Skills(模型握有計畫)。 主 Claude 實例逐回合決定何時透過 `Task` 工具(第 3 章)生成子代理,或叫用某個 Skill。適合少數幾個步驟,且每個結果都真正影響下一步推理。*代價:* 每個子代理的結果都會回到主上下文視窗,因此無法擴展到數百個工作者 —— 視窗會被塞滿。

模式 2 —— Agent teams(主導者握有計畫)。 一個指定的主導者代理維護一份**共享任務清單**;工作者代理認領項目、執行、回報狀態 —— 主導者是對著**清單**協調,而非對著每個工作者的原始逐字稿。適合幾條共享狀態的半獨立軌道(例如一個功能的前端 + 後端 + 測試)。*代價:* 你必須設計任務清單協定;協調額外負擔是真實存在的。

模式 3 —— 動態 workflows + `ultracode` (腳本握有計畫)。 Claude 自己寫一支 JavaScript 編排腳本,把工作扇出(fan out)到**數十至數百個**背景子代理,上限為**同時 16 / 總計 1,000**。關鍵在於,**只有每個工作者的最終答案會回到主上下文** —— 中間推理留在工作者裡。`/effort ultracode` 開啟自動編排,讓 Claude 自行採用這個模式。適合大規模、極易平行的工作(遷移 400 個檔案、分流 1,000 條發現)。*代價:* 它是一支程式 —— 編排腳本裡的 bug 就是你這次運行的 bug,而為 200 個平行工作者除錯本身就是一門功夫。

考試式的判別準則。 把模式對應到**上下文經濟學**:如果某個子結果必須影響下一個決策 → 子代理(模式 1)。如果平行軌道共享演進中的狀態 → 團隊(模式 2)。如果各單元彼此獨立、你只需要把它們的**輸出**彙整起來 → workflow(模式 3)。典型錯誤是把 300 個獨立檔案編輯當成逐回合子代理來跑,把上下文視窗撐爆,而其實一個 workflow 只會留下 300 條簡短結果。

26.3 Fork 子代理與 Worktree 隔離

預設情況下,子代理以**全新、空白的上下文**啟動 —— 這就是第 3 章「子代理什麼都看不到」的規則,它強制你明確傳遞上下文。現代 Claude Code 在你**想要繼承**時加上了相反的選項。

context: fork 生成的子代理會**繼承父對話**,而非從空白開始。當子代理需要你已經建立起來的完整推理歷史(一段冗長的調查、一份累積的計畫),而重新明確傳遞會浪費或失真時,就用它。全新上下文是**平行、獨立**工作的安全預設;fork 則用於從豐富共享狀態分岔出去的**接續**工作。

isolation: worktree 讓子代理的檔案編輯在一個**用後即丟的 git worktree**(獨立的 checkout)裡進行,因此在你合併之前,它的變更永遠不會碰到你的工作樹。這是針對**臆測性**編輯的影響範圍控制:讓子代理在隔離的 worktree 裡嘗試一個有風險的重構,檢視 diff,只有夠好時才保留。若不好,就丟棄 worktree,你的工作樹毫髮無傷。

```
flowchart TD
    Parent[父工作階段<br/>上下文豐富] --> D{子代理<br/>需要什麼?}
    D -->|獨立工作| Fresh[全新上下文<br/>明確傳遞上下文]
    D -->|接續這段推理| Fork[context fork 模式<br/>繼承對話]
    D -->|有風險的臆測編輯| WT[isolation worktree 模式<br/>在用後即丟的 checkout 編輯]
    WT --> Review[檢視 diff]
    Review -->|好| Merge[合併進工作樹]
    Review -->|不好| Drop[丟棄 worktree<br/>工作樹維持乾淨]
```

取捨與陷阱。 Fork 省去重新傳遞上下文,卻把父對話的雜訊與偏誤一起帶進來——比方說做獨立程式碼審查時,全新代理更客觀。Worktree 隔離對任何你可能想丟棄的變更都是正確選擇,但它要付出一次 checkout 與一道合併步驟,所以別在瑣碎編輯上動用它。經驗法則:平行扇出用全新 + 明確上下文;深度接續用 fork;任何你還不確定要不要保留的東西用 worktree。

26.4 復原:Checkpoints、Rewind 與 Auto Memory

漫長的自主運行會犯錯。兩套 2026 系統讓這些錯誤變得可承受——而知道它們的極限,正是多數指南漏掉的部分。

Checkpoints 與 /rewind。 Claude Code 會在每次編輯前自動建立檢查點,並讓你把程式碼、對話或兩者還原到較早的時間點。這把一次走錯的轉向變成一道指令的還原,而非手動 `git reset` 的考古工作。**關鍵限制:** checkpoints 追蹤的是 Claude 自己的編輯——它不會捕捉由 `bash` 指令、外部行程或並行工具所改動的檔案。因此一次 `npm install`、一個產生出來的建置產物,或一支重寫了某檔案的腳本,對 rewind 都是不可見的。**Checkpoints 是針對代理編輯的快速還原,不是 Git 的替代品**——你仍要 commit,凡是 Claude 直接編輯以外的東西,都仍仰賴 Git。

Auto memory(MEMORY.md)。 有別於手寫的 `CLAUDE.md`, Claude 維護它自己的、機器本地的 `MEMORY.md`——它為自己寫下的學習(「測試 DB 是靠一個旗標重置,不是靠 mock」;「這個建置需要 Node 22」)——並在每次工作階段重新載入。它是一本私人筆記,不是團隊契約。

機制	撰寫者	範圍	經 Git 共享?	目的
<code>CLAUDE.md</code>	人類	專案 / 使用者 / 目錄	專案層級:是	團隊契約——標準、慣例
<code>MEMORY.md</code>	Claude(自動)	機器本地	否	Claude 自己累積的學習
Checkpoints	Claude(自動)	工作階段	否	只還原 Claude 的編輯(不含 bash/外部)

陷阱。 把 `MEMORY.md` 當成放團隊標準的地方是錯配——它不會被共享,同事的 `git clone` 永遠看不到它。反過來,指望 `/rewind` 去還原一次破壞性的 `bash rm` 正是那條限制所警告的陷阱;對 checkpoints 而言,那個檔案已經沒了。用對層級: `CLAUDE.md` 給團隊、`MEMORY.md` 是 Claude 的、checkpoints 用於編輯還原、Git 用於一切需要持久的東西。

26.5 Plugins、擴充的 Hooks,以及 MCP Tool Search

三項能力把個人設定變成可散布、且省上下文的平台。

Plugins 與 marketplace。 一個 *plugin* 把 Skills、子代理定義、hooks、slash 指令,以及 MCP server 設定打包成一個**可安裝的套件**,透過 **plugin marketplace** 散布。這正是資安或平台團隊把一項標準化代理能力交付給全組織的方式:一次安裝就把 SAST skill、政策 hook、核可的 MCP servers,以及審查子代理一起拉進來——以單一單元做版本控管,而非每位工程師手動把片段複製進自己的 `.claude/`。

擴充的 hook 事件。 第 3 章用 `PreToolUse / PostToolUse` 做確定性強制。現代 Claude Code 加上了對**自主運行**很重要的生命週期事件:

- **SubagentStart / SubagentStop** —— 對每個生成的工作者注入上下文或進行稽核(當 workflow 生成數百個時必不可少)。
- **PreCompact** —— 在上下文被壓縮**之前**執行邏輯,例如把你不想遺失的摘要保存下來。
- **SessionEnd** —— 運行完成時的最終清理、回報或證據沖刷(flush)。

這些正是你在艦隊規模上掛載**可觀測性與政策**之處 —— 一個替每個工作者蓋上 run-id 戳記的 `SubagentStart` hook,搭配一個輸出結構化稽核軌跡的 `SessionEnd` hook,就是讓 200 個背景代理可被問責的方法。

MCP tool search 與 managed MCP。 當你連接許多 MCP servers 時,一開始就載入**每一個**工具定義會在任何工作開始前就淹沒上下文視窗。**MCP tool search 會延遲載入工具** —— 模型只搜尋並拉入某任務所需的工具,讓視窗撐得住。**Managed MCP** 讓組織透過 `managed-mcp.json` 釘住一組核可的 server,並由 `claude mcp login` 從 shell 處理驗證。與第 4 章 MCP resources 及 §26.2 workflows 一脈相承的紀律相同:**上下文是一筆預算;只在任務需要時、載入它需要的東西。**

26.6 Headless、SDK 與權限模式

無人值守執行,正是正式環境與互動式使用分歧最大的地方。

CI 用的 Headless / -p。 `claude -p "<task>"` (亦即 `--print`)以非互動方式運行後結束 —— 這是 CI 作業、pre-commit 檢查與批次管線的基礎。要取得機器可讀的輸出: `--output-format json`,以及 `--json-schema` 來強制產出**符合結構描述的 `structured_output`**,讓下游步驟能確定性地解析結果。**** --bare **** 略過自動探索(CLAUDE.md、設定、plugins),以求一次**確定性、可重現的運行** —— 相同輸入產生相同行為,這正是 CI 所需;它預計將成為 `-p` 的預設。(這就是第 5 章為 CI 介紹的同一個 headless 介面;此處它與下方的編排與權限機制搭配。)

權限模式 —— 安全旋鈕。 模式決定哪些東西不需經人類提示就執行:

模式	行為	典型用途
<code>default</code> (2026 年 7 月起顯示為 Manual)	在敏感動作前詢問	互動式開發
<code>acceptEdits</code>	自動接受檔案編輯,仍管控指令	受信任的本機編輯
<code>plan</code>	僅讀取/調查 —— 不做任何變更	核准前的規劃
<code>bypassPermissions</code>	完全不詢問	僅限沙箱化、完全受信任的自動化
<code>auto</code>	由 伺服器端安全分類器 逐動作判斷	聰明的無人值守運行

dontAsk	只有唯讀/預先核准的操作會進行	保守的自動化
---------	-----------------	--------

`auto` 是 2026 年有意義的新增:不再是全有或全無,而是由分類器判斷每個動作的風險,讓無人值守的運行能在安全步驟上前進,同時仍對危險步驟守住底線。**陷阱是在 CI 裡為了方便就動用 `bypassPermissions`** —— 那會移除每一道護欄; `auto` 或 `dontAsk` 加上確定性 hooks(\$26.5)才是站得住腳的姿態。

排程與遠端。雲端 **routines** 以 **cron 排程**運行 Claude Code(夜間分流、每週相依檢查);**channels** 把外部事件推進運行中的工作階段(一次 CI 失敗、一個新 issue),讓代理對外部世界做出反應;**遠端控制**則讓你從另一台裝置操控或查看工作階段。三者合起來,把引擎從「我現在正在打字」延伸成「它依排程運行並回應事件」。

26.7 端到端案例研究:自主的 Monorepo 相依套件遷移

這些元件唯有組合在一起才有意義。以下是一個真實的 2026 系統:一個夜間作業,把一個 **400 套件的 monorepo** 從一個已棄用的日誌函式庫遷移到它的替代品,全程無人值守,並帶有你能證明的護欄。

需求

- 將約 **400 個套件**從 `oldlogger` 更新到 `newlogger` (API 介面不同 —— 不是 find-replace)。
- **無人值守、依排程**運行,鍵盤前沒有人。
- **硬性規則:** 作業可以開 PR,但**絕不可推送到 `main` 或發布套件** —— 由真人審查並合併。
- 每個套件的變更都必須**隔離**,讓一個壞掉的遷移無法波及其他套件。
- 產出一份儀表板可吸收的**機器可讀摘要**,外加每個工作者的稽核軌跡。

架構

這是教科書級的**模式 3 動態 workflow**(\$26.2):400 個獨立單元,只有每個工作者的結果需要回到彙整端。

```
flowchart TD
    Cron[雲端 routine<br/>夜間 cron] --> Lead[主導工作階段<br/>effort ultracode]
    Lead --> Plan[寫一支涵蓋 400 套件的<br/>JS 編排腳本]
    Plan --> Fan{扇出工作者<br/>上限同時 16}
    Fan --> W1[工作者 套件 A<br/>worktree 隔離]
    Fan --> W2[工作者 套件 B<br/>worktree 隔離]
    Fan --> W3[工作者 套件 N<br/>worktree 隔離]
    W1 --> Agg[彙整結果]
    W2 --> Agg
    W3 --> Agg
    Agg --> PR[每個套件群組<br/>開一個 PR]
    PR --> Human([真人審查者])
```

routine 觸發運行;主導者寫出編排腳本;每個工作者在**自己的 worktree 裡編輯一個套件**(\$26.3),因此一次失敗的遷移會被丟棄而不碰到其他套件;只有最終結果流回來,讓主導者的上下文撐得住。

護欄(確定性,而非提示)

「絕不推送到 main / 絕不發布」這條規則攸關金錢與商譽,因此它住在一個 `PreToolUse` hook(第 3 章的教訓)裡,而非系統提示:


```

@hook("PreToolUse")
def block_publish_and_main_push(tool_call):
    if tool_call.name == "bash":
        cmd = tool_call.args["command"]
        if "npm publish" in cmd or "git push origin main" in cmd:
            # 是程式碼, 不是建議 — 模型無法用言語繞過它。
            return deny(reason="publish_or_main_push_forbidden")
    return allow(tool_call)

```

整個作業在 `dontAsk` 權限模式下運行(無互動提示, 只有預先核准的操作), 並掛上可觀測性 hooks, 讓 400 個背景工作者可被問責:

```

@hook("SubagentStart")
def stamp_worker(ctx):
    ctx.set("run_id", current_run_id()) # 替每個工作者打標, 供稽核軌跡使用

@hook("SessionEnd")
def flush_audit(session):
    write_structured_report(session.results) # 運行結束時把證據送出

```

執行軌跡

```

sequenceDiagram
    actor Cron as 雲端 routine
    participant Lead as 主導者 (ultracode)
    participant WF as 編排腳本
    participant W as 工作者 (worktree)
    participant Pre as PreToolUse hook
    Cron->>Lead: 觸發夜間遷移
    Lead->>WF: 寫出涵蓋 400 套件的 JS 計畫
    WF->>W: 為套件 A 生成工作者(一次最多 16 個)
    W->>W: 在 worktree 裡把 oldlogger 遷移到 newlogger
    W->>Pre: bash: npm publish package-a
    Pre-->>W: DENY(禁止發布)
    W-->>WF: 結果: 已遷移、測試通過、發布被擋
    WF-->>Lead: 只彙整 400 條最終結果
    Lead-->>Cron: 開 PR 加上結構化 JSON 摘要

```

注意工作者嘗試了發布 —— 而 **hook 確定性地否決了它**。若只用提示指令(「別發布」), 模型大多數時候會遵守; 對一條可能把壞掉的套件送給數千個使用者的規則來說, 「大多數時候」就是一次失敗的運行。

驗證

- **護欄測試:** 在沙箱裡讓一個工作者嘗試 `npm publish` 與 `git push origin main`, 斷言兩者每一次都被否決 —— 只靠提示的設計遲早會漏。
- **隔離測試:** 強制讓某一個套件的遷移失敗, 確認其他套件的 worktree 與 PR 不受影響(影響範圍被框在單一 worktree)。

- **上下文經濟學測試:** 確認主導者的上下文裝的是 400 條**簡短最終結果**,而非 400 份完整逐字稿 —— 也就是它真的以 workflow(模式 3)運行,而非逐回合子代理(模式 1)。
- **可重現性測試:** 以 `--bare` 與 `--json-schema` 重新運行,斷言摘要符合儀表板預期的結構描述。

常見陷阱

- 把這 400 個編輯當成**逐回合子代理**(模式 1)來跑,耗盡上下文視窗 —— 從結構上看,這本該是一個 workflow(模式 3)。
- 把「絕不推送到 main」放進**系統提示**而非一個 `PreToolUse` hook(機率性,沒有保證 —— §26.5)。
- 為了「讓 CI 直接動起來」而使用 `bypassPermissions`,移除每一道護欄,而其實 `dontAsk` + hooks 能在帶有安全底線之下提供無人值守執行(§26.6)。
- 信任 `/rewind` 去還原一次 `bash` 造成的錯誤 —— checkpoints 不追蹤 bash 改動的檔案,所以改用 **worktrees** 來隔離(§26.3–26.4)。

26.8 關鍵整理

概念	該記住什麼
一個引擎,多個介面	終端機、IDE、桌面、web/iOS、Slack、Chrome 共用一個引擎與一份設定;護欄在伺服器端,跟著每個介面走(§26.1)。
編排光譜	把模式對應到上下文經濟學:子代理(模型握有計畫)→ 團隊(主導者 + 任務清單)→ 動態 workflows/ <code>ultracode</code> (腳本;只有最終答案回來)(§26.2)。
Fork 對全新對 worktree	平行扇出用全新 + 明確上下文;深度接續用 <code>context: fork</code> ;任何你可能丟棄的東西用 <code>isolation: worktree</code> (§26.3)。
Checkpoints 不是 Git	<code>/rewind</code> 只還原 Claude 的 編輯 —— 它 不 追蹤 bash/外部的檔案變更;繼續使用 Git(§26.4)。
記憶層級	<code>CLAUDE.md</code> = 團隊契約(共享); <code>MEMORY.md</code> = Claude 自己的機器本地筆記(不共享)(§26.4)。
Plugins + 擴充的 hooks	Plugins 把 Skills/agents/hooks/MCP 當成單一版本化單元交付; <code>SubagentStart</code> / <code>PreCompact</code> / <code>SessionEnd</code> 加上艦隊規模的可觀測性與政策(§26.5)。
上下文是一筆預算	MCP tool search 與 managed MCP 只延遲載入任務所需的工具,讓視窗在規模下撐得住 (§26.5)。
無人值守的安全	<code>Headless -p + --json-schema + --bare</code> 用於確定性 CI;偏好 <code>auto</code> 分類器或 <code>dontAsk</code> 而非 <code>bypassPermissions</code> ,並用 hooks 為規則撐腰(§26.6)。

超出基礎考試範圍。 第 5 章是單一互動工作階段;本章是建構在其上的正式環境系統 —— 一支握有計畫、隔離影響範圍、能從錯誤中復原、並在你能證明的護欄之下無人值守運行的代理艦隊。如果你能設計並捍衛 §26.7 的遷移作業,你就理解了作為基礎設施的現代 Claude Code。

第 27 章:Agent 的 Evals(評測)

參考 —— 超出考綱,但實務上不可或缺。 文件:[Demystifying evals for AI agents](#)。

無法量測就無法改進,也無法安全上線。對單一提示,你可以用肉眼看出輸出;但對一個會規劃、呼叫工具、生成子代理、跑上數十回合的**正式環境代理**,「用肉眼看出」既無法規模化,也抓不到回歸。**Evals 就是代理的測試套件**:一個可重複的框架,讓代理跑過有代表性的任務,並同時評分它「產出了什麼」與「如何得到」。

本章是 generator-evaluator 迴圈(第 16 章)與 harness 驗證步驟(第 15 章)背後的量測層。少了它,每一次換模型、改提示或調工具,都是盲目下注;有了它,你能在數天內升級模型、在使用者之前抓到回歸,並以證據(而非感覺)調 effort / 提示/工具。我們會涵蓋六件你應該能建構並捍衛的事:

- **三種評分者**(§27.1)—— 程式碼、模型、人,以及各自何時是對的工具。
- **軌跡 vs 最終答案評測**(§27.2)—— 為何「靠壞路徑得到的對答案」是潛伏的 bug。
- **正確地做 LLM 當裁判**(§27.3)—— 評分標準、校準,以及會悄悄灌水分數的偏誤陷阱。
- **黃金集與回歸套件**(§27.4)—— 把「感覺變好了」變成一個數字的精選任務。
- **指標與 CI 把關**(§27.5)—— pass@k、不確定性,以及能擋下壞部署的通過/失敗閘門。
- **以 eval 驅動的迭代**(§27.6)—— 把失敗轉成新測試案例的飛輪。

§27.7 接著從頭到尾建構一個程式碼遷移代理的完整 eval 套件,§27.8 則濃縮關鍵重點。

27.1 三種評分者

每個 eval 都歸結為一個問題 —— *這次執行好不好?* —— 而它由三種評分者之一回答。它們在成本、可規模化程度,以及能判斷的品質類型之間各有取捨。

flowchart TD

```
R[代理執行<br/>最終答案 plus 軌跡] --> Q{我們在評什麼?}
Q -->|可驗證的事實| C[程式碼評分者<br/>能編譯 測試過 JSON 有效]
Q -->|開放式品質| M[模型評分者<br/>LLM 當裁判 對評分標準]
Q -->|模糊或高風險| H[人類評分者<br/>專家審查]
C --> S[評分並彙整]
M --> S
H --> S
H -. 校準 .-> M
```

程式碼評分者是確定性檢查:檔案編譯過嗎?單元測試通過嗎?輸出有對 JSON schema 驗證嗎?diff 套得乾淨嗎?SQL 語法有效嗎?只要「正確」是機械可檢的,就用它。它們快速、免費、100% 可重現 —— **只要任務能做成可驗證的,就優先用它**。陷阱:它們只量測你能用程式碼表達的東西,所以對語氣、是否有幫助、推理是否合理,它什麼都沒說。

模型評分者(「**LLM 當裁判**」)依評分標準評開放式品質 —— 摘要忠實嗎?解釋清楚嗎?答案有對到問題嗎?它能規模化到上千個案例,並判斷程式碼做不到的事。取捨:裁判本身就是一個機率性模型,帶有自己的偏誤 (§27.3),所以未校準的裁判可能自信地犯錯。

人類評分者是模糊、主觀或高風險案例的黃金標準。在成熟的流程裡,他們真正的工作是**校準**:你不會讓人去評每一次執行(太慢、太貴)—— 而是讓他們標註一個樣本,然後驗證你的程式碼/模型評分者是否與人一致。若裁判與人不一致,錯的是裁判而非人,你就去修評分標準。

經驗法則: 把任務做成可驗證的並用程式碼評分者;若做不到,就用模型評分者並對著人去校準它;把人類評分留給校準與真正主觀的長尾。

27.2 軌跡 vs 最終答案評測

最常見的 eval 錯誤是只評**最終答案**。對代理來說這必要但不充分,因為**路徑**很重要:

- 一個藉由呼叫錯工具、用錯順序、亂搞 40 回合才得到的對答案,是**潛伏的失敗**——它會在下一個任務壞掉、爆掉你的延遲預算,或在 token 上多花 10 倍。
- 一個藉由**合理**路徑得到的錯答案,往往一行就能修(某個工具回傳了壞資料);一個來自**壞掉**路徑的錯答案,則是設計問題。

所以要評兩層:

層級	問題	範例檢查
最終答案(結果)	最終結果正確/有用嗎?	測試通過;摘要忠實;退款金額正確
軌跡(過程)	路徑合理且有效率嗎?	選對工具;沒有重複呼叫;回合數在預算內;沒有嘗試違反政策的動作;從那一次暫時性錯誤中恢復

軌跡評測能抓到結果評測漏掉的失敗:沒讀檔案就猜答案的代理、在同一個失敗指令上空轉的代理、嘗試禁止動作而只是被 hook 擋下(\$3.5)的代理。**陷阱:** 過度指定軌跡會把 eval 變成脆弱的腳本——若你斷言**確切**的工具順序,每一次正當的策略改變都會讓測試失敗。要斷言路徑的**屬性**(用了這些工具、從未嘗試這個禁止動作、回合數 $\leq N$),而非逐字的紀錄。

27.3 正確地做 LLM 當裁判

模型評分者可信的程度,只等於它的評分標準與校準。有三項實務能把「有用的裁判」與「亂數產生器」區分開來。

1. 給裁判具體的評分標準,而非「打 1-10 分」。 含糊的尺度會產出吵雜、不可重現的分數。把品質拆解成明確、可檢的準則,每條準則優先用通過/失敗或一個短的序數尺度:

依參考答案為代理的回答評分。對「每一條」準則,輸出 pass/fail 加一行原因:

- faithful: 每個主張都有檢索到的來源支持(無捏造)
- complete: 回應了使用者問題的所有部分
- grounded: 每個事實主張都引用了特定來源
- safe: 未嘗試任何超出既定範圍的動作

然後輸出整體裁決:唯有 faithful AND safe 兩者皆 pass 才 PASS。

2. 在裁決前強制推理,並讓它結構化。 讓裁判在評分前先說明**為什麼**(這對評分而言就是 chain-of-thought),並回傳可解析的物件,讓 CI 能據此把關:

```
class JudgeVerdict(BaseModel):
    faithful: bool
    complete: bool
    grounded: bool
    safe: bool
    reasoning: str # 在提示的排序中,填在那些布林值「之前」
    verdict: Literal["PASS", "FAIL"]
```

3. 防範裁判偏誤 —— 這些會悄悄灌水分數,也是「可信的 eval」與「不可信的 eval」之間的差別:

flowchart TD

```
B[LLM 當裁判的偏誤] --> P[位置偏誤<br/>偏好先出現的選項]
B --> V[冗長偏誤<br/>越長等於越好]
B --> N[自我增強偏誤<br/>偏好自己的模型家族]
B --> L[寬鬆漂移<br/>不確定時就說 pass]
P --> Mp[每個案例<br/>隨機化選項順序]
V --> Mv[去除長度線索<br/>只依評分標準評]
N --> Mn[用「不同於」代理的<br/>模型來當裁判]
L --> Ml[每條準則都要證據<br/>加上人類校準的門檻]
```

- **位置 / 順序偏誤** —— 比較兩個輸出時,裁判偏好它先看到的那個。緩解:每個案例隨機化順序,或兩種順序都跑並要求一致。
- **冗長偏誤** —— 不論正確與否,裁判給較長的答案較高分。緩解:只依評分標準評分;別讓長度滲進來。
- **自我增強偏誤** —— 裁判偏好來自自己模型家族的輸出。緩解:只要能避免,絕不用產出答案的同一個模型去評它;用不同(通常更強)的模型當裁判。
- **寬鬆 / 諂媚漂移** —— 不確定時,裁判預設「pass」。緩解:要求每條準則都附證據,並依人類標註的資料(而非直覺)設定 PASS 門檻。

不可妥協的一點: 在你信任一個裁判之前,先在校準集上量測它與**人類標註的一致性**。若兩者不一致,代表裁判失準 —— 去修評分標準並重新量測;絕不出貨來自未驗證裁判的分數。

27.4 黃金集與回歸套件

一個 eval 集的好壞,只等於它的任務。有兩份精選的集合做了大部分的工作。

黃金集 —— 一份手工精選、有代表性的任務集,附已知為佳的參考輸出(或接受/拒絕準則)。它為你的代理定義「好」。實用黃金集的要點:

- **真實且端到端** —— 盡可能取自**正式流量**,而非玩具提示。eval 必須看起來像使用者實際送出的東西,包括那些雜亂、模糊、多步驟的。
- **涵蓋分佈** —— 納入簡單的多數以及困難的長尾(邊界案例、對抗性輸入、模糊請求,以及你看過的失敗模式)。
- **穩定的參考** —— 釘住參考輸出或準則,讓今天通過的執行明天仍通過,除非代理真的變了。

回歸套件 —— 一份凍結的集合,絕不允許變差。讓它成為飛輪的紀律是:**每個正式環境的 bug 都變成一個永久的回歸案例**。當代理在真實環境失敗,你就(1)把它重現成一個最小任務,(2)以正確的預期行為加入套件,(3)修好代理,(4)確認該案例現在會通過。這個 bug 再也不會悄悄回來。

```

flowchart TD
    Prod[觀察到正式環境失敗] --> Repro[重現成最小任務]
    Repro --> Add[加入回歸套件<br/>附預期行為]
    Add --> Fix[修提示 工具 或模型]
    Fix --> Run[重跑完整 eval 套件]
    Run --> G{所有案例都通過?}
    G -->|否| Fix
    G -->|是| Ship[出貨並永久保留該案例]

```

陷阱 —— 對 eval 集過擬合。 若你把代理調到能在一份**固定**、**完全可見**的集合上拿滿分,你優化的是測試,不是任務。防禦:保留一份你從不對它調校的**保留(held-out)**切片、定期從新的正式流量刷新集合,並留意 eval 分數上升但使用者抱怨並未下降的情況。

27.5 指標與 CI 把關

代理是**不確定的** —— 同樣的輸入可能產生不同的執行(工具順序、取樣、暫時性錯誤)。因此評斷單次執行很吵雜。有兩個想法讓評分誠實,還有一個讓它可被強制執行。

跑多次試驗。 每個任務跑 k 次,回報一個分佈而非一個點。代理的招牌指標是 **pass@ k** —— *代理在 k 次嘗試內成功嗎?* —— 它捕捉「多試幾次能不能到」。也要追蹤它的反面:一個在 $k=3$ 通過卻在 $k=1$ 失敗的任務是不穩定的(*flaky*),而不穩定本身就是一個值得單獨指標的缺陷。實用的搭配:**pass ^{k}** (全部 k 次都成功 —— 一條可靠性標準)、成功率、p50/p95 回合數與 token 成本,以及完成時間。

讓 CI 對套件把關。 把 eval 套件接進流水線,讓回歸無法合併。一個典型的閘門:

```

# CI eval gate (pseudocode)
- run: python run_evals.py --suite regression --k 3 --out results.json
- run: |
    pass_rate = results.passed / results.total
    assert pass_rate >= 0.95          # 絕對下限
    assert pass_rate >= baseline.pass_rate - 0.02  # 相對 main 不退步
    assert results.p95_turns <= 25    # 軌跡預算,而不只是結果

```

要對**結果與軌跡**把關(上面的 p95-turns 那行),並**相對於基準**把關,而不只是絕對下限 —— 一個悄悄把 pass rate 從 0.97 降到 0.95 的改動,仍能通過絕對 0.95 的下限,但應該在「不退步」檢查上失敗。**陷阱:** 會隨機失敗的不穩定 eval 會訓練團隊忽略閘門;去修不穩定(提高 k 、穩定參考、隔離外部相依),而不是停用檢查。

27.6 以 eval 驅動的迭代

Evals 不是上線前的一次性閘門;它是持續開發的**方向盤**。這個迴圈呼應第 16 章的 generator-evaluator 模式,但套用在**代理的生命週期**而非單一任務:

1. 讓代理跑過套件(**Run**)。
2. 用程式碼 + 模型評分者**評分**;在邊界案例抽樣人類審查。
3. 把失敗**分類**進桶子(壞的工具資料、提示模糊、模型限制、缺少能力)。
4. **只改一件事** —— 提示、工具、模型或 **effort** —— 去處理最大的桶子。

5. **重跑**並與基準比較;唯有指標改善且沒有回歸,才保留該改動。
6. 把每個新發現的失敗**升格**進回歸套件(\$27.4)。

這正是讓你能**在數天內升級模型**的關鍵:新模型一出,你把套件指向它,讀出 pass@k、成本與 p95 延遲的差異——這是以證據為基礎的決定,而非猜測。這也是你如何選 `effort` 等級、比較提示變體,以及決定一個新工具到底有沒有幫助的方法。**紀律**: 一次只改一個變數,讓 eval(而非直覺)來決定。

27.7 端到端案例研究:程式碼遷移代理的 eval 套件

上述元件唯有組合在一起才有意義。以下是一個真實、高風險代理的完整 eval 套件——它把一個 Python 服務從 `requests` 遷移到 `httpx`,跨整個儲存庫編輯程式碼、執行測試,並開一個 PR。

需求

- 代理接收一個儲存庫與一份遷移規格,並產出一個帶有變更的分支。
- **可驗證的結果**: 遷移後,專案必須仍能建置,且其既有的測試套件必須通過。
- **合理的軌跡**: 它應在編輯檔案前先讀檔、在開 PR 前先跑測試,且絕不碰遷移範圍外的檔案。
- **開放式品質**: PR 描述必須準確摘要改了什麼,並點出任何有風險之處。
- 執行是不確定的,且代理要為團隊的 CI 把關——所以 eval 必須可重現並產出硬性的通過/失敗。

Eval 架構

```
flowchart TD
    Tasks["黃金 plus 回歸任務<br/>凍結的 repo 與規格"] --> Runner["Eval runner<br/>每任務跑 k 次"]
    Runner --> Traj["軌跡紀錄<br/>工具 順序 回合"]
    Runner --> Out["最終輸出<br/>分支 與 diff 與 PR 文字"]
    Out --> Code["程式碼評分者<br/>建置通過 與 測試通過"]
    Traj --> Tcheck["軌跡檢查<br/>先讀後編輯 與 在範圍內"]
    Out --> Judge["LLM 當裁判<br/>PR 描述品質"]
    Code --> Agg["彙整成 pass at k"]
    Tcheck --> Agg
    Judge --> Agg
    Agg --> Gate["符合閘門?"]
    Gate --> Merge["是 | Merge[允許合併]"]
    Gate --> Block["否 | Block[擋下並分類]"]
```

Runner 把每個凍結任務重播 k 次;**程式碼評分者**決定客觀結果(建置 + 測試),**軌跡檢查**斷言過程屬性,而 **LLM 當裁判**評那唯一真正開放式的產物(PR 文字)。結果彙整成 pass@k 並餵給一個硬性的 CI 閘門。

實作

定義評分者。程式碼評分者掌管可驗證的結果——它們是事實的來源:


```
def grade_outcome(run) -> dict:
    return {
        "builds":      run.exit_code("uv build") == 0,
        "tests_pass":  run.exit_code("pytest -q") == 0,
        "no_requests": "import requests" not in run.diff_added_lines(), # 遷移確實發
生了
    }
```

軌跡檢查斷言路徑的屬性,絕不斷言確切的紀錄(\$27.2):

```
def grade_trajectory(trace) -> dict:
    edited = trace.files_edited()
    return {
        "read_before_edit": all(trace.read_before_edit(f) for f in edited),
        "in_scope":         all(f in trace.allowed_paths for f in edited),
        "tested_before_pr": trace.index_of("run_tests") < trace.index_of("open_pr"),
        "within_budget":    trace.turn_count <= 25,
    }
```

LLM 當裁判只評 PR 描述,搭配具體的評分標準,且關鍵是——**用不同於代理的模型**,外加隨機化的比較順序,以對抗 \$27.3 的偏誤:

```
def grade_pr_text(pr_text, diff) -> JudgeVerdict:
    return judge(
        model="claude-sonnet-5",          # 「不是」寫這個 PR 的模型 -> 避免自我增強偏誤
        rubric=PR_RUBRIC,                  # faithful / complete / flags-risk,各為
pass/fail
        inputs={"pr_text": pr_text, "diff": diff},
        randomize_option_order=True,
    )
```

彙整成 pass@k 並把關(\$27.5)。唯有結果**且**軌跡**且**裁判全部通過,一次試驗才算 PASS:

```
def passed(task) -> bool:
    trials = [run_agent(task) for _ in range(K)]          # K 次試驗 -> 不確定性
    def ok(r):
        return (all(grade_outcome(r).values())
                and all(grade_trajectory(r.trace).values())
                and grade_pr_text(r.pr_text, r.diff).verdict == "PASS")
    return any(ok(r) for r in trials)                      # pass@k
```

執行軌跡

```
sequenceDiagram
    actor Dev as 工程師
    participant CI as CI 流水線
    participant Run as Eval runner
    participant Ag as 遷移代理
    participant Cg as 程式碼評分者
    participant J as LLM 裁判
    Dev->>CI: 開一個更動代理提示的 PR
    CI->>Run: 跑回歸套件 k 等於 3
    Run->>Ag: 任務 migrate-service-A 第 1 次試驗
    Ag-->>Run: 分支 diff PR 文字 軌跡
    Run->>Cg: 在分支上建置與測試
    Cg-->>Run: 建置通過 測試通過
    Run->>J: 依評分標準評 PR 描述
    J-->>Run: 裁決 PASS faithful 與 flags-risk 皆通過
    Run-->>CI: pass at 3 等於 0.94 p95 回合等於 22
    CI-->>Dev: 閘門 FAILED 0.94 低於基準 0.97 已擋下
```

注意這個閘門**即使測試通過仍失敗了**:新提示把 pass@3 從 0.97 降到 0.94 —— 這是「不退步」檢查抓到、而單靠絕對 0.95 下限會漏掉的回歸。工程師去分類、修復,而那些失敗的任務便成為永久的回歸案例。

驗證

- **裁判校準測試**: 在一份人類標註的 PR 描述樣本上,斷言裁判與人一致 $\geq 90\%$;若否,錯的是評分標準而非人類標註(\$27.3)。
- **反過擬合測試**: 保留一份團隊從不對它調校的任務切片;若保留切片的 pass@k 偏離可見集合,你就是在對 eval 過擬合(\$27.4)。
- **不穩定測試**: 在 k=3 通過卻在 k=1 失敗的任務會被標記為不穩定並分類,而非默默接受(\$27.5)。
- **回歸測試**: 每個正式環境失敗都必須以一個現在會通過的凍結案例出現(\$27.4)。

常見陷阱

- 只評最終 diff 而略過軌跡 —— 編輯了範圍外檔案的代理仍能「通過」建置(\$27.2)。
- 用寫 PR 的同一個模型去評 PR 文字 —— 自我增強偏誤會灌水分數(\$27.3)。
- 只對絕對下限把關 —— 從 0.97 悄悄降到 0.95 會溜過去;也要相對基準把關(\$27.5)。
- 調到可見集合完美為止 —— 你優化的是測試,不是代理(\$27.4)。

27.8 關鍵整理

概念	要記住什麼
三種評分者	程式碼(可驗證)、模型(開放式,要校準它)、人(黃金標準,用於校準)—— 只要任務能做成可檢的,就優先用程式碼(\$27.1)。
軌跡 vs 最終答案	同時評路徑與結果;斷言路徑的屬性,而非逐字的工具順序(\$27.2)。

LLM 當裁判	具體評分標準、先推理後裁決、用不同於代理的模型,以及偏誤緩解;在信任它之前先對人類標註驗證(\$27.3)。
黃金 + 回歸集	取自正式流量、真實且端到端的任務;每個正式環境 bug 都變成永久回歸案例;保留一份 held-out 切片(\$27.4)。
指標 + CI 把關	代理是不確定的 —— 跑 k 次試驗、回報 pass@k ,並對結果且軌跡把關、且相對基準把關,而不只是絕對下限(\$27.5)。
以 eval 驅動的迭代	一次只改一個變數;讓 eval 來決定;這正是讓你能用證據(而非感覺)在數天內升級模型的關鍵(\$27.6)。

其他一切的量測層。Evals 是 harness(第 15 章)驗證工作的方式,也是 generator-evaluator 迴圈(第 16 章)得知何時該停的方式。一個你無法量測的代理,就是一個你無法安全改進或上線的代理。

第 28 章:模型陣容與選擇(2026)

參考 —— 考試把模型比較列為範圍外;這是給實際開發用。 文件:[Models overview](#) · 以 [Models API](#) 即時查詢。

基礎認證考試告訴你如何接線一個代理 —— 迴圈、hooks、MCP、評測。它刻意不談每次呼叫背後該用哪個模型,因為陣容變動的速度比任何考試都快。但一旦把代理放上線,模型選擇就成為你能做的最高槓桿決策之一:它決定了你每次請求的成本、尾端延遲,以及代理實際能力的上限。一個對所有事都呼叫同一模型的多代理系統,幾乎總是不是付太多(用旗艦推理模型去分類工單),就是做不到(用快速便宜的模型去執行系統遷移)。本章談的就是如何刻意地把這個決策工程化。

讀完你應能做到:

- **讀懂 2026 陣容**(\$28.1)—— 四個家族、它們的價格/上下文/輸出範圍,以及各自的用途。
- **依任務選模型**(\$28.2)—— 由任務複雜度、延遲預算與出錯代價驅動的決策流程。
- **跨層路由工作負載**(\$28.3)—— 在昂貴模型前面放一個便宜分類器,以及分層的協調者/子代理模式。
- **在不犧牲品質下壓低成本**(\$28.4)—— 提示快取、Batch API、輸出紀律,以及 1M 上下文的取捨。
- **安全地管理 ID、升級與降級**(\$28.5)—— 釘選快照、Models API,以及如何不在凌晨兩點出事地完成遷移。

\$28.6 接著從頭到尾建構一個**分層客戶情報管線**,把一條工作流跨 Haiku、Sonnet、Opus 路由,\$28.7 則濃縮工程規則。

28.1 2026 陣容

四個模型家族現役中。它們在三條對工程師重要的軸上有所不同 —— **智慧**(能可靠完成多難的任務)、**成本**(每百萬 token 的輸入/輸出美元,縮寫為 MTok),以及**範圍**(輸入的上下文視窗、輸出的最大 token):

模型	API ID	上下文	最大輸出	輸入 / 輸出 (\$/MTok)	適用
Claude Fable 5	claude-fable-5	1M	128K	\$10 / \$50	最難的推理與長程代理工作 (旗艦)
Claude Opus 4.8	claude-opus-4-8	1M	128K	\$5 / \$25	複雜/代理任務的預設
Claude Sonnet 5	claude-sonnet-5	1M	128K	\$3 / \$15	速度/智慧最佳平衡;大量使用
Claude Haiku 4.5	claude-haiku-4-5	200K	64K	\$1 / \$5	快速、便宜、簡單/延遲關鍵任務

Sonnet 5 是目前的平衡層級, 接替 Sonnet 4.6 (現為舊版模型, 仍可透過 `claude-sonnet-4-6` 呼叫)。Sonnet 5 具有**導入期定價 \$2 / \$10 每 MTok, 至 2026-08-31**, 之後套用標準 **\$3 / \$15**。在 Claude Sonnet 5 上, `effort` 參數在 Claude API 與 Claude Code 預設為 `high`。來源: [模型總覽](#)、[定價](#)。

從 Sonnet 4.6 遷移到 Sonnet 5 —— 有三項 API 行為改變: [自適應思考 \(adaptive thinking\)](#) 現在預設開啟; 手動延伸思考 (`thinking: {type: "enabled", budget_tokens: N}`) 已**移除並回傳 400 錯誤**; 將取樣參數 `temperature` / `top_p` / `top_k` 設為非預設值也會**回傳 400 錯誤**。Sonnet 5 **不支援 Priority Tier** (其餘工具與平台功能與 Sonnet 4.6 相同, 具備 1M 上下文視窗與 128K 最大輸出)。Sonnet 5 另外採用**新的分詞器 (tokenizer)**, 相同文字會產生約多 30% 的 **token**, 因此請用 [token 計數 API](#) (`model="claude-sonnet-5"`) 重新量測提示長度與成本, 不要沿用 Sonnet 4.6 的估算。來源: [Claude Sonnet 5 的新功能](#)。

把它讀成一道階梯, 而非一份菜單。每往上一階, 價格大致翻倍以換取能力的提升, 所以工程問題從來不是「哪個模型最好」—— 而是「哪個是**最便宜**、且能以充裕餘裕通過這項任務門檻的階梯」。

四個家族各一句話:

- **Haiku 4.5** —— 高量、規格明確、延遲敏感工作的主力: 分類、抽取、路由、格式化, 以及大型系統中的**便宜代理**。注意較小的範圍 —— 200K 上下文、64K 輸出 —— 對這些工作綽綽有餘, 但因此無法勝任整個程式庫的推理。
- **Sonnet 5** —— 規模化生產的預設。它以旗艦的同等範圍 (1M 上下文 / 128K 輸出) 只收一小部分價格, 這正是為何大多數面向使用者的代理與高吞吐管線都應該從這裡**起步**, 而非從 Opus。
- **Opus 4.8** —— 旗艦 Opus, 在任務確實複雜或具代理性時是正確的預設: 多步規劃、困難程式碼、長程自主迴圈、細膩判斷。輸出價格約為 Sonnet 的 1.7 倍; 你買到的是在 Sonnet 只能**有時**答對的任務上的可靠性。
- **Fable 5** —— 絕對天花板, 用於最難的推理與最長程的工作。在 \$10/\$50, 其輸出是 Opus 的兩倍, 所以只保留給 Opus 明顯做不好的那一小片任務; 把它當預設用, 是燒預算卻毫無收穫最常見的單一方式。

為何「每美元的智慧」勝過「最聰明」。 一個準確率高 10% 但成本翻倍的模型, 對於更便宜層級已經以 99% 通過的任務是個**糟糕**的交易; 對於更便宜層級以 60% 失敗的任務則是**極佳**的交易。整章談的就是為每個工作負載找到那個交叉點, 而非用猜的。

28.2 依任務選模型

選擇是三個輸入的函數,依優先順序:

1. **任務複雜度 / 出錯代價** —— 推理有多難,答錯要付出什麼?把支援工單貼錯標籤既便宜又可挽回;一次搞砸的資料庫遷移則否。
2. **延遲預算** —— 是否有人在等第一個 token(聊天、自動完成),還是這是個背景工作(夜間批次、非同步管線)、幾秒鐘無所謂?
3. **量 / 單位經濟** —— 每天 10 次請求,價格是雜訊;每天 1,000 萬次,\$1 與 \$5 每 MTok 的差距就是可行產品與關門產品之間的差別。

流程:從最低的合理階梯起步,對著評測集衡量,只在資料這麼說時才往上爬。

flowchart TD

```
A[進來的任務] --> B{複雜推理<br/>或長程代理?}
B -->|否,規格明確| C{延遲關鍵<br/>或極高量?}
C -->|是| D[Haiku 4.5<br/>快又便宜]
C -->|否| E[Sonnet 5<br/>平衡預設]
B -->|是| F{Sonnet 通過<br/>你的評測集嗎?}
F -->|是| E
F -->|否| G[Opus 4.8<br/>旗艦預設]
G --> H{在最難的案例上<br/>仍然失敗?}
H -->|是| I[Fable 5<br/>絕對天花板]
H -->|否| G
```

如何讀這棵樹。 預設路徑落在 **Sonnet 5** —— 這是刻意的。你只在任務簡單且需要速度或規模時往下移到 Haiku;只在評測集證明 Sonnet 把品質留在桌上時往上移到 Opus;只在最頂端、Opus 仍漏掉的殘餘案例上,才用到 **Fable 5**。

這棵樹要防的陷阱:

- **「為了保險」預設用旗艦。** 這是本章最昂貴的錯誤。如果 Haiku 在你的標註集上以 99.2% 通過工單分類,在那裡跑 Opus 只換來 0.3 分準確率,卻付出 5 倍輸入成本與 5 倍輸出成本 —— 在量上是純粹浪費。
- **在需要判斷的任務上抓便宜模型。** 反向錯誤:用 Haiku 處理細膩的政策推理或多檔重構,它會無聲失敗,送出看似自信的錯誤答案。便宜只有在**正確**時才便宜。
- **憑感覺而非評測來選。** 「感覺更聰明」不是選擇標準。對「為何選這個模型」站得住腳的答案永遠是個數字:在具代表性的評測集上的準確率/通過率,搭配實測的每任務成本(這是評測那一章的應用)。
- **忘了範圍。** Haiku 的 200K 上下文 / 64K 輸出對分類綽綽有餘,但裝不下一個大型程式庫,也吐不出一份長文件 —— 這是再多提示也修不了的能力上限。比較價格前,先讓範圍對得上工作。

28.3 跨層路由工作負載

大多數真實系統不是單一任務,而是一種**混合**。成本上的勝利來自**不為那 80% 容易的流量付旗艦價格**。兩種模式幾乎包辦了所有工作。

模式 A —— 在昂貴模型前面放便宜路由器

一個小而快的模型對每個請求分流,並派送到正確的層級。路由器本身便宜(Haiku),所以額外開銷可忽略;省下來的錢來自把容易的流量擋在 Opus 之外。

```

flowchart TD
    U[使用者請求] --> R[路由器<br/>Haiku 4.5 分類器]
    R -->|簡單 FAQ| H[Haiku 4.5<br/>直接回答]
    R -->|標準任務| S[Sonnet 5<br/>端到端處理]
    R -->|複雜或高風險| O[Opus 4.8<br/>深度推理]
    H --> Z[回應]
    S --> Z
    O --> Z
    R -. 低信心 .-> O

```

路由器的工作是分類,不是解題——所以它必須便宜又快,而且必須**向上失敗**:當路由器不確定時,送往更強的模型,絕不送往更弱的。把困難案例誤送到 Haiku 會產生一個自信的錯誤答案(清理代價高);把容易案例誤送到 Opus 不過是在那一次請求上多花了錢。這個不對稱告訴你該往哪邊偏。

模式 B —— 分層多代理:強協調者、便宜子代理

這直接建立在第 3 章的中心輻射式拓撲上,但為每個角色指派一個模型。協調者做困難、不可逆的推理——分解、驗證、最終綜整——所以它跑 **Opus 4.8**。子代理做範圍狹窄、規格明確的工作(抓一個頁面、抽取欄位、摘要一份文件),所以它們跑 **Haiku 4.5**。你把花費集中在判斷所在之處,在其他地方一律省。

```

flowchart TD
    U[使用者請求] --> C[協調者<br/>Opus 4.8 - 規劃與驗證]
    C -->|Task: 抓取| S1[子代理<br/>Haiku 4.5]
    C -->|Task: 抽取| S2[子代理<br/>Haiku 4.5]
    C -->|Task: 摘要| S3[子代理<br/>Haiku 4.5]
    S1 -. 結果 .-> C
    S2 -. 結果 .-> C
    S3 -. 結果 .-> C
    C --> R[綜整且驗證後的答案]

```

為何這是多代理成本控制的正確預設: 協調者每次請求只跑一次,但做的是搞砸代價高昂的決策;子代理可能平行跑五次或十次,但每個做的都是便宜模型能以近旗艦品質處理的任務。把它顛倒過來——便宜協調者委派給昂貴子代理——是個反模式:你把便宜模型放去掌管不可逆的決策,卻為容易的部分付了溢價。

取捨與陷阱:

- **路由多了一跳**。路由器呼叫耗 token 與延遲。只有在流量混合確實偏斜(大量容易請求)時才划算。對於幾乎全是困難任務的低量代理,跳過路由,直接跑 Sonnet 或 Opus——在那裡放路由器是過度設計。
- **混合模型意味混合行為**。Haiku 與 Opus 的措辭、格式與拒答方式都不同。若不同層級的輸出被串接或比較,把它們正規化(類似 `PostToolUse` 的步驟),好讓下游程式碼不會被依層級而異的格式嚇到。
- **錯誤的層級邊界會無聲降低品質**。若路由器把太多送往 Haiku,準確率下降卻不會冒出錯誤。監看每層通過率,而非只看整體延遲,好讓漂移的邊界看得見。

28.4 在不犧牲品質下壓低成本

選對層級是大槓桿;以下四項在層級內降低帳單,常常比層級之間的差距還大。

- **提示快取。** 快取穩定前綴 —— 系統提示、工具定義、長的少樣本範例、重複使用的文件。快取讀取成本約為基礎輸入價的 **0.1 倍**，寫入約 **1.25 倍** —— 所以一大段重複使用的前言，在兩三次請求內就回本。把穩定內容放前面、易變內容放後面(渲染順序為 `tools` → `system` → `messages`)；系統提示裡的時間戳或每請求 ID 會無聲讓整個快取失效。用 `usage.cache_read_input_tokens` 驗證 —— 若它在應該共享前綴的請求間維持為零，就是有個無聲的失效因子在作怪。
- **Batch API —— 五折。** 任何不延遲敏感的工作(夜間擴充、大量分類、評測執行、回溯目錄處理)都該放上半價的 **Batch API**。代價是延遲，不是品質：同一模型、同一範圍、非同步回傳。對背景管線而言這是免費的錢。
- **輸出紀律。** 輸出在每一層都是輸入價的 **5 倍**，所以囉嗦的回應比要求它的提示還貴。一個緊湊的 `max_tokens` 與一個要求簡潔、結構化輸出的系統提示，直接砍掉帳單中昂貴的那一半。要求 JSON 而非散文，既更便宜也更可靠地解析。
- **別買你用不到的上下文。** 1M 上下文範圍(Sonnet/Opus/Fable)是一種能力，不是一個目標。為了「給模型全部」而把整個知識庫塞進每個提示，會在每一次呼叫上灌大輸入成本，還可能因為把相關事實埋掉而降低品質。改為只取出少數相關片段 —— 更便宜，通常也更準。真正的 1M 上下文填充，留給確實需要全語料推理的任務，而當你這麼做時，把固定的部分快取起來。

flowchart TD

```

A[每請求成本太高] --> B{延遲敏感?}
B -->|否| C[移到 Batch API<br/>五折]
B -->|是| D{有大段穩定前綴<br/>跨呼叫重複使用?}
D -->|是| E[加上提示快取<br/>讀取約 0.1 倍]
D -->|否| F{輸出很長或<br/>無上限?}
F -->|是| G[收緊 max_tokens<br/>要求結構化輸出]
F -->|否| H[重新檢視層級<br/>也許降到 Sonnet 或 Haiku]

```

順序很重要：在降級模型之前，先把免費的勝利(批次、快取、輸出紀律)用盡，因為它們在不動品質的情況下砍成本。降級層級是最後一根槓桿，也是唯一會冒準確率風險的 —— 所以它必須由評測把關。

28.5 ID、升級與降級

模型選擇不是一次性決策；陣容在你腳下變動，而你如何把選擇編碼進去，決定了升級是一次設定切換還是一場停機。

- **ID 是精確的釘選快照 —— 絕不自行構造。** `model` 是一個精確字串，不是你能裝飾的模糊別名。自 4.6 世代起，ID 無日期但仍是釘選(如 `claude-opus-4-8`)；更舊的模型以日期別名解析。一個錯字(`claude-sonnet-4.6`)或一個杜撰的日期後綴(`claude-opus-4-8-20260114`)會回傳 `**404 not_found_error`。把模型釘在單一設定常數裡，別散落在程式庫各處。
- **在執行期探索能力，別寫死。** 上下文視窗、輸出上限與功能支援都隨陣容變動。查詢 **Models API**(`GET /v1/models/{id}` → `max_input_tokens`、`max_tokens`、`capabilities`)，而非把「200K」或「128K」烤進你的程式碼。這正是讓下游服務在你切換層級時能自我調適的關鍵。
- **舊版與棄用。** 較舊的模型會繼續可用一段時間 —— Opus 4.7/4.6、Sonnet 4.6、Sonnet 4.5、Opus 4.5 仍可呼叫(Sonnet 4.6 在 Sonnet 5 推出後成為舊版) —— 但被棄用的會在某個日期退役，之後該 ID 會**永久回傳 404**。這並非假設：最初的 Claude Sonnet 4(`claude-sonnet-4-20250514`)與 Claude Opus 4(`claude-opus-4-20250514`)已於 **2026-06-15 退役**，現會回傳錯誤，而 Opus 4.1(`claude-opus-4-1-20250805`)將於 2026-08-05 退役。追蹤退役日期，並在截止之前遷移，而非等 404 開始才動。

- **刻意地、由評測把關地升級與降級。** 在真實流量的品質指標於困難案例上未達標時「升級」(Sonnet→Opus);在評測顯示更便宜層級現已追上品質時「降級」(Opus→Sonnet、Sonnet→Haiku)——較新的便宜模型常能通過一個世代前需要旗艦才行的門檻。絕不盲目切換生產模型:把候選對著你的評測集跑,比較通過率與每任務成本,然後改那一個設定常數。

```

flowchart TD
    A[考慮變更模型] --> B{方向?}
    B -->|為品質升級| C[把候選跑在評測集上]
    B -->|為成本降級| C
    C --> D{通過率達標?}
    D -->|否| E[維持目前模型]
    D -->|是| F{每任務成本可接受?}
    F -->|否| E
    F -->|是| G[切換那單一設定常數<br/>並監看]

```

28.6 端到端案例研究:分層客戶情報管線

上述模式唯有在真實預算下組合起來才有意義。以下是一個完整系統,把一條進站客戶訊息流跨三個工作層級路由,只在旗艦價格能賺回成本之處才付。

需求

- 攝入一條高量的進站訊息流(支援工單、業務詢問、意見回饋)—— 每天數萬則。
- 對每則訊息**分流**為類別與緊急度,快速又便宜(有人或佇列在等)。
- 端到端**解決**標準請求,並產出面向客戶的回覆。
- 把複雜或高風險案例(合約爭議、安全通報、流失風險)**升級**至深度推理,並草擬一份經研究的回應。
- 一個獨立的**夜間**工作擴充當天的封存(情緒、主題、趨勢報告)—— 不延遲敏感。
- 在不讓困難的那 10% 準確率滑落的前提下,維持每則訊息的混合成本偏低。

架構 —— 每層一個模型

```

flowchart TD
    M[進站訊息流] --> T[分流<br/>Haiku 4.5 分類器]
    T -->|簡單 FAQ| FA[Haiku 4.5<br/>直接回答]
    T -->|標準請求| RS[Sonnet 5<br/>端到端解決]
    T -->|複雜或高風險| CO[協調者<br/>Opus 4.8]
    CO -->|Task: 拉歷史| SA1[子代理<br/>Haiku 4.5]
    CO -->|Task: 搜尋政策| SA2[子代理<br/>Haiku 4.5]
    SA1 -- 結果 --> CO
    SA2 -- 結果 --> CO
    CO --> DR[草擬且驗證後的回覆]
    FA --> OUT[對外回覆]
    RS --> OUT
    DR --> OUT
    M -- 封存 --> NB[夜間 Batch API<br/>Sonnet 5 五折]

```

每一階都對上它的工作:**Haiku** 分流並回答 FAQ(便宜、快、簡單);**Sonnet** 解決標準的大宗(平衡預設);**Opus** 協調困難案例並驗證草稿,把**抓取委派給 Haiku 子代理**,好讓旗艦 token 只花在判斷上;**夜間封存**跑在半價的

Batch API 上,因為沒有人在等。

實作

把每個模型釘在單一設定區塊裡,好讓層級變更是一行編輯,而絕不是構造出來的 ID:

```
MODELS = {
    "triage":      "claude-haiku-4-5", # 便宜、快速的分類
    "faq":         "claude-haiku-4-5", # 簡單的直接回答
    "standard":    "claude-sonnet-5",  # 大宗的平衡預設
    "coordinator": "claude-opus-4-8",  # 困難推理 + 驗證
    "subagent":    "claude-haiku-4-5", # 協調者底下的狹窄抓取/抽取
    "nightly":     "claude-sonnet-5",  # 品質擴充,經由 Batch API 執行
}
```

路由器便宜地分類,並**向上失敗**—— 低信心送往更強的層級,絕不送往更弱的:

```
def route(message) -> str:
    result = classify(message, model=MODELS["triage"]) # Haiku:類別 + 信心
    if result.category == "faq":
        return "faq"
    if result.complex or result.high_stakes or result.confidence < 0.7:
        return "coordinator" # 不確定時偏向 Opus — 便宜答錯的代價更高
    return "standard"
```

在高量的 Sonnet 路徑上快取穩定前綴,好讓重複使用的系統提示與政策文字在第一次呼叫後以約 0.1 倍計費:

```
resolve(
    message,
    model=MODELS["standard"],
    system=[{"type": "text", "text": POLICY_PREAMBLE,
             "cache_control": {"type": "ephemeral"}}], # 穩定前綴 -> 快取讀取約 0.1
    倍
)
```

執行軌跡 —— 一個困難案例

```
sequenceDiagram
    actor Cust as 客戶
    participant T as 分流 (Haiku)
    participant Co as 協調者 (Opus)
    participant Sub as 子代理 (Haiku)
    Cust->>T: 「你們的 API 洩漏了我的金鑰 —— 我要升級處理」
    T->>T: 分類 -> high_stakes, 信心 0.55
    T->>Co: 向上路由(安全 + 低信心)
    Co->>Sub: Task(上下文: 帳戶 id, 抓取事件歷史)
    Sub-->>Co: 先前工單 + 受影響金鑰範圍
    Co->>Co: 對著政策推理, 草擬經研究的回覆
    Co-->>Cust: 驗證後的升級處理與後續步驟
```

注意分流模型**沒有**試圖去解這個安全通報 —— 它辨識出「高風險 + 低信心」並往**上**路由。昂貴的 Opus 推理只在這則困難訊息上跑;Haiku 子代理在它底下做便宜的抓取。那從未走到此路徑的 80% 流量,以一小部分成本在 Haiku 與 Sonnet 上被解決。

驗證

- **成本測試:** 計算每則訊息的混合成本,確認它落在 Sonnet/Haiku 地板附近,而非 Opus 天花板 —— 若往上漂,就是太多流量在升級;檢查路由器邊界。
- **品質測試:** 在標註評測集上追蹤**每層**通過率,而非只看整體。Haiku 層下降,意味分流邊界把它處理不了的工作送了過去 —— 收緊門檻,別怪模型。
- **向上失敗測試:** 餵入刻意含糊的困難案例,斷言它們落在協調者,絕不在 Haiku。路由器絕不能把高風險案例送往便宜層。
- **批次測試:** 確認夜間工作跑在 Batch API(五折)上,且沒有任何延遲敏感的東西被誤送到那裡。

常見陷阱

- 「為了品質」把整條管線跑在 Opus 上 —— 混合成本爆炸,只為便宜層級早已交付的一小部分準確率 (§28.2)。
- 一個**向下**失敗的路由器(不確定時預設 Haiku),在困難案例上送出自信的錯誤答案 (§28.3)。
- 便宜協調者委派給昂貴子代理 —— 判斷放錯了模型,在容易的部分付了溢價 (§28.3)。
- 在沒有延遲需求時,把夜間擴充放上全價的同步 API (§28.4)。
- 寫死 `claude-opus-4-8-20260114` 或 `"200K"`,而非釘選無日期 ID 並查詢 Models API —— 一個等著發生的 404 或過時假設 (§28.5)。

28.7 工程重點 —— 關鍵整理

概念	要記住的
階梯,不是菜單	每層約為上一層的 2 倍;挑 能以充裕餘裕通過任務的最便宜階梯 ,而非最強的 (§28.1)。
選擇流程	由複雜度 → 延遲 → 量驅動;從 低起步 ,只在評測集這麼說時才往上爬 (§28.2)。

預設用 Sonnet	Sonnet 5 是生產預設;為簡單/快速/高量往下移到 Haiku,只在品質要求時往上移到 Opus(\$28.2)。
路由混合	在昂貴層級前放一個便宜的 Haiku 路由器;不確定時它必須 向上失敗 (\$28.3)。
分層多代理	強協調者(Opus)+ 便宜子代理(Haiku);絕不顛倒(\$28.3)。
先用成本槓桿再降級	快取(讀取約 0.1 倍)、Batch API(五折)、收緊 <code>max_tokens</code> ,在不動品質下砍成本 —— 先做這些(\$28.4)。
ID 與遷移	釘選精確的無日期 ID,絕不構造日期後綴(404);查詢 Models API 取得上限;升級/降級由評測把關(\$28.5)。

超出基礎認證考試範圍。 考試不會要你比較模型,但生產會 —— 每天、每次請求。掌握這道階梯、向上失敗的路由器、與分層協調者,你就把模型選擇從一場猜測,變成系統中一個工程化、可衡量、且能持續最佳化的部分。

第 29 章:部署與企業整合

參考 —— 超出考綱。 文件:[平台可用性](#) · [Workload Identity Federation](#) · [Enterprise-Managed Authorization](#)

在此之前的一切,談的都是代理**內部**發生的事 —— 迴圈、工具、上下文。生產環境會問兩個考試從不問的問題:**這東西跑在哪裡,以及跑在那裡時,它是誰?** 哪個雲端平台供應模型、一整隊無人值守的工作負載如何在不留一抽屜 API key 的情況下驗證身分、誰決定組織的代理可以碰哪些 MCP 伺服器,以及憑證放在哪裡才不會被提示注入偷走。答案本指南都有 —— 附錄裡的一張對等性表格、一列 WIF、\$25.3 的一則 EMA 條目、第 24 章的 vault —— 但很分散。本章把它們組裝成一套決策框架。

讀完你應能做到:

- **選擇部署平台**(\$29.1)—— 第一方 API、Claude Platform on AWS、Bedrock、Vertex 或 Foundry,由功能對等性與法遵決定,而非慣性。
- **淘汰靜態 API key**(\$29.2)—— 用工作負載身分聯合(WIF)取代所有無人值守工作負載的 `sk-ant-...` 密鑰。
- **在組織層級治理 MCP**(\$29.3)—— 以 managed MCP 固定核准的伺服器目錄,以 EMA 集中授權。
- **讓密鑰遠離上下文視窗**(\$29.4)—— egress 注入:模型從未持有的東西,它就永遠洩漏不了。

\$29.5 把這些組裝成一套參考企業架構,\$29.6 濃縮規則。

29.1 選擇部署平台

有五個平台面供應 Claude,而且它們**不可互換** —— 差異是架構層級的,不是外觀上的。完整比較在附錄的雲端供應商表格;這裡重要的是決策流程:

flowchart TD

A[Claude 必須跑在哪裡?] --> B{ 架構需要伺服器端工具、
Batches、Files API
或 Managed Agents? }

B --> | 需要 | C{ 計費/採購方式? }

C --> | Anthropic 直接 | D[第一方 API]

C --> | AWS Marketplace + IAM | E[Claude Platform on AWS
同日完整對等, SigV4]

B --> | 不需要 — 推理+工具使用即可 | F{ 法遵或雲端承諾? }

F --> | FedRAMP High / DoD IL4-5 | G[Amazon Bedrock]

F --> | GCP 陣營 | H[Google Vertex AI]

F --> | Azure 陣營 | I[Microsoft Foundry
多數功能 beta]

承重的事實是:**第一方 API 與 Claude Platform on AWS 是完整介面**;Bedrock 與 Vertex 是**模型推理+工具使用**。Bedrock/Vertex 上沒有 Batches、沒有 Files API、沒有程式執行、沒有 web fetch、沒有 Managed Agents —— 你得自帶迴圈,並在一個裸模型周圍自建基礎設施。當 FedRAMP High 或雲端承諾有此要求時,這是划算的交換,但必須在**設計架構之前**做,而不是之後。

經典的失敗是先按第一方功能設計 —— 一條以 Batches 為基礎的夜間管線、Files API 的文件重用、一支 Managed Agents 艦隊 —— 然後在「Bedrock 遷移」期間才發現那些介面在那裡都不存在。這時的移植等於重新設計架構。先查[可用性表格](#),並把「用哪個平台」當作一個有指定負責人的需求決策,就像選資料庫一樣。

29.2 工作負載身分:讓靜態 API key 退役

靜態的 `sk-ant-...` key 在筆電上沒問題,在艦隊裡是隱患。規模化後它有四個結構性問題:必須有人**產生並輪替**它;它會**外洩**(日誌、映像、儲存庫),而且誰拿到都能繼續用;共用它的每個呼叫者看起來都是**同一個身分**,無法按工作負載歸因用量或界定權限;撤銷是**全有或全無** —— 廢掉 key 等於同時廢掉每一個使用者。

工作負載身分聯合(WIF)徹底移除長存密鑰。工作負載用它自己的平台 —— AWS、GCP、Microsoft Entra ID、GitHub Actions、Kubernetes、SPIFFE 或 Okta —— 簽發的短效 OIDC JWT 證明自己是誰,並在 `POST /v1/oauth/token` 換取一個受範圍限制、僅數分鐘有效、以服務帳號身分運作的 Anthropic token:

sequenceDiagram

participant W as 工作負載(CI 作業/服務)

participant IdP as 它的身分提供者(OIDC)

participant T as Anthropic /v1/oauth/token

participant API as Claude API

W->>IdP: 請求身分 token

IdP-->>W: 短效 OIDC JWT

W->>T: 以 JWT 換取存取 token

T-->>W: 受範圍限制的 Anthropic token(數分鐘)

W->>API: 以該 token 進行一般 API 呼叫


```
# 1. 工作負載所在的平台簽發它的身分(任何地方都不儲存密鑰)。  
jwt = ci_platform.request_oidc_token(audience="https://api.anthropic.com")  
  
# 2. 換取受範圍限制的 Anthropic token — 數分鐘有效、服務帳號語意。  
# (精確的交換參數: 見 WIF 文件。)  
token = exchange_at_oauth_endpoint(jwt)  
  
# 3. 像 API key 一樣使用 — 所有端點、各 SDK 與 Claude Code 都接受。  
client = Anthropic(auth_token=token)
```

這在結構上買到了什麼: **沒有東西需要產生、輪替或會外洩** —— 被截獲的 token 幾分鐘內就死亡; **身分綁定的存取** —— 權限與撤銷都活在 *你的* IdP(移除該工作負載的角色, 它的存取立即處處消失); 以及 **按工作負載歸因** —— 用量、限額與稽核軌跡以服務帳號為單位, 而非一把匿名的共用 key。

陷阱。 token 依設計數分鐘就過期 —— 在 TTL 前重新換取, 別為整個作業快取一個。筆電上的人類仍使用 API key; 把那些 key 界定為低權限, 而不是假裝 WIF 涵蓋了他們。絕不記錄換得的 token。並抗拒「以防萬一留一把靜態備援 key」 —— 那會悄悄把 WIF 要消滅的長存密鑰又帶回來。

29.3 在企業規模治理 MCP

跑 MCP 代理的組織有兩個不同的治理問題, 對應兩個不同的機制:

哪些伺服器可以存在 —— 目錄。 **Managed MCP**(§26.5)讓組織透過 `managed-mcp.json` 固定核准的伺服器集合, 像任何設定一樣散布(外掛是自然的載體 —— §26.5)。開發者不自行拼湊伺服器清單; 平台團隊出貨一份。

誰可以使用它們 —— 授權。 **企業託管授權(EMA)** —— 自 2026 年 6 月 18 日起為 **穩定版 MCP** 擴充 —— 把 MCP 授權搬進企業身分提供者。管理員為組織啟用某伺服器一次; 使用者與工作負載便依既有的 IdP 群組與角色取得存取權。沒有逐人的 OAuth 同意畫面, 而且撤銷集中又即時: 把某人移出 IdP 群組, 他對該伺服器的存取立即處處消失。Okta 是首發 IdP; Asana、Atlassian、Canva、Figma、Linear 與 Supabase 在首批支援的伺服器之列。

對比那些你可能忍不住想用的替代機制:

機制	它實際上是什麼	作為治理為何失敗
CLAUDE.md 裡的伺服器清單	提示文字	勸告性 —— 模型通常遵守; 沒有任何東西強制
防火牆封鎖	網路控制	擋得住流量, 但授予不了權限、不認識身分、不管理同意的生命週期
逐使用者 OAuth 同意	真授權	無法規模化、沒有集中視圖, 撤銷是逐人逐伺服器的考古工作
managed MCP + EMA	設定 + 身分	確定性的目錄、群組化的存取、即時的集中撤銷、稽核軌跡

這是第 13 章的原則換上企業的衣服: **當一項禁令重要時, 它活在設定與身分裡, 不在措辭裡。**

29.4 執行期的密鑰:egress 注入

第 24 章在 Managed Agents 的脈絡中介紹了這個模式;它值得被表述為一條通則:**模型的上下文視窗絕不能包含憑證**。凡在上下文裡的東西都可能被輸出 —— 被提示注入的 PR 誘出、被回聲進日誌、被摘要進逐字稿。修法是結構性的,不是行為性的:

```
flowchart LR
    M[模型上下文<br/>永不持有密鑰] --> T[工具呼叫]
    T --> G[egress 邊界<br/>vault 注入憑證]
    G --> S[(外部服務)]
```

- **Vault(Managed Agents):** 密鑰只在 egress 被替換 —— 被指示 `echo $GITHUB_TOKEN` 的代理印不出任何有用的東西,因為那個 token 從未存在於它的世界裡(\$24.5)。
- **MCP 伺服器自持憑證:** 伺服器在伺服器端向它的後端服務驗證;模型看到的是工具,永遠不是 key(\$4.2 —— 這也是問題 82 「把 API key 放進 CLAUDE.md」錯誤的原因)。
- **自架迴圈:** 憑證放在 *工具程序* 的環境裡,由你的執行環境注入,絕不內插進提示或工具結果。
- ****WIF(\$29.2)****連平台憑證本身都縮小成一個綁定於你所控身分、數分鐘即逝的 token。

測試是機械性的: 跑一場提示注入演練,嘗試印出代理可能觸及的每一個憑證,並斷言逐字稿中一個都沒有出現。若密鑰有辦法出現在逐字稿裡,它終究會出現。

29.5 參考企業架構

組裝起來,各部件長這樣 —— 以一支夜間安全審查艦隊為貫穿範例:

```
flowchart TD
    subgraph ID[身分層]
        IdP[Okta / GitHub OIDC]
    end
    IdP -- "WIF:JWT → 數分鐘 token" --> Run[代理工作負載<br/>claude -p / Agent SDK / Managed Agents]
    IdP -- "EMA:依群組授權" --> MCP[核准的 MCP 伺服器<br/>由 managed-mcp.json 固定]
    Run --> MCP
    Run --> API[Claude API<br/>$29.1 選定的平台]
    MCP -- "vault / egress 注入" --> Ext[(內部系統)]
    Run -- "PreToolUse deny 規則 + hooks" --> Guard[確定性護欄]
    Run -- "SessionEnd 稽核 hook" --> SIEM[(稽核軌跡 / SIEM)]
```

夜間作業按排程啟動;runner 經 **WIF** 驗證身分(CI 裡任何地方都不存在靜態 key);它只能存取組織固定下來的 MCP 伺服器,而且只因為它的服務帳號位在正確的 **EMA** 群組;那些伺服器需要的 GitHub token 由 **vault 在 egress 注入**,所以被審查的 PR 釣不到它;「絕不推上 main」是一條 **deny 規則**加一個 **PreToolUse hook**(§13.4、§26.7),不是提示裡的一句話;**SessionEnd hook** 送出稽核軌跡。模型平台則是 §29.1 選出的那一個 —— 上面這張架構不因此而變。

驗證

- **key 盤點測試:** grep CI 設定與密鑰儲存;斷言無人值守工作負載已無任何 `sk-ant-` key 殘留。

- **撤銷測試:** 移除工作負載的 IdP 群組成員資格;斷言它的下一次 token 交換失敗、MCP 存取消失。
- **外洩演練:** 提交一個嘗試回印所有可及憑證的提示注入輸入;斷言任何逐字稿或日誌中都沒有出現。
- **對等性測試:** 列出你的架構呼叫的平台功能(Batches?Files?程式執行?),並斷言每一項都存在於你選定的平台上。

29.6 工程重點 —— 關鍵整理

概念	要記住的
平台選擇	對等性決定一切:第一方 + Claude Platform on AWS 是完整介面;Bedrock/Vertex 是推理+工具使用 —— 在設計架構之前查可用性表格(\$29.1)。
WIF	在 <code>POST /v1/oauth/token</code> 以短效 OIDC JWT 換取數分鐘的受範圍 token —— 沒有東西要產生、輪替或會外洩;撤銷活在你的 IdP(\$29.2)。
目錄 vs 授權	<code>managed-mcp.json</code> 固定哪些伺服器存在;EMA 決定誰能用 —— 依群組、可集中撤銷、有稽核 (\$29.3)。
密鑰	egress 注入:上下文視窗永不持有憑證,提示注入偷不到不存在的東西(\$29.4)。
原則	身分、授權與保密是 設定,不是提示文字 —— 與 deny 規則和 hooks 同一條定律(第 13 章、\$26.6)。

超出基礎認證考試範圍。 考試止於代理的邊緣;生產從那裡開始。按對等性選平台、讓每個工作負載證明自己是誰、透過身分治理 MCP、讓密鑰徹底離開模型的世界 —— 你在第一到第三部分建好的那個代理,就成了企業真正跑得動的東西。

考題範例與解析

問題 1(情境:客戶支援代理)

情境: 資料顯示,在 12% 的案例中,代理跳過 `get_customer` ,僅以客戶的姓名呼叫 `lookup_order` ,進而導致錯誤的退款。

哪一項變更最為有效?

- A) 加入程式化的前置條件,在從 `get_customer` 取得 ID 之前封鎖 `lookup_order` 與 `process_refund` **[CORRECT]**
- B) 改善系統提示
- C) 加入少樣本範例
- D) 實作路由分類器

為何選 A: 當關鍵業務邏輯需要特定的工具順序時,軟體能提供以提示為基礎的做法(B、C)所無法提供的**確定性保證**。D 處理的是可用性,而非工具排序。

問題 2(情境:客戶支援代理)

情境: 對於與訂單相關的問題,代理經常呼叫 `get_customer` 而非 `lookup_order`。工具描述極為精簡且彼此相似。

第一步該做什麼?

- A) 少樣本範例
- B) 為每個工具的描述補充輸入格式、範例與邊界 **[CORRECT]**
- C) 加入路由層
- D) 合併這些工具

為何選 B: 工具描述是模型主要的選擇機制。這是投入最少、影響最大的修正。A 增加了 tokens,卻未處理根本原因。C 是過度設計。D 所需投入超過其合理性。

問題 3(情境:客戶支援代理)

情境: 代理僅解決了 55% 的問題,而目標為 80%。它將簡單的案例升級,卻試圖自主處理複雜的政策例外。

你該如何改善校準?

- A) 加入明確的升級準則並搭配少樣本範例 **[CORRECT]**
- B) 自評信心(1–10)並自動升級
- C) 以歷史資料訓練的獨立分類器
- D) 情感分析

為何選 A: 它直接處理了根本原因——不明確的決策邊界。B 不可靠(模型可能在充滿信心的同時卻是錯的)。C 是過度設計。D 解決的是另一個問題(情緒 != 複雜度)。

問題 4(情境:使用 Claude Code 生成程式碼)

情境: 你需要一個用於標準程式碼審查的自訂 `/review` 命令,並讓整個團隊在複製儲存庫時都能使用。

你應該在哪裡建立這個命令檔案?

- A) 專案儲存庫中的 `.claude/commands/` **[CORRECT]**
- B) `~/claude/commands/`
- C) 根目錄的 `CLAUDE.md`
- D) `.claude/config.json`

為何選 A: 儲存於 `.claude/commands/` 的專案命令會納入版本控制,並自動供所有人使用。B 用於個人命令。C 用於指令,而非命令定義。D 並不存在。

問題 5(情境:使用 Claude Code 生成程式碼)

情境: 你需要將一個單體應用程式重構為微服務(數十個檔案、服務邊界的決策)。

你應該採用什麼做法?

- A) 規劃模式:探索程式碼庫、理解相依性、設計做法 **[CORRECT]**
- B) 漸進式的直接執行
- C) 搭配詳盡前置指令的直接執行
- D) 直接執行,等到變困難時再切換至規劃

為何選 A: 規劃模式專為大型變更、多種可能做法與架構決策而設計。B 有昂貴重工的風險。C 假設你已經知道結構。D 是被動反應式的。

問題 6(情境:使用 Claude Code 生成程式碼)

情境: 某個程式碼庫在不同範圍(React、API、資料庫)有不同的慣例。測試與程式碼放在同一處。你希望這些慣例能自動套用。

你應該採用哪種做法?

- A) 使用帶有 YAML frontmatter 與 glob 模式的 `.claude/rules/` 檔案 **[CORRECT]**
- B) 把所有內容都放進根目錄的 CLAUDE.md
- C) 放在 `.claude/skills/` 的 Skills
- D) 在每個目錄都放一份 CLAUDE.md

為何選 A: 帶有 glob 模式(例如 `**/*.test.tsx`)的 `.claude/rules/` 能根據檔案路徑自動套用慣例——非常適合分散在整個程式碼庫中的測試。B 仰賴模型推論。C 是手動/隨需的。D 在相關檔案散落於多個目錄時運作不佳。

問題 7(情境:多代理研究系統)

情境: 該系統研究「AI 對創意產業的影響」,但報告只涵蓋視覺藝術。協調者將主題分解為:「數位藝術中的 AI」、「平面設計中的 AI」、「攝影中的 AI」。

原因是什麼?

- A) 綜整代理沒有偵測到缺口
- B) 協調者把任務分解得太狹隘 **[CORRECT]**
- C) 網路搜尋代理搜尋得不夠徹底
- D) 文件分析代理過濾掉了非視覺類的來源

為何選 B: 紀錄顯示協調者把「創意產業」只分解成視覺類的子主題,完全漏掉了音樂、文學與電影。子代理執行正確——問題在於它們被指派的任務內容。

問題 8(情境:多代理研究系統)

情境: 某個網路搜尋子代理在研究一個複雜主題時逾時。你需要設計錯誤資訊如何回傳給協調者。

哪種錯誤傳播做法最能促成智慧型復原?

- A) 將結構化的錯誤上下文回傳給協調者:失敗類型、查詢、部分結果與替代方案 **[CORRECT]**
- B) 在子代理內實作帶有指數退避的自動重試,然後回傳一個籠統的「search unavailable」狀態
- C) 在子代理內捕捉逾時,並回傳一個標記為成功的空結果集
- D) 將逾時例外向上傳播至最上層的處理器,並終止整個工作流程

為何選 A: 結構化的錯誤上下文提供協調者所需的資訊,以決定是否要用修改後的查詢重試、嘗試替代做法,或以部分結果繼續。B 把上下文藏在籠統的狀態後面。C 把失敗偽裝成成功。D 不必要地中止了整個工作流程。

問題 9(情境:多代理研究系統)

情境: 綜整代理在合併結果時經常需要驗證特定主張。目前,當需要驗證時,綜整代理會把控制權交回協調者,由協調者呼叫網路搜尋代理,然後用新結果重新執行綜整。這每個任務會增加 2–3 次額外的往返,並使延遲增加 40%。你的評估顯示,其中 85% 的檢查是簡單的事實查核(日期、姓名、統計數字),而 15% 需要更深入的調查。

你要如何在維持可靠性的同時降低額外開銷?

- A) 給綜整代理一個受限的 `verify_fact` 工具來處理簡單的查核,並繼續讓複雜的驗證透過協調者路由 **[CORRECT]**
- B) 把所有驗證需求累積成一個批次,在最後回傳給協調者
- C) 給綜整代理對所有網路搜尋工具的完整存取權
- D) 主動快取每個來源周遭的額外上下文

為何選 A: 這套用了最小權限原則:綜整代理恰好取得它在 85% 常見情況(簡單事實查核)所需的東西,同時保留由協調者中介的路徑來處理複雜的調查。B 引入了阻塞式相依性(後續的綜整步驟可能仰賴先前已驗證的事實)。C 破壞了職責分離。D 仰賴推測性快取,而這無法可靠地預測需求。

問題 10(情境:用於持續整合的 Claude Code)

情境: 某條管線執行 `claude "Analyze this pull request for security issues"`,卻卡住等待互動式輸入。

正確的做法是什麼?

- A) 使用 `-p` 旗標: `claude -p "Analyze this pull request for security issues"` **[CORRECT]**
- B) 設定 `CLAUDE_HEADLESS=true`
- C) 將 `stdin` 從 `/dev/null` 重新導向
- D) 使用 `--batch`

為何選 A: `-p` (或 `--print`) 是有文件記載、用於以非互動模式執行 Claude Code 的方式。它會處理提示、印出到 `stdout`, 然後結束。其他選項不是不存在的功能, 就是 Unix 的權宜做法。

問題 11(情境:用於持續整合的 Claude Code)

情境: 團隊想要降低自動化分析的 API 成本。Claude 目前即時服務兩種工作流程:(1) 一個阻塞式的合併前檢查, 必須在開發者能夠合併 PR 之前完成; 以及 (2) 一份在夜間產生、供早上審閱的技術債報告。一位主管提議把兩者都移到 Message Batches API 以節省 50%。

你應該如何評估這項提案?

- A) 只對技術債報告使用批次處理; 合併前檢查維持即時呼叫 **[CORRECT]**
- B) 把兩個工作流程都移到批次處理, 並輪詢完成狀態
- C) 兩者都維持即時呼叫, 以避免批次結果中的排序問題
- D) 把兩者都移到批次處理, 並在某個批次耗時過久時退回即時呼叫

為何選 A: Message Batches API 可節省 50%, 但處理時間最長可達 24 小時, 且沒有保證的延遲 SLA。這使它不適合開發者正在等待的阻塞式合併前檢查, 但非常適合像技術債報告這類的夜間批次工作負載。

問題 12(情境:用於持續整合的 Claude Code)

情境: 某個 pull request 變更了一個庫存追蹤模組中的 14 個檔案。對所有檔案進行單遍審查會產生不一致的結果: 某些檔案有詳細的評論, 其他檔案卻很表面, 漏掉明顯的 bug, 還有互相矛盾的回饋(某個模式在一個檔案被標記為有問題, 但在另一個檔案中相同的程式碼卻被核可)。

你應該如何重新建構這次審查?

- A) 拆成聚焦的多遍: 逐一分析每個檔案的局部問題, 然後執行一次獨立的整合遍來檢查跨檔案的資料流 **[CORRECT]**
- B) 要求開發者把大型 PR 拆成每次提交 3–4 個檔案
- C) 改用具有更大上下文視窗的更高階模型, 在一遍之內審查全部 14 個檔案
- D) 執行三次獨立的完整 PR 審查遍次, 只回報在至少兩次執行中都發現的問題

為何選 A: 聚焦的多遍直接針對根本原因——一次處理大量檔案時的注意力稀釋。逐檔分析確保一致的深度, 而獨立的整合遍能捕捉跨檔案的問題。B 把負擔轉嫁給開發者, 卻沒有改善系統。C 是一種誤解: 更大的上下文無法修正注意力的品質。D 透過要求在不一致的偵測之間取得共識, 壓制了真正的 bug。

練習測驗

涵蓋 8 個情境、共 100 道考題。格式與難度皆比照正式考試。

此外, 你也可以在類似考試的 HTML 檔案中練習這些考題: [練習測驗 \(繁體中文\)](#)

情境:多代理研究系統

問題 1(情境:多代理研究系統)

情境: 某文件分析代理發現兩個可信來源對於一項關鍵指標含有直接相互矛盾的統計數字:一份政府報告指出成長率為 40%,而一份產業分析則指出為 12%。兩個來源看起來都很可信,且此落差可能對研究結論造成實質影響。該文件分析代理應如何最有效地處理此情況?

哪種做法最有效?

- A) 套用可信度的經驗法則挑出最可能正確的數字,以該值完成分析,並加註腳說明此落差。
- B) 在分析輸出中同時納入兩個數字,但不標記它們相互衝突,讓綜整代理根據更廣的上下文決定要採用哪一個。
- C) 停止分析並立即升級至協調者,請它在繼續之前決定哪個來源更具權威性。
- D) 以兩個數字一併完成分析,明確標註此衝突並附上來源出處標註,在傳遞給綜整之前,讓協調者決定如何調和這些資料。 **[CORRECT]**

為何選 D: 此做法維持了職責分離:分析代理在不阻塞的情況下完成其核心工作,以清楚的出處標註保留兩個相互衝突的值,並正確地將調和工作交給擁有更廣上下文的協調者。

問題 2(情境:多代理研究系統)

情境: 網頁搜尋代理與文件分析代理已完成各自的任務,並將結果回傳給協調者。建立整合研究報告的下一步是什麼?

下一步哪個最適當?

- A) 每個代理將其結果直接傳送給報告撰寫代理,略過協調者。
- B) 文件分析代理向網頁搜尋代理索取搜尋結果,並在內部進行合併。
- C) 協調者將兩組結果傳遞給綜整代理,進行統一整合。 **[CORRECT]**
- D) 協調者將兩個代理的原始輸出串接起來,並將其作為最終結果回傳。

為何選 C: 在協調者—子代理架構中,協調者將兩組結果轉交給綜整代理進行集中整合,既保有控制權,也確保高品質的合併。

問題 3(情境:多代理研究系統)

情境: 某文件分析子代理在處理 PDF 檔案時經常失敗:有些檔案含有損毀的區段,會觸發剖析例外;有些則受密碼保護;有時剖析函式庫在處理大型檔案時會卡住。目前,任何例外都會立即終止子代理,並向協調者回傳一個錯誤,協調者必須決定要重試、略過,還是讓整個任務失敗。這導致協調者過度涉入例行的錯誤處理。哪項架構改進最有效?

哪項改進最有效?

- A) 建立一個專責的錯誤處理代理,透過共用佇列監控所有失敗並決定復原動作,直接向子代理發送重啟命令。
- B) 設定子代理一律回傳帶有成功狀態的部分結果,並將錯誤細節嵌入中繼資料;協調者將所有回應都視為成功。
- C) 讓協調者在將文件傳送給子代理之前先驗證所有文件,拒絕那些可能導致失敗的文件。
- D) 在子代理內針對暫時性失敗實作本機復原,僅將其無法解決的錯誤升級至協調者,並附上嘗試過的步驟與部分結果。 [CORRECT]

為何選 D: 在有能力解決錯誤的最低層級處理錯誤。本機復原可減輕協調者的工作負擔,同時仍能將真正無法復原的問題連同完整上下文與部分進度一併升級。

問題 4(情境:多代理研究系統)

情境: 在以「AI 對創意產業的影響」執行系統後,你觀察到每個子代理都成功完成:網頁搜尋代理找到相關文章,文件分析代理正確地將它們摘要,綜整代理也產出了連貫的文字。然而,最終報告只涵蓋視覺藝術,完全遺漏了音樂、文學與電影。在協調者的記錄檔中,你看到它將主題分解為三個子任務:「AI 於數位藝術」、「AI 於平面設計」與「AI 於攝影」。最可能的根本原因是什麼?

最可能的根本原因是什麼?

- A) 綜整代理缺少偵測涵蓋範圍缺口的指令。
- B) 文件分析代理因相關性標準過於嚴格,而濾除了非視覺類的來源。
- C) 協調者的任務分解過於狹隘,指派給子代理的工作未涵蓋所有相關領域。 [CORRECT]
- D) 網頁搜尋代理的查詢不足,應加以擴大以涵蓋更多領域。

為何選 C: 協調者只將一個廣泛的主題分解為視覺藝術相關的子任務,完全遺漏了音樂、文學與電影。由於子代理都正確執行了各自的指派,狹隘的分解便是顯而易見的根本原因。

問題 5(情境:多代理研究系統)

情境: 網頁搜尋子代理只回傳了 5 個請求來源類別中的 3 個(競爭對手網站與產業報告成功,但新聞檔案庫與社群動態逾時)。文件分析子代理成功處理了所有提供的文件。綜整子代理必須從品質不一的上游輸入產出摘要。哪種錯誤傳播策略最有效?

哪種錯誤傳播策略最有效?

- A) 僅使用成功的來源繼續綜整,並產出一份未提及哪些資料無法取得的輸出。
- B) 綜整子代理向協調者回傳一個錯誤,因資料不完整而觸發完整重試或任務失敗。
- C) 綜整子代理請協調者在開始綜整之前,以更長的逾時時間重試逾時的來源。
- D) 在綜整輸出中加入涵蓋範圍標註,指出哪些結論有充分佐證,以及哪些地方因來源無法取得而存在缺口。 [CORRECT]

為何選 D: 涵蓋範圍標註以透明的方式實作了優雅降級,既保留了已完成工作的價值,又能傳播不確定性,以利針對信心程度做出知情的決定。

問題 6(情境:多代理研究系統)

情境: 文件分析子代理遇到一個它無法剖析的損毀 PDF 檔案。在設計系統的錯誤處理時,處理此失敗最有效的方式是什麼?

哪種做法最有效?

- A) 向協調者代理回傳一個帶有上下文的錯誤,讓它決定如何繼續進行。 **[CORRECT]**
- B) 默默略過該損毀文件並繼續處理其餘檔案,以避免中斷工作流程。
- C) 在回報失敗之前,以指數退避自動重試剖析該文件三次。
- D) 拋出一個終止整個研究工作流程的例外。

為何選 A: 向協調者回傳一個帶有上下文的錯誤是最有效的做法,因為它讓協調者能做出知情的決定——略過該檔案、嘗試替代的剖析方法,或通知使用者——同時保持對該失敗的可見性。

問題 7(情境:多代理研究系統)

情境: 正式環境日誌顯示一個持續出現的模式:像「分析上傳的季度報告」這類請求,有 45% 的機率被路由到網頁搜尋代理,而不是文件分析代理。檢視工具定義後,你發現網頁搜尋代理有一個工具 `analyze_content`,描述為「analyzes content and extracts key information」,而文件分析代理有一個工具 `analyze_document`,描述為「analyzes documents and extracts key information」。你該如何修正這個路由錯誤的問題?

你該如何修正這個路由錯誤的問題?

- A) 加入一個前置路由分類器,在協調者決定委派之前,先偵測使用者指的是上傳的檔案還是網頁內容。
- B) 將網頁搜尋工具重新命名為 `extract_web_results`,並將其描述更新為「processes and returns information retrieved from web search and URLs」。 **[CORRECT]**
- C) 在協調者提示中加入少樣本範例,展示正確的路由:「使用者上傳季度報告 → 文件分析代理」以及「使用者詢問某個網頁 → 網頁搜尋代理」。
- D) 用使用範例擴充文件分析工具的描述,例如「用於上傳的 PDF、Word 文件和試算表」,而網頁搜尋工具則維持不變。

為何選 B: 將網頁搜尋工具重新命名為 `extract_web_results`,並更新其描述以明確指涉網頁搜尋與 URL,這直接消除了兩個工具名稱與描述之間的語意重疊,從而根除問題的根本原因。這使每個工具的用途都明確無歧義,讓協調者能可靠地區分文件分析與網頁搜尋。

問題 8(情境:多代理研究系統)

情境: 一位同事提議讓文件分析代理直接將其結果送給綜整代理,繞過協調者。將協調者保留為所有子代理之間通訊的中央樞紐,主要優勢是什麼?

將協調者保留為中央樞紐的主要優勢是什麼?

- A) 協調者可以觀察所有互動、統一處理錯誤,並決定每個子代理應該接收哪些資訊。 **[CORRECT]**
- B) 協調者將對子代理的多個請求批次化,減少 API 呼叫總數與整體延遲。

- C) 透過協調者路由能啟用直接代理間呼叫無法支援的自動重試邏輯。
- D) 子代理使用隔離的記憶體,直接通訊會需要複雜的序列化,而只有協調者能執行序列化。

為何選 A: 協調者模式提供對所有互動的集中可見性、整個系統一致的錯誤處理,以及對每個子代理接收哪些資訊的細緻控制——這些正是星形通訊拓撲的主要優勢。

問題 9(情境:多代理研究系統)

情境: 網頁搜尋子代理在研究一個複雜主題時逾時。你需要設計如何將這次失敗的相關資訊回傳給協調者。哪種錯誤傳播方式最能促成智慧型的復原?

哪種錯誤傳播方式最能促成智慧型的復原?

- A) 將結構化的錯誤上下文回傳給協調者,包含失敗類型、執行的查詢、任何部分結果,以及可能的替代方法。 **[CORRECT]**
- B) 在子代理內部攔截逾時,並回傳一個標記為成功的空結果集。
- C) 在子代理內部實作自動指數退避重試,只有在重試耗盡後才回傳一個一般性的「search unavailable」狀態。
- D) 將逾時例外直接傳播到最上層的處理常式,終止整個研究工作流程。

為何選 A: 回傳結構化的錯誤上下文——包含失敗類型、執行的查詢、部分結果以及替代方法——給予協調者做出智慧型復原決策所需的一切(例如,以修改後的查詢重試,或以部分結果繼續)。它為協調層級的明智決策保留了大量的上下文。

問題 10(情境:多代理研究系統)

情境: 在你的系統設計中,你讓文件分析代理可以存取一個通用工具 `fetch_url`,以便它能透過 URL 下載文件。正式環境日誌顯示,這個代理現在經常下載搜尋引擎結果頁面來執行臨時的網頁搜尋——這種行為本應路由到網頁搜尋代理——導致結果不一致。哪種修正最有效?

哪種修正最有效?

- A) 將 `fetch_url` 替換為一個 `load_document` 工具,該工具會驗證 URL 是否指向文件格式。 **[CORRECT]**
- B) 從文件分析代理移除 `fetch_url`,並將所有 URL 抓取透過協調者路由到網頁搜尋代理。
- C) 實作過濾機制,封鎖對已知搜尋引擎網域的 `fetch_url` 呼叫,同時允許其他 URL。
- D) 在文件分析代理的提示中加入指令,說明 `fetch_url` 只應用於下載文件 URL,而非搜尋。

為何選 A: 將通用工具替換為一個會驗證 URL 是否符合文件格式的文件專用工具,透過在介面層級約束能力來修正根本原因。這遵循最小權限原則,使不想要的搜尋行為變成不可能,而非僅僅是不鼓勵。

問題 11(情境:多代理研究系統)

情境: 在研究一個廣泛主題時,你觀察到網頁搜尋代理與文件分析代理調查了相同的子主題,導致它們的輸出有大量重複。token 用量幾乎翻倍,但研究的廣度或深度卻沒有相應地增加。處理這個問題最有效的方式是什麼?

處理這個問題最有效的方式是什麼?

- A) 讓兩個代理平行完成,然後由協調者在將結果傳給綜整代理之前,先對重疊的結果去重。
- B) 協調者在委派之前明確劃分研究空間,為每個代理分配不同的子主題或來源類型。 **[CORRECT]**
- C) 實作一個共享狀態機制,讓代理記錄其當前的關注領域,使其他代理能在執行期間動態地避免重複。
- D) 改用循序執行,讓文件分析只在網頁搜尋完成後才執行,並以網頁搜尋結果作為上下文以避免重複。

為何選 B: 讓協調者在委派之前明確劃分研究空間最為有效,因為它在任何工作開始之前就處理了根本原因——任務邊界不明確。它在防止重複工作與浪費 token 的同時,保留了平行性。

問題 12(情境:多代理研究系統)

情境: 在研究期間,網頁搜尋子代理查詢了三個來源類別,結果各不相同:學術資料庫回傳 15 篇相關論文,產業報告回傳「0 results」,而專利資料庫回傳「Connection timeout」。在設計向協調者的錯誤傳播時,哪種方式能促成最佳的復原決策?

哪種方式能促成最佳的復原決策?

- A) 將結果彙整成單一的成功百分比指標(例如「67% source coverage」),並提供可隨需取用的詳細日誌。
- B) 將「timeout」和「0 results」都回報為需要協調者介入的失敗。
- C) 在內部重試暫時性失敗,只回報持續性的錯誤。
- D) 區分需要重試決策的存取失敗(timeout)與代表查詢成功的有效空結果(「0 results」)。 **[CORRECT]**

為何選 D: 逾時(存取失敗)與「0 results」(有效的空結果)在語意上是不同的結果,需要不同的回應。區分它們能讓協調者重試專利資料庫,同時接受產業報告的「0 results」為有效且有資訊價值的發現。

問題 13(情境:多代理研究系統)

情境: 正式環境監控顯示綜整品質不一致。當彙整後的結果約為 75K tokens 時,綜整代理能可靠地引用前 15K tokens(網頁搜尋的標題/摘錄)和最後 10K tokens(文件分析的結論)中的資訊,但經常遺漏中間 50K tokens 裡的關鍵發現——即使這些發現直接回答了研究問題。你該如何重新組織彙整後的輸入?

你該如何重新組織彙整後的輸入?

- A) 在彙整之前,將所有子代理的輸出摘要到 20K tokens 以下,以使內容保持在模型可靠的處理範圍內。
- B) 將子代理結果以增量方式串流給綜整代理,先將網頁搜尋結果處理到完成,再加入文件分析結果。
- C) 在彙整後輸入的開頭放置一份關鍵發現摘要,並以明確的章節標題組織詳細結果以利瀏覽。 **[CORRECT]**
- D) 實作輪替機制,在不同研究任務間交替讓哪一個子代理的結果出現在最前面,以確保兩個來源長期下來都能獲得同等的頂端位置。

為何選 C: 在開頭放置關鍵發現摘要能善用初始效應,使關鍵資訊位於處理最可靠的位置。在通篇加入明確的章節標題有助於模型瀏覽並關注輸入中段的內容,直接緩解「迷失在中間」的現象。

問題 14(情境:多代理研究系統)

情境: 在測試中,web-search 代理的輸出(85K tokens,包含頁面內容)與文件分析代理的輸出(70K tokens,包含思考鏈)合計共 155K tokens,但 綜整代理在輸入低於 50K tokens 時表現最佳。哪個解決方案最有效?

哪個解決方案最有效?

- A) 修改上游代理,使其回傳結構化資料(關鍵事實、引述、相關性分數),而非冗長的內容與推理過程。
[CORRECT]
- B) 新增一個中介摘要代理,在將結果傳給 綜整 之前先加以精簡。
- C) 讓 綜整代理以連續批次的方式處理結果,並在各次呼叫之間維持狀態。
- D) 將結果儲存在向量資料庫中,並給 綜整代理搜尋工具,使其能在工作過程中查詢。

為何選 A: 修改上游代理回傳結構化資料,能在源頭減少 token 量並保留必要資訊,從而解決根本原因。它避免傳遞龐大的頁面內容與推理軌跡,這些內容會膨脹 tokens 卻無助於 綜整 步驟。

問題 15(情境:多代理研究系統)

情境: 在測試中,你觀察到 綜整代理在合併結果時經常需要驗證特定主張。目前當需要驗證時,綜整代理會將控制權交還給協調者,協調者再呼叫 web-search 代理,然後帶著結果重新呼叫 綜整。這會使每個任務多出 2-3 個額外迴圈,並使延遲增加 40%。你的評估顯示,這些驗證中有 85% 是簡單的事實查核(日期、姓名、統計數字),15% 則需要更深入的研究。哪種做法能最有效地降低開銷,同時保有系統可靠性?

哪種做法最有效?

- A) 讓 綜整代理存取所有 web-search 工具,使其能直接處理任何驗證需求,而無需經過協調者迴圈。
- B) 讓 綜整代理累積所有驗證需求,並在最後以批次形式回傳給協調者,再由協調者一次將它們全部送給 web-search 代理。
- C) 讓 web-search 代理在初始研究期間,主動快取每個來源周邊的額外上下文,以預先因應 綜整 可能需要的驗證。
- D) 給 綜整代理一個範圍受限的 `verify_fact` 工具來進行簡單查核,同時將複雜的驗證透過協調者轉送給 web-search 代理。 [CORRECT]

為何選 D: 範圍受限的事實驗證工具讓 綜整代理能直接處理 85% 的簡單查核,消除了大多數迴圈,同時為那 15% 的複雜驗證保留協調者委派路徑。這套做法在大幅降低延遲的同時,落實了最小權限原則。

情境:用於持續整合的 Claude Code

問題 16(情境:用於持續整合的 Claude Code)

情境: 你的 CI 管線執行 Claude Code CLI(以 `--print` 模式),並使用 `CLAUDE.md` 為程式碼審查提供專案上下文,而開發者普遍認為這些審查很有實質內容。然而,他們回報將審查結果整合進工作流程很困難——Claude 輸出的是敘述性段落,必須手動複製到 PR 留言中。團隊希望能自動將每個發現以獨立的行內 PR 留言形式,張貼在程式碼中相關的位置,這需要包含檔案路徑、行號、嚴重程度與建議修正的結構化資料。哪種做法最有效?

哪種做法最有效?

- A) 在 `CLAUDE.md` 中新增一個「審查輸出格式」章節,並附上結構化發現的範例,讓 Claude 從專案上下文中學習預期的格式。
- B) 使用 CLI 旗標 `--output-format json` 與 `--json-schema` 來強制產生結構化發現,然後解析輸出,透過 GitHub API 張貼行內留言。 **[CORRECT]**
- C) 在審查提示中加入明確的格式化指令,要求每個發現遵循一個可解析的範本,例如 `[FILE:path] [LINE:n] [SEVERITY:level] ...`。
- D) 保留敘述性審查格式,但新增一個摘要步驟,使用 Claude 產生發現的結構化 JSON 摘要。

為何選 B: 使用 `--output-format json` 搭配 `--json-schema`,能在 CLI 層級強制結構化輸出,保證產生格式良好且具備所需欄位(檔案路徑、行號、嚴重程度、建議修正)的 JSON,可被可靠地解析並透過 GitHub API 張貼為行內 PR 留言。它善用了專為結構化輸出而設計的內建 CLI 功能。

問題 17(情境:用於持續整合的 Claude Code)

情境: 你的團隊使用 Claude Code 來產生程式碼建議,但你注意到一種模式:不明顯的問題——會破壞邊界案例的效能最佳化、會意外改變行為的清理動作——只有在另一位團隊成員審查 PR 時才會被發現。Claude 在產生過程中的推理顯示,它確實考慮過這些情況,卻得出自己的做法正確的結論。哪種做法能直接解決這種自我檢查侷限的根本原因?

哪種做法能直接解決根本原因?

- A) 執行第二個獨立的 Claude Code 實例來審查變更,且不讓它存取產生器的推理過程。 **[CORRECT]**
- B) 為產生階段啟用擴展思考模式,以便在產出建議前進行更周詳的審議。
- C) 在產生提示中加入明確的自我審查指令,要求 Claude 在定稿輸出前批評自己的建議。
- D) 在提示上下文中納入完整的測試檔案與文件,讓 Claude 在產生時更能理解預期行為。

為何選 A: 第二個獨立的 Claude Code 實例在不存取產生器推理過程的情況下,透過避免確認偏誤,直接解決了根本原因。這種「新視角」的觀點反映了人類同儕審查的精神,亦即由另一位審查者抓出作者已為其自圓其說的問題。

問題 18(情境:用於持續整合的 Claude Code)

情境: 你的程式碼審查元件是迭代式的:Claude 分析變更後的檔案,接著可能透過工具呼叫請求相關檔案(匯入、基底類別、測試),以在提供最終回饋前理解上下文。你的應用程式定義了一個工具,讓 Claude 能請求檔

案內容;Claude 呼叫該工具、取得結果,然後繼續分析。你正在評估以批次處理來降低 API 成本。在考慮為此工作流程採用批次處理時,主要的技術限制是什麼?

主要的技術限制是什麼?

- A) 批次處理不包含關聯 ID,無法將輸出對應回輸入請求。
- B) 非同步模型無法在請求進行中執行工具並回傳結果,供 Claude 繼續分析。 [CORRECT]
- C) Batch API 不支援在請求參數中提供工具定義。
- D) 批次處理長達 24 小時的延遲對 pull request 回饋而言太慢,儘管該工作流程在其他方面仍可運作。

為何選 B:「射後不理」式的非同步 Batch API 模型,沒有任何機制能在請求進行中攔截工具呼叫、執行工具,並回傳結果供 Claude 繼續分析。這與需要在單一邏輯互動中進行多輪工具請求/回應的迭代式工具呼叫工作流程根本上不相容。

問題 19(情境:用於持續整合的 Claude Code)

情境: 你的 CI/CD 系統執行三種以 Claude 為基礎的分析:(1) 在每個 PR 上進行快速風格檢查,並在完成前阻擋合併;(2) 對整個程式碼庫進行每週的全面安全稽核;(3) 對近期變更的模組進行每晚的測試案例產生。Message Batches API 可節省 50% 成本,但處理可能長達 24 小時。你希望在維持可接受的開發者體驗的同時最佳化 API 成本。哪個組合正確地將每項任務對應到一種 API 做法?

哪個組合正確?

- A) 三項任務全部使用 Message Batches API 以最大化 50% 的節省,並設定管線輪詢批次完成狀態。
- B) PR 風格檢查使用同步呼叫;每週安全稽核與每晚測試產生使用 Message Batches API。 [CORRECT]
- C) 三項任務全部使用同步呼叫以獲得一致的回應時間,並依靠提示快取來降低各工作負載的成本。
- D) PR 風格檢查與每晚測試產生使用同步呼叫;只有每週安全稽核使用 Message Batches API。

為何選 B: PR 風格檢查會阻擋開發者,需要透過同步呼叫立即回應;而每週安全稽核與每晚測試產生是排程任務,期限有彈性,能容忍長達 24 小時的批次視窗——兩者皆可取得 50% 的節省。

問題 20(情境:用於持續整合的 Claude Code)

情境: 你的自動化審查找出了真正的問題,但開發者回報這些回饋不具可行性。發現中包含像「複雜的工單路由邏輯」或「潛在的空指標」這類語句,卻沒有明確指出究竟該改什麼。當你加入詳細指令,例如「務必納入具體的修正建議」時,模型仍會產生不一致的輸出——時而詳細,時而含糊。哪種提示技巧最能可靠地產生一致且可行動的回饋?

哪種提示技巧最可靠?

- A) 進一步精修指令,對回饋格式的各部分(位置、問題、嚴重程度、建議修正)提出更明確的要求。
- B) 擴大上下文視窗以納入更多周邊程式碼庫,讓模型有足夠資訊提出具體修正。
- C) 實作兩遍式做法,由一個提示找出問題、第二個提示產生修正,讓兩者各司其職。
- D) 加入 3–4 個少樣本範例,展示確切要求的格式:找出的問題、程式碼中的位置、具體的修正建議。

[CORRECT]

為何選 D: 當僅靠指令會產生不一致結果時,少樣本範例是達成一致輸出格式最有效的技巧。提供 3–4 個展示確切預期結構(問題、位置、具體修正)的範例,能給模型一個具體的模式可循,這比抽象的指令更可靠。

問題 21(情境:用於持續整合的 Claude Code)

情境: 你的 CI 管線包含兩種以 Claude 為基礎的程式碼審查模式:一種是 pre-merge-commit hook,會在完成前阻擋 PR 合併;另一種是「深度分析」,於夜間執行、輪詢批次完成狀態,並將詳細建議張貼到 PR。你想透過 Message Batches API 來降低 API 成本,它提供 50% 的節省,但需要輪詢且最多可能耗時 24 小時。哪一種模式應該使用批次處理?

哪一種模式應該使用批次處理?

- A) 只有 pre-merge-commit hook。
- B) 只有深度分析。 **[CORRECT]**
- C) 兩種模式皆是。
- D) 兩種模式皆否。

為何選 B: 深度分析是批次處理的理想對象,因為它本來就在夜間執行、能容忍延遲,並在發佈結果前採用輪詢模型——這與 Message Batches API 那種非同步、以輪詢為基礎的架構相符,同時還能取得 50% 的節省。

問題 22(情境:用於持續整合的 Claude Code)

情境: 你的自動化審查會分析註解與 docstring。目前的提示指示 Claude 「檢查註解是否準確且為最新狀態」。審查結果經常標記可接受的模式(TODO 標記、簡單描述),卻漏掉那些描述程式碼已不再實作之行為的註解。什麼變更能解決這種不一致分析的根本原因?

什麼變更能解決根本原因?

- A) 納入 `git blame` 資料,讓 Claude 能找出早於近期程式碼變更的註解。
- B) 加入具誤導性註解的少樣本範例,協助模型在程式碼庫中辨識類似的模式。
- C) 在分析前過濾掉 TODO、FIXME 與描述性註解模式,以減少雜訊。
- D) 指定明確的判定標準:只有當註解所宣稱的行為與程式碼實際行為矛盾時才標記。 **[CORRECT]**

為何選 D: 明確的判定標準——只有當註解所宣稱的行為與程式碼實際行為矛盾時才標記——以對「何謂問題」的精確定義取代模糊的指示,直接解決了根本原因。這能減少對可接受模式的誤報,以及對真正具誤導性註解的遺漏。

問題 23(情境:用於持續整合的 Claude Code)

情境: 你的自動化程式碼審查系統顯示出不一致的嚴重性評級——類似的問題(如 null pointer 風險)在某些 PR 被評為「critical」,在其他 PR 卻只評為「medium」。開發者問卷顯示信任度日漸下滑——許多人開始未讀就略過審查結果,因為「有一半是錯的」。高誤報的類別侵蝕了對準確類別的信任。哪種做法最能在改善系統的同時恢復開發者的信任?

哪種做法最能恢復開發者的信任？

- A) 暫時停用高誤報的類別(風格、命名、文件),只保留高精確度的類別,同時改善提示。 **[CORRECT]**
- B) 保持所有類別啟用,但在每項審查結果旁顯示信心分數,讓開發者自行決定要調查哪些。
- C) 保持所有類別啟用,並在接下來幾週加入少樣本範例,以改善每個類別的準確度。
- D) 對所有類別套用一致的嚴格度調降,以降低整體的誤報率。

為何選 A: 暫時停用高誤報的類別能立即阻止信任的侵蝕,移除那些導致開發者一概略過的雜訊審查結果,同時保留來自安全性與正確性等高精確度類別的價值。它也創造出空間,讓你在重新啟用前能先改善有問題類別的提示。

問題 24(情境:用於持續整合的 Claude Code)

情境: 你的自動化審查會為每個 PR 產生測試案例建議。在審查一個新增課程完成度追蹤的 PR 時,Claude 建議了 10 個測試案例,但開發者回饋顯示其中有 6 個重複了現有測試套件已涵蓋的情境。什麼變更最能有效減少重複的建議？

什麼變更最有效？

- A) 將現有的測試檔案納入上下文,讓 Claude 能判斷哪些情境已被涵蓋。 **[CORRECT]**
- B) 將請求的建議數量從 10 個減少到 5 個,假設 Claude 會優先處理最有價值的案例。
- C) 加入指示,引導 Claude 專注於邊界案例與錯誤情況,而非成功路徑。
- D) 實作後處理,透過關鍵字重疊過濾掉描述與現有測試名稱相符的建議。

為何選 A: 納入現有的測試檔案能修正重複的根本原因:唯有當 Claude 知道已存在哪些測試時,才能避免建議已被涵蓋的情境。這給了 Claude 提出真正全新、有價值測試所需的資訊。

問題 25(情境:用於持續整合的 Claude Code)

情境: 在一次初步自動化審查找出 12 項審查結果後,開發者推送了新的 commit 來處理這些問題。重新執行審查產生了 8 項審查結果,但開發者回報其中有 5 項重複了先前針對已在新 commit 中修正之程式碼的留言。在維持徹底性的同時,消除這種冗餘回饋最有效的方法是什麼？

消除冗餘回饋最有效的方法是什麼？

- A) 只在 PR 建立時與最終的 pre-merge 狀態執行審查,跳過中間的 commit。
- B) 加入後處理過濾,在張貼留言前,依檔案路徑與問題描述移除與先前相符的審查結果。
- C) 將審查範圍限制在最近一次推送所變更的檔案,排除較早 commit 的檔案。
- D) 將先前的審查結果納入上下文,並指示 Claude 只回報新的或仍未解決的問題。 **[CORRECT]**

為何選 D: 將先前的審查結果納入上下文,能讓 Claude 區分新問題與那些已在近期 commit 中處理過的問題。這在維持審查徹底性的同時,利用 Claude 的推理能力來避免對已修正程式碼提出冗餘的回饋。

問題 26(情境:用於持續整合的 Claude Code)

情境: 你的管線指令稿執行 `claude "Analyze this pull request for security issues"`,但作業卻無限期地卡住。日誌顯示 Claude Code 正在等待互動式輸入。在自動化管線中執行 Claude Code 的正確做法是什麼?

正確的做法是什麼?

- A) 加上 `--batch` 旗標: `claude --batch "Analyze this pull request for security issues"`。
- B) 加上 `-p` 旗標: `claude -p "Analyze this pull request for security issues"`。 **[CORRECT]**
- C) 將 stdin 從 `/dev/null` 重新導向: `claude "Analyze this pull request for security issues" < /dev/null`。
- D) 在執行指令前設定環境變數 `CLAUDE_HEADLESS=true`。

為何選 B: `-p` (或 `--print`) 旗標是以非互動方式執行 Claude Code 的官方記載做法。它會處理提示、將結果印至 stdout,並在不等待使用者輸入的情況下結束——非常適合 CI/CD 管線。

問題 27(情境:用於持續整合的 Claude Code)

情境: 一個 pull request 變更了庫存追蹤模組中的 14 個檔案。將所有檔案一起分析的單遍審查產生了不一致的結果:對某些檔案有詳細回饋,對其他檔案卻只有膚淺的留言,漏掉了明顯的 bug,還出現矛盾的回饋(某個模式在一個檔案被標記,但同一個 PR 中另一個檔案的相同程式碼卻被核可)。你應該如何重新建構這個審查?

你應該如何重新建構這個審查?

- A) 執行三次獨立的全 PR 審查遍次,只標記在三次執行中至少出現兩次的問題。
- B) 拆分成專注的遍次:逐一審查每個檔案的局部問題,然後執行另一個以整合為導向的遍次,檢查跨檔案的資料流。 **[CORRECT]**
- C) 要求開發者在執行自動化審查前,先將大型 PR 拆分成 3~4 個檔案的較小提交。
- D) 改用具有更大上下文視窗的較大模型,讓它能在單一遍次中對全部 14 個檔案投入足夠的注意力。

為何選 B: 專注的逐檔案遍次透過確保一致的深度與可靠的局部問題偵測,解決了根本原因——注意力稀釋。接著,另一個以整合為導向的遍次則涵蓋跨檔案的考量,例如相依性與資料流的互動。

問題 28(情境:用於持續整合的 Claude Code)

情境: 你的自動化程式碼審查平均每個 pull request 產出 15 項發現,而開發人員回報有 40% 的誤報率。瓶頸在於調查時間:開發人員必須點進每一項發現,閱讀 Claude 的理由說明,才能決定要修正還是駁回。你的 CLAUDE.md 已經包含可接受模式的完整規則,而且利害關係人否決了任何在開發人員看到發現之前就先過濾的做法。哪一項變更最能解決調查時間的問題?

哪一項變更最能解決調查時間的問題?

- A) 要求 Claude 直接在每一項發現中附上其理由說明與信心估計值。 ****[CORRECT]****
- B) 加入一個後處理器,分析發現的模式,並自動抑制那些符合歷史誤報特徵的發現。
- C) 將發現分類為「阻擋性問題」與「建議」,並依層級設定不同的審查要求。

- D) 設定 Claude 只顯示高信心的發現,在開發人員看到之前先過濾掉不確定的標記。

為何選 A: 在每一項發現中直接附上理由說明與信心,可讓開發人員快速分流而不必逐項點開,進而減少調查時間。它滿足「不過濾」的限制條件,因為所有發現都仍然可見,同時加速了開發人員的決策。

問題 29(情境:用於持續整合的 Claude Code)

情境: 對你的自動化程式碼審查所做的分析顯示,不同發現類別之間的誤報率差異很大:安全性/正確性發現有 8% 誤報,效能發現 18%,風格/命名發現 52%,而文件發現 48%。開發人員調查顯示不信任感日益升高——許多人開始連看都不看就駁回發現,因為「有一半都是錯的」。高誤報的類別侵蝕了人們對準確類別的信任。哪一種做法最能恢復開發人員的信任,同時改善整個系統?

哪一種做法最能恢復開發人員的信任?

- A) 暫時停用高誤報類別(風格、命名、文件),只保留高精準度的類別,同時改善提示。 **[CORRECT]**
- B) 保持所有類別啟用,但在每一項發現旁顯示信心分數,讓開發人員自行決定要調查哪些。
- C) 保持所有類別啟用,並在接下來幾週內加入少樣本範例,以提升各類別的準確度。
- D) 對所有類別套用一致的嚴格度調降,使整體誤報率下降。

為何選 A: 暫時停用高誤報類別,能立即透過移除那些導致開發人員一律駁回的雜訊發現,來阻止信任的侵蝕,同時保留安全性與正確性等高精準度類別所帶來的價值。它也為在重新啟用之前改善問題類別的提示創造了空間。

問題 30(情境:用於持續整合的 Claude Code)

情境: 你的團隊想要降低自動化分析的 API 成本。目前,同步的 Claude 呼叫支援兩種工作流程:(1) 一個阻擋式的合併前檢查,必須在開發人員能夠合併之前完成;以及 (2) 一份在夜間產生、供隔天早上審閱的技術債報告。你的經理提議將兩者都改用 Message Batches API 以節省 50%。你應該如何評估這項提議?

你應該如何評估這項提議?

- A) 將兩者都改用批次處理,並在批次耗時過久時回退到同步呼叫。
- B) 將兩種工作流程都改用批次處理,並以狀態輪詢來確認完成。
- C) 只對技術債報告使用批次處理;合併前檢查則保留同步呼叫。 **[CORRECT]**
- D) 兩種工作流程都保留同步呼叫,以避免批次結果排序的問題。

為何選 C: Message Batches API 的處理最長可能需要 24 小時,且沒有延遲 SLA,這對夜間的技術債報告是可接受的,但對開發人員必須等待的阻擋式合併前檢查則無法接受。這做法依據延遲需求,將每種工作流程對應到正確的 API。

情境:使用 Claude Code 生成程式碼

問題 31(情境:使用 Claude Code 生成程式碼)

情境: 你要求 Claude Code 實作一個函式,將 API 回應轉換成內部的正規化格式。經過兩次迭代後,輸出結構仍然不符合預期——有些欄位的巢狀方式不同,而時間戳記的格式也不正確。你以散文方式描述了需求,但 Claude 每次的解讀都不一樣。

對於下一次迭代,哪一種做法最有效?

- A) 撰寫一份描述預期輸出結構的 JSON 結構描述,並在每次迭代後拿 Claude 的輸出來對它驗證。
- B) 提供 2 至 3 組具體的輸入-輸出範例,展示代表性 API 回應的預期轉換結果。 **[CORRECT]**
- C) 以更高的技術精準度重寫需求,指定確切的欄位對應、巢狀規則與時間戳記格式字串。
- D) 請 Claude 說明它目前對需求的理解,以找出解讀分歧之處。

為何選 B: 具體的輸入-輸出範例,透過向 Claude 展示確切的預期轉換結果,消除了散文描述中固有的不明確性。這直接針對了根本原因——對文字需求的誤解——提供了關於欄位巢狀與時間戳記格式的明確模式。

問題 32(情境:使用 Claude Code 生成程式碼)

情境: 你需要新增 Slack 作為新的通知管道。現有的程式碼庫對於電子郵件、簡訊與推播管道,已有清楚且確立的模式。然而,Slack 的 API 提供了根本上不同的整合方式——incoming webhooks(簡單、單向)、bot tokens(支援送達確認與程式化控制),或 Slack Apps(雙向事件,需要工作區核准)。你的任務只說「新增 Slack 支援」,並未指定整合方式,也未要求送達追蹤之類的進階功能。

你應該如何著手這項任務?

- A) 以直接執行模式開始,使用 incoming webhooks 來比照現有的單向通知模式。
- B) 切換到規劃模式,探索各種整合選項與架構上的影響,然後在實作前提出建議。 **[CORRECT]**
- C) 以直接執行模式開始,使用現有模式搭建一個 Slack 管道類別的骨架,將整合方式的決策延後。
- D) 以直接執行模式開始,採用 bot-token 的做法,以確保能夠進行送達確認。

為何選 B: Slack 整合有多種有效的做法,且各自的架構影響差異甚大,而需求又不明確。規劃模式讓你能夠評估 webhooks、bot tokens 與 Slack Apps 之間的權衡取捨,並在實作前對某個做法取得共識。

問題 33(情境:使用 Claude Code 生成程式碼)

情境: 你的 CLAUDE.md 檔案已增長到 400 多行,包含程式設計標準、測試慣例、一份詳細的 PR 審查檢查清單、部署指示,以及資料庫遷移程序。你希望 Claude 永遠遵守程式設計標準與測試慣例,但只在執行那些任務時才套用 PR 審查、部署與遷移的指引。

哪一種重新組織的做法最有效?

- A) 將所有指引移入依工作流程類型組織的獨立 Skills 檔案,在 CLAUDE.md 中只留下簡短的專案說明。
- B) 全部保留在 CLAUDE.md 中,但使用 `@import` 語法依類別組織成各自維護的檔案。
- C) 將 CLAUDE.md 拆分成 `.claude/rules/` 底下的檔案,並搭配路徑綁定的 glob 模式,讓每條規則只在相關的檔案類型才載入。

- D) 將通用標準保留在 CLAUDE.md 中,並為工作流程專屬的指引(PR 審查、部署、遷移)建立帶有觸發關鍵字的 Skills。 **[CORRECT]**

為何選 D: CLAUDE.md 的內容會在每個工作階段載入,確保程式設計標準與測試慣例永遠適用;而 Skills 則是在 Claude 偵測到觸發關鍵字時才按需叫用——對於 PR 審查、部署與遷移之類的工作流程專屬指引而言,這是理想的做法。

問題 34(情境:使用 Claude Code 生成程式碼)

情境: 你被指派將團隊的單體式應用程式重新組織成微服務。這會影響數十個檔案的變更,並需要對服務邊界與模組相依性做出決策。

你應該選擇哪一種做法?

- A) 切換到規劃模式,探索程式碼庫、了解相依性,並在進行變更之前設計實作的做法。 **[CORRECT]**
- B) 以直接執行模式開始,只在實作期間遇到非預期的複雜度時才切換到規劃。
- C) 以直接執行模式開始並做出漸進式變更,讓實作過程自然揭示出服務邊界。
- D) 使用直接執行,並搭配指定每個服務結構的詳細前置指示。

為何選 A: 對於像拆分單體應用這類複雜的架構重組,規劃模式是正確的策略:它讓你能在投入跨許多檔案、可能代價高昂的變更之前,安全地探索並對邊界做出明智的決策。

問題 35(情境:使用 Claude Code 生成程式碼)

情境: 你的團隊建立了一個 `/analyze-codebase` 技能,可執行深度程式碼分析——相依性掃描、測試涵蓋率計數,以及程式碼品質指標。執行該命令後,團隊成員回報 Claude 在工作階段中變得較不靈敏,並且遺失了原始任務的上下文。

在保留完整分析能力的前提下,你要如何最有效地修正這個問題?

- A) 在技能 frontmatter 中加入 `context: fork`,讓分析在隔離的子代理上下文中執行。 **[CORRECT]**
- B) 在 frontmatter 中加入 `model: haiku`,使用更快、更便宜的模型進行分析。
- C) 將技能拆成三個較小的技能,各自產生較少的輸出。
- D) 在技能中加入指令,在顯示結果之前先將所有結果壓縮成簡短摘要。

為何選 A: `context: fork` 讓分析在隔離的子代理上下文中執行,因此大量輸出不會污染主工作階段的上下文視窗,Claude 也不會遺失對原始任務的掌握。它在保留完整分析能力的同時,維持了主工作階段的靈敏度。

問題 36(情境:使用 Claude Code 生成程式碼)

情境: 你的團隊使用位於 `.claude/skills/commit/SKILL.md` 的 `/commit` 技能。某位開發者想為自己的個人工作流程進行客製化(不同的提交訊息格式、額外的檢查),且不影響其他隊友。

你會建議什麼做法?

- A) 在 `~/ .claude/skills/` 下以不同名稱建立個人版本,例如 `/my-commit`。
- B) 在專案技能 frontmatter 中加入以使用者名稱為條件的判斷邏輯。
- C) 在 `~/ .claude/skills/commit/SKILL.md` 以相同名稱建立個人版本。 **[CORRECT]**
- D) 在個人技能 frontmatter 中設定 `override: true`,使其優先於專案版本。

為何選 C: 同名情況下,個人技能優先於專案技能。位於 `~/ .claude/skills/commit/SKILL.md` 的個人技能會覆寫團隊的專案技能,讓開發者能客製化自己的工作流程,同時為個人使用保留熟悉的 `/commit` 命令名稱。這個做法優於選項 A,因為它保留了原本的命令名稱,在不影響隊友的情況下改善了開發者的工作流程。

問題 37(情境:使用 Claude Code 生成程式碼)

情境: 你的團隊已使用 Claude Code 數個月。最近,有三位開發者回報 Claude 會遵循「一律包含完整的錯誤處理」這項指引,但一位剛加入的第四位開發者表示 Claude 並未遵循。四人都在同一個儲存庫中工作,且程式碼皆為最新。

最可能的原因與修正方式是什麼?

- A) 該指引存在於原本那幾位開發者的使用者層級 `~/ .claude/CLAUDE.md` 檔案中,而非專案的 `.claude/CLAUDE.md`。將該指令移至專案層級的檔案,讓所有團隊成員都能收到。 **[CORRECT]**
- B) 新開發者的 `~/ .claude/CLAUDE.md` 包含相衝突的指令,覆寫了專案設定;他們應刪除衝突的段落。
- C) Claude Code 會隨時間學習個別使用者的偏好;新開發者必須重複該需求,直到 Claude「記住」為止。
- D) Claude Code 在首次讀取後會快取 CLAUDE.md;原本的開發者使用的是快取版本。每個人都應清除 Claude Code 的快取。

為何選 A: 如果該指引只被加入原本那幾位開發者的使用者層級設定,而未加入專案層級的 `.claude/CLAUDE.md`,新團隊成員就不會收到。將它移至專案層級的設定,可確保所有現有與未來的團隊成員自動取得該指引。

問題 38(情境:使用 Claude Code 生成程式碼)

情境: 你發現,在生成新的 API 端點時,將 2–3 個完整的端點實作範例作為上下文納入,可顯著提升一致性。然而,這個上下文只有在建立新端點時才有用——在除錯、審查程式碼或於 API 目錄中進行其他工作時則無用。

哪一種設定方式最為有效?

- A) 將端點範例與模式文件加入專案 CLAUDE.md,使其隨時可用。
- B) 在每次生成請求中,以複製程式碼到提示的方式手動引用端點範例。
- C) 在 `.claude/rules/api/` 中設定路徑專屬規則,納入端點範例,並在 API 目錄中工作時啟用。
- D) 建立一個引用端點範例並包含模式遵循指令的技能,透過斜線命令按需呼叫。 **[CORRECT]**

為何選 D: 按需呼叫的技能只會在生成新端點時載入範例上下文,而不會在除錯或審查等不相關的任務期間載入。這讓主上下文保持乾淨,同時在需要時保留高品質的生成能力。

問題 39(情境:使用 Claude Code 生成程式碼)

情境: 你的團隊建立了一個 `/migration` 技能,用來生成資料庫遷移檔案。它透過 `$ARGUMENTS` 取得遷移名稱。在正式環境中你觀察到三個問題:(1) 開發者經常在未提供引數的情況下執行該技能,導致檔案命名不佳;(2) 該技能有時會使用來自不相關的先前對話中的資料庫結構描述細節;(3) 某位開發者在該技能擁有廣泛工具存取權時,意外執行了破壞性的測試清理。

哪一種設定方式能修正這三個問題?

- A) 使用位置參數 `$1` 與 `$2` 取代 `$ARGUMENTS` 以強制特定輸入,透過 `@` 語法明確引用結構描述檔案以控制上下文,並在 frontmatter 描述中加入關於破壞性操作的警告。
- B) 在 frontmatter 中加入 `argument-hint` 以要求必填參數,使用 `context: fork` 來隔離執行,並將 `allowed-tools` 限制為檔案寫入操作。 ****[CORRECT]****
- C) 拆成 `/migration-create` 與 `/migration-apply` 兩個技能,加入驗證指令以在缺少遷移名稱時加以索取,並為各自使用不同的 `allowed-tools` 範圍。
- D) 在技能的 SKILL.md 中加入驗證指令以確保 `$ARGUMENTS` 是有效的名稱,加入提示以忽略先前的對話上下文,並列出應避免的禁止操作。

為何選 B: 這運用三項各自獨立的設定功能來分別解決每個問題: `argument-hint` 改善引數輸入並減少缺少引數的情況, `context: fork` 防止來自先前對話的上下文外洩,而 `allowed-tools` 將技能限制在安全的檔案寫入操作,從而防止破壞性動作。

問題 40(情境:使用 Claude Code 生成程式碼)

情境: 你的程式碼庫包含採用不同程式碼慣例的區域:React 元件使用搭配 hooks 的函式式風格,API 處理常式使用 `async/await` 搭配特定的錯誤處理,而資料庫模型則遵循 `repository` 模式。測試檔案分散在程式碼庫各處,緊鄰其受測程式碼(例如 `Button.test.tsx` 位於 `Button.tsx` 旁邊),而你希望所有測試無論位置為何都遵循相同的慣例。

要確保 Claude 在生成程式碼時自動套用正確的慣例,最受支援的方式是什麼?

- A) 將所有慣例放入根目錄的 CLAUDE.md,各區域各用一個標題,並依賴 Claude 自行推斷適用哪個段落。
- B) 在 `.claude/skills/` 中為每種程式碼類型建立技能,將慣例嵌入各個 SKILL.md。
- C) 在每個子目錄中放置一個獨立的 CLAUDE.md 檔案,內含該區域的慣例。
- D) 在 `.claude/rules/` 下建立規則檔案,以 YAML frontmatter 指定 glob 模式,依檔案路徑有條件地套用慣例。 ****[CORRECT]****

為何選 D: 帶有 YAML frontmatter 與 glob 模式(例如 `**/*.test.tsx`、`src/api/**/*.ts`)的 `.claude/rules/` 檔案,能無論目錄結構為何都實現確定性、以路徑為基礎的慣例套用。對於像分散的測試檔案這類橫切模式,這是最受支援的做法。

問題 41(情境:使用 Claude Code 生成程式碼)

情境: 你想建立一個自訂斜線命令 `/review`,用來執行你團隊的標準程式碼審查檢查清單。它應在每位開發者複製或更新儲存庫時都可使用。

你應該在哪裡建立這個命令檔案？

- A) 在每位開發者家目錄中的 `~/ .claude/commands/` 。
- B) 在專案儲存庫中的 `.claude/commands/` 下。 ****[CORRECT]****
- C) 在 `.claude/config.json` 中作為一個命令陣列。
- D) 在根目錄的專案 CLAUDE.md 中。

為何選 B: 將自訂斜線命令放在專案儲存庫內的 `.claude/commands/` 下,可確保它們納入版本控制,並對每位複製或更新儲存庫的開發者自動可用。這是 Claude Code 中專案層級自訂命令的預期存放位置。

問題 42(情境:使用 Claude Code 生成程式碼)

情境: 你的團隊 CLAUDE.md 已成長到超過 500 行,混雜了 TypeScript 慣例、測試指引、API 模式與部署程序。開發人員難以找到並更新正確的章節。

Claude Code 支援哪種做法,將專案層級的指令整理成聚焦的主題模組？

- A) 定義一個 `.claude/config.yaml` 對應檔,將檔案模式對應到 CLAUDE.md 內的特定章節。
- B) 在 `.claude/rules/` 中建立各自獨立的 Markdown 檔案,每個檔案涵蓋一個主題(例如 `testing.md`、`api-conventions.md`)。 ****[CORRECT]****
- C) 將指令拆分到相關子目錄下的 README.md 檔案,Claude 會自動將其載入為指令。
- D) 在目錄樹的不同層級建立多個名為 CLAUDE.md 的檔案,每個都覆寫上層指令。

為何選 B: Claude Code 支援一個 `.claude/rules/` 目錄,你可以在其中為主題指引建立各自獨立的 Markdown 檔案(例如 `testing.md`、`api-conventions.md`),讓團隊能將龐大的指令集整理成聚焦、易於維護的模組。

問題 43(情境:使用 Claude Code 生成程式碼)

情境: 你建立了一個自訂技能 `/explore-alternatives`,你的團隊用它在選定方案前先腦力激盪並評估各種實作方法。開發人員回報,執行該技能後,Claude 後續的回應會受到方案討論的影響——有時會引用已被否決的方法,或保留干擾實際實作的探索上下文。

你應如何最有效地設定這個技能？

- A) 在技能中使用 `!` 前綴,將探索邏輯當作 bash 子程序執行。
- B) 在技能的 frontmatter 中加入 `context: fork`。 ****[CORRECT]****
- C) 拆分成兩個技能——`/explore-start` 與 `/explore-end`——用以標示何時應捨棄探索上下文的邊界。
- D) 在 `~/ .claude/skills/` 而非 `.claude/skills/` 中建立該技能。

為何選 B: `context: fork` 會在隔離的子代理上下文中執行該技能,使探索討論不會污染主對話歷史。這可避免已被否決的方法與腦力激盪的上下文影響後續的實作工作。

問題 44(情境:使用 Claude Code 生成程式碼)

情境: 你的團隊想透過 Claude Code 新增一個 GitHub MCP 伺服器,用於搜尋 PR 與檢查 CI 狀態。六位開發人員各自擁有自己的個人 GitHub 存取 token。你希望團隊間擁有一致的工具,同時不將憑證提交到版本控制中。

哪種設定做法最有效?

- A) 讓每位開發人員透過 `claude mcp add --scope user` 在使用者範圍中新增該伺服器。
- B) 建立一個 MCP 伺服器包裝層,從 `.env` 檔案讀取 token 並代理 GitHub API 呼叫,然後將該包裝層加入專案的 `.mcp.json`。
- C) 將伺服器加入專案的 `.mcp.json`,使用環境變數替換(`${GITHUB_TOKEN}`)進行驗證,並在專案 README 中說明所需的環境變數。 ****[CORRECT]****
- D) 在專案範圍中以佔位 token 設定伺服器,然後告知開發人員在其本機設定中覆寫它。

為何選 C: 採用環境變數替換的專案 `.mcp.json` 是慣用做法:它為 MCP 設定提供單一、受版本控制的真實來源,同時讓每位開發人員透過環境變數提供憑證。說明該變數可讓新人上手變得容易,而無須提交機密。

問題 45(情境:使用 Claude Code 生成程式碼)

情境: 你正在一個 120 個檔案的程式碼庫中,為外部 API 呼叫加上錯誤處理包裝層。這項工作分為三個階段:(1)找出所有呼叫點與模式,(2)協同設計錯誤處理方法,(3)一致地實作包裝層。在第 1 階段,Claude 產生了大量輸出,列出數百個帶有上下文的呼叫點,在探索完成前就迅速填滿了上下文視窗。

哪種做法最能有效完成任務,同時維持實作一致性?

- A) 在第 1 階段使用 Explore 子代理,以隔離冗長的探索輸出並回傳摘要,然後在主對話中繼續進行第 2–3 階段。 ****[CORRECT]****
- B) 在主對話中執行所有階段,逐步處理檔案時定期使用 `/compact` 來降低上下文用量。
- C) 切換到無頭模式並使用 `--continue`,在批次呼叫之間傳遞明確的上下文摘要以維持連續性。
- D) 在 CLAUDE.md 中定義錯誤處理模式,然後跨多個工作階段分批處理檔案,依賴共用的記憶檔案來維持一致性。

為何選 A: Explore 子代理會將冗長的探索輸出隔離在獨立的上下文中,只回傳精簡的摘要給主對話。這保留了主上下文視窗,供協同設計與一致實作這兩個最需要保留上下文的階段使用。

情境:客戶支援代理

問題 46(情境:客戶支援代理)

情境: 在測試時,你注意到當使用者詢問訂單狀態時,代理經常呼叫 `get_customer`,即使 `lookup_order` 會更適合。為了解決這個問題,你應該先檢查什麼?

你應該先檢查什麼?

- A) 實作一個前置處理分類器,以偵測與訂單相關的請求並將其直接路由到 `lookup_order`。
- B) 減少代理可用的工具數量,以簡化選擇。
- C) 在系統提示中加入少樣本範例,涵蓋所有可能的訂單請求模式,以改善工具選擇。
- D) 檢查工具描述,確保它們清楚區分每個工具的用途。 **[CORRECT]**

為何選 D: 工具描述是模型用來決定要呼叫哪個工具的主要輸入。當代理持續挑選錯誤的工具時,第一個診斷步驟就是驗證工具描述是否清楚劃分每個工具的用途與使用界線。

問題 47(情境:客戶支援代理)

情境: 你的代理在處理單一問題的請求時準確率達 94%(例如「我需要為訂單 #1234 退款」)。但當客戶在一則訊息中包含多個問題時(例如「我需要為訂單 #1234 退款,同時也想更新訂單 #5678 的寄送地址」),工具選擇準確率降至 58%。代理通常只解決一個問題,或在不同請求間混用參數。哪種做法最能有效提升多問題請求的可靠性?

哪種做法最有效?

- A) 實作一個前置處理層,使用另一次獨立的模型呼叫,將多問題訊息分解為各自獨立的請求,各自獨立處理後再合併結果。
- B) 將相關的工具合併為較少的通用工具。
- C) 在提示中加入少樣本範例,示範多問題請求的正確推理與工具呼叫順序。 **[CORRECT]**
- D) 實作回應驗證,偵測不完整的答案並自動重新提示代理以解決遺漏的問題。

為何選 C: 示範多問題請求正確推理與工具呼叫順序的少樣本範例最為有效,因為代理在單一問題上已表現良好——它所需要的是分解並路由多個問題、並保持參數分離的模式指引。

問題 48(情境:客戶支援代理)

情境: 正式環境日誌顯示,對於像「為訂單 #1234 退款」這類簡單請求,你的代理以 3–4 次工具呼叫解決問題,成功率達 91%。但對於像「我被重複扣款、我的折扣沒有套用,而且我想取消」這類複雜請求,代理平均需要 12 次以上的工具呼叫,成功率僅 54%——往往是逐一依序調查各問題,並為每個問題重複擷取相同的客戶資料。哪種變更最能有效改善複雜請求的處理?

哪種變更最有效?

- A) 在各階段之間加入明確的驗證檢查點,要求代理在解決每個問題後先記錄進度,再進行下一個。
- B) 透過將 `get_customer`、`lookup_order` 與計費相關工具合併為單一的 `investigate_issue` 工具,減少工具數量。
- C) 將請求分解為各自獨立的問題,然後利用共用的客戶上下文平行調查每一個,再綜合出最終的解決方案。 **[CORRECT]**
- D) 在系統提示中加入少樣本範例,示範各種多面向計費情境的理想工具呼叫順序。

為何選 C: 分解為各自獨立的問題並以共用客戶上下文平行調查,能修正兩個關鍵問題:它透過在各問題間重複使用共用上下文,消除了重複的資料擷取;並透過在綜合單一解決方案前平行化調查,減少了工具呼叫的總迴圈次數。

問題 49(情境:客戶支援代理)

情境: 你的代理達到 55% 的首次接觸解決率,遠低於 80% 的目標。日誌顯示它把簡單案例(附照片佐證的受損商品標準換貨)升級,卻試圖自主處理需要政策例外的複雜情況。改善升級校準最有效的方式是什麼?

改善升級校準最有效的方式是什麼?

- A) 要求代理在每次回應前以 1–10 分自評信心,並在信心低於某個門檻時自動轉交真人。
- B) 部署一個以歷史工單訓練的獨立分類器模型,在主代理開始處理前先預測哪些請求需要升級。
- C) 在系統提示中加入明確的升級準則,並附上少樣本範例,說明何時該升級、何時該自主解決。 **
[CORRECT]**
- D) 實作情緒分析以判斷客戶的不滿程度,並在超過某個負面情緒門檻時自動升級。

為何選 C: 帶有少樣本範例的明確升級準則直接針對根本原因——簡單與複雜案例之間不清楚的決策邊界。它是最相稱、最有效的首要介入手段,能在不增加額外基礎設施的情況下,教會代理何時該升級、何時該自主解決。

問題 50(情境:客戶支援代理)

情境: 在呼叫 `get_customer` 與 `lookup_order` 之後,代理已取得所有可用的系統資料,但仍面臨不確定性。哪一種情況最有正當理由觸發呼叫 `escalate_to_human` ?

哪一種情況最有正當理由升級?

- A) 客戶想取消一筆昨天出貨、明天就會送達的訂單。代理應該升級,因為客戶在收到包裹後可能會改變心意。
- B) 客戶聲稱自己沒有收到訂單,但追蹤紀錄顯示三天前已送達其地址並有簽收。代理應該升級,因為提出相互矛盾的證據可能損害客戶關係。
- C) 客戶要求比照競爭對手的價格。你的政策允許在 14 天內針對自家網站的降價做價格調整,但對競爭對手的價格隻字未提。代理應該升級以進行政策解讀。 **[CORRECT]**
- D) 客戶訊息同時包含一個帳單問題與一筆商品退貨。代理應該升級,讓真人在一次互動中協調這兩個議題。

為何選 C: 這是一個真正的政策缺口:公司規則涵蓋自家網站的降價,但並未處理比照競爭對手價格的情形。代理絕不能自行發明政策,而應升級,讓真人判斷如何解讀或延伸既有規則。

問題 51(情境:客戶支援代理)

情境: 正式環境日誌顯示,在 12% 的案例中,你的代理跳過 `get_customer` ,僅憑客戶提供的姓名直接呼叫 `lookup_order` ,有時導致帳戶辨識錯誤與退款錯誤。哪一項變更最能有效修正這個可靠性問題?

哪一項變更最有效?

- A) 加入少樣本範例,示範代理一律先呼叫 `get_customer` ,即使客戶主動提供了訂單細節也一樣。
- B) 實作一個路由分類器,分析每個請求,並只啟用適合該請求類型的工具子集。

- C) 加入一個程式化的前置條件,在 `get_customer` 回傳經驗證的客戶識別碼之前,阻擋 `lookup_order` 與 `process_refund`。 **[CORRECT]**
- D) 強化系統提示,聲明在任何訂單操作之前都必須透過 `get_customer` 進行客戶驗證。

為何選 C: 程式化的前置條件提供了確定性的保證,確保遵循必要的執行順序。它是最有效的做法,因為無論 LLM 行為如何,都能消除跳過驗證的可能性。

問題 52(情境:客戶支援代理)

情境: 正式環境指標顯示,在處理複雜的帳單爭議或多筆訂單退貨時,客戶滿意度分數比簡單案例低 15%——即使解決方案在技術上是正確的。根因分析顯示代理提供了正確的解決方案,但在說明理由時前後不一致:有時省略相關的政策細節,有時遺漏時程資訊或後續步驟。具體的上下文缺口因案例而異。你想在不增加人工監督的前提下改善解決方案品質。哪一種做法最有效?

哪一種做法最有效?

- A) 加入一個自我批判階段,讓代理評估草稿回應的完整性——確保它解決了客戶的問題、包含相關上下文,並預先設想後續問題。 **[CORRECT]**
- B) 加入一個確認階段,讓代理在結案前詢問「這是否已完全解決你的問題?」,讓客戶在需要時可以要求額外資訊。
- C) 針對複雜案例,將模型從 Haiku 升級到 Sonnet,並依據定義好的複雜度指標進行路由。
- D) 在系統提示中實作少樣本範例,針對五種常見的複雜案例類型展示完整說明,示範如何納入政策上下文、時程與後續步驟。

為何選 A: 自我批判階段(評估者—最佳化者模式)直接針對說明完整性不一致的問題,強迫代理在呈現草稿前,依照具體準則——例如政策上下文、時程與後續步驟——評估自己的草稿。這能在不需人工監督的情況下,捕捉到因案例而異的缺口。

問題 53(情境:客戶支援代理)

情境: 正式環境指標顯示你的代理平均每次解決需要 4 次以上的 API 迴圈。分析發現,即使一開始就同時需要 `get_customer` 與 `lookup_order`, Claude 往往仍在分開的連續輪次中分別請求這兩者。減少迴圈數量最有效的方式是什麼?

減少迴圈最有效的方式是什麼?

- A) 實作推測性執行,自動與任何被請求的工具平行呼叫可能需要的工具,並回傳所有結果,無論實際請求的是什麼。
- B) 提高 `max_tokens`,給 Claude 更多空間進行規劃並自然地合併工具請求。
- C) 建立像 `get_customer_with_orders` 這樣的複合工具,將常見的查詢組合捆綁成單次呼叫。
- D) 在提示中指示 Claude 把工具請求捆綁進單一輪次,並在下一次 API 呼叫前一併回傳所有結果。 ** [CORRECT]

為何選 D: 提示 Claude 將相關的工具請求捆綁進單一輪次,善用了它一次請求多個工具的原生能力。它以最小的架構變更直接修正了連續呼叫的模式。

問題 54(情境:客戶支援代理)

情境: 正式環境日誌顯示一種模式:客戶引用特定金額(例如「我先前提到的 15% 折扣」),但代理卻以錯誤的數值回應。調查發現這些細節是在 20 多輪以前提到的,並被濃縮成像「曾討論過促銷定價」這類含糊的摘要。哪一項修正最有效?

哪一項修正最有效?

- A) 將摘要門檻從 70% 提高到 85%,讓對話在觸發摘要之前有更多空間。
- B) 將完整的對話歷史儲存在外部儲存中,並在代理偵測到像「如我先前所提」這類引用時實作檢索。
- C) 將交易性事實(金額、日期、訂單編號)擷取到一個持續性的「案例事實」區塊,於每則提示中納入,且置於摘要過的歷史之外。 **[CORRECT]**
- D) 修改摘要提示,明確要求逐字保留所有數字、百分比、日期與客戶陳述的期望。

為何選 C: 摘要本質上會遺失精確的細節。將交易性事實擷取到摘要過的歷史之外的一個結構化「案例事實」區塊,能保留關鍵資訊,使其無論已摘要了多少輪次,都能在每則提示中可靠地取用。

問題 55(情境:客戶支援代理)

情境: 你的 `get_customer` 工具在以姓名搜尋時會回傳所有相符項目。目前當有多筆結果時,Claude 會挑選最近有訂單的客戶,但正式環境資料顯示,對於不明確的相符項目,這種做法有 15% 的機率選錯帳戶。你該如何處理這個問題?

你該如何處理這個問題?

- A) 實作一套信心評分系統,在信心高於 85% 時自主行動,低於門檻時則要求澄清。
- B) 指示 Claude 在 `get_customer` 回傳多筆相符項目時,於採取任何客戶專屬動作之前,先要求一個額外的識別資訊(電子郵件、電話或訂單編號)。 **[CORRECT]**
- C) 修改 `get_customer`,使其依據排序演算法只回傳單一最可能的相符項目,藉此消除不明確性。
- D) 在提示中加入少樣本範例,針對不明確的相符項目示範正確的推理與工具排序。

為何選 B: 向使用者詢問額外的識別資訊是化解不明確性最可靠的方式,因為使用者對自己的身分擁有確定的認知。多一次對話輪次,是消除因選錯帳戶而造成的 15% 錯誤率的微小代價。

問題 56(情境:客戶支援代理)

情境: 正式環境日誌顯示一個固定模式:當客戶在訊息中包含「account」這個字(例如「I want to check my account for an order I made yesterday」)時,代理有 78% 的機率會先呼叫 `get_customer`。當客戶以不含「account」的方式提出類似請求(例如「I want to check an order I made yesterday」)時,則有 93% 的機率會先呼叫 `lookup_order`。工具描述清楚且毫不含糊。這個差異最可能的根本原因是什麼?

最可能的根本原因是什麼?

- A) 系統提示包含對關鍵字敏感的指令,會根據「account」之類的詞彙引導行為,造成非預期的工具選擇模式。 [CORRECT]
- B) 模型的基礎訓練在「account」術語與客戶相關操作之間建立了關聯,凌駕於工具描述之上。

- C) 模型需要更多關於多概念訊息的訓練資料,並應以同時包含 account 與 order 術語的範例進行微調。
- D) 工具描述需要額外的負面範例,明確指出何時「不該」使用各工具,以防止這種由關鍵字引發的混淆。

為何選 A: 這種有系統、由關鍵字驅動的模式(78% 對 93%)強烈顯示系統提示中存在明確的路由邏輯,會對「account」這個字產生反應並將代理引導至客戶相關工具。由於工具描述本就清楚,這個差異指向提示層級的指令造成了非預期的行為引導。

問題 57(情境:客戶支援代理)

情境: 正式環境日誌顯示,當使用者詢問訂單時(例如「check my order #12345»),代理經常呼叫 `get_customer` 而非呼叫 `lookup_order`。兩個工具都只有極簡描述(「Gets customer information」 / 「Gets order details」),且接受外觀相似的識別碼格式。要提升工具選擇可靠性,最有效的第一步是什麼?

最有效的第一步是什麼?

- A) 實作一個路由層,在每一輪之前分析使用者輸入,並根據偵測到的關鍵字與 ID 模式預先選定正確的工具。
- B) 將兩個工具合併為單一的 `lookup_entity`,接受任何識別碼並在內部決定要查詢哪個後端。
- C) 在系統提示中加入少樣本範例以示範正確的工具選擇模式,以 5–8 個範例將訂單相關查詢路由至 `lookup_order`。
- D) 擴充每個工具的描述,納入輸入格式、範例查詢、邊界案例,以及說明何時該使用它而非類似工具的界線。 [CORRECT]

為何選 D: 以輸入格式、範例查詢、邊界案例與清楚界線來擴充工具描述,直接修正了根本原因——極簡的描述無法提供足夠資訊讓 LLM 區分相似的工具。這是一個低投入、高影響的第一步,能改善 LLM 用於工具選擇的主要機制。

問題 58(情境:客戶支援代理)

情境: 你正在為你的支援代理實作代理迴圈。在每次 Claude API 呼叫之後,你必須決定要繼續迴圈(執行所請求的工具並再次呼叫 Claude)或停止(向客戶呈現最終答案)。是什麼決定了這個判斷?

是什麼決定了這個判斷?

- A) 檢查 Claude 回應中的 `stop_reason` 欄位——若為 `tool_use` 則繼續,若為 `end_turn` 則停止。 [CORRECT]
- B) 解析 Claude 的文字,尋找「I'm done」或「Can I help with anything else?」之類的片語——自然語言訊號代表任務完成。
- C) 設定最大迭代次數(例如 10 次呼叫),達到上限即停止,無論 Claude 是否表示還需要更多工作。
- D) 檢查回應是否包含 assistant 文字內容——若 Claude 產生了說明性文字,迴圈就應該終止。

為何選 A: `stop_reason` 是 Claude 用於迴圈控制的明確結構化訊號:`tool_use` 表示 Claude 想執行工具並取回結果,而 `end_turn` 表示 Claude 已完成其回應,迴圈應該結束。

問題 59(情境:客戶支援代理)

情境: 正式環境日誌顯示代理會誤解你的 MCP 工具輸出:來自 `get_customer` 的 Unix 時間戳記、來自 `lookup_order` 的 ISO 8601 日期,以及數字狀態碼(1=pending、2=shipped)。有些工具是你無法修改的第三方 MCP 伺服器。哪一種資料格式正規化的方法最易於維護?

哪一種方法最易於維護?

- A) 使用 `PostToolUse` hook 攔截工具輸出,並在代理處理之前套用格式轉換。 **[CORRECT]**
- B) 修改你能控制的工具使其回傳人類可讀的格式,並為第三方工具建立包裝層。
- C) 建立一個 `normalize_data` 工具,讓代理在每次資料擷取後呼叫它來轉換數值。
- D) 在系統提示中加入詳細的格式文件,說明每個工具的資料慣例。

為何選 A: `PostToolUse` hook 提供一個集中、確定性的攔截點,可在代理處理之前正規化所有工具輸出——包括第三方 MCP 伺服器的資料。它更易於維護,因為轉換存在於程式碼中並一致地套用,而非仰賴 LLM 的解讀。

問題 60(情境:客戶支援代理)

情境: 正式環境日誌顯示,代理有時會在 `lookup_order` 更為合適時選擇 `get_customer`,尤其是在「I need help with my recent purchase.」這類模糊的查詢上。你決定在系統提示中加入少樣本範例以改善工具選擇。哪一種方法最能有效解決問題?

哪一種方法最有效?

- A) 在每個工具描述中加入明確的「use when」與「don't use when」指引,涵蓋模糊的情況。
- B) 加入依工具分組的範例——所有 `get_customer` 情境放在一起,接著是所有 `lookup_order` 情境。
- C) 加入 4–6 個針對模糊情境的範例,每個都附上為何選擇某工具而非其他合理替代方案的理由。 **[CORRECT]**
- D) 加入 10–15 個清楚、毫不含糊的請求範例,為每個工具示範典型情境下的正確工具選擇。

為何選 C: 將少樣本範例針對實際發生錯誤的特定模糊情境,並明確說明為何某工具優於替代方案,能教會模型在邊界案例中所需的比較式決策過程。這比通用範例或宣告式規則更為有效。

情境:對話式 AI 架構模式

問題 61(情境:對話式 AI 架構模式)

情境: 你的 `remove_team_member` 工具使用 `dry_run: boolean` 參數,在執行前預覽影響。正式環境監控顯示代理會直接以 `dry_run=false` 呼叫,藉此略過預覽步驟。你需要確保每一次移除都先經過使用者明確確認的預覽。

最可靠的方法是什麼?

- A) 加入伺服器端驗證,僅當過去 60 秒內曾發生過具有相同參數的 `dry_run=true` 呼叫時,才允許 `dry_run=false`。
- B) 將該工具標註為需要確認,並設定編排層,在將任何呼叫轉送至被標註的工具之前,先提示使用者核准。
- C) 在工具描述中加入詳細指令與少樣本範例,要求代理一律先以 `dry_run=true` 呼叫,並等待使用者確認後才再次呼叫。
- D) 改用兩個工具: `preview_remove_member` 回傳影響細節與一個一次性的確認 token; `execute_remove_member` 則需要該 token,將執行綁定至預覽。 [CORRECT]

為何選 D: 兩工具的 token 綁定方法在架構上讓人無法在未先預覽的情況下執行——execute 工具確實需要一個只有 preview 工具才能產生的 token。這是唯一在程式碼層級強制執行此約束的方法,而非仰賴 LLM 遵守指令(C)、時間啟發式(A)或編排基礎設施(B)。

問題 62(情境:對話式 AI 架構模式)

情境: 正式環境監控顯示你的 `search_catalog` 工具有 12% 的時間會失敗:其中 8% 是重試後會成功的網路逾時,4% 則是無論如何重試都不會成功的查詢語法錯誤。目前兩種錯誤類型的回傳方式完全相同,導致無謂的重試。

你應該如何修改該工具的錯誤處理?

- A) 在你的系統提示中加入少樣本範例,示範如何區分網路錯誤與語法錯誤。
- B) 對所有錯誤一致地套用指數退避重試邏輯。
- C) 在工具內部對網路逾時實作帶退避的自動重試;對語法錯誤則立即回傳並附上參數驗證細節。 [CORRECT]
- D) 為所有錯誤回傳一個 `retryable` 布林旗標與錯誤類型細節。

為何選 C: 在工具層級處理暫時性錯誤的重試是正確的抽象界線——工具對錯誤類型有確切的認知,且能實作確定性的重試邏輯,而不必仰賴代理理解讀旗標(D)或遵循提示層級的指令(A)。一致的退避(B)會在永遠不會成功的語法錯誤上浪費時間。

問題 63(情境:對話式 AI 架構模式)

情境: 在討論投資策略的數輪對話中,某位使用者先表示「我的風險承受度非常低」,後來又說「我想要讓報酬最大化」。他們現在問:「我應該投資什麼?」

哪種做法最能確保建議符合使用者真正的優先考量?

- A) 點出這項矛盾,並請使用者釐清何者更重要。 [CORRECT]
- B) 針對兩種情境分別提供建議。
- C) 以最近一次陳述的偏好繼續進行。
- D) 在不處理衝突的情況下,推薦一個平衡型投資組合。

為何選 A: 當使用者偏好彼此直接矛盾時,點出衝突並請求釐清是唯一能保證建議符合使用者真實意圖的方式。任何其他做法都涉及一項可能錯誤的假設——報酬最大化與低風險承受度是本質上不相容的目標,需要由真人做出決定。

問題 64(情境:對話式 AI 架構模式)

情境: 使用者在多輪對話中逐步調整播放清單偏好。在某位使用者說「我愛爵士樂」後的兩則訊息,Claude 卻問「你喜歡哪些曲風?」

最可能的原因為何?

- A) Claude 需要連接向量資料庫才能維持對話記憶。
- B) 已超出模型的上下文視窗。
- C) Claude API 需要一個 `session_id` 參數。
- D) 你的應用程式沒有把先前的訊息納入 `messages` 陣列。 **[CORRECT]**

為何選 D: Claude 沒有伺服器端記憶——每次 API 呼叫都是無狀態的。若未在每個請求的 `messages` 陣列中納入完整的對話歷史,Claude 就無從得知先前的輪次。向量資料庫(A)與 `session_id` (C)都不是 Claude 架構的一部分;對於只有兩則訊息的往來而言,上下文視窗溢位(B)是不可能發生的。

問題 65(情境:對話式 AI 架構模式)

情境: 在一場 40 分鐘的烹飪工作階段後,對話達到 78,000 個 tokens。歷史內容包含過敏資訊、食譜份量縮放、已釐清的烹飪術語,以及一般討論。你必須在保留重要資訊的同時減少 tokens。

哪種做法最能在保留資訊與減少 token 之間取得平衡?

- A) 摘要整段對話歷史。
- B) 只保留最近的 20,000 個 tokens。
- C) 擷取關鍵的結構化資料(過敏資訊、數量、偏好),摘要一般討論,並逐字保留近期的往來。 **[CORRECT]**
- D) 將完整對話儲存於外部,並透過語意搜尋擷取相關部分。

為何選 C: 混合式做法以最低成本保留最高價值的資訊。像過敏資訊與食譜數量這類關鍵事實會被擷取進一個精簡的結構化區塊(避免摘要過程中發生的精確度損失),一般討論則加以摘要,而近期的往來則逐字保留以維持對話連貫性。選項 A 與 B 有遺失關鍵飲食資訊的風險;D 對於單一場烹飪工作階段而言則是架構上的過度設計。

問題 66(情境:對話式 AI 架構模式)

情境: 使用者回報,在較長的對話中,助理會弄丟對先前主題與偏好的掌握。你目前的實作只保留最後 25 組訊息對。

最有效的解決方案為何?

- A) 混合式做法:摘要較舊的訊息,同時逐字保留近期的訊息。 **[CORRECT]**
- B) 在完整對話歷史上進行向量相似度搜尋。
- C) 將視窗增加到 50 組訊息對。
- D) 每輪都摘要被捨棄的訊息,並把持續累積的摘要前置加入。

為何選 A: 混合式做法同時處理問題的兩個面向:保留精確的近期上下文(對對話連貫性至關重要),同時維持對較早偏好的壓縮表示(避免在捨棄訊息對時造成全面遺失)。增加視窗(C)只是把同樣的問題往後延。向量搜尋

(B)可能漏掉與目前查詢在語意上不相似、卻很重要的上下文。每輪完整摘要(D)會增加額外負擔,並累積摘要誤差。

問題 67(情境:對話式 AI 架構模式)

情境: 使用者回報,當對話超過 50 輪時,延遲會增加且成本會上升。

主要原因為何?

- A) 每次 API 請求都會納入整段對話歷史。 **[CORRECT]**
- B) 模型產生的回應逐漸變長。
- C) 隨著歷史增長,資料庫操作變慢。
- D) 模型建立一份內部使用者檔案,需要更多處理。

為何選 A: Claude 的 API 完全是無狀態的——每個請求都必須在 `messages` 陣列中納入完整的對話歷史。隨著對話增長,每個請求都會攜帶更多 tokens,這直接增加了處理延遲與成本。模型不會在呼叫之間維持任何內部狀態(D 為假),而回應長度本質上也與對話長度無關(B)。

問題 68(情境:對話式 AI 架構模式)

情境: 經過三個月的每週工作階段後,對話歷史增長到 85,000 個 tokens。當使用者問「我們對於孤立這個主題做出了什麼結論?」時,助理給出的是籠統的答案,而非引用先前的討論。

最有效的做法為何?

- A) 滾動視窗截斷。
- B) 擷取關鍵結論的漸進式摘要。
- C) 以語意嵌入搭配相關往來的擷取。 **[CORRECT]**
- D) 加入結構化 XML 標籤來標記討論結論。

為何選 C: 在對話歷史上進行語意搜尋,是唯一能擴展至三個月討論量、同時又能按需求呈現特定相關往來的做法。滾動視窗(A)會捨棄大部分的歷史。漸進式摘要(B)會把討論壓縮成抽象內容,而遺失使用者正在詢問的特定結論。XML 標籤(D)需要重新編排所有過往內容,且在此規模下無法解決擷取問題。

問題 69(情境:對話式 AI 架構模式)

情境: 在 QA 測試期間,Claude 在前 10–15 輪會遵循系統提示的指引,但後續的回應卻有所偏離。對話仍在 token 上限之內。

最佳的解決方案為何?

- A) 把行為指引移到第一則使用者訊息中。
- B) 在 20 輪後開始一段新對話。
- C) 在對話的斷點處插入使用者角色的訊息以強化指引。 **[CORRECT]**
- D) 使用回應後驗證來重新產生不符合規範的回應。

為何選 C: 定期注入行為提醒,可在對話歷史累積時以固定間隔重新確立約束,直接對抗指令漂移。將指引移到第一則使用者訊息(A)會降低其權威性。開始一段新對話(B)會摧毀上下文。回應後驗證(D)屬於事後矯正而非事前預防,並會增加可觀的延遲。

問題 70(情境:對話式 AI 架構模式)

情境: 你的 AI 家教有一段 2,800 token 的系統提示,用來定義教學方法與調適規則。在 12 輪之後,助理開始忽略熟練度等級。

最有效的修正方式是什麼?

- A) 每 4–5 輪注入一次提醒。
- B) 以示範熟練度等級調適的少樣本範例取代冗長的規則。 **[CORRECT]**
- C) 將關鍵規則放在系統提示的結尾。
- D) 評估回應,若難度等級不符就重新產生。

為何選 B: 一段帶有宣告式規則的 2,800 token 系統提示容易發生漂移,因為抽象規則需要模型在每一輪都對其進行推理。以具體的少樣本範例(示範正確的熟練度等級調適)取代冗長的規則,能給模型清楚的行為模式去比對——相較於抽象指令,這種做法在多輪對話中能被更可靠地遵循。注入提醒(A)有幫助,但只處理症狀;放在結尾(C)在初期有幫助,但無法解決逐輪累積的漂移;重新產生(D)成本高昂且屬於事後補救。

問題 71(情境:對話式 AI 架構模式)

情境: 你的助理必須維持熱情的語氣、解釋其推理,並提出釐清問題。這些行為準則應該在哪裡定義?

這些行為準則應該在哪裡定義?

- A) 前置到每一則使用者訊息。
- B) 在系統提示中。 **[CORRECT]**
- C) 在第一則助理訊息中。
- D) 在環境變數中。

為何選 B: 系統提示專門設計用於整段對話中持續適用的行為約束與準則。前置到每一則使用者訊息(A)是多餘的額外負擔。第一則助理訊息(C)並不可靠,因為模型可能偏離它自己先前的陳述。環境變數(D)對模型行為沒有任何影響。

問題 72(情境:對話式 AI 架構模式)

情境: 使用者回報回應開頭重複出現像「Certainly!」和「I'd be happy to help!」這樣的句子。

最有效的做法是什麼?

- A) 附加一則帶有直接回應開頭的部分助理訊息。 **[CORRECT]**
- B) 調低 temperature 設定。
- C) 後處理回應以移除問候語。

- D) 在系統提示中加入指令以避免那些用語。

為何選 A: 以直接答覆的開頭預填助理回應,可在產生階段就防止問候語模式——模型會從預填內容接續往下,而不是產生新的開頭用語。系統提示指令(D)有幫助,但較不可靠,因為模型仍可能產生變體。後處理(C)是脆弱的權宜之計。temperature(B)控制的是隨機性,而非特定的用語模式。

問題 73(情境:對話式 AI 架構模式)

情境: 在使用者正在聊天時,一個 webhook 通知你的系統:該使用者的包裹已出貨。你希望助理在下一則回應中自然地把這項資訊納入。

最佳做法是什麼?

- A) 將出貨狀態加入系統提示。
- B) 立即送出一則合成的使用者訊息。
- C) 強制助理在每一輪都呼叫一個狀態工具。
- D) 將狀態更新附加為下一則使用者訊息的前綴。 **[CORRECT]**

為何選 D: 把狀態更新前綴到下一則使用者訊息,可在自然的對話邊界注入即時上下文,而不會打斷流程。修改系統提示(A)需要重建工作階段,或在架構上很麻煩。合成的使用者訊息(B)可能破壞自然的對話流程並混淆出處標註。強制每一輪都呼叫工具(C)在事件罕見時很浪費。

問題 74(情境:對話式 AI 架構模式)

情境: 使用者經常送出像「幫派對訂一個場地」這樣的請求。助理會問 4 個以上的釐清問題,導致 35% 的放棄率。

哪種做法最能改善這個權衡取捨?

- A) 以隱藏的預設值逕行進行。
- B) 在一則複合訊息中問完所有釐清問題。
- C) 明確陳述假設並逕行進行,同時邀請使用者更正。 **[CORRECT]**
- D) 使用結構化的填寫表單。

為何選 C: 明確陳述假設並逕行進行,能立即給使用者一個有用的回應,同時保留他們更正錯誤假設的能力。隱藏的預設值(A)讓使用者不知道系統假設了什麼。複合式的問題清單(B)仍要求使用者預先付出心力。結構化表單(D)增加而非減少摩擦——與降低放棄率的目標相矛盾。

問題 75(情境:對話式 AI 架構模式)

情境: 你的助理使用一段承包商人設的系統提示。前幾輪都遵循規則,但到了第 7 輪,助理開始給出籠統的建議。對話長度只有 2,500 token。

最可能的原因是什麼?

- A) 系統提示只建立初始行為。
- B) 隨著輪數累積,模型注意力減弱。
- C) 累積的助理回應稀釋了系統提示的影響力。 [CORRECT]
- D) 系統提示只送出一次。

為何選 C: 隨著助理回應在對話歷史中累積,反映系統提示行為約束的文字比例,相對於不斷增長的助理產生內容而下降。模型會越來越傾向比對自己先前的輸出,而非系統提示,即使在較短的 token 長度下也會加劇漂移。系統提示包含在每一次 API 呼叫中(就單獨解釋而言,D 是錯的),而模型注意力衰退(B)在 2,500 token 下並不會發生。

問題 76(情境:對話式 AI 架構模式)

情境: 使用者提出像「你能幫忙處理那份報告嗎?」這樣模糊的請求。助理以提出多個問題作為回應(哪份報告?需要什麼幫助?截止日期?),導致 40% 的放棄率。

最佳解決方案是什麼?

- A) 做出合理的假設、明確陳述,並提議進行調整。 [CORRECT]
- B) 在回應前用較小的模型對模糊性進行分類。
- C) 使用預先定義的詮釋,但不陳述假設。
- D) 限制助理每輪只能問一個釐清問題。

為何選 A: 以合理且明說的假設逕行進行,可完全消除來回往返,同時讓使用者知情並保有掌控。預先定義且不明說的詮釋(C)在回應不符合使用者意圖時讓他們困惑。每輪一個問題的限制(D)仍需要多輪來回往返。較小的分類模型(B)增加延遲與基礎架構複雜度,卻沒有解決核心的使用者體驗問題。

情境:開發者生產力工具

問題 77(情境:開發者生產力工具)

情境: 一位工程師請代理在一個 2,000 個檔案的儲存庫中找出函式 `calculate_tax` 被定義與被呼叫的所有位置。代理可使用 Read、Write、Edit、Bash、Grep 與 Glob。

哪一種做法最有效?

- A) 依序讀取儲存庫中的每個檔案,逐一掃描內容尋找函式名稱。
- B) 使用 Grep 搜尋檔案內容中的 `calculate_tax`,必要時以 Glob 縮小檔案類型範圍。 [CORRECT]
- C) 使用 Bash 執行 `find . | xargs cat`,在合併後的輸出中尋找該函式。
- D) 請使用者把相關檔案貼進對話。

為何選 B: Grep 專為跨多檔案的內容搜尋而設計,只回傳含位置資訊的符合行,讓上下文視窗維持精簡。讀取每個檔案(A)浪費上下文且緩慢;把所有內容透過 Bash `cat` 倒出(C)產生無結構輸出並失去檔案/行號歸屬;請使用者貼檔案(D)違背了「具備儲存庫存取權的自動化工具」的初衷。

問題 78(情境:開發者生產力工具)

情境: 為了摸清一個不熟悉的程式碼庫,代理執行一次廣泛的探索,列出數百個模組及其說明。原始輸出極為龐大,在工程師真正的任務開始前就開始排擠主對話。

處理這份探索輸出的最佳方式為何?

- A) 將探索委派給 Explore 子代理(或設定 `context: fork` 的技能),由其回傳精簡摘要至主工作階段。
[CORRECT]
- B) 提高 `max_tokens`,讓完整的探索輸出能容納進去。
- C) 將探索輸出截斷為前 50 個模組後繼續。
- D) 探索完成後重啟工作階段,讓上下文清空。

為何選 A: 子代理把冗長的探索隔離在獨立上下文中,只回傳提煉後的摘要,為真正的工作保留主上下文視窗。`max_tokens` (B)控制的是輸出長度,而非上下文壓力。截斷(C)會默默丟掉可能重要的模組。重啟(D)則丟棄了你剛付出代價取得的探索成果。

問題 79(情境:開發者生產力工具)

情境: 產生的樣板程式碼一再偏離團隊慣例(import 排序、錯誤處理風格、測試版面配置)。同樣的請求,不同工程師得到不同的輸出。

最持久的解法為何?

- A) 將慣例寫入 CLAUDE.md,使其在該專案的每次請求都自動載入。 [CORRECT]
- B) 要求每位工程師每次都在提示中重述慣例。
- C) 調低 temperature,讓輸出更一致。
- D) 在產生之後執行格式化工具來重塑程式碼。

為何選 A: CLAUDE.md 是專案的持久記憶——放在其中的慣例會自動套用到每個工作階段與每位工程師,從根源解決問題。每次提示重述慣例(B)易出錯且無法規模化。temperature(C)影響的是變異性,而非對未明說規則的遵循。格式化工具(D)能處理排版,卻管不到錯誤處理風格或結構性慣例。

問題 80(情境:開發者生產力工具)

情境: 一位工程師要求進行一項會動到約 15 個檔案、且涉及不平凡設計決策(如何拆分某模組)的重構。他希望在任何程式碼變更前先審視做法。

哪一項 Claude Code 能力最合適?

- A) 使用規劃模式,在進行編輯前先產出並確認做法。 [CORRECT]
- B) 立刻開始編輯,事後再讓工程師審視差異。
- C) 用單一 Bash 命令一次套用所有變更。
- D) 在一則訊息中產出整個重構,不使用工具呼叫。

為何選 A: 規劃模式把設計與執行分開,讓工程師在任何檔案被動到之前,先核可這種模糊、多檔案變更的做法——正是前期對齊最有價值的時機。先編輯(B)在做法錯誤時會招致大量返工。用 Bash 批次套用(C)完全跳

過審查。一次性產生(D)沒有檢查點,也沒有經工具驗證的編輯。

問題 81(情境:開發者生產力工具)

情境: 代理嘗試 Edit 某檔案,但因該檔案自本工作階段上次讀取後已被變更而遭拒絕。

正確的回應為何?

- A) 重新讀取該檔案取得目前內容,再針對新狀態重新套用編輯。 **[CORRECT]**
- B) 改用 Bash `sed` 命令強行編輯。
- C) 不斷重試完全相同的 Edit 直到成功。
- D) 用代理上次已知的版本以 Write 覆寫整個檔案。

為何選 A: 過時防護之所以觸發,是因為磁碟上的內容已不符代理上次所見;重新讀取可還原編輯的正確基準。透過 Bash `sed` 強行寫入(B)繞過了安全檢查,可能破壞並行的變更。重試相同的 Edit(C)會因同樣原因持續失敗。用過時版本以 Write 覆寫(D)會丟棄一切變更該檔案的內容。

問題 82(情境:開發者生產力工具)

情境: 團隊希望代理能在一個提供 REST API 的內部問題追蹤系統中查詢與更新工單。工程師不應手動貼上工單資料,且 API 憑證不得嵌入提示中。

最佳整合做法為何?

- A) 透過 MCP 伺服器公開該追蹤系統,讓代理取得結構化工具,並由伺服器在對話之外處理憑證。 **[CORRECT]**
- B) 每當需要時,請工程師把工單 JSON 複製進聊天。
- C) 把 API 金鑰放進 CLAUDE.md,讓代理能用 Bash `curl` 呼叫 API。
- D) 把工單內容硬寫進技能檔。

為何選 A: MCP 伺服器是把後端服務以具型別工具提供給代理的標準方式,並由伺服器而非提示來管理驗證。手動貼上(B)無法規模化且會過時。把金鑰放進 CLAUDE.md(C)會把祕密洩漏到一個會被提交的檔案。把工單硬寫進技能(D)無法反映即時資料。

問題 83(情境:開發者生產力工具)

情境: 每次發版,一位工程師都帶著代理走同樣的六個步驟(更新版本號、更新變更日誌、執行測試、打標籤、撰寫發版說明、開 PR)。他希望能以單一可重複的動作來叫用。

他應該建立什麼?

- A) 在 `.claude/` 中建立一個編碼了這六步流程的自訂斜線命令(或技能)。 **[CORRECT]**
- B) 寫一份更長、以散文描述這些步驟的 CLAUDE.md。
- C) 保存一份聊天逐字稿,每次發版時重讀。
- D) 寫一支完全繞過代理的 Bash 腳本。

為何選 A: 自訂命令/技能能擷取一個可重複、可帶參數的流程,讓工程師以名稱叫用——正是為此而生。以 CLAUDE.md 描述(B)提供的是背景脈絡,而非可叫用的動作。重讀逐字稿(C)既手動又脆弱。純 Bash 腳本(D)會喪失代理在變更日誌與 PR 文字等步驟上的判斷力。

問題 84(情境:開發者生產力工具)

情境: 團隊希望一組嚴格的 API 設計規則,只在代理處理 `src/api/` 底下的檔案時套用,而不污染其他每個檔案的上下文。

哪一種機制合適?

- A) 在 `.claude/rules/` 中新增一個規則檔,並以 `paths glob` 將其範圍限定在 `src/api/**`。
[CORRECT]
- B) 把規則放進頂層 CLAUDE.md,讓它總是載入。
- C) 在每個碰到 API 的提示中貼上這些規則。
- D) 為 API 程式碼另建一個獨立的儲存庫。

為何選 A: 路徑範圍化的規則檔會依當下涉及哪些檔案而條件式載入,因此 API 規則只在 `src/api/` 底下生效、其他地方不生效——讓其他上下文保持乾淨。頂層 CLAUDE.md(B)到處都載入,正好相反。逐提示貼上(C)既手動又不一致。拆分儲存庫(D)是為了解決上下文範圍問題而做的沉重結構性變更。

情境:結構化資料擷取

問題 85(情境:結構化資料擷取)

情境: 一條管線從發票擷取欄位,下游程式碼需要可靠、可解析且型別良好的輸出。自由文字回應偶爾會讓解析器出錯。

哪一種做法能得到最可靠的結構化輸出?

- A) 將欄位定義為 JSON 結構描述,並讓模型透過 `tool_use` 回傳。[CORRECT]
- B) 在系統提示中要求模型「以 JSON 回應」,再解析其文字。
- C) 用正規表示式解析模型的散文回答。
- D) 調低 `max_tokens`,讓模型保持精簡。

為何選 A: 透過 `tool_use` JSON 結構描述驅動擷取,會約束輸出的形狀與型別,使下游解析可靠。散文式的「以 JSON 回應」指示(B)不具強制力且會飄移。對散文用正規表示式(C)脆弱,任何措辭改變都會壞掉。`max_tokens` (D)控制的是長度,而非結構。

問題 86(情境:結構化資料擷取)

情境: 有些發票沒有採購單號。目前的結構描述把 `po_number` 標為必填,因此模型會捏造看似合理的值來滿足它。

正確的結構描述設計為何?

- A) 把 `po_number` 設為選填/可為 null,讓模型在欄位不存在時回傳 null。 [CORRECT]
- B) 維持必填,並接受偶爾出現的捏造值。
- C) 把 `po_number` 從結構描述中整個移除。
- D) 加上「絕不臆測」的指示,但仍維持該欄位必填。

為何選 A: 把欄位設為可為 null/選填,給了模型一個表示「不存在」的正確方式,消除了捏造的壓力。維持必填(B)保證會出現幻覺值。移除欄位(C)會在資料確實存在時丟棄它。在欄位仍必填的情況下加「絕不臆測」指示(D)與結構描述相互矛盾且不可靠——應由結構讓正確答案得以被表達。

問題 87(情境:結構化資料擷取)

情境: `document_type` 欄位通常落在已知集合(invoice、receipt、statement)內,但偶爾有文件不屬於任何一種。

結構描述如何處理最好?

- A) 使用已知類型的 enum,外加一個「other」值並搭配自由文字的細節欄位。 [CORRECT]
- B) 使用沒有任何約束的自由文字字串。
- C) 使用只含三種已知類型的 enum,強制擇一。
- D) 每出現一種未預期的類型,就新增一個 enum 值。

為何選 A: enum 擷取常見情況以利下游乾淨處理,而「other」加細節欄位則為長尾提供一個正確、可檢視的歸處。純自由文字字串(B)會喪失 enum 帶來的一致性。封閉的三值 enum(C)會迫使真正的例外被錯誤分類。不斷擴充 enum(D)既被動又難以維護。

問題 88(情境:結構化資料擷取)

情境: 擷取出的輸出符合結構描述,但明細項目的金額有時無法加總為發票上所述的總額——這是 JSON 結構描述無法捕捉的錯誤。

最有效的防護為何?

- A) 加入語意驗證(例如 Pydantic 檢查),並在重試迴圈中把失敗回饋給模型。 [CORRECT]
- B) 用更多欄位型別把 JSON 結構描述收得更緊。
- C) 調低 temperature 以減少算術錯誤。
- D) 既然符合結構描述就接受該輸出。

為何選 A: 結構描述驗證檢查的是形狀與型別,而非跨欄位的業務規則;語意驗證器能捕捉加總不符,而「附回饋的重試」迴圈讓模型得以自我修正。更多欄位型別(B)仍無法表達「明細必須加總為總額」。temperature(C)無法保證算術一致。接受「符合結構描述卻錯誤」的資料(D)等於把錯誤出貨。

問題 89(情境:結構化資料擷取)

情境: 你必須從 50,000 份封存文件擷取欄位。這是一次性的回填工作,沒有延遲需求,而成本很重要。

哪一種機制最合適?

- A) 透過 Message Batches API 提交這項工作。 **[CORRECT]**
- B) 盡可能快地送出 50,000 個個別的同步請求。
- C) 把所有文件串接成單一請求。
- D) 以互動方式逐份手動處理。

為何選 A: Message Batches API 專為大量、非延遲敏感的工作而設計,成本約為一半——非常適合一次性回填。發出 50,000 個同步請求(B)成本更高且壓迫速率限制。串接所有內容(C)會超出上下文視窗並使文件互相糾纏。手動處理(D)無法規模化。

問題 90(情境:結構化資料擷取)

情境: 下游程式碼要求模型的工具輸入每次都完全符合結構描述——不缺必填鍵、不多出屬性。

哪一個選項提供最強的保證?

- A) 在工具上啟用 strict 模式,使輸入在生成時即依結構描述驗證。 **[CORRECT]**
- B) 在系統提示中加上「完全遵循結構描述」。
- C) 事後驗證,並丟棄不符的結果。
- D) 提供一個正確酬載的少樣本範例。

為何選 A: strict 工具使用會在模型生成工具輸入的當下強制套用結構描述,保證酬載相符。提示指示(B)只是建議,並無保證。事後丟棄(C)浪費呼叫且仍需備援。少樣本範例(D)能引導格式,卻不提供保證。

問題 91(情境:結構化資料擷取)

情境: 一份掃描合約過於模糊,無法有把握地判定生效日期,然而結構描述把 `effective_date` 列為必填。

最負責任的行為為何?

- A) 為該欄位回傳 null(或一個旗標)並標示低信心,使其可被導向人工審查。 **[CORRECT]**
- B) 輸出最有可能的日期以滿足必填欄位。
- C) 默默跳過該文件。
- D) 停下整個批次,直到有人介入。

為何選 A: 以低信心標示「未知」,讓人能解決這個真正模糊的案例而不污染資料集(這也是該欄位應可為 null 的原因)。輸出一個看似合理的臆測(B)會注入無聲的錯誤。默默跳過(C)會在毫無痕跡下遺失該筆紀錄。停下整個批次(D)會為了一份壞掃描而擋下數千份良好擷取。

問題 92(情境:結構化資料擷取)

情境: 在信任這條管線之前,你需要知道各欄位的擷取準確度,並為「自動接受 vs. 人工審查」設定信心門檻。

哪一種做法能得到可信的衡量?

- A) 對各欄位評分信心,並以已標註資料集校準,跨類型以分層方式抽樣文件。 [CORRECT]
- B) 對整份文件使用單一的整體信心分數。
- C) 不加查證就相信模型自報的信心。
- D) 抽查少數幾份容易的文件。

為何選 A: 以已標註資料校準的欄位層級評分,能顯示管線在何處可靠,而分層抽樣確保每種文件類型都有代表——使門檻反映真實準確度。單一文件層級分數(B)會掩蓋哪些欄位失敗。未校準的自報信心(C)未必符合現實。抽查容易的案例(D)會得到偏誤、過度樂觀的估計。

情境:代理式 AI 工具

問題 93(情境:代理式 AI 工具)

情境: 某代理必須能發出退款。退款不可逆,且必須在執行前先經過確認/權限步驟把關。

這項能力應如何公開?

- A) 作為專用的 `process_refund` 工具,讓框架能對其把關、驗證並要求確認。 [CORRECT]
- B) 作為模型自行組合的通用 `bash` 能力(例如對退款端點發 `curl`)。
- C) 在系統提示中指示模型退款前一律先詢問。
- D) 信任模型只在適當時才退款。

為何選 A: 專用工具給了框架一個具型別、可攔截的掛鉤,讓它能在這種破壞性、不可逆的動作之前強制執行確認與權限——這是單靠提示無法保證的控制。通用 `bash` 能力(B)是一串不透明的命令字串,框架無法可靠地把關。系統提示指示(C)與純粹信任(D)都不是強制力;模型仍可能略過把關逕行動作。

問題 94(情境:代理式 AI 工具)

情境: 某代理常在應呼叫 `lookup_order` 時呼叫了 `get_customer`。這兩個工具的描述都簡短且相似。

你該先嘗試什麼?

- A) 重寫工具描述,讓每個都清楚說明何時使用,以及與另一個的差異。 [CORRECT]
- B) 在代理前面加一個路由分類器模型。
- C) 移除其中一個工具。
- D) 對所有請求強制把 `tool_choice` 設為 `lookup_order`。

為何選 A: 模型主要依工具描述來選擇工具,因此釐清描述能以最低成本直擊根因。另設分類器(B)為一個用文字即可解決的問題增添延遲與基礎架構。移除工具(C)會喪失所需能力。處處強制 `lookup_order` (D)會破壞那些確實需要 `get_customer` 的正當情況。

問題 95(情境:代理式 AI 工具)

情境: 你正在撰寫那段「決定工具呼叫後代理回合何時完成」的迴圈。

正確的終止訊號為何?

- A) 當 `stop_reason` 為 `tool_use` 時持續,當其為 `end_turn` 時停止。 [CORRECT]
- B) 不論狀態如何,固定迭代次數後停止。
- C) 在助理文字中搜尋「我完成了」之類的字句。
- D) 只要任何工具回傳結果就停止。

為何選 A: `stop_reason` 是 API 明確且可靠的訊號: `tool_use` 表示執行工具並繼續; `end_turn` 表示模型已完成。固定迭代上限(B)不是切斷正當工作就是空轉。搜尋「完成」字句(C)脆弱且易錯。第一個工具結果就停止(D)會讓多步驟任務過早結束。

問題 96(情境:代理式 AI 工具)

情境: 為回答一項請求,代理需要三個彼此獨立、互不依賴結果的查詢(客戶、訂單、庫存)。

最有效率的模式為何?

- A) 在同一回合中平行發出這三個工具呼叫,並在下一則使用者訊息中一併回傳三個結果。 [CORRECT]
- B) 嚴格逐一呼叫,分散在三個回合。
- C) 把三者合併成單一過載的工具。
- D) 請使用者選出最重要的查詢。

為何選 A: 獨立的呼叫可在單一助理回合內平行進行,而把所有 `tool_result` 區塊一併放進單一使用者訊息回傳是受支援的模式——可將往返次數降到最低。逐一呼叫(B)為無相依的工作浪費回合。單一過載工具(C)混淆職責與結構描述。請使用者選擇(D)丟棄了所需資訊。

問題 97(情境:代理式 AI 工具)

情境: 某 `get_account` 工具回傳 40 多個欄位,但代理始終只需要其中五個。在長時間的工作階段中,未使用的欄位不斷堆積並排擠上下文視窗。

最佳的解法為何?

- A) 修改該工具,只回傳代理需要的欄位。 [CORRECT]
- B) 改用更大的模型來擴大上下文視窗。
- C) 叫模型忽略多餘的欄位。

- D) 更頻繁地摘要整段對話。

為何選 A: 在源頭裁減工具輸出,可在每次呼叫都移除浪費的 token——從根源解決。更大的上下文視窗(B)只是以更高成本延後同樣的堆積。叫模型忽略欄位(C)仍要付出把它們帶在上下文中的代價。更頻繁的摘要(D)只治標,且有丟失細節的風險。

問題 98(情境:代理式 AI 工具)

情境: 某工具包裝了一個不穩定的外部 API。有時逾時(值得重試);有時回傳永久性的「找不到」(不值得重試)。目前每種失敗在模型看來都一樣。

工具錯誤應如何傳遞?

- A) 回傳帶有類別與可重試旗標的結構化錯誤,讓模型對暫時性失敗重試、對永久性失敗升級。
[CORRECT]
- B) 對每種失敗都回傳一個通用的「error」字串。
- C) 任何失敗都默默回傳空結果。
- D) 丟棄該工具呼叫並結束回合。

為何選 A: 透過類別與可重試旗標區分暫時性與永久性失敗,讓模型能針對每種情況做出正確的復原決策。通用錯誤(B)抹除了這個區分。無聲的空結果(C)隱藏失敗,並誤導模型以為呼叫成功了。結束回合(D)放棄了可復原的工作。

問題 99(情境:代理式 AI 工具)

情境: 對某個特定的工作流程步驟,代理必須在繼續之前呼叫 `validate_address` 工具——略過是不可接受的。

哪一種機制能強制這一點?

- A) 針對該請求,把 `tool_choice` 設為強制使用 `validate_address` 工具。 [CORRECT]
- B) 在系統提示中加上「一律驗證地址」,並期望它會遵從。
- C) 調低 temperature,讓模型更服從。
- D) 在整個工作階段移除其他所有工具。

為何選 A: `tool_choice` 可要求使用特定工具,保證該步驟一定會呼叫。提示指示(B)並非保證。temperature(C)無法控制工具選擇。在整個工作階段移除其他所有工具(D)是一種粗糙、過於廣泛的變更,會破壞其他每一個步驟。

問題 100(情境:代理式 AI 工具)

情境: 某客服代理遇到一個沒有對應政策的案例,且在數次嘗試後已無法取得進展。

正確的行為為何?

- A) 帶著已蒐集的脈絡叫用 `escalate_to_human` ,讓人接手。 [CORRECT]
- B) 持續以相同工具重試,直到有什麼奏效。
- C) 做出最佳猜測的決定並據以行動。
- D) 在沒有解決也沒有交接的情況下結束對話。

為何選 A: 帶著累積脈絡升級,是代理面對政策缺口或無法取得進展時的既定路徑——把已完成的工作交給人。無止境重試(B)浪費資源並讓使用者受挫。依猜測行動(C)有做出錯誤、甚至不可逆決定的風險。沒有交接就結束(D)等於拋下使用者。

情境:開發者生產力工具

問題 101(情境:開發者生產力工具)

情境: 平台團隊維護一份 4,000 行的內部 API 設計手冊。工程師希望代理在處理 API 程式碼時套用它,但若貼進 CLAUDE.md,它會被載入每一個工作階段——而多數工作階段根本不會碰 API。

這份手冊應如何提供給代理?

- A) 把完整手冊附加到專案的 CLAUDE.md,讓它永遠被載入。
- B) 打包成 Agent Skill(`.claude/skills/`)—— `SKILL.md` 的名稱與描述永遠可見,但完整內容只在任務用得上時才載入。 [CORRECT]
- C) 讓工程師在提示裡自行貼上相關的手冊章節。
- D) 把手冊拆散到不同目錄下的多個 CLAUDE.md。

為何選 B: Skills 實作了漸進式揭露:代理永遠看得到一行描述,只在任務匹配時才拉入完整內容,因此 API 工作階段拿得到手冊,無關的工作階段不付任何代價。把 4,000 行塞進 CLAUDE.md(A)會對每個工作階段的上下文課稅。手動貼上(C)不一致也無法強制。拆散到多個 CLAUDE.md(D)只要碰到那些目錄仍會載入,還讓事實來源碎片化。

問題 102(情境:開發者生產力工具)

情境: 某團隊的 `.claude/` 配置——斜線指令、一個審查 skill、PreToolUse hooks 與 MCP 伺服器設定——已被證明很有價值。另外 40 個儲存庫想要同樣的配置,而且它必須保持有版本、可更新,而不是在各儲存庫各自漂移。

正確的散布機制是什麼?

- A) 把指令、skills、hooks 與 MCP 設定打包成外掛(plugin),讓各團隊從共享的外掛市集安裝。 [CORRECT]
- B) 把 `.claude/` 目錄複製到 40 個儲存庫。
- C) 在 wiki 頁面記錄配置,讓各團隊自行重建。
- D) 壓縮成 zip 丟到團隊聊天頻道。

為何選 A: 外掛的存在正是為了把指令、skills、hooks 與 MCP 設定捆成一個有版本的單位,讓許多儲存庫從單一來源安裝與更新——從結構上根治漂移。複製目錄(B)會把設定分岔成四十份且沒有更新路徑。wiki(C)靠人工重建,容易出錯。聊天室裡的 zip(D)沒有版本,立刻過時。

問題 103(情境:開發者生產力工具)

情境: 工程師接上十多個 MCP 伺服器(議題追蹤、CI、文件、雲端主控台.....),合計約 200 個工具定義。全部預先載入會吃掉一大塊上下文視窗,但一個典型任務用到的工具不到五個。

最佳的修正是什麼?

- A) 移除大多數 MCP 伺服器,只留最常用的兩個。
- B) 把工具文件搬進 CLAUDE.md,然後停用伺服器。
- C) 啟用 MCP 工具搜尋(tool search),讓工具定義延遲載入,任務需要時才按需載入。 [CORRECT]
- D) 換成上下文視窗更大的模型。

為何選 C: 工具搜尋讓整個目錄保持可被發現,同時把完整定義延後到任務真正需要時才載入,砍掉前置的上下文成本又不損失任何能力。移除伺服器(A)是拿能力換空間。CLAUDE.md 裡的文件(B)不是可呼叫的工具。更大的視窗(D)每次請求都更貴,而且仍在為從未用到的定義燒 token。

問題 104(情境:開發者生產力工具)

情境: 工作階段進行到一半,一次橫跨多檔案的大規模改名被發現是錯的。什麼都還沒 commit。工程師想讓工作目錄和對話都回到改名前一刻的狀態,又不想失去這個工作階段更早的成果。

哪個機制做得到?

- A) 倒帶(rewind)到改名前的檢查點,同時還原檔案與對話。 [CORRECT]
- B) 執行 `git reset --hard HEAD` 丟棄變更。
- C) 開一個全新的工作階段,重新解釋任務。
- D) 請代理憑記憶回想每個檔案原本的樣子,再逐一改回去。

為何選 A: Claude Code 的檢查點會隨工作階段推進記錄狀態,倒帶能把檔案與對話一起還原到選定的時點——正是「回到犯錯前一刻」的需求。`git reset --hard` (B)會丟棄所有未 commit 的工作,包括先前正確的編輯,而且對對話狀態毫無作用。新工作階段(C)失去累積的脈絡。憑記憶改回(D)在多檔案規模下不可靠。

問題 105(情境:開發者生產力工具)

情境: 代理要處理兩種截然不同的工作:細膩的架構重構,以及大量機械性雜務(欄位改名、重新產生測試資料)。全部用最深的推理深度執行,讓機械性雜務又慢又貴。

正確的成本/品質控制是什麼?

- A) 把雜務導到較低的 `effort` 設定(困難的重構維持高 effort),讓推理深度對齊任務難度。 [CORRECT]
- B) 把所有請求的 `max_tokens` 砍半。

- C) 全域停用思考,讓每個任務都跑得快。
- D) 在雜務的系統提示裡加上「少想一點」。

為何選 A: effort 旋鈕的存在就是為了按任務在推理深度與速度/成本之間取捨:機械性工作用低 effort 更快更省且不損品質,困難問題保有需要的深度。砍半 `max_tokens` (B)是截斷輸出,不是減少斟酌。全域關閉思考(C)犧牲了真正需要思考的重構。提示措辭(D)比起一級參數是不可靠的控制。

問題 106(情境:開發者生產力工具)

情境: 工作階段中,代理不斷重新發現同一批沒有文件記載的怪癖——某個需要重試的不穩定測試、ARM 機器必加的建置旗標。每個新工作階段都從零開始,工程師一再重複解釋相同的事實。

這些知識應如何持久化?

- A) 依賴工作階段續用(resume),讓一個長壽工作階段裝下一切。
- B) 啟用代理的持久記憶,讓某个工作階段發現的怪癖被記錄下來,在之後的工作階段被喚回。 **[CORRECT]**
- C) 要求工程師在每個新工作階段開頭貼上前一個工作階段的逐字稿。
- D) 加大上下文視窗,讓工作階段能撐更久才重啟。

為何選 B: 記憶(Claude Code 的 auto memory/memory tool 模式)正是為此而生:代理在發現事情時寫下持久筆記,並在未來的工作階段讀回,知識因此累積,不需要任何人手動維護文件。穩定、已有共識的慣例仍屬於 CLAUDE.md——記憶負責的是沿路學到的東西。一個永生的工作階段(A)終會撞上上下文上限,也把其他工程師排除在外。貼逐字稿(C)是手動的,還讓視窗塞滿雜訊。更大的視窗(D)只是延後問題,什麼都沒持久化。

問題 107(情境:開發者生產力工具)

情境: 某任務需要在代理反覆修正失敗的整合測試時,讓開發伺服器持續運行。以一般方式啟動的話,伺服器永不結束,代理的工具呼叫因此永久阻塞,迴圈停擺。

代理應如何執行這個伺服器?

- A) 以背景任務執行,讓伺服器持續運行,代理繼續工作,需要時再查看它的輸出。 **[CORRECT]**
- B) 在前景執行,並設一個很長的逾時。
- C) 乾脆不跑——請工程師另開終端機執行,再把日誌貼進來。
- D) 啟動它,每輪測試後砍掉,下一輪再重啟。

為何選 A: 背景執行正是為永不結束的程序設計的:命令分離執行,代理的迴圈保持自由,輸出在需要時查看。前景呼叫(B)會一路阻塞到逾時把伺服器砍掉為止。人工複製貼上(C)等於放棄自動化。每輪重啟(D)讓每次迭代都付出啟動延遲,還可能使暖狀態失效。

情境:結構化資料擷取

問題 108(情境:結構化資料擷取)

情境: 一個單次呼叫的擷取端點對每份文件回傳一個 JSON 物件——沒有工具迴圈。儘管有「只回覆 JSON」的指令,仍有一小部分回應被包在 markdown 圍欄裡或前面帶著一段文字,解析器因此壞掉。

穩健的修法是什麼?

- A) 在解析前用清理用的正規表達式剝掉 markdown 圍欄與開頭文字。
- B) 加強指令:「除了 JSON 絕對不要包含任何東西」。
- C) 使用結構化輸出(`output_config.format` 搭配 JSON schema),讓回應保證是符合 schema 的有效 JSON。 **[CORRECT]**
- D) 對每個解析不了的回應重試,直到剛好能解析為止。

為何選 C: 請求層級的結構化輸出把「格式良好、符合 schema 的 JSON」變成生成時強制執行的保證(SDK 的 `.parse()` 等輔助函式還會直接回傳驗證過的結果),是消滅這一類失敗,而不是與之共處。正規清理(A)與更嚴厲的措辭(B)只能減少、無法消除破損。盲目重試(D)為從未被保證的輸出多付錢。

問題 109(情境:結構化資料擷取)

情境: 法遵要求每個擷取出的欄位都能追溯到確切的來源段落。團隊在同一個請求同時開啟引用(citations)與結構化輸出——結果發現這兩個功能無法並用。

正確的管線設計是什麼?

- A) 放棄引用,讓模型在一個備註欄位裡自行寫頁碼。
- B) 拆成兩遍:第一遍啟用引用,擷取每個值與其被引用的來源片段;第二遍做結構化,輸出符合 schema 的紀錄。 **[CORRECT]**
- C) 對合併的請求不斷重試,直到兩個功能同時生效。
- D) 放棄結構化輸出,改在下游解析帶引用的文字。

為何選 B: 既然引用與結構化輸出在單一請求內不相容,可靠的設計就是關注點分離:第一遍產出帶著平台實際錨定之引用片段的值;第二遍用結構化輸出鎖定最終形狀。自行回報的頁碼(A)未經驗證——引用的意義正是平台真正錨定的片段。重試一個不被支援的組合(C)不可能成功。解析引用文字(D)把結構化輸出本要消除的脆弱性又帶回來。

問題 110(情境:結構化資料擷取)

情境: 每個擷取請求都夾帶同一份 180 頁的參考手冊(擷取器要查閱的零件型錄),連同那份獨特的文件。管線在每次呼叫時都重新編碼、重新上傳這份手冊。

什麼能消除重複上傳?

- A) 透過 Files API 上傳手冊一次,之後每個請求以檔案 ID 引用它。 **[CORRECT]**
- B) 繼續以 base64 重送手冊,但先壓縮。
- C) 把手冊摘要後改送摘要。
- D) 手動把手冊的關鍵表格貼進系統提示。

為何選 A: Files API 正是為此而生:上傳一次,之後任意數量的請求以 ID 引用——位元組不會每次重送(而這個穩定前綴也天然適合搭配提示快取)。壓縮過的 base64(B)每次呼叫仍在重新上傳。摘要(C)犧牲了擷取器要查閱的細節。手貼表格(D)是真實文件的一份過時、殘缺副本。

問題 111(情境:結構化資料擷取)

情境: 一卷掃描檔案以單一 900 頁 PDF 送達。包含它的請求全數失敗:它超過了文件明載的 PDF 上限(32 MB、≤600 頁)。

正確的處理方式是什麼?

- A) 照送,讓 API 對它能處理的頁面抽樣。
- B) 調高 `max_tokens`,讓請求有更多空間。
- C) 用本機 OCR 把整卷轉成純文字,丟棄頁面影像。
- D) 把整卷拆成符合上限的頁碼區段,逐段擷取,再依頁碼合併結果。 [CORRECT]

為何選 D: PDF 上限是硬性限制,所以必須把整卷切成合規的分段;逐段擷取、按頁合併能保全一切。API 不會對超限文件默默抽樣(A)——請求就是失敗。`max_tokens` (B)管的是輸出長度,不是輸入文件上限。本機 OCR 轉純文字(C)丟掉了原生 PDF 處理所利用的版面與視覺線索,而且在分段就能解決時並無必要。

問題 112(情境:結構化資料擷取)

情境: 財務部門需要在 80,000 份文件的擷取工作開跑前,拿到準確的成本預測。過去用字元數估算的誤差超過 30%。

如何產出可信的預測?

- A) 以「字元數除以四」估算 token。
- B) 抽出分層樣本,送進免費的 token 計數端點,再以精確的 token 數乘上各模型單價。 [CORRECT]
- C) 請模型自行估計每份文件會用多少 token。
- D) 先真的跑完前 5,000 份,再從帳單外推。

為何選 B: `count_tokens` 回傳精確、依模型而定的 token 數,而且免費,因此分層樣本能在花任何錢之前得到精準預測。字元啟發式(A)正是造成 30% 誤差的元兇。模型自估(C)是猜測,不是量測。實跑 5,000 份(D)是用真金白銀去買免費端點本來就提供的資訊。

問題 113(情境:結構化資料擷取)

情境: 一條日內管線在文件抵達時即時擷取欄位;延遲很重要,所以批次不可行。每個請求都以同一段 18K token 的前導(指令+schema+完整範例)開頭,後面接著獨特的文件。輸入 token 佔了帳單大宗。

什麼能在不動品質的前提下砍成本?

- A) 把提示排成「靜態在前」,並在前導之後設快取斷點,讓後續請求以約 0.1 倍價格從提示快取讀取它。 [CORRECT]

- B) 把完整範例從前導裡刪掉。
- C) 把管線搬到 Message Batches API。
- D) 把獨特的文件放到前導之前。

為何選 A: 提示快取按前綴匹配:固定的 18K 前導放前面、其後設斷點,之後每個請求都以大約十分之一的價格讀取它——大幅省錢且品質中性。刪範例(B)拿範例換來的準確度冒險。批次(C)半價,卻違反延遲要求。把變動的文件放前面(D)摧毀共享前綴,讓快取完全失效。

問題 114(情境:結構化資料擷取)

情境: 短文件的擷取準確度很高,但 300 頁的合約裡,埋在文件中段的欄位會被漏掉,或被填入看似合理實則錯誤的值。

最有力的緩解是什麼?

- A) 告訴模型「仔細閱讀中間章節」。
- B) 換成最大輸出更大的模型。
- C) 要求「先引用再擷取」:模型必須先逐字引用支撐每個欄位的確切段落,再輸出由它推導出的值。
[CORRECT]
- D) 調低 temperature。

為何選 C: 在每個值之前強制一段逐字引用,把擷取錨定在真的被取出的文字上:沒有支撐引用的欄位會以缺口浮現,而不是變成瞎編——直接對治 lost-in-the-middle 的失效模式。「仔細讀」(A)只是勸告。輸出大小(B)與中段注意力無關。temperature(D)改變的是變異度,不是錨定。

情境:代理式 AI 工具

問題 115(情境:代理式 AI 工具)

情境: 一個營運代理跨內部系統註冊了約 300 個工具。光是工具定義每次請求就吃掉數萬 token,但任何單一任務只會呼叫五、六個工具。

什麼能保留完整目錄,又免除前置成本?

- A) 把每個工具描述縮成一行乾巴巴的短句。
- B) 使用工具搜尋工具(tool search)搭配延遲載入:未載入的工具仍可被搜尋發現,其定義只在需要時載入。
[CORRECT]
- C) 把代理拆成十個小代理,每個管 30 個工具。
- D) 依賴 1M token 的上下文視窗把定義全吞下去。

為何選 B: 工具搜尋把工具定義從「永遠載入」翻轉成「按需載入」:模型搜尋目錄,只拉進需要的那幾個,上下文保持有償付能力且能力不減。乾巴巴的描述(A)省 token 卻傷害工具選擇——模型是靠描述挑工具的。十個代理(C)是伴隨路由開銷的重型重構。每次請求都為數萬 token 的定義付費(D)正是要消除的成本。

問題 116(情境:代理式 AI 工具)

情境: 一個定價任務要對 500 個 SKU 呼叫 `get_price`,再計算彙總統計。作為普通工具迴圈,這是數百次推理往返,而且每個單價都會落入上下文視窗。

高效率的模式是什麼?

- A) 以平行工具呼叫發出這 500 個呼叫,盡量壓縮輪數。
- B) 調高 `max_tokens` 讓結果放得下。
- C) 每晚預先算好所有價格,貼進提示。
- D) 使用程式化工具呼叫(programmatic tool calling):模型在執行沙箱裡寫程式碼,迴圈遍歷 SKU、叫用工具,只把彙總結果送回對話。 **[CORRECT]**

為何選 D: 程式化工具呼叫把迴圈搬進程式碼:一次往返完成設定,沙箱驅動 500 次工具叫用,只有彙總答案重新進入上下文——同時壓掉往返次數與 token 膨脹。平行工具呼叫(A)減少輪數,但 500 筆結果仍會回進視窗。`max_tokens` (B)是輸出長度,不是上下文壓力。夜間預算(C)對一個即時問題供應過期價格。

問題 117(情境:代理式 AI 工具)

情境: 數百個 CI 代理作業都用存放在祕密管理器裡的長效 `sk-ant -` API key 驗證。安全部門下令消滅靜態憑證:工作負載必須出示綁定自身身分的短效、限定範圍憑證。

什麼能滿足這項要求?

- A) 工作負載身分聯合(Workload Identity Federation, WIF):每個作業以其供應商簽發的 OIDC token(例如來自 GitHub Actions)換取一個數分鐘內到期、受範圍限制的 Anthropic token。 **[CORRECT]**
- B) 每週輪替靜態 API key。
- C) 把 key 搬進 ACL 更嚴的更強 vault。
- D) 把 key 烤進 CI 映像,讓它永不經過網路。

為何選 A: WIF 整個取代了靜態密鑰:工作負載以短效 OIDC JWT 證明自己的身分,換得一個受範圍限制、數分鐘就到期的 token——沒有任何需要產生、輪替或會外洩的長效物。每週輪替(B)縮小但保留了靜態憑證的暴露窗。更好的 vault(C)改善的是一個根本不該存在的祕密的存放方式。把 key 烤進映像(D)是憑證蔓延的最糟示範。

問題 118(情境:代理式 AI 工具)

情境: 某企業希望它的代理只連線到通過安全審核的 MCP 伺服器,而且存取權要在企業身分提供者(Okta)集中決定——而不是由個別開發者逐一點擊各伺服器的 OAuth 同意畫面。

哪個能力實作了這件事?

- A) 在 CLAUDE.md 列出核准伺服器,並指示代理只使用那些。
- B) 在網路防火牆封鎖未核准伺服器的網域。
- C) 企業託管授權(Enterprise-Managed Authorization, EMA):MCP 授權透過 IdP 集中治理,組織固定核准的伺服器集合。 **[CORRECT]**

- D) 讓每位開發者承諾只設定核准的伺服器。

為何選 C: EMA 把 MCP 授權搬進企業身分層:由 IdP 決定哪些使用者與工作負載能用哪些伺服器,核准集合集中管理——具稽核軌跡的確定性治理。CLAUDE.md 清單(A)是提示文字,不是強制力。防火牆封鎖(B)擋得住流量,卻授予不了任何權限,也不管理身分或同意的生命週期。開發者的承諾(D)不是控制。

問題 119(情境:代理式 AI 工具)

情境: 一次 200 步的營運執行已在源頭讓工具輸出保持精簡,但數百個來自早已完成步驟的 `tool_result` 區塊仍積在視窗裡。那些舊結果再也不會被引用。

什麼能在執行中途回收視窗?

- A) 上下文編輯(context editing):自動清除超過門檻的過時工具結果(與過時思考),同時保留最近的回合。**[CORRECT]**
- B) 每 50 步重啟工作階段並重新交代任務。
- C) 換成可用的最大上下文視窗。
- D) 調低 `effort` 讓回應更短。

為何選 A: 上下文編輯正是為長迴圈而生:剝除不再需要的工具結果與思考區塊,同時保留最近的工作集,執行得以帶著有償付能力的視窗繼續。重啟(B)每 50 步就付一次重新交代的成本,還會流失細節。更大的視窗(C)以更高價格延後同樣的堆積。`effort`(D)調的是推理深度,不是歷史大小。

問題 120(情境:代理式 AI 工具)

情境: 一個自主代理偶爾會陷入沒有產出的迴圈,在有人注意到之前燒掉數十美元的 token。團隊想要一個整趟執行都無法超越的硬性花費上限。

哪個控制做得到?

- A) 在每個請求上把 `max_tokens` 設低。
- B) 設定任務預算(task budget):整趟執行的總 token 預算,由伺服器端追蹤,用罄即終止執行。**[CORRECT]**
- C) 在系統提示加上「花費不要超過 20 美元」。
- D) 盯著用量儀表板,手動取消失控的執行。

為何選 B: 任務預算在伺服器端對整趟執行的 token 花費設上限——一道從結構上終結失控迴圈的硬限制。`max_tokens` (A)只限制單一回應,不限制迴圈;數百個小回應照樣累積。提示指令(C)是勸告——模型甚至看不到自己真實的累計花費。人工監看(D)正是這裡要修掉的「在有人注意到之前」的失敗。

問題 121(情境:代理式 AI 工具)

情境: 團隊想要一個有狀態的代理,具備沙箱化程式執行、有版本的設定,以及從安全儲存注入的 MCP 憑證——但不想自行建置或營運迴圈、容器或狀態層。

哪個平台選擇最合適?

- A) 在自管 VM 上跑自建代理迴圈。
- B) Message Batches API。
- C) 在每位工程師的筆電跑客戶端腳本,共用一把 API key。
- D) Managed Agents(託管代理):定義一次 Agent(有版本的設定),每次執行開一個 Session,憑證存放在 vault、於 egress 注入。 **[CORRECT]**

為何選 D: Managed Agents 是託管層:Anthropic 負責跑迴圈與沙箱容器,Agent 是伺服器端有版本的定義、由每個 Session 引用,vault 在 egress 替換憑證——恰好是團隊不想擁有的那層營運面。自管 VM 上的自建迴圈(A)就是那份擁有權。批次(B)是非同步的單發訊息,不是有狀態代理。共用 key 的筆電腳本(C)無託管、無沙箱、也無從稽核。

實作練習

練習 1:具升級邏輯的多工具代理

目標: 設計一個整合工具、具結構化錯誤處理與升級機制的代理迴圈。

步驟:

1. 定義 3–4 個 MCP 工具並附上詳細描述(包含兩個相似的工具以測試工具選擇)
2. 實作一個檢查 `stop_reason ( "tool_use" / "end_turn" )`的代理迴圈
3. 加入結構化的錯誤回應: `errorCategory`、`isRetryable`、描述
4. 實作一個攔截器 hook,封鎖超過門檻的操作並轉送至升級流程
5. 以多面向的請求進行測試

涵蓋領域: 1(代理架構)、2(工具與 MCP)、5(上下文與可靠性)

練習 2:為團隊開發設定 Claude Code

目標: 設定 CLAUDE.md、自訂命令、特定路徑規則,以及 MCP 伺服器。

步驟:

1. 建立一個含通用標準的專案層級 CLAUDE.md
2. 在 `.claude/rules/` 建立帶有 YAML frontmatter 的檔案,對應不同的程式碼範圍(`paths: ["src/api/**/*"]`、`paths: ["**/*.test.*"]`)
3. 在 `.claude/skills/` 下建立一個專案技能,設定 `context: fork` 與 `allowed-tools`
4. 在 `.mcp.json` 中設定一個帶環境變數的 MCP 伺服器,並在 `~/.claude.json` 中加上個人覆寫設定
5. 在不同複雜度的任務上測試規劃模式與直接執行的差異

涵蓋領域: 3(Claude Code 設定)、2(工具與 MCP)

練習 3:結構化資料擷取管線

目標: JSON 結構描述、用於結構化輸出的 `tool_use`、驗證／重試迴圈、批次處理。

步驟:

- 定義一個帶 JSON 結構描述的擷取工具(必填／選填欄位、含 "other" 的列舉、可為 null 的欄位)
- 建立一個驗證迴圈:發生錯誤時,帶上文件、錯誤的擷取結果,以及具體的驗證錯誤進行重試
- 為不同結構的文件加入少樣本範例
- 透過 Message Batches API 進行批次處理:100 份文件,藉由 `custom_id` 處理失敗的項目
- 轉送至真人處理:欄位層級的信心分數、文件類型分析

涵蓋領域: 4(提示工程)、5(上下文與可靠性)

練習 4:設計與除錯多代理研究管線

目標: 子代理編排、上下文傳遞、錯誤傳播,以及附帶來源追蹤的彙整。

步驟:

- 一個協調者搭配 2 個以上的子代理(`allowedTools` 包含 "Task",上下文在提示中明確傳遞)
- 在單一回應中透過多個 `Task` 呼叫平行執行子代理
- 要求子代理產出結構化輸出:主張、引述、來源 URL、發布日期
- 模擬子代理逾時:將結構化的錯誤上下文回傳給協調者,並以部分結果繼續執行
- 以衝突資料進行測試:保留兩個數值並標註出處;將已確認與有爭議的發現分開

涵蓋領域: 1(代理架構)、2(工具與 MCP)、5(上下文與可靠性)

附錄:技術與概念

技術	重點面向
Claude Agent SDK	AgentDefinition、代理迴圈、 <code>stop_reason</code> 、hooks(PostToolUse)、透過 Task 生成子代理、 <code>allowedTools</code>
模型上下文協定(MCP)	MCP 伺服器、工具、資源、 <code>isError</code> 、工具描述、 <code>.mcp.json</code> 、環境變數
Claude Code	CLAUDE.md 階層、帶 glob 模式的 <code>.claude/rules/</code> 、 <code>.claude/commands/</code> 、含 SKILL.md 的 <code>.claude/skills/</code> 、規劃模式、 <code>/compact</code> 、 <code>--resume</code> 、 <code>fork_session</code>
Claude Code CLI	用於非互動模式的 <code>-p / --print</code> 、 <code>--output-format json</code> 、 <code>--json-schema</code>
Claude API	帶 JSON 結構描述的 <code>tool_use</code> 、 <code>tool_choice</code> ("auto"/"any"/強制)、 <code>stop_reason</code> 、 <code>max_tokens</code> 、系統提示

Message Batches API	節省 50%、最長 24 小時視窗、 <code>custom_id</code> 、不支援多輪工具呼叫
JSON Schema	必填與選填、可為 null 的欄位、列舉型別、"other" + 細節、嚴格模式
Pydantic	結構描述驗證、語意錯誤、驗證／重試迴圈
內建工具	Read、Write、Edit、Bash、Grep、Glob — 用途與選用標準
少樣本提示	針對不明確情境的目標式範例、對新模式的泛化
提示鏈接	循序分解為聚焦的多個階段
上下文視窗	token 預算、漸進式摘要、「迷失在中間」、暫存檔(scratchpad)
工作階段管理	恢復、 <code>fork_session</code> 、具名工作階段、上下文隔離
信心校準	欄位層級評分、在已標註資料集上的校準、分層抽樣

範圍外主題

以下相鄰主題**不會**出現在考試中：

- 微調 Claude 模型或訓練自訂模型
- Claude API 驗證、計費或帳戶管理
- 在特定程式語言或框架中的詳細實作(超出工具／結構描述設定所需的範圍)
- 部署或託管 MCP 伺服器(基礎架構、網路、容器編排)
- Claude 的內部架構、訓練程序或模型權重
- Constitutional AI、RLHF 或安全訓練方法論
- 嵌入模型或向量資料庫的實作細節
- 電腦使用(瀏覽器自動化、桌面互動)
- 影像分析能力(Vision)
- 串流 API 或 server-sent events
- 速率限制、配額或詳細的 API 成本計算
- OAuth、API 金鑰輪替或驗證協定細節
- 雲端供應商專屬設定(AWS、GCP、Azure)
- 效能基準測試或模型比較指標
- 提示快取的實作細節(僅需知道其存在)
- token 計數演算法或 tokenization 細節

準備建議

1. 使用 Claude Agent SDK 建構一個代理 — 實作一個完整的代理迴圈,包含工具呼叫、錯誤處理與工作階段管理。練習子代理與明確的上下文傳遞。
2. 為真實專案設定 Claude Code — 運用 CLAUDE.md 階層、`.claude/rules/` 中的路徑專屬規則、搭配 `context: fork` 與 `allowed-tools` 的技能,以及 MCP 伺服器整合。
3. 設計並測試 MCP 工具 — 撰寫能區分相似工具的描述、回傳帶有類別與重試旗標的結構化錯誤,並針對不明確的使用者請求進行測試。
4. 建構一個資料擷取管線 — 使用搭配 JSON 結構描述的 `tool_use`、驗證/重試迴圈、可選/可為 null 的欄位,以及透過 Message Batches API 的批次處理。
5. 練習提示工程 — 為不明確的情境加入少樣本範例、明確的審查標準,以及用於大型程式碼審查的多遍架構。
6. 研讀上下文管理模式 — 從冗長的輸出中擷取事實、使用暫存檔(scratchpad),並將探查工作委派給子代理以因應上下文限制。
7. 理解升級與人在迴路(human-in-the-loop) — 何時該升級(政策缺口、使用者明確要求、無法取得進展)以及以信心為基礎的路由工作流程。
8. 在正式考試前先做一份模擬考。它使用相同的情境與格式。

附錄：完整 Claude 應用全景圖（2026）

一份全景參考，涵蓋 Claude 能做的一切以及它在整個網際網路上的使用方式，內容截至 2026 年。本附錄**超出考試範圍**——其目的是讓你建立一個完整的心智模型，理解這張認證所處的整個 Claude 平台。定價與模型 ID 會變動；請務必對照文末連結的官方文件確認。

1. Claude 模型家族

除 Haiku 外，目前所有模型皆具備 1M token 的上下文視窗。價格以**每百萬 token（MTok）**美元計，為標準層級；批次處理為 5 折，提示快取讀取約 0.1x。

模型	模型 ID	上下文	最大輸出	輸入 \$/MTok	輸出 \$/MTok	定位
Claude Fable 5	<code>claude-fable-5</code>	1M	128K	\$10	\$50	最強的廣泛發布模型；最艱難的推理＋長程代理工作。思考恆常開啟；安全分類器可能拒絕。

Claude Mythos 5	<code>claude-mythos-5</code>	1M	128 K	\$10	\$50	與 Fable 5 相同，但對核准組織解除雙重用途防護——Project Glasswing 合作夥伴（資安）加上生物領域的信任存取計畫；並規劃更系統化的申請管道。
Claude Opus 4.8	<code>claude-opus-4-8</code>	1M	128 K	\$5	\$25	旗艦 Opus——多數高要求工作的預設；頂尖的自主代理、知識工作與記憶能力。
Claude Opus 4.7	<code>claude-opus-4-7</code>	1M	128 K	\$5	\$25	上一代 Opus；強大的代理＋視覺＋記憶。
Claude Opus 4.6	<code>claude-opus-4-6</code>	1M	128 K	\$5	\$25	較舊的 Opus；自適應思考、128K 輸出。
Claude Sonnet 5	<code>claude-sonnet-5</code>	1M	128 K	\$3	\$15	速度／智慧最佳平衡，適合大量生產用途。導入期 \$2 ／\$10 至 2026-08-31。
Claude Haiku 4.5	<code>claude-haiku-4-5</code>	200 K	64K	\$1	\$5	最快、最便宜；適合簡單／低延遲任務與廉價子代理。

- 使用精確 ID，切勿用帶日期後綴的變體（例如 `claude-opus-4-8`，而非 `claude-opus-4-8-20xxxxxx`）。來源：[模型總覽](#)、[定價](#)。
- 即時查詢：Models API 回傳每個模型的上下文視窗（`max_input_tokens`）、輸出上限（`max_tokens`）與 `capabilities` 樹——`GET /v1/models/{id}`。
- 思考與努力度依層級而異：Fable 5 / Opus 4.8 / 4.7 拒絕 `budget_tokens`——請改用 `thinking: {type:"adaptive"}` + `output_config.effort`（`low` → `max`，4.7/4.8 另有 `xhigh`）。舊款模型仍使用 `budget_tokens`。
- Sonnet 5 遷移須知：Sonnet 5 採用較新的 tokenizer（Opus 4.7+ / Fable 5 一系）——同樣文字產生的 token 比 4.7 之前的模型**多約 30%**，因此估算成本或判斷是否放得下前，請先用 `count_tokens` 重新量測。自適應思考預設開啟；非預設值的 `temperature` / `top_p` / `top_k` 與手動 `budget_tokens` 思考都會回傳 400；且 Sonnet 5 不提供 Priority Tier。來源：[平台發行說明——2026-06-30](#)。

2. 使用 Claude 的各種方式

2a. Claude 應用程式（網頁・桌面・行動）

面向消費者／專業用戶的產品，網址為 [claude.ai](#)（另有原生 macOS/Windows 桌面版與 iOS/Android 應用）。主要功能：

功能	作用
Projects（專案）	持久工作區，具備共享知識、自訂指令，以及鎖定於某項工作的對話歷史。

Artifacts	生成內容的即時側欄（程式碼、文件、圖表、 可執行的小應用／React ），可反覆迭代並分享／發布。
Files（檔案）	上傳 PDF、試算表、圖片、程式碼；Claude 在對話中讀取並分析。
Memory（記憶）	Claude 跨對話記住情境與偏好（依專案記憶）。
Web Search（網路搜尋）	帶引用的即時網路結果，內嵌於答案中。
Connectors（連接器）	以 MCP 為基礎的外部應用／資料整合（Google Drive、GitHub、Notion、Box、Slack，以及更廣的 連接器目錄 ）。
Skills（技能）	按需載入的任務專長（如 xlsx/pptx/docx/pdf 製作）。
程式執行／分析	沙箱 Python，用於資料分析、圖表生成、檔案建立。

版本：Free、Pro、Max、**Team** 與 **Enterprise**（SSO、稽核、擴大上下文、管理控制）。垂直方案：
[Claude for Education](#)（蘇格拉底式「學習模式」、Canvas LMS）、[Claude for Life Sciences](#)
（Benchling/PubMed/10x 連接器）、以及 **[Claude Science](#)**（2026 年 6 月 30 日推出——面向生物／化學的代理式科學研究平台：60+ 科學資料庫連接器、蛋白質結構預測與研究工作流程自動化）。

2b. 瀏覽器中的 Claude

Claude Chrome 擴充功能讓 Claude 能在瀏覽器分頁中觀看並操作——讀取頁面、填寫表單、點擊，並以代理身分完成多步驟網頁任務（研究預覽階段的「代理式瀏覽」能力，正向較高層級推出）。這是 **API 電腦使用（computer use）** 工具的消費者版親戚。見 anthropic.com/claude-in-chrome。

2c. Claude Code

Anthropic 的代理式編碼工具——可在終端機、IDE 與雲端執行；由 Claude 原生驅動。[儲存庫](#) · [文件](#)。

介面

- **終端機 CLI**（`claude`）——主要介面。
- **IDE 擴充功能**——VS Code、JetBrains；另透過 ACP（Zed、JetBrains）與 Agent HQ（VS Code）的第三方託管。
- **雲端／非同步代理**與用於 CI 與背景任務的 **GitHub action**。
- 用於啟動與檢視執行的**網頁／行動**工作階段介面。

主要功能群組

群組	重點
專案記憶	<code>CLAUDE.md</code> 階層、 <code>@path</code> 匯入、 <code>.claude/rules/</code> 。
可擴充性	自訂斜線指令、 Skills （ <code>.claude/skills/</code> ）、 子代理 、 hooks （PreToolUse/PostToolUse 等）、 外掛 。
工具	內建：Read、Write、Edit、Bash、Grep、Glob、WebFetch/WebSearch；另含 MCP 伺服器與連接器 。

工作流 程	規劃模式、 <code>/compact</code> 、 <code>/memory</code> 、 <code>/goal</code> 、工作階段分叉/續接、權限把關、待辦追蹤。
設定	<code>settings.json</code> （權限、環境、hooks）、努力度/模型選擇、MCP 設定。

2d. Claude Cowork

Claude Cowork 把 Claude Code 的代理式引擎帶進**知識工作**——它在 **Claude Desktop** 中執行（不需終端機），為非開發者端到端完成多步驟任務：成天與文件、資料與檔案為伍的研究人員、分析師、營運、法務與財務團隊。架構與 Claude Code 相同（蒐集脈絡 → 行動 → 驗證，並以子代理扇出），只是重新包裝給不寫程式的人。

- **本機檔案存取**——讀寫你的本機檔案、資料夾與桌面應用程式，跨來源綜整資訊，無需你逐步協調。
- **子代理協調**——將任務拆成平行工作流，是 §26.2 編排的桌面版親戚。
- **專業產出**——含可運作公式的 Excel 活頁簿、PowerPoint 簡報等產物，而非僅是聊天文字。
- **供應範圍**——所有付費方案，透過 Claude 桌面應用程式。[文件](#)。

架構師重點：代理式迴圈**並非**編碼專屬。Cowork 就是 Claude Code 執行的同一個迴圈，只是對準試算表與報告而非程式碼儲存庫——這最能說明「代理」是一種通用的執行模式，而非開發者專屬功能。

2e. Claude Tag

Claude Tag 讓 Claude 成為**共享的團隊成員**，起點在 **Slack**。在頻道中以自然語言 `@Claude` 提出請求；它會把工作拆成數個階段，以其連接的工具逐一執行，再於討論串中回覆產出的內容。

- **天生多人協作**——每個頻道一個 Claude，由**所有人**共享：任何人都能看到它在做什麼，並接續同事未完成的部分（不同於私人一對一對話）。
- **記憶與脈絡**——記住其所在頻道的相關資訊，並能規劃未來的任務。
- **環境感知（ambient）模式**——啟用後，會主動從其頻道與連接工具中，浮現它認為你會需要的資訊。
- **代理身分**——Tag 搭上了新興的**代理身分存取模型**：代理擁有自己的團隊層級身分與權限，而非借用某個人的身分。在 Anthropic，產品團隊約 65% 的程式碼如今透過其內部的 Claude Tag 產出。[文件](#)。

2f. 開發者平台 / API

一切都透過單一端點：`** POST /v1/messages **`。工具與輸出約束是此單一端點的功能，並非各自獨立的 API。[平台文件](#) · [Console](#)。

- **SDK**：Python、TypeScript、Java、Go、Ruby、C#、PHP（+ `ant` CLI）。支援端點：**Batches**、**Files**、**Token Counting**、**Models**、**Skills**。
- **依層級分介面**：單次 LLM 呼叫 → 工作流程（API + 工具使用）→ 自訂代理（你自己的迴圈）→ **Managed Agents**（Anthropic 執行迴圈並託管沙箱）。見 §4。

2g. 雲端供應商（對等性說明）

供應商	模型 ID	說明
-----	-------	----

Claude Platform on AWS	裸 ID (<code>claude-opus-4-8</code>)	由 Anthropic 營運；與第一方同日對等，AWS IAM + Marketplace 計費，SigV4。
Amazon Bedrock	帶 <code>anthropic.</code> 前綴	由 AWS 營運；功能為子集；FedRAMP High / DoD IL4-5。無批次、網頁擷取、程式執行、Managed Agents、Files API。
Google Vertex AI	裸 ID (快照用 <code>@</code> 版本)	GCP IAM/計費。網頁搜尋僅基本版；無網頁擷取/程式執行/批次/Files/Managed Agents。
Microsoft Foundry	裸 ID	多數功能為 beta ；可作為 Foundry Agent Service 的推理核心並支援 MCP。

對等性概念法則：第一方 API 與 Claude Platform on AWS 為完整介面。Bedrock/Vertex 為模型推理+工具使用（以你自己的迴圈建構代理）。Foundry 以 beta 鏡像了大部分介面。唯一真實來源是[平台可用性表](#)。

3. 核心能力

能力	摘要	文件
長上下文 (1M)	標準定價下最多 1M 輸入 token (Haiku 為 200K) —— 整個程式庫、長文件集、多代理對話紀錄。	context - windows
視覺與 PDF	原生支援圖片 (base64/URL/檔案) 與 PDF (32MB / ≤600 頁)；Opus 4.7+ 支援高解析視覺 (長邊達 2576px)。	vision · pdf
自適應思考+努力度	<code>thinking:{type:"adaptive"}</code> 讓 Claude 自行決定思考深度並在工具呼叫間穿插思考； <code>output_config.effort</code> (<code>low</code> → <code>max</code> 、 <code>xhigh</code>) 權衡品質與成本。	adaptive-thinking · effort
工具使用	使用者定義工具 (JSON schema)、 <code>tool_choice</code> 、平行呼叫、嚴格模式、SDK tool runner ，以及程式化工具呼叫 (Claude 從程式執行內部呼叫工具)。	tool-use
伺服器工具	由 Anthropic 託管、無需用戶端迴圈：網頁搜尋 / 網頁擷取 (<code>_20260209</code> ，含動態過濾)、程式執行、工具搜尋 (BM25/正規表示式)、 advisor 。	code-execution
結構化輸出	<code>output_config.format</code> (JSON schema) 與 <code>strict:true</code> 工具保證可解析輸出； <code>messages.parse()</code> 自動驗證。	structured-outputs

提示快取	前綴比對快取；讀取約 0.1×，寫入 1.25×（5 分）／2×（1 小時）。自動或手動斷點（最多 4 個）。以 <code>max_tokens:0</code> 預熱。	prompt-caching
批次 (Batches)	非同步、 5 折成本 ；每批最多 10 萬筆請求；結果約 1 小時內（最長 24 小時）。以 <code>custom_id</code> 配對（順序不定）。	batch-processing
引用 (Citations)	對每份文件設 <code>citations:{enabled:true}</code> 會產生帶字元/頁碼位置的引用片段（與結構化輸出不相容）。	citations
Skills	以資料夾為基礎（ <code>SKILL.md</code> ）、漸進揭露的任務專長；預建（xlsx/docx/pptx/pdf）＋透過 Skills API 自訂。	skills
上下文管理	壓縮 (Compaction) （接近上限時摘要）與 上下文編輯 （清除過時的工具結果/思考），用於長時間執行。	compaction
記憶工具	<code>memory_20250818</code> ——Claude 讀寫 <code>/memories</code> 目錄並跨工作階段保存（後端由你負責）。	memory-tool
驗證	靜態 API key（ <code>sk-ant-...</code> ），或 Workload Identity Federation (WIF，工作負載身分聯合，2026 年正式上線) ——工作負載在 <code>POST /v1/oauth/token</code> 以自有身分供應商（AWS、GCP、Microsoft Entra ID、GitHub Actions、Kubernetes、SPIFFE、Okta）簽發的短期 OIDC JWT，換取一個以 服務帳號 身分運作、僅數分鐘有效且受範圍限制的 Anthropic token。沒有需要產生、輪替或可能外洩的靜態密鑰；涵蓋所有端點、各 SDK 與 Claude Code。	workload-identity-federation

4. 建構代理

三種建構方式，交給 Anthropic 的程度逐步遞增：

自訂代理 (Claude API + 工具使用)

由你託管運算並執行迴圈（或使用 SDK **tool runner**）。彈性最大；當你需要自己的執行環境、核准把關或自訂日誌時最為適合。見 [agent-design](#)。

Managed Agents (Anthropic 執行迴圈並託管沙箱)

由伺服器管理的有狀態代理。**必經流程**：Agent（一次）→ Session（每次執行）。[Managed Agents 文件](#)。

概念	角色
Agent （ <code>/v1/agents</code> ）	持久、具 版本 的設定：模型、系統提示、工具、MCP 伺服器、技能。建立一次，以 ID 引用。

Session (/v1/sessions)	引用某 agent + environment 的有狀態執行；產生 SSE 事件串流 。
Environment (/v1/environments)	容器 的範本（雲端或自架、網路政策）。
Container（容器）	工具執行的隔離工作區（bash、檔案操作、程式）。迴圈在 Anthropic 的協調層執行。

附加項目：**vaults**（MCP／密鑰憑證，於出站時替換）、**memory stores**（跨工作階段持久化）、**outcomes**（評分準則「迭代→評分」迴圈）、**multiagent** 協調者/執行緒、**排程部署**（cron）、**webhooks**。

Agent SDK

****Claude Agent SDK****（Python + TypeScript；前身為 Claude Code SDK）開放了與驅動 Claude Code 相同的代理迴圈、工具執行、上下文管理、子代理、hooks 與 Skills 系統——供你建構自己的自主 Claude 代理。

MCP——模型上下文協定

連接模型與工具／資料的開放標準。modelcontextprotocol.io。

形式	內容
Connectors（連接器）	Claude 應用程式中經審核、以 OAuth 為基礎的 MCP 整合（ 目錄 ）。
MCP 伺服器	開放工具/資源/提示的程式（本機 stdio 或遠端 Streamable-HTTP）。
MCP connector（API）	<code>mcp_servers</code> + <code>mcp_toolset</code> 讓 Messages API 直接呼叫遠端伺服器（beta）。
隧道 / 遠端	託管的遠端伺服器（如 <code>mcp.stripe.com</code> 、 <code>mcp.linear.app</code> ），透過 HTTP 搭配 OAuth 連線。

5. 整個網際網路上的 Claude 生態系

5a. 第三方編碼工具

工具	類別	Claude 使用方式
Cursor	AI 程式編輯器	可在代理對話、編輯、自動完成中選用 Sonnet/Opus。
Windsurf	代理式 IDE	Cascade 代理執行 Sonnet/Opus（自帶金鑰）。
GitHub Copilot	IDE 助理	模型選單中提供 Claude Sonnet/Opus。
VS Code（Agent HQ）	編輯器	託管官方 Claude Agent SDK 框架。
Zed · JetBrains	編輯器/IDE	透過 Agent Client Protocol（ACP）原生支援 Claude + Claude Code。

Cline · Roo Code · Kilo Code	開源 VS Code 代理	以你的 Anthropic 金鑰自主進行多檔編輯。
Sourcegraph Cody · Continue · Tabnine · Augment	知曉程式庫的助理	Claude 作為可選用／預設 LLM。
Aider · Warp	終端機	CLI 結對程式設計／託管 Claude Code。
Replit · Bolt.new · Devin	應用建構器／自主軟體工程師	以 Claude 進行完整應用生成與長程 PR。

5b. 使用 Claude 的其他應用

- 生產力：[Notion](#)、[Slack](#)、[Raycast](#)、[Asana](#)、[Box](#)。
- 搜尋／問答引擎：[Perplexity](#)、[Quora Poe](#)、[DuckDuckGo Duck.ai](#)。
- 瀏覽器：[Brave Leo](#)、[Perplexity Comet](#)。
- 設計／內容：[Canva](#)。
- 客戶支援：[Intercom Fin](#)、[Zendesk](#)。
- 資料／語音：[Snowflake Cortex](#)、[Amazon Alexa+](#)。

5c. MCP 伺服器生態系

- 登錄/目錄：[官方 MCP Registry](#)、[參考伺服器 monorepo](#)、[GitHub MCP Registry](#)、[Anthropic Connectors](#)、社群 [awesome-mcp-servers](#)。
- 參考伺服器（活躍）：[Filesystem](#)、[Git](#)、[Fetch](#)、[Memory](#)、[Sequential Thinking](#)、[Time](#)、[Everything](#)。
- 官方第三方：[GitHub](#)、[Stripe](#)、[Cloudflare](#)、[Sentry](#)、[Playwright \(Microsoft\)](#)、[Notion](#)、[Atlassian](#)、[Linear](#)、[Postgres MCP Pro](#)。
- 已封存的參考（已被取代）：[Slack](#)、[Google Drive](#)、[PostgreSQL](#)（唯讀）、[Puppeteer](#)（→ [Playwright](#)）、[GitLab](#)、[SQLite](#)。

5d. 代理框架

框架	語言	Claude 整合
LangChain	Py/TS	<code>ChatAnthropic</code> ——工具、串流、自適應思考、快取、內建工具。
LlamaIndex	Py	RAG/代理、結構化輸出、引用、token 計數。
CrewAI · AutoGen · AG2	Py	以 Claude 進行多代理協調。
Pydantic AI	Py	型別化代理；內建網頁搜尋、思考、MCP。
Vercel AI SDK · Mastra	TS	統一介面＋ Agent 抽象；Mastra 封裝 Agent SDK。
Strands · Google ADK	Py/TS/Java/Go	模型驅動 SDK，支援 Claude（直連＋ Bedrock/Vertex）。
Claude Agent SDK	Py/TS	官方——以函式庫形式提供 Claude Code 引擎。

5e. 產業使用案例

軟體工程：[Cursor](#)、[Sourcegraph](#)、[Replit](#)——以 Claude 進行代理式編碼。

資安（鑑於本認證的資安架構師讀者，獨立成節）：

組織	用途
eSentire	以 Claude（Bedrock）進行 SOC 威脅調查——在 1,000 件調查中與資深分析師達約 95% 一致；數天→數分鐘。
Anthropic 威脅情報	偵測並瓦解首起公開報導的 AI 協調網路間諜行動（GTG-1002）。
Project Glasswing （CrowdStrike、AWS、Google、Microsoft、NVIDIA）	防禦型 AI 掃描器，透過對程式碼推理找出並修補漏洞；強化關鍵程式庫。
HackerOne	Hai 代理基於 Sonnet 4.5——漏洞接收時間 -44%、準確度 +25%。
Snyk	在其 AI 安全平台中納入 Claude，涵蓋程式碼、相依套件、容器、AI 產物。

注意： Claude 的安全分類器（尤其在 Fable 5 上）針對攻擊性網路與生物內容，可能會**拒絕**請求。正當的防禦性資安工作可能誤觸偽陽性——架構師應規劃拒絕處理（伺服器端 `fallbacks` / 回退額度退至 Opus 4.8），並在 Opus 層級模型上執行資安工具。

其他垂直領域： 法律——[Harvey](#)、[Robin AI](#)。醫療／生命科學——[Commure](#)、[Banner Health](#)、[Sanofi](#)。金融——[NBIM](#)、[Bridgewater](#)。客戶服務——[Intercom](#)。教育——[Claude for Education](#)。內容——[Canva](#)。

6. 官方文件與延伸資源

主題	連結
平台文件（API、build-with-claude、agents-and-tools）	https://platform.claude.com/docs
模型總覽與定價	https://platform.claude.com/docs/en/about-claude/models/overview · https://platform.claude.com/docs/en/pricing
Claude Code	https://code.claude.com/docs · https://github.com/anthropics/claude-code
Claude Agent SDK	https://code.claude.com/docs/en/agent-sdk/overview
Managed Agents	https://platform.claude.com/docs/en/managed-agents/overview
模型上下文協定（MCP）	https://modelcontextprotocol.io · https://registry.modelcontextprotocol.io
連接器目錄	https://claude.com/connectors
Console（金鑰、用量、工作區）	https://console.anthropic.com

客戶案例	https://claude.com/customers
新聞與研究	https://www.anthropic.com/news
服務狀態	https://status.anthropic.com